《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第一章：时钟的房间——思想实验

摘要

设想一个封闭的房间：里面有多个时钟，房间里的人能完整读出每一个钟面，却没有任何独立于时钟的通道与外部世界接触。门外有人问 “现在几点”。

他拥有全部读数，却不知道任一读数与真实时间之间的映射关系——即不知道面前的时钟是准是快、偏差多少。这就是 “时钟的房间” 思想实验（the Clock Room）所刻画的认识论困境。

该思想实验的核心论断是：认知者能否据读数推断真实状态，取决于对映射函数（π）的可靠约束，而不能仅由读数的多少保证。当映射完全未知、候选映射没有先验约束且缺乏独立校准时，任意多的读数仍不能排除任何候选真实状态。用读数反推映射、再用反推出的映射解释读数，可以形成内部自洽的关系网，却不能仅凭这种自洽确认与外部真实的对齐；即使映射已知，唯一恢复还取决于映射本身是否保留了所需的状态差异。

为精确刻画这种结构性不对齐，本书引入纤维（fiber）概念工具：一个读数所兼容的全部可能真实状态的集合。在此工具下，纤维非单点——即一个读数与不止一种真实兼容——是房间困境的几何化表述。纤维框架进一步识别出三层递进的不可逆：映射完全未知且候选映射无先验约束时，相容状态集合为全集；已有先验约束则可能使其缩小（信息缺失）；当读数反过来改写映射本身时，既有校准约束面临持续失效的压力（动态腐蚀）；在通常的欧氏空间或有限维流形条件下，从高维真实状态空间到低维观测空间的连续映射不可能对全部真实状态保持单射（本体论降维）。

冯 • 诺依曼自述其关于绝对数学真理的观点 “接连改变了三次”，这一思想经历为这一困境提供了历史上的结构类比：这位 20 世纪最精密的形式系统建造者曾支持用有限主义方法证明古典数学一致性的计划，而后重新评价了绝对数学真理的根据。这一经历涉及证明方法的限制，不与时钟房间的状态不可确定性等同。映射行为不仅产生读数，也反过来重塑认知者本身的存在方式——当人把自己的行动节律交给时钟时，他从 “在时间中存在” 滑向了 “在时钟中反应”。同一结构在当代人工智能（Artificial Intelligence，AI）对齐问题中再次出现，构成 “多读数—未知映射” 困境的当代版本。

读数、映射、真实是三个不同的认识论范畴：读数不等于真实，多读数不等于多知识；此外，映射行为本身还会改变认知者与真实的关系。

关键词

时钟的房间；映射函数；纤维；三层不可逆；校准；冯·诺依曼

读前说明：关于“纤维”一词

本章 §3 将引入一个数学概念——“纤维”（fiber）。本章仅取其直觉内核：

> **纤维 = 一个读数兼容的全部可能真实。**

举个例子。墙上有一个圆形的影子。墙后面可能是一个球，可能是一个圆盘，可能是一个圆柱。这个影子（读数）没有告诉观测者墙后到底是哪一个。所有能投出这个影子的物体的集合，就是该影子的“纤维”。

这个例子会在 §3.1 完整展开。本章使用“纤维”一词，是因为它能精确表达一个长期被感知却难以被形式化的事实：**当观测（读数）不足以决定真实状态时，同一个读数背后藏着不止一种可能。**读者不需要懂拓扑学或纤维丛理论，只需要带着这个影子的比喻往下读。

§1 时钟的房间

§1.1 最小设定

这个认识论实验的最简配置如下：一个封闭的房间，没有窗户。房间里有很多个钟，各自显示着时间的读数。房间里的人完全懂得如何读表。他能报出每一个钟的读数、算出任意两个钟之间的差异、按读数大小排序。门外有人问：“现在几点？”

完备的能力与完全的无力在同一个主体身上并存——这正是映射困境的结构性特征（此处“映射”指将真实状态转换为读数的映射函数，详见 §3.2）。在计算能力上，他能对读数执行任意推理；在校准能力上，他需要独立验证任一读数是否对应真实时间——前者他完备，后者他完全缺失。

在进入时钟房间的结构之前，有一个先决问题需要回答：为什么是时钟？刘易斯·芒福德（Lewis Mumford）在《技术与文明》（*Technics and Civilization*, 1934）中给出了一个精确的判断：

> The clock, not the steam-engine, is the key-machine of the modern industrial age. For every phase of its development the clock is both the outstanding fact and the typical symbol of the machine: even today no other machine is so ubiquitous. (Mumford, 1934)
>
> 译文：时钟——而不是蒸汽机——是近代工业时代的关键机器。在它发展的每一阶段，时钟都既是机器的突出事实，又是它的典型象征：直到今天，没有别的机器像它这样无处不在。

四十余年后，约瑟夫·魏岑鲍姆（Joseph Weizenbaum）在《计算机能力与人类理性》（*Computer Power and Human Reason*, 1976）中进一步锚定了时钟的本体论地位——时钟是人类建造的第一批自主机器（autonomous machine），它不延伸人的肌肉或感官，而是凭借对真实世界某一方面的内部化模型自行运行：

> An autonomous machine is one that, once started, runs by itself on the basis of an internalized model of some aspect of the real world. Clocks are fundamentally models of the planetary system. They are the first autonomous machines built by man, and until the advent of the computer they remained the only truly important ones. (Weizenbaum, 1976)
>
> 译文：自主机器是这样一种机器：一旦启动，它就在自身内部化的、关于真实世界某个方面的模型基础上自行运行。时钟从根本上说是行星系统的模型。它们是人类建造的第一批自主机器，并且直到计算机出现之前，它们一直是唯一真正重要的自主机器。

这正是选择时钟来演示映射困境的结构性理由：时钟这个物件本身就是第一个“把真实状态内部化为可读数的自主模型”。用时钟和时间的关系，来讨论“读数与真实之间的间隙”，不是在找一个方便的隐喻——而是在把映射困境追溯到它最古老的机械载体。

以下先展开四类问题，说明这个困境为什么如此顽固。

§1.2 四个问题如何从同一房间生成

同一个房间，会生成四类不同的问题。

第一类：事实问题。外面有人问：“现在几点？”

这是最直接的问题。它预设存在一个唯一真值，门外的人期待一个确定答案。房间里的人面对许多候选读数，却没有任何根据判断哪一个读数对应外面的真实时间。房间里的人面临的困境不是“没有答案”，而是“没有选择答案的依据”。

第二类：关系问题。外面有人问：“过多久是六点？”

这个问题不要求回答绝对时间，而是要求计算一个时间差：$f(T) = 6:00 - T$。房间里的人对任何一个钟都能算出距离六点还有多久，这意味着他拥有的正确运算结果与钟的数量一样多。但他仍然无法回答——因为他无法选择该以哪个钟为起点。推理能力完备，启动条件缺失。

一个变体把问题从绝对时刻转向持续时间。如果外面的人说：“三小时后可以出门”——这不是一个问题，而是一个承诺。承诺规定了从此刻起等待三小时的条件，却没有告诉观测者钟面上的三小时是否对应真实时间的三小时。他能记录发话时的读数，却不能确认何时已经满足承诺。困难不再是选择哪个钟来报告“现在几点”，而是校准等待的时长。这个变体已经从关系问题滑向行动问题——它因此也是通向第三类问题的过渡。

第三类：行动问题。外面有人说：“可以随时离开。报酬取决于离开时的真实时间与六点整的接近程度。”

现在事情变了。人不再只是被要求给出一个答案，而是必须做一个有后果的决策。他需要的不是读数能力，而是行动判断。而他没有任何手段验证哪个钟是对的。

第四类：元信息问题。他还在等的时候，门开了，有人推进来五个新时钟，放在地上，然后离开。不说话。

前三类问题都由门外的人明确提出问题或给出行动条件。在第四类问题中，外部的人没有发问，只发生了一个事件。房间里的人现在必须自己决定：这是更多的数据，还是关于数据来源的信号？它是否意味着旧钟不可信？新钟更可信？还是这只是一次干扰？

区分“把事件当作更多数据”与“追问事件本身意味着什么”的，不是智力或计算能力，而是**能否把事件本身识别为需要解释的信号——这种识别属于元认知，先于对事件的处理而发生**。无论处理结果为何[1]，信号识别必须先行发生。一个系统如果只在被提问时才处理信息，它在第四类问题面前不产生任何信号识别行为。

这四类问题说明“时钟的房间”不是一个单点谜题，而是一个母实验。同一个装置，在不同提问方式下，生成了不同层级的认知困境。因此需要补充一个前提：本实验不假设门外的人是否知道真实时间——门外的人也可能身处一个更大的封闭空间。论证只依赖房间内外的信息不对称这一关系结构，不依赖任何一方对真实时间的占有。

一个读表能力完备的人，在这个房间里变成了一个无法做出有据判断的囚犯。他拥有完备的计算能力，却丧失了判断的根据。他的困境不在智力，而在结构：校准所需的参照位于系统之外，而他所据以判断真实时间的读数，全部来自未经独立校准的系统内部时钟——论证见 §3.5。

§1.3 为什么直觉策略会失败

回到第一类问题。面对“现在几点”，房间里的人可能尝试以下策略。

- **策略一：取统计量。**计算所有读数的均值或中位数。但要把这些统计量当作真值的可靠估计，需要对误差的中心位置及相关结构有根据的约束；均值与中位数所需的具体条件并不相同。他没有任何根据作此约束——一千个钟可能全部快两小时，均值仍快两小时。统计量不增加信息，只重组已存在的信息。如果原始信息中不包含真值，汇总后仍然不包含。
- **策略二：找聚类。**如果六百个钟聚集在 3:00 附近，他倾向相信这个聚类。但聚类反映的是共识，不是真相。六百个钟可能出自同一条流水线，共享同一个系统性偏差——比如出厂时全部被调快了两小时。共识扩大不等于完成校准。在极端情况下，共识是偏差的放大器，不是真相的信号或指标。（在直觉层面，人面对聚类时无法区分两种可能的生成机制——“指向同一真值”与“出自同一条流水线”——这正是困境的核心。形式论证见 §3.6。）
- **策略三：观察走速。**哪些钟在匀速走动、哪些停了？走速正常的钟“看起来”更可靠。但走速正确（每秒走一秒）只保证增量准确，不保证起点准确。一个快了两小时但走速完美的钟，永远快两小时。走得准不等于指得对。
- **策略四：选择权威钟。**有一个钟看起来比别的更精密、更昂贵、标着“标准时间”。他倾向信任它。但“看起来权威”是叙事属性，不是校准属性。标签可以伪造，精密可以空转。一个钟不会因为镀了金就指向正确的时间。
- **策略五：承认无知。**他说：“我能报出一些钟的读数，但我不知道现在几点。”

前四种策略的共同结构是：**用钟校准钟**。在没有外部锚点时，用钟校准钟只是一个闭环。它可以产生内部一致性，不能保证与真实的对齐。

唯一诚实的回答是第五种。“用钟校准钟不是校准”是贯穿本章的基本判断——后文不再重复论证，只引用此处。（关于“承认无知”本身是否也只是一个内部读数，见 §7.1 的自指警告。）

英语认识论有一个与钟相邻的著名案例——罗素的停摆钟：一个人看一口停了的钟，他以为钟在走，碰巧看到的时刻恰好正确，于是得到一个关于时刻的正确信念；罗素以此说明，正确的信念还不是知识（Russell, 1948）。时钟房间与停摆钟结构不同。停摆钟里的人对映射持有一个恰好为错的信念——他以为钟在走，他的正确信念靠运气获得；时钟房间里诚实的人不假装知道映射，他知道每个读数都未经独

[1]处理结果可采取三种形式之一：追问该事件的含义、将事件归为噪声而忽略、标记为待定而延迟判断。

立校准。前者问 “碰巧为真的信念算不算知识”，后者问 “映射未知时，读数能否确定真值”——本章讨论的是后者。Gettier 引发的辩护真信念文献（Gettier, 1963）延续的也是前一个问题：其反例的关键是从假前提合式地推出真结论的运气，不含读数与真实之间的映射未知。

§1.4 时钟数量（N）的堆积

一个看似自然的直觉是：更多的时钟应当提供更多的信息，从而更有帮助。但在本实验的设定下，这一直觉需要被重新检视。一个未校准的时钟与一千个未校准的时钟，在认识论上的差别并不如想象中显著。若它们共享同一个系统性偏差，数量的增加仅增加冗余，不增加关于真实时间的独立信息。

如果时钟数量（N）增加到极大——覆盖了表盘上每一个可能读数——情况更糟而非更好。面对的不再是 “某些候选答案”，而是 “所有可能的答案都同时在场”。对于任何一个想回答的时间，墙上必然有一个钟精确地指向它——但指向它不等于证明它。纤维并未缩小——形式论证见 §3.5。

如果时钟数量（N）增加到千亿，还有另一层面的恶化。Zheng 与 Meister 综述了跨越大半个世纪、涵盖知觉、动作与想象的测量，写道：

> The information throughput of a human being is about 10 bits/s. In comparison, our sensory systems gather data at $\sim 10^9$ bits/s. (Zheng & Meister, 2025)
>
> 译文：人的信息吞吐率约为 10 bits/s。与之对照，我们的感觉系统以约 10^9 bits/s 的速率采集数据。

这两个数字之间的悬殊落差，论文自陈尚无解释。当钟多到读不完时，人会被迫建立一个筛选、汇总、加权的 “元系统” 来处理这些钟。这个元系统本身是什么？**一个关于时钟的时钟——元时钟。**而元时钟的构建过程里嵌入了先验假设。先验假设有质量高低之分，但在缺乏外部校准的条件下，假设本身的质量不可验证。元时钟的构建者必须在不知道哪些假设正确的情况下选择假设——这个选择的映射函数本身是未知的。元时钟一旦建成，就**取代了原始时钟成为他的操作界面**——他不再直接面对读数，而是面对元时钟的输出。问题被抬升到另一个抽象层，但并未消失。

关键变量不是时钟数量（N），而是映射函数（π）的已知程度。不管时钟数量（N）有多大，在完全未知且缺乏外部校准的边界条件下，单纯增加时钟数量（N）不提供关于真值的可验证增益。这一判断在控制论中有一个独立的度量表述：调节者的调节能力不可能超过它自身作为通信通道的容量——超出通道容量的多样性无法转化为调节能力（Ashby, 1956）。

当所有时钟显示完全相同的读数，房间里的人最可能直接报出那个数字，不再犹豫。但他的认识论处境并未改善——完全一致的读数可能来自所有时钟共享同一个系统性偏差。映射函数仍然未知，纤维并未缩小；改变的只是主观确定感显著上升。在这种情况下，**观测者启动进一步校准或怀疑的动机被降到最低——尽管校准的需求并未减少。**

这是时钟的房间。一个最小的设定，四类问题，四种失败的策略，和一个不会被时钟数量（N）拯救的困境。

要理解这个困境为什么如此顽固——即 §1 所识别的 “读数与真实之间的结构性距离”——有必要先看一个人——一个 20 世纪最精密的时钟制造者——如何在自己的研究与反思中遭遇它。

---

§2 最精密的时钟制造者

这一节的作用不是做冯·诺依曼思想史，而是用一个数学研究者的经历说明以数学方法寻求绝对可靠性根据的目标如何遇到限制，并与时钟房间作有边界的结构比较。

§2.1 冯·诺依曼的三次自我否定

冯·诺依曼是 20 世纪最伟大的数学家之一。他在 1925 年给出了集合论的公理化体系，为量子力学奠定了严格的数学基础，创立了博弈论，参与了第一台通用电子计算机——电子数值积分计算机（Electronic Numerical Integrator and Computer，ENIAC）——的研制，提出了现代存储程序通用计算机的方案。[2]

他在本章中出现，不是因为他的名望，而是因为他的经历。他是 20 世纪 “最精密的时钟制造者” 之一，在制造 “时钟” 的过程中发现时钟的局限。他不是单纯转述外部结论的旁观者——哥德尔的第一不完全性定理公告及两人的讨论构成了重要思想触发；他随后用哥德尔的方法独立得到第二不完全性定理，并据此重新评价希尔伯特纲领。

1947 年，他在 “数学家” 一文中写道：

> “这件事就发生在我们自己的有生之年，而且我也知道我自己在这一事件中如何令人惭愧地轻易改变了自己关于绝对数学真理的观点，并且如何接连改变了三次！”（von Neumann, 1947, “The Mathematician”）

以下对三次转变的刻画，依据冯·诺依曼本人在相应时段的著作与书信：1925 年集合论公理化论文，1930 年 11 月至 1931 年 6 月与哥德尔、卡尔纳普的通信，1947 年 “数学家”，1954 年 “数学在科学和社会中的作用”，1955 年 “我们能在技术条件下劫后余生吗？”[3]

第一次（1925–1930 年秋）。冯·诺依曼站在希尔伯特一边，认同数学可以通过公理化方法获得安全的基础。他 1925 年发表了集合论公理化的论文（von Neumann, 1925/1967），试图为全部数学提供一个逻辑上无可非议的形式系统。他相信希尔伯特纲领的目标——用有限主义方法证明古典数学的一致性——是可以实现的。这里区分作为证明方法的有限主义数学与被研究的古典数学系统，不把这一计划直接等同于被研究系统对自身的一致性证明。

第二次（1930–1931 年）。哥德尔在 1930 年柯尼斯堡会议上宣布了第一不完全性定理。与会者中几乎只有冯·诺依曼注意到了这一公告的意义。几周后，他独立地获得了第二不完全性定理的证明——任何足够强的一致的形式系统不能证明自身的一致性。他在 1930 年 11 月 20 日的信中通知了哥德尔，但得知哥德尔已提交论文后，悄悄放弃了优先权主张（Formica, 2011; Rédei, 2005; von Plato, 2020）。[4]

---

[2]关于冯·诺依曼的科学生涯概述，参见李文林为《数学在科学和社会中的作用》（2009）所撰译者序。以下对他思想演变的三阶段划分是一种启发式重构。他本人在 1947 年的 “数学家” 一文中只说了 “接连改变了三次”，没有给出任何分期界定；本书的划分保留方向性的对应，不声称严格的历史分期。

[3]中译本取李文林主编、程钊、王丽霞、杨静编译本《数学在科学和社会中的作用》（大连理工大学出版社，2009），通信取 Rédei 编《冯·诺依曼书信选》（*John von Neumann: Selected Letters*, American Mathematical Society, 2005）；1947 年文章 “The Mathematician”、1954 年文章 “The Role of Mathematics in the Sciences and in Society”（中译收入《数学在科学和社会中的作用》）以及 1955 年文章 “Can We Survive Technology?”（中译常作《我们能在技术条件下劫后余生吗?》）的英文原文汇编于《冯·诺依曼概要》（*The Neumann Compendium*, Bródy & Vámos eds., World Scientific, 1995）第七部分。其中，§2.1 关于系统一致性的引文首句和 §2.2 关于理论物理学家知识范围的引文首句据英文原文校译，不作为上述中译本的逐字引文。

[4]三封关键通信见 Rédei（2005）：前两封（致哥德尔）原件存普林斯顿大学 Gödel Archive，第三封（致卡尔纳普）原件存匹兹堡大学科学哲学档案库（Archives of Scientific Philosophy，RC 029-08-01）。(1) 1930 年 11 月 20 日冯·诺依曼致哥德尔（Rédei, 2005）：“I was able to show that the consistency of mathematics is unprovable.”（我得以证明，数学的一致性是不可证的。）冯·诺依曼从未发表这一结果，其完整证明未存世（在其遗稿与哥德尔的未刊材料中均无），今日所知为其信中对论证思路的概述；其具体推导路径，学界有不同重建（Formica, 2023）。(2) 1930 年 11 月 29 日冯·诺依曼致哥德尔（Rédei, 2005）：“As you have established the theorem on the unprovability of consistency as a natural continuation and deepening of your earlier results, I clearly won’t publish on this subject.”（既然你已将 “一致性不可证” 这一定理作为你早前结果的自然延伸与深化确立起来，那我自然不会就此主题发表。）(3) 1931 年 6 月 7 日冯·诺依曼致卡尔纳普（Rédei, 2005）：“Thus I am today of the opinion that (1)

他对这一结果的评价如下：

> “如果一个数学系统不会导致矛盾，那么这一事实无法用该系统本身的程序来论证。……我个人和其他许多人的共同看法是，哥德尔已经说明了希尔伯特的方案实质上毫无希望。”（von Neumann, 1947, “The Mathematician”）

哥德尔定理与 §1.3 的判断共享同一种结构直觉。需要强调，两者不是同一个数学命题——哥德尔定理关于证明可能性，本章 §3 的命题关于状态可确定性——但在本书的解读下它们共享一个结构特征：一个系统无法仅凭内部资源确证自身与它所试图表征之物之间的关系。本章将哥德尔定理作为 §1.3 判断的一个同领域内的结论来讨论，不声称两者等同。

第三次（约 1931 年之后）。希尔伯特的方案和布劳威尔-外尔的方案都不能给古典数学一个绝对的辩护。大多数数学家决定无论如何还是要使用这个系统。冯 • 诺依曼写道：

> “毕竟，古典数学正产生着既优美又实用的结果，而且，即使人们再也不能绝对相信它的可靠性，但它至少是建立在如同电子的存在一样坚实的基础上的。”（von Neumann, 1947, “The Mathematician”）

冯 • 诺依曼在 1947 年 “数学家” 一文中说自己关于绝对数学真理的观点 “接连改变了三次”；1954 年在 “数学在科学和社会中的作用” 中他又说自己对什么是数学严格性的看法在近 30 年里 “至少转变了两次”。两次自述针对的对象并不相同——前者是关于绝对数学真理的观点，后者是对数学严格性的看法——本书不据计数差异对 “第三次” 是否完成下断语。他在 1954 年那篇文章中还写道：“因此怀疑是存在的；在评价数学的特征和作用时，人们千万不能忘记：怀疑是存在的。”（原文首句作 “there is a certain area of doubt there”；英文版按原文全句引用。）

以下是本书对这一转向的读法，不是冯 • 诺依曼本人的表述。他在这里做的与希尔伯特恰好相反：希尔伯特试图把认识论问题内化——用有限主义数学证明古典数学的可靠性；冯 • 诺依曼则把它外化。这里的 “内化” 指在数学方法之内寻求可靠性的根据，不等于在同一个形式系统中证明该系统自身的一致性。上面那句自陈就是落点所在——古典数学 “至少是建立在如同电子的存在一样坚实的基础上的”（von Neumann, 1947）——辩护从数学的一致性证明，移到了经验科学的有效性上。他不再把绝对可靠性寄托于这一证明计划，而是接受了一个不可消除的不确定性，然后在不确定性内部做功——同时始终记得不确定性的存在。

§2.2 巴洛克诊断

冯 • 诺依曼不仅在形式系统的层面经历了这个困难，他也在学科演化的层面诊断了同一个结构。

在 “数学家” 一文中，他观察到：数学从经验中诞生，然后发展出自己的形式系统。在形式系统内操作一段时间后，学科会出现退化的倾向：

> “当一门数学学科远离其经验本源的时候……它将变得越来越纯粹地美学化，越来越纯粹地‘为艺术而艺术’。”（von Neumann, 1947, “The Mathematician”）

他用了一个精确的词：**巴洛克**。他借 “巴洛克” 一词形容因自我引用而丧失功能性的精密度——就像巴洛克装饰那样逐层叠加而离开结构本身。

> “起初，数学学科的风格通常是古典式的；一旦它显露出巴洛克式的迹象，危险信号就出现了。”（von Neumann, 1947, “The Mathematician”）

Gödel has shown the unrealizability of Hilbert’s program.”（因此我现在的看法是：(1) 哥德尔已表明希尔伯特方案的不可实现。）

巴洛克风格的特征是装饰引用装饰、形式引用形式、结构变得精密但离原始功能越来越远。在时钟房间的语言里，这就是 §1.3 闭环的学科版本：定理证明定理、技巧服务技巧、概念建立在概念之上——产生这门学科的经验问题从映射的输入中消失了。

他给出了处方：

> “无论如何，每当到了这个阶段，在我看来唯一的补救措施就是为了恢复活力而返本求源也就是或多或少地注入直接经验思想。我相信，这是使该学科保持清新与活力的必要条件，而且这在将来也仍然会是同样正确的。”（von Neumann, 1947, “The Mathematician”）

本书进一步把 “经验本源” 解释为具身、多通道的接触方式；这不是冯 • 诺依曼对 “empirical source” 的逐字定义。就本章的用法而言，它不是某个具体校准物，而是人作为具身存在者与世界接触的方式——手碰到材料、实验产生了意外、观察到了理论没有预测的现象。脱离经验本源，因而不是脱离某个外部参照物，而是脱离这种接触方式本身。（当然，身体感知本身亦是一种映射，但它提供了多通道、可交叉校验的接触方式，这与单维度的符号操作有质的区别——详见 §5.2。）

他用了 “每当到了这个阶段”——退化不是一次性事件，是反复发生的倾向。研究者需要不断回到学科的经验本源，学科在返本之后又不断漂移。

他还注意到一个与此相关的症状：

> “一个好的理论物理学家今天仍然能对其学科一半以上的内容保持足以实际运用的掌握。但我怀疑现在在世的数学家中有谁能与其研究学科中四分之一以上的知识有联系。”（von Neumann, 1947, “The Mathematician”）

为什么物理学家能掌握一半的学科知识？因为物理学被经验的严格约束保持了知识的集中状态——“几乎在任何时候，所有理论物理学家的大部分努力都集中在不超过一两个界限非常明确的领域里。” 在冯 • 诺依曼 1947 年的比较中，理论物理的问题通常由实验困难客观给出，数学各分支则给研究者更大的选题自由；与理论物理相比，数学通常缺少同等直接、统一的经验约束。在他所讨论的远离经验本源的分支中，新方向首先受到内部一致性与审美判据的约束，但这不等于全部数学都没有经验约束。

§2.3 这对时钟房间意味着什么

冯 • 诺依曼的三次转变不是哲学思辨——转变的推动力包括他亲手执行的形式操作及其结果。它们为 §1.3 的判断提供了形式系统研究中的结构类比（见 §2.1 边界声明）：一个 20 世纪最精密的时钟制造者，在持续的数学研究及其反思中，从 “相信可以用有限主义方法证明古典数学的一致性” 走到了 “接受不确定性的存在，在不确定性内部做功”。不是因为他不够聪明。是因为一致性证明所能使用的方法本身受到限制。

本章另取冯 • 诺依曼在两篇文章中的两段判断作有边界的对照。1954 年，在题为 “The Role of Mathematics in the Sciences and in Society” 的文章中（中译收录于《数学在科学和社会中的作用》），他讨论的是非功利研究的长期成效：

> “在很大程度上，成功在于完全忘掉终极所求；拒不研究获利之事，只依赖智能雅趣准则的指引；遵循此道，长远来看其实会遥遥领先，远胜于执守功利主义之所获。”（von Neumann, 1954, “The Role of Mathematics in the Sciences and in Society”；本条按李文林中译本原句引用。原文此句尚有 “or whether one wanted anything ultimately”——或究竟是否有任何终极所求——一分句，中译本未译出；英文版按原文全句引用，两侧覆盖差异特此注明）

1955 年，在题为 “Can We Survive Technology?” 的文章中（中译常作《我们能在技术条件下劫后余生吗?》），他给出了一条安全准则：

> “Any attempt to find automatically safe channels for the present explosive variety of progress must lead to frustration. The only safety possible is relative, and it lies in an intelligent exercise of day-to-day judgment.”
>
> “任何为当前这种爆炸性的进步寻找自动安全渠道的企图，都必然受挫。能够获得的安全只能是相对的，它有赖于日常判断的明智运用。”（von Neumann, 1955, “Can We Survive Technology?”；“日常判断的明智运用” 对应英文 “an intelligent exercise of day-to-day judgment”；某中译本曾意译为 “日常决策判断的智力体操”，略有扩张）

这两段材料属于不同语境。1954 年段落针对科学发现与应用之间的时间滞后，强调不受短期功利目标支配的研究可以产生长期成果；1955 年段落针对技术进步的安全问题，强调自动安全渠道不可得，只能依靠日常判断。把它们联结到时钟房间，是本书的进一步解释，不是冯 • 诺依曼本人建立的因果或思想史顺序。本书据此提出的对照是：研究不能由终极目的保证成效，安全也不能由系统自动保证；二者都不取消具体情境中的判断责任。1954 年的 “忘掉终极所求” 不能直接等同于放弃数学基础证明。

要把这个处方所对应的困境说精确——将 §1 的直觉判断转化为形式化命题——需要一个比叙事更严格的语言。下一节用纤维提供这个语言。

---

§3 从影子到纤维

§3.1 影子比喻

请想象有一堵墙。墙上有一个圆形影子。

问：投出这个影子的物体是什么形状？

观测者答：可能是球。可能是圆盘。可能是圆柱。也可能是别的物体，在某个光照角度下恰好投出圆形影子。

影子是一个读数。墙后的物体是真实。影子比喻的核心问题是 “同一个读数，可能对应许多不同的真实”。光的方向决定了物体如何映射成影子——它就是这幅投影场景中的 “映射函数”。

这个比喻与柏拉图洞穴在结构上相似，但关注点不同——洞穴寓言关心囚徒能否转身看到真实，本章比喻关心即便观察者完全清醒，单一影子也不足以确定物体。

§3.2 纤维：首次解释

在进入形式化定义之前，先明确一个术语：**本书将 “真实状态到读数的对应关系” 统一称为 “映射函数”**（π）。在时钟房间里，每个时钟就是一个映射函数——它把真实时间转换为钟面读数。映射函数可能是准确的、可能快两小时、可能走得时快时慢。关键在于：房间里的人不知道映射函数。

给定一个读数，所有能产生该读数的真实状态的集合，在数学中称为**纤维（fiber）**。

在本章中，“纤维” 可以先读作：

> 一个读数兼容的全部可能真实

在影子比喻里，它就是：

> 所有能投出这个影子的物体

在同一任务与同一比较口径下，若新增证据使候选真实状态集合按包含关系缩小，读数就排除了更多候选状态；对非包含的集合，不能仅凭‘大小’判断信息量。[5]

这一框架如何系统地区分出三种不同性质的困境，将在 §4 完整展开。

§3.3 翻译表

表 1. 纤维语言与影子比喻的对应

纤维语言	影子比喻
纤维	能投出同一个影子的所有物体
纤维为全集	这个影子可以是任何东西造成的
纤维为单点	只有一种物体能投出这个影子
纤维缩小	排除了一些可能的物体
纤维非单点	一个影子对应多个可能物体

§3.4 形式化定义

定义 1（真实状态）。存在一个真实状态（T），对房间里的人不可直接观测。

定义 2（映射函数）。每个时钟是一个映射函数（π_i）：$r_i = \pi_i(T)$。映射函数编码了第 i 个时钟的全部特性。房间里的人不知道映射函数。他看到的只是读数（r_i）。

定义 3（纤维）。给定读数（r），纤维为：

$$\pi_i^{-1}(r) = \{T' \mid \pi_i(T') = r\}$$

上式针对给定映射。讨论映射未知时，本章用 “纤维” 指在尚未排除的候选映射下、与已有读数相容的真实状态集合；校准知识的增加缩小的是这一候选集合。§4.3 讨论的结构性非单点，则是给定映射本身的性质。

定义 4（校准）。校准是获取关于映射函数（π_i）的知识，从而缩小纤维（可能真实的范围）的过程。校准的必要条件是能够获得与真实状态有因果接触的独立参照；独立性指参照证据不是由待校准读数集合循环生成，且其误差不与待校准系统同源，而不取决于参照在物理上是否位于房间之外，或形式上是否属于某个更大的读数集合。

§3.5 命题与证明

以下命题给出的是边界条件（映射函数完全未知且候选映射函数空间无先验约束）的结论。现实条件下先验约束对纤维的收缩效果，紧跟证明之后讨论。

[5] 本章使用 “纤维” 一词时，取其核心直觉——一个读数兼容的全部可能真实。这里不需要纤维丛理论的全部装备，只需要 “一个读数对应多少种可能真实” 这个直觉。需要数学精确性的读者可参考 Steenrod（1951）。这套翻译词汇本身也是一个时钟——它是纤维概念的映射，不是纤维概念本身。

命题。若全部映射函数 $\{\pi_1, \dots, \pi_N\}$ 均未知，且候选映射函数空间没有任何先验约束，则对任意观测集 $\{r_1, \dots, r_N\}$，所有可能的真实状态 T' 均与观测相容。[6]

证明。取任意 T'。对每个 i，构造 π_i' 使得 $\pi_i'(T') = r_i$。由于候选映射函数空间没有先验约束，π_i' 是合法候选。故 T' 与全部观测相容。■

这里的 “无先验约束” 是边界条件，不是典型条件。这种边界情形在科学哲学里有一个名字：欠定（underdetermination）——证据（观测）不足以唯一决定理论。本节命题是它在读数与真实状态之间的形式。现实中人总是知道一些关于映射函数的东西：它是时钟不是温度计，它大致单调，走速有物理限制。这些先验约束会缩小纤维，有时缩小到实践中完全够用的程度——人们每天根据手表出行。

本章的论点不是 “先验无用”，而是两方面：第一，先验可以缩小候选真实状态的范围，在特定假设下甚至只剩一个候选状态。但这种唯一性以先验成立为条件；先验本身未经独立校准时，不能仅凭候选状态唯一就确认它是真实状态。第二，更重要的是，先验的外部可靠性不由内部一致性独自保证。某些先验可以被内部观测排除；但未被排除，并不意味着已经得到校准。假设 “多数钟是准的”，如果这个假设恰好对了，中位数会接近真值——但即使多个钟给出一致读数，这种一致也不能独自排除共同偏差——这就是 §3.6 闭环伪校准的要点。先验缩小纤维的效力取决于先验本身的准确性，而一个未被内部排除的先验，其外部准确性在缺乏独立校准的条件下仍属未知。一个恰好正确的先验会把纤维缩小到可操作的范围；一个系统性错误的先验会把纤维缩小到一个远离真值的错误区间——后者比纤维为全集更危险，因为它制造了虚假的确定性。

核心结论不变：关键变量不是数据量，而是映射函数的已知程度。这个命题的作用不是描述日常生活中人们总是如何认识世界，而是揭示：一旦失去对映射函数的任何可靠把握，单纯增殖读数为何不能替代校准。（§4.1 将讨论一个进入过法律程序的制度案例：核验做到当时史无前例的程度，仍须区分证明是否完成、何种论证被接受为证明，以及模型是否得到外部校准。链内核验的进展不能替代最后这一项。）

§3.6 闭环伪校准

房间里的人可以算出任意两个读数之间的差值。但这只给出读数之间的相对关系，不给出任何读数与真实状态之间的绝对关系。他可以建立一张完整的差异表——一个内部一致的关系结构——但这是一张没有原点的坐标网格——只有相对关系、没有绝对基准的坐标系。所有钟都快两小时但彼此差距恒定的系统，内部完美一致，外部完全错误。

一个外部观测者（例如门外的人）在仅看到内部一致性时，常常误判系统已经校准。但内部一致性不足以证明系统与真实对齐。房间里的人也可能发生这种误认；由于他无法接触独立的校准信号，这种误认缺少被纠正的依据。一个完全封闭的回音室，内部的声音可以完美和谐，外部的真实可以完全缺席。

§3.7 与测量理论的衔接

表征性测量理论（Krantz et al., 1971）将测量定义为经验关系系统到数值关系系统的同态映射。基于模型的测量观（Tal, 2020）进一步指出：读数不是直接从对象 “读取” 的，而是在包含了仪器模型、环境模型和校准模型的复杂中介过程中产生的。

[6]本节命题与休谟 “归纳问题”（《人性论》第一卷第三部 “Of Knowledge and Probability”，Hume, 1739–1740）可以作有限的结构类比：已有观测不能自行保证从观测走向结论所需的全部前提。休谟追问的是，为什么可以把已观察到的因果联系推及尚未观察的情形；本节追问的是，在候选映射完全没有先验约束时，读数为何不能确定真实状态。两者的对象与可补救条件不同，本章不把增加外部校准通道当作休谟问题的解答。本章不展开这一类比：休谟以 “未来事件与过去事件相似” 的因果律为讨论场，本节以 “读数与真实之间的映射函数” 为讨论场，两套语言各自的哲学负载不同。本书对休谟的实质援引集中于其难题二（实然—应然，is-ought 问题），留待跋章关于 “人之为人的存在条件” 的讨论使用；此处仅作有限结构类比的承认与让位。

本章的增量贡献在于：将这一洞见从物理测量扩展到 AI 对齐、金融指标、学术评价这类依赖映射函数生成读数的实践情境；用纤维的直觉框架提供统一语言；并将映射未知、动态腐蚀与降维限制组织为三层递进结构。经典测量理论已经分析多对一同态，因此本章不把第三层的非单点性本身主张为理论空白；其增量在于三层问题的整合及其在 AI 对齐等场景中的诊断用途。

在测量过程的场论分析中亦有采用纤维丛构造的先例（Urbański & Samsonowicz, 2003），但两者哲学取向不同：该文的基空间为被测量量的拓扑性质、纤维指向标度值的代数性质，建模的是测量仪器与被测量对象之间物理交互的拓扑结构；本章的基空间为读数空间、纤维指向与读数兼容的可能真实状态的集合，建模的是认知者与真实之间映射不可逆的认识论结构。两者共享数学隐喻而研究对象不同。Tal 的综述已经讨论经济测量及多面向社会概念的单指标局限；本章的增量不在于首次把测量分析带入这些领域，而在于将这些问题与映射未知、动态腐蚀和降维限制整合为同一诊断框架。

---

§4 三层不可逆

§4.1 第一层：信息缺失

在映射函数未知的条件下，纤维（与给定读数相容的可能真实状态的集合）过大，读数本身提供的信息不足以唯一确定真实状态。

这一层在原则上可解。如果能够建立一条独立于所有时钟的、与真实状态有因果接触的信息通道，就可以获取第一个校准点。第一个校准必须来自独立于待校准读数集合的证据链——校准链必须有一端锚定在该集合的循环生成过程之外。

“可解” 在此处的含义不是获得绝对真实。外部参照本身也是一种映射，用它校准不能保证唯一恢复真实状态。“可解” 意味着纤维从全集（或极大集合）缩小到足以支持行动决策的程度。这一收缩在实践层面构成关键变化。第一层的可解性依赖于校准通道的独立性——它必须与真实状态有因果接触（定义四），但其证据不得由被校准的读数集合循环生成，其误差不得与被校准系统同源。当这一独立性被侵蚀时，第一层的解法退化为第二层的持续竞争。

一个推论需要在此明确：追加内部核验不改变第一层的处境。§1.4 说明了读数的数量不产生锚点；此处要补充的是，核验的严格程度同样不产生锚点。这句话需要一个限定才准确：链内核验确实缩小纤维，它单调地缩小 “设计与规格之间” 那个纤维——即设计是否符合写下来的规格；但不能仅凭自身保证 “器件与意图之间” 那个纤维相应缩小——即造出来的物件是否符合当初想要的东西。两者是不同的集合，前者收缩不蕴含后者收缩。所以本节的命题不是严格核验无用，而是严格核验作用于另一个纤维。在读数集合内部提高相互比对的数量与精度，可以增强集合的内部一致性，却不能在集合内部生成一个锚点。校准点的资格不由核验的严格程度决定，而由核验证据是否独立于待校准集合的循环生成与同源误差决定。

标准的循环。设想用一支水银温度计去测量物体的温度，而目的是检验 “物体受热膨胀” 这条定律。这里乍看有一个恶性循环：水银柱正是靠受热膨胀来指示温度的，拿它去检验热膨胀定律，等于用待检的定律去检验待检的定律（Franklin et al., 1989，转引自 Tal, 2020）。这个循环不是温度计独有的。用理论去判定哪一个测量标准更准确，同样是循环的——因为在选定标准之前，理论无法确定地应用到个别对象上。这一循环在科学哲学里已经有名字：van Fraassen 称之为协调问题（problem of coordination），Chang 称之为定律性测量问题（problem of nomic measurement）（协调问题出自 van Fraassen 2008，定律性测量问题出自 Chang 2004；两者均据 Tal, 2020 的综述）。本节所说的第一层，就是这个问题在纤维语

言里的形态。

解法的资格来自通道，不来自精度。 Franklin 等人的结论是这个循环并不恶性：水银温度计可以拿另一支温度计来校准——一支其工作原理并不预设热膨胀定律的温度计，例如定容气体温度计——从而在独立的基础上确立水银温度计的可靠性（转引自 Tal, 2020）。关键不在于第二支温度计更精密，而在于它的工作原理不预设待检的那条定律。换成本节的语言：它的读数来源不在被校准的那个读数集合之内，所以它能充当 §3.4 定义四所要求的外部参照。追加同类温度计、把刻度刻得更细，都不产生这个资格；换一条原理独立的通道才产生。

而判据之争也不必永远悬置。标准可以在理论与仪器的共同修正中改变；本书将下述千克定义从实物原器转向基本物理常数的变化称为“换锚”：Chang 把标准的历史描述为一连串“认识迭代”（epistemic iteration），每一次迭代都尊重既有传统同时修正它，后继标准被认为比前者更准确（据 Tal, 2020）。这个过程有可以定年的落点：千克在 2019 年被重新定义——不再指向任何特定种类的物理系统，而是通过固定一个基本物理常数的数值来定义（据 Tal, 2020）。这里把千克定义的这一变化称为“换锚”，是本书的进一步解释；这一称呼不意味着定义的改变本身就完成了独立校准，也不意味着它可以取代理论与仪器之间的共同修正。

千克为什么要换锚，计量学家自己算过：国际千克原器作为一件实物，没有与任何自然不变量相联系，相对于同龄的铂铱标准群，其质量看起来正在变化，约每世纪 50 微克，也可能显著更多。更要紧的是：全世界一千克铂铱标准之间的一致性已做到几微克，相互比对的精度还要更细，但这一整群标准相对于某个自然不变量的漂移，在半个世纪乃至一个世纪的尺度上、1 毫克以下仍属未知（Mills et al., 2005）。微克级的内部一致性，不能证明整组标准相对于自然不变量也具有微克级稳定性——§3.6 那张没有原点的坐标网格，在这里有了定量形态。判据从一件实物移到了一个自然常数上；它不是靠链内追加精度移过去的，是靠换一个锚移过去的。

判据之争进过法院。英国国防部下属皇家信号与雷达研究院（Royal Signals and Radar Establishment，RSRE）研制过一款可验证的高可靠性集成处理器（Verifiable Integrated Processor for Enhanced Reliability，VIPER），其证明链由四级递减抽象的数学模型串成——顶层规格、主状态机、块级、门级，每一级都是模型（MacKenzie, 2001）；所经受的测试、模拟、核查与数学分析在当时是史无前例的（MacKenzie, 2005）。1991 年初，取得技术授权的 Charter Technologies 公司起诉国防大臣，指控“已获证明”这一主张构成虚假陈述；争点不在哪些工作做了、哪些没做，而在这个过程的产物算不算证明（MacKenzie, 1991, 2001）。

就国防部安全攸关系统的实际应用而言：按英国国防部 1991 年 5 月的议会书面答复，该处理器当时“未被用于国防部控制的任何安全攸关计算机系统”；同一份答复还承认，就该处理器在何种程度上可称为形式数学意义上的“已获证明”，理论界存在争论（House of Commons, 1991）。案子最终没有开庭——Charter Technologies 公司在开庭之前破产，诉讼随之失效（MacKenzie, 2001）。受美国航空航天局（National Aeronautics and Space Administration，NASA）委托评估此项工作的 Bishop Brock 与 Warren Hunt 也认定，截至该报告评估时，这条链尚未完成形式验证（Brock & Hunt, 1990/1991）。皇家信号与雷达研究院（RSRE）团队自己的 John Kershaw 由此走到一个明确的相对主义结论[7]：

[7]Humpty Dumpty 是卡罗尔《爱丽丝镜中奇遇记》第六章中的角色。原文：“When *I* use a word,” Humpty Dumpty said in rather a scornful tone, “it means just what I choose it to mean—neither more nor less.”（我用一个词的时候，Humpty Dumpty 用相当轻蔑的语气说，它的意思恰恰就是我选定的意思——不多不少。）紧接的对答把争点又推进一层：“The question is,” said Alice, “whether you *can* make words mean so many different things.” “The question is,” said Humpty Dumpty, “which is to be master—that’s all.”（爱丽丝说，问题在于你能不能让一个词表示那么多不同的意思。Humpty Dumpty 说，问题在于谁来做主——仅此而已。）（Carroll, 1871）以他命名的用法，指一个词的意义由使用者当场规定，没有外部标准可供裁决。Kershaw 那句的收尾 “no more and no less” 正是第一句的回声；而他借这个典故的落点在第二句——争的不是词能否多义，而是谁有权裁定词义，判据于是留在从业者的接受上。同一判断在中国古典里有更早也更系统的表述：《荀子 • 正名》“名无固宜，约之以命，约定俗成谓

> “Proof,” he wrote, “is a typical Humpty Dumpty word, which means precisely what you want it to mean. … In practice proof seems to mean ‘an argument that most practitioners in the field accept as valid,’ no more and no less.” (Kershaw, quoted in MacKenzie, 2001)
>
> 译文：证明是一个典型的 “Humpty Dumpty 式” 词汇，它的意思精确地就是你要它表示的意思。……在实践中，证明似乎意味着 “一个该领域的大多数从业者接受为有效的论证”，不多不少。

以下推论由本书作出，MacKenzie 未如此表述；段内所标出处只指材料来源。用本章的语言：该处理器这条证明链的每一级都位于读数集合之内，模型对模型的核验无论追加多少、做得多严格，都不能仅凭自身完成模型与实际器件之间的独立校准。Brock 与 Hunt 批评过链条里两道非形式翻译的正确性在当时不能被证明——缺的是关联不同语言的形式理论；他们同时以统一逻辑理论下的核验作对照，说明这种证明缺口与证明义务是否完成有关（Brock & Hunt, 1990/1991; MacKenzie, 2001）。链内追加核验可以弥补模型关系的证明缺口，但弥补这一缺口不等于产生了模型之外的校准点。

这里需要区分证明是否完成、何种论证被接受为证明，以及模型是否得到外部校准。在尚未就证明判据取得共同承诺时，追加某一判据之内的证据，不保证终结关于判据本身的争议；但判据已经明确后，补齐链内证明义务仍能回答是否满足这一判据的问题。即使后一问题得到回答，模型与实际器件、规格与意图之间的独立校准也不会因此自动完成。这场处理器之争并未经过法院对证明判据的裁决，而是随着公司的破产结束；诉讼没有给出解决判据之争的答案。

判据也并未因此消失，只是换了载体：英国国防部在 1991 年发布的安全攸关软件采购标准，就把判据写进了制度文本——它要求的是可被独立机械核查的形式证明，而不是通行的严格论证（MacKenzie, 2001）[8]。这与本章 §7.3 要讨论的记账结构指向同一类需求：将采用的证明判据、在该判据下尚未完成的证明义务，以及不能由链内证明替代的外部校准分别记录下来。

意图与硅片的核对具有不同的限制，判据仍是 §3.4 的定义四。硅片满足这个判据——不是因为 “硅片的实际行为” 是一个能被看到的对象（能得到的只是有限条件下经由测试装置产生的有限个读数），而是因为这些读数的来源在链外，是与器件的因果接触，不是模型之间的推导；按 Cohn 的说法，物质器件只能被观察和测量，不能被验证（Cohn, 1988）。架构师的意图也不能由规格内部的证明直接核验：按 Cohn 的说法它本身不可直接通达——规格可以表达意图，但规格是否忠实、充分地表达了意图，不能由规格内部的证明自行担保；从意图到规格的压缩另属第三层的性质（§4.3），不在第一层的解法所能覆盖的范围内。

§4.2 第二层：动态腐蚀

假设第一层被部分解决：某个时钟或指标在初始时刻是可靠的，其映射函数大致已知且经过验证。

在此条件下出现一个新的困难：一旦该读数被用于奖励、惩罚、资源分配或绩效评估，便可能诱发行为者围绕读数调整行为。在足够强且持续的激励下，映射函数可能不再稳定——其使用本身参与了映射的改写。

之宜，异于约则谓之不宜”。差别在于 Humpty Dumpty 是个人当场规定，荀子说的是群体约定俗成——Kershaw 的 “该领域大多数从业者接受” 正落在后者，不在前者。

[8] 该标准为英国国防部《临时国防标准 00-55：国防装备中安全攸关软件的采购》（*Interim Defence Standard 00-55: The Procurement of Safety Critical Software in Defence Equipment*），第一部分第一版，1991 年 4 月 5 日发布（书目信息据 MacKenzie, 1991 文献条目 15；本书未直接查阅该标准原文）。MacKenzie 记述，国防部在该标准中所设想的是由自动定理证明器产出、再由独立编写的程序核查的证明；这种独立机械核查只有在使用形式证明时才可设想，对通行的严格论证则几乎不可想象（MacKenzie, 2001）。MacKenzie 界定的 “严格论证”（rigorous argument），指那些被数学家或相关专家接受为证明、但并非形式证明的论证（MacKenzie, 2005）。

这一现象在经济学中由 Lucas（1976）给出了影响深远的形式化表述：政策变化会引起行为者决策规则的调整——行为体会根据新政策重新优化自己的策略——因此不能无条件地把旧政策环境下估计的模型关系视为政策不变。Lucas 的命题最初针对宏观计量模型，但其结构在更广泛的领域被反复确认。[9]

具体而言，存在两种偏移机制：

- **策略性博弈（有意图的）。**行为体主动操纵读数，以在给定指标上获得更有利的结果，而不改变指标本应测量的底层真实。例如，学者组建引用联盟互相抬高被引次数，企业通过会计手段平滑季度盈利。在这一过程中，从底层真实到读数的映射被有意修改，而底层真实本身保持不变。
- **选择性适应（无意图的）。**不适应指标的行为体在系统运行过程中被逐步淘汰，存活者呈现出适应指标特征的自然集中。在此情形下，不将精力投入指标优化行为的学者，其研究成果在指标上的可见度降低，从而在资源分配中处于不利位置，其持续参与研究的条件逐渐丧失。不需要任何主体有意识地操纵指标，系统同样发生腐蚀。选择性适应比策略性博弈更难防御——因为不存在可以识别和惩罚的行为主体。

五个研究传统的相邻支持。古德哈特（Goodhart, 1984）从货币政策经验出发，指出被当作政策目标的货币统计量会丧失其作为良好指标的属性；斯特拉森（Strathern, 1997）将这一判断一般化为今日广为流传的版本[10]。坎贝尔（Campbell, 1979）从社会评估实践出发，指出量化社会指标越多地被用于社会决策，就越承受腐蚀压力，也越容易扭曲和腐蚀其本应监测的社会过程。Espeland & Sauder（2007）从大学法学院排名的实证研究出发，识别出 “自我实现预言” 与 “通约” 两种引发反应性的机制，并把博弈策略的扩散列为反应性的三类效应之一——博弈策略对应本节区分的策略性博弈（有意图的偏移）；自我实现预言通过期望—反馈确认自身，选择性适应通过差异存续改变主体构成，二者不能等同。Scott（1998）从国家治理的可读化工程出发，指出 “特定形式的知识与控制要求一种视野的窄化”，使视野中心的现象更可读；当这种简化与国家权力结合，被压制的非正式过程不只是被忽视，而是被重塑。赵鼎新（2022）从社会本体论角度指出，物理定律不因人类理解而改变其运行方式，而 “人类巨大的策略性行动能力和自我论证能力导致了结构和功能在人类社会中大规模的脱节，导致了不具稳定性的正反馈机制主导了人类的个体行为和整个社会的发展，给了人类巨大的创造社会机制和改变这些机制的重要性和作用方式的能力……”。这五个传统分别来自货币政策、社会项目评估、组织社会学、国家治理与社会机制理论，但它们并不各自证明本节两种偏移机制，也不构成同一结论的五份独立证据。它们共同支持的是一个较宽的命题：当读数、分类与评价进入行动和治理过程后，社会行动者及其环境会随之改变。其中，Goodhart、Campbell、Espeland & Sauder 更直接支持指标失稳与反应性；Scott 与赵鼎新分别提供国家可读化重塑和社会机制非稳定性的相邻解释。本节的选择性适应仍须按差异存续与主体构成变化另行举证，不能仅由自我实现预言或一般正反馈推出。

映射的自我引用。当多个时钟互相校准——每个时钟的读数以其他时钟的读数为参照——映射函数从 “以真实状态为输入的映射函数 $\pi_i(T)$” 退化为 “以其他读数为输入的映射函数 $\pi_i(\{r_j\}_{j\neq i})$”。真实状态从映射的输入中部分消失。时钟开始更多地指向其他时钟而非真实。在此过程中，系统内部的一致性持续增长，但与真实之间的偏差也可能同步增长——两者不是相互制约的关系，而是可以同步推进。当代金融市场的价格发现机制、学术评价的引用网络、社交媒体的话题趋势，都在不同程度上依赖这一结构运作。

---

[9] Lucas, R. E., Jr. (1976). Econometric Policy Evaluation: A Critique. *Carnegie-Rochester Conference Series on Public Policy*, 1. 关键命题原文：“[G]iven that the structure of an econometric model consists of optimal decision rules of economic agents, and that optimal decision rules vary systematically with changes in the structure of series relevant to the decision maker, it follows that any change in policy will systematically alter the structure of econometric models.” 卢卡斯批判作为方法论命题的影响远超出宏观计量本身：本节将其视为指标 / 读数系统在被用于政策或评估时映射函数失稳的一个形式化锚点，不据此作历史优先权断言。

[10] 广为流传的 “When a measure becomes a target, it ceases to be a good measure” 并非 Goodhart（1984）原著原文，而是 Strathern（1997）对 Goodhart 原意的一般化改写。Goodhart 原文的表述更窄，限于货币政策领域。

金融市场给了这个结构一个有据可查的实例。按 MacKenzie（2006）第六章的记述，布莱克-斯科尔斯-默顿期权定价模型进入交易实践后，交易者改用一个叫隐含波动率（implied volatility）的量沟通与定价——它是把模型倒过来跑、用观察到的期权价格反推标的股票波动率得出的；到后来，期权价格有时不再以美元报出，而直接以隐含波动率报出（同书第九章）。而模型所需的这个参数本来不可直接观测，因此不存在唯一的理论价格可与实际价格相比。缺锚的那一处，最终由一个从读数反推出来的量填上：被报出、被比较、被据以决策的数，是读数经模型加工后的产物，不是与标的资产的独立接触。用本节的语言，映射函数（π_i）的输入从真实状态换成了其他读数；用 §1.4 的语言，这是一个关于读数的读数取代原始读数成为操作界面。

MacKenzie 本人的核心概念与本节方向不同。他所说的巴恩斯式表演性（Barnesian performativity）指一项经济学的实际使用使经济过程变得更接近经济学所刻画的样子，即使模型变得更真（同书第一章）——那是偏差下降，不是本节所说的偏差上升。在本书的语言里，这里需要区分两种情形：真实过程受模型使用影响，并不自动意味着对实际结果的独立检验已经失效；但若把这种反馈促成的一致性本身当作模型已经得到独立校准的证据，就会把模型参与塑造的结果误当作独立验证。只有当校准证据也由这一读数闭环生成、且缺乏独立检验时，才能说参照的独立性失效。此时，锚点不是漂移，而是被吸收进了读数系统的自我验证。他还指出这种效果不依赖任何人相信模型——模型并入算法、程序、例行做法与物质装置之后，即使使用者怀疑它的优点、不了解它的细节、甚至不知道它的存在，它仍然产生效果。这说明模型的作用不必以使用者相信模型为前提；若要进一步说明本节定义的选择性适应，还须指出模型如何参与资源分配和存续条件的筛选，使不适应指标者逐步退出、存活者的构成随之改变。

需要明确的是：自我引用是一个程度问题，不是一个类别问题。金融市场中仍然存在套利机制和破产事件——这些构成与真实的因果接触。学术引用仍然与论文内容保持一定关联，这一关联可能受到策略性引用与声誉累积效应的削弱。“部分脱节” 意味着校准仍然可能，尽管困难增加；“完全脱节” 则意味着校准在原则上不再可能。本章讨论的是前者——脱节的持续恶化趋势——而非后者的已然完成状态。

动态读取的时间代价。观测本身消耗时间。当房间里的人开始读取第一个时钟时，“现在” 已经变成了“过去”。当他完成所有时钟的读取，真实时间已经继续前进。他所获得的并非 “此刻的读数集合”，而是不同时刻读数的拼接——一个滞后于真实状态的信号组合。

与第一层的区别。第一层是静态困境：映射函数未知但稳定，解法是一次性的校准。第二层是动态困境：映射可能因使用而被改写；校准结果一旦进入激励与资源分配，便可能触发去校准的连锁反应。只要这些激励与适应条件持续存在，这就不是一次干预即可终结的问题，而是需要持续投入校准资源的过程。

§4.3 第三层：本体论降维

前两层都保留了一个理想极限——如果校准速度无限快于腐蚀速度，也许可以逼近完美。第三层否定了这个极限。

真实状态有多个维度，时间的即时位置是其中的一个维度。时钟将多维真实压缩为一维读数，丢失了与被丢弃维度之间的关系——这种关系有时是时间信息的组成部分（例如 “几点了” 在某种情境中实际上在问 “现在是傍晚还是深夜”，后者的信息来自光线和身体状态，不是来自钟面）。温度、光线的角度与色温、身体的疲惫程度、窗外的声音、空气的湿度、心跳的节律——这些不是时间的 “附加属性”，它们是 “此刻” 本身的构成维度（作为体验范畴；物理计时范畴见下文）。当时钟将 “现在” 压缩为一个数字，它执行的是降维。被丢弃的维度不能再由该读数逐一唯一恢复；这不等于它们对读数毫无影响。

如果真实状态空间（$\mathcal{T}$）的维度高于可观测空间（$\mathcal{O}$）的维度（即 $\dim(\mathcal{T}) > \dim(\mathcal{O})$），在通常的拓扑假设下（$\mathcal{T}$ 与 $\mathcal{O}$ 取欧氏空间开区域或有限维流形一类通常形态时），任何连续映射 $\pi : \mathcal{T} \to \mathcal{O}$ 都不可能

是单射——高维空间中两个不同的真实状态必然在低维空间中映射为同一个读数。因此至少存在非单点纤维。即使完美知道映射函数的每一个细节，也不存在能够对所有真实状态都作唯一恢复的逆向映射——用于全局唯一恢复全部真实状态的信息不再由该映射可逆保留；读数仍可能携带关于这些状态的部分信息。

需要交代这里的可观测空间（$\mathcal{O}$）指什么。它指钟面这一类低维连续对象——指针的位置本身连续变化，所以谈它的维度、谈映射是否连续都有意义。人实际记下的读数还要在此之上再经一道刻度化："三点四十七分" 是把连续的指针位置归入一个有限的刻度集。那是第二重损失。§1.4 说的 "覆盖了表盘上每一个可能读数"、§5.2 说的 "离散的、有刻度的"，都落在第二重上。本节的论证只用到第一重：即使刻度无限细密，降维本身已经排除了全局唯一逆向恢复。

这一论证在不同场景中的适用强度不同。在社会指标的场景中，降维论证较为直接——"学术质量" 确实不能被压缩为一个数字，因为确定学术质量本身就需要被丢弃的维度（上下文、动机、原创性的微妙差别）。在物理计时的场景中，降维论证的力度较弱——协调世界时（Coordinated Universal Time，UTC）确实可以被一个数字良好近似，时钟的 "降维" 更像温度计 "丢弃" 了气压信息：技术上是准确的，但构不成对温度计的批评。本章的核心应用场景——人工智能（AI）对齐、金融指标、学术评价——属于前一类，降维论证在这些场景中有完整的效力。本章讨论这些场景中需要保留上述多维差异的评价任务；若任务只要求某个已定义的低维量，不能仅凭全状态不可恢复就断言该指标失效。

冯·诺依曼在《计算机与人脑》中从工程方向识别了两种记谱系统的根本差异，尽管他的比较对象是人脑与计算机的符号系统，而非真实状态与读数系统：他指出人脑神经系统所使用的记号系统于本质上属于统计性（"essentially statistical"）的计算模式，信息由脉冲串的统计特征承载，与数字计算机所依赖的离散、序列化符号系统（其中每一标记的精确位置决定了信息含义）属于根本不同的记谱类型——在这种记谱方式中，系统以较低的算术精度换取较高的逻辑可靠性。本书把这一差异引申为降维命题的工程侧呼应；这一引申是本书的，冯·诺依曼本人的落点是精度与可靠性之间的权衡，不是降维（von Neumann, 1958, *The Computer and the Brain*, "Arithmetical Precision or Logical Reliability, Alternatives" 一节）。

§4.4 汇总

表 2. 三层不可逆的困境与可解性

层次	困境	纤维状态	原则上可解？
第一层：信息缺失	不知道映射函数	完全未知且无先验约束时为全集；有先验约束时可能缩小	可解，需要外部锚点
第二层：动态腐蚀	激励与适应可能改写映射函数	既有校准约束可能失效，需要持续更新	需要持续校准，能否收敛取决于腐蚀与校准条件
第三层：本体论降维	映射本身必然有损	存在不能靠校准消除的非单点纤维	不可彻底消除

三层之间是递进的。第一层说需要校准。第二层说校准所依赖的映射可能受到腐蚀。第三层说即使校准不被腐蚀，映射本身也是有损的。这里的递进，是后一层指出前一层的解法仍不能消除的限制。现实中

三层通常同时在场。[11]

本章不提供 “突破房间” 的方案——对钟点这类低维任务，障碍在第一层（映射未知，原则上可解）；而只要任务要求恢复被降维丢弃的状态维度，第三层在数学上不可消除，房间就没有完全的出口。本章提供的是对困境结构的精确判断，以及在结构内部通过 “可见性” 来降低灾难风险的路线。

---

§5 在时钟上做功与在时间上做功

三层不可逆描述了读数与真实之间的关系。但还有一个问题不在三层之内——映射行为对认知者自身的影响。

§5.1 两种做功方式

人类文明的绝大部分历史中，人与世界的接触是多通道的、连续的、关系性的。手碰到材料的质感，眼睛看到火焰的颜色变化，师傅示范给徒弟的动作——这些是在时间中做功，在做的过程中积累了做的能力。

当读数系统介入——计时器、关键绩效指标（Key Performance Indicator，KPI）、评分、算法——一部分做功从时间中转移到了时钟上。在这些场景中，人的部分行动开始更多依赖一个或少数几个读数，而不是同时动用原有的多通道接触。读数更清晰、更方便、更适合协调。它带来的首先不是错误，而是收益；正因为收益巨大，它的存在性代价才容易被忽略。但它同时也在重新塑造认知者的位置。

这两种做功方式的区别不是 ‘原始 vs. 现代’——不是一条进化阶梯。它们是两种不同的与世界接触的方式，各有适用的场景。Weizenbaum（1976）以 ‘从判断到计算’（From Judgment to Calculation）为副标题指出了这一区分的认识论实质：‘权力，若不是选择的权力，就什么都不是。工具理性能做出 “决定”，但 “决定” 与 “选择” 之间横亘着全部差距’[12]。在时间上做功更直接体现判断——在嵌入的、关系性的、不可完全形式化的情境中选择；在时钟上做功更突出计算——在读数构成的形式系统中作出决定。两者都能产出行动，也都可以被纳入人对行动意义的承担；本章批评的是行动的最终理由只剩读数系统的最优指令、选择不再由行动者承担的情形。在时间上做功长期是人类生存的重要基底。近两个世纪，随着工业化与现代组织扩张，在时钟上做功在越来越多协调与治理场景中占据重要位置，推动了资源开发与工业革命，也使三层不可逆描述的困境获得新的规模与制度化形态。本章提出的问题不是 ‘要不要用时钟’，而是：当 ‘在时钟上做功’ 成为压倒性的主导模式时，三层不可逆的困境会系统性地加剧。

与 “科学主义” 的接合。王德峰对 “科学主义” 给过一个相邻的诊断：“反对 ‘科学主义’，不是反对 ‘科

[11] Ashby（1956）在《控制论导论》第十一章给出的必要多样性定律，为第一层提供了一个来自控制论的外部度量说法：调节者的调节能力不可能超过它作为通信通道的能力（原书 S.11/11 节）；在要求结果完全恒定、且固定调节动作时不同干扰仍产生不同结果的条件下，调节者的多样性必须不低于干扰的多样性（S.11/5–S.11/7）。若系统本身已阻断部分干扰，则应计入这一消减，不能把全部干扰的多样性直接作为调节者的必要下界（S.11/9、S.11/11）。时钟的房间抽掉的正是这条通道——时钟都在房间内部，没有连到外面。定律的性质需要说明：Ashby 特意指出它的不可能性与物质的性质无关、与机器的性质无关，只是关于一张矩形表里哪些排列做不出来的陈述，因此不欠实验任何东西（S.11/10 节）。它是结构命题，不是经验命题——不会被违反；在上述条件下，当调节者的多样性不足以匹配干扰的多样性时，所要求的完全恒定结果无法实现——这种失败是定律约束的体现，而不是对定律的违反。第二层的动态腐蚀超出这条定律的适用范围：Ashby 把干扰与表当作外生给定的硬世界（S.11/11 节），不处理干扰的多样性因调节行为而内生增长的情形；本章把第二层接到这一度量语言上，是本章的扩展，不是 Ashby 的命题。

[12] Weizenbaum, Joseph. *Computer Power and Human Reason: From Judgment to Calculation*. San Francisco: W. H. Freeman, 1976. 引文见第十章 “Against the Imperialism of Instrumental Reason”：“Power is nothing if it is not the power to choose. Instrumental reason can make decisions, but there is all the difference between deciding and choosing.” 另见第一章 “On Tools”（论工具）中关于时钟的讨论：“experiences of reality had to be representable as numbers in order to appear legitimate in the eyes of the common wisdom”。副标题 “从判断到计算” 与本章 “从时间维度到时钟维度” 的命题结构同构。

学’……科学一旦突破了自身的意义范围，承当起对人生意义的诠释，其结果一定是人的异化、物化”[13]。“在时钟上做功” 成为压倒性主导模式，在哲学侧的对应正是 “科学主义”——把测量当成栖居，把读数当成生活的基础。本章不展开这一对应，只在此标注：三层不可逆描述的认识论困境，与 “科学主义” 作为一种生存取向的存在论病灶，在结构上是同一组问题的两面。

§5.2 时间维度与时钟维度

可以更精确地说：

时间维度是连续的、多通道的、关系性的存在模式。人的饥饿和上一顿饭的关系、人的疲劳和劳动的关系、人的心跳和情绪的关系——这些是关系性的，不是孤立个体的感官接收。

时间维度不是 “无映射的纯粹存在”——身体感受本身也是映射。视觉经过视网膜、视神经、视皮层多层处理；触觉经过受体、脊髓、大脑皮层。柏拉图早已区分过 “凭借” 与 “经由”：在《泰阿泰德》184c–184d 里，苏格拉底追问我们究竟是 “凭借” 眼和耳而感觉、还是 “经由” 眼和耳而感觉，泰阿泰德答 “经由”，苏格拉底的表述将这一区分概括为——不是凭借感官感觉，而是经由感官感觉。这段对举在前半句：可感事物不是经由心灵、而是凭借心灵来感知（“not through, but with the mind”）——心灵占据 “凭借” 之位，感官占据 “经由” 之位（Jowett 译本）。身体的因果链不一定比时钟读数 “更短”。但身体有时钟做不到的东西：同时多通道整合。人同时在温度、光线、饥饿、疲劳、心率等独立通道上接收信号，这些通道之间可以交叉校验。时钟是单通道读数，没有旁证。纤维的差异不来自因果链的绝对长度，而来自通道数量和交叉校验的可能性。

多通道交叉校验的优势有一个前提：不同通道的偏差来源通常不同。视觉的偏差和触觉的偏差通常由不同原因导致，所以互相校验有效。但当偏差来源相同时——药物改变所有感知通道，高烧让时间感、温度感、疲劳感全部失调——多通道交叉校验失效，因为所有通道同时被同一来源扭曲。多通道的优势是统计性的（通常有效），不是结构性的（必然有效）。

时钟维度是离散的、有刻度的、仅处理读数的操作模式。一个数字，没有旁证。关系性的多维存在被压缩为单维度的数字读数。

本章主张的不是 “存在一种无映射的存在方式”，而是 “映射有更好和更差之分——在保留原有观测的基础上，增加能够提供新约束的可校验通道，可以进一步缩小相容状态集合；重复信息或同源偏差的通道不保证带来这一效果”。这两种模式各有适用场景；当多通道、可交叉校验的映射被系统性压缩为单通道读数时，三层不可逆困境加剧。本章默认以候选集合的包含关系作偏序比较：只有 $F_A \subseteq F_B$ 时，才说 A 的纤维不大于 B；严格包含时才说缩小。有限集合可以计数，给定概率模型时也可计算任务相关的信息量，但本章不预设跨场景通用的单一数值尺度。

§5.3 进入时钟维度

当人开始完全以钟表读数作为决策依据，就从时间维度进入了时钟维度。这不是一次中性的操作模式切换——行动节律由内生转为外置（摘要中 “从在时间中存在滑向在时钟中反应” 的精确所指）。本节进

[13] 王德峰对 “科学主义” 的规范定义见《寻觅意义》（山东文艺出版社，2022）「当代文化状况与中华文化之生命」篇「科学主义与资本逻辑」节：“反对 ‘科学主义’，不是反对 ‘科学’，我们要区分这两个概念：一个是科学，一个是科学主义。科学本身没什么错。……但是我们反对科学主义。科学一旦突破了自身的意义范围，承当起对人生意义的诠释，其结果一定是人的异化、物化。” 最简洁的定义见《哲学导论》课程讲稿（王德峰, 2014）：“我们今天只相信科学的才是真实的。这里边有这样一个信念，我们把这种信念叫科学主义。科学主义是一种信念。我们批评的不是科学而是批评了科学主义。” 这两条合起来给出本节所用的 “科学主义” 双重定位：不是以可检验、可证伪的科学本身为对象，而是以 “只相信科学才是真实的” 这一信念为对象——这一信念使读数从工具越到生活基础的位置。

一步讨论这一模式与 §4.2 所述的激励和适应过程结合、且未被编码的经验不再进入判断的情境；在这一情境中，三层困难相互强化。

第一层：独立校准的缺失。在时间维度，多通道交叉校验提供对映射函数的部分约束——人不知道映射的全部，但多通道之间的一致性检验能排除部分可能状态，纤维部分缩小。时钟维度的定义就是：单通道、无旁证、无外部接入。这意味着独立校准不再提供新的约束；既有的先验和校准知识仍可限制纤维，但不能仅凭读数自身确认这些约束仍然有效。只有当映射函数完全未知、且没有先验约束时，纤维才为全集。

第二层：激励与适应对校准的侵蚀。此处沿用 §4.2 的前提：读数被用于奖励、惩罚、资源分配或绩效评估，行为者通过策略调整或选择性适应回应这些安排。在这一反馈过程中，映射函数不再能被当作始终稳定的外生参数，既有校准必须随之接受持续检验。

第三层：本体论降维。将连续、多维的真实压缩为离散、有限维的读数，在信息论上是必然有损的。但本体论降维比信息损失更深一层。Weizenbaum（1976）指出："对现实的经验必须能被表示为数字，才能在流行见识眼中显得合法"（"experiences of reality had to be representable as numbers in order to appear legitimate in the eyes of the common wisdom"）。这揭示了读数系统的合法性逻辑：不可量化的经验不仅"暂时不被看到"，而是丧失了作为经验的合法地位。读数系统不只是为真实加了一层简化——它压制了无法被编码的部分。未被读数编码的维度在时钟维度的操作语言中不存在，且不被承认为合法的认知对象。人无法用读数的语言提问 "读数没有编码什么"——这个问题本身就在时钟维度的词汇之外。

三层之间的递进与自封闭。当偏差的可辨别信息随被省略的维度一并消失时，单凭时钟维度的读数及其既有约束，无法识别这些偏差；读数内部违反既有约束的信号仍可能暴露异常，但发现异常不等于完成校准。若能观察到被读数省略的维度，第一层就可以被部分修复（即看出映射缺了什么）；若能观察到博弈和适应性偏移的发生，第二层就可以被部分抵御（即看出映射在退化）。但当识别偏差所需的信息确实随降维丢失时，第三层会遮蔽这类偏差；是否完全不可识别，取决于具体映射和既有约束。三层不是三个并列的问题，而是一个自封闭的陷阱：第三层保护这些偏差免于被发现，前两层持续恶化人与真实的关系。这是上述条件共同作用下形成的自封闭处境。

---

§6 当代时钟房间

三层不可逆不是一个抽象的认识论困境。它以不同形式出现在当代人工智能（AI）系统的评估、对齐与使用中。

§6.1 人工智能（AI）对齐与有帮助、诚实、无害（HHH）三难困境

当代人工智能（AI）伦理的核心框架——有帮助、诚实、无害（Helpful, Honest, Harmless；HHH）——在时钟房间的视角下暴露了深层困境。

有帮助（Helpful）。房间里的人面对 "过多久是六点" 时，能给出时钟数量（N）个精确的运算结果。计算能力上他完备。但他无法确定哪一个答案对应于真实——因为 "有用" 的条件是答案与真实时间对齐，而他不知道真实时间。N 个答案中可能恰好有一个是对的，但他无法将其从其他答案中识别出来。当人工智能（AI）的训练数据包含相互矛盾的信息源时，如果开发与评估流程隐含地将有帮助（Helpful）

等同于 “给出确定答案”[14]，系统便会在映射未知的情况下强行输出一个 “看似确定” 的答案，这就是用流利掩盖不确定性。

诚实（Honest）。当大语言模型（Large Language Model，LLM）的人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF）训练奖励偏向自信回应时，系统会面临少报知识边界的压力。以下研究分别提供概率校准与错误模仿方面的证据，不能单凭它们断言所有当前模型均有同一种回应倾向。对模型自我评估能力的测量显示：较大的模型在格式恰当的多选与判断题上校准良好，但经人类反馈强化学习（RLHF）训练的策略会出现校准失真（这一失真可通过温度调节部分校正），并且模型在新任务上难以校准自己 “是否知道答案” 的判断（Kadavath et al., 2022）；模型还会系统性地模仿训练数据中的人类错误观念（Lin et al., 2022）。宪法 AI（Constitutional AI）等范式试图通过原则约束缓解这一问题（Bai et al., 2022），但校准的根本困难——映射函数未知——仍然独立于任何训练技巧。

无害（Harmless）。当人工智能（AI）在高危领域给出流畅、自信但未经校准的答案时，表面的无害掩盖了实质的危害。

在本段采用的狭义操作定义下，三者之间存在结构性张力。若将有帮助（Helpful）理解为必须输出一个确定的、可行动的回答，则任何具体答案均有出错的概率；若将诚实（Honest）理解为必须声明不确定性，则声明本身可能降低回答的有用性；若将无害（Harmless）理解为避免任何可能的错误输出，则沉默本身违反有帮助（Helpful）的要求。三者能否在更精细的定义下兼容，是另一个问题——但当前工程实践中的两类证据分别提示了两方面风险：上述校准失真提示训练可能扭曲置信表达；而把弃答按错误计分的准确率评估，会通过模型选择与开发过程形成偏向确定输出的激励（Kalai et al., 2026）。当系统把这类得分优势转化为输出策略时，第一种定义的有帮助（Helpful）可能以少报不确定性为代价；在高危应用中，这种取舍还会增加伤害风险。需要指出的是，有帮助的、诚实的、无害的（HHH）框架的提出者在原始论文中已承认三个目标间的张力（Askell et al., 2021）；后续的宪法 AI 路线则试图通过原则约束来重新定义有帮助（Helpful）——使其包含诚实的维度，即在不确定时表达不确定（Askell et al., 2021；Bai et al., 2022 通过原则约束推进此方向）。本章的分析并非否定这一方向，而是揭示：只要系统优化目标中包含对 “流畅确定性” 的偏好奖励，系统就持续面临生产 “看起来确定但实际不确定” 的输出的结构性压力。

§6.2 中文房间与时钟房间

Searle（1980）发表在《行为与脑科学》上的论文《心灵、大脑和程序》（Minds, Brains, and Programs），设计中文房间思想实验，是为了检验强人工智能（strong AI）的一项主张：得到适当程序的计算机，可以在字面意义上理解故事并具有认知状态，程序本身也因而构成对人类理解的解释。

该实验设想一个完全不懂中文的人被锁在房间里。房间里的人按照一套英文规则，仅凭符号形状把输入与输出关联起来，再递出相应的中文符号。他不知道这些符号分别是故事、问题和答案，也不知道这套规则就是程序。房间外的人无法把他的中文回答与中文母语者的回答区分开来。

Searle 据此主张，正确的输入输出和纯形式的符号操作，不足以构成理解。这个论证针对的是强人工智能，而不是把计算机作为研究工具的弱人工智能（weak AI）。

中文房间与时钟房间的核心差异如下：

表 3. 中文房间与时钟房间的比较

[14]Kalai et al.（2026）分析了把弃答按错误计分的准确率评估：在模型认为仍有答对可能的情况下，猜测的期望得分高于弃答；这类指标通过模型选择与开发过程，形成不利于在不确定时弃答的激励。

维度	中文房间	时钟房间
规则	有手册（保证正确输出）	无手册
局部理解	无（人不懂中文）	有（人懂每个时钟）
核心命题	语法操作 ≠ 语义理解	局部理解 + 全部内部读数 ≠ 全局真值

中文房间揭示了 “正确输出” 不蕴含 “理解”。时钟房间揭示了 “理解” 不蕴含 “正确输出”。两者嵌套而非平行——无论中文房间之争如何解决，时钟房间的问题独立存在。能够理解读数，并不意味着已经具备校准这些读数的独立依据。

针对中文房间，一种常见反驳是 “系统回应”（Systems Reply）：即使房间里的个人不理解中文，由个人、规则手册、符号数据库和演算工具组成的整体系统仍可能理解中文。Searle 的回应是，让这个人把规则、数据库和演算过程全部内化；他仍然不理解中文，因此，单纯扩大系统的组成并未回答原论证。

时钟房间不受中文房间遭遇的 “系统回应”（Systems Reply）反驳的影响——把所有时钟联网、加上算法与加权平均，整个 “系统” 产出一个精美的共识读数——这仍是 §1.3 判断的一个实例：增加系统复杂度改善的是精度，不是与真实的对齐。

§6.3 中介问题

当代中介系统——从推荐算法到大语言模型——添加了一个新问题：自然语言界面可能使部分使用者在某些任务中降低对中介层的辨识。

中文房间里的人知道自己在遵循规则手册。时钟房间里的人知道自己在读钟。但当中介以自然语言对话的形式呈现输出，使用者可能从 ‘使用工具’ 滑向 ‘信任同伴’；界面因此可能遮蔽中介的身份。

先排除一个伪问题。当代中介系统不是封闭房间里的时钟——它们可以连接传感器、检索实时数据。在某种意义上它们有窗户。人类一直通过中介（书籍、教师、地图、仪器）接触世界，中介本身不是问题。当代人工智能（AI）中介的特殊之处在于其界面：以自然语言对话呈现输出，并主动填充使用者的认知缺口——补全省略的背景、重构语境、生成看似连贯的推理、给出具备完整句法和语气的回应。这一界面使使用者难以察觉自己正在经过一个中介层。

但问题不在于它有没有窗户。问题在于：**人们可能不再主动使用自己的窗户——习惯于通过中介的窗户看。**此时获得的主要是中介对真实的报告，而不是未经中介的真实本身。中介本身就是一个映射层，关键信号的筛选与呈现规则通常由系统设定，而不是由使用者逐项了解或决定。

忘记自己在通过中介接触世界，比中介本身的偏差更值得关注。

必须精确地说：问题不是人们不能检查——当中介系统报告天气而使用者走出门外发现不符，使用者知道系统错了。人们仍然有自己的感官经验。真正的危险是人们停止检查——这是一个行为问题（习惯的养成），不只是结构问题（系统不可能被检查）。但行为问题在规模化后会产生结构性后果：当足够多的人停止检查，中介的输出开始塑造共识，共识反过来强化对中介的信任。个体层面的行为惰性，在集体层面变成了 §4.2 描述的自我引用结构。

校准——如 §3.4 定义四所述——的目标不只是模型的输出准确性。当中介系统使人丧失了独立验证的习惯时，即使输出完全准确，使用者与真实之间的关系已经发生了变化——他从在时间上做功滑入了在时钟上做功。

§7 结论

§7.1 自指

本章本身是一次映射操作。

如果读者在读完后觉得自己“理解了”时钟不是时间——他应当追问：这种理解是来自校准（他用自己的经验独立检验了论证），还是来自另一个读数（他被论证的叙事说服了）。后者是 §3.6 闭环伪校准的又一实例。

本章的全部论证可以用它自身来检验——但需要区分两类检验。对 §5 中“时间维度”与“时钟维度”的区分，读者可以回想自己在具体情境中的体验：在何时自己的判断完全依赖单一数字读数，又在何时依赖多通道的、交叉校验的身体感知。区分是否成立，由读者根据自己的经验做出判断——这不属于形式验证。对 §3.5 的数学命题（“纤维在映射完全未知且候选映射无先验约束时为全集”），检验方式则是检查证明的逻辑结构——这是形式验证。自指的警告对后者仍然适用（读者可能只是被证明的叙事说服了而没有真正检查逻辑），但检验路径不同。

如果读者在读完后仅因论证的叙事力量而接受其结论——未对存在论部分回溯自身经验，也未对形式化部分检查论证逻辑——那么“我理解了映射困境”这个信念本身就是一个读数：它来自论证的说服力，而非来自读者的独立检验。这便在房间里添了一面内部一致的新钟。

§7.2 核心判断

在完全缺乏外部连续校准的条件下，一组映射读数本身并不保证包含关于被映射对象的可验证信息。

信息可以缺失（可补救）。校准可以被腐蚀（难补救）。映射本身可以是有损的（不可补救）。映射行为还会改变认知者与世界的关系——从在时间上做功，滑入在时钟上做功。

仅凭数量本身，千百个时钟回答不了“现在几点”。千百篇论文回答不了“真相是什么”。千百个指标回答不了“质量如何”。

不是因为不够多。是因为“多”是在映射空间里的多，不是在真实空间里的多。

§7.3 从认识论到记账

文明不能不用时钟。问题从来不是“要不要用时钟”，而是当人们不得不使用时钟时，怎么追踪时钟和真实之间的差距？怎么在差距累积到危险程度之前发出警报？怎么区分“这个钟虽然有偏差但偏差可控”和“这个钟的偏差正在被系统性掩盖”？

以下不是本章的完整解决方案，而是从上述分析自然推出的一种最小制度直觉。追踪差距需要一个记账结构——一套强制性的纪律，让每一笔被接受的读数都同时记录：映射函数有多少是已知的，候选集合的范围及其任务特定度量（如有），校准最后一次发生在什么时候，以及谁在承担候选集合发生变化的后果。

对第一层，记账追踪校准状态——哪些映射函数已知，哪些未知。对第二层，记账追踪腐蚀速度——映射函数的偏移率与校准频率的比值，当比值超过阈值时触发警报。这一比值须在具体任务中规定偏移的度量、校准的有效性及报警阈值；这里先提出追踪关系，不预设全场景通用的数值尺度。对第三层，记账不追踪差额（未被编码的维度不能仅凭该读数直接计量），而是标记差额的存在——在每一笔记录

旁边写下 “此处存在不可消除的不确定性——映射可能丢弃了未被编码的维度”。标记不消除这种不确定性，但它防止人忘记不确定性的存在。忘记比不确定性本身更危险。

记账结构不是问题的解决方案。它是使问题可见的工具。“没有记账” 和 “有记账但记账本身也是时钟” 之间的差别是真实的——但这个差别是关于可见性的，不是关于消除的。记账让人知道自己在一个有纤维的系统中做功。它不消除纤维。记账结构本身也是一种映射——当其结果进入激励与资源分配过程时，它可能触发第二层动态腐蚀，也会呈现第三层所讨论的降维与残余不确定性，且其自身的纤维不可消除，将需要被持续审计。建立它不意味着问题解决，只意味着问题被推到了一个可以被持续关注的层面。建立这个记账结构，将认识论的洞察转化为操作的纪律，是下一步的任务。该记账结构的操作化方案将在后续的第三章宏观认知债务记账框架（Macro-Cognitive Accounting Framework，MCAF）中给出。

参考文献

柏拉图. (2018). 泰阿泰德 (詹文杰译). 载《柏拉图哲学作品集》(汉译世界学术名著丛书). 北京: 商务印书馆.

冯・诺依曼. (2009). 数学在科学和社会中的作用 (李文林主编, 含译者序). 大连: 大连理工大学出版社.

王德峰. (2014). 哲学导论 (课程讲稿, 视频文字整理稿). 哔哩哔哩. https://www.bilibili.com/video/BV1XQ4y1d7BB/

王德峰. (2022). 寻觅意义. 济南: 山东文艺出版社.

《荀子・正名》. 引文据王先谦《荀子集解》, 沈啸寰, 王星贤整理, 北京: 中华书局, 2012(中华国学文库).

赵鼎新. (2022). 解释的层次与诠释圈. 人类学研究, 第 15–16 辑. https://mp.weixin.qq.com/s/iE1IyUj7IDhrET1fH-eA5g

Ashby, W. R. (1956). *An Introduction to Cybernetics*. London: Chapman & Hall.

Askell, A., et al. (2021). A General Language Assistant as a Laboratory for Alignment. arXiv:2112.00861. https://arxiv.org/abs/2112.00861 [预印本, 尚未经同行评审]

Bai, Y., et al. (2022). Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073. https://arxiv.org/abs/2212.08073 [预印本, 尚未经同行评审]

Brock, B. & Hunt, W. (1990/1991). Report on the Formal Specification and Partial Verification of the VIPER Microprocessor. NASA Contractor Report 187540 / CLI Technical Report 46. https://ntrs.nasa.gov/citations/19910018472

Bródy, F., & Vámos, T. (Eds.). (1995). *The Neumann Compendium*. Singapore: World Scientific.

Campbell, D. T. (1976/1979). Assessing the Impact of Planned Social Change. *Occasional Paper Series*, 8, Dartmouth College (1976); 重刷于 *Evaluation and Program Planning*, 2(1) (1979). https://doi.org/10.1016/0149-7189(79)90048-X

Carroll, L. (1871). *Through the Looking-Glass, and What Alice Found There*. London: Macmillan. 引文据 Project Gutenberg 电子文本 (eBook #12). https://www.gutenberg.org/ebooks/12

Chang, H. (2004). *Inventing Temperature: Measurement and Scientific Progress*. Oxford: Oxford University Press.

Cohn, A. (1988). *Correctness Properties of the Viper Block Model: The Second Level*. Technical Report 134, University of Cambridge Computer Laboratory. https://www.cl.cam.ac.uk/techreports/UCAM-CL-TR-134.pdf

Espeland, W. N., & Sauder, M. (2007). Rankings and Reactivity: How Public Measures Recreate Social Worlds. *American Journal of Sociology*, 113(1). https://doi.org/10.1086/517897

Formica, G. (2011). Almost von Neumann, Definitely Gödel: The 2nd Incompleteness Theorem's Early Story. *Logic and Philosophy of Science*, IX(1). https://sites.units.it/episteme/L&PS_Vol9No1/L&PS_Vol9No1_2011_12_Formica.pdf

Formica, G. (2023). John von Neumann's Discovery of the 2nd Incompleteness Theorem. *History and Philosophy of Logic*, 44(1). https://doi.org/10.1080/01445340.2022.2137324

Gettier, E. L. (1963). Is Justified True Belief Knowledge? *Analysis*, 23(6). https://www.jstor.org/stable/3326922

Goodhart, C. A. E. (1975/1984). Problems of Monetary Management: The U.K. Experience. In *Papers in Monetary Economics*, Vol. I, Reserve Bank of Australia (1975); reprinted in *Monetary Theory and Practice*. London: Macmillan (1984).

House of Commons (1991). VIPER Microprocessor. Written Answers, *Hansard*, HC Deb 23 May 1991, vol 191. https://api.parliament.uk/historic-hansard/written-answers/1991/may/23/viper-microprocessor

Hume, D. (1739–1740). *A Treatise of Human Nature*. London: John Noon (Vols. 1–2); Thomas Longman (Vol. 3). 中译本：休谟著，关文运译，《人性论》（上下册），北京：商务印书馆，1980。

Kadavath, S., et al. (2022). Language Models (Mostly) Know What They Know. arXiv:2207.05221. https://arxiv.org/abs/2207.05221 [预印本, 尚未经同行评审]

Kalai, A. T., et al. (2026). Evaluating Large Language Models for Accuracy Incentivizes Hallucinations. *Nature*, 653. https://doi.org/10.1038/s41586-026-10549-w

Krantz, D. H., et al. (1971). *Foundations of Measurement, Volume I: Additive and Polynomial Representations*. New York: Academic Press.

Lin, S., Hilton, J., & Evans, O. (2022). TruthfulQA: Measuring How Models Mimic Human Falsehoods. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics. https://doi.org/10.18653/v1/2022.acl-long.229

Lucas, R. E., Jr. (1976). Econometric Policy Evaluation: A Critique. *Carnegie-Rochester Conference Series on Public Policy*, 1. https://doi.org/10.1016/S0167-2231(76)80003-6

MacKenzie, D. (1991). The Fangs of the VIPER. *Nature*, 352. https://doi.org/10.1038/352467a0

MacKenzie, D. (2001). *Mechanizing Proof: Computing, Risk, and Trust*. Cambridge, MA: MIT Press.

MacKenzie, D. (2005). Computing and the Cultures of Proving. *Philosophical Transactions of the Royal Society A*, 363(1835). https://doi.org/10.1098/rsta.2005.1649

MacKenzie, D. (2006). *An Engine, Not a Camera: How Financial Models Shape Markets*. Cambridge, MA: MIT Press.

Mills, I. M., et al. (2005). Redefinition of the Kilogram: A Decision Whose Time Has Come. *Metrologia*, 42(2). https://doi.org/10.1088/0026-1394/42/2/001

Mumford, L. (1934). *Technics and Civilization*. New York: Harcourt, Brace & Co.

Plato. (1892). *Theaetetus*. In *The Dialogues of Plato*, trans. B. Jowett, 3rd ed. rev., Vol. 4. Oxford: Oxford University Press.

Rédei, M. (Ed.). (2005). *John von Neumann: Selected Letters*. History of Mathematics, Vol. 27. Providence, RI: American Mathematical Society & London Mathematical Society.

Russell, B. (1948). *Human Knowledge: Its Scope and Limits*. London: George Allen and Unwin.

Scott, J. C. (1998). *Seeing Like a State: How Certain Schemes to Improve the Human Condition Have Failed*. New Haven, CT: Yale University Press.

Searle, J. R. (1980). Minds, Brains, and Programs. *Behavioral and Brain Sciences*, 3(3). https://doi.org/10.1017/S0140525X00005756

Steenrod, N. (1951). *The Topology of Fibre Bundles*. Princeton: Princeton University Press.

Strathern, M. (1997). 'Improving Ratings': Audit in the British University System. *European Review*, 5(3). https://doi.org/10.1002/(SICI)1234-981X(199707)5:3<305::AID-EURO184>3.0.CO;2-4

Tal, E. (2020). Measurement in Science. *Stanford Encyclopedia of Philosophy* (substantive revision Aug 7, 2020). https://plato.stanford.edu/entries/measurement-science/

Urbański, M. K., & Samsonowicz, J. (2003). On the Field Nature of Measuring Process. *Measurement*, 34(1). https://doi.org/10.1016/S0263-2241(03)00017-4

van Fraassen, B. C. (2008). *Scientific Representation: Paradoxes of Perspective*. Oxford: Clarendon Press.

von Neumann, J. (1925/1967). An Axiomatization of Set Theory. In J. van Heijenoort (Ed.), *From Frege to Gödel: A Source Book in Mathematical Logic, 1879–1931*. Cambridge, MA: Harvard University Press.

von Neumann, J. (1947). The Mathematician. In *The Works of the Mind*, Vol. I. Chicago: The University of Chicago Press.

von Neumann, J. (1954). The Role of Mathematics in the Sciences and in Society. *Collected Works*, Vol. VI. Oxford: Pergamon Press.

von Neumann, J. (1955). Can We Survive Technology? *Fortune*. Reprinted in *Collected Works*, Vol. VI. Oxford: Pergamon Press, 1963.

von Neumann, J. (1958). *The Computer and the Brain*. New Haven: Yale University Press.

von Plato, J. (2020). *Can Mathematics Be Proved Consistent?* Cham: Springer.

Weizenbaum, J. (1976). *Computer Power and Human Reason: From Judgment to Calculation*. San Francisco: W. H. Freeman.

Zheng, J. & Meister, M. (2025). The Unbearable Slowness of Being: Why Do We Live at 10 bits/s? *Neuron*, 113(2). https://doi.org/10.1016/j.neuron.2024.11.008
