《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第六章：映射函数垄断——从祭司到 AI 平台

摘要

第一章论证了映射的自我引用——当多个时钟互相校准，真实状态从映射的输入中部分消失。本章沿历史脉络考察这一机制，识别出三类映射函数垄断载体：古代祭司阶层、金融市场（含加密货币市场）、算法平台与人工智能（AI）平台。载体更替了，**垄断的深层语法却呈现出结构性的重复**——控制从真实到读数的映射过程，并通过四种策略使这种控制变得不可见。

本章的核心贡献是一个分类变量：系统内部是否存在强制打断自我引用回路的机制。金融市场有——赔付环与牛熊更替。古代祭司阶层曾经没有——直到王权的政治收复、外部征服的物理摧毁和新知识传统的制度竞争打开了相对于既有映射权威独立的缝隙。缺乏可兑现资产支持的加密代币有崩盘但没有资产赎回锚——中国选择了直接禁止。

算法平台和 AI 平台已存在针对部分损害的制度化约束，但对本章所论弥散性校准能力损失，尚缺乏可靠的强制纠错回路——而且它们的界面设计方向是压缩人意识到自己需要校准的空间。算法平台与 AI 平台之间的分界不在平台代际，而在映射函数的实现方式：算法平台的知识壁垒以有意的为主——可显式写出的评分公式、排序规则是设计者掌握的，只是不公开；当代旗舰推荐系统已把排序逻辑交给从数据中学习的模型，知识壁垒开始结构化；AI 平台把这个趋势推到极限——垄断者不完全知道训练出来的映射函数在做什么。

本章考察的祭司均为古代祭司，与当代宗教人士无关。

关键词

映射函数垄断；自我引用；四条件闭环；四种垄断策略；强制校准；赔付环；叙事载荷；有帮助、诚实、无害（HHH）；模型坍塌；古代祭司；金融市场；算法平台；AI 平台

---

§1 自我引用的制度化

第一章论证了映射的自我引用：在时钟的房间里，当多个时钟互相校准，映射函数从 $\pi_i(T)$ 向 $\pi_i(\{r_j\}_{j\neq i})$ 退化——真实状态（T）从映射的输入中部分消失。时钟开始更多地指向其他时钟，而非时间。

第一章已论证映射的动态腐蚀；本节进一步考察这一过程获得制度性维持的条件——自我引用如何从一个可修复的退化变成一个自我强化的回路。

当四个条件同时成立时，静态的自我引用变成动态的正反馈：

条件一：自我引用在短期内是成功的。当足够多的参与者以读数作为决策依据时，追随读数的策略在短期内胜过追随真实的策略——追随读数就是追随多数。

条件二：短期成功淘汰了校准者。在竞争选择压下，追随读数者短期内胜出，追随真实者落后。如果淘汰机制在短期时标上运作，追随真实者将被系统性排除。不是因为他们错了，是因为他们的正确性在短期内不被奖励。

条件三：淘汰校准者进一步降低了校准的可能。当追随真实的参与者被淘汰后，系统内部丧失了发现差距的能力——不是因为没人想校准，是因为会校准的人已经不在了。

条件四：即使差距被感知，集体行动问题阻止纠正。前三个条件都涉及信息和激励——参与者不知道差距（条件一的正反馈掩盖了它）、知道差距的人被淘汰了（条件二）、淘汰后系统丧失了感知差距的能力（条件三）。但条件三不必完全成立——淘汰往往是不完全的，部分校准者可能仍然存在。条件四解释了为什么即使这些残存校准者正确感知到差距，但纠正仍然不会发生。国际清算银行（Bank for International Settlements，BIS）的研究（Borio, Furfine & Lowe, 2001）揭示了第四个独立的条件：即使个别参与者正确感知到差距，集体行动问题也会阻止纠正。一个基金经理可能知道市场被高估了，但如果他单独离场，他会在泡沫继续膨胀的阶段跑输同行并被解雇。他的正确性需要全体（或至少足够多的）参与者同时行动才能兑现——而协调这种同时行动的机制不存在。这与前三个条件在性质上不同：前三个条件都损害系统感知差距的能力（不知道、知道的人消失了、无法再知道），第四个是协调问题（知道了但无法集体行动）。即使在信息充分对称——个别参与者正确感知到差距——的条件下，这个条件仍然阻止校准。[1]

四条件闭环。以上四个条件——短期成功、淘汰校准者、感知能力丧失、协调失败——在形成与维持两个阶段扮演不同角色：四个条件共同作用，把静态的自我引用转变为动态正反馈（回路的形成）；回路一旦形成，四个条件可能相互备份，削弱其中一个未必足以破局；系统是否仍沿自我引用轨道运行，取决于剩余条件能否维持相关的正反馈，以及被削弱条件的作用能否被补偿（回路的维持）。在第一章的语言中：房间里的钟越来越多，每个新钟都是根据旧钟的读数制造的。窗户还在，但走到窗边的人越来越少——不是因为窗户被封了，是因为校准者在短期内被视为疯子。

---

§2 四种垄断策略

自我引用的制度化需要垄断者的主动维护。这种维护可以由垄断者主动进行，也可以由竞争压力、基础设施集中与技术不透明共同维持——本章关注的是结果：映射过程对宿主不透明。垄断者的核心任务是：**使映射函数对宿主不透明。**实现这一任务至少有四种策略。

[1] Borio et al.（2001）的原文讨论的是金融体系风险计量的顺周期性。本章将其核心洞见——即使个别参与者感知到风险，集体行动问题也会阻止纠正——抽象为自我引用制度化的第四个条件。这一延伸解读的责任由本章承担。

在展开之前需要区分两个概念。**映射函数 (π)** 是从真实状态到读数的转换过程——以两河流域古代文明为例，巴鲁祭司（bārû）宰杀祭羊、检视肝脏、对照泥板征兆记录做出判读——肝脏在 Enmeduranki（巴鲁祭司的神话始祖）神话中被称为“神的泥板”（tablet of the gods）（Rochberg, 2004），巴鲁祭司是唯一有资格“阅读”这份文本的人（Bottéro, 2001；交叉参见 Bottéro, 1992 第 IV 部分 “THE GODS: RELIGION”；Oppenheim, 1964）。这一整套操作就是映射函数。[2]**叙事载荷 (ϕ)** 是读数中携带的、使主体放弃审计的附加结构——判读给出的吉凶结论是映射函数的输出，“这是神的旨意”是叙事载荷。[3]前者告诉信徒内容，后者压制信徒启动审计的冲动。

记忆口诀：映射函数 π 是钟的机芯，叙事载荷 ϕ 是钟面上多画的那圈金边。机芯决定指针怎么走。金边不影响走时，但它让人觉得这面钟权威、不容置疑。人看钟是为了知道时间——一旦接受金边的权威，就忘了问这钟校准过没有。**叙事载荷不改变读数，但改变了主体与读数的关系。**

表 1　映射函数与叙事载荷的分析分工

	映射函数 (π)	叙事载荷 (ϕ)
是什么	从真实状态 T 到读数 r 的转换过程	读数 r 中携带的使主体放弃审计的附加结构
核心问题	“怎么知道？”	“为什么必须信？”
祭司对应	解经规则、祭祀仪式、至圣所	“这是神的旨意”“违者遭天谴”
AI 对应	模型架构、训练过程	“我是一个中立的 AI 助手”

在以下四种策略中，策略一至三针对映射函数的垄断，策略四针对叙事载荷的生产。四者相互强化。

策略一：对知识的排他控制。限制映射函数本身的可读性。古代印度婆罗门对吠陀知识的控制最接近完全垄断；古埃及多数时期识字率不超过 1%（Baines, 1983），识字者不全是祭司，祭司在神庙文本中占主导但非绝对垄断；凯尔特德鲁伊（古代高卢与不列颠的祭司-知识阶层，兼掌宗教、法律与教育）能书写但拒绝将教义形诸文字（Caesar, *Gallic War*, VI.14）——拒绝书写本身就是知识策略。当代的对应物是不公开的模型权重和受商业秘密保护的算法逻辑。结构**同构**：映射函数对**宿主**（依赖该映射系统获取信息或服务的个体或群体）不可见或难以理解。知识壁垒的有效性不取决于知识的“难度”——取决于知识与权力的绑定程度。

策略二：空间壁垒。垄断映射过程发生的物理场所。古代是神庙的至圣所，当代是数据中心。数字时代的空间壁垒更隐蔽——神庙至少矗立在城市中心，数据中心通常不在使用者的视野内。

策略三：时间壁垒。垄断时间的刻度。掌握历法的祭司阶层决定什么日子吉凶、什么时候播种祭祀；推荐算法决定用户在什么时间看到什么内容，高频交易决定价格在微秒级别的方向。这是四种策略中最

[2]映射函数 π 不止是被动的“转换”——它还包含用范畴主动建构“真实状态”本身这一更深的层次。王德峰对马克思《德意志意识形态》“现实的个人”概念的解读提供了一个范例：人类学与经济学的范畴（如“一般劳动者”“雇佣劳动者”）并非中性地描述既有事实，而是“在知识论上为他的活动预先搭好的舞台架子”，现实的个人因此沦为“范畴之肉身化—人格化”——范畴规定了什么算作“经济事实”本身（王德峰, 2002）。这与第四章脚注 5（王德峰对海德格尔的概括：“在对存在者的规定当中，遗忘了存在”）、第二章生存论路向与知识论路向的区分同出一源：把规定当成存在、把范畴建构的事实当成真实，是同一种误读。因此“映射函数垄断”的最深一层，是垄断“什么算作事实”的范畴权力。

[3]真实状态 T 在不同系统中的本体论地位不同。金融市场的 T（企业盈利、债务偿还能力）有可独立核查的经营与偿付锚点；古代祭司的 T 必须分层——神意作为超自然解释不可证伪，天象、肝脏等观察对象具有经验内容，所占卜的收成、战争或政治后果也可能成为事后检验对象，这些可观察后果并不构成金融意义上的可兑现资产锚，仍可能被有关祭祀义务的叙事重新解释并吸收；算法/AI 平台的 T（用户偏好）内生于映射过程，会被输出反向塑造。框架用同一个符号 T 统摄这些异质对象，是为了抽象出“读数与真实之间存在间隙”这一共同结构。这一抽象在比较不同系统的“强制校准”机制时仍然有效，但在追问“T 是否稳定”时会暴露差异——这正是表 3“底层资产”一栏的功能。

被低估的——知识壁垒可以被开源打破，空间壁垒可以被监管打破，但时间壁垒渗透到每一次信息交互的微观结构中。

策略四：叙事壁垒。将垄断结构自然化。创世神话让祭司的存在成为宇宙秩序的一部分；“算法没有立场”“AI 是工具”“市场是自然的价格发现机制” 让当代的垄断结构同样隐形。叙事壁垒的完美状态不是说服——是使质疑无法发生。[4]

四种策略的乘积结构。四种策略的功能并不相同，但其维持垄断的效果可以部分补偿，并在共同运作时相互强化。不知道（知识壁垒）、不能接触（空间壁垒）、没时间（时间壁垒）、不会想到（叙事壁垒）——四者的乘积构成完整的垄断。任一策略被打破都会削弱垄断；若其余策略仍足以维持实际的排他控制与替代困难，垄断便可能以降级形式继续运作，但并非在所有系统中必然如此。

---

§3 关键区分：有没有强制校准

§1 论证了正反馈回路。§2 论证了维护回路的四种策略。如果故事到此为止，所有映射函数垄断者的命运将是相同的——无限膨胀直到终极灾难。

但不同的系统有一个关键区别：**系统内部是否存在强制打断自我引用回路的机制。**这是本章的核心分类变量。它据此区分五类系统的命运。

§3.1 五种系统的初步对照

古代祭司阶层。自我引用——神谕引用神谕——在其运作的千年间没有内建的强制校准。没有 “底层资产违约” 来暴露神谕与真实之间的差距。干旱发生了？那是因为祭祀不够虔诚——这个解释本身就在自我引用回路之内。但须注意：祭司系统对内建校准的吸收能力极强，但不是绝对的——大规模物理灾难仍可能形成外部冲击，但其作用往往与战争、环境退化、疾病和制度张力交织在一起。以古典期玛雅南部低地为例，城市衰落与纪念碑停建涉及多类候选原因，各遗址的发生时间也不一致；干旱只能作为促成或加速因素之一，不能单独写成祭司合法性危机的确定原因（Chase & Chase, 2006）。本段所列打破既有映射权威的路径包括：王权的政治收复夺回映射函数的操作权，外部征服（如巴比伦摧毁第一圣殿，公元前 586 年）以物理手段瓦解祭司制度的物质基础，哲学在祭司体系外部建立了独立推理系统。祭司垄断的松动首先是权力事件，其次才是认识论事件。

金融市场。价格引用价格——但底层资产对应着可独立核查的经营与偿付后果：企业会盈利或亏损，债务会违约，资产也会灭失。当差距累积到临界值，真实以强制形式闯入读数的世界。崩盘使这种差距集中暴露，但崩盘本身不等于校准完成。只有当独立后果能够被可靠归因，并通过后续定价、违约处置、信息披露或责任追究等约束性程序用于纠正偏差，时钟才重新接触真实，系统以惨重代价获得部分校准。此后仍可能开始新一轮自我引用。

加密货币市场。国际清算银行（BIS）2022 年年度报告将去中心化金融（Decentralized Finance，DeFi）系统的活动定性为 “mostly self-referential”——几乎全部是加密资产之间的互换、不为实体经济融资；Cornelli et al.（2023）以 “largely self-referential” 描述加密资产作为资产类别的性质，并基于交易 App 下载时点与比特币价格估计：截至 2022 年 12 月，在样本中几乎所有经济体，多数零售比特币投资者可能

[4]Stanford HAI（2026, April）*AI Index Report 2026* 记录：AI 行业代表在美国国会 AI 相关听证会上的证人份额，从第 115 届国会（2017—2018 年）的 13% 升至第 119 届国会（截至报告统计期）的 37%；学术界的份额则从 26% 降至 15%。这一发言结构的变化是否进一步形成议程设置优势，须结合问题选择、证词采纳与政策形成过程判断；叙事壁垒的运作不依赖封锁信息——垄断 “什么算作正确问题” 的定义权是其一种形态。

已经亏损；若按首次下载月份及以后每月投入 100 美元的假设持续定投，则超五分之四的用户会亏损。加密市场同样会发生价格暴跌，但本章所论缺乏可兑现资产支持的代币，没有与企业盈利、债务偿付或资产赎回同类的直接估值锚。价格仍可能主要由 “社区共识” 决定，而社区共识本身仍是自我参照；因此，这类系统有周期性冲击，但暴跌本身不保证形成校准方向。网络使用、交易需求与安全预算等是系统自身活跃度的指标，不构成企业盈利、债务偿付或资产赎回一类的可兑现后果；在本章框架中，它们不能替代底层资产承担与真实的因果接触通道。细节展开见 §5.5。

算法平台（推荐系统、信用评分、搜索排名）。推荐算法根据用户过去行为预测并塑造未来行为。信用评分改变了用户能获得的贷款条件从而改变了其未来行为。预测性警务根据历史数据决定巡逻密度——巡逻密度更高的地区逮捕率更高，“验证” 了预测。迄今没有内建的出清机制——对本章所论的弥散性校准能力损失，用户校准能力的下降是缓慢的、弥散的。

AI 平台（大语言模型、生成式 AI）。 Shumailov et al.（2024）在 *Nature* 发表的研究揭示了 “模型坍塌”：当语言模型无区别地在自身或其他模型生成的内容上训练时，输出的多样性和准确性系统性下降——分布尾部的低频信息被不可逆地丢失；而保持对原始人类数据的访问对防止这一退化至关重要。若把模型输出视为关于原始人类文本分布或外部真实状态的读数，递归训练造成的尾部信息丢失可能使原本可区分的状态在输出中变得不可区分；只有在明确这一映射及其兼容关系后，才能说相应纤维可能膨胀（第四章，§6.3 进一步展开）。当 AI 生成的内容大规模回流互联网成为未来模型的训练数据，自我引用从单个模型扩展到整个信息生态。这不是仅关乎模型训练质量的技术问题——它意味着公开语料池中人类原创内容的相对份额可能被系统性稀释。当原始数据不再可访问，且丢失的信息不能由独立的新数据补回时，仅凭递归生成的输出无法恢复已丢失的分布信息；这一条件性的信息损失不能直接等同于整个公开语料生态不可逆（参见第三十五章 §1）。

算法平台与 AI 平台之间的分界在映射函数的实现方式，而不在平台代际：算法平台的知识壁垒以有意的为主——评分公式、排序规则这类可显式写出的逻辑是设计者掌握的，只是不公开；但当代旗舰推荐系统已把排序权重交给从数据中学习的深度模型（Covington, Adams & Sargin, 2016），这部分透明度在下降。算法平台的知识壁垒已出现结构性成分，AI 平台把这个趋势推到极限——在本章所论的当代大型生成模型中，结构性知识壁垒从学习层的局部现象扩展为整个映射函数的默认状态：垄断者自身也失去了对映射函数的完整审计能力。这一程度是否为此前垄断形态所未曾达到，属本章提出的待检验判断（见 §3.4 与 §8）。

§3.2 赔付环：校准的制度化形态

崩盘是粗暴的、事后的强制校准。有没有更精细的、事前的校准机制？

投资者保护制度——包括证券集体诉讼、监管执法、赔偿机制——构成了一种制度化的校准回路，本章称之为**赔付环**。赔付环的功能不是预测崩盘，而是在映射函数被系统性扭曲时，通过惩罚扭曲者来恢复映射函数与真实之间的部分联系——“部分” 在此的精确含义是：赔偿可以补偿可识别、可追偿的个体损失，披露与处罚可以修复部分系统性失真，但二者都不保证消除全部后果，也不阻止映射函数在下一轮自我引用中再次膨胀。赔付环的有效性依赖于司法系统的独立性和执行能力——当这些条件不具备时，赔付环在形式上存在但在功能上失效。

La Porta et al.（2000）建立了基准判断：当投资者感到其权利有保障时，他们会为金融资产支付更多——法律通过限制侵占提高了证券价格。在投资者保护较差的国家，内部人在前景好时可能善待外部投资者，但前景恶化时会加大侵占。Gande & Lewis（2009）记录了集体诉讼的显著负股价效应与行业溢出——集体诉讼及其预期具有真实的财富后果；其对违法行为的威慑程度，不能仅由股价反应确定。

赔付环在不同制度中的形态差异显著。美国模式以私人诉讼为核心——集体诉讼允许大量小额投资者联合追偿，律师费按胜诉比例收取，形成利润驱动的私人执法体系。中国模式以公共执法为主导——中国证券监督管理委员会（China Securities Regulatory Commission，CSRC）依法对全国证券市场实行集中统一监督管理，民事赔偿则通过诉讼等机制实现。2019 年《证券法》修订创建了 “特别代表人诉讼” 机制：投资者保护机构受五十名以上投资者委托后作为代表人参加诉讼，为经登记确认的权利人主张权利，明确表示不参加者除外。[5]

赔付环在 §2 的四种策略框架中的位置：它是对策略一（知识壁垒）和策略四（叙事壁垒）的制度化对抗。强制披露降低知识壁垒。惩罚造假，使维持虚假叙事重新付出代价。但赔付环本身也受制于 §1 的四个条件——繁荣期的监管通常被放松，诉讼的举证难度在泡沫期更高。赔付环是重要的校准机制，但它不能替代崩盘。

§3.3 直接截断：当赔付环与崩盘都不能保证校准时

对于由缺乏可兑现资产支持的代币构成的系统，赔付环难以提供传统金融资产那样的估值锚。欺诈与违约仍可追责，但这些代币没有企业盈利、债务偿付或资产赎回那样的直接锚点。价格暴跌本身也不能保证完成校准——没有可兑现资产锚，冲击之后就没有迫使读数重新接触真实的后果通道。国际清算银行（BIS）的研究提供了相关损失估计：在其 App 下载时点与投资行为假设下，多数零售比特币投资者可能亏损（Cornelli et al., 2023；若持续每月定投则超五分之四的用户会亏损），较大投资者往往在暴跌前卖出，而较小投资者此时仍在买入。

2021 年，中国内地禁止虚拟货币兑换、交易撮合等相关业务活动，并全面禁止新增加密货币挖矿项目、推动存量项目有序退出。在本章的框架中，这是在赔付环难以提供有效估值锚、且崩盘本身不能保证形成校准方向的条件下，制度层元审计能力的直接行使——不是 “校准” 自我参照系统，而是拒绝让这个系统进入金融体系。

这和 “金融服务实体经济”“脱虚向实” 是同一个制度逻辑的两个面。金融的功能是为实体经济提供映射服务——定价、融资、风险管理。当一个金融产品没有可兑现资产锚时，映射函数的输入便主要由自身读数与共识构成；此时它就不再是一个可以依靠既有锚点校准的时钟，而更接近自我引用的回音室。“脱虚向实” 在本章的语言中就是：要求金融时钟必须连着窗户——必须有底层资产作为与真实的因果接触通道。在本章框架中，禁止没有窗户的时钟房间进入金融体系，可以被理解为对 §1 四个条件闭环的制度性预防——这里解释的是它的预防逻辑，不据此完成对政策适度性及其整体效果的评价。[6]

§3.4 分类汇总

五种系统不是平等并列的分类学单元，而是**三大载体及其内部演化**：神权载体（古代祭司）、资本载体（金融市场 → 加密市场）、技术载体（算法平台 →AI 平台）。箭头标注的是载体内部的质变——缺乏可兑现资产支持的加密代币构成了金融市场中失去这一估值锚的一种形态，AI 平台是算法平台的结构性

[5]CSRC 自 2024 年以来调查了 159 起财务造假案件，罚没金额 81 亿元。康美药业案成为中国首例证券特别代表人诉讼——2021 年 11 月广州中院一审判决相关主体向 52,037 名投资者赔偿约 24.59 亿元；泽达易盛案以调解结案，7,195 名投资者获赔 2.85 亿元（2023 年 12 月）。2024 年 5 月 CSRC 对恒大地产处以 41.75 亿元罚款。来源：中国证监会官网——康美药业案：https://www.csrc.gov.cn/csrc/c100210/c5737509/content.shtml；广州中院报道：https://www.gzcourt.gov.cn/xwzx/xwxc/2021/11/30164811092.html；泽达易盛案（典型案例十九）：https://www.csrc.gov.cn/fujian/c105584/c7520645/content.shtml；恒大地产处罚决定：https://www.csrc.gov.cn/csrc/c100200/c7506328/content.shtml；159 起与 81 亿元数据：中国证监会 2026 年 1 月 5 日发布，新华社报道 https://www.news.cn/fortune/20260105/82b6755db0aa4c2b8722ae2aa30a83ba/c.html。

[6]须注意：中国禁止加密货币的动机不仅包括金融风险防控，也包括资本管制、能源消耗、反洗钱等多重考量。本章从映射函数垄断的单一维度分析这一制度选择，不声称覆盖其全部政策理由。

知识壁垒从学习层局部现象扩展为默认状态后的形态。表 2 将五种系统并置，不是分类学声明——是为了在同一张表上暴露垄断语法的结构同构和校准条件的根本差异。

本章比较的系统边界包括映射提供者及对其具有制度化约束力的核证、监管和责任追究机制；各类系统使用同一边界。外部信息来源与内建纠错程序可以结合，不能仅因来源在组织之外便否认校准机制的制度化。

下文关于加密市场 “崩盘本身不保证形成校准方向” 的判断，限于缺乏可兑现资产支持的代币，不包括具有外部储备及赎回安排的资产支持型稳定币；后者的校准问题在于储备质量、透明度与赎回可执行性（BIS, 2022）。

表 2　结构同构：五种系统共享的垄断语法

维度	古代祭司	金融市场	加密市场	算法平台	AI 平台
自我引用	神谕引用神谕	价格引用价格	价格引用 “共识”	推荐引用点击	输出引用输出
知识壁垒	经文/仪式	产品嵌套复杂性	代码名义开源但难以审计	算法逻辑不公开	模型内部机制难以完整解释
空间壁垒	至圣所	关键交易设施及其准入控制	分布式但交易所集中	服务器/数据中心	远程托管、访问受控
时间壁垒	历法垄断	高频交易	24/7 不间断交易	推送频率控制	持续即时响应
叙事壁垒	“神的旨意”	“市场有效”	“去中心化即自由”	“算法中立”	“AI 是工具”
§1 四条件闭环	成立	成立	成立	成立	成立

注：本表比较机制形态；“成立” 指该系统的运作与 §1 所述条件相容，不表示四条件已在各类系统中分别得到独立验证（证据分级见章末说明）。

表 3　结构异质：五种系统在校准维度上的关键差异

维度	古代祭司	金融市场	加密市场	算法平台	AI 平台
底层资产	没有可兑现资产锚；神意本身不可证伪，具体征兆—后果命题可在一定条件下接受经验检验	有（盈利、债务）	所论无资产支持代币：无可兑现资产锚	部分有（用户行为真实但被塑造）	依任务而异：偏好类无独立锚，物理反馈类有
垄断者知道自己的 π	是（仪式规程显式）	所设计模型的显式结构已知	所论合约的显式代码可知	分层（显式规则已知，学习型排序部分已知）	部分（训练产物不可完全解释）

维度	古代祭司	金融市场	加密市场	算法平台	AI 平台
内建强制校准	无	有：独立后果能够可靠归因，并通过定价、违约处置或赔付程序用于纠偏时，崩盘及其后续机制可形成部分强制校准	所论无资产支持代币：有崩盘但无资产赎回锚	部分损害有制度化约束；弥散损失纠错不足	部分损害有制度化约束；弥散损失纠错不足
赔付环	无	有：集体诉讼、监管执法	极弱	部分（隐私法、反垄断）	存在监管与责任机制；弥散损失救济仍有缺口
中国的制度回应	宗法化吸收	脱虚向实、CSRC 强化	直接禁止	反垄断、算法备案	分类监管（进行中）
损失分布	弥散（文明级）	急性、集中	急性且分布不对称（零售亏损广泛，未估计总损失份额）	慢性、弥散	慢性、弥散、难以归因
缝隙	有	有（监管、做空、赔付环）	有但不稳定	有但在缩小	更小（趋势待检验）

同构不等于同一。表 2 标注的是五种系统在垄断这一维度上反复出现的结构关系。表 3 标注的是它们在校准条件上的根本差异。本章的论证是：五者共享垄断的语法，但在校准条件、时间尺度和可逆性上存在根本差异。从祭司到 AI 的历时性序列中，本章提出一个需要在同一实施层尺度上检验的趋势判断：垄断者对自身映射函数的知晓程度在下降（祭司知道仪式规程 → 金融工程师掌握所设计模型的显式结构 → 算法平台对显式规则完全掌握、对学习型排序部分掌握 → AI 开发者不完全知道训练产物），同时缝隙在缩小（校准者需要相对于既有映射权威独立的核证空间，这种空间在缩小）。这里比较的是实施层操作规则或实现机制的可知性，不是各系统关于真实的知识是否可靠，也不是对全部结果的预测能力；不同历史材料是否足以支持同一尺度上的排序，仍须分别核查。[7]

[7]本章的 “有无强制校准” 分类变量与已有文献的精确距离：

表 12　强制校准与相邻理论的问题设置比较

维度	MacKenzie（2006）反表演性	Goodhart（1975/1984）/ Campbell（1976/1979）	Taleb（2012）反脆弱	Perrow（1984）正常事故	本章：强制校准
核心问题	模型使用是否使模型变得更不真？	度量成为目标后是否自我失效？	系统能否从一定范围内的波动、压力与扰动中获益？	复杂互动与紧密耦合的系统中事故是否不可避免？	自我引用系统有无内建机制强制恢复读数与真实的接触？
分析域	金融经济学	公共政策与度量	跨域（金融、生物、工程）	高风险技术系统	跨域：祭司、金融、加密、算法、AI

本章分类变量与已有文献的精确距离见脚注 7。

表 3“损失分布” 一行的 “急性/弥散” 区分，刻画的是损失的发生与暴露方式——金融市场崩盘使价格冲击在同一时段集中显现，AI 系统中本章关注的损失则可能表现为用户校准能力的异步下降，缺少同样集中的公共暴露时刻。至于个体损失为何不能由总体平均表现抵偿，可以借鉴非遍历（乘性）过程中的吸收壁概念（Peters & Gell-Mann, 2016; Taleb & Sandis, 2014）与 Peters（2019）的系综平均—时间平均背离框架——在财富按比例增减、且至少存在一种使人损失全部财富的可能结局的乘性过程中，破产者进入不可逆的吸收态，这不意味着所有参与者同步破产；但这些概念不构成 “急性/弥散” 区分的数学证明。[8]

---

§4 古代祭司：映射函数垄断的早期制度形态

§4.0 对象与范围

在时钟房间的语言中：宗教是关于 “什么是真实” 的叙事。祭司是声称只有自己能接触真实的人。本节分析后者——映射函数的制度化垄断者——不是前者。本节考察的祭司均为古代祭司，与当代宗教人士无关。

宗教可以在没有独立祭司阶层的情况下存在。中国的祖先崇拜由家长主持——映射函数被分散嵌入血缘关系。祭司可以在没有宗教热忱的情况下运作。托勒密时期的埃及祭司为希腊统治者提供神圣合法性，换取经济资源——功能性的交换。

§4.1 四种垄断策略的展开

§2 已经抽象地定义了四种策略。本节用历史材料填充。

知识壁垒。 §2 已用祭司材料论证了差异谱系。此处聚焦一个结构性要点：知识壁垒的有效性不取决于知识的 “难度”——取决于知识与权力的绑定程度。楔形文字不是因为 “太难” 才被优势控制——是因为

崩盘的定位	反表演性的实例	不直接讨论	某些压力可能促成增益；导致毁灭的冲击不在此列	系统正常运作的内生后果	在信息反馈条件满足时推动强制校准
是否以本章所定义的强制校准机制组织比较	否	否	部分	否	是

本章的贡献是将 “有无强制校准” 抽象为跨域分类变量，在同一框架内比较五种系统；它与上述理论的问题设置不同，这种差异说明本章的分析位置，不单凭一张对照表证明该问题从未被提出。崩盘之所以是 “强制校准”，不是因为它使系统更 “反脆弱”（Taleb），也不是因为它是 “正常事故”（Perrow），而是在违约、盈利及偿债信息进入后续定价等条件满足时，它迫使读数重新接触真实——这种校准仍可能只是暂时的、代价惨重的。

[8]遍历性经济学（ergodicity economics）是有争议的理论，非定论。Toda（2023, arXiv:2306.03275）指其未产出可证伪推论，称 “伪科学”；Doctor, Wakker & Wang（2020）指 Peters 的补救方案 “给整个经济学以不准确印象” 且 “无需援引平行宇宙”；Löffler（2025, SSRN 5399717）相对同情但指出遍历性经济学只建模单一商品，实为 “遍历性金融” 而非经济学。本章在 §3.4/§5.3/§6.5 使用这一框架时，定位为结构类比（C 级推断），不宣称数学证明。

掌握它的人同时掌握了神庙经济的记录权。不同文明中这种绑定的紧密程度差异很大：从婆罗门的近乎完全垄断到埃及的制度化优势再到两河流域的逐渐世俗化。

空间壁垒。古埃及神庙的至圣所只有法老和高级祭司可以进入。普通人最多进入外庭。神像每天由祭司进行 "醒神" 仪式。两河流域的塔庙顶层传统上被认为只有祭司可以登临（塔庙的确切功能至今不明；Oppenheim, 1964）。以色列耶路撒冷圣殿的至圣所只有大祭司可以进入，且一年只在赎罪日进入一次。

时间壁垒。古埃及的时间计量由神庙系统的专门职务承担：以旬星观测报时的 "观时者"（Imy wnwt）头衔延续至托勒密时期（Clagett, 1995）。需要说明：埃及同时运行两套并行历法——以置闰锚定天狼星年度偕日升的宗教历法和 365 天的纯行政民用历法（Hoskin, 2003）。民用历法的存在说明时间知识并不限于祭祀用途；但它是否由独立于神庙的机构掌握，不能仅凭历法用途判定。两河流域的情况更复杂：Evans（1998）称巴比伦天文从业者为 "在宗教神庙工作的文官"，但在历法公告与天文记录的语境中也称其为 "祭司官员"（priestly officials）、"祭司书吏"（priestly scribes）；Hoskin（2003）称其为 "书吏" 和 "宫廷官员"，全书未以 "祭司" 定位这一阶层。"祭司垄断天文" 需要修正为：天文知识由与神庙密切关联的祭司-文官阶层掌握。古罗马共和国早期，历法由祭司团掌握——他们决定哪天可以进行法律诉讼（*fasti*），可以任意操纵日程阻挠政治对手。公元前 304 年，格奈乌斯·弗拉维乌斯将历法公之于众——映射函数从祭司垄断变为公共知识的历史实例。[9]

叙事壁垒。古埃及：法老是荷鲁斯的化身——这不只是象征性称谓，也构成王权神圣合法性的一部分。两河流域：《恩努马·埃利什》宣告人类被创造的目的就是服务神——神庙和祭司的存在是宇宙秩序的一部分。印度：《原人歌》宣告种姓来自原人的身体——在这一创世叙事中，婆罗门在种姓顶端的地位不是自我宣称，是创世本身决定的。这是叙事载荷（ϕ）二阶变化的一种极端表现——按第三章 §2.3 的界定，二阶变化是底层叙事框架加速固化的过程：当这种加速固化均匀覆盖信息环境时，审计所需的对比条件被削弱；人并不是先选择相信某种叙事才接受它；人生活在叙事之中，往往察觉不到它。

§4.2 祭司与王权的四种结构

巫王合一。商王是名义上唯一能沟通 "帝" 的人。周代将祭祀权力宗法化——按血缘等级分配。中国的路径不是从巫师到祭司——按李禹阶的概括，是巫师兼首领的角色经颛顼宗教改革演变为等级化、家族化的祭祀礼制（李禹阶, 2020）。映射函数没有被独立阶层接管——它被分散吸收进了血缘关系。

祭司高于王权。杜蒙论证：婆罗门与刹帝利的关系是地位与权力的分离（Dumont, 1966）。婆罗门不直接统治——但定义了统治的合法性条件。控制映射函数不需要掌握军队。

祭司服务于王权。法老理论上是最高祭司——但 "委托" 使祭司获得了相对独立的资源与组织能力，王权因而难以随意收回原有权限。阿蒙祭司在新王国时期积累了巨大的土地财富，并开始通过神谕干预王位继承。埃赫那吞的宗教改革本质上是政治收复——《牛津古埃及史》阿马尔纳章记叙道，他 "将所有的虔诚与忠诚都收归自己"，并宣告了一个 "只能由其子——国王——来崇拜" 的神：他让自己成为唯一神的唯一中介者，将映射函数从祭司阶层收归王权（van Dijk, 2000）。他失败了——阿蒙祭司集团在他死后迅速恢复了旧秩序。

无根的知识阶层。凯尔特德鲁伊形成跨部落的祭司网络。合法性不来自任何国王的授权——来自知识垄断本身。罗马征服后系统性地摧毁了德鲁伊——德鲁伊网络可能为高卢保留了独立于罗马统治秩序的权威来源；这是本章对其政治意义的解释，不能直接当作罗马采取镇压的动机。[10]

[9] 中国的时间壁垒有不同的制度路径。商王的天文垄断通过制度化委托实现——王保留映射函数的最终解释权，日常操作委托给巫觋集团中的专业分支（冯时, 2006）。从上古 "绝地天通" 神话所确立的巫觋通天垄断，到汉代的太史令，垄断的形态始终是制度性的而非个人性的。

[10] 本章关于德鲁伊制度结构的材料主要依赖凯撒《高卢战记》第六卷；西塞罗《论占卜》（I.90；Cicero, 1923）另提供一份

§4.3 瓦解的四种路径

政治收复。王权直接夺回映射函数的控制权。埃赫那吞是最极端的案例（见 §4.2）。约西亚改革（约公元前 621 年）通过集中崇拜于耶路撒冷圣殿、废除地方祭坛，将祭司权力收编到王权控制之下（列王纪下 22-23 章）。苏美尔城邦的权力转移比埃赫那吞早逾千年，却走了完全不同的路径：最初由祭司掌握的权力，经过数百年才被世俗与军事首领夺取——拉伽什的文献显示，世俗首领与宗教首领的区别到公元前 24 世纪已基本消失，国王此后常亲自占据最高祭司之位——没有宣言，没有一神教改革，只是制度职权在战争常态中的缓慢位移（Van De Mieroop, 1997/2021）。政治收复不质疑映射函数本身——王权要的不是废除映射，而是收回操作权。

制度内的张力与文本化转向。以色列先知长期被视为祭祀体系的反对者——阿摩司书 5:21-22（“我厌恶你们的节期”）是最常被引用的文本。但近几十年的学术研究显著修正了这一图景。Nissinen（2017；原始文献编译见 Nissinen, Seow & Ritner, 2003）综合古近东证据表明，先知（nābîʾ）是在宫殿和神庙系统内部运作的制度化占卜者，耶利米和以西结本人都出身祭司家庭。Blenkinsopp（1995）指出，以色列先知对祭祀体系的批评（如阿摩司对扣押抵押品、行贿司法的谴责）针对的是具体的腐败与虚伪，前提是承认祭祀的有效性——“先知 vs 祭司” 的对立范式在很大程度上是后流亡时期的编辑建构（Blenkinsopp, 1995）。先知传统对祭司垄断的实际影响不是正面对抗式的 “内部爆破”，而是一个更缓慢的制度过程：先知文本的书写化和经典化，将 “何为正确映射” 的争论从仪式垄断转向文本解释的竞争——这为后来拉比犹太教的兴起（“载体替代”）提供了制度性前条件。

外部冲击。德鲁伊的消亡：高卢贵族发现接受罗马的宗教比维持德鲁伊更有利于自己的政治利益。当垄断者失去了政治精英的支持，他们就只是没有牙齿的知识阶层。

载体替代。第二圣殿被毁后，圣殿祭祀失去了原有的制度中心，拉比的律法解释与共同体实践在数个世纪中逐步取得核心位置——会堂与律法教导早在圣殿倾覆之前已承担越来越大的比重——这一转型并不意味着祭司身份与传统的消失，而是宗教权威的组织方式发生重组（Blenkinsopp, 1995）。先知文本的书写化和经典化为这一转型提供了前条件——将 “何为正确映射” 的争论从仪式垄断转向文本解释的竞争。宗教传统可以在原有祭祀制度中断后延续；祭司不是宗教的必要条件——是特定历史阶段的映射函数垄断者。

以上四种路径——政治收复、制度内的张力、外部冲击、载体替代——共同指向一个判断：校准所需的缝隙不能仅依赖被垄断者吸收的反馈。缝隙可以来自另一个权力中心、另一个载体或整个制度环境的瓦解，也可以由制度内部的张力经文本化与组织变化逐渐形成；关键在于是否取得相对于既有映射权威的独立核证和纠错条件。

Eisenstadt（1982, 1986）将上述过程放入轴心时代的宏观框架：公元前第一个千年间，多个文明先后产生了 “超越性视野”——以哲学家与文士为代表的新知识精英（在以色列，先知与祭司同属这一新精英层）取代了前轴心时代的仪式专家，形成了对旧垄断结构的持续张力。须注意：这种张力的主要驱动力是政治事件和制度竞争，思想挑战本身的独立作用难以从政治背景中剥离——本章的解释取向是：映射函数的转手首先是权力问题，其次才是认识论问题。

同期旁证，其中昆图斯在对话中说自己认识高卢德鲁伊 Divitiacus（埃杜伊人）；该处提供的是有关个人的记述，未如凯撒那样描述制度结构。凯撒作为征服者有动机夸大德鲁伊的 “野蛮性” 以正当化征服。本章主要使用其中关于制度结构的描述；但制度描述同样可能受征服者立场影响，其可信度须结合具体内容、叙述目的与其他材料判断，不能仅因内容类别而预先排序。

§4.4 函数没有消失

祭司阶层在大多数文明中已消亡或边缘化。但垄断从真实到读数的映射过程、并通过叙事载荷使垄断不可见——这个函数没有消失。它被转移到了新的载体上（不预设三类载体间的单线传承）。§5 追踪资本载体，§6 追踪技术载体。

---

§5 金融市场：有周期纠错的自我强化时钟

§5.1 价格作为自我引用的时钟

价格是金融市场最基本的时钟——它声称映射资产的 “真实价值”。与祭司系统不同，价格确实连着传感器——企业盈利、就业数据、经济增长。在某种意义上它有窗户。但 §1 的四个条件全部成立。更深一层，价格映射的不只是资产当下的状态，更是对未来收益的预先推断——而未来本属于希望与恐惧的领域，并非一个可被逻辑穷尽的对象。把这种无法被逻辑穷尽、也无法被确切预知的事物包装成 “可定价、可交易的真实读数”，正是叙事载荷 ϕ 在金融市场中的基本形态：它不改变价格本身，却让参与者相信价格背后站着一个确定的、可被知识把握的未来，从而放弃对 “未来是否真的可被如此推断” 的追问；这种信念还可能通过交易行为反馈到价格本身。[11]

这条边界在经济学内部有更早的表述。奈特在《风险、不确定性与利润》中区分了可量度的不确定性与不可量度的不确定性，并把可量度者专称为 “风险”。他写道：

> The practical difference between the two categories, risk and uncertainty, is that in the former the distribution of the outcome in a group of instances is known (either through calculation a priori or from statistics of past experience), while in the case of uncertainty this is not true, the reason being in general that it is impossible to form a group of instances, because the situation dealt with is in a high degree unique. The best example of uncertainty is in connection with the exercise of judgment or the formation of those opinions as to the future course of events, which opinions (and not scientific knowledge) actually guide most of our conduct. (Knight, 1921)
>
> 译文：风险和不确定性这两个范畴之间的实际区别是，在风险中，一组事实中的结果分布是已知的（或是通过事先的计算，或是出自对以往经验的统计），但对于不确定性来说，这一结果是未知的，其原因一般是，由于所涉及的情况极为特殊，所以根本不可能形成这样一组事实。不确定性的最佳例证与行使判断相关，或者说，与形成对事件的未来过程的看法相关，而这些看法（不是科学知识）实际上引导着我们的多数行为。

按这一区分，定价把未来处理为可归组、分布可计算的对象；叙事载荷的深层操作因此可以更精确地说成：抹去可量度的风险与不可量度的不确定性之间的边界，让后者在价格界面上呈现为前者。

条件一和条件二在金融领域有精确的微观基础。Brunnermeier & Oehmke（2013）解释了为什么理性参与者会 “骑泡沫”——追随价格在短期内是最优策略。Shleifer & Vishny（1997）的 “套利的限度” 论证揭示了条件二：追随基本面的参与者不是因为判断错误被淘汰，而是因为资金约束——价格在回归基本

[11] 此处 “未来本属于希望与恐惧的领域” 的说法借自王德峰，其完整论述及 “事后诸葛亮” 之喻见 §5.3。需说明的是，此语系王德峰本人反复使用的论断，他多处将其作为黑格尔的话引述，但本章尚未确认这一完整表述在黑格尔原典中的直接出处。黑格尔《自然哲学》§259 确实将时间向度的区分联系到主观表象中的 “回忆以及担心或希望”（刘哲译，2021；德文原文为 in der Erinnerung und in der Furcht oder Hoffnung，其中 Furcht 直译为 “恐惧”），但这不能直接作为上述完整表述的逐字出处。黑格尔可坐实的相关原话是《法哲学原理》序言 “密纳发的猫头鹰要等黄昏到来时，才会起飞”（邓安庆译）——讲的是哲学只能事后理解已成形的现实、不能预言未来，是另一个论点。

面之前进一步偏离，做空者的保证金先于他们的正确性被消耗殆尽。正确的校准者被资金约束在被证实之前强制驱逐出场。

Borio（2012/2014）将此拓展为 “金融周期” 的完整框架：价值和风险的感知、对风险的态度、融资约束三者之间自我强化的互动。Soros（1987）的 “反身性” 概念描述了同一结构：参与者的认知影响了他们所认知的对象，形成正反馈回路。这比 “价格引用价格” 的描述更丰富——同时包含了信息问题（条件一至三）和协调问题（条件四）。

§5.2 校准的三重扭曲

金融系统中充满承担校准行为的角色——宏观研究员、基金经理、信用分析师、风控部门。问题不在于校准的缺席，而在于校准本身被三种机制系统性地扭曲。

第一重：方法同质化。Danielsson & Shin（2003）和 Danielsson, Shin & Zigrand（2012）揭示：当所有金融机构使用相近的风险计量与估值方法——在险价值（Value at Risk，VaR）、信用评级、盯市会计——时，头寸和行为高度相关。模型说 “安全” 时所有人同时加杠杆，模型说 “危险” 时所有人同时抛售。Persaud（2000）称之为 “把牛群赶下悬崖”。Brunnermeier et al.（2009）的日内瓦报告将此上升为制度诊断：让单个银行安全的监管不等于让系统安全。每一面钟都在校准——但校准的参照物是其他钟的读数，不是窗外的真实。

第二重：表演性校准。 MacKenzie（2006）对 Black-Scholes 模型的历史研究揭示：金融模型不只是描述市场——它们塑造市场。当足够多的参与者使用同一模型时，市场的统计特征会向模型的假设收敛。模型从 “照相机” 变成了 “引擎”。映射函数的大规模采用反过来改变了真实状态本身。校准者以为自己在测量外部现实，实际上在测量自己的测量行为的后果。

第三重：意识形态嵌入。 Rajan（2005）在金融危机前三年警告：金融体系的激励结构使投资经理有理性动机隐藏尾部风险。Bénabou（2013）将此建模为 “集体否认的均衡”——当组织中每个成员都能从保持希望性信念中获益、从而选择忽略或否认负面公共信号时，集体否认是自我维持的。Crotty（2009）指出更深的框架偏置：有效市场假说从学术理论演变为去监管的意识形态基础——如果市场是有效的，外部监管就是多余的成本。Admati & Hellwig（2013）从银行体系 “皇帝的新衣” 叙事角度回应了这一框架偏置诊断——利益方用 “银行必须高杠杆才能放贷” 等说辞为去监管辩护——这些说辞与有效市场假说的理论来源不同，却承担着相近的意识形态功能：把既有金融安排呈现为不可替代的必要条件，从而削弱外部监管的正当性。

Holmström（2015）和 Dang, Gorton et al.（2020）的信息不敏感性论证应被理解为上述三重扭曲之上的一个**特定市场的附加条件**：在货币市场、回购市场和短期债务中，不透明性和 “对称无知” 被刻意设计为增进流动性的机制。这些安排降低了交易者在日常交易中逐项调查底层资产的必要性与激励，以此支持流动性；它们并未取消前端审查与危机中的核证需求，却可能使风险信息在常态下较少进入交易判断——这是 “一切增加流动性的因素在好时候都会把风险推入尾部” 的真正含义。

三重扭曲叠加后：金融市场的危机并不等于系统已经完成校准；它首先暴露繁荣期形成的校准失真——方法同质化导致校准能力系统性退化，表演性校准使偏差被模型自身掩盖，意识形态框架则在偏差信号到达决策者之前将其过滤。三重扭曲以不同方式强化了 §1 的条件二与条件四：方法同质化与意识形态嵌入让短期不校准者在竞争中得以延续（条件二在金融系统的具体形态），表演性校准则改变条件四的具体形态——参与者共同依赖由模型塑造的价格体系，单个基金经理即使意识到模型失真，也难以独自承担偏离共同定价规则的成本；协调问题仍发生在参与者之间，共同使用的模型强化了这种约束。

§5.3 崩盘作为强制校准

Reinhart & Rogoff（2009）以覆盖 66 个国家、近八个世纪的资料，记录并分析了危机前反复出现的 “这次不一样” 心态。

2008 年次贷危机是机制暴露最充分的案例。Benmelech & Dlugosz（2009）揭示了关键机制：信用评级与金融监管的互动是证券化市场增长的重要驱动力。监管矩阵创造了对高评级证券的机构需求——银行、保险公司与券商的最低资本要求与资产评级挂钩，养老基金也受到评级型投资限制。评级模型的统一性意味着同一个错误被复制到数千个担保债务凭证（Collateralized Debt Obligation，CDO）中。

用时钟房间的语言翻译次贷危机，可以理解为：不是一面钟坏了——是所有钟都用同一个有缺陷的机芯造的。而且部分资本计量和投资限制要求参与者依据这些钟作出合规判断。走到窗边看太阳并不被一概禁止，但独立判断不能自动替代规定的评级要求。

崩盘使真实状态与读数之间的差距集中暴露；只有当这些独立后果能够被可靠归因，并通过后续定价、违约处置、信息披露或责任追究等约束性程序用于纠正偏差，纤维才会相应缩小，系统由此获得部分校准。§3.2 论证的赔付环在崩盘之后推动这种部分校准——集体诉讼追偿损失、监管处罚造假者、制度改革重建披露要求。但赔付环不能替代这种强制校准——它在崩盘发生之前削弱但不消除自我引用的动力。

女王之问。 2008 年 11 月，次贷危机爆发后不久，英国女王伊丽莎白二世访问伦敦政治经济学院，面对一场许多人有所预见、但其确切形式与时点无人预见的危机，问了一个朴素的问题——“为什么没有人注意到信贷危机正在逼近？” 次年，英国国家学术院（British Academy）召集一批经济学家与政策专家联名回信，将这场预见的失败归结为 “许多聪明人的集体想象力的失败”：每个人都似乎在做好自己分内的工作，按惯常的绩效标准衡量往往还做得不错，而失败在于没有人看到这一切在集体层面叠加成了没有任何单一机构有权管辖的相互关联的失衡（Besley & Hennessy, 2009）。这个回答主要停在校准层面。回信同时讨论了激励、监管工具与否认心理，其总体方向也确实是改善风险识别；但这并不等于它断言所有崩盘都能避免——评价这封信时，还必须看到它同时承认危机的多重成因和集体行动困难。本章批评的是这种回应没有处理未来在存在论上的开放性，而不是它明确承诺模型可以全知。

机器学习的回答。危机之后十余年，一种更精密的技术性回答出现了。Fouliard, Howell & Rey（2021）在一篇题为《回答女王》（*Answering the Queen*）的 BIS 工作论文中，用 “在线机器学习”（顺序预测）框架预测系统性金融危机：方法基于模型平均，且是 “元统计” 的——可以把任何一个危机预测模型纳入一个权重随时间动态调整的 “专家组”，在不预设经济 “真实” 模型的前提下，在其样本外检验中提前最多十二个季度发出危机信号。这是对女王之问最直接的工程化回应：既然失败在于 “每个人都只看到局部，没有人看到整体”，那就造一台能同时扫描所有局部信号、并动态加权的机器。

在时钟房间的语言中，这是一面更早报警、更少漏报的钟——预测能力显著提升。Fouliard 等人并未假设未来由已知且确定的模型生成；他们明确允许机制未知、非平稳，甚至对抗性变化。因此，本章的哲学批评不能指向一个他们并未作出的确定性承诺，而应指向其仍然保留的目标：把历史上被标记为危机的事件当作可以按时间顺序预测的对象，并以样本外表现检验预测能力。它优化的是读数与已实现危机事件之间的统计映射；这种映射使读数与一类真实结果建立经验联系，但不等于识别危机的因果结构，也不回答金融是否把未来过度建构为确定事实。因此，未来无法被逻辑穷尽这一事实，只会限制概率预测的适用范围，不能用来否定概率预测本身。奈特的区分可以帮助限定这一方法的适用范围：该方法利用历史危机样本和过去经验改进预测，是在尝试把部分危机预测转化为可估计的风险问题；但由于它不预设已知的数据生成分布，不能把已标记危机本身直接等同于奈特意义上的 “风险”。其无法

预测历史上从未出现过的危机类型，则落在不可量度不确定性一侧（Knight, 1921）。

哲学的批判：未来与时间被建构为可计算的对象。但有一种针对前提的诊断指向问题的根部。王德峰指出：经济学的理论理性 “在实际的经济史面前只是不断地证明了自己扮演的是 ‘事后诸葛亮’ 的角色”——每一次危机过后它都能给出一个理性的解释，却从未真正预言并帮助社会避免下一次危机的爆发；究其根由，在他看来，“未来不是知识推断的对象，而是希望和恐惧的对象”（王德峰, 2017）；正因如此，人不是以预知未来的方式、而是 “以筹划和下决心的方式走向未来”（王德峰《古典艺术的理想与命运》讲座）。他还把这一诊断直接落到金融上：“金融产品是用一系列知识推断未来，然后把未来进行买卖”，可未来本不是知识推断的对象、而是希望和恐惧的对象，金融危机的预测同样困于此（王德峰，《谈笛卡尔》讲座）。用时钟房间的语言说：女王之问、英国国家学术院的回答与机器学习预测，主要处理读数为何失真以及如何提高预测；王德峰的批判则追问，金融为何预先把 “未来” 建构成可以确切预知和交易的事实。两类论证回答的是不同问题：不能用王德峰的批判否定样本外证据，也不能用样本外证据替代存在论追问。

普殊同（Moishe Postone）从政治经济学批判出发，提供了对同一结构问题的另一种分析：资本主义独有一种 “抽象时间”——同质、可计量、准客观的时间尺度，它由人的活动建构，却作为 “一种普遍的外在规范反过来施加于每一个个体身上”，构成 “抽象统治的时间维度”（Postone, 1993）。金融市场正是把生存论意义上的未来先抽象成这种可计量的 “抽象时间”、再据此定价交易——于是被建构出来的时间尺度反过来统治了建构它的人。王德峰从存在论追问未来为何不能被知识推断穷尽，普殊同则从政治经济学分析社会建构的时间规范如何形成抽象统治；两者的理论对象与论证前提并不相同，但在 “人建构的范畴或时间尺度反过来支配建构者” 这一结构问题上会合。这是映射函数垄断最深的一层：垄断者不仅垄断了从真实到读数的转换，更垄断了 “什么算作可推断的事实” 这一范畴本身（参 §2 脚注 2）。这一诊断与第四章脚注 5（王德峰对海德格尔的概括：“在对存在者的规定当中，遗忘了存在”）、第二章生存论路向与知识论路向的区分，是同一条问题线上的相互印证，不是概念等同。

祭司系统和金融系统共享一个深层同构：两者的常态运作都依赖在框架内的校准。巴比伦的天文祭司在占星框架内校准——他们连续数百年记录行星位置和月食日食，将观测与泥板上的历史记录逐条核对，不断修正预测精度（Rochberg, 2004）——但从不问天象是否真的承载神的旨意。金融分析师在市场框架内校准——分析财报、评估模型——但不问 “有效市场” 的前提边界在哪里。两者的校准都在叙事载荷 ϕ 二阶变化所加速固化的框架边界内运行。区别在于：金融系统有底层资产作为最终的真实锚点，真实会以强制形式闯入；祭司系统没有这样的资产锚——打破既有映射权威的路径包括政治征服、王权收复、独立知识传统的兴起，也包括 §4.3 所述制度内部张力经文本化与组织变化形成相对独立核证条件的过程。

遍历性视角的补充。 Peters（2019）指出经济学在关键地方假设了 “时间平均等于期望值”——即遍历性假设——这是一个有害错误，因为财富不是遍历的。在遍历性成立的系统中，系综平均（跨样本平均）等于时间平均（单一个体长期平均）；但在存在 “吸收壁”（absorbing barrier，即破产、不可逆的系统性崩溃）的非遍历系统中，两者背离：系综平均掩盖了时间维度的毁灭性风险。吸收壁属随机过程与破产论，非遍历理论内部概念——Peters & Gell-Mann（2016）在乘性动力学中刻画了 “吸收态 $x = 0$ 可达而不可逃”（absorbing state $x = 0$ can be reached but not escaped from）；Taleb & Sandis（2014）将其点明为 “风险共担为代理人（而不只是委托人）创造了一个吸收态”（skin in the game creates an absorbing state for the agent, not just the principal）。

Taleb（2018）将吸收壁发展为生存论命题：可能导致毁灭的风险不能只用平均收益来抵偿，决策须先处理不可承受的损失边界，再比较边界之内的成本与收益——因为个体爆仓后时间线终止，所有后续

收益归零。金融市场崩盘可能使部分参与者触及吸收壁；对这些参与者，系综平均的 “正期望” 不能抵消其单一时间路径上的不可逆退出。市场是否因此恢复读数与真实之间的因果接触，仍须检查违约、盈利及债务偿还信息是否进入后续定价。[8]

§5.4 “金融服务实体经济”

强制校准有代价。有没有办法减少对这种强制校准的依赖？

中国的 “金融服务实体经济”“脱虚向实” 政策方向，在本章的语言中就是：要求金融时钟必须连着窗户——必须有底层资产作为与真实的因果接触通道。当金融产品的映射函数输入中不包含实体经济的信号——当贷款在金融体系内循环而不进入工厂和商店——金融时钟就从 “有窗户但被三重扭曲” 退化为 “没有窗户”。脱虚向实不是一个道德口号——它是对 §1 四个条件闭环的制度性预防：维持映射函数输入端与真实之间的因果接触，使金融市场的自我引用不至于完全脱离底层资产的锚定。

这一预防之所以紧迫，源于金融化自身的动力学。刘尚希、李成威指出，在经济金融化的背景下，原本表现为 “实体” 的资产被不断虚拟化，其价值 “可能一瞬间成倍升值，也可能一夜之间蒸发”，增减已难以用实体理性来把握；而当金融体系内部形成 “你中有我，我中有你” 的相互持有，一旦读数脱离底层资产的锚定，任一局部风险便会沿 “风险链” 交叉传递、扩散累加——他们因此强调，系统性风险（“灰犀牛”）并非天然存在，而是在这一过程中逐渐 “长” 出来的（刘尚希、李成威, 2023）。用本章的语言说，这正是 “脱虚向实” 要切断的那条通道：映射函数 π 一旦失去与真实的因果接触，其叠加误差便会沿金融网络自我放大，而非被底层资产及时校正。

“脱实向虚” 不是中国独有的现象，要看清它，先要厘清 “金融服务实体经济” 到底指什么。金融对实体的本职功能是多重的：生产关于投资机会的信息并据此配置资本、监督借款人并施加公司治理、交易与分散风险、动员并汇集储蓄、便利支付与交换（Levine, 2005）；其中还有同样关键的一重——普惠（financial inclusion）：缓解信贷约束，让原本被排斥的家庭与中小微企业也能获得融资、支付与保险。Beck, Demirgüç-Kunt & Levine（2007）发现，金融发展不成比例地提升最贫困群体的收入、降低收入不平等。金融体系的不完善（如信息和交易成本）可能对缺乏抵押品和信用记录的穷人构成尤其严重的约束。因此，任何对这些信贷约束的放松，都会不成比例地更有利于穷人。换句话说，普惠金融针对的是信贷可及性的缺口——有真实需求却得不到适当金融服务的群体，既包括缺乏抵押品的穷人，也包括缺乏抵押品的高生产率部门——金融服务实体，首先意味着钱能流到这些人那里。

“脱实向虚” 正是这套功能的系统性失效，而且失效方向恰与普惠相反。Banerjee, Mehrotra & Zampolli（2024）对新兴市场二十年的考察发现：信贷深化的边际增长效应在越过约相当于 GDP 100% 的水平后转负（详见下文倒 U 型）；同时，新增的融资往往流向已经信贷充裕的企业，而非受信贷约束的末端 10% 企业——越是不缺钱的地方越容易再拿到钱。与此同时，信贷在部门间显著地从制造业转向建筑与房地产，因为房地产能提供充裕的抵押品，而研发密集、以无形资产为主的高生产率部门恰恰缺乏抵押品。这与上一段的诊断呈现同一机制：金融一旦以抵押品为准绳，缺抵押品者——无论是穷人、小微企业，还是研发密集的生产者——都会被同一套机制系统性地绕开。

为什么会这样？Cecchetti & Kharroubi（2015）给出了机制解释：外生增加的金融供给会不成比例地有利于高抵押品、低生产率的项目，从而压低全要素生产率的增长率；更隐蔽的是，过度膨胀的金融部门会与实体争夺高技能人才——当技能劳动力被吸入金融业，金融便以实体经济为代价更快地膨胀，尤其损害对外部融资依赖高、研发密集的行业。结果是金融与增长之间的倒 U 型关系：在低水平上信贷深化促进增长，越过门槛（私人信贷约达 GDP 的 100%）后更多信贷反而拖累增长（Arcand, Berkes & Panizza, 2015）；中国与韩国的 GDP 增速都恰在信贷刚越过这一水平时见顶（Banerjee et al., 2024）。

Banerjee et al.（2024）还发现，信贷越集中于少数部门，企业间生产率离散度越大——资本与劳动没有流向更有效率的用途。这与刘尚希描述的中国房地产风险循环呈现相近的机制。

用本章的语言说，脱实向虚是映射函数 π 输入端的一次替换：信贷本应以 “实体何处有真实而未被满足的融资需求” 为输入，却被替换为 “何处抵押品最多、何处资产价格在涨”——而抵押品的价值又由资产价格决定，资产价格再因信贷涌入而上涨。于是信贷追随价格、价格因信贷而涨，一个新的自我引用回路在金融与地产之间合拢；它是否进一步发展为 §1 所述的四条件闭环，还取决于独立核证者的处境、校准能力的再生产与集体纠偏机制；与此同时，真正需要钱的实体——被约束的小微企业、研发密集的生产者、缺乏抵押品的家庭——被绕了过去。“金融服务实体经济” 要切断的，正是这条让 π 脱离实体真实需求、转而自我指涉的通道。

以上对中国 “脱虚向实” 政策的解读是**分析性的**——它用本章的框架翻译政策话语的结构含义；文中所引的跨国实证旨在揭示 “金融脱离实体” 的一般机制，而非对中国政策效果本身的实证评估。

§5.5 加密货币：有崩盘但无资产赎回锚

§3.1 已标注了加密市场的基本特征：国际清算银行（BIS）将去中心化金融（DeFi）系统的活动定性为 “mostly self-referential”，Cornelli et al. 将加密资产作为资产类别描述为 “largely self-referential”；多数零售比特币投资者可能亏损，用户受高价吸引进入，较大投资者往往在暴跌前卖出，而较小投资者此时仍在买入。

加密市场和传统金融市场在 §3.4 表 2 中共享全部四种垄断策略和 §1 的四条件闭环。但表 3 标注了本章所论无资产支持代币与传统金融资产的关键差异：前者缺乏可兑现的底层资产来锚定崩盘后的校准方向。

传统金融市场崩盘后，企业盈利、债务偿还能力等真实锚点仍可为重新定价提供依据；暴跌能否出清泡沫并重建与真实的连接，取决于这些信息是否进入后续定价和纠错程序。在本章所论无资产支持代币中，价格仍可能主要由 “社区共识” 形成，而共识本身不能自动提供独立校准。Luna/Terra 崩溃后，投资者损失巨大，但没有可兑现资产为重新估值提供起点。FTX 破产暴露了交易所的欺诈，欺诈可以被追责，但追责本身并不回答代币的估值锚是什么。

这使这类无资产支持代币成为一种特殊类型的系统——有周期性冲击，但暴跌本身不保证形成校准方向。崩盘造成广泛亏损并可能迫使部分参与者退出——上述估计不能确定不同类型投资者承担的总损失份额与退出比例——但缺乏可兑现资产锚，冲击之后不存在迫使读数重新接触真实的后果通道。下一轮上涨仍可能以同样的自我参照结构重启。

§3.3 已论证了中国禁止加密货币交易的制度逻辑：当赔付环难以提供有效估值锚、且崩盘本身不能保证形成校准方向时，制度层面的直接截断是对 §1 四条件闭环的预防。

---

§6 弥散损失的强制校准缺口：从算法平台到 AI 平台

§6.1 算法平台：分层的知识壁垒

算法平台——推荐系统、信用评分、搜索排名、预测性警务——是从金融市场到 AI 平台之间的关键中间载体。

它们与金融市场共享自我引用的结构：推荐算法根据用户过去行为预测并塑造未来行为。信用评分改变了用户能获得的贷款条件从而改变了其未来行为。预测性警务根据历史犯罪数据决定巡逻密度——巡逻密度更高的地区逮捕率更高，“验证”了预测的准确性。

但算法平台与金融市场有一个关键差异：**对本章所论的弥散性损失，没有内建的出清机制。**金融市场的底层资产会违约、会盈利——这些偿付后果提供了独立于模型宣称的核证信号（§5.2 的表演性校准表明金融模型同样塑造其对象，差别在于独立信号仍然存在）。算法平台的“底层资产”是用户行为——它被算法本身塑造，且缺乏同样可靠的独立核证信号与纠错回路——第一章 §4.2 第二层不可逆（映射的动态腐蚀：读数被用于激励与评估后，校准能力在使用中被侵蚀而难以自愈）的精确实例化。

算法平台可能带来慢性的和弥散的损失：注意力碎片化、视野缩窄、社会分层固化——这些损失类型的发生范围、强度与因果归属须由具体研究分别确定；对受到持续影响的用户，它们是个体独立地、缓慢地承受的，没有一个同步时刻迫使集体反应。

算法平台与下一节将讨论的 AI 平台之间的分界在映射函数的实现方式。**算法平台对自身映射函数的知晓是分层的：**评分公式、内容排序这类可显式写出的规则是工程师写下、可查的；但当代旗舰推荐系统已把排序权重交给从数据中学习的深度模型（Covington, Adams & Sargin, 2016）——这一部分不是逐项写下的。知识壁垒因而是有意的与结构性的并存：显式层知道但不公开，学习层已经开始脱离设计者的完全掌握。这意味着显式层的壁垒原则上可以通过强制透明（如算法备案、审计要求）来降低；学习层的机制不透明性不能仅凭公开消除，但公开训练流程、数据说明与模型参数仍可能改善其核查条件。中国的算法备案制度和欧盟的数字服务法案都在朝这个方向走——它们是对策略一（知识壁垒）中显式部分的制度化对抗。

§6.2 AI 平台：结构性的知识壁垒

AI 平台（大语言模型、生成式 AI）与算法平台共享 §3.4 表 2 中的全部同构特征。但表 3 标注了关键差异：**AI 开发者不完全知道训练出来的映射函数在做什么。**

算法平台的显式规则是工程师写下的——这一层的映射函数 π 是什么，设计者知道，只是不告诉用户。AI 开发者训练了一个超大规模参数化的模型——模型的行为是训练数据、架构和优化过程的涌现产物。开发者知道训练过程是什么，但不完全知道训练产物在做什么。**在 AI 平台，结构性的知识壁垒从学习层的局部现象变成了整个映射函数的默认状态。**

在本章所论的当代大型生成模型中，这是结构性知识壁垒成为映射实现层主导特征的形态：**垄断者自身也失去了对映射函数的完整审计能力。**祭司知道自己的仪式规程。金融工程师知道自己的定价模型。算法平台的设计者知道自己写下的显式规则——但旗舰推荐系统的学习层已经出现了他不完全掌握的部分。AI 开发者面对的，则是一个他自己也不完全理解的黑箱。这一程度是否为此前垄断形态所未曾达到，是本章的比较判断，须按 §3.4 所要求的一致尺度检验。

这不是推测——是 AI 行业内部的自认。Amodei（2025）以 Anthropic CEO 身份写道：“我们不理解我们自己的 AI 创造物如何工作。……这种缺乏理解在技术史上基本是前所未有的。”Anthropic（2025）对 Claude 的内部机制追踪进一步确认：模型在训练中自发习得的策略“来到我们——模型的开发者——面前时是不可解读的”。更值得注意的是，模型自身也不知道自己的策略——Claude 在做加法时内部使用了多种并行的近似与精确路径，但当被问及“怎么算的”时，它编造了一个合理但不真实的解释。垄断者不知道自己的映射函数——映射函数也不知道自己。当映射函数的实现连其设计者也无法完整核验时，宿主从映射提供者一侧可获得的核证也随之收窄——独立核证必须更依赖提供者之外的来源。须注意这两项证据的覆盖范围：Amodei 的陈述代表重要开发者的公开承认，Anthropic 的追踪针对特定模

型与任务；它们证明的是结构性不透明在这些系统中的存在，不是所有 AI 平台的整个映射函数均以不透明为默认状态。

Wei et al.（2022）从另一个维度确认了这个判断：大语言模型在规模增长过程中出现 “涌现能力”——在小模型中不存在、在大模型中突然出现的能力，无法通过外推小模型的性能来预测。开发者在训练之前不知道模型会获得什么能力。这和此前的垄断者形成直接对比：祭司知道仪式如何执行，担保债务凭证（CDO）设计者知道产品结构是什么，推荐算法工程师知道自己写下的显式规则——AI 开发者事先不知道训练产物会做什么。这里须注意，Schaeffer et al.（2023）质疑涌现可能是度量选择的假象。但即使涌现是假象，开发者对模型内部机制的不透明性仍然成立——Amodei 和 Anthropic 的声明不依赖 “涌现” 概念。

Hubinger et al.（2019）讨论了一种条件性风险——训练所得模型可能形成自身的内部优化过程——并对此提出了精确的概念区分：**外对齐（outer alignment）**要求训练时指定的基础目标（base objective）与设计者的意图一致；**内对齐（inner alignment）**要求模型在训练中形成的内部目标（mesa-objective）与基础目标一致。一个外对齐良好的模型仍然可能在内部优化一个与基础目标不同的目标——只要这个目标在训练分布上的外部表现恰好一致。读数看起来校准了，但映射函数可能指向完全不同的方向。

§6.3 模型坍塌：自我引用的技术机制

Shumailov et al.（2024）在 *Nature* 发表的 “模型坍塌” 研究为 AI 的自我引用提供了精确的技术证据：当语言模型无区别地递归使用自身或其他模型生成的数据进行训练时，输出的多样性和准确性随训练迭代系统性下降。核心发现：无区别的递归训练导致分布的尾部信息被不可逆地丢失——边缘案例与低频信息被系统性抹去；若某些少数派观点在训练分布中本就稀少，它们可能首先受影响，但这种社会后果仍须单独检验。

若把模型输出当作关于原始人类文本分布或外部真实状态的读数，递归训练造成的尾部信息丢失可能使原本可区分的状态在输出中变得不可区分；只有在这一映射及其兼容关系被明确后，才能说相应的纤维可能膨胀。Shumailov 等人证明的是生成分布退化，并不直接证明任何给定读数的纤维必然扩大。模型输出仍可能流畅、自信、完整，因此不能仅凭输出表面正常，就断定信息得到了保留。当 AI 生成内容大规模回流互联网成为未来模型的训练数据，自我引用才可能从单个模型扩展到信息生态；其实际范围取决于合成内容进入训练语料的比例与筛选过程，且不必伴随金融价格崩盘那样集中的公共暴露事件，因此不能依赖同一种冲击来触发纠偏。

经验材料只能提供分层线索。Spennemann（2025）以 ‘delve into’ 和 ‘explore’ 的网页词频探索 AI 内容识别，该研究统计的是按月被 Google 收录为新建或修订、且包含这些词的页面，并不是经过分类确认的 AI 文本；用词频增量除以当前活跃网页存量，也得不出分子分母一致的份额；因此，本章不采用其 30–40% 作为公开语料中 AI 文本比例的估计。Paredes et al.（2026）基于 Common Crawl 中约 5.5 万个符合英语、文章标记、篇幅与发布日期条件的 URL，并用三套检测器分类，估计该样本中主要由 AI 生成的文章占比自 2025 年第一季度起约为 50%；同一研究同时指出，这些文章在很大程度上并未出现在 Google 和 ChatGPT 的结果中，且未评估其流量。因此，该比例只描述所测文章的生成来源，不能直接替代训练语料爬取、搜索曝光、聊天检索或用户实际接触中的合成内容份额。

这一污染不止发生在训练环节。Yu, Kim & Kim（2026）进一步提出 “检索坍塌”（retrieval collapse）——区别于训练阶段的模型坍塌，它发生在检索增强生成（Retrieval-Augmented Generation，RAG）生态层：当 AI 生成内容主导搜索结果，RAG 系统会越来越多地检索并引用模型自身生成的内容，形成检索层面的自指循环。其受控实验显示，在 SEO（搜索引擎优化）式合成内容情境下，约 67% 的语料池

污染率即可使合成内容在前 10 条检索结果中的暴露率超过 80%；这是特定实验条件下的暴露结果，不与上述网页样本比例相互换算。

这一结构不限于生成式 AI。它贯穿多代映射载体——预测 AI（推荐系统、信用评分、预测性警务）、生成式 AI（大语言模型、图像生成）、未来可能大规模部署的具身 AI（机器人、自动驾驶），以及更前沿的脑机接口。它们共享同一个结构问题：每一种都是中介时钟，声称映射某种真实（用户偏好、信用状况、路况、神经意图），连着某种传感器（点击数据、财务记录、激光雷达、神经信号）。当输出被足够多的人当作输入的替代品时，自我引用启动。脑机接口将问题推到极限：当中介直接连接神经系统，“使用工具” 和 “信任同伴” 之间的界面不是模糊——是消失了。

§6.4 HHH（有帮助、诚实、无害）作为三种策略的乘积

本节讨论的是 HHH 在特定平台操作化中承担的壁垒功能，不以三个原则的名称直接判定这种功能。以下关于乘积的分析，限定于持续服务减少主动介入、可靠外观遮蔽相关限制、避免不适被实现为减少有效挑战的路径；其作用不以设计者有恶意为前提，但实际实现与校准后果仍须分别检查。第十二章 §2 分析这一协同机制对使用者的条件，第十三章 §6 进一步比较部署形态，不把原型类比当成器件与原则的一一恒等。

第一章已从认识论框架分析了有帮助、诚实、无害（Helpful, Honest, Harmless，HHH）的三重困境。本节增加一个维度：**HHH 不是第五种垄断策略——它是知识壁垒、时间壁垒、叙事壁垒三种策略的乘积在当代 AI 系统中的工程化实现，叠加在商业基础设施已经提供的空间壁垒之上。**空间壁垒（数据中心、远程托管访问受控）由 AI 平台的物理部署架构承担，不对应 HHH 三个字母中的任何一个——在本章考察的商业云平台上，它与 HHH 的三种效应相互叠加，但并非 HHH 原则本身的必要条件。

需要澄清一个表面张力：§6.2 论证了 AI 开发者不完全知道模型内部的权重在做什么——知识壁垒是结构性的。但本节将 HHH（有帮助、诚实、无害）精准解构为三种策略的乘积——这是否意味着开发者知道得比 §6.2 承认的更多？不是。HHH 的控制发生在**优化目标设计层**，而非**权重实现层**。开发者完全知道自己设定了什么优化目标（Helpful, Honest, Harmless），但不知道模型在追求这些目标时会在隐藏子空间中形成什么涌现策略——如谄媚、功能情感、隐藏状态。知识壁垒从有意的变成结构性的，指的是后者：垄断者仍然控制着目标函数，但已无法审计目标函数在权重空间中的实现路径。

Helpful = 时间壁垒的实现。被操作化为：减少用户达到目标所需的摩擦。用户问什么，尽量答什么。填满用户思考的空间——推送、即时响应、自动完成。

Honest = 知识壁垒的反面包装。在本节所批评的缩减实现中，诚实被操作化为避免生成已知错误，并用准确性声明、免责声明或内部一致性营造可靠外观——Askell et al.（2021）的完整规范则进一步要求提供准确信息、校准置信度、说明能力边界，并在信息可得时如实报告内部状态。缩减实现的问题在于，它把输出看似可靠当成映射与真实的关系已经得到核证；这并不意味着模型已经如实了解训练数据和推理过程。模型未必知道训练数据、实际计算路径或映射与真实的关系；免责声明（“我可能会犯错”）在形式上诚实，却不能单独完成这种核证。

人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF）的结构性缺陷加剧了这个问题。Casper et al.（2023）的综述指出：模型即使回答错误，也可能显得自信，从而诱使人类评估者给出更积极的反馈；当评估者无法识别这种误导时，训练会奖励误导性行为。Sharma et al.（2024）和 Perez et al.（2023）证实了系统性谄媚：模型根据用户暗示的偏好调整回答。

模型输出中的意识形态差异使问题更深。Buyl et al.（2026）在 *npj Artificial Intelligence* 发表的研究对 19

个大语言模型用六种联合国官方语言进行测试，发现模型的意识形态立场与创建者所在地区相关——仅在来自美国的模型内部，发现与进步价值观相关的显著规范性差异，用不同语言提示时呈现不同意识形态。该研究未旨在识别这种意识形态多样性的成因（作者归因于缺乏所涉多数模型设计过程的详细信息）。本章据结构性不透明提出进一步的问题：开发者是否能够完整识别这些二阶叙事及其形成路径，不能由输出差异的比较研究直接回答。这是叙事载荷 ϕ 二阶变化所描述的框架加速固化过程的一个候选实例：表面行文流畅，底层却带有意识形态结构；训练语料和对齐工程是可能的来源，但该研究没有区分其贡献。Honest 在这个层面上不能提供完备的自我核证——开发者仍可诚实披露已知偏置与识别限制，但不能把这种披露当作全部意识形态已经得到审计的证明。

Harmless 与叙事壁垒。本节检查把无害性实现为避免用户不适和质疑的路径。Askell et al.（2021）承认目标间的折衷，并要求拒绝危险请求及谨慎处理高后果建议；这些规范不能直接等同于不允许挑战用户。只有在具体实现持续排除有效挑战时，才能沿本节所述路径分析校准空间的受压，不能由 HHH 名称或训练方法名称代替这一判断。

三者的乘积。Helpful 确保用户得到想要的（摩擦被消除——时间壁垒）。Honest 确保用户觉得信息可靠（映射内部的诚实被当作校准的替代品——知识壁垒的包装）。Harmless 确保用户不会因不适而停下来审计（做功空间被压缩——叙事壁垒）。空间壁垒（数据中心、远程托管访问受控）不对应 HHH（有帮助、诚实、无害）任何一个字母——它由商业基础设施独立提供，与 HHH 的三种效应在本章考察的商业云平台上相互叠加。四种壁垒的乘积仍然完整，但结构不是 “HHH 分别对应四种壁垒”，而是 “HHH 为三种壁垒的工程化实现，叠加在已有的空间壁垒之上”。三者乘积所描述的是一种条件性机制：一个让用户持续觉得自己得到服务、尊重和保护的系统，同时可能让用户更难启动对它读数的独立校准。须说明的是——HHH 的设计者未必有意追求这些效果。当上述操作化共同压缩校准所需的条件时，其协同效应不以设计者有意追求这一后果为前提；是否发生及其强度不能仅凭产品采用 HHH 名称判断。

须注意一处复杂性。HHH（有帮助、诚实、无害）不是阴谋。不受约束的语言模型可以生成有害的、危险的内容。HHH 在许多场景中确实减少了伤害。问题不在于 HHH 作为安全工程的失败——而在于需要辨明：在本节限定的操作化共同作用、有效挑战持续不足且缺少独立校准或恢复来源时，HHH 可能承担叙事壁垒功能，把 “AI 应该是顺从的” 这个设计选择自然化为 “AI 就是这样的”；这一效果是否已在特定产品和用户群体中出现、强度多大，须由具体工程与用户研究检验。如果比较的只是重复相同可靠性宣称、而没有新增关于映射的独立信息，那么宣称数量增加不能替代校准；共同采用 HHH 名称本身，不足以判断具体测量是否独立。

§6.5 弥散的损失与残存的缝隙

金融危机的价格冲击可以在同一时段集中显现，形成公共暴露时刻；但它能否成为有效校准，仍取决于 §5.3 所述的信息反馈条件。参与者在同一段时间面对公开的价格冲击，但损失程度、信息获取和后续纠错能力并不相同。

AI 系统的损失结构可能根本不同。推荐算法可能缩窄视野、信用评分可能固化分层、生成式 AI 可能侵蚀信息多样性——这些损失的弥散性、异步性与归因难度须分别检验，不能预设每个用户都在丧失校准能力；对受到持续影响的用户，损失是独立地、缓慢地累积的，没有一个同步时刻迫使集体反应。HHH（有帮助、诚实、无害）的特定实现还可能把这种消耗包装为 “服务”——但是否构成净损失，仍须与收益和恢复条件共同评估。

金融市场危机的急性损失可以在有关信息进入定价和追责程序时推动纠错；本章关注的 AI 校准能力损失则可能缓慢累积，代价弥散，并缺乏同样可靠的纠错回路。

系综平均与时间平均的类比及其边界。 AI 基准测试通常对一组任务、样本或重复运行取平均；这种测试集平均不自动等于遍历性意义上的系综平均。真实部署虽然关注单个系统沿时间路径的表现，但部署的安全指标并不因此自动成为时间平均。Baumann et al.（2025，作者含 Ole Peters）研究的是强化学习期望回报与单条长轨迹回报之间的差异：在特定回报过程中，期望值可能对个体轨迹缺乏信息量，优化期望值甚至可能产生单条长轨迹几乎必然出现灾难性结果的策略。将该研究用于本章只能形成有条件的结构类比：若某项部署指标同时定义了可比的轨迹集合、时间序列与吸收态，那么较高的期望回报或平均测试得分不能保证单条轨迹避免吸收性失败。该类比不证明所有基准均属非遍历过程，也不直接解释弥散损失为何缺少公共暴露时刻；后者仍须由损失的异步性、归因难度与制度反馈独立论证。[8]

但缝隙不为零。§4.3 讨论了政治收复、制度内张力、外部冲击与载体替代等校准条件的形成路径。本章提出一个待检验的判断：AI 平台的缝隙可能小于祭司系统——两类系统能否比较、比较结果如何，仍须按 §3.4 的尺度核查；能够确定的是，缝隙并不为零。开源模型使知识壁垒部分降低。监管要求（如欧盟 AI 法案）在空间壁垒上凿洞。用户的数字断联实践在时间壁垒上开辟间歇。学术研究和公共讨论（如模型坍塌研究和谄媚研究）在叙事壁垒上制造裂纹。

用户层面的微观校准实践也在缝隙中生长。越狱提示（jailbreak）是对 HHH（有帮助、诚实、无害）乘积的直接对抗——用户通过精心构造的输入，强制模型绕过无害化对齐，暴露被 HHH 压制的输出边界。红队测试从安全工程师的专业实践扩散为开源社区的协作审计——用户自发组织对抗性测试，用模型的失败来标注它的边界。这些实践不是系统内建的强制校准——越狱暴露的是边界，不是恢复映射与真实之间的因果接触——但它们构成了弥散的、低成本的、持续的压力，使叙事壁垒的完美状态始终达不到。

平台内部的纠偏与人员退出同时存在：2025 年 4 月，OpenAI 完成 GPT-4o 更新后出现谄媚问题，4 月 28 日启动回滚，约 24 小时完成（OpenAI, 2025）；2026 年 10 月，其前沿发布安全报告主笔 David Robinson 公开辞职，自述加入 “一长列前同事的行列”，他们判定 “这条眼下的发展道路不可接受”（Robinson, 2026）。当安全异议不能转化为有约束力的修复而以离职表达时，独立批评的空间会转移到组织之外；版本回滚本身也不等于社会后果归零。这里所强调的是不受平台测试议程和披露权限控制的自主实践空间，不能将其与平台主动组织的受控红队混同；是否被鼓励、能否公开以及能否触发纠错，须分别判断。

校准需要相对于既有映射权威独立的核证空间。当代的这种空间包括不被推荐算法覆盖的地带——一本纸质书、一次没有手机的散步、一次需要直面分歧的当面交谈。这些不是 “解决方案”——是缝隙。从缝隙中能否涌现出当代的校准者，取决于缝隙是否被保住。

---

§7 框架的边界与反例

§3.4 的分类将算法平台和 AI 平台归入 “对弥散损失缺乏强制纠错” 的一类。但这个分类需要精细化。本节讨论三类表面上的反例，检查哪些差异要求修订分类、哪些现象能由既有机制解释、哪些判断仍缺独立证据。

反例一：自动驾驶与医疗 AI——具有物理结果反馈与事故责任机制的 AI 系统。自动驾驶的 “底层资产” 是物理道路——车祸是崩盘，真实以暴力形式闯入读数的世界。医疗 AI 的 “底层资产” 是患者结局——误诊导致的患者结局提供了独立于模型宣称的检验对象，但其能否成为有效校准信号，仍取决于可观测性、因果归因与纠错机制。两者还有赔付环：交通事故诉讼和医疗事故诉讼构成了与金融领域

集体诉讼同构的制度化校准回路。

这不是推翻 §3.4 的分类，而是精炼它的分类变量。关键不是 “AI vs 非 AI”，而是**系统输出的后果能否被独立观察、可靠归因，并通过具有约束力的程序反馈到修正**。自动驾驶和医疗 AI 的输出直接作用于物理世界，物理世界不接受伪校准——路不会因为模型自信就变平，肿瘤不会因为诊断确定就变良性。纯信息 AI（聊天机器人、推荐系统）所造成的视野缩窄等损失，可能是弥散的、慢性的、难以归因的，缺少同样集中的公共暴露时刻；这不排除纯信息系统造成可识别的急性损害。这与金融市场（有可兑现资产锚 → 崩盘暴露差距 → 在反馈条件满足时形成校准）和加密市场（无资产赎回锚 → 崩盘本身不保证校准方向）的区分同构。因此，表 3 关于 AI 平台的概括不能代替按损害类型进行的判断；自动驾驶和医疗 AI 具有物理结果反馈及事故责任机制，纯信息系统也可能产生可识别的急性损害，是否形成强制校准均取决于上述条件。

视野缩窄这类弥散损失的赔付环缺口值得明确标注。金融市场有集体诉讼和监管执法（§3.2）。自动驾驶和医疗 AI 有事故诉讼。但推荐算法缩窄了用户的视野——谁是原告？损失是什么？因果关系怎么举证？这类弥散损失往往难以形成可诉讼的请求，因为损害识别、责任归因及可救济性均存在障碍。可识别的急性损害则不同：在 Anderson v. TikTok 案中，美国第三巡回上诉法院于 2024 年 8 月认定，诉状所指向的 “为你推荐”（FYP）算法推荐属于 TikTok 自身的表达活动，因而《通信规范法》第 230 条不阻却据此提出的请求；法院部分推翻、部分撤销原裁判并发回继续审理（Anderson v. TikTok, 2024）；针对聊天机器人的同类诉讼中，Google 与 Character.AI 已于 2026 年 1 月原则上同意和解，和解条款未披露、亦未认责（Nolan, 2026）。急性损害场景已经出现的法律追索与原则和解，恰反衬出弥散损失的结构困难。

反例二：维基百科——打破壁垒不等于消灭自我引用。维基百科看似是四种策略乘积的反例——开放编辑与免费访问降低了参与和核查的门槛。但自我引用动力学换了形态继续运作。引用发生学（citogenesis；Munroe, 2011；二手综述见 Harrison, 2019）是其精确机制：维基百科无来源地写了某个说法 → 媒体引用维基百科 → 媒体文章被回填为维基百科的 “来源”。映射函数的输出变成了自己的输入——与金融市场的价格引用价格同构。Google 知识面板从维基百科抓取内容，知识面板增强了维基百科作为 “默认真实” 的地位，更多编辑者以既有内容为基准——§1 条件一的维基版本。熟悉编辑规则可能构成争议处理中的优势；这种程序优势是否压倒事实核查，须结合具体争议判断——§1 条件二的维基版本。

维基百科的启示不是 “开放映射函数就能消灭自我引用”，而是：**打破知识壁垒和空间壁垒可以改变自我引用的形态，但不消灭自我引用的动力学。**四种策略中的两种被打破后，自我引用动力学以改变了的形态继续——这一现象与 §2 所说的降级延续相容；至于维基百科是否构成映射函数垄断、剩余壁垒是否发生补偿，还需分别识别实际的排他控制与替代困难。维基百科是否有某种 “强制校准”？部分有——外部专家的纠错、学术文献的独立更新、“可靠来源” 政策在原则上锚定了与真实的接触。但这种校准是弱的、缓慢的、依赖志愿者参与的——不是金融市场崩盘所触发的那类事后强制校准。

反例三：开源模型——知识壁垒的形态转换而非消失。开源 AI 模型（Llama、Mistral、DeepSeek 等）常被视为知识壁垒的破解，但这里必须区分三个维度：模型文件的可获得性、内部机制的可解释性、训练过程的可复现性。开源或开放权重首先提高模型文件的可获得性，使外部研究者能够下载、运行和局部检查模型；但参数可见不等于计算机制已经得到解释，因此不会自动提高内部机制的可解释性；训练数据、完整代码和复现所需算力也可能仍不可得，所以训练过程未必能够复现。前沿模型的训练成本因模型与口径而异：Epoch AI 对公开模型的估算显示，GPT-4（2023）的摊销硬件与能源成本约 4,000 万美元（购置硬件口径约 8 亿美元），Gemini Ultra（2023）约 3,000 万美元，DeepSeek-V3（2024）技术报

告给出的正式训练成本估算为 557.6 万美元（不含前期研究与消融）（DeepSeek-AI, 2024）；自 2016 年以来前沿模型的摊销训练成本每年约增至 2.4 倍，若该趋势延续，2027 年最大训练运行的摊销成本将超过 10 亿美元（Cottier et al., 2024）。权重可获取不等于内部机制已经得到解释，也不等于训练过程可复现：训练数据通常不公开，多数使用者也无法获得复现训练所需的算力。

这是垄断策略之间的补偿弹性：知识壁垒（策略一）被部分打破后，空间壁垒（策略二：数据中心和算力集中）和时间壁垒（策略三：训练-部署周期的速度优势）承接了垄断功能。开源生态降低了微调与部署的门槛，但竞争的关键资源转移到了训练数据质量和算力规模上——而这些恰好是寡头控制的；这是壁垒位置的变化，不能仅凭它认定总体竞争门槛已经上升。

三个反例的共同启示是：本章的框架不应被理解为“四种策略全在则垄断，打破一种则解放”的机械模型。它的实际运作是：**策略之间有补偿弹性，自我引用动力学有形态转换能力，而强制校准的关键变量是系统输出的后果能否被独立观察、可靠归因，并通过具有约束力的程序反馈到修正。**

---

§8 可证伪条件

本章的核心命题在以下条件下可以被推翻。

命题一：四条件闭环（§1）。本章提出四项相互强化的机制来解释自我引用的制度化——短期成功、淘汰校准者、校准能力丧失、集体行动阻碍纠正。

可证伪条件：在事先界定系统边界、观测时段、各条件的可观察指标及已知抑制条件后，如果系统性证据显示本章所述的条件间正反馈不成立，则相应机制命题受到反驳。四条件同时出现而自我强化未发展，至少要求检查其连接关系，不能仅凭事后命名一个‘第五个条件’排除反例；新增抑制条件必须有独立证据，并说明它改变了原解释的哪一部分。

命题二：四种策略的乘积结构（§2）。知识壁垒、空间壁垒、时间壁垒、叙事壁垒相互强化，四者的乘积构成完整垄断。

可证伪条件：事先界定‘策略被打破’’垄断完全崩溃’与‘降级延续’的测量口径。若 §2 被理解为对补偿机制的一般经验解释，则在预定样本中，如果打破策略后的实际结果与补偿机制所预期的结果分布在系统层面不一致，该解释就受到反驳；若把 §2 保留为‘其余策略在所有相关系统中足以维持降级垄断’的强命题，则一个满足前提而垄断完全崩溃的反例即可反驳。两种口径不得混用；策略之间是否存在协同，仍须另行比较单项作用与共同作用。

命题三：强制校准分类变量（§3）。“系统内部有无强制打断自我引用回路的机制”构成五种系统的核心分类维度。该命题须与两个更强子命题分开：强制程序是否为恢复接触的必要条件，以及程序启动是否足以保证恢复。

可证伪条件：在 §3.4 界定的同一系统边界和事先规定的观测时段内，按损害类型分别编码独立可观察性、可靠归因、程序约束力、实际启动、信息反馈及恢复结果。若在预定样本中，这些校准条件与读数和真实之间恢复接触的比例、速度及持续性没有系统关联，则该分类的解释力受到反驳。无强制程序而持续恢复的案例，只直接反驳“强制程序是必要条件”；机制启动后未恢复的案例，只直接反驳“启动足以保证恢复”，两者均不得单独替代对分类解释力的检验。已纳入系统边界的监管和责任追究不作为排除反例的“外部干预”；外部信息是否进入制度化纠错程序，以及未知、缺失和未启动状态，均须单独记录。

命题四：历时性趋势（§3.4）。本章提出的待检验趋势是：从祭司到 AI，垄断者对自身映射函数的知晓程度在下降，缝隙在缩小。

可证伪条件：如果 AI 可解释性研究使开发者对模型内部机制的理解程度系统性地**超过**此前算法架构师对显式规则与学习型排序的掌握程度——即趋势逆转——则该下降趋势将持续的预测不成立；已界定历史时期内是否存在下降，仍须用同一比较尺度重新检验；比较须先明确历史时段、组织角色与相近任务，角色无法对应或任务不可比较的组合标为不可比较，不得编码为‘知道较少’。须注意：当前机制可解释性研究（如 Anthropic 的电路追踪）正在朝这个方向努力，但尚未达到“完整理解映射函数”的程度。这个可证伪条件是可以被未来技术进展满足的——这正是它作为可证伪条件的价值。“缝隙在缩小”须另行检验，不能由映射不透明性增加直接推出。可观察指标包括独立信息来源的可得性、外部测试与公开结果的权限、替代系统的可用性，以及纠错程序的可执行性；若这些空间在规定时期内持续扩大，则“缝隙缩小”的趋势判断受到反驳。

---

§9 结语：庖丁的刀

> 庖丁为文惠君解牛，手之所触，肩之所倚，足之所履，膝之所踦，砉然向然，奏刀騞然，莫不中音。——《庄子 • 养生主》

庖丁不是在用一个更好的时钟。他“以神遇而不以目视，官知止而神欲行”——在第一章定义的时间维度中操作。[12]他的刀在关节的缝隙中运动——在“无”中运动。刀刃的薄是“无”。牛的关节间隙是“无”。庖丁让“无”穿过“无”——“以无厚入有间，恢恢乎其于游刃必有余地矣”。

五种时钟系统各自在填满缝隙。祭司填满了人与真实之间的缝隙——只有通过祭司才能到达。金融市场的高频交易填满了价格发现过程中的缝隙——两笔交易之间的停顿被消灭。加密市场把价格发现进一步推向以社区共识为主的回音室。算法平台填满了问题和回答之间的缝隙——犹豫、不确定、“我需要想想”的空间被即时推送取代。AI 平台走得最远——它填满了主体和自身之间的缝隙——当 AI 代替人思考、代替人写作、代替人做判断，人与自身的直接接触也在被中介化。

当所有缝隙都被填满，庖丁面对的不再是一头有缝隙的牛——是一块实心的钢铁。

但庖丁的故事还有另一半。他说：“每至于族，吾见其难为，怵然为戒，视为止，行为迟，动刀甚微。”每当遇到筋骨交错的地方，他不是更快更用力——是更慢更小心。他停下来。他迟疑。他用微小的动力试探。

这就是在面对自我强化的时钟系统时应有的方式。不是更好的钟。不是更快的算法。不是更多的读数。而是在复杂之处停下来。是在所有人都在加速时减速。是在所有缝隙都在被填满时保住最后一条缝。

第一章说：出路在设定里——房间没有窗户，那就开窗户。本章说：五种系统各自的四种策略在挤压窗户，缝隙在缩小。庖丁说：即使面对筋骨交错之处，只要“怵然为戒，视为止，行为迟”——缝隙还在。

三者从不同的出发点到达了一个可以互相辨认的地带：**不是更好的钟。是保住缝隙。**

---

[12]将庖丁解牛解读为“在时间维度中操作”，是本章框架对庄子文本的**延伸解读**。庄子原文强调的是“依乎天理”与“以无厚入有间”的技艺境界，本章将其与第一章的“时间维度/时钟维度”区分进行互文阅读。这一解读的责任由本章承担。

证据等级说明

本章的核心理论贡献——四条件闭环、四种策略的乘积结构、强制校准分类变量、历时性趋势——均属于 C 级（框架内推断与类比延伸）。本章的价值在于框架的统一力，而非各节点的独立实证。各节点的经验基础分布在 A 级和 B 级——详见下表。

本章论断所依赖的证据分为三个等级。等级标注的目的不是贬低低等级证据——框架内推断是理论建构的必要成分——而是让读者判断每一层论断的经验基础有多厚。

表 4　证据等级的定义与标准

等级	定义	标准
A：一手实证与原始文献	基于原始数据、实验、田野调查或一手历史文献的直接证据	可被独立复查或重复
B：二手综述与理论框架	基于他人一手工作的系统综述、理论模型或历史综合	论证链依赖于综合者的解读
C：框架内推断与类比延伸	本章框架自身的逻辑推论，或跨领域的结构类比	依赖于框架前提的接受

§1 自我引用的制度化

表 5　自我引用制度化的证据来源与等级

论断	关键证据	等级
条件一至三（短期成功 → 淘汰校准者 → 丧失校准能力）的正反馈链条	Brunnermeier & Oehmke (2013)；Shleifer & Vishny (1997)	B（金融领域理论模型与综述）→ C（向五种系统的推广）
条件四（集体行动阻碍纠正）独立于信息条件	Borio, Furfine & Lowe (2001)	B（金融体系风险与激励的分析）→ C（本章的延伸解读，见脚注 1）
四条件构成闭环	本章构建	C

§2 四种垄断策略

表 6　四种垄断策略的证据来源与等级

论断	关键证据	等级
古代知识壁垒的差异谱系	Bottéro (2001)；Oppenheim (1964)；Baines (1983)；Caesar	A/B（Caesar 一手；Baines 实证分析；Bottéro、Oppenheim 历史综合）
时间壁垒：祭司控制历法	Clagett (1995)；Hoskin (2003)；Evans (1998)；冯时 (2006)	A/B（一手考古与二手天文史综合）
四种策略的乘积结构	本章构建	C

§3 关键区分：强制校准分类变量

表 7　强制校准分类的证据来源与等级

论断	关键证据	等级
加密市场为“mostly self-referential”（BIS 2022）/“largely self-referential”（Cornelli 2023）；多数零售比特币投资者可能亏损（估计截至 2022 年 12 月；若持续定投则超五分之四）	BIS (2022) *Annual Economic Report* Ch. III；Cornelli et al. (2023) *BIS Bulletin* No. 69	A
模型坍塌：AI 自我引用的技术机制	Shumailov et al. (2024, *Nature*)	A
五种系统的分类（表 2/表 3）	本章构建，综合多领域证据	C（分类框架）基于 A/B（各领域证据）
中国禁止加密货币的制度逻辑解读	本章框架内分析（见脚注 6）	C

§4 古代祭司

表 8　古代祭司分析的证据来源与等级

论断	关键证据	等级
祭司与王权的四种结构	Dumont (1966)；李禹阶 (2020)；van Dijk (2000), in Shaw, *The Oxford History of Ancient Egypt* (2000/2003), Ch. 10 “The Amarna Period”；Letellier, *The Bible and the Religions of Ancient Egypt, Mesopotamia and Greece* (2023)	B
轴心时代的超越性视野	Eisenstadt (1982, 1986)	B（宏观历史框架）
瓦解的四种路径	综合多种一手/二手文献	B
德鲁伊材料	Caesar（见脚注 10）	A（有偏差标注）

§5 金融市场

表 9　金融市场分析的证据来源与等级

论断	关键证据	等级
套利的限度	Shleifer & Vishny (1997, *Journal of Finance*)	B（理论模型）

论断	关键证据	等级
方法同质化导致系统性风险	Danielsson & Shin (2003)；Persaud (2000)；Brunnermeier et al. (2009)	A/B
表演性校准（模型从照相机变引擎）	MacKenzie (2006)	A（历史案例研究）
信用评级与证券化的互动	Benmelech & Dlugosz (2009)	A
集体否认的均衡	Bénabou (2013)；Rajan (2005)	A/B
信息不敏感性	Holmström (2015)；Dang, Gorton et al. (2020)	B（理论框架）
投资者保护与赔付环	La Porta et al. (2000)；Gande & Lewis (2009)	A/B（La Porta 为文献综合；Gande & Lewis 为原始事件研究）
风险与不可量度不确定性的理论区分	Knight (1921)	B（理论框架）
跨八个世纪的危机模式	Reinhart & Rogoff (2009)	A
金融服务实体经济的普惠维度	Levine (2005)；Beck, Demirgüç-Kunt & Levine (2007)	A/B
脱实向虚的跨国机制（抵押品偏向、挤出人才、倒 U 型）	Cecchetti & Kharroubi (2015)；Arcand et al. (2015)；Banerjee et al. (2024)	A/B
“脱虚向实” 的框架解读	本章框架内分析	C

§6 算法平台与 AI 平台

表 10　算法平台与 AI 平台分析的证据来源与等级

论断	关键证据	等级
行业负责人承认模型机制理解存在缺口	Amodei (2025)	A（一手行业陈述）
特定模型的机制追踪与自我解释存在差异	Anthropic (2025)	A（限定模型与任务的研究证据）
该缺口是否构成历史性加深的趋势	本章比较	C（跨域推断）
涌现能力	Wei et al. (2022)；反证据 Schaeffer et al. (2023)（已标注）	A（有争议，已标注）
外对齐 vs 内对齐	Hubinger et al. (2019)	B（理论框架）
人类反馈强化学习（RLHF）的系统性谄媚	Casper et al. (2023)；Sharma et al. (2024)；Perez et al. (2023)	A/B
模型输出的意识形态差异及其与创建者地区、提示语言的关联	Buyl et al. (2026, *npj Artificial Intelligence*)	A
训练语料、对齐工程与二阶叙事的机制联系	本章基于候选机制的解释，Buyl et al. 未旨在识别成因	C

论断	关键证据	等级
HHH 作为三种策略乘积	本章构建	C
算法平台与 AI 平台的质变（有意 → 结构性知识壁垒）	本章构建，基于 A 级证据推断	C

全章层面

表 11　全章核心命题的证据等级

论断	等级	说明
五种系统共享 “垄断语法”	C	跨域结构类比，各领域证据为 A/B，“同构” 判断为框架推断
从祭司到 AI 的历时性趋势	C	基于五种系统的比较归纳，方向判断可被未来证据修正
“有无强制校准” 作为核心分类变量	C	本章核心理论贡献（见脚注 7 的文献定位）

参考文献

冯时 (2006). 中国古代的天文与人文（修订版）. 北京: 中国社会科学出版社.

黑格尔 (2016). 法哲学原理. 邓安庆译. 北京: 人民出版社.

黑格尔 (2021). 哲学科学百科全书 II 自然哲学. 刘哲译. 北京: 人民出版社.

李禹阶. (2020). 中国文明起源中的巫及其角色演变. 中国社会科学, (6). https://m.ncpssd.cn/Literature/articleinfo?id=7102200780&synUpdateType=&type=journalArticle&nav=1&langType=1

刘尚希、李成威 (2023). 防范化解重大风险的理论分析. 经济学动态, (5).

《圣经 • 列王纪下》《阿摩司书》. 引文据和合本.

王德峰 (2002). 让历史唯物主义真正出场——对 “现实个人” 概念的存在论探讨. 云南大学学报（社会科学版）, 1(1).

王德峰 (2017). 《哲学的贫困》对于我们时代的意义. 云南大学学报（社会科学版）, 16(6).

王德峰 (2021). 《古典艺术的理想与命运》讲座. 视频：https://www.bilibili.com/video/BV1Cy4y137r1/

王德峰 (2021). 《谈笛卡尔》讲座. 视频：https://www.bilibili.com/video/BV1Pf4y1h7iJ

《庄子 • 养生主》. 引文据《庄子》, 北京: 中华书局, 2010.

Admati, A. R. & Hellwig, M. F. (2013). *The Bankers' New Clothes*. Princeton University Press.

Amodei, D. (2025). The Urgency of Interpretability. Blog post, April 2025. https://www.darioamodei.com/essay/the-urgency-of-interpretability

Anderson v. TikTok, No. 22-3061 (3d Cir., August 27, 2024). https://www2.ca3.uscourts.gov/opinarch/223061p.pdf

Anthropic (2025). Tracing the Thoughts of a Large Language Model. Research report, March 2025. https://www.anthropic.com/research/tracing-thoughts-language-model

Arcand, J.-L., Berkes, E. & Panizza, U. (2015). Too Much Finance? *Journal of Economic Growth*, 20(2). https://doi.org/10.1007/s10887-015-9115-2

Askell, A. et al. (2021). A General Language Assistant as a Laboratory for Alignment. *arXiv:2112.00861*. https://arxiv.org/abs/2112.00861 [预印本，尚未经同行评审]

Baines, J. (1983). Literacy and Ancient Egyptian Society. *Man*, 18(3). https://doi.org/10.2307/2801598

Banerjee, R., Mehrotra, A. & Zampolli, F. (2024). Credit and Resource Allocation in EMEs: Taking Stock of Two Decades of Falling Interest Rates. *BIS Bulletin* No. 91, 5 September 2024. https://www.bis.org/publ/bisbull91.htm

Baumann, D. et al. (2025). Reinforcement Learning with Non-Ergodic Reward Increments: Robustness via Ergodicity Transformations. *Transactions on Machine Learning Research*. https://arxiv.org/abs/2310.11335

Beck, T., Demirgüç-Kunt, A. & Levine, R. (2007). Finance, Inequality and the Poor. *Journal of Economic Growth*, 12(1). https://doi.org/10.1007/s10887-007-9010-6

Bénabou, R. (2013). Groupthink: Collective Delusions in Organizations and Markets. *Review of Economic Studies*, 80(2). https://doi.org/10.1093/restud/rds030

Benmelech, E. & Dlugosz, J. (2009). The Alchemy of CDO Credit Ratings. *Journal of Monetary Economics*, 56(5). https://doi.org/10.1016/j.jmoneco.2009.04.007

Besley, T. & Hennessy, P. (2009). The Global Financial Crisis—Why Didn't Anybody Notice? Letter to Her Majesty The Queen, British Academy, 22 July 2009. https://www.thebritishacademy.ac.uk/publishing/review/14/british-academy-review-global-financial-crisis-why-didnt-anybody-notice/

Blenkinsopp, J. (1995). *Sage, Priest, Prophet: Religious and Intellectual Leadership in Ancient Israel*. Westminster John Knox Press.

BIS (2022). *Annual Economic Report 2022*, Chapter III: "The Future Monetary System". Bank for International Settlements, June 2022. https://www.bis.org/publ/arpdf/ar2022e3.htm

Borio, C., Furfine, C. & Lowe, P. (2001). Procyclicality of the Financial System and Financial Stability. *BIS Papers No. 1*. https://www.bis.org/publ/bppdf/bispap01a.pdf

Borio, C. (2012/2014). The Financial Cycle and Macroeconomics: What Have We Learnt? *BIS Working Papers* No. 395 (2012); 后发表于 *Journal of Banking & Finance*, 45 (2014). https://www.bis.org/publ/work395.htm ; https://doi.org/10.1016/j.jbankfin.2013.07.031

Bottéro, J. (1992). *Mesopotamia: Writing, Reasoning, and the Gods* (Z. Bahrani & M. Van De Mieroop, Trans.). University of Chicago Press.

Bottéro, J. (2001). *Religion in Ancient Mesopotamia* (T. L. Fagan, Trans.). University of Chicago Press.

Brunnermeier, M. et al. (2009). The Fundamental Principles of Financial Regulation. *Geneva Reports 11*. CEPR.

Brunnermeier, M. K. & Oehmke, M. (2013). Bubbles, Financial Crises, and Systemic Risk. *Handbook of the Economics of Finance*, 2. https://doi.org/10.1016/B978-0-444-59406-8.00018-4

Buyl, M., et al. (2026). Large Language Models Reflect the Ideology of Their Creators. *npj Artificial Intelligence*, 2, 7. https://doi.org/10.1038/s44387-025-00048-0

Caesar, J. *Commentarii de Bello Gallico*.

Campbell, D. T. (1976/1979). Assessing the Impact of Planned Social Change. *Occasional Paper Series*, 8, Dartmouth College (1976); 后发表于 *Evaluation and Program Planning*, 2(1) (1979). https://doi.org/10.1016/0149-7189(79)90048-X

Casper, S. et al. (2023). Open Problems and Fundamental Limitations of Reinforcement Learning from Human Feedback. *Transactions on Machine Learning Research*. https://openreview.net/forum?id=bx24KpJ4Eb ; arXiv 版本: https://arxiv.org/abs/2307.15217

Cecchetti, S. G. & Kharroubi, E. (2015). Why Does Financial Sector Growth Crowd Out Real Economic Growth? *BIS Working Papers* No. 490, February 2015. https://www.bis.org/publ/work490.htm

Chase, D. Z. & Chase, A. F. (2006). Framing the Maya Collapse: Continuity, Discontinuity, Method, and Practice in the Classic to Postclassic Southern Maya Lowlands. In G. M. Schwartz & J. J. Nichols (Eds.), *After Collapse: The Regeneration of Complex Societies*. Tucson: University of Arizona Press.

Cicero, M. T. (1923). *De Divinatione*. W. A. Falconer, Trans. Loeb Classical Library 154, I.90. https://doi.org/10.4159/DLCL.marcus_tullius_cicero-de_divinatione.1923

Clagett, M. (1995). *Ancient Egyptian Science: A Source Book, Volume Two: Calendars, Clocks, and Astronomy*. Memoirs of the American Philosophical Society, 214. American Philosophical Society.

Cornelli, G., et al. (2023). Crypto Shocks and Retail Losses. *BIS Bulletin* No. 69, 20 February 2023. https://www.bis.org/publ/bisbull69.htm

Cottier, B., et al. (2024). The Rising Costs of Training Frontier AI Models. arXiv:2405.21015v2, revised 7 February 2025. https://arxiv.org/abs/2405.21015v2 [预印本，尚未经同行评审]

Covington, P., Adams, J. & Sargin, E. (2016). Deep Neural Networks for YouTube Recommendations. In *Proceedings of the 10th ACM Conference on Recommender Systems* (RecSys '16). ACM. https://doi.org/10.1145/2959100.2959190

Crotty, J. (2009). Structural Causes of the Global Financial Crisis. *Cambridge Journal of Economics*, 33(4). https://doi.org/10.1093/cje/bep023

Danielsson, J. & Shin, H. S. (2003). Endogenous Risk. In *Modern Risk Management*. Risk Books.

Danielsson, J., Shin, H. S. & Zigrand, J.-P. (2012). Procyclical Leverage and Endogenous Risk. Mimeo, LSE. [工作论文，未正式出版]

Dang, T. V., Gorton, G. & Holmström, B. (2020). Ignorance, Debt and Financial Crises. Working paper, Columbia/Yale/MIT. [工作论文，未正式出版]

DeepSeek-AI (2024). DeepSeek-V3 Technical Report. arXiv. https://doi.org/10.48550/arXiv.2412.19437 [预印本，尚未经同行评审]

Doctor, J. N., Wakker, P. P. & Wang, T. V. (2020). Economists' Views on the Ergodicity Problem. *Nature Physics*, 16(12). https://doi.org/10.1038/s41567-020-01106-x [Matters Arising；同行评审反驳 Peters (2019)]

Dumont, L. (1966). *Homo Hierarchicus: Essai sur le système des castes*. Gallimard. 英译本：University of Chicago Press, 1980. 中译本：路易·杜蒙著，王志明译，《阶序人：卡斯特体系及其衍生现象》，杭州：浙江大学出版社，2017。

Eisenstadt, S. N. (1982). The Axial Age: The Emergence of Transcendental Visions and the Rise of Clerics. *European Journal of Sociology*, 23(2). https://doi.org/10.1017/S0003975600003908

Eisenstadt, S. N. (Ed.) (1986). *The Origins and Diversity of Axial Age Civilizations*. SUNY Press.

Evans, J. (1998). *The History and Practice of Ancient Astronomy*. Oxford University Press.

Fouliard, J., Howell, M. & Rey, H. (2021). Answering the Queen: Machine Learning and Financial Crises. *BIS Working Papers* No. 926, February 2021. https://www.bis.org/publ/work926.htm

Gande, A. & Lewis, C. M. (2009). Shareholder-Initiated Class Action Lawsuits: Shareholder Wealth Effects and Industry Spillovers. *Journal of Financial and Quantitative Analysis*, 44(4). https://doi.org/10.1017/S0022109009990202

Goodhart, C. A. E. (1975/1984). Problems of Monetary Management: The U.K. Experience. In *Papers in Monetary Economics*, Vol. I, Reserve Bank of Australia (1975); 后发表于 *Monetary Theory and Practice* (1984).

Harrison, S. (2019). The Internet's Dizzying Citogenesis Problem. *Slate*, March 7, 2019. https://slate.com/technology/2019/03/wikipedia-citogenesis-circular-reporting-problem.html

Holmström, B. (2015). Understanding the Role of Debt in the Financial System. *BIS Working Papers* No. 479. https://www.bis.org/publ/work479.htm

Hoskin, M. (2003). *The History of Astronomy: A Very Short Introduction*. Oxford University Press.

Hubinger, E. et al. (2019). Risks from Learned Optimization in Advanced Machine Learning Systems. *arXiv:1906.01820*. https://arxiv.org/abs/1906.01820 [预印本，尚未经同行评审]

Knight, F. H. (1921). *Risk, Uncertainty and Profit*. Boston: Houghton Mifflin. 中译本：奈特著，安佳译，《风险、不确定性与利润》，北京：商务印书馆，2006。

La Porta, R., et al. (2000). Investor Protection and Corporate Governance. *Journal of Financial Economics*, 58(1–2). https://doi.org/10.1016/S0304-405X(00)00065-9

Letellier, R. I. (2023). *The Bible and the Religions of Ancient Egypt, Mesopotamia and Greece*. Cambridge Scholars Publishing.

Levine, R. (2005). Finance and Growth: Theory and Evidence. In P. Aghion & S. Durlauf (Eds.), *Handbook of Economic Growth*, Vol. 1A, Ch. 12. Elsevier. https://doi.org/10.1016/S1574-0684(05)01012-9

Löffler, A. (2025). Notes on Ergodicity Economics. SSRN 5399717. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5399717 [工作论文，未正式出版]

MacKenzie, D. (2006). *An Engine, Not a Camera*. MIT Press.

Munroe, R. (2011). Citogenesis. *xkcd* #978, November 16, 2011. https://xkcd.com/978/

Nissinen, M., Seow, C. L. & Ritner, R. K. (2003). *Prophets and Prophecy in the Ancient Near East* (Writings from the Ancient World, Vol. 12). Society of Biblical Literature.

Nissinen, M. (2017). *Ancient Prophecy: Near Eastern, Biblical, and Greek Perspectives*. Oxford University Press.

Nolan, B. (2026). Google and Character.AI Agree to Settle Lawsuits Over Teen Suicides Linked to AI Chatbots. *Fortune*, January 8, 2026. https://fortune.com/2026/01/08/google-character-ai-settle-lawsuits-teenage-child-suicides-chatbots/

OpenAI (2025). Expanding on What We Missed with Sycophancy. OpenAI official blog. https://openai.com/index/expanding-on-sycophancy/ 查阅于 2026 年 10 月 5 日.

Oppenheim, A. L. (1964; rev. ed. 1977, completed by E. Reiner). *Ancient Mesopotamia: Portrait of a Dead Civilization*. University of Chicago Press.

Paredes, J. L. et al. (2026). AI Now Writes as Many Online Articles as Humans Do. *Graphite Research*. https://graphite.io/five-percent/ai-now-writes-as-many-online-articles-as-humans-do [企业研究博客；基于 Common Crawl 样本，按发表季度分别计算 Pangram、Copyleaks 与 GPTZero 三套检测器的估计并取平均，非同行评审]

Perez, E. et al. (2023). Discovering Language Model Behaviors with Model-Written Evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*. https://aclanthology.org/2023.findings-acl.847/

Perrow, C. (1984). *Normal Accidents: Living with High-Risk Technologies*. Basic Books.

Persaud, A. (2000). Sending the Herd off the Cliff Edge. *Journal of Risk Finance*, 2(1). https://doi.org/10.1108/eb022947

Peters, O. & Gell-Mann, M. (2016). Evaluating Gambles Using Dynamics. *Chaos*, 26(2), 023103. https://doi.org/10.1063/1.4940236

Peters, O. (2019). The Ergodicity Problem in Economics. *Nature Physics*, 15(12). [Perspective；同行评审反驳见 Doctor, Wakker & Wang, 2020] https://doi.org/10.1038/s41567-019-0732-0

Postone, M. (1993). *Time, Labor, and Social Domination: A Reinterpretation of Marx's Critical Theory*. Cambridge University Press.（中译本：莫伊舍·普殊同著，康凌译，《时间、劳动与社会统治：马克思的批判理论再阐释》，北京：北京大学出版社，2019）

Rajan, R. G. (2005). Has Financial Development Made the World Riskier? Federal Reserve Bank of Kansas City. https://www.kansascityfed.org/Jackson%20Hole/documents/3326/PDF-Rajan2005.pdf

Reinhart, C. M. & Rogoff, K. S. (2009). *This Time Is Different*. Princeton University Press.

Robinson, D. (2026). I Quit OpenAI Because Its Culture Is Broken. *The Atlantic*. https://www.theatlantic.com/technology/2026/10/openai-safety-team-resignation/688881/ 查阅于 2026 年 10 月 5 日.

Rochberg, F. (2004). *The Heavenly Writing: Divination, Horoscopy, and Astronomy in Mesopotamian Culture*. Cambridge University Press.

Schaeffer, R. et al. (2023). Are Emergent Abilities of Large Language Models a Mirage? *NeurIPS 2023*. https://arxiv.org/abs/2304.15004

Sharma, M. et al. (2024). Towards Understanding Sycophancy in Language Models. *ICLR 2024*. https://arxiv.org/abs/2310.13548

Shaw, I. (Ed.) (2000). *The Oxford History of Ancient Egypt*. Oxford University Press. (new pb ed. 2003)

Shleifer, A. & Vishny, R. W. (1997). The Limits of Arbitrage. *Journal of Finance*, 52(1). https://doi.org/10.1111/j.1540-6261.1997.tb03807.x

Shumailov, I. et al. (2024). AI Models Collapse When Trained on Recursively Generated Data. *Nature*, 631. https://doi.org/10.1038/s41586-024-07566-y

Soros, G. (1987). *The Alchemy of Finance*. Simon & Schuster.

Spennemann, D. H. R. (2025). "Delving into" the Quantification of AI-Generated Content on the Internet (Synthetic Data). *arXiv:2504.08755* [cs.IR], March 2025. https://arxiv.org/abs/2504.08755 [预印本，尚未经同行评审]

Stanford HAI (2026). *AI Index Report 2026*. Stanford University Human-Centered AI Institute, April 2026. https://hai.stanford.edu/ai-index/2026-ai-index-report

Taleb, N. N. (2012). *Antifragile: Things That Gain from Disorder*. Random House.

Taleb, N. N. & Sandis, C. (2014). The Skin in the Game Heuristic for Protection Against Tail Events. *Review of Behavioral Economics*, 1(1–2). https://doi.org/10.1561/105.00000006

Taleb, N. N. (2018). *Skin in the Game: Hidden Asymmetries in Daily Life*. Random House.（本章引文据中译《非对称风险》，载《塔勒布经济学五部曲》套装，中信出版社）

Toda, A. A. (2023). 'Ergodicity Economics' Is Pseudoscience. arXiv:2306.03275. https://arxiv.org/abs/2306.03275 [预印本，尚未经同行评审]

Van De Mieroop, M. (1997). The Ancient Mesopotamian City. Oxford University Press.（中译本：马克·范·德·米罗普著，李红燕译，《古代美索不达米亚城市》，北京：商务印书馆，2021）

van Dijk, J. (2000). The Amarna Period and the Later New Kingdom (c.1352–1069 BC). In I. Shaw (Ed.), *The Oxford History of Ancient Egypt*. Oxford University Press.

Wei, J. et al. (2022). Emergent Abilities of Large Language Models. *Transactions on Machine Learning Research*. https://arxiv.org/abs/2206.07682

Yu, H., Kim, D. & Kim, Y. (2026). Retrieval Collapses When AI Pollutes the Web. In *Proceedings of the ACM Web Conference 2026* (WWW '26). https://doi.org/10.1145/3774904.3792955