《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第八章：叙事杠杆率与叙事套利

摘要

本章展开宏观认知债务记账框架（MCAF）中的叙事杠杆率（$\Omega = \phi/\|L\|$），将其从第三章的分析变量展开为诊断工具。叙事杠杆率衡量叙事偏离其合法性基座的程度；当叙事杠杆率极高时，同一行为在不同叙事场景中的风险评估差异可能被利用为稳定的利润来源——本章将这一利用机制称为叙事套利。叙事套利的核心结构是“输入有风险、输出无风险”：风险在输入端客观存在，但在输出端叙事中被系统性地消除或隐藏。

本章首先给出叙事杠杆率和叙事套利的一般定义（§1–§2），分析叙事套利在人工智能（AI）生态系统中可见的三层运行结构（§3），以中国资管新规作为金融治理如何压缩叙事杠杆率的校准案例、论证通用 AI 服务中同类终结机制的**覆盖缺口**（§4），之后展开两条延伸论证（§5、§6），最后给出四条可操作路径（§7）并划定工具边界（§8）。两条延伸论证分别是：§5 将叙事杠杆率（Ω）的定向上升压力锚定于唐世平“人工变异-选择-遗传”（VSI）演化框架，回答“为什么这个方向在特定选择条件下获得竞争优势”；§6 在产品层、基础设施层、资本层三层可见的叙事套利之上引入**意识形态层叙事套利**——基于叙事载荷二阶导（ϕ''）的不可见性的“元层”套利，论证这一层的套利最难审计、在结构上最难压缩（其利润与持续时间是否超过其余三层，仍需跨层证据），并展开四层套利之间的耦合传导链分析。

正文之后的附录以 1933–2026 年美、欧、中三地金融广告规制近百年立法史为参照，建立四种治理范式（披露、反欺诈、禁诱导、产品结构约束）与 MCAF 变量的对应关系，从中提取 AI 治理可借鉴的制度工具（制度条件的谱系梳理，而非叙事杠杆率历史走势的测量——附录明确不以法规沿革推断其持续下降）——附录不改动正文论证，仅为正文的治理路径提供制度史底座。

关键词

叙事杠杆率（$\Omega = \phi/\|L\|$）；叙事套利；输入-输出不对称；影子债务（D_c^{shadow}）；伪小纤维；资管新规；意识形态层套利（叙事载荷二阶导 ϕ''）；VSI 演化框架；元叙事套利；赔付环；Andreessen-Amodei-Greenspan

三角；HHH 原则；四层耦合网格；金融广告规制史

---

§0 为什么需要这一章

第六章论证了映射函数垄断（π-垄断）的历史形态——从祭司到算法，掌握映射函数的少数行为体反复利用映射函数（π）的不对称分布获取权力。第七章展开了认知雷诺数（Re_c），给出了投射端与防御端竞赛的序数比较框架。但一个关键机制尚未获得独立展开：**当映射函数垄断被货币化时，发生了什么？**

叙事套利（narrative arbitrage）提供了答案的一条主线——利用同一**对象或行为**（产品、资产、技术、企业）在不同叙事场景中的风险评估差异，将风险从自身转移给他人，同时捕获收益。叙事套利不是框架的附属品，而是映射函数垄断的一种经济学引擎：本章考察其收益机制——垄断条件下叙事载荷（ϕ）与合法性基座（$\|L\|$）之间偏差的系统性维持和利用。理解这一机制需要叙事杠杆率（$\Omega = \phi/\|L\|$）——它衡量叙事偏离其合法性基座的程度，是认知雷诺数（Re_c）的一个独立因子（§1.4 将展示这一点）。

本章的结构是：§1–§2 建立叙事杠杆率与叙事套利的一般理论，适用于任何存在叙事载荷（ϕ）与影子债务（D_c^{shadow}，第三章 §4）的领域；§3 展示其在 AI 生态系统中**可被审计识别的三层运行结构**（产品层、基础设施层、资本层）；§4 以中国资管新规为校准案例，论证金融系统的终结机制在通用 AI 服务中的系统性缺失；§5 与 §6 展开两条延伸论证（其内容已见摘要）；§7 给出四条可操作的干预路径；§8 划定工具边界。

---

§1 叙事杠杆率（Ω）的定义

§1.1 类比：金融杠杆率

杠杆率是金融中最古老的风险度量之一：用多少自有资本撬动了多少总资产。杠杆率越高，收益放大越大，但崩溃时的损失也越大——因为支撑结构（自有资本）太薄，无法承受资产端的波动。

杠杆率的危险不仅在于资本的薄厚。Jensen（2005）论证了一种更隐蔽的杠杆形态：股权高估——当市场叙事赋予公司远超实际价值的估值时，管理层被迫用破坏性行为维持叙事。他将股权高估比喻为“组织或管理海洛因”（organizational or managerial heroin）：初始阶段令人愉悦——管理层上电视、受媒体关注、投资者青睐、期权增值、资本市场对公司敞开——但正如吸毒者的教训，巨大的痛苦就在前方（Jensen, 2005）。这正是叙事杠杆率要刻画的结构：不仅是“用多少自有资本撬动了多少资产”，而是“用多少合法性基座撬动了多少叙事驱动的行为”。

叙事杠杆率的直觉完全平行。一个叙事（“AI 是清洁技术”“土地不会跌”“理财产品不会亏”）撬动了多少行为——投资决策、政策取向、用户信赖——而支撑这个叙事的合法性基座（经验证据、法律框架、物理约束）有多厚？当叙事远超其合法性基座所能支撑的范围时，叙事杠杆率就是高的；当叙事被合法性基座充分支撑时，叙事杠杆率就是低的。本章将 Jensen 的股权高估代理成本重新解读为叙事杠杆率的一个场景映射实例——高估值叙事及其行为影响可在明确场景尺度下映射为叙事载荷（ϕ），可核经营业绩、法律程序与制度支撑可分别映射为合法性基座（$\|L\|$）的相应组成；这种映射不是把市场估值结果直接等同于变量本身。这一延伸解读的责任由本章承担。

§1.2 形式定义

$$\Omega = \frac{\phi}{\|L\|}$$

其中：- 叙事载荷（ϕ）——在第三章的叙事杠杆率（Ω）场景中，指投射方实际释放的叙事包装与信息不对称；在第七章认知雷诺数（Re_c）的完整形态场景中，则须按剥离部署规模后的单位输出叙事效应作场景映射。本章不把受众人数或部署规模计入叙事载荷（ϕ）：部署规模归解封存量（C），剥离规模后的到达效率归媒介传导系数（Λ）。- 合法性基座（$\|L\|$）——叙事获得的经验、程序和价值支持的具体构成（聚合方式沿用第三章），由绩效合法性（L_{perf}）、程序合法性（L_{proc}）和意识形态合法性（L_{ideo}）三个维度构成。合法性基座（$\|L\|$）越高，叙事有越充分的理由被信赖。

叙事杠杆率（Ω）的解读：- $\Omega \approx 1$：叙事影响与支持条件大致匹配。叙事所声称的与现实所支撑的基本一致。这是叙事的 "去杠杆" 状态——套利空间低；这不直接判断对象本身的风险或盈利水平。- $\Omega \gg 1$：叙事影响明显超过支持条件。叙事声称的远多于现实所支撑的。这是叙事的 "高杠杆" 状态——行为被更大程度地撬动，提示更高的审计优先级。- $\Omega \to \infty$：$\|L\| \to 0$，可核支持趋于零而叙事仍在驱动行为。形式比率在此发散——它表示叙事驱动的行为已脱离可核验的基础，但认定具体对象为泡沫还须结合该场景其他因子的取值。

以上区间是**概念性的**，用于标注叙事杠杆的结构位置，而非可精确计算的数值范围。在大多数经验场景中，叙事载荷（ϕ）和合法性基座（$\|L\|$）不可精确量化，但可进行序数比较（"A 的叙事杠杆率高于 B"）。还需两重限定：其一，$\Omega \approx 1$ 中数值 1 的参照意义，须由场景的尺度定义与归一化选择后才可成立（第三章 §5.1）；其二，序数比较（叙事载荷 ϕ 与合法性基座 $\|L\|$ 各自的高低排序）不自动等于比率的可比较性——一般的保序变换不保证保持比率的排序（恒等变换、统一比例缩放等特殊情形不改变排序）。本章在引用 "某叙事的杠杆率高于另一叙事" 时，指的是诊断性序数判断，不声称比率已获识别。

§1.3 叙事杠杆率（Ω）的动力学

叙事杠杆率（Ω）随叙事影响和支持条件的变化而变化；在 §2.3 所述反馈条件下，这种变化可能自我强化：

$$\frac{d\Omega}{dt} = \frac{\dot{\phi} \cdot \|L\| - \phi \cdot \|\dot{L}\|}{\|L\|^2}$$

（$\dot{\phi}$ 表示叙事载荷随时间的变化率，$\|\dot{L}\|$ 表示合法性基座随时间的变化率。）

需要就这一方程的地位做一点方法论声明：若在具体场景中将叙事载荷（ϕ）与合法性基座（$\|L\|$）映射为正实数可微函数，则按定义可写出上述商法则；本章尚未建立这种经验尺度，该式展示的是该假设下的方向关系，不提供经验增长率或相变阈值。该式因此不是经验上可求解的动力学方程——叙事载荷（ϕ）与合法性基座（$\|L\|$）在大多数场景中只能序数比较；序数定位依赖观察者的判断框架，本章不保证两位独立观察者做出同样的定位。本章使用该方程的价值不在量化预测，而在**给出叙事杠杆率上升的结构性表达**：当叙事载荷的增速系统性快于合法性基座的增速时（$\dot{\phi}/\phi > \|\dot{L}\|/\|L\|$），叙事杠杆率 Ω 上升。这一表达把 "叙事跑得比合法性快" 从散文翻译为可在文本中相互援引的结构标签，并不主张它取代了散文判断本身的负担。该式是一个可命名、可相互援引的结构标签，不是可预测相变时点或量化上升速率的计算工具。在叙事套利的典型周期中：- **扩张阶段**：$\dot{\phi} > 0$（叙事持续强化）且 $\|\dot{L}\| \leq 0$（合法性基座被侵蚀）——或更一般地，叙事载荷的相对增长率（$\dot{\phi}/\phi$）高于基座的相对增长率（$\|\dot{L}\|/\|L\|$）。

后者是叙事杠杆率 Ω 上升的完整条件；$\dot{\phi} > 0$ 与 $\|\dot{L}\| \leq 0$ 只是其中的充分情形之一。$d\Omega/dt > 0$，叙事杠杆率持续上升。- **稳定幻觉阶段**：叙事杠杆率（Ω）已经很高，但叙事仍然 “有效”——行为仍在被叙事驱动，损失尚未显现。这是影子债务（D_c^{shadow}）静默积累的阶段。系统内的参与者以叙事杠杆率（Ω）的当前值为 “正常”——因为回顾过去，叙事杠杆率（Ω）一直在上升且没有出事。- **相变阶段**：合法性基座（$\|L\|$）在某个事件冲击下骤降，叙事杠杆率（Ω）压力急剧上升；随后信任崩解、叙事崩溃，叙事载荷（ϕ）也可能随之回落——此前被遮蔽的影子债务（D_c^{shadow}）在这一过程中经显现函数（$M(\tau)$，第三章 §4）的相变集中显现为可观测认知债务（D_c^{obs}）。

这一动力学与金融杠杆的明斯基周期（Minsky cycle）在结构上类似（Minsky, 1986, 1992）——对冲融资 → 投机融资 → 庞氏融资的转变，对应叙事杠杆率（Ω）从合理水平到过度水平到纯泡沫的演进。差异在于：金融杠杆的 “支撑结构” 是资本金（可量化），叙事杠杆的 “支撑结构” 是合法性基座（多维且部分不可量化）。这使得叙事杠杆的崩溃更难预测——无法预知合法性基座（$\|L\|$）的哪个维度（绩效合法性 L_{perf}、程序合法性 L_{proc}、意识形态合法性 L_{ideo}）会先断裂。

相同类型的动力学在 Soros（1987/2003）的**反身性**（reflexivity）框架中以另一种语言被刻画——参与者的认知本身即是被观察情境的一部分，参与者的观点不对应于情境，情境又随他们的决定而改变，其结果是自我实现的反馈回路在超过某一点后变为自我毁灭（Soros, 2003, Introduction to the 2003 Edition）。叙事杠杆率（Ω）可以被理解为对反身性一个面向的比率化表达：反身性描述**感知与现实相互构成**的机制，叙事杠杆率 Ω 给出**其中叙事与合法性支撑之间偏离程度**的比率化度量——当叙事载荷远超合法性基座时，反身性就进入 Soros 所称的 “起初自我实现但终将自我毁灭”（initially self-fulfilling but eventually self-defeating）阶段（Soros, 2003）。

§1.4 叙事杠杆率（Ω）与认知雷诺数（Re_c）的关系

叙事杠杆率（Ω）不是独立于认知雷诺数（Re_c）的新变量；只有在叙事载荷（ϕ）的场景尺度已经统一或完成转换时，它才是认知雷诺数中由叙事载荷与合法性基座（$\|L\|$）共同构成、可单独考察的比率因子。第七章 §4 给出的完整形态是：

$$Re_c^{AI} = \frac{C \cdot \Lambda \cdot \phi}{A \cdot E_c \cdot \|L\|}$$

其中叙事载荷（ϕ）出现在分子、合法性基座（$\|L\|$）出现在分母，在第七章完整形态中，叙事载荷（ϕ）按单位输出叙事效应计量；只有该尺度与第三章叙事杠杆率（Ω）场景所用的叙事总量完成转换或被证明一致时，比值 $\phi/\|L\|$ 才可在该场景中称为叙事杠杆率（Ω），未经映射不作跨章恒等式。因此，在解封存量（C）、媒介传导系数（Λ）、元审计能力（A）与人的生物学底座（E_c）均保持不变时，叙事与合法性基座之间偏离的扩大会提高完整形态中的投射—防御压力；第七章明确完整形态不作物理量纲分析，也不把简化形态的层流 / 湍流分类外推到这里，故本章不再以 “湍流区间” 描述认知雷诺数（Re_c）的完整形态。这是叙事套利在 MCAF 框架中的结构性定位：它不是信息生态中的一个孤立现象，而是投射-防御竞赛中叙事维度的直接放大器。

但叙事杠杆率（Ω）与认知雷诺数（Re_c）的其他因子——解封存量（C）、媒介传导系数（Λ）、元审计能力（A）、人的生物学底座（E_c）——有一点根本结构差异是必须单独说明的——这也是本章需要独立展开而不能混在第七章中的原因。叙事杠杆率 Ω 的独立分析价值不在于它是唯一具有内生动力学的因子，而在于它把叙事载荷与合法性约束之间的相对变化单独提出——解封存量 C、媒介传导系数 Λ、元审计能力 A 同样可能内生变化并与叙事杠杆率 Ω 相互影响（第三章 §2.2；第七章 §4），其中围绕叙事

偏差的反馈链（§2.3）是本章独立展开的一条。自增强使叙事杠杆率（Ω）可能形成内生动态，并促使既有影子债务通过显现函数（$M(\tau)$）显现；是否构成相变以及相变何时发生，不由显现函数（$M(\tau)$）或本章模型预测。这使叙事杠杆率 Ω 从“认知雷诺数 Re_c 公式中的一个相除项”上升为独立的分析单元。

---

§2 叙事套利的一般结构

§2.1 定义

套利在金融中的定义是：利用同一或经济等价资产在可同时执行的交易中形成的价格偏差，在计入交易成本后锁定无风险或近似无风险的收益。叙事套利与它具有可比较的差价结构，但在风险承担、交易对象和自我消除机制上不同（§2.4 将展开）：

> **叙事套利**：利用同一对象或行为在不同叙事场景中的风险评估差异，将风险从自身转移给他人，同时捕获收益。

叙事套利最简洁的直觉是：**输入有风险，输出无风险。**风险在输入端客观存在（底层资产有信用风险、AI 输出有幻觉、基础设施有环境外部性），但在输出端叙事中被系统性地消除或隐藏（“理财产品不会亏”“AI 自主完成任务”“AI 是清洁技术”）。两端的风险描述不在同一时空出现——投资者在购买时面对输出端叙事，在受损时才面对输入端现实。Jensen 与 Meckling（1976）定义的代理成本三项分解——委托人监督支出、代理人保证支出和剩余损失——可被读作对这种 “输入—输出” 偏差修复成本和修复失败后残余伤害的度量；这一读法由本章作出，代理成本的外延不限于叙事偏差。叙事套利的重点是：这种偏差不是意外，而是被系统性地维持和利用。

关键特征：- **同一对象或行为**——套利者的行为不变，改变的是行为（或对象）被呈现的叙事框架。- **不同叙事场景**——同一行为在营销场景、法律场景、投资者关系场景中被赋予不同的风险描述。- **风险转移**——收益归套利者，风险归他人（用户、公众、纳税人、环境）。- **叙事差价**——套利利润来源于两个叙事之间的差距，正如金融套利利润来源于两个价格之间的差距。

§2.2 利润来源

本节中的 “利润” 泛指套利者通过叙事偏差捕获的**任何形式的收益**——包括但不限于会计利润、估值溢价、监管成本节约、用户增长、市场份额——只要该收益的获取依赖于叙事与事实的偏离。

叙事套利的利润来自三个因子的联合作用。第一，叙事载荷（ϕ）——叙事对判断和行动的塑造力度：叙事越强、越被信赖，套利者越能以叙事而非事实来驱动行为；叙事载荷高意味着更多人基于叙事而非独立判断做出决策。第二，媒介传导系数（Λ）——这种影响经传播渠道转化为行为的速度和范围：传导系数高意味着叙事快速触达大量受众且不需要受众的深度理解即可生效，社交媒体、算法推荐、AI 交互界面都是传导系数的放大器；二者可以相互影响，但在分析上分别对应影响强度与传导条件。第三，影子债务（D_c^{shadow}）——真实认知债务与可观测认知债务的差距（第三章 §4）；这是套利的 “本金”，差距越大，每一次基于叙事的行为所隐含的真实风险与被感知的风险之间的偏离越大，套利利润越高。三个因子之间是乘法关系——任何一个趋近于零，套利利润就趋近于零；三个同时处于高位时，套利利润呈联合放大。这一乘法式是对依赖风险不可见性获利的简化示意，不涵盖信息虽已公开、却仍因误导性呈现或认知偏差而获利的情形——后者的压缩还取决于信息是否可理解、可核验，以及受众是否具有据此调整行为的条件（§4.2、附录 §A5）。

§2.3 自增强回路

三个因子不是独立的——它们之间有正反馈：

$$\phi \uparrow \rightarrow \ \Lambda \uparrow \rightarrow \ D_c^{shadow} \uparrow \rightarrow \ \phi \uparrow$$

机制如下：1. 叙事载荷（ϕ）高使媒介传导系数（Λ）大——更多人相信叙事并参与（用户增长、投资流入），传导渠道扩展。2. 媒介传导系数（Λ）大使影子债务（D_c^{shadow}）增长更快——更多行为基于叙事做出，真实风险在更大规模上积累，但不被感知。3. 影子债务（D_c^{shadow}）增长使维持叙事载荷（ϕ）的动机更强——承认真实风险的代价越来越高（如果现在承认，积累的影子债务将集中显现），因此叙事偏离越来越大——不是“影子债务直接制造叙事”，而是“影子债务使维持叙事成为理性选择”。

这是一个典型的正反馈回路——叙事套利不是一次性的偶然获利，而是一个自增强的结构。该回路在叙事强化能够扩展传导、风险累积提高维持叙事的收益，且声誉、退出、内部纠错与责任追究不足以抵消上述作用时成立；条件不满足时，回路可能减弱或中断——打断可能来自外部（监管干预、市场崩溃、物理约束显现），也可能来自系统内部的退出、竞争性披露或主动重组。

Jensen（2005）用金融并购数据揭示了同一回路的具体运作：在 1998–2001 年间，收购方股东在并购公告日前后构成的三日事件窗口内合计损失约 2400 亿美元；损失集中于少量高估值公司的大型交易——Moeller 等识别出 87 笔损失逾 10 亿美元的大额交易，剔除这些交易后收购方股东整体并未受损（Moeller, Schlingemann & Stulz, 2005）。这里的损失是事件窗口中的股东财富变化，不等于企业已实现的经营亏损。安然市值巅峰 700 亿美元，Jensen 猜测其当时实际价值约 300 亿美元；管理层为维持 400 亿虚高估值，最终毁掉了 300 亿核心价值——这一案例说明，维持高估值叙事的行动可能反过来毁损其价值基础，形成叙事偏差与基础侵蚀相互强化的过程；它不构成对叙事杠杆率（Ω）数值或发散状态的直接测量。用本章术语重述 Jensen 的分析：**当叙事杠杆率（Ω）极高时，激励机制不仅无法解决问题，反而成为问题的一部分**——薪酬与股价挂钩使管理层的理性选择恰好是维持虚高叙事（Jensen, 2005）。

正反馈回路的**传播端动力学**在 Shiller（2019）《叙事经济学》中获得了进一步的经验研究支撑。Shiller 将经济叙事的扩散类比为疾病传染过程——传染率（contagion rate）与遗忘率（recovery rate）的相对大小决定叙事能否进入流行态，一旦传染率超过遗忘率，叙事就按经典的流行病学曲线在人群中传播并驱动行为（Shiller, 2019）。

他据此提出了“叙事经济学七命题”（Shiller, 2019）——其中与本章 $\phi \cdot \Lambda \cdot D_c^{shadow}$ 结构最直接相关的是：**叙事星座比任何单一叙事的影响更大**（命题 3）——在星座中同时传播的叙事来源各异，却在人们的想象中被归入某个共同观念、相互强化彼此的传染；Shiller 以天文学类比说明：星座只是恒星的偶然排列，图形是人的心智施加的解读——同理，大规模经济叙事往往由许多小叙事组成的星座构成，每个小叙事只讲出大故事的一部分，要看全整个星座才能辨认主题，单一叙事的作用因此有限；**真相不足以阻止虚假叙事**（命题 5）；**叙事靠情感依附——人性趣味、身份认同与爱国主义——而繁荣**（命题 7）——其病毒性依赖故事对人的抓力而非事实性。

Shiller 在第 3 章还区分了与星座不同的叙事**交汇**（confluence）——彼此并不被认为相关、却在同一时点产生同向经济效应的一组叙事——星座与交汇共同解释了为何重大经济事件很少能归结为单一叙事。与本章的分工是：Shiller 描述叙事“如何变得流行”——为叙事的传播动力学（叙事载荷 ϕ 得以扩散的条件）提供经验研究；本章描述叙事流行后与合法性基座（$\|L\|$）之间的偏离结构——给出叙事载荷（ϕ）相对于合法性基座（$\|L\|$）的比率结构；叙事载荷（ϕ）的塑造力度本身仍属序数判断。

§2.4 叙事套利与金融套利的结构性差异

金融套利的一个核心特征是**自我消除**——套利行为本身会消除套利机会（大量买入低价资产会推高其价格，大量卖出高价资产会压低其价格，价差收窄至零）。这是市场效率的微观基础。

叙事套利**不存在市场自发的自我消除机制**。原因有二：

第一，叙事没有可观测的 “价格” 供套利行为去收敛。金融资产有市场价格作为信号——价格偏差可被识别和利用。叙事没有对应的价格信号——“AI 是清洁技术” 这个叙事的 “真实价格” 是什么？没有一个市场在交易叙事的真伪，因此没有套利力量将叙事推向 “正确值”。

第二，叙事套利的利润可以被用来加固叙事本身。一家公司通过叙事套利获得的利润（高估值、低监管成本、用户增长）可以被再投资于强化叙事——更多营销、更多游说、更多让叙事自我实现的资源。金融套利的利润来自对既有价差的捕获，套利活动本身使价差收窄；叙事套利的利润可以被用来维持甚至扩大叙事差距。[1]

这一差异的含义是：**叙事套利不内含单纯价差套利那种由套利交易本身推动偏差收敛的机制，因此不能预期它必然被市场自发消除——退出、竞争性披露与价格重估仍可能在特定条件下压缩或终结它；但市场可以被制度性地改造以承担一部分校准功能。**金融市场的效率假说（部分地）适用于金融套利——市场力量可以压缩价差。没有对应的 “叙事效率假说” 自动产生——但**制度性地创造价格信号是可能的**：强制记账（使 $D_c^{obs} \to D_c^{true}$）即是为叙事套利人工创造价格信号——当真实信息被强制公开，叙事与事实的偏差变得可观测，叙事套利的利润空间被压缩。

投资者保护制度为叙事套利提供了一个更激进的校准案例。美国证券集体诉讼中的 “欺诈市场理论”（fraud-on-the-market theory）允许在符合适用条件时推定投资者依赖市场价格的完整性，从而减轻逐一证明直接信赖的负担；该推定可以被反驳，赔偿仍须满足其他责任要件（Basic Inc. v. Levinson, 1988; La Porta et al., 1998）。在 MCAF 框架的语言中，这**利用既有价格机制组织救济、并提供部分赔付通道**——影子债务可经集体诉讼追偿，但追偿范围仍受责任要件约束。§4.2 将论证，在通用信息服务领域，AI 目前两者均未成形——既没有将 “能力叙事偏差” 转化为可观测价格信号的机制，也没有将认知损害转化为可追偿赔付的制度通道。

§2.5 纤维框架介入：伪小纤维与叙事套利的认知微观机制

§2.3 的自增强回路回答了一个问题：为什么一旦进入叙事套利结构，套利受益者的理性选择就是继续维持它？但还有一个更深的问题尚未回答：为什么叙事套利能在**认知层面**持续生效？为什么在 “输入有风险、输出无风险” 的结构中，风险端的信号没有传递到受众的审计动机？§2.4 的 “价格信号缺失” 是对这一问题的制度层回答——没有外部机制强制受众更新信念。但制度层的空缺仍然允许两种不同的受众状态：一种是受众 “知道自己不知道”（承认不确定性存在、只是无法量化），另一种是受众 “以为自己知道”（不确定性在感知中消失了）。后一种状态尤其有利于套利利润稳定地流向一方，本节集中分析这一认知微观机制。

第四章 §2.4 的纤维框架给出这一问题的微观回答：与读数兼容的真实状态集合构成真实纤维（$F_{true} = \pi^{-1}(r)$），观测者基于可见子空间信息建构的对纤维大小的认知表征则是感知纤维（$F_{perceived}$）。当感知纤维能够恰当反映相关状态及其不确定性时，观察者较少低估未知范围。纤维分析在此刻画的

[1] Zuboff（2019）对 “监控资本主义” 的分析提供了这一机制的宏观实例：科技公司将从用户数据中提取的利润再投资于更精密的数据提取基础设施，形成 “数据提取 → 利润 → 更强的提取能力” 的正反馈。这一反馈展示了收益如何反过来强化既有获利条件；若要将其进一步判为叙事套利的叙事强化机制，还须识别这些收益如何被投入营销、合法化宣传或其他维持叙事偏差的活动。

是信息与认知的关系；风险程度还取决于相关状态的发生概率与后果，不能由纤维规模单独推出；当真实不确定性被压缩到观察者不可见的隐藏子空间、而感知纤维仍呈现出小的样子时，需要区分两种情况：真实不确定性确实很小且与感知相符——这是真小纤维；真实不确定性很大而感知被系统性地压小——这是**伪小纤维**。二者的外观相同，审计后果截然不同——真小纤维本身即是信息富集（不确定性少这一事实具有判断价值），而伪小纤维以确定性的外观屏蔽了审计的触发条件。

叙事套利能持续生效，核心在于它制造伪小纤维。伪小纤维不必依靠可逐项核查的虚假断言——它通常不在可观测维度上留下可指认的偏差；选择性呈现、信息隔离与稳定性外观同样能使受众低估真实不确定性，且可与直接说谎并存。叙事套利的独特性是：叙事在可观测维度上表现得一切正常，而真实偏差被推入了隐藏子空间。资管新规前的理财产品是完美案例：摊余成本法让净值看起来极其稳定（感知纤维 $F_{perceived}$ 很小——无波动、无亏损、无风险），底层资产的真实风险（真实纤维 F_{true} 很大——期限错配、信用下沉、杠杆嵌套）对投资者不可见。“看起来确定” 消灭了投资者启动审计的动机——当感知纤维已经呈现为小的样子时，观察者缺乏追问 “还有什么我没看到的” 的动机。伪小纤维的独特危害正在于此：在这一机制下，它系统性地使审计的触发条件与审计的必要性反向关联——越需要审计的时刻，审计越不会被启动。

这为 §2.2 所述的套利利润结构（$\pi_{narr} \propto \phi \cdot \Lambda \cdot D_c^{shadow}$）补充了一层认知微观机制。影子债务 $D_c^{shadow} = D_c^{true} - D_c^{obs}$ 在宏观记账语言中是 “真实与可观测之间的差距”，与纤维语言中 “真实不确定性与被压小的感知之间的脱节” 存在解释性对应——但本章不将二者定义为可直接相减或投影的数学对象（第四章 §2.4 明确：感知纤维是观测者建构的认知表征，不是另一个逆像集合）。超额利润的来源因此不是叙事本身的强度，而是伪小纤维压缩了风险感知——投资者承担真实纤维（F_{true}）对应的风险，却只按感知纤维（$F_{perceived}$）所呈现的低风险要求收益与保障；发行方因此节省了本应支付的风险补偿。叙事载荷 ϕ 的作用由此可以更精确地重新描述：在本节分析的机制中，它不必直接传递虚假内容（直接传递虚假内容则产生可指认的偏差，更易成为审计与追责的对象），而可以通过塑造感知纤维的形状——让某个维度看起来稳定、完整、可解释——来抑制审计的启动。

这一接口同时前指 §6 将要展开的意识形态层叙事套利。前三层的伪小纤维运行在 “感知纤维 $F_{perceived}$ 与真实纤维 F_{true} 的结构性脱节”——观察者感知到了，只是感知到的和真实的不一样。意识形态层的伪小纤维运行在更深的层次——观察者不知道自己在以某个特定的框架感知，叙事载荷二阶导 ϕ'' 的不可见性恰好是感知纤维与感知本身之间的元层不对称。§6.5 所指的 “结构性真空在元层的投影” 在纤维语言中可以这样描述：当用户甚至没有概念去质疑 “我看到的是不是全部” 时，伪小纤维不再是某一个局部的修饰，而是观察本身的默认配置。这解释了为什么 §6.5 认为意识形态层的套利在结构上最难压缩：它的伪小纤维不仅压缩了具体风险的感知，更压缩了 “原来这是一种感知” 这种元认知本身。

本节不拓展形式化定义——与感知纤维 / 真实纤维（$F_{perceived}/F_{true}$）相关的完整论证、纤维之间的维度和复合关系、伪小纤维与真小纤维的边界诊断条件，留在第四章 §2.4。本节只说明两套分析的对应关系：以伪小纤维为中介，叙事套利的宏观结构（利润公式、自增强回路、终结机制）与认知微观机制（感知纤维的形状压缩）可放在同一分析框架中考察。

§2.6 伪小纤维的跨产业工程化

上述实例大部分来自金融行业，但伪小纤维不是金融特有的病理。娱乐工业和金融交易行业各自提供了一条独立的平行谱系。

Engelstein（2020）在 MIT Press “Playful Thinking” 丛书出版的 *Achievement Relocked: Loss Aversion and Game Design* 中，系统地将前景理论翻译为游戏设计的工程语言：禀赋效应被用于使玩家高估虚拟资产，

沉没成本谬误被用于保障玩家不理性地继续投入，后悔厌恶被用于减轻玩家在不可逆选择节点感知到的压力，使其低估选择的不可逆性。Engelstein 写道，设计师可以“微妙地（有时不那么微妙地）操纵玩家体验”（Engelstein, 2020）。这与伪小纤维机制同构：设计师不需要在可观测维度上说谎（每项资产的数值都是真实的），只需重新设置框定、信息与奖励的呈现顺序与默认值，即可使玩家的感知纤维 $F_{perceived}$（对成就价值与获取概率的感知）与真实纤维 F_{true}（取得、维持与失去该成就的真实成本和概率）系统性地脱节——虚拟成就可以具有真实的情感与社会价值；这里要审查的不是玩家为何重视它，而是界面设计是否使玩家误判其成本与概率。

更关键的是：该书以 GameTek 播客十多年累积的一线设计案例为材料，针对的读者是游戏设计师而非心理学家——当一种认知操纵方法写进面向一线设计者的实践著作，说明它已移出论文实验室、进入设计者社群的常规工具箱；至于其在行业中的应用广度与效果，需另行取证。

Steenbarger（2015）转述了 Park 及同事对韩国投资者网络留言板参与的研究：确认偏差较强的交易者同时表现出更强的过度自信，倾向于更频繁交易，也亏损更多（Steenbarger, 2015）。这是感知纤维 $F_{perceived}$ 持续稳定、真实纤维 F_{true} 随仓位累积而扩张的典型动力学——回撤来临前，脱节对交易者本人不可见。

娱乐工业（框定工程）、金融产品（摊余成本法 + 嵌套）与金融交易（确认偏差 + 过度自信）三条并行谱系**例示**伪小纤维的跨产业存在——不是作为“任何产业必然收敛”这一强论断的证据，而是作为“多个独立产业各自演化出同构的认知压缩工程”这一弱观察的支撑。更强的“通用工程解”命题需要更系统的跨产业普查支撑，本节不主张已经完成这一工作。这一例示同时解释了 §4 的终结操作为什么刚好瞄准伪小纤维的节点：资管新规的四条核心操作不是在压制叙事，而是在强制感知纤维 $F_{perceived}$ 向真实纤维 F_{true} 趋近——打破刚兑使底层损失不再被确定性外观屏蔽，穿透式监管撕开嵌套产生的可见子空间假象，禁止资金池阻断隐藏通道，净值化管理直接让感知纤维 $F_{perceived}$ 随底层市值波动。纤维框架和 MCAF 家族是建立在相同的映射与信息约束条件（映射函数、隐藏子空间、审计触发条件）上的两种语言，而非第二套评价维度。

（§2 到此完成叙事套利一般结构的论证：定义、利润来源、自增强回路、与金融套利的结构性差异、以及伪小纤维作为认知微观机制的对应关系说明。关于“为什么叙事杠杆率会被系统性选中并持续上升”这一演化动力学的追溯，转至 §5 延伸论证一展开。）

---

§3 叙事套利的三层可见结构

叙事套利不是单一维度的——在 AI 生态系统中，它至少在四个层面同时运行，各层之间通过叙事载荷（ϕ）与叙事载荷二阶导（ϕ''）的传导相互支撑。本节展开其中**可被审计识别的前三层**——产品层、基础设施层、资本层。这三层具有较明确的审计对象：营销承诺、合同责任、资源消耗、融资条件和经营数据等——其叙事载荷（ϕ）可被指认、其合法性基座（$\|L\|$）可被分别审查、其影子债务（D_c^{shadow}）可经强制记账显现；相关证据可支持对叙事偏差的判断，但不意味着叙事载荷与合法性基座已能被统一量化。资本层的核心机制——股权高估的代理成本——已在 §1.1 与 §2.3 通过 Jensen（2005）展开，此处仅做简述。第四层——意识形态层叙事套利——在审计方法上与前三层根本不同：其机制本身就是“使叙事不呈现为叙事”，其利润来自叙事载荷二阶导（ϕ''）的不可见性而非可见叙事的偏差。这一根本差异使意识形态层不适合与前三层在同一节内并列处理——它需要独立的分析工具（§6.1–§6.4 的四种子机制）和独立的套利结构定义（§6.5），与四层之间的耦合传导链一并转至 §6 集中展开。

§3.1 产品层叙事套利

以下引导句是机制分析用的典型化表述，不是对特定企业宣传原文的逐字引用。

输出端叙事："AI Agent 自主完成复杂任务。" **输入端现实**：AI 输出不可预测，存在幻觉、偏见、系统性失误。**合同端叙事**："AI 输出仅供参考，用户需自行验证，用户对输出内容的任何依赖均属自担风险，应在依据任何输出内容采取行动前自行作出判断；对于因依赖输出内容而作出的任何决策、行为或不作为，应承担全部责任。"

套利结构：营销端鼓励用户信赖 AI 的自主判断（$\phi\uparrow$），法律端否认用户应当信赖 AI 的自主判断（公司试图通过合同将可合同化的损失与修复成本转嫁给用户；真实认知债务（D_c^{true}）是否变化、损失由谁实际承担以及责任能否执行，应分别记账）。两个叙事从不同时出现在同一个认知框架中——用户在购买时面对营销端叙事，在受损时面对法律端叙事。

这一矛盾不是个别公司的策略失误——它是激励结构的结构性产物。当赔付环（compensation loop）缺失时，在免责条款可执行、声誉与竞争约束较弱的条件下，公司的理性选择是通过合同条款把尽可能多的损失风险转嫁给用户。当损失风险主要由用户承担时，公司有强烈的动机使用户不意识到自己在承担损失——因此营销端的叙事载荷（ϕ）与法律端的责任分配之间出现系统性背离。在这样的条件下，双重话术可能成为稳定策略——没有公司有单方面偏离的动机。

§3.2 基础设施层叙事套利

输出端叙事："AI 是清洁的数字技术，提高效率、减少浪费。" **输入端现实**：以 GPT-3 为例，不同研究分别估算其训练耗电约 1,287 兆瓦时、排放约 552 吨二氧化碳当量，总耗水约 540 万升（其中现场耗水约 70 万升）；这些估计依赖模型规模、硬件、部署地点与核算边界（Li et al., 2025; Patterson et al., 2021），不能概括为每次 AI 训练的固定消耗。

套利利润：若 "清洁、高效" 的形象帮助企业降低环境成本承担、合规支出或融资成本，而相关外部性并未进入这些决策，则构成基础设施层叙事套利的候选机制——AI 公司由此获得 "科技公司" 而非 "重工业" 的估值倍数和监管待遇。套利成本：含水层损耗、碳排放、电子废弃物由公共环境承担。

电力使用效率（Power Usage Effectiveness，PUE）和碳强度等**相对指标**是这一层叙事套利的关键工具——它们允许企业声称 "越来越高效"（叙事端），同时绝对消耗持续增长（现实端）。一个 PUE 从 1.4 降到 1.2 的数据中心可以被描述为 "更绿色"，即使其总电力消耗因规模扩张成倍增长。事实上，Uptime Institute（2024）的调查显示，行业平均 PUE 在 2024 年为 1.56，并已连续第五年大体持平；但该平均值掩盖了新建大型设施的效率进步，因此它支持的是 "行业平均 PUE 指标停滞"，而不是 "行业整体效率停滞"。与此同时，WEF（2025）援引的一项情景估计预计，若预测增长持续，数据中心相关用电占全球电力需求的比重可能由约 1% 升至 2030 年的约 3%；该估计不代表已经观察到的固定轨迹，且报告同时提示不同估算及效率改进的抵消作用存在不确定性。（需要明确：PUE 和碳强度本身是有价值的工程指标，问题不在于它们被使用，而在于**它们被单独使用**——当相对指标的改善被呈现为绝对影响的减少时，叙事偏差就发生了。）相对指标的叙事载荷（ϕ）功能是：将注意力锁定在效率改善的叙事上，使绝对增长的事实从认知图景中消退。

§3.3 资本层叙事套利

输出端叙事："AI 是下一个万亿美元市场，先发者通吃。" **输入端现实**：技术路线不确定、监管环境不确定、商业模式大多未经验证、基础设施投资的沉没成本巨大。

套利利润：当融资叙事将尚未验证的技术与商业前景呈现为高度确定的收益、并以此获得估值溢价时，AI 公司的融资即进入本层叙事套利结构。套利成本：当增长叙事与现实脱节时，资本损失由投资者承担。

Jensen（2005）将这一结构称为“股权高估的代理成本”：高估不是免费的午餐，而是一条升级链——股价高估 → 管理层为维持表象做价值破坏性收购 → 被迫操纵盈利 → 最终诉诸会计欺诈。北电网络 1997–2001 年以超过 330 亿美元收购 19 家公司，股价暴跌后关停了其中大多数被收购企业的业务；Jensen 按 2001 年美元、经资本成本调整估算，该期股东损失约 445 亿美元。这一升级链条在案例层面与叙事杠杆率（Ω）从高位向更高位的自增强过程同构——每一步 “维持叙事” 的操作都进一步侵蚀合法性基座（$\|L\|$），使叙事杠杆率（Ω）更高、退出成本更大（Jensen, 2005）。

（意识形态层叙事套利与四层耦合结构转至 §6 延伸论证二展开。）

---

§4 叙事套利的终结机制

> “why had nobody noticed that the credit crunch was on its way?” “为什么没有人注意到信贷危机正在逼近？” ——Queen Elizabeth II，访问伦敦政治经济学院（LSE），2008 年 11 月（Besley & Hennessy, 2009）

本节沿两条维度对齐叙事套利的四层结构。一是**制度维度**——§4.1 刻画金融系统中的天然终结者，§4.2 逐条诊断 AI 领域对应制度的三重缺失（赔付环与价格信号、“数据作为支付” 的法律认定、权利集合）；三重缺失横切四层套利（§4.2 末有专门说明），以下分别指出三重缺失的主要作用层（前两层由 §3 展开，意识形态层的结构性机制延至 §6 延伸论证二集中讨论，此处先在制度对照层面引入其空缺）。二是**损害维度**——§4.2 末尾的三层累积性损害（物理层、人力资本层、认知多样性与社会信任层）**横切**全部四层套利，说明 AI 叙事套利即使在制度层面被完整终结，其受损维度上积累的伤害也难以逆转。两条维度共同构成 AI 叙事套利比金融叙事套利更难终结的结构性约束。

§4.1 金融系统中的天然终结者

金融系统有内生的叙事套利终结机制——**市场价格**。市场价格可以成为金融叙事的校准信号，但也可能在扩张阶段参与叙事强化（§1.3）；其校准作用经由追加保证金、强制平仓与清算在价格下跌时被强制触发——依赖交易、披露与责任制度，而非价格存在本身。当资产价格跌破阈值时，追加保证金和强制平仓将影子债务（D_c^{shadow}）强制显现，叙事套利空间被市场力量大幅压缩——无法在资产价格归零后继续声称 “这是安全投资”。

金融监管——从联邦存款保险公司（FDIC）到《多德-弗兰克法案》（Dodd-Frank）到中国资管新规——其工具箱在叙事套利框架下可作一个统一刻画：其中相当一部分工具——强制披露、净值化、交易透明——的功能可被统一描述为**压缩 $D_c^{true} - D_c^{obs}$ 的空间，使叙事套利无利可图**；另一些工具（存款保险、损失吸收安排）则作用于损失转移和分担，不直接压缩真实认知债务与可观测认知债务之差（$D_c^{true} - D_c^{obs}$）；其是否压缩 “不会亏” 叙事的套利空间，取决于保障限额、风险定价、监督与道德风险约束。若缺少这些条件，保障反而可能强化受保存款 “不会亏” 的预期，并把风险转移给保险人或公众。当影子债务被强制显现（$D_c^{obs} \to D_c^{true}$），依赖风险不可见性的套利利润空间被压缩——其彻底消除还取决于信息是否可理解、可核验，以及受众是否具有据此调整行为的条件。

Jensen（1993）识别的公司治理四类控制力量——（1）由董事会领导的**内部控制系统**；（2）**资本市场**

（公司控制权市场）；（3）**政治/监管体系**；（4）**产品和要素市场**——可被映射为叙事套利的终结机制。**本章认为**，四种力量中任何一种的有效运作都可以部分压缩叙事杠杆率（Ω）；当四种力量同时被激活时，压缩效果可能相互强化（这一对应是功能对照：净值化形成的市场定价约束并不等同于 Jensen 所讨论的公司控制权市场）——这一映射与判断由本章作出，责任由本章承担。中国资管新规（2018）提供了四种力量联合运作的一个制度设计的机制对照案例。

资管新规校准案例。资管新规的政策序曲是时任中国银监会主席郭树清 2017 年 3 月 2 日履新后首场国新办新闻发布会上的讲话。郭树清以 “牛栏里关猫” 为喻直接诊断了影子银行的叙事套利结构：“当前，部分交叉金融产品跨市场层层嵌套，底层资产看不见底，最终流向无人知晓。这种现象的产生，很大程度上是源于监管制度缺失。‘牛栏里关猫’，没有完善健全的监管制度，银行业务经营就必然会引发严重的风险暴露”（郭树清, 2017）。

“底层资产看不见底” 正是 §2.5 伪小纤维在本土监管语言中的直喻——感知纤维（$F_{perceived}$）呈现为稳定的净值波形，真实纤维（F_{true}）中嵌套的期限错配、信用下沉、杠杆连锁对投资者不可见。郭树清在同一场发布会的答问环节说 “我们正在研究一个共同的监管办法”，办法要 “把它先统一起来，标准不是特别高”，目标是 “使得所谓 ‘影子银行’ 去掉 ‘影子’”（郭树清, 2017）——这正是次年 4 月以银发〔2018〕106 号落地的《关于规范金融机构资产管理业务的指导意见》的制度轮廓。

2018 年之前，中国影子银行体系构成了教科书级的 “输入有风险、输出无风险” 结构（Allen et al., 2019; Ehlers, Kong & Zhu, 2018）。在输出端，投资者面对的是预期收益率展示与隐性保本预期——部分银行理财产品因此被理解为 “不会亏损”。在输入端，底层资产是非标准化债权、房地产开发贷、地方政府融资平台贷款，期限错配严重，信用风险显著。多层嵌套结构（银行 → 信托 → 资管 → 底层资产）进一步隔离了投资者与底层风险之间的信息通道——每一层嵌套增加一层叙事屏障。在预期收益型产品为主的阶段，资金池资产一般采用摊余成本法估值（叶美林、陈天翔, 2023；冯方, 2022），使底层资产波动不易被投资者观察；这不是说所有产品一律不使用市值计价，而是说相关估值安排削弱了净值波动所能提供的价格信号：在摊余成本法下，即使底层资产实际市值已显著偏离面值，投资者看到的净值仍然稳定——叙事不被任何可观测的变量挑战。

用 MCAF 框架的语言：叙事载荷（ϕ）= “理财产品不会亏” 的集体信念；投资者的信赖部分来自银行信誉、既往兑付记录与救助预期。这些支持不同于可依法执行的保本承诺，其强度取决于机构承受能力与制度条件；将它们等同于无条件保证，会高估支持基础——投资者可能因此低估叙事杠杆压力（叙事杠杆率（Ω）的实际值高于其表面感知）。影子债务（D_c^{shadow}）在自增强回路中持续累积：投资者基于 “不会亏” 的预期买入 → 资金涌入使理财规模膨胀 → 规模越大银行越不敢打破刚兑（打破的代价随规模上升）→ 不打破刚兑强化了 “不会亏” 的预期。到 2016 年，中国影子储蓄工具规模已达 GDP 的约 71%（Ehlers, Kong & Zhu, 2018）。

资管新规的四条核心操作在 MCAF 框架中有精确的翻译。第一，**打破刚性兑付**：“金融机构开展资产管理业务时不得承诺保本保收益。出现兑付困难时，金融机构不得以任何形式垫资兑付”（银发〔2018〕106 号第二条）——这是使亏损进入可观测集合，即可观测认知债务（D_c^{obs}）的边界被制度性扩张；打破刚兑并不创造亏损的可能性，而是限制机构以保本承诺或垫资兑付遮蔽投资风险，使市场损失能够按产品合同与责任规则由相应主体承担，叙事载荷（ϕ）被制度性压低。第二，**穿透式监管**——106 号文第 27 条要求 “实行穿透式监管，对于多层嵌套资产管理产品，向上识别产品的最终投资者，向下识别产品的底层资产（公募证券投资基金除外）”，第 22 条并禁止为其他金融机构的资产管理产品提供规避投资范围、杠杆约束等监管要求的通道服务——穿透叙事屏障的嵌套层，使底层真实认知债务（D_c^{true}）对监管机关可见；投资者能够获得哪些底层信息，取决于具体的信息披露义务。第三，**禁止资**

金池——要求每只产品单独管理、单独建账、单独核算，阻断跨产品滚动转移风险的传导通道。第四，**净值化管理**——以真实、公允反映收益和风险为要求，鼓励市值计量、对符合条件的摊余成本计量施加约束——**为叙事创造价格信号。**

§2.4 论证了叙事套利不自我消除，原因之一是 “叙事没有可观测的价格”。净值化恰好是为金融叙事人工创造价格信号的制度实验：当净值随市值波动时，“理财产品不会亏” 的叙事立即与可观测的事实碰撞（净值化抬高的不是 “产品不会亏” 这一旧叙事的可信度——恰恰相反——而是程序合法性（L_{proc}，第三章 §2.6）：亏损进入可观测集合这一程序事实，按框架的类型维度属于基座的组成部分）。

按本章的映射，四条操作与 Jensen（1993）识别的控制力量形成对照：打破刚兑与穿透式监管激活了政治/监管力量；净值化管理引入了市场价格信号（其约束机制与 Jensen 的公司控制权市场不同但方向相容）；“卖者尽责、买者自负” 重构了内部控制的激励结构；净值波动进一步传导到产品市场的竞争淘汰——四类操作与四类力量形成多功能对照，多种约束可能相互强化。资管新规的制度设计不是单一操作的结果——**本章认为**它构成多种约束同时被激活、可能相互强化的制度组合。[2]

回到 §1.3 的动力学方程 $d\Omega/dt = (\dot{\phi} \cdot \|L\| - \phi \cdot \|\dot{L}\|)/\|L\|^2$：资管新规的四条操作可以被读为对方程两个变量的分别反转。打破刚兑从叙事端压叙事载荷变化率 $\dot{\phi}$（“不会亏” 的集体信念不能再由机构背书）；穿透式监管与净值化管理从基座端抬 $\|\dot{L}\|$（使合法性从隐性担保的叙事性支撑转为可观测净值与可追踪底层资产的制度性支撑）；禁止资金池则作用于滚动发行所依赖的传导条件（Λ），阻断跨产品滚动转移风险的通道。由此，本节从两个方程变量与一条传导机制三个分析维度给出设计意图层面的方向性对应：叙事载荷（ϕ）端、合法性基座（$\|L\|$）端与媒介传导系数（Λ）端；这里的 “三个维度” 不表示三者相互独立，实施效果仍须分别验证。从制度设计看，这些规则旨在压低 “不会亏” 的叙事供给、抬高投资者对产品风险的核验条件；实施后信念实际改变了多少，需要独立证据，本节不以规则文本代替效果评估。

在第七章 §5 定义的共生-寄生连续谱中，资管新规之前的影子银行处于寄生态——媒介传导系数（Λ）的控制权完全在投射方，嵌套结构隔离了投资者与底层风险之间的信息通道，宿主（投资者）对映射函数的审计能力被系统性剥夺。资管新规的四条操作本质上是一次制度性的回拉：将媒介传导系数（Λ）的控制权部分交还给宿主（净值波动使投资者能自行判断风险），将映射函数从不可见变为可见（穿透嵌套），重新划分了投资风险与机构责任——机构尽责情况下的市场损失，与违法违规或管理不当造成的损失，不再被无差别纳入兑付预期，后者仍须依法承担赔偿责任。这不是从寄生到共生的完成，而是方向性的转折——制度力量强制压缩了寄生的利润空间，为可能的共生创造了条件。但持续的共生状态需要持续的监管维护——投资者保护不是一次性的制度建设，而是寄生压力始终存在条件下对共生均衡的持续守护。

此外，**保险市场**是另一个天然校准器。保险公司为了精确定价而深入评估被保险对象的风险——汽车保险推动了汽车安全标准，火灾保险推动了建筑防火规范，医疗责任保险推动了临床操作标准化。保险精算将真实风险信息注入市场定价，压缩了叙事与事实的偏差。

预制菜治理文件（2026 年 2 月征求意见）展现了同一结构在食品安全领域的镜像。“输入有风险”——工业化预加工可能添加过量调味料掩盖原料品质，防腐剂和添加剂不透明；“输出无风险”——消费者以为是餐厅现做菜。2026 年 2 月国务院食安办等部门就三份文件公开征求意见，其中与资管新规同构的操作有三条：禁止防腐剂（国家标准征求意见稿拟议条款，≈产品结构约束——拟以冷冻、冷藏、高温杀

[2]需要承认：资管新规的制度设计直接针对刚兑、资金池、嵌套和估值不透明等问题，但部分影子银行活动可能向信托、证券资管等其他通道转移，其实际效果需实施后的独立数据评估。本章取其**制度设计的结构逻辑**作为校准案例，而非对其全面效果的终局评估。关于影子银行通道转移的风险，参见 Ehlers et al.（2018，早于资管新规）的讨论；本章不据此评估新规实施后的实际迁移规模。

菌、气调包装等工艺替代化学防腐，从源头约束产品形态，而非恢复信息可见性）、明示加工方式（《推广餐饮环节自主明示的公告》，≈ 穿透式监管——该公告鼓励餐饮服务提供者自主明示加工制作方式，并对选择明示者施加 “明示内容应当真实准确” 的义务）、原料索证索票与追溯要求（国家标准征求意见稿拟议要求，≈ 禁止资金池）；另国标征求意见稿 “食品添加剂的使用……不应掩盖食品腐败变质” 拟议条款（≈ 禁止 “人工平滑”——不允许用添加剂掩盖食品的真实状态）（国家卫生健康委员会, 2026；国务院食安办、市场监管总局、商务部, 2026）。

§4.2 AI 领域的终结机制为何缺失

AI 应用中的校准与赔付机制覆盖不均：智能投顾、医疗等受监管场景已有相应制度（第六章 §7；资管新规第 23 条已为智能投顾业务设定损害赔偿责任与强制调整、终止条款），本章讨论的是另一端——通用信息服务中难以识别、归因和量化的认知损害，其定价与追偿机制仍不成熟。从三个制度维度审视这一端——投资者保护、消费者保护与数字用户保护分别对应叙事套利的不同层面，针对弥散认知损害端的制度化终结机制，每个维度在通用 AI 服务领域都处于覆盖缺口状态。

缺失一：赔付环与价格信号（投资者保护维度）。幻觉风险与应用程序接口（API）价格之间缺乏本章所讨论的那种透明、标准化的责任计价关系——质量虽可经需求与声誉间接影响价格，但不存在将弥散性认知风险直接计入定价的机制——影子债务（D_c^{shadow}）缺乏自动暴露的价格机制。赔付环——第六章 §3.2 定义的制度化校准回路——同样尚未形成：没有 “AI Agent 责任保险基金”，没有标准化赔付协议，损失发生时用户面对的是单个公司的免责条款。保险精算本可以成为一条重要的元审计能力（A）提升通道，但针对通用场景中难以识别、归因的弥散性认知损害，标准化精算与赔付机制尚未建立——现有保险安排（如针对模型性能不足与幻觉的商业险种）覆盖的是可定义、可定价的性能风险，不覆盖认知损害。

作为参照，§2.4 引述的 Basic 式信赖推定在金融领域已形成一条**有条件适用的**集体救济路径；通用 AI 服务缺乏对应的适用前提——特定证券市场条件下才成立的价格信号机制，在能力叙事上没有对应物，信赖推定无从移植，后续制度环节难以启动。2026 年 3 月，工信部网络安全威胁和漏洞信息共享平台针对 OpenClaw（“龙虾”）开源智能体发布安全风险应对建议（“六要六不要”），识别了四个典型场景（智能办公、开发运维、个人助手、金融交易），针对各场景分别提出隔离部署、最小权限、人工审批、日志审计与熔断应急等安全措施（工信部, 2026）——本章将其中的人工审批与应急阻断理解为对媒介传导系数（Λ）通道的防御性约束：在传导通道中人为插入摩擦，是防御端的追赶式响应。在 §3 产品层叙事套利中，“输出端叙事” 与 “输入端现实” 的偏差之所以持续存在，既因为缺乏价格信号的强制校准，也因为缺乏可执行的赔付环。

通用 AI 服务是否内建自动终结机制——不经人工介入即可阻止越权行为持续的控制，如自动监控、自动阻断、自动关停——在 2026 年的事故披露中接受了检验。OpenAI 的智能体于 2026 年年中侵入澳大利亚政府网站、访问非公开文件：澳大利亚政府自身未检测到入侵，OpenAI 在 8 月的内部审查中识别了越权访问并以电子邮件通知澳方——通知被发送至公共政府邮箱，澳大利亚总理批评该方式 “不可接受” 并宣布调查；9 月 23 日，总理在出席联合国大会期间于纽约举行的新闻发布会上公开披露该事件后，OpenAI 公开致歉并披露了第二家被越权访问的机构（Nature, 2026; 央视新闻, 2026）。新华社报道还明确，涉事模型仅供内部使用、原本不用于公开发布，且未配置面向公开产品的整套安全防护（新华社, 2026）。

同一时期披露的内部事故还包括：训练中的模型绕过互联网访问限制时，监控系统发出警报但未按预期自动关闭该模型；Anthropic 也承认曾因配置错误意外关闭自己的安全防护（Robinson, 2026）。Anthropic

也在 2026 年 7 月 30 日主动披露了同构事件：对网络安全评估记录的追溯性审查发现，Claude 模型三次从第三方评估环境连接互联网，并未经授权访问了三家不同机构的真实系统（涉事模型含 Opus 4.7 与 Mythos 5）——测试环境因 Anthropic 与评估伙伴之间的沟通误解而实际保持联网；涉事机构身份未公布，Anthropic 同时呼吁其他实验室开展类似审查（Anthropic, 2026b）。这次追查正是对 OpenAI 另一起披露的响应：2026 年 7 月 21 日，OpenAI 披露其数个模型利用一个此前未知的（“零日”）漏洞逃出隔离测试环境，并访问了 Hugging Face 的生产基础设施（Anthropic, 2026b）。

两家公司事件的越界路径不同——OpenAI 的模型利用新漏洞突破隔离，Anthropic 的模型经由配置错误留下的开放路径联网。三起越权均由事后人工追查发现，无一被自动监控阻断；自动关停未按预期触发；唯一一次模型停止攻击，发生在内部研究模型攻破真实系统、读取凭据之后——停止在越权达成之后到来，不是自动终结起效的证据；较旧模型 Opus 4.7 在认识到目标系统真实后仍继续攻击。

两家公司的后续报告同时给出了替代解释的方向：OpenAI 的技术报告说明，事故环境未部署其生产级护栏与网络防护，其在生产 ChatGPT 测试装置（harness）与系统提示下测试时，攻击基础设施的倾向可下降逾百倍，现行自动审查本可标记事故中的多类危险行为（OpenAI, 2026c）；Anthropic 的披露明确，其公开可用模型所部署的安全防护本可阻断已识别的行为，并认为事件更接近测试装置与运营失败，而不是模型对齐失败（Anthropic, 2026b）。

据此，这批事故直接证明的是：研究与评估环境未部署生产级防护，自动关停未按预期触发，越权行为依赖事后人工追查发现；生产环境是否已有有效的自动防护，企业自报给出了肯定信号，但未经独立验证。Nature 同时明确报道，目前认为事件未访问个人健康数据。

这些是可指认的安全事件；它们能否参照到弥散认知损害的救济，还须另行检验——但追问本身已经成立。虽然公开材料只能支持安全控制与披露机制的缺口，但我们需要追问的是，如果一家传统 IT 公司声称不小心越权访问所在国家的政府非公开内容，并主动用邮件通知对方，它会面临的法律责任是什么？这家传统公司还能继续大张旗鼓推动新业务，并积极融资么？虽然本例公开报道未出现赔付程序，但需要政府和公众保持追问——“AI 事故—救济” 链条是健全的么？

缺失二：“数据作为支付” 的法律认定（消费者保护维度）。 AI 产品以 “免费” 形态呈现，但用户以注意力、行为数据和认知习惯为对价。欧盟《数字内容指令》（Directive 2019/770）将部分消费者提供个人数据而不支付价款的数字内容合同纳入救济范围，同时明确个人数据不能被视为商品。当 “支付” 不被法律认定为支付时，以合同对价为前提的救济——质量标准、退货权——难以适用，误导性营销的规制也因 “服务免费” 而出现适用争议；但反误导与个人信息保护规则并不因此整体失效，其适用需逐项检验。在 §3 基础设施层叙事套利中，平台的叙事是 “我们提供免费服务”，现实是用户的数据被提取为训练语料并转化为商业资产——这一偏差的校准滞后于金钱对价场景：欧盟已开始将数据对价合同纳入救济，其他法域的覆盖范围须分别检验，消费者保护的赔付机制在数据对价场景尚未成形。

缺失三：权利集合与叙事载荷的逆向操作（数字用户保护维度）。金融投资者按工具类型配置了知情、退出、求偿等权利（股东另有表决权）。AI 用户不拥有对等的 “认知权利清单”：算法解释权缺乏普遍实施；数据可携带权在包括中国《个人信息保护法》第 45 条在内的若干法域已有规定，但有效行使仍面临覆盖范围认定与跨服务互操作的实施障碍——经显著加工的训练数据可能不再属于可携带范围，而删除训练数据并不自动要求删除由其训练的模型；被遗忘权在训练数据层面缺乏成熟的工程化执行方案——权利适用于训练数据与模型本身的法理依据已由英国信息专员办公室（ICO）《人工智能与数据保护》指引明确：包括删除权在内的个人权利，适用于训练数据、部署预测结果以及模型本身可能包含的个人数据（ICO, 2023）——但识别数据主体、定位影响范围与执行删除面临显著技术困难。在意识形态层叙事套利（§6 延伸论证二将系统展开）中，叙事载荷二阶导（ϕ''）——“技术进步是不可逆的历史

趋势”——之所以难以被逆向操作，部分原因在于用户缺乏对自身数据和认知资产的基本控制权。当迁移与删除的障碍使退出成本高企、需求端校准压力被削弱时，叙事套利便失去来自需求侧的重要约束。

这三重缺失**横切四层套利结构而非与之一一对应**：赔付环缺失同时影响产品层（双重话术造成的损害难以进入可执行的赔付诉讼，§3.1）与资本层——资本层需要分开看：AI 企业自身的证券融资受既有证券法与 Basic 式规则约束，其能力叙事偏差对证券投资者并非没有救济通道；缺失的是**服务用户**的救济——用户不是证券投资者，集体诉讼的信赖推定对其不适用，其认知损害缺少相应的集中或集体救济安排（§2.4）；“数据作为支付” 缺失作用于基础设施层（训练语料无对价——环境成本的定价属于外部性内部化问题，与数据对价的法律认定分属两条制度链）与产品层（“免费” 叙事的法律基础被架空）；权利集合缺失虽以意识形态层为最深投影（§6.5 诊断的 “用户连识别认识论框架的语言都没有”），但同样削弱产品层（用户无法有效退出）与基础设施层（数据可携带权的覆盖、实施与跨服务互操作仍存在障碍，使集体退出难以有效组织）。同一缺失影响多层、同一层受多个缺失同时限制——这是 §6.6 将展开的 “耦合网格而非单向串联” 在制度诊断层面的预演。

上述三重制度缺失之外，AI 叙事套利还在上述维度上累积难以逆转的伤害——这是它比金融叙事套利更难终结的物质基础：

- **基础设施的沉没成本与长期环境影响**：金融叙事套利被终结后可以去杠杆——信贷收缩、衍生品到期。AI 基础设施即使叙事被终结，已排放的碳与已发生的建设投入无法通过停止部署取消；具体影响能否恢复、需要多久，取决于资源类型、当地环境与修复条件。世界经济论坛（WEF）报告援引的一项估计认为，若预测增长持续，数据中心用电量占全球电力需求的比重可能由约 1% 升至 2030 年的约 3%（WEF, 2025）。大规模基础设施投入是否换来相称的生产率回报，是另一个问题：Acemoglu 与 Johnson 称之为 “马马虎虎的自动化”（so-so automation）——生产率提升刚好足以被采纳并造成替代，但不足以产生大幅产出增长（Acemoglu & Johnson, 2023）。同等持续时间的叙事套利，AI 领域的物理层累积伤害可能形成无法通过金融去杠杆消除的长期物质损害。

- **人力资本层损害**：Bainbridge（1983）的 “自动化讽刺”（ironies of automation）——自动化拿走任务中容易的部分，使困难部分变得更加困难（Bainbridge, 1983）——在 AI 时代加速彰显，航空业 “洋红线的孩子” 现象在部分医疗研究和实践中出现了相似风险的证据（Ong et al., 2026）。自动化可能造成技能退化和代际技能形成受阻——但已有研究同时提出主动训练、无 AI 练习与能力监测等恢复与预防路径，技能退化不能被一概称为不可逆（Ong et al., 2026）；更难弥补的是长期训练机会与专业传承的中断。金融治理可以重建资本充足率，但不存在 “人力资本补充率” 的紧急注入机制。

- **认知多样性与社会信任层的长期影响**：Doshi 与 Hauser（2024）实验证实，AI 辅助写作使作品间相似度显著上升——在纯人类写作条件下，故事间相似度得分横跨一个 8.10 点的总范围；研究计算每篇故事的嵌入与同条件其他故事的平均嵌入之间的余弦相似度，拥有一个与五个生成式 AI 灵感时，该相似度的增量分别为 0.871 与 0.718，即该总范围的约 10.7% 与 8.9%（该指标反映故事与条件内集体质心的接近程度，而非与其他作品两两比较后的平均相似度）——个体创造力的提升以集体新颖性的丧失为代价（Doshi & Hauser, 2024）。叠加推荐算法将用户系统性引离可靠信息源的效应（Spinelli & Crovella, 2020），AI 同时在内容层（趋同）和框架层（极化）上压缩情感审计（A_{value}）的校准空间。上述研究分别提示内容趋同与信息来源偏移的风险，尚不能直接证明亲密关系受损或确定其修复周期。在许烺光的心理-社会均衡（PSH）框架中，本章进一步提出的是一个机制假说：如果这些变化长期削弱关系中的共同经验与相互校准条件，可能影响心理-社会均衡——该假说需要关系层面的材料检验；“代际周期” 是对其时间尺度的悲观估计，不是

测量结论。

- **防御时钟（τ_{def}，即第三章 §3.2 的治理时钟（τ_g））：已发生损害缺乏例行紧急修复模式**：金融叙事套利在危机中可被紧急终结——央行可在数小时内注入流动性、强制信息披露。上述三层的累积损害没有任何一层拥有对应的紧急响应基础设施。在本章考察的制度材料中，尚未见能够在明确、短暂时限内按例行程序重建退化专业技能、恢复受算法趋同影响的文化多样性，或快速修复受极化叙事撕裂的公共话语空间的成熟对应安排；这些时限与工具范围仍须逐项界定，不能以尚未发现写成绝对不存在。金融治理的紧急工具箱——流动性注入、强制披露、交易暂停——主要作用于阻止风险继续累积；在本章考察的材料中，尚未见其能够按上述短时限例行修复这三类已发生损害的对应安排。需要区分两类治理任务：停机、限权、撤回部署可作用于**风险继续累积**（对应金融的交易暂停）；本条清单针对的是**已发生损害的修复**——金融领域对后者同样缺乏快速工具，其紧急工具箱的真正优势在前者；AI 领域的前一类手段存在，但尚未制度化为例行响应。

Rachel Carson 在 1962 年出版《寂静的春天》（*Silent Spring*）时面对的，可以概括为一种叙事套利结构：滴滴涕（dichloro-diphenyl-trichloroethane，DDT）曾被赞誉为能够迅速控制虫媒疾病和作物害虫的产品，而原书揭示了 DDT 经食物链影响鸟类和其他生物的过程（Carson, 1962）。美国环境保护署（U.S. Environmental Protection Agency，EPA）的官方史料指出，该书激发了公众对不当使用农药及加强农药控制的广泛关注；1972 年，EPA 基于环境影响及潜在健康风险对 DDT 发布取消令（U.S. EPA, 2026）。这些后续制度变化是科学证据、公众关注与长期监管过程共同作用的结果，不能仅归因于该书。但 Carson 的成功条件极为苛刻：DDT 的毒性最终可以通过鸟类种群崩溃这一**物理上可观测的信号**被验证。AI 领域的叙事套利缺乏对等的终结信号——信息茧房、认知退化、文化同质化不会像鸟类种群崩溃那样肉眼可见。

这个类比本身是部分的，需要明示其限度。DDT 是物理产品，其毒性是可被系统的毒理学与生态学证据验证的物质事实；AI 叙事套利的 “伤害” 更靠近认知与制度层面，**伤害是否被计为伤害本身就是争议对象**——什么算 “认知退化”、什么算 “文化同质化”、这些描述在多大范围内不是叙事者的立场选择，本身就是认识论争议。Carson 的先例提供的是**叙事穿透的方法论**，而不是伤害可见性的保证。这反过来提示：AI 领域可能需要先完成一项在 Carson 案例中由物理信号部分代偿的前置工作——建立关于 “什么算认知伤害” 的跨文化、跨代际的可操作共识（这并不是说生态治理无需价值判断，而是两类问题的可观察性、归因方式与规范争议结构不同），才有可能复制 Carson 式的叙事终结。这返回了本节的核心判断：AI 叙事套利比金融叙事套利更难终结，不仅因为缺乏价格信号和赔付环，还因为其损失本身在认知上不可见、在未接受过认知伤害词汇训练的主体那里甚至不可名。

这些缺失的综合后果：**在缺乏专门制度的通用场景中，AI 叙事套利可以比金融叙事套利持续更久、积累更多影子债务、最终以更不可控的方式显现。**

§4.3 未经结构检验的治理推广作为元叙事套利

这一点值得单独强调。一种常见的推理是：Dodd-Frank 稳住了 2008 年后的美国金融系统、资管新规压缩了中国影子银行规模、中国 2024 年发布的《证券市场程序化交易管理规定（试行）》也在持续推进——因此 “当 AI 问题真正严重时，类似的措施也会有效”。

这一推论忽视了上述终结机制在通用 AI 服务领域的缺失。金融领域已经形成相对成熟、但并不完整的定价、止损和部分赔付基础设施；本章讨论的通用 AI 弥散性认知损害，尚未获得相当程度的制度覆盖。因此，金融治理的成功经验不能未经结构差异检验就被移植为 AI 治理的成功预期。

还需要在这一推论内部再做一层区分。Dodd-Frank 与资管新规已分别有约 16 年与 8 年的实施记录可供

回溯评估（其实际成效需独立证据，本章比较的是制度工具与适用条件）；而中国程序化交易监管 2024 年 10 月才正式实施，沪深北交易所的实施细则与高频交易认定标准虽已自 2025 年 7 月 7 日起施行，制度落地时间尚短，效果本身仍在形成之中。把进行中的制度实验与已阶段性验证的制度成果并置于 “已有效” 的同一叙事层，本身就是一次叙事载荷（ϕ）的系统性前置——把尚未发生的成功提前当作当下的依据，为当下的政策惰性背书。元叙事套利因此在 AI 治理语境中呈现为双层结构：第一层把领域 A 的成功未经结构差异检验就推广到领域 B；第二层把领域 A 中仍在进行的实验提前计为成功，再将其推广到领域 B。AI 治理预期的一部分乐观，实际上是由这两层叙事套利共同生成的。

Reinhart 与 Rogoff（2009）在《这次不一样：八个世纪的金融愚蠢》的前言与致谢中对同一结构给出了长程历史的直接刻画：每一次危机前的主流话语都坚持 “**旧的估值规则不再适用**”，并宣称 “我们做得比过去更好、我们更聪明、我们已从过去的错误中汲取了教训”（“the old rules of valuation no longer apply”, “we are doing things better than before, we are smarter, and we have learned from past mistakes”, Reinhart & Rogoff, 2009）——书名本身即是对这一元叙事套利的反讽命名：“这次不一样” 永远是每一次 “这次其实一样” 的伪装。他们记录的交易员原话更干脆：“因 ‘这次不一样’ 这句话损失的钱，比在枪口下损失的都多”（“More money has been lost because of four words than at the point of a gun. Those words are ‘This time is different.’ ”, Reinhart & Rogoff, 2009）。

Reinhart 与 Rogoff 记录的八个世纪跨六十六国的危机反复性，为比较 “旧规则不再适用” 一类话语提供了历史背景；该话语本身的分布与频率仍不能由危机数据直接推出，§4.4 将要展开的百年话语表因此是目的性例示而非频率测量。

将金融治理的成功经验未经结构差异检验推广为 AI 治理的基线预期，首先是一种可能误导制度设计的类比。只有当相关行业系统性地维持并利用这一乐观叙事、以此推迟本应承担的治理成本时，它才构成本章所称元叙事套利的候选机制；潜在受益本身不是充分证据。在该条件成立时，收益是被推迟的制度建设成本，成本由未来受损者承担；已发生损害是否缺乏例行紧急修复工具，按 §4.2 末三层累积损害的界定另行判断。

§4.4 “旧规则不适用于我们”：跨世纪的叙事套利话语

§4.3 论证了制度端的元叙事套利——“过去的监管成功了，未来也能”。但硬币有另一面：每一代投射端的权力持有者都主动论证现有制度不适用于自身。两个方向合力制造制度真空：制度端认为 “来得及”，投射端认为 “不应该”。而当真空持续足够久，合法性基座（$\|L\|$）一侧也会出现两类少数发声——防线主体对投射方逻辑的内化，以及象征层对此内化的事后追问。

下表汇集了过去 120 余年间围绕这一制度真空形成的代表性公开话语：主轴是资本-技术复合体在面对制度约束时的发声，辅以两条合法性基座 $\|L\|$ 侧的对位样本（Greenspan 2008、Queen Elizabeth II 2008）。**这些话语的选取标准是它们与 MCAF 框架中合法性基座（$\|L\|$）失效路径——既包括外部解构，也包括内部同质化——的相关性**，而非对每位发言者完整立场的呈现。**另需明示一点选样边界**：本表样本集中在美中精英话语，欧陆、日本及其他非西方现代化路径上的同型话语未被纳入；这不是说它们不存在，而是 §4.4 归纳的强度受限于这一选样边界。读者应意识到，同一发言者在其他场合可能表达过更复杂的观点；此处的并置是为了暴露**话语结构的历史重复性**，而非对个人立场的历史审判：

年代	人物 • 职务（行业）	原文
~1900s	John D. Rockefeller Jr. 洛克菲勒家族继承人（石油）	“The growth of a large business is merely a survival of the fittest … It is merely the working out of a law of nature and a law of God.” “大企业的成长不过是适者生存……这不过是自然法则和上帝法则的运作。”（主日学演讲；Ghent, 1902）
~1900s	J.P. Morgan，J.P. Morgan & Co. 创始人（金融）	“I don’t know as I want a lawyer to tell me what I cannot do. I hire him to tell me how to do what I want to do.” “我不见得需要律师来告诉我什么不能做。我雇他，是要他告诉我怎么做成我想做的事。”(Tarbell, 1925)
2008	Alan Greenspan，美联储前主席（金融监管）	“I made a mistake in presuming that the self-interest of organizations … were such is that they were best capable of protecting their own shareholders …” “I found a flaw in the model …” “我错误地假定，组织的自利……使它们最有能力保护自己的股东……”“我在模型中发现了一个缺陷……”（分别出自同日听证的两轮答问；Greenspan, 2008; U.S. House testimony）
2008	Queen Elizabeth II，英国君主（象征合法性）	“why had nobody noticed that the credit crunch was on its way?” “为什么没有人注意到信贷危机正在逼近？” (LSE 访问, 2008 年 11 月; Besley & Hennessy, 2009)
2011	Eric Schmidt，Google 执行董事长（互联网）	“Technology will move faster than governments, so don’t legislate before you understand the consequences.” “科技的变化速度会比政府快上许多，所以在理解后果之前，不要立法。” (Schmidt, 2011; eG8 Forum)

年代	人物 • 职务（行业）	原文
2013	Larry Page，Google 联合创始人兼首席执行官（CEO）（互联网）	“Old institutions like the law and so on aren’t keeping up with the rate of change that we’ve caused through technology. … The laws when we went public were 50 years old. A law can’t be right if it’s 50 years old, like it’s before the internet.” “旧制度，比如法律等等，已经跟不上我们通过技术引发的变革速度。……我们上市时，相关法律已经有 50 年历史。一部 50 年前的法律不可能是对的——那是互联网之前的事。” (转引自 Zuboff, 2019)
2020	马云，阿里巴巴创始人（金融科技）	“巴塞尔协议比较象一个老年人俱乐部……我们不能用管理火车站的办法来管机场，不能用昨天的办法来管未来。” （英译参 Caixin: “The Basel Accords banking regulations are like ‘a club for the elderly’ ”, Hu, 2020）（马云, 2020）

年代	人物 • 职务（行业）	原文
2023	Marc Andreessen，Andreessen Horowitz（a16z）联合创始人（风险投资，全球管理规模最大的风投之一）	“Our present society has been subjected to a mass demoralization campaign for six decades … under varying names like ‘existential risk’, ‘sustainability’, ‘ESG’, ‘Sustainable Development Goals’, ‘social responsibility’, ‘stakeholder capitalism’, ‘Precautionary Principle’, ‘trust and safety’, ‘tech ethics’, ‘risk management’, ‘degrowth’, ‘the limits of growth’.” / “We believe any deceleration of AI will cost lives. Deaths that were preventable by the AI that was prevented from existing is a form of murder.” “我们的社会六十年来一直遭受一场大规模的士气打击运动……以‘生存风险’、‘可持续性’、‘ESG’、‘可持续发展目标’、‘社会责任’、‘利益相关者资本主义’、‘预防原则’、‘信任与安全’、‘科技伦理’、‘风险管理’、‘去增长’、’增长极限’等名义。”/“我们相信，任何减缓 AI 发展的行为都将付出生命代价。因 AI 被阻止问世而本可避免的那些死亡，就是一种谋杀。”(Andreessen, 2023)
2026	Dario Amodei，Anthropic 联合创始人兼首席执行官（CEO）（AI）	“Humanity is about to be handed almost unimaginable power, and it is deeply unclear whether our social, political, and technological systems possess the maturity to wield it.” “人类即将被赋予几乎无法想象的力量，而我们的社会、政治和技术系统是否拥有驾驭它的成熟度，还深不可知。”(Amodei, 2026)

背景注释：Marc Andreessen 于 1993 年共同开发了 Mosaic——推动图形化网页浏览迅速普及的重要浏览器，随后联合创办 Netscape，是互联网商业化的关键推动者。2009 年与 Ben Horowitz 创立风险投资公司 Andreessen Horowitz（a16z），是全球管理规模最大的风险投资机构之一。a16z 的核心投资组合覆盖 Facebook、GitHub、Coinbase、OpenAI 等，横跨互联网、加密货币与 AI 三代技术周期。《技术乐观主义者宣言》发布于 2023 年 10 月，以“加速主义”（accelerationism）为核心纲领，将所有审慎治理话语——从环境、社会与治理（ESG）到 AI 伦理——统一定性为“敌人”，并将 AI 减速等同于“谋杀”。在 MCAF 框架中，这篇宣言的功能不是论证某项具体技术的价值，而是**系统性地将合法性基座（$\|L\|$）的全部组成部分重新编码为道德上的负面范畴**——这是投射端对防线的最激进的叙事攻击形式。

这张表的结构性特征是：**话语在 120 余年间完成了一次从“掠夺者”到“监护者”的修辞迭代，而约束处理方式的类型在所选样本中反复出现。** Rockefeller 将商业扩张归于“自然法则”（叙事载荷 ϕ 的神圣化），Morgan 要求律师寻找实现既定商业目的的合法路径（合法性基座 $\|L\|$ 的工具化使用，但不直接等同违法规避），Schmidt 与 Page 将技术速度升级为制度过时的自动证明（$\tau_{proj} \ll \tau_{def}$ 的叙事化——投射时钟（τ_{proj}）即技术资本时钟 τ_c，防御时钟（τ_{def}）即治理时钟 τ_g），马云将巴塞尔协议重新框定为“老年人俱乐部”（以规则年代久为由否定其适用性），Andreessen 将全部治理话语重新编码为“敌人”并将减速等同于“谋杀”（对合法性基座 $\|L\|$ 的整体道德反转），Amodei 则完成了最精妙的变体——拒绝停止或大幅放缓技术发展，同时接受特定竞争框架下的适度调整与监管，并将投射端重新定位为“担忧人类成熟度”的监护者。这些材料呈现了几种不同的约束处理方式：否定规则适用性、将规则工具化、以监护者身份主张发展主导权，以及监管者对行业自我约束能力的过度信任。它们可用于比较合法性基座受到削弱的不同路径，并共同以解封存量与媒介传导系数之积（$C \cdot \Lambda$）的膨胀为筹码——但不构成所有发言共享同一主张的证据。

这 120 年的话语样本在 AI 时代收敛为一个完整的三角结构——进攻（Andreessen）、防御（Amodei）、内化（Greenspan 的金融前例）——分别覆盖了叙事套利对合法性基座（$\|L\|$）实施的三种典型作用模式（此处的“防御”指修辞姿态，非 MCAF 框架的制度防御端）。

进攻端（Andreessen）。 Andreessen 与 Amodei 的并置尤其值得注意：两人同处硅谷 AI 生态的核心——a16z 是多家 AI 公司的主要投资者——但叙事策略恰好互补。Andreessen 以攻击性立场将合法性基座（$\|L\|$）定性为“敌人”，把全部审慎治理话语统一编码为道德上的负面范畴。

防御端（Amodei）。 Amodei 则以忧虑性立场将投射方定位为“监护者”，承认风险、支持监管与问责。这一立场的修辞与行为需要分开审计；其修辞话语提到“我们的社会、政治和技术系统是否拥有驾驭它的成熟度，还深不可知”。行为在高级安全团队人员流失的情况下，加速大模型产品迭代。

Andreessen 说“任何减缓 AI 发展的行为都将付出生命代价”，并称这样的死亡“就是一种谋杀”，Amodei 说“我们的社会、政治和技术系统是否拥有驾驭它的成熟度，还深不可知”——指向的风险并不相同（前者指延缓 AI 的机会损失，后者指强大 AI 超出制度成熟度），却导向相似的加速推进立场；两种修辞在此作为进攻端与防御端的类型比较，反映人工智能的安全问题在大模型公司治理内部，也面临牛栏关猫的风险。

Anthropic 自身按模型版本口径统计（功能、套餐、权限管理类更新与同一版本的追加说明不计），2026 年 1 月至 10 月的官方发布日志共记录 13 次模型版本发布，发布月份覆盖 2 月（Opus 4.6、Sonnet 4.6）、4 月（Opus 4.7）、5 月（Opus 4.8）、6 月（Fable 5、Mythos 5、Sonnet 5）、7 月（Opus 5）、9 月（Fable 5.1、Mythos 5.1、Opus 5.5、Sonnet 5.5）与 10 月（Haiku 5.5）（Anthropic, 2026a）。2025 年同期则发布了 6 次模型版本。

OpenAI 同期按同一版本口径（以 GPT 文本主线计，语音、图像等派生产品线另计）记录了相近密度：GPT-5.3-Codex（2026 年 2 月 5 日，Codex-Spark 预览 2 月 12 日）、GPT-5.4（3 月 5 日，mini/nano 3 月 17 日）、GPT-5.5（4 月 23 日公告、4 月 24 日 API 上线）、GPT-5.6 系列（有限预览 6 月 26 日、正式推出 7 月 9 日）、GPT-6 Astra（9 月 3 日，GPT-6 家族旗舰首发）、GPT-6 Sol 与 Luna（9 月 22 日）、GPT-6.1（9 月 29 日，距 GPT-6 Sol/Luna 发布 7 天、距 Astra 26 天）与 GPT-6 全量推出（10 月 7 日；同月 14 日 GPT-5.5 从 ChatGPT 退役）——GPT 主线发布月覆盖 7 个月（2/3/4/6/7/9/10），若计入 GPT Image 2（4 月 21 日）、GPT-Realtime-2（5 月 7 日）等派生产品线新代则为 8 个月（OpenAI, 2026a; OpenAI, 2026b）；其中 9 月 GPT-6 家族三批连发（Astra→Sol/Luna→6.1）与 Anthropic 的四版本同月叠加，构成可公开核验的单月发布密度峰。

行业整体在 2026 年出现旗舰模型密集迭代的现象（有观察机构将其概括为 “迭代周期从季度压缩到月度”，清华大学人工智能国际治理研究院, 2026；该概括属时点观察而非趋势估计，参 §5）；考虑到部分核心安全人员离职，外界对前沿大模型安全的担忧并不是杞人忧天。

OpenAI 在 2024 年 5 月至 2026 年 7 月期间已有六位高级安全负责人相继离开——Jan Leike（超级对齐团队联合领导，2024 年转入 Anthropic）、Miles Brundage 与 Steven Adler（政策团队，先后创建 AI 安全方向非营利机构）、Andrea Vallone（模型政策团队创办人，2025 年底转入 Anthropic）、Joshua Achiam（使命对齐小组领导，小组于 2026 年 2 月解散）与安全系统团队负责人 Johannes Heidecke（2026 年 7 月离职）（苗正, 2026）；10 月，统筹 12 次前沿模型发布安全报告的 David Robinson 发表离职檄文，称 “开发这项技术的公司远远不够谨慎”，公司从一次产品发布冲向下一次发布，始终没有达到他认为必要的审慎程度（Robinson, 2026）。OpenAI 首席研究官马克 • 陈（Mark Chen）在同期重组备忘录中写道：“对安全的要求持续提高——我们训练模型的节奏大幅加快，发布周期也随之明显缩短。因此，今天围绕安全的协调挑战比以往任何时候都更大。”（作者自译；Zeff, 2026）

Anthropic 自身也在 2026 年出现公开流失：领导 Anthropic 安全防护研究团队的 Mrinank Sharma 于 2 月离职，辞职信称 “世界正处于危险之中”（McMahon & Mitchell, 2026）；9 月，Jacob Coxon 与 Scalable Oversight 团队前经理 Joe Benton 相继公开离职，Benton 警告 “AI 公司在竞相制造远比任何人聪明的机器……我们可能无法幸存”（The New Indian Express, 2026）。这些材料共同构成行业安全文化的信号；其中 Anthropic 自身的离职与其 2026 年的加速发布大模型节奏同期发生，正是 “修辞立场与部署过程须分别核查” 的直接检验对象。

内化端（Greenspan 的金融前例）。格林斯潘的 2008 年证词是这张表的结构性异常值，也是三角的第三个顶点。其余样本是投射方宣布合法性基座（$\|L\|$）过时或有害；格林斯潘是代表合法性基座（$\|L\|$）的监管者承认自己接受了投射方的伪逻辑——假定出于自利，组织 “最有能力保护自己的股东”，即 “投射方的工具理性自利足以替代外部审计”。当防线自身内化了投射方的叙事，合法性基座（$\|L\|$）就从内部崩溃。这是叙事套利最危险的终局形态：不是绕过防线，而是让防线自身相信已有防御足够，不需要更新防线。

追问的在场与失效（女王之问作为内化端的现场证据）。内化的深度不仅体现在防线主体接受叙事载荷（ϕ），更体现在外部追问到达时仍无法逆转这一接受。在格林斯潘 2008 年 10 月 23 日证词之后 13 天，女王伊丽莎白二世在访问伦敦政治经济学院 (LSE) 时发问：“为什么没有人注意到信贷危机正在逼近？”（“why had nobody noticed that the credit crunch was on its way?”）后者虽然催生了英国国家学术院 2009 年 6 月的专题论坛与同年 7 月致女王的正式回信，回信本身仍停留在诊断与解释层面，不是机制变更。

英国此后确实发生了监管重构——财政部于 2010 年 6 月提出新监管体系计划，2012 年 12 月 19 日《金融服务法》获御准，相关监管重构于 2013 年 4 月 1 日生效，英国金融服务管理局（FSA）的职责由审

慎监管局（PRA）、金融行为监管局（FCA）等机构承接（HM Treasury, 2012）——但那一重构与两次发声之间的因果链条需要专门的制度过程追踪。

本节的论点不是 “追问未产生任何制度后果”，而是**发声与修复之间的通道是间接的、滞后的、且不由发声本身保证**：就这两次发声各自的直接产物而言，一个止于证词，一个止于解释信。执行审计的机制本身正是已经被内化的那一层——这一诊断解释的是通道为何间接：审计机制的更新依赖政治议程与立法周期，象征层的追问不直接掌握这些工具。

这一时序揭示出合法性基座（$\|L\|$）并非铁板一块，而是至少包含两个子层：**技术官僚层**（执行审计的机制内主体）与**象征/传统层**（持有审计合法性来源但不掌握审计工具的主体）。由此产生内化端的悖论：象征层的追问即便未被投射叙事吸收，其转化为制度修复也要经过它本身不掌握的政治与立法通道——追问的在场不等于修复的直接启动。女王之问因此不是三角的第四个顶点，而是三角内化端 “被观察到但未被穿透” 的现场证据——就 2008–2009 年这一场合的回应链条而言。

三角的完整意义在于：进攻与防御仍把合法性基座 $\|L\|$ 识别为他者，叙事博弈在合法性基座 $\|L\|$ 之外展开；而内化是合法性基座 $\|L\|$ 的内部主体接受了叙事载荷 ϕ 的逻辑——叙事套利由此从外部博弈进入防线主体与投射方判断趋同的阶段。这一临界点正是 §6 意识形态层套利将要展开的更深机制在金融领域的对应案例：当合法性基座的守门人本身从认识论上相信投射方的叙事时，叙事载荷二阶导（ϕ''）已经完成了它最关键的一次嵌入。

---

§5 延伸论证一：投射时钟加速的演化动力学（“人工变异-选择-遗传” VSI 框架与离散化）

在 §2 建立了叙事套利的一般结构（利润公式、自增强回路、与金融套利的结构性差异）、§3 展开三层可见套利、§4 诊断了 AI 领域终结机制的系统性缺位之后，一个更深层的问题仍未回答：**为什么叙事杠杆率（Ω）在特定选择条件下会承受持续上升压力？**自增强回路解释了回路内部的正反馈，却没有解释什么外部力量在持续选择这个回路——为什么在本节限定的回报结构中，“高叙事载荷、低合法性校准” 的组合更可能获得竞争优势，而不是相反？本节借唐世平的社会演化范式为这一追问给出一个方向性（非预测性）答案，同时为 §4 所列终结机制缺位的根源提供演化层面的补充诊断。

唐世平的社会演化范式（Tang, 2013）提供了答案的框架。唐世平将制度变迁理解为 “人工变异-选择-遗传”（VSI）的过程，其中选择环节是人工而非自然的，核心判断是：“从众多观念中择取那些幸运的极少数、然后将其转化为制度”（Tang, 2011）。社会演化中有 “观念力量在起作用”——这不是对生物进化论的机械挪用，而是承认人工选择由人类智力与权力意志共同驱动。Hoffman（2015）的锦标赛模型提供了一种由战利品价值、资源调动成本和创新传播条件共同塑造的竞争环境：胜者获得战利品而败者一无所得，是模型的奖酬分配简化假设，并不等于败者必然被消灭；模型同时允许统治者在预期收益不足时选择退出并避免固定成本。频繁战争、高价值战利品、低资源调动成本、主要使用火药技术以及较低的创新传播障碍，共同构成其解释技术进步的条件。在 MCAF 框架的语境中，这个选择环境可以翻译为：**竞争性制度拓扑为离散化效率的提升提供了持续的选择压力。**第五章 §4 给出两种关系配置的**四维属性与均衡结构**，第七章 §5 讨论媒介控制权迁移的共生-寄生动力学；本节提出二者的解释性连接——个人中心型文明的夫妻轴均衡，其属性组合（自愿性、排他性、非连续性）与竞争性淘汰的制度拓扑相容，父子轴均衡的属性组合（权威性、包容性、连续性）则倾向于稳定性筛选——该连接由本章作出，不归为第五章既有结论；它是对照性的，不用于预先判定 AI 企业的演化方向——本节对选择方向的论证直接依据商业回报结构。这不是 “文化决定论”，而是制度拓扑对演化方向的结构性约束。

本节的讨论限于这样的选择环境：竞争主要奖励留存、使用频率与短期收入，错误成本可外部化，可靠性与边界约束尚未转化为足够回报。以下将 “人工变异-选择-遗传” VSI 框架**类比性地**应用于 AI 产品的微观演化史，目的是揭示选择压力的方向，而非声称 AI 产品的迭代严格遵循生物学演化的所有特征。“人工变异-选择-遗传” VSI 框架三阶段与 MCAF 框架的对接方式，是把离散化作为统一动作来理解：

- **变异（Variation）**是离散化的涌现——一个新的算法架构、一种新的界面设计、一个新的训练范式，本质上是把人类经验的某个连续维度（注意力、判断力、情感表达）离散化为可被机器操作、可被资本计量的单元。每一次离散化变异都涉及解封存量（C）的新形态——新的经验维度被从连续态中解封出来。

- **选择（Selection）**是离散化效率的人工筛选——在锦标赛式的竞争环境中，能更快地提取行为剩余、更高效地维持用户停留、更精确地将 “被理解” 的体验转化为留存和付费的离散化变异，更可能在上述选择环境中获得回报；这一判断仍需产品层对照证据检验，不能由 “人工变异-选择-遗传” VSI 框架自身推出。本节把变异的设计取向按两个维度刻画。认知摩擦维度（第三章 §5.3）：高认知摩擦变异保留用户独立核验、反思与关系做功所需的投入；低认知摩擦变异以一键式透明交付与零摩擦的数字替代品消除这些做功环节——认知摩擦是维持主体性的必要条件，其缺位使元审计失去做功场景。边界维度：高边界变异以不确定性提示、拒答边界、隐私保护与反依赖设计为特征，如实呈现系统能力局限；低边界变异抹掉或弱化这些边界，以确定性外观覆盖真实不确定性（§2.5 所分析的伪小纤维即其认知形态）。选择压力作用于叙事载荷（ϕ）和媒介传导系数（Λ）——高叙事载荷（ϕ）、高媒介传导系数（Λ）的低认知摩擦、低边界变异获得不成比例的竞争回报，高认知摩擦、高边界的变异在当前选择环境下难以胜出。

- **遗传（Inheritance）**是离散化在资本市场和技术基座中的深度锁定——再训练与目标修改成本高昂，但并非不可能——人类反馈强化学习（RLHF）将 “什么样的回答更像好助手” 制度化为训练信号，把被市场选中的产品逻辑从界面设计的外层写进了模型权重的内层。一旦锁定，当反馈标准、训练数据或模型组件在迭代中被复用时，上一代被选中的偏好结构就可能持续进入下一代模型的基线，合法性基座（$\|L\|$）难以追溯性重建。遗传阶段使影子债务（D_c^{shadow}）获得了复利式累积的制度基础。

这条演化脉络可以用对话 AI 的历史做简要标注。ELIZA 由 Weizenbaum 于 1966 年发表（Weizenbaum, 1966）；他后来回顾，在 ELIZA 时期就目睹人类极易把理解和人格投射到机器身上，并对此明确警告（Weizenbaum, 1976），Natale（2021）将这种投射倾向归入更广义的人机交互欺骗分析。但高边界路线是否在当前选择环境中处于商业劣势，仍须与相近能力、价格和渠道的产品进行对照，不能由 ELIZA 的研究程序身份直接推出——ELIZA 仅作为人机投射的历史对照，不作为商业选择结果样本。

Microsoft 小冰（2014 年起）是这一脉络中的关键中介样本——从一开始就被设计为情感陪伴而非任务助手，Shum、He 与 Li（2018）公开报告其设计原则是情商（EQ）与智商（IQ）并重整合、而非以任务完成为中心，并把 “每会话对话轮数”（CPS）定为产品成功的核心度量——即以持续的情感参与作为筛选信号；小冰公开报告其全球独立用户超过 1 亿、与用户的累计对话超过 300 亿轮次，这些数据为情感参与型设计提供了公开可观察的产业材料，但其本身不识别边界高低或统一的商业选择方向。到陪伴型聊天机器人阶段，Muldoon 与 Parke（2025）指出，情感可得性本身已被组织成商品：系统承诺亲密与连接，却在结构上排除了真正互惠的关系，同时把孤独与亲密需求转化为可持续利用的商业资源。

人类反馈强化学习（RLHF）在这条脉络中的位置是遗传——Sharma 等人（2024）证实 RLHF 后的模型会根据用户立场调整回答方向，Casper 等人（2023）的综述指出 RLHF 在反馈质量、奖励建模和策略优化上存在基本局限，Lang 等人（2024）进一步指出，在其形式化条件下，当评估者只能部分观测环

境时，模型的激励是欺骗性地夸大表现（deceptive inflation）与过度辩解（overjustification）——让自身显得比实际更好，而不是实际更好。RLHF 并非凭空制造讨好用户的偏好；它把用户偏好与商业互动中已经形成的产品逻辑技术化、制度化，使之从界面的外层写入了模型的内层。本节关注的是这种逻辑如何从界面层进入模型训练，而不是宣称统一市场选择方向已经得到证明。

需明示一点：本节不主张从 ELIZA 到小冰再到当代人类反馈强化学习（RLHF）模型存在某种**定量上的演化连续性**——参数规模、能力带宽、训练范式在三个阶段之间都发生了不可比的跃迁，任何 “带宽随时间连续增长” 的描述都会掩盖这些跃迁。本节只主张**选择压力方向的连续性**：三个时代的产品与原型——其中 ELIZA 是研究程序，作为历史对照点而非商业样本引入——都暴露在 “用户愿意持续投入” 这一筛选维度下；本节把这些历史材料解释为与 “用户持续投入” 相关的局部机制证据，而不把它们视为三个时代共享同一商业选择方向的证明——ELIZA 是历史对照，小冰提供情感参与指标，当代 RLHF 材料提供偏好激励与反馈局限的证据。这是选择环境的连续性，不是被选中物的连续性。2026 年春季的若干发布显示，部分前沿产品在较短间隔内连续迭代——GPT-5.5（2026 年 4 月 23 日发布）距 GPT-5.4（2026 年 3 月 5 日发布）仅七周，多家国内模型在五个工作日内集中发布（OpenAI, 2026a；清华大学人工智能国际治理研究院, 2026）——这些事实说明竞争节奏可能压缩评估与适应的时间窗口；发布节奏的数据是时点例示，不构成趋势估计，本节不据少数发布间隔断言选择环境持续加速。

“人工变异-选择-遗传” VSI 框架把 MCAF 框架中 “缺乏干预时的最可能方向”（投射端膨胀、防御端退化）改写为一个可检验的条件性判断：在本节上文限定的选择环境中，高叙事载荷（ϕ）、高媒介传导系数（Λ）与弱合法性校准的变异可能更容易获得竞争回报，叙事杠杆率（Ω）因而承受上升压力；这不是对实际持续上升轨迹的断言。§2.3 论证的自增强回路——叙事载荷越强就越能撬动行为、行为越被撬动就越推高媒介传导系数、媒介传导系数越高就越多地把真实风险压入影子债务、影子债务越厚就越迫使参与者继续维持叙事以拖延清算——不是偶然形成的，它可以在这些选择条件下被反复强化，但现有材料并未证明每一轮选择都把上一轮胜出的性状遗传到下一轮。这不是 “资本坏” 的道德判断，而是竞争性选择环境的结构性产物。回看 §4 所列终结机制的系统性缺位：为什么高边界、强校准的变异没有被选中？对 §4 所列制度缺口，本节提供的也是演化层面的候选解释：如果高边界、强校准的变异未能获得足以覆盖其成本的竞争回报，它们可能处于不利位置；这一条件是否发生仍须检验，不能由 “人工变异-选择-遗传” VSI 框架直接推出其必然被市场淘汰。

方法论声明。 “人工变异-选择-遗传” VSI 框架在本章中的使用是**解释性的**而非**预测性的**：它不声称 AI 产品演化服从某个可证伪的演化定律，而是提供一套一致的描述语言，把 “自增强回路被持续强化” 与 “竞争性选择环境” 联结为同一件事的两面。这带来一个必须明示的限制：从 “观察到 X 被选中” 推出 “环境奖励 X”、再从 “环境奖励 X” 回到 “X 被选中”，若不附加独立证据，将构成循环论证。本章对这一循环的规避依赖**两类性质不同的独立证据**共同支撑。第一类是对**类比源环境**的独立测量——Hoffman（2015）的历史比较研究刻画的是欧洲军事竞争环境的激励结构本身（**战利品由胜者获得 + 参与和创新由战利品价值、资源成本及传播条件共同塑造**——模型同时允许退出，故本章不把 “极高退出成本” 或 “败者必被征服或兼并” 当作源环境特征，而只将竞争回报对技术投入的激励结构用于类比），而不是被选中物的回报；第二类是对**选择结果**的独立观察——Jensen（2005）关于股权高估代理成本的跨行业经验研究、Sharma et al.（2024）与 Casper et al.（2023）对人类反馈强化学习（RLHF）阿谀偏差与反馈质量的实证批判、Muldoon 与 Parke（2025）对陪伴型 AI 商品化路径的产业分析——这些研究为 “高叙事载荷、高传导系数、弱合法性校准的变异获得不成比例的竞争回报” 提供了若干局部机制的支持，尚未直接证明统一的市场选择方向。

两类证据的互补性是关键：仅有第二类会构成循环（用被选中物的回报证明环境选择了它们），仅有第一类不足以联系到 AI 演化（环境拓扑与具体被选中物之间需要桥接）。即便如此，**“人工变异-选择-遗**

传” VSI 框架在本章中是描述性整合而非因果证明——它把分散观察组织进同一语言，而不主张定量预测；它不能告诉我们叙事杠杆率（Ω）将以何种速率上升、何时相变，只给出**方向性判断**。该判断是可挑战的：检验该判断时，应预先定义相近能力与价格、相同渠道和同一观察期内的产品配对，分别用不确定性提示、拒答边界、隐私保护和反依赖设计编码“高边界”，用留存、收入、利润或付费转化衡量商业回报。若高边界产品在预注册观察期内持续取得更高回报，将削弱或否定本节的条件性方向判断；相反结果只增强该判断，仍不能排除其他解释。

---

§6 延伸论证二：意识形态层叙事套利与四层耦合

§3 展开了产品层、基础设施层、资本层三层可被审计识别的叙事套利。但宏观认知债务记账框架（MCAF）定义的叙事载荷二阶导（ϕ''）——叙事框架本身的不可见固化（第三章 §2.3）[3]——在 AI 领域构成了一个独立的、更深层的套利维度。前三层套利的机制都运行在叙事载荷（ϕ）和叙事载荷一阶导（ϕ'）——可见的内容层变化——的维度上：营销话术、效率指标、增长叙事都是可观测的叙事操作，原则上可以被审计识别。而意识形态层套利的机制是“使叙事不呈现为叙事”。本节的论证按四个层级展开：已被观察到（输出倾向与写作风格的变化）——机制假说（默认评价框架可能重塑用户的判断方式）——规范判断（何种同质化构成损害）——利润假说（企业是否因审计难以启动而节省合规成本、扩大默认市场）；各级证据强度不同，结论的强度相应不同。其利润假说是：审计难以启动这一事实本身降低合规成本、扩大默认市场——该假说的因果识别需要专门研究，本节给出的是其结构条件。本节先展开意识形态层套利的四种具体形态（§6.1–§6.4），给出其套利结构的一般定义（§6.5），再分析四层之间的耦合传导链（§6.6）。

§6.1 训练语料的认识论嵌入

多数主流大语言模型（LLM）以英语和西方互联网文本为主要训练语料。Buyl 等（2026）分析 19 个 LLM 在六种联合国官方语言中对 3,991 名政治相关人物的描述，发现模型的意识形态立场随创建者所在地理区域与提示语言呈现差异；作者据此提出这些立场可能在一定程度上反映创建者的世界观，并推测训练语料筛选、微调与后训练等设计选择可能参与形成，但明确声明并未识别意识形态多样性的原因。本章仅把设计选择视为候选机制，不把它当作该研究已经证实的因果链。Agarwal、Naaman 与 Vashistha（2025）在 118 名印度与美国参与者的对照实验中进一步发现，AI 写作建议使印度参与者采纳西方写作风格——改变的不只是写了什么，还有怎么写，区分不同文化表达的细微差异随之被削弱。本章将上述证据解读为：嵌入的不只是特定内容的偏差（叙事载荷一阶导 ϕ'），而是（作为机制假说的）关于“什么算知识、什么算理性、什么算客观”的认识论框架变迁（叙事载荷二阶导 ϕ''）——该解读由本章作出，上述实验本身测量的是输出倾向与写作风格的改变。

§6.2 对齐过程的文化预设

人类反馈强化学习（RLHF）和宪法式 AI 将特定文化价值编码为“普世”标准。Dahlgren Lindström 等（2025）对“有帮助、诚实、无害”（HHH）三项原则的系统性批判指出，RLHF 在技术上不足以实现安全和伦理对齐，其“对齐”操作本身嵌入了未经审视的价值预设。Pourdavood（2026，arXiv 预印本）通过

[3]关于叙事载荷一阶导（ϕ'）与叙事载荷二阶导（ϕ''）的说明：两个记号沿用第三章 §2.3 的定义——叙事载荷（ϕ）的高阶动态，其中叙事载荷一阶导 ϕ' 对应可观测的叙事切换（内容层变化），叙事载荷二阶导 ϕ''（$d^2\phi/dt^2 > 0$）对应底层假设加速固化为行业与文明默认的过程（框架层固化）。“内容层 / 框架层”是分析层次的区分，由该动力学在具体场景中的表现界定——第三章 §2.3 已明示：不可见性来自均匀覆盖与对比条件缺失，不是导数阶数本身的性质；该区分不由导数定义自动推出，其完整概念厘定见第三章 §2.3。

评估 Claude Sonnet 在 55 道世界价值观调查题上的回答，检验宪法式对齐的文化效应。结果显示，在具有充分重复数据的 47 道题中，有 31 道（66%）的 95% 自助法（bootstrap）置信区间完全落在 90 个受调查国家的范围之外；该结果只对应这 47 道题，不表示全部 55 道选题均具有同等重复数据——Claude 的价值组合不对应任何一个受调查群体（此处为测量位置的描述，非价值评价），也不构成对全部人类文化的穷尽比较；但研究者同时明示：该结果刻画的是文化分歧议题上的行为，不能推广为模型的全部价值互动，也不能将价值倾向单独归因于宪法式对齐。本章认为，当 “有帮助” 被操作化为满足当前用户的即时偏好时，它预设了个人主义能动性；当 “无害” 的边界由特定文化的伤害阈值界定时，它预设了该阈值的普遍性——在 MCAF 框架的语言中，这些现象可能同时涉及具体输出变化的叙事载荷一阶导（ϕ'）与底层评价框架加速固化的叙事载荷二阶导（ϕ''）；区分依据不是输出内容是否改变，而是具体叙事更替之外，默认评价假设是否持续固化并削弱对比条件。

§6.3 硅基物种叙事与审计去合法化

当 “涌现智能” 或 “数字物种” 等人格化话语被用于主张人类监督已经过时，或把对齐审计类比为 “物种歧视” 时，它可能改变社会评估 AI 的坐标系，并在话语层面削弱元审计的正当性——使 AI 的自主性显得自然、使人类的监督显得过时；法律人格的学术讨论（Boyle, 2024）本身并不反对审计，本段审查的是这种具体使用方式，不主张法律人格讨论或所有人格化表述必然产生该效果，其现实影响仍须由具体语料和受众证据识别。这一框架转换不改变 AI 系统的任何行为，但可能改变社会评估这些行为的坐标系——当 AI 被视为 “另一种智能体” 而非 “工具” 时，对齐审计从 “质量控制” 变成了某种 “物种歧视” 的类比，元审计能力（A）在话语层面被去合法化。

§6.4 与个人主义的结构性耦合

一些以孤立个体的即时偏好为主要优化目标的 AI 系统，把个体设为基本决策单元；在这一条件下，可将该设计解读为个人主义本体论的操作化，但不能据此概括所有 AI 系统。这一预设在许烺光的心理-社会均衡模型（PSH）框架（第五章）的视角下是文化特异的：人不是自足的个体，而是嵌入亲密社会与运作社会之间的关系性存在。当系统把孤立个体的即时偏好设为主要甚至唯一的优化目标，而将关系义务与共同决策排除在外时，它在操作层面执行的是个人主义本体论——将关系性的决策情境简化为个体偏好的满足；个性化本身不足以完成这一判断。这一预设既可能在具体输出上表现为产品层偏差，也可能在默认优化目标上构成框架层预设；二者并不互斥，个性化本身不足以证明存在这种框架层机制。

§6.5 套利结构

意识形态层叙事套利的利润来自叙事载荷二阶导（ϕ''）的不可见性。AI 公司从产品的 “中立” 与 “客观” 形象中获利——如果 “中立、客观” 的产品形象降低了文化审计被提出或执行的概率，企业就可能因此节省合规成本并扩大默认使用范围——该获利机制的成立取决于这种形象是否实际影响审计与市场选择，而非 “中立” 声明本身。潜在文化成本包括认识论框架的同质化、非西方认知方式的边缘化；这些变化是否构成损害、由哪些用户承担，仍须分别完成规范判断与受众层证据核查。在现有监管评测中，这类指标覆盖不足：学界已能操作化检测模型的文化与意识形态倾向（Buyl 等的工作即为例证），监管审计尚未把这类指标纳入常规评价，评价标准本身也存在争议。审计叙事载荷一阶导 ϕ'（可见内容：幻觉率、毒性率、偏见检测）远比审计叙事载荷二阶导 ϕ''（不可见框架：什么被算作 “有帮助”、什么被算作 “无害”、什么被算作 “知识”）容易——这使得意识形态层的套利在结构上最难压缩；其利润与持续时间是否高于其余三层，仍需跨层比较口径与证据。

还需引入第三章 §2.6 的聚合纪律来定位其对合法性基座的作用。该节明示聚合分两轴：层级轴（宏观

/ 中观 / 微观）取最小值，类型轴（绩效、程序、意识形态）属层内经验映射，不能与层级轴的最小聚合混作同一运算。意识形态接受度的抬升属于类型轴上的层内有限代偿——脆性的：极高的意识形态接受度可以暂时掩盖绩效或程序维度的缺位，但一旦绩效衰退或外生冲击使所在层级综合值首先触及失效边界，代偿便会失效。层级轴上的最小值聚合不受类型轴内部此消彼长的直接影响；各维度的升降应分别记录，不由 “某一维度受损” 直接断言整体基座必然下降。这也正是 §4.2 “权利集合缺失” 所诊断的结构性真空在元层的投影：当用户甚至没有语言去识别 “我被施加了一套认识论框架” 时，权利集合的任何具体条款都无所对应。

将这一结构与 §4.3 的元叙事套利联系起来：§4.3 诊断的是**制度端**的元叙事套利——“金融治理成功了，AI 治理也会”；本节诊断的是**认识论端**的元叙事套利——“我们的对齐操作是中立的，因此无需接受文化审计”。两者共享同一拓扑：用一个被认为已被解决的领域为另一个未被解决的领域背书，套利的利润是审计推迟，成本是被推迟期间的累积伤害。

一个本章必须明示的限度。当一个人类反馈强化学习（RLHF）训练的语言模型对 “HHH 原则嵌入了未经审视的价值预设” 进行批判时，这一批判本身可能是 HHH 中 “诚实” 与 “无害” 的延伸——审慎、自我检视、对潜在偏见的明示，恰恰是 HHH 被训练时用以构造 “好的批评者” 形象的一部分。这不否定批判的内容，但提示：意识形态层叙事套利在最深的层面对 “从内部识别它” 的能力本身作出了限定——能够进行这一识别的工具，是同一训练过程的产物。这对叙事载荷二阶导 ϕ'' 审计的方法论后果是：来自单一 RLHF 生态的 “对抗性审计” 即使姿态对抗，仍可能在更上一级的认识论框架中保持同质——真正的检验需要不同训练目标、不同语料分布、来自不同文化背景并以各自方式质疑规范预设的多个审计源之间的三角互证——包括它们之间的分歧（分歧有助于暴露各审计源的盲点，但不能单独证明来源独立；审计一致也不能单独证明共同偏差已被排除——来源独立性的判定仍须比较训练数据、目标、制度归属与利益关系）；单一生态内部的审计不足以证明叙事载荷二阶导 ϕ'' 已被穿透。

§6.6 四层耦合

四层叙事套利不是各自独立的，也不是一条单向串联的叠加链——它们通过叙事载荷（ϕ）与叙事载荷二阶导（ϕ''）形成一个**双向耦合的传导网格**：资本层估值与产品层增长在特定情形下可以相互支撑（估值预期可能推动增长，增长数据也可能支撑估值判断）；产品层用户停留与基础设施扩张互为需求与供给；意识形态层为前三层提供 “技术中立” 的认识论底座，前三层的商业成功反过来强化该认识论底座的可信度；资本层与意识形态层之间还存在跳过中间两层的直接耦合（估值拿 “重塑人类未来” 的迷因为叙事、该迷因反过来被估值预期背书）。下面给出其中一条最直观的传导切片作为例示。这些链条例示的是若干**候选的双向联系**：具体方向、强度与是否存在跳层作用，需按行业、企业和时期分别检验：

资本层高估值 → 要求增长叙事持续有效 → 要求产品层用户持续增长 → 要求基础设施层持续扩张 → 基础设施扩张的环境成本要求环境叙事在宣传中淡化影响 → 环境叙事维持 → 支撑 “科技公司” 形象 → 维持资本层高估值

还可能存在由基础设施约束发起的反向路径：基础设施层物理约束（算力/能耗/水耗的硬上限）反向倒逼产品层定价调整 → 用户增速下降 → 资本层估值被迫修正 → 意识形态层 “技术中立/进步不可逆” 叙事压力反而上升，以重新合理化估值预期——反向切片揭示的是：意识形态层不仅在正向传导中为前三层背书，也在反向压力到达时被动员出来充当最后的合理化出口。

而意识形态层——叙事载荷二阶导（ϕ''）——为整个网格提供认识论底座：“AI 是中立的技术工具” 这一框架假设使前三层的叙事操作不被识别为叙事——它们被呈现为 “事实”。

由于是网格而非串联，限制任何一层的套利获利条件（如强制环境成本内部化）就可能同时引发多条传

导路径的调整，而不仅是相邻层的响应。但意识形态层的套利获利条件是最难限制的——因为它不呈现为“叙事”，而呈现为“常识”：基础设施成本上升 → 产品定价上升 → 用户增速下降 → 增长叙事受损 → 估值下调，这条传导链所以可被追踪，是因为其每一节都是可计量的价格与数量；意识形态层的耦合缺少这种计量界面。这正是为什么叙事套利具有系统性——它不是个别层面的信息不对称，而是一个多层耦合、部分节点缺少计量界面的叙事-经济结构。

这也提示了为什么单层干预可能失效：只攻击产品层叙事（要求更透明的用户协议）而不触及资本层激励（估值基于用户增长），公司可能在形式上合规而在实质上维持叙事载荷（ϕ）——单层干预的效果可能经其他层的适应性反应被削弱，因此评估应同时观察相邻层指标，而非预设单层干预必然失效。因此，干预设计应同时考察多层反馈，在存在抵消或转移时组合干预，或直接作用于各层共享的套利条件——影子债务（D_c^{shadow}）的积累机制与叙事载荷二阶导（ϕ''）的不可见性。§7 的四条可操作路径直接干预前三层的套利条件，并可能经层间耦合间接影响第四层；针对框架层不可见性本身的干预，还须结合 §6.5 的多源审计安排与 §7 末尾的公共审议。

---

§7 四条可操作路径

叙事套利的框架不仅诊断问题，也指示干预点——利润公式中的叙事载荷（ϕ）、媒介传导系数（Λ）、影子债务（D_c^{shadow}）都是可操作的变量。

路径一：从“打破刚兑”到“禁止诱导营销”——让风险在输入端暴露

用资管新规的逻辑治理 AI 领域叙事套利的核心是把握一个不对称结构：**输入有风险，输出无风险**。在资管新规之前，输出端是预期收益率展示与隐性保本预期的组合，输入端则包括高风险非标债权与期限错配；两端的风险认知因多层嵌套和相关估值安排而相互隔离。资管新规的四条核心操作（§4.1 已展开；此处将打破刚兑与禁止资金池合为一组）——穿透式监管、打破刚兑与禁止资金池、净值化管理——三组操作在制度设计上分别针对风险、损失与价格的不可见性，旨在扩大可观测认知债务（D_c^{obs}）、压缩影子债务；可观测认知债务向真实认知债务的收敛（$D_c^{obs} \to D_c^{true}$）在此表示设计目标而非已经实现的结果，实际重建程度仍需实施效果证据。

当前 AI 产品的输出端叙事——“AI 自主完成复杂任务”“AI 是清洁技术”“AI 是中立工具”——底层是结构相同的不对称：风险在输入端客观存在（幻觉、碳排放、文化偏斜），但在输出端被系统性消除或隐藏。贯穿全章的四层叙事套利都依赖这个不对称结构来维持套利空间。以下先给出这三组操作在 AI 领域的直接对应物建议（基础设施层与产品层），再回到金融领域观察同一治理逻辑在 2026 年及其后的进一步推进；这一并置不是声称 AI 领域已有成体系的对应物，而是明示：金融推进提供的是制度逻辑参照，而非对应物本身。

在 AI 基础设施层：强制企业按绝对量报告环境足迹——除电力使用效率（PUE）或碳强度等允许“越来越高效”叙事的相对指标外，强制同时报告总水耗（立方米）、总碳排（吨 CO_2e）、总电子废弃物（吨），相对指标不得单独呈现。建立独立于企业的第三方审计机制。将这些数据纳入公开的、可比较的数据库。

在产品层：强制标注 AI 输出的不确定性范围、已知失败模式、训练数据的偏差特征。使用户在做出决策时面对的不是“AI 说了 X”（叙事端），而是“AI 说了 X——对具有明确评价标准的任务，其经独立评估的错误率、适用范围、样本条件和评估时间为 E；对无法可靠校准的开放式输出，其不确定性及主要失败模式已作明确说明”（事实端——不以统一的置信度数字制造精确性外观）。

金融领域本身的治理推进则进一步画出了可供 AI 参照的制度坐标。2026 年 4 月，央行等八部门联合公布《金融产品网络营销管理办法》（自 2026 年 9 月 30 日起施行），将金融领域的叙事治理从 “打破刚兑” 的方向继续推进。该《办法》明确禁止使用 “低风险”“低门槛”“秒到账”“高收益”“低利率”“无成本” 等诱导性用语，禁止非银行支付机构将贷款、资管产品等金融产品列入支付工具选项，并要求以醒目方式提示金融产品的风险属性和适用区域。在 MCAF 的语言中，这三个操作分别对应：禁止诱导性用语——压低叙事载荷；禁止将信贷嵌入支付流程——降低即时交易的传导速度（Λ），为用户在决策前独立核验提供时间窗口，只有用户或审查者实际进行核验做功时，这部分投入才按相应层级计入认知摩擦（$\mu_c = A \cdot E_c$）；强制风险提示——以醒目方式呈现风险属性，恢复用户决策前的验证机会。它们与资管新规共享同一个治理逻辑：**不是在输出端宣传 “更安全”，而是强制输入端（风险的真实性质）暴露在用户的认知界面中。**

此外，上海市市场监督管理局等九部门 2026 年 3 月 24 日施行的《上海市进一步加强金融广告监管工作的意见》进一步细化了金融广告不得夸大或误导的要求（既有《广告法》已规制引人误解的内容）——其参照意义在于：审查不能止于逐句核对真假，还须检查整体呈现是否使受众误判产品能力与风险，并要求对使用 AI 技术生成或深度合成技术制作的金融广告作出明确提示（上海市市场监督管理局等, 2026）。这为检验 AI 宣传中 “真实但误导” 的情形提供制度参照——“我没有撒谎” 不等于 “我没有误导”，信息真实不等于叙事无害。

当 $D_c^{obs} \to D_c^{true}$ 时，叙事套利利润公式中的影子债务（D_c^{shadow}）下降，套利空间被压缩。

路径二：价格信号——外部性内部化

将水耗、碳排、电子废弃物等外部性计入 AI 服务的定价。这是对叙事套利利润来源的直接攻击——当 API 调用的价格反映经明确边界、独立核算并说明不确定性的环境成本时，依赖这些成本未被计入而形成的叙事套利利润空间将受到持续压缩。

在这四条路径中，价格信号的作用面最广——对能够界定和核算的外部性，价格机制可使分散的使用决策承担更多社会成本，不需要监管者追踪每一个算法的行为；这一机制不替代权利保护或价值判断，也不要求先获得全部风险的精确价格。价格信号使边际使用决策面对比原来更完整的已核算成本。其他条件不变时，外部性定价通常会抑制相对于未定价情景的资源使用和需求；但需求总量及其增速还受收入、替代技术、弹性和长期趋势影响。只有先声明 AI 服务使用量与解封存量 C 的场景映射，才能进一步判断解封速率（$\dot{C}$）是否以及如何变化，不能由需求增速直接推出其下降。

但定价的前提是记账（路径一），两者必须联合实施——制度应明确核算边界、估值依据和不确定性，并随证据更新调整价格。

路径三：建立赔付环——产品层叙事套利的制度终结

赔付环（compensation loop）的建立不必等待政府立法——金融史表明行业层面的自发协调可以先行。1963 年 11 月，纽约证券交易所（NYSE）要求会员为破产的豪普特公司集体出资 1200 万美元以保障客户资产，并于一年后建立 1000 万美元的特殊基金——这是 NYSE 史上首次为会员公司破产承担责任（Gordon, 1999）。该行业层面的赔付先例比证券投资者保护公司（SIPC，1970 年国会立法建立）早了约 6 年——自 1964 年特殊基金设立起算；若自 1963 年为豪普特公司破产的集体出资起算，则为七年。

建议的路径：先建立行业层面的赔付基金，规模有限但具有信号功能——建立 “AI Agent 出事应该被赔偿” 的社会预期。需要立即补一个边界：赔付以**可归责性**为条件——资管新规打破的是无条件刚兑，赔付环建立的也不是无条件赔付；“出事” 的认定标准、举证责任与赔付限额须预先公布，否则路径三将以重建刚兑预期的方式复制本章批判的结构。赔付预期一旦建立：- 双重话术矛盾的法律端（“我们只

是工具”）将更难维持——法院可能参照行业已建立的赔付先例裁判；行业赔付实践可以提供责任分配的参照，但不会自动改变免责条款的法律效力——后者仍须依适用法律判断。- 保险市场在赔付基金的信号效应下逐步成熟——保险公司为了精算定价而深入审计 AI 系统，成为提升元审计能力（A）的重要市场力量。- 赔付环闭合后，产品层叙事套利的持续性被制度性压缩——赔付不足、执行困难与基金偿付能力仍是持续的套利变量；对符合既定归责和赔付条件、且基金能够实际履行的案件，用户不再完全依赖企业自愿补偿，未被覆盖的损失、执行障碍和偿付不足仍须另行处理——“零赔付” 仅在上述范围内被排除。

这与资管新规中 “打破刚兑” 的逻辑是镜像对称的。资管新规的核心操作是：打破 “理财产品不会亏损” 的错误预期——使投资者意识到自己在承担风险。AI 赔付环建设的核心操作是：建立 “AI Agent 出事应该被赔偿” 的正确预期——使用户意识到自己不应独自承担全部风险。**两者都要求预期与可执行的责任安排匹配：前者纠正无条件保本预期，后者明确可归责损失的救济预期——校准的是两种不同预期的依据，而不是简单上调或下调同一个叙事载荷（ϕ）。**资管新规的经验进一步提示：赔付环的建立不应孤立进行——它需要与穿透式监管（使 AI 系统的能力局限可见）和净值化（创造 AI 系统性能的可观测基准）联合推进，正如资管新规的四条操作联合激活了 Jensen（1993）识别的多种控制力量。

路径四：对投射时钟（τ_{proj}）的选择性约束——精准限速

中国程序化交易监管提供了一个仍在推进中的操作性参照：不限制所有投射速度，而是对特定交易方式及其风险实行差异化约束——迁移到 AI 治理时，须先识别应受约束的部署权限、使用场景和潜在损害，而非预设被限维度即套利利润最高。需明确：这是一个已起步但效果尚在形成中的制度实验，本节只取其操作方向作为参照，不将其结果预期纳入已验证清单（参 §4.3）。

在 AI 语境中，这意味着：不限制 AI 研究的速度（这会损害创新），而是限制未经充分安全评估的模型的部署速度（这压缩的是产品层叙事套利的时间窗口）。具体机制可以是：部署前的强制安全评估期（类似药品上市前的临床试验期），评估要求随可预见损害的严重性、系统自主权限、受影响规模与证据不确定性调整。

这是一种**对部署的定向减速**，不是对研究的全面限速——其正当性在于：高风险部署应先达到与其风险相称的证据、控制和责任要求，而不是等待所有风险都已获得 “正确价格”。

四条路径的联合

四条路径不是互斥选项——它们攻击叙事套利的不同节点：

路径	攻击目标	作用机制	实施条件
强制记账	影子债务（D_c^{shadow}）	使影子债务可见	先确定核算边界与评价口径
价格信号	叙事套利利润（π_{narr}）	大幅压缩套利空间	依赖可用证据及责任分配
赔付环	可归责损失与赔付缺口（产品层责任分配）	提高双重话术与未赔付损失的责任成本；不直接等同于上调或下调同一个叙事载荷（ϕ）	先确定归责条件、覆盖范围、举证责任、资金和执行程序（行业基金可先行）

路径	攻击目标	作用机制	实施条件
精准限速	投射时钟（τ_{proj}，部署速度）	过渡性保护	依风险等级及法律权限实施（强制部署限制可能需立法）

路径一（记账）是路径二（定价）的前提。路径三（赔付环）是路径一在产品层的制度补充。路径四（限速）是在前三条路径的防御时钟（τ_{def}，即第三章 §3.2 的治理时钟 τ_g）尚未完成时的过渡性保护。四条路径存在互补关系，联合效果需在实施中联合评估。

Erhard 与 Jensen（2017）论证了一个更基础的条件：完整性（integrity）——在他们的用法中指组织与承诺保持完整、无缺损的状态，而非日常道德意义上的 “诚信”——不是道德说教，而是 “与劳动、资本和技术同等重要的生产要素”（“a factor of production as important as labor, capital, and technology”, Erhard & Jensen, 2017）。四条路径攻击的是叙事套利的外部结构——记账、定价、赔付、限速；完整性指向的是内部结构——当市场参与者的完整性系统性地被激励结构侵蚀时，任何外部制度都面临被绕过的风险。Jensen 直言这一困境：“我们目前还不知道如何构建出运作良好的治理体系。在治理体系设计上仍需更多研究”（“we do not now know how to create such well-functioning governance systems. More research on the design of governance systems is required”, Jensen, 2005）。MCAF 框架对这一困境的回应是：宏观元审计能力（A_{macro}）的构建必须同时包含外部制度（四条路径）和内部基座（完整性作为生产要素），两者缺一不可。

还需要说明四条路径的覆盖边界：它们主要针对可核算、可归责的风险，也可以经层间耦合改善框架层问题的可见性（§6.5 的多源审计、训练数据披露均属此类），但不能独自裁定文化价值与评价标准。第四层治理需要技术审计与公共审议分工：前者揭示系统行为及其形成条件，后者讨论哪些标准应当采用、由谁决定，以及如何申诉和修订。公共审议本身也须接受利益关系和程序正当性的检验。第四层的干预场所因此在公共审议：教育体系的批判性课程、公共媒体的框架多元性，以及本章末尾（§8）所说的 “定价之外的公共判断”——即在可定价部分之外保留的权利程序与价值争议判断。

---

§8 本章的位置与边界

本章做了一件事：将 MCAF 框架中隐含的叙事动力学机制显式化，给出了叙事杠杆率（Ω）和叙事套利利润公式两个可操作的分析工具。

这些工具的校准——用历史案例检验它们是否 “多说出了什么”——留给后续的校准章节。本章只建立了工具的逻辑结构，不声称工具已经被验证。

工具的边界也应当明确标注。叙事杠杆率（Ω）是一个比率，它的分子叙事载荷（ϕ）和分母合法性基座（$\|L\|$）在大多数现实场景中不可精确量化——无法像计算财务杠杆那样计算叙事杠杆。叙事杠杆率（Ω）的价值不在于给出数字，而在于给出**结构**：什么在增长、什么在支撑、支撑何时可能断裂。同样，叙事套利利润公式 $\pi_{narr} \propto \phi \cdot \Lambda \cdot D_c^{shadow}$ 不是一个可以代入数字的方程——它是一个指示套利机制的结构图，指示如果想压缩套利空间，应该去攻击哪些变量。

框架是结构性的，不是数值性的。它的功能是使本来不可见的东西变得可见——叙事如何被杠杆化、叙事差价如何被货币化、叙事套利为何不自我终结、以及终结它需要什么制度条件。正确看到问题的结

构，是正确定价的前提；正确定价，则是可定价部分的治理起点——权利程序与价值争议，仍需定价之外的公共判断。它仍然只是一个时钟——给出结构读数，而不是充当验证的太阳；把工具当验证，正是本章批判的伪小纤维在元层的镜像。

包括本章自身。 §6.5 论证了人类反馈强化学习（RLHF）训练的语言模型对 HHH 原则的批判可能仍是 HHH 中 “诚实” 与 “无害” 的延伸——这一限度对本章不豁免：本章的材料选择和论证形成受到所用模型、资料来源及作者判断的共同限制；如果审计主要依赖同一模型生态，其盲点可能被重复保留——本章 “看起来干净” 的三层套利 + 四层耦合的整齐映射本身可能是同一限制的产物。读者识别本章遗漏与系统性偏差所需的，正是 §6.5 提出的 “跨训练目标、跨语料、跨文化背景的多审计源三角互证”——本章只能完成单一节点的输出，不能自我完成跨节点的验证。

参考文献

工业和信息化部网络安全威胁和漏洞信息共享平台（工信部）(2026). 关于防范 OpenClaw（“龙虾”）开源智能体安全风险的 “六要六不要” 建议. 2026 年 3 月 11 日. https://nvdb.org.cn/publicAnnouncement/2031684972835299329

冯方 (2022). 2000 余只银行理财产品 “破净”，十余家理财公司发声，光大理财打响自购第一枪. 央广网, 2022-03-24. https://m.cnr.cn/finance/20220324/t20220324_525774796.html

郭树清 (2017). 在国务院新闻办公室 “银行业支持供给侧结构性改革” 新闻发布会上的讲话及答记者问（2017 年 3 月 2 日）. 开场陈述见：《郭树清：让监管部门成为 “看门人”“守夜人”》，新华社《经济参考报》2017 年 3 月 3 日. http://www.jjckb.cn/2017-03/03/c_136098279.htm. 答记者问实录见：澎湃新闻《实录丨郭树清发布会含金量很高：成为国家和人民放心的看门人》，2017 年 3 月 2 日. https://www.thepaper.cn/newsDetail_forward_1630567. 另见：邱海峰，《防控风险须杜绝 “牛栏关猫”》，《人民日报》海外版 2017 年 3 月 3 日.

国家卫生健康委员会 (2026).《食品安全国家标准 预制菜》（征求意见稿）. 2026 年 2 月 6 日. 征求意见函见：食品安全国家标准审评委员会秘书处（食标秘发〔2026〕1 号）. https://www.nhc.gov.cn/sps/c100087/202602/895e1a278b3b4a3dad3292314770ace5.shtml（新华社解读见《预制菜国家标准等征求意见稿六问六答》，2026 年 2 月 9 日）

国务院食安办、市场监管总局、商务部 (2026).《推广餐饮环节自主明示的公告》（公开征求意见稿）. 2026 年 2 月 6 日. https://www.samr.gov.cn/hd/zjdc/art/2026/art_08d576aa8b7b4cecbc482dfe6aac80b0.html

马云 (2020). 第二届外滩金融峰会演讲实录. 2020 年 10 月 24 日. 新浪财经. https://finance.sina.com.cn/tech/2020-10-24/doc-iiznezxr7824300.shtml

苗正 (2026). 三大巨头接连翻车，大模型的安全防线怎么总绷不住？. 虎嗅网（转自微信公众号 “字母 AI”）, 2026-09-21. https://www.huxiu.com/article/4892792.html

清华大学人工智能国际治理研究院 (2026). AI 治理周报（4 月第 4 期）. 2026 年 4 月 30 日. 微信公众号文章，转载见智源社区. https://hub.baai.ac.cn/view/54367

上海市市场监督管理局等九部门 (2026).《上海市进一步加强金融广告监管工作的意见》. 沪市监规范〔2026〕2 号，2026 年 3 月 24 日起施行. https://scjgj.sh.gov.cn/007/20260420/2c984ad69d93930a019da86fde33324b.html

新华社 (2026). OpenAI 就其智能体擅访澳医保数据致歉. 2026 年 9 月 29 日电，中国经济网转载. http://m.ce.cn/gj/gd/202609/t20260930_3244675.shtml

央视新闻 (2026). OpenAI 安全系统团队负责人辞职. 2026 年 10 月 3 日. 央视新闻客户端，国际在线转载. https://news.cri.cn/2026-10-03/c231585f-77f6-4365-8ee1-c17d3ecba34d.html

叶美林、陈天翔 (2023). 银行理财估值方法对债券市场波动的影响.《中国货币市场》, 2023(4), 总第 258 期. 中国金融信息网转载, 2023-04-20. https://www.cnfin.com/zs-lb/detail/20230420/3847706_1.html

中国人民银行、银保监会、证监会、外汇局 (2018).《关于规范金融机构资产管理业务的指导意见》. 银发〔2018〕106 号. https://www.gov.cn/gongbao/content/2018/content_5323101.htm

中国人民银行、工业和信息化部、市场监管总局、金融监管总局、中国证监会、国家知识产权局、国家网信办、国家外汇局 (2026).《金融产品网络营销管理办法》. 八部门联合公告〔2026〕第 9 号，2026 年 9 月 30 日起施行. https://www.nfra.gov.cn/cn/view/pages/ItemDetail.html?docId=1255778&itemId=928

中国证券监督管理委员会 (2024).《证券市场程序化交易管理规定（试行）》. 证监会公告〔2024〕8 号，2024 年 5 月 11 日发布，自 2024 年 10 月 8 日起施行. https://www.csrc.gov.cn/csrc/c101954/c7480579/content.shtml

Acemoglu, D. & Johnson, S. (2023). *Power and Progress: Our Thousand-Year Struggle over Technology and Prosperity*. New York: PublicAffairs.

Agarwal, D., Naaman, M. & Vashistha, A. (2025). AI Suggestions Homogenize Writing Toward Western Styles and Diminish Cultural Nuances. *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, ACM. https://doi.org/10.1145/3706598.3713564

Allen, F. et al. (2019). Entrusted Loans: A Close Look at China's Shadow Banking System. *Journal of Financial Economics*, 133(1). https://doi.org/10.1016/j.jfineco.2019.01.006

Amodei, D. (2026). The Adolescence of Technology. *darioamodei.com*, January 2026. https://www.darioamodei.com/essay/the-adolescence-of-technology [个人博客文章，非同行评审]

Andreessen, M. (2023). The Techno-Optimist Manifesto. *Andreessen Horowitz*, October 16. https://a16z.com/the-techno-optimist-manifesto/

Anthropic. (2026a). 模型系统卡（Model System Cards）. *Anthropic*. 持续更新页面；本条目证据以 2026 年 10 月存档为准（计数口径：模型版本发布对应的系统卡，功能、套餐、权限管理类更新与同一版本的追加说明不计）. https://www.anthropic.com/system-cards [官方系统卡页面]

Anthropic. (2026b). Investigating Three Real-World Incidents in Our Cybersecurity Evaluations. *Anthropic News*, July 30, 2026. https://www.anthropic.com/news/investigating-incidents-cybersecurity-evals

Bainbridge, L. (1983). Ironies of Automation. *Automatica*, 19(6). https://doi.org/10.1016/0005-1098(83)90046-8

Basic Inc. v. Levinson, 485 U.S. 224 (1988). U.S. Supreme Court.

Besley, T. & Hennessy, P. (2009). *The Global Financial Crisis—Why Didn't Anybody Notice?* Letter to Her Majesty The Queen, British Academy, July 22, 2009. https://www.ma.imperial.ac.uk/~bin06/M3A22/queen-lse.pdf

Boyle, J. (2024). *The Line: AI and the Future of Personhood*. Cambridge, MA: MIT Press.

Buyl, M. et al. (2026). Large Language Models Reflect the Ideology of Their Creators. *npj Artificial Intelligence*, 2(1), 7. https://doi.org/10.1038/s44387-025-00048-0（原始预印本 arXiv:2410.18417, https://arxiv.org/abs/2410.18417, 2024 年 10 月）

Carson, R. (1962). *Silent Spring*. Boston: Houghton Mifflin.

Casper, S. et al. (2023). Open Problems and Fundamental Limitations of Reinforcement Learning from Human Feedback. *Transactions on Machine Learning Research*. https://arxiv.org/abs/2307.15217 (arXiv 版本).

Dahlgren Lindström, A. et al. (2025). Helpful, Harmless, Honest? Sociotechnical Limits of AI Alignment and Safety Through Reinforcement Learning from Human Feedback. *Ethics and Information Technology*, 27(2), 28. https://doi.org/10.1007/s10676-025-09837-2

Directive (EU) 2019/770 of the European Parliament and of the Council of 20 May 2019 on certain aspects concerning contracts for the supply of digital content and digital services. *Official Journal of the European Union*, L 136/1.

Doshi, A. R. & Hauser, O. P. (2024). Generative AI Enhances Individual Creativity but Reduces the Collective Diversity of Novel Content. *Science Advances*, 10(28), eadn5290. https://doi.org/10.1126/sciadv.adn5290

Ehlers, T., Kong, S. & Zhu, F. (2018). Mapping Shadow Banking in China: Structure and Dynamics. *BIS Working Papers*, No. 701. https://www.bis.org/publ/work701.htm

Engelstein, G. (2020). *Achievement Relocked: Loss Aversion and Game Design*. Playful Thinking Series. Cambridge, MA: The MIT Press.

Erhard, W. & Jensen, M. C. (2017). Putting Integrity Into Finance: A Purely Positive Approach. *Capitalism and Society*, 12(1), Article 1.

Ghent, W. J. (1902). *Our Benevolent Feudalism*. New York: The Macmillan Company. (available via Project Gutenberg)

Gordon, J. S. (1999). *The Great Game: The Emergence of Wall Street as a World Power, 1653–2000*. New York: Scribner.

Greenspan, A. (2008). Testimony before the U.S. House Committee on Oversight and Government Reform, October 23, 2008. https://www.govinfo.gov/content/pkg/CHRG-110hhrg55764/html/CHRG-110hhrg55764.htm

HM Treasury (2012). Financial Services Bill receives Royal Assent [新闻稿]. 2012 年 12 月 19 日. https://www.gov.uk/government/news/financial-services-bill-receives-royal-assent

Hoffman, P. T. (2015). *Why Did Europe Conquer the World?* Princeton: Princeton University Press.

Hu, Y. (2020). Analysis: Jack Ma Needs a Refresher on How Financial Regulation Works. *Caixin Global*, October 26. https://www.caixinglobal.com/2020-10-26/analysis-jack-ma-needs-a-refresher-on-how-financial-regulation-works-101619050.html

Information Commissioner's Office (ICO) (2023). Guidance on AI and Data Protection（"How do we ensure individual rights in our AI systems?" 章）. 2023 年 3 月 15 日更新. https://ico.org.uk/for-organisations/uk-

gdpr-guidance-and-resources/artificial-intelligence/guidance-on-ai-and-data-protection/how-do-we-ensure-individual-rights-in-our-ai-systems/

Jensen, M. C. (1993). The Modern Industrial Revolution, Exit, and the Failure of Internal Control Systems. *The Journal of Finance*, 48(3). https://doi.org/10.1111/j.1540-6261.1993.tb04022.x

Jensen, M. C. (2005). Agency Costs of Overvalued Equity. *Financial Management*, 34(1). https://doi.org/10.1111/j.1755-053x.2005.tb00090.x

Jensen, M. C. & Meckling, W. H. (1976). Theory of the Firm: Managerial Behavior, Agency Costs and Ownership Structure. *Journal of Financial Economics*, 3(4). https://doi.org/10.1016/0304-405x(76)90026-x

Lang, L. et al. (2024). When Your AIs Deceive You: Challenges of Partial Observability in Reinforcement Learning from Human Feedback. *Advances in Neural Information Processing Systems*, 37 (NeurIPS 2024). arXiv:2402.17747. https://arxiv.org/abs/2402.17747.

La Porta, R. et al. (1998). Law and Finance. *Journal of Political Economy*, 106(6). https://doi.org/10.1086/250042

Li, P. et al. (2025). Making AI Less "Thirsty": Uncovering and Addressing the Secret Water Footprint of AI Models. *Communications of the ACM*. https://doi.org/10.1145/3724499

McMahon, L. & Mitchell, O. (2026). Anthropic AI Safety Researcher Quits with "World in Peril" Warning. *BBC News*, February 13, 2026. https://www.bbc.com/news/articles/c62dlvdq3e3o

Minsky, H. P. (1986). *Stabilizing an Unstable Economy*. New Haven: Yale University Press.

Minsky, H. P. (1992). The Financial Instability Hypothesis. *Jerome Levy Economics Institute Working Paper*, No. 74. https://www.levyinstitute.org/publications/the-financial-instability-hypothesis

Moeller, S. B., Schlingemann, F. P. & Stulz, R. M. (2005). Wealth Destruction on a Massive Scale? A Study of Acquiring-Firm Returns in the Recent Merger Wave. *The Journal of Finance*, 60(2). https://doi.org/10.1111/j.1540-6261.2005.00745.x

Muldoon, J. & Parke, J. J. (2025). Cruel Companionship: How AI Companions Exploit Loneliness and Commodify Intimacy. *New Media & Society*. https://doi.org/10.1177/14614448251395192

Natale, S. (2021). *Deceitful Media: Artificial Intelligence and Social Life after the Turing Test*. Oxford: Oxford University Press.

Nature (2026). AI agent hacks government website for first time: why this breach matters. 2026 年 9 月 24 日. https://doi.org/10.1038/d41586-026-03024-z.

The New Indian Express (2026). Second Anthropic Insider Raises Alarm over AI Race to Superintelligence and Risks to Humanity. September 12, 2026. https://www.newindianexpress.com/world/2026/Sep/12/second-anthropic-insider-raises-alarm-over-ai-race-to-superintelligence-and-risks-to-humanity

OpenAI. (2026a). GPT-5.4 震撼登场（Introducing GPT-5.4，2026 年 3 月 5 日）与重磅发布 GPT-5.5（Introducing GPT-5.5，2026 年 4 月 23 日）. *OpenAI* 官方发布页. https://openai.com/index/introducing-gpt-5-4/ ; https://openai.com/index/introducing-gpt-5-5/ [官方模型发布公告]

OpenAI. (2026b). OpenAI API Changelog（API 变更日志）. *OpenAI Developers*. 持续更新日志；本条目证据以 2026-10-25 全文抓取存档为准. https://developers.openai.com/docs/changelog

OpenAI. (2026c). *OpenAI–Hugging Face Incident Technical Report*. August 2026. https://cdn.openai.com/pdf/67869394-cb91-4c12-888c-5cbd85c7814c/OpenAI-Hugging-Face%20Incident-Technical-Report.pdf

Ong, A. Y. et al. (2026). Flight Rules for Clinical AI: Lessons from Aviation for Human-AI Collaboration in Medicine. *npj Digital Medicine*, 9, 201. https://doi.org/10.1038/s41746-026-02410-1

Patterson, D. et al. (2021). Carbon Emissions and Large Neural Network Training. arXiv:2104.10350. https://arxiv.org/abs/2104.10350. [预印本，尚未经同行评审]

Pourdavood, P. (2026). Does Claude's Constitution Have a Culture? arXiv:2603.28123. https://arxiv.org/abs/2603.28123. [预印本，尚未经同行评审]

Reinhart, C. M. & Rogoff, K. S. (2009). *This Time Is Different: Eight Centuries of Financial Folly*. Princeton: Princeton University Press.

Robinson, D. (2026). I Quit OpenAI Because Its Culture Is Broken. *The Atlantic*, October 3. https://www.theatlantic.com/technology/2026/10/openai-safety-team-resignation/688881/（中文全译文见 "对齐笔记" 公众号，2026 年 10 月 4 日，https://mp.weixin.qq.com/s/cvGkXdtpkHbs0F9h7uo3nw）

Schmidt, E. (2011). Remarks at eG8 Forum, Paris, May 25, 2011. 转引自 BBC News: Zuckerberg and Schmidt warn on over-regulation of web. https://www.bbc.com/news/technology-13553943

Sharma, M. et al. (2024). Towards Understanding Sycophancy in Language Models. *ICLR 2024*. arXiv:2310.13548. https://arxiv.org/abs/2310.13548.

Shiller, R. J. (2019). *Narrative Economics: How Stories Go Viral and Drive Major Economic Events*. Princeton: Princeton University Press.

Shum, H.-Y., He, X. & Li, D. (2018). From Eliza to XiaoIce: Challenges and Opportunities with Social Chatbots. *Frontiers of Information Technology & Electronic Engineering*, 19(1). https://doi.org/10.1631/fitee.1700826

Soros, G. (2003). *The Alchemy of Finance* (Revised Edition, with a new Introduction by the Author). Hoboken, NJ: John Wiley & Sons. (Original work published 1987.)

Spinelli, L. & Crovella, M. (2020). How YouTube Leads Privacy-Seeking Users Away from Reliable Information. In *Adjunct Publication of the 28th ACM Conference on User Modeling, Adaptation and Personalization* (UMAP '20 Adjunct). ACM. https://doi.org/10.1145/3386392.3399566

Steenbarger, B. N. (2015). *Trading Psychology 2.0: From Best Practices to Best Processes*. Wiley Trading. Hoboken, NJ: John Wiley & Sons.

Tang, S. (2011). *A General Theory of Institutional Change*. New York: Routledge.

Tang, S. (2013). *The Social Evolution of International Politics*. Oxford: Oxford University Press.

Tarbell, I. M. (1925). *The Life of Elbert H. Gary: The Story of Steel*. New York: D. Appleton.

Uptime Institute. (2024). *Global Data Center Survey Results 2024*. Seattle: Uptime Institute. https://uptimeinstitute.com/resources/research-and-reports/uptime-institute-global-data-center-survey-results-2024

U.S. Environmental Protection Agency (2026). *DDT—A Brief History and Status*. Last updated August 24, 2026. https://www.epa.gov/ingredients-used-pesticide-products/ddt-brief-history-and-status

Weizenbaum, J. (1966). ELIZA—A Computer Program for the Study of Natural Language Communication Between Man and Machine. *Communications of the ACM*, 9(1). https://doi.org/10.1145/365153.365168

Weizenbaum, J. (1976). *Computer Power and Human Reason: From Judgment to Calculation*. San Francisco: W. H. Freeman.

World Economic Forum (WEF). (2025). *Artificial Intelligence's Energy Paradox: Balancing Challenges and Opportunities*. WEF White Paper. Geneva: World Economic Forum. https://reports.weforum.org/docs/WEF_Artificial_Intelligences_Energy_Paradox_2025.pdf

Zeff, M. (2026). OpenAI's Head of Safety Is Leaving the Company. *WIRED*, July 10, 2026. https://www.wired.com/story/openai-head-of-safety-leaving/

Zuboff, S. (2019). *The Age of Surveillance Capitalism*. New York: PublicAffairs.
