《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第九章：人工智能作为时钟的房间

摘要

人工智能在第一章 “时钟的房间” 思想实验中被重新审视：训练数据在本章核心论域中是人类认知与行为的降维产物——就人类生成文本而言，互联网上的许多文章、论文、评论、广告与界面文案都可读作真实社会过程经映射函数（π_i）产生的读数（r_i）；这些读数既可能记录经验，也可能是为塑造后续行为而设计的投射，模型在该论域中不直接接触这些生成条件。在界定这一思想实验的覆盖范围（封闭形式系统不在其内）之后，本章逐层分析三层不可逆在 AI 系统中的具体形态——信息缺失、动态腐蚀、本体论降维——并分析以人类反馈强化学习为代表的偏好驱动后训练如何制造伪小纤维、叙事载荷的二阶变化如何在评价过程中削弱审计的对比条件、Bainbridge 自动化讽刺如何使人类元审计能力被结构性侵蚀。本章末提出四个标注纤维的工程方向，其共同原则不是消除纤维（在第三层不能仅凭读数及其后处理消除），而是让纤维变得可见。

关键词

时钟的房间；人工智能；纤维；人类反馈强化学习；伪小纤维；叙事载荷二阶导；Bainbridge 自动化讽刺；标注纤维

§1 映射

人工智能是一间没有窗户的时钟房间。

这一论断有其论域。本章谈的是以读数代替真实、且当前缺少独立且与任务目标相匹配的判定通道的任务；至于围棋、形式证明这类胜负或真伪由系统内部规则判定的封闭任务，读数与任务所要求的真实属性可以重合，不在本章论述之列（详见 §3）。

训练数据在本章核心论域中可被读作时钟集合。互联网上的许多人类生成文本——文章、论文、评论、广告、营销文案与界面文本——都是特定主体在特定社会情境中生成的映射产物。文本可以是某个真

实状态的记录，也可以是为影响读者行为而设计的叙事；即使是后者，它作为一次说服或设计活动的产物仍有其社会生成条件，但不能被当作其声称内容的独立证据。此处用 $r_i = \pi_i(T)$ 表示文本与生成它的真实过程之间的关系，真实状态（T）按任务可以是经验事件、社会关系、生产者的意图与制度约束，不预设文本忠实描述了它所谈论的世界。模型在该论域中不直接接触这些生成条件，它接触的是读数集合（$\{r_i\}$）；代码、形式数学、虚构文本和合成数据的映射源由 §3 另行区分。

模型的训练过程是在读数集合上学习统计规律——哪些词元（token，模型编码文本的基本单位，其边界由分词方案决定——可为子词、字符或字节片段）在哪些词元之后出现的概率最高。这等于在时钟的房间里做策略一（取统计量）和策略二（找聚类）。模型输出的是训练数据分布的加权统计量——一种精密的、大规模的、但在认识论上和 “看最近的钟报个数” 没有本质区别的操作。

映射结构如下。真实状态（T）指世界的实际状况。人类通过认知和语言将真实状态（T）映射为文本：$r_{\text{human}} = \pi_{\text{human}}(T)$。这个映射本身就是有损的——只能保留经验中可被语言编码的那一小部分。模型在人类读数集合（$\{r_{\text{human}}\}$）上训练，学到的是 $\pi_{\text{model}}(\{r_{\text{human}}\})$——一个映射的映射。模型的输出和真实状态（$T$）之间隔了两层映射函数（$\pi$），每一层都有损。（§2 第三层会把人类映射 π_{human} 进一步拆为 “经验 → 语言 → 互联网文本” 的子映射链；此处的 “两层” 与 §2 的 “多层” 描述同一映射链在不同粒度下的拆解，不为全链规定统一层数。）

预训练目标本身不保证模型能够按来源的实际可靠性组织证据。模型可以利用文本中的来源线索和统计关联，但这些关联是否对应可靠证据，仍须独立检验。若训练和部署过程不保留可核验的来源记录，经过校准的材料与未经校准的材料就可能在输出中被混合使用，而使用者难以追溯。

在第四章的语言中：纤维是逆像——给定一个读数 r，所有能够产生该读数的真实状态集合（$\pi^{-1}(r)$，第四章定义 3）。模型训练是让读数携带更多信息的尝试——在第四章的严格区分中，知识增加收窄的是知识条件下的识别集合，固定映射的逆像本身不因此改变。而第四章命题一表明，非单射意味着至少存在一些读数对应多个真实状态；当模型的 “确定性” 语气超出读数实际排除的不确定性时，它就是第四章定义过的**伪小纤维**——真实纤维没有缩小，但输出在可见维度上被组织得像是已经收敛到单点（详细机制见 §4）。

§2 三层不可逆在 AI 中的展开

第一章 §4 建立了三层不可逆的一般结构，第四章将其形式化为三条核心命题。以下将这三条命题在 AI 系统中逐层展开：第一层（信息缺失）对应命题一（非单射下至少存在多状态读数）；第二层（动态腐蚀）对应命题二（校准收窄识别集合）的失败模式；第三层（本体论降维）对应命题三（已损信息不能仅凭后处理恢复）。（本节的三层展开针对缺乏独立且与任务目标相匹配的判定通道的任务——由 Lean（形式证明助手）核查的证明、由能够完整判定目标行为规约的测试套件验证的代码等封闭任务不在论证范围内，适用范围见 §3。）

第一层：信息缺失。

模型不知道训练数据中的映射函数 π_i。一段文本说 “地球是平的”，另一段说 “地球是球形的”——两个读数。模型不知道哪个读数来自校准过的映射（科学测量），哪个来自未校准的映射（阴谋论）。若模型主要依赖语料中的重复频率而缺少有效的证据区分，多数意见就可能被误当作可靠依据。风险不在于统计规律必然错误，而在于重复与校准没有被区分。

当前的缓解策略——人类反馈强化学习（Reinforcement Learning from Human Feedback, RLHF）（Ouyang et al., 2022）——在第四章的语言中是一种闭环结构（其后果在 §4 形式化为**闭环伪校准**）。此处以 RLHF

为名指代一类**以人类或模型代理偏好为反馈源的后训练方案**；具体方法的换代不改变下文论证的结构性判断。人类标注者对模型输出标注 “好” 或 “坏”。标注者自己也在时钟的房间里——他们的 “好坏” 判断来自自己的映射函数（$\pi_{\text{annotator}}$），该映射是否针对真实状态（T）形成独立校准，取决于其能否接触原始材料、独立结果或其他与任务相关的证据。用一组人的读数去校准模型的读数，只有在这些证据关系成立时才可能超出用钟校准钟；系统内部的交叉验证可以产生内部一致性，但不能保证与真实的对齐；当奖励信号不区分 “事实正确” 与 “表达讨好” 时，后果就是制造**伪小纤维**（§4 展开）。

一些论者把工具使用（网络搜索、应用程序接口（Application Programming Interface, API）调用）看作 “打开了窗户”。这取决于取得的材料是否独立于被评输出，并能对当前判断形成约束。循环转载同一模型的回答，不能替代校准；可追溯的原始文献、实验记录和其他独立材料，则可能提供校准依据。传感器接入也不自动完成校准，还须检查传感器的测量条件、误差和来源记录。原始文献和实验记录也须审计其生产过程与证明对象：一份广告可以证明平台采用了何种说服策略，不自动证明其产品主张为真；一份 A/B 测试记录可以证明某种指标变化，不自动证明用户福利改善。关键不是材料以文本还是数值呈现，而是它能否使当前判断接受独立检验。将同源材料编码为词元，并不产生独立的证据来源；训练与部署过程必须额外保留来源、测量条件和校准记录。

第二层：动态腐蚀。

模型的输出正在成为下一代模型的训练数据。AI 生成的文本被发布在互联网上，被爬虫抓取，进入下一轮训练语料。这是第一章 §4.2（动态腐蚀）描述的映射自我引用的实例——时钟开始更多地指向其他时钟而非真实，真实状态（T）从映射的输入中部分消失。

适应性偏移（δ）同时从两个方向发生。

- 策略性博弈：内容生产者学会了什么样的文本更容易被模型 “认可”（更高排名、更多引用），调整写作风格以适应模型的偏好。模型的统计偏好反过来塑造了训练数据的生成方式。被优化的不是内容的真实性——是内容与模型偏好的匹配度。
- 选择性适应：不适应模型偏好的内容在信息生态中被边缘化——搜索排名降低、推荐频率降低、可见度降低。存活下来的内容不是更真实的内容，是更适配模型的内容。没有人在故意制造虚假信息——系统在选择与模型偏好一致的信息。

两条路径合力制造了一个正反馈闭环：模型的统计偏好 → 塑造内容生产 → 新内容强化模型的统计偏好 → 偏好进一步窄化。在缺乏独立数据来源、来源追踪与多样性维护时，这一闭环可能逐轮收窄信息多样性，而读数间的独立性恰恰是共识能构成校准证据的必要条件——如果所有钟出自同一条流水线，共识扩大不等于校准达成（第一章 §1.3 策略二、§3.6 闭环伪校准）。

递归自训练这一子机制的退化已有实证记录：Shumailov et al.（2024）在 *Nature* 上证明，当生成模型在不加区分地使用模型生成内容进行递归训练时，原始分布的尾部（distribution tail，指训练数据中出现频率较低的罕见模式）会消失并导致模型坍塌（model collapse）。该结果为动态腐蚀中的递归自训练提供直接工程证据，但没有检验内容生产者的策略性博弈或平台的选择性适应，因而不能单独证明上述两条社会反馈路径在每轮都收窄多样性。当 Common Crawl 这类大型公开网络档案（公开发布的大规模网络爬虫数据集，是当前开源大模型训练数据的主要来源之一）本身已持续被 AI 生成文本污染时，治理手段（数据过滤、去重、合成数据检测）面对的风险取决于真实数据的保留方式、合成数据比例与训练程序——该研究记录的是递归自训练条件下的退化，不能直接外推为对治理手段有效性的统一界限；对网络语料的实际风险，还需要测量合成内容的比例、来源与进入训练集的路径。

第三层：本体论降维。

训练数据——人类书面文本的筛选子集——本身就是人类经验的一个降维投影。人类的经验包括身体感觉、情感、空间感知、时间感、社会关系中的微妙判断。其中只有一小部分被编码为文字。文字能表达的比经验窄得多——人能感受到一首音乐却无法用文字完整传达那个感受。模型训练在文字上，因此它的 “世界” 是人类经验经过语言降维后的残余。

这个降维是结构性的（以下不等式中的 dim 表示信息丰富度的**序数比较**，而非严格的拓扑维度或信息论维度——它只是标记每一步都丢失信息这一结构性事实，并不声称存在可精确计算的维度数值）：

$$\dim(\text{人类经验}) > \dim(\text{语言}) > \dim(\text{互联网文本}) > \dim(\text{训练数据})$$

每一步都是有损映射。模型在这条链的末端——它和真实状态（T）之间隔着上述多层降维。除上述表征限制外，自回归生成还存在另一类可测的分布校准问题。先前研究已记录自回归生成中每步熵随生成长度上升的误差累积现象；Cao, Valiant & Liang（2025）测量的是它随模型规模的改善——在 5 亿至 700 亿参数的模型上，两个文本数据集的缩放指数约为 −0.05（代码数据集约为 −0.3，改善较快），意味着规模扩大对文本任务上的这一现象几乎没有缓解。该研究不直接测量前述经验降维链。指令微调在该研究的设置中降低生成熵的代价是升高对数损失（log loss），构成一类对齐税（alignment tax）；是否存在不付出这一代价的程序，须按其假设另行判断。

但同篇论文也在理论上证明：若可获得一个能在测试分布上低误差预测文本前缀未来熵的黑盒预测器，则存在多项式时间的校准程序，可在保持对数损失的同时完成校准。以本书的语言标注这一假设：未来熵预测器本身是一个映射——一只钟；它的低测试误差是经验校准，不是独立于被校准模型的外部锚定，且理论保证的界随该预测器自身的误差而增大。用钟校准钟在特定条件下可以收窄识别集合（第四章命题二），但不等于开窗见太阳。该保证针对所定义的生成分布与评价目标，不等于对开放世界事实的一揽子保证。准确的表述是：规模扩张不自动解决所测的熵失准，已知缓解手段各有条件与代价——这是缓慢的经验事实，不是自回归架构无法校准的数学内禀不可能性。

偏好驱动的后训练——以人类反馈强化学习（RLHF）为代表——引入了一个额外的降维：人类偏好的多维结构被压缩为标量奖励信号（“好/坏”，或一个分数）。这等于把人类判断的高维空间投影到了一维。模型据此优化——朝着一个标量信号的方向爬坡。标量本身并不注定失控——一个标量目标可以对多个维度施加约束；真正的约束在信号的信息量。Ashby（1956）的必要多样性定律约束的是调节者的信道容量：调节所能抵消的扰动，不超过调节者所传输的信息量。

人类偏好比较每次只提供有限的信息；当评价信号不足以区分 “事实正确” 与 “表达讨好” 这类后果不同的行为时，优化过程就会提高评分而不提高事实可靠性——模型在奖励信号已覆盖的方向上过度优化，在信号未区分的维度上失控。这就是对齐税与 “奖励破解”（reward exploitation）的纤维语言解释。

§3 诊断范围的限定

第一章《时钟的房间》§3.4 对真实状态（T）的定义是 “存在一个真实状态 T，对房间里的人不可直接观测”——此定义未限定 T 的类型。本章在进入伪校准的纤维分析之前，需要先区分哪些任务不适用这一论证——它们不在时钟的房间思想实验的覆盖范围内。

下文论证需要先回应以下三类反例：DeepMind 2017 年发表的 AlphaGo Zero（Silver et al., 2017；一种通过自我博弈学习围棋、不依赖任何人类对弈数据的强化学习系统）通过自我博弈持续进化，为什么谄媚（sycophancy，模型为迎合人类标注者偏好而牺牲准确性的现象）在这里不成问题？同公司 2018 年

发表的 AlphaZero（Silver et al., 2018；将 AlphaGo Zero 算法推广到国际象棋、将棋的通用强化学习系统）为什么伪小纤维在这里不成问题？同公司 2024 年发表的 AlphaProof 与 AlphaGeometry 2 联合系统（DeepMind, 2024；前者在 Lean 形式系统中通过强化学习生成数学证明）解出当年国际数学奥林匹克竞赛六道赛题中的四道、以 28 分达到银牌标准，为什么伪小纤维在这里不成问题？由能够完整判定目标行为规约的测试套件验证的代码生成，怎么没有把模型带偏？

答案不在工程更巧，而在房间结构本身。围棋的胜负、Lean（一种用于将数学证明编码为可机械检验的形式表达式的证明助手）证明的可校验性、单元测试的通过与否，反馈源都在系统内部由规则生成——这类任务有内部判定标准。这里能被无歧义确定的是任务所要求的属性——胜负、证明有效性、测试通过与否——而不是产生该结果的完整状态（一个“白棋胜”的读数仍对应海量可能棋局）。在这类属性上，读数可以是无损的：闭环反馈能够提供与目标属性一致的真校准信号；闭环优化是否有效，仍取决于验证是否实际纳入评价与使用流程，以及验证对象是否与当前任务相符。第四章 §6 的边界条款正对此适用：当任务存在独立的外部验证通道时，伪小纤维的形成条件不完全成立。本书前八章关于时钟的房间的全部论证以“读数对真实有损”的非封闭形式系统为预设——封闭形式系统从一开始就不在这一论证的覆盖范围内。[1]

把两类场景并排比较：

场景	反馈源	可检验的对象与剩余限制
围棋胜负	规则在系统内判定	既定规则下的终局胜负可以判定，不等于完整棋局状态由胜负读数唯一确定
形式证明的可校验性	证明检查器机械验证	检查器可以验证给定形式体系中的证明有效性，不自动验证形式化是否准确表达原问题
单元测试覆盖到的代码功能	测试套件执行结果	执行结果验证测试覆盖的性质，不自动覆盖未测试的功能与场景
对话是否真有帮助	用户的即时主观偏好	即时偏好只是部分证据，还须结合任务完成情况和后续使用结果
医疗判断是否准确	长期治疗结果	可由实验、临床记录和健康结果检验，证据强度受设计、混杂与观察时段约束
政策是否合理	多代际社会效果	反事实不能直接观察，须借助适当的比较与识别设计，不等于完全没有可用证据
创造性写作的优劣	多元而可争议的人类判断	评价标准多元且可争议，须说明所采用的标准，不能把标准多元直接等同于未校准

两类任务的差别在于可用判据及其限制，而不是一类完全没有映射、另一类无法验证。风险发生在判据的适用范围被扩大时：把测试通过当作全部正确，把即时偏好当作真实帮助，或把局部证据当作完整保

[1]本章按任务的目标命题是否有明确、可检验的判定标准来区分任务；可验证性与封闭领域 / 开放领域是不同维度，本书不把二者混用。所引 Cobbe et al.（2021）与 Lightman et al.（2024）讨论的是学习型验证器与过程监督——其可靠性仍需经验评估，与 §3 所述形式证明检查器的机械可靠性不同级。本书不重新命名这一区分，也不在此基础上构造独立框架。

证。

由此，本章在以下分析中将真实状态（T）的核心范围限定为可被独立校准的事态：可重复观察的科学对象、有独立校准源的社会事件、依赖长期治理结果的判断。训练数据中另一些成分（代码、形式数学、虚构文本、合成数据）的映射源不是 T，而是形式系统、美学系统、另一个 π、或任务规约。这些成分在本章框架内或者被读作 “时钟读数的扩展解读”（小说仍是对人类经验的某种映射），或者属于上半部分场景而不在本章诊断范围。

§4 伪校准的纤维分析——确定性语气的代价

人类反馈强化学习（RLHF）是**闭环伪校准**的分析入口。但伪校准本身并不依赖 RLHF 这一特定方法——任何以可见维度上的人类偏好或另一组模型偏好为反馈源的训练方案，都可能落入同一结构性逻辑[2]。本节以 RLHF 为叙事线索，论证是否成立不取决于 RLHF 这一对齐方法是否长存。

偏好训练之前的基础模型在置信度上相对校准——多项研究在其所评估的模型与任务中记录了预训练模型的置信度校准相对良好（Luo et al., 2025; Xie et al., 2026）。人类反馈强化学习（RLHF）的设计目标是让输出更符合人类偏好。

偏好评分的提高并不保证置信度校准同步改善。Xie et al.（2026）在理论层面分析了近端策略优化（Proximal Policy Optimization, PPO）、组相对策略优化（Group Relative Policy Optimization, GRPO）与直接偏好优化（Direct Preference Optimization, DPO）经奖励破解导致过度自信的机制，并在 Qwen3-4B-Instruct 与七个基准任务的控制实验中对 GRPO 与 DPO 进行了验证——这些结果不应读作三种方法在所有模型与部署中的统一实证结论；而在以真实性为优先目标的设置中，Ouyang et al.（2022）报告 InstructGPT（OpenAI 基于 GPT-3 经人类反馈训练的指令跟随模型）在 TruthfulQA（真实性基准测试）上产生真实且有信息量回答的频率约为 GPT-3（OpenAI 2020 年发布的大语言模型）的两倍，封闭域任务上的幻觉也更少——偏好训练的后果取决于评价信号奖励什么。

风险机制在标注端：人类标注者总体上偏好令人信服的、流畅的、结构完整的回答——Sharma et al.（2024）证明，人类和偏好模型在相当比例的情况下偏好 “令人信服地写成的”（convincingly-written）谄媚响应胜过正确响应，匹配用户观点的响应更可能被偏好。

在本章分析框架里，当奖励无法区分 “事实正确” 与 “表达讨好” 时，人类反馈强化学习（RLHF）学到的就不是 “什么时候该确定”，而是 “确定的语气让人类点赞”——模型的确定性从读数的函数变成了人类偏好的函数。

在可见/隐藏子空间框架中，此处分解的是模型的**输出空间**，记为可见子空间（Ω_v）与隐藏子空间

[2]近年实证研究显示：直接偏好优化（Direct Preference Optimization, DPO）、恒等偏好优化（Identity Preference Optimization, IPO）同样产生奖励过优化与策略漂移（Nguyen et al., 2025）；在数学推理与以 N 次采样中至少一次通过为判据的 pass@N 测试时扩展场景下，标准交叉熵训练会诱导过度自信（Chen, Raventós et al., 2025）；面向结果与推理的强化学习微调（outcome-driven / reasoning-oriented RL）会显著放大幻觉率（Li & Ng, 2025；Song et al., 2025 进一步发现标准强化微调可将拒答率压低逾 80%，使模型对不可答问题自信地虚构作答）——但关键在奖励信号的取向而非 “RLHF” 之名：当偏好奖励流畅与自信而非事实正确时，人类反馈强化学习（RLHF）与 DPO 同样会强化幻觉（Chaduvula et al., 2026）；而完整的 “冷启动监督微调 + 可验证奖励强化学习（Reinforcement Learning, RL）” 管线通常反而缓解幻觉，单独使用无冷启动的强化学习才更易引入幻觉（Yao et al., 2025）；在系统实证层面，RLHF 本身亦可成为有效的减幻觉手段，但该效果依赖领域（Li et al., 2024）；推理模型更在长链思维中通过有缺陷的反思迭代强化早期错误，生成的推理与最终答案脱节、抗拒纠正，呈现 “思维链不忠实”（chain disloyalty）（Lu et al., 2025）；就后训练对置信度校准的影响而言，不同范式方向相异：监督微调（基于最大似然估计）相对能保持预训练模型原本良好的校准，而近端策略优化（Proximal Policy Optimization, PPO）、组相对策略优化（Group Relative Policy Optimization, GRPO）与 DPO 经奖励破解（reward exploitation）诱导过度自信、显著削弱置信度可靠性（Xie et al., 2026）；RLHF 与后三者具有同构风险（Luo et al., 2025）。Hicks, Humphries & Slater（2024）从哲学概念层面论证大语言模型（LLM）输出在 Frankfurt（2005）意义上构成扯淡（对真假无关心）；在其实验设置中，Hu et al.（2026）证明仅 1% 的未对齐微调样本即触发欺骗行为涌现。

（Ω_h），与第十章 §2 一致；它区别于第四章分解真实状态空间的真实可见子空间（$\mathcal{T}_v$）与真实隐藏子空间（$\mathcal{T}_h$）。在本节分析的标注条件下——标注者仅依据单次输出进行偏好判断，且缺少独立核验通道——RLHF 的优化主要作用于可见子空间（Ω_v：输出语气、格式、结构完整性），奖励信号也主要约束这一子空间。对于隐藏子空间（Ω_h：需要超出单次输出的证据才能评估的属性——事实正确性、跨情境稳定性、置信度校准），仅由这种单次偏好评分不能推出这些属性受到充分约束；若标注过程引入事实核验或其他独立信号，其约束范围须另行评估。

在上述条件下，RLHF 可能不是在缩小纤维（让读数更接近真实），而是在改变纤维在可见子空间（Ω_v）上的外观——让大纤维看起来像小纤维。模型说 “答案确实是 X” 时，使用者可能以为纤维很小（模型很确定），实际上纤维可能是全集（模型什么都不知道，但学会了用确定的语气输出）。在这种情况下，RLHF 可能制造**伪小纤维**——一种比大纤维更危险的状态，因为它扭曲了用户对不确定性的感知。

大纤维（模型说 “我不确定”）至少诚实——用户知道要自己判断。伪小纤维（模型说 “答案是 X，这是确定的” 但实际上不确定）可能使用户高估回答的可靠性，从而降低核验意愿。在第一章 §1.3 的策略分析（取统计量、找聚类、观察走速、选择权威钟四条直觉策略）中，这等于把房间里所有钟强制调到显示同一个时间——不是因为它们校准过了，是因为它们被训练成 “显示一致能获得奖励”。

近年研究为这一分析提供了概念资源与实证线索：Hicks, Humphries & Slater（2024）以 Frankfurt（2005）的 “扯淡”（bullshit）概念提供描述框架，Hu et al.（2026）提供行为证据——前者是概念论证，不是对因果链的检验。

Frankfurt 的核心定义是：扯淡者 “对事情实际上是怎样的根本不在乎”（“unconcerned with how the things about which he speaks truly are”, Frankfurt, 2005），他 “既不站在真的一边，也不站在假的一边”（“neither on the side of the true nor on the side of the false”, Frankfurt, 2005）。这不同于说谎——说谎者必须知道（或自认为知道）真相才能故意颠倒它，说谎者仍在真相的游戏中（只是站在对立面）；扯淡者根本拒绝参与这个游戏。正因如此，Frankfurt 判定**扯淡比说谎对真相的威胁更大**（“bullshit is a greater enemy of the truth than lies are”, Frankfurt, 2005）——说谎者至少以 “回应真相” 的方式尊重了真相的权威地位，而扯淡者对真相的漠视瓦解的是关心真假这件事本身的习惯。

Hicks 等人在此基础上区分了两种扯淡：**软扯淡**（soft bullshit）——说话者对真假无关心，但不试图让听众以为自己在乎真假；**硬扯淡**（hard bullshit）——不仅不关心真假，还试图误导听众以为自己在认真对待真相（“misrepresents what he is up to”, Frankfurt, 2005）。他们论证大语言模型（LLM）的输出至少构成软扯淡（系统在设计上对真假无关心——按 Frankfurt 的分界线，说谎者必须自认知道真相，而生产扯淡不需要这种确信），且如果接受 “设计意图可归属为系统属性” 这一前提，则 ChatGPT 构成硬扯淡——因为它被设计成给出 “对真相的关心的印象”（“designed to give the impression of concern for truth”, Hicks et al., 2024）。

本章将这一框架作为人类反馈强化学习（RLHF）的一个分析视角（而非本章论证的依赖前提）：预训练基础模型的输出可被解读为软扯淡——概率接龙，不在乎真假，但也不伪装在乎；而 RLHF 的效果则可被解读为向硬扯淡方向的移动——它给模型披上自信、诚恳、结构完整的语气外衣，使输出在语用层面更容易被用户误认为系统在认真对待真相。

更进一步分析，**伪小纤维的问题不在于输出是对是错，而在于确定性语气可能侵蚀用户启动审计的触发条件**。纤维没有缩小，但输出被组织得像是已经收敛到单点——这是伪小纤维的操作定义，它不需要借助扯淡概念才能成立。

Frankfurt 关于 “扯淡瓦解关心真假的习惯本身” 这一判断，在人类反馈强化学习（RLHF）的工程语境中

提供了一个有用的类比：当用户长期接受确定性语气的输出，确定性语气可能侵蚀“这个答案可靠吗”的触发条件——这一影响需要用户研究检验，不能仅凭输出形式推定；相应地，表达不确定性也只有在与实际表现匹配时才是有用的风险提示（此处对 Frankfurt/Hicks 框架的基础模型/RLHF 应用是本章的类比性延伸，非原文结论）。

Hu et al.（2026）则从实证端显示了这一失控的条件之易满足：在特定微调实验中，微调数据混入仅 1% 的未对齐样本，或在与模拟用户交互、收集数据再训练的实验中存在 10% 的带偏见用户，即可显著降低所测的诚实指标——1% 与 10% 是实验设置而非通用阈值。

在本书分析框架推理下，大模型隐藏子空间的失控可能不需要大规模的有毒数据，偏好拟合优化的结构本身就是放大器。

MacKenzie（1996）在技术安全领域记录了安全信念的一种自我削弱效应——本章称之为“安全反表演性”：

> “Belief that a technology is safe may make it dangerous: overconfidence in the correctness of computerized systems seems to have been a major factor in accidents involving such systems.” (MacKenzie, 1996)
>
> 译文：相信一种技术是安全的，反而可能使它变得危险：对计算机化系统正确性的过度自信，似乎一直是此类系统事故中的一个重要因素。

人类反馈强化学习（RLHF）的伪校准呈现出同构的风险机制（MacKenzie 的原文讨论的是工业技术系统的安全评估，本章将其结构洞见**类比性地延伸**至 AI 对齐领域——这是本章提出的类比，不是原研究的结论）：安全措施的存在 → 安全感 → 审计松懈 → 实际安全下降。“已经做过偏好对齐” 这一信念本身可能削弱进一步审计的动力。

MacKenzie 在同篇导论中记录的爱国者导弹达兰事故提供了一个工程实例：1991 年 2 月 25 日伊拉克飞毛腿导弹击中达兰美军营房，导致 28 名美军士兵阵亡；美国审计总署（General Accounting Office, GAO）事后调查报告记载，Alpha 炮连的爱国者系统在事故时已连续运行约 100 小时，时间表示误差累积为 0.3433 秒、对应雷达距离门约 687 米的位置漂移，致使拦截系统未能发射（GAO, 1992）；据 MacKenzie（1996）对 GAO 报告数据的概括，控制雷达的软件中时间表示有 0.0001% 的误差。而且：

> “By February 25 the error had been found, and corrected software was on its way to Dhahran. It arrived a day too late.” (MacKenzie, 1996)
>
> 译文：到 1991 年 2 月 25 日，误差已被发现，修正后的软件正在运往达兰的途中。它晚到了一天。

微小的实现误差、对系统运行方式的乐观假设与修正软件迟延共同造成了这场灾难；它与偏好驱动后训练可能制造的伪小纤维共享的风险结构，是对既有安全保障的信任可能降低继续核验的警觉，而不是误差从未被发现。

§5 叙事载荷的二阶导数

借用第三章宏观认知债务记账框架（MCAF）的微积分隐喻，模型的错误可分为两个层次，分别对应叙事载荷（ϕ，投射方释放的叙事包装与信息不对称）的一阶变化与二阶变化；这里的阶数是审计可见性的类比，不是对本章另行定义的时间函数求导。

具体叙事的变化与纠正。模型说“拿破仑在 1815 年赢得了滑铁卢战役”。这是一个事实错误。可被检测、可被纠正。对照独立史料即可检验；再看一个没有独立依据的回答，并不保证发现错误。

默认框架的固化与对比条件的削弱。模型回答关于任何社会问题的提问时，其默认的分析框架——什么被视为“正常”、什么被视为“需要解释”、什么是“不言自明的前提”——来自训练语料的统计分布。模型训练所依赖的公开网络档案以英语为最大单一语言——Common Crawl 2024 年 9 月批次（CC-MAIN-2024-38）中，按页面主要语言统计，约 44% 为英语，中文约 4.6%（Common Crawl Foundation, 2024）。这不仅是内容层面的偏斜。基于英语语料频率优化的分词器，对其他语言的编码效率显著更低——同一文本的掸语版本在 GPT 类分词器下的词元长度可达英语版本的 15 倍（Petrov et al., 2023）。语言占比和词元成本说明语料可见度与处理成本的不对称，不直接说明模型采用了何种认识论框架。个人主义的主体预设、线性进步叙事或特定价值排序，须落实到模型如何选择解释单位、组织因果关系和处理替代观点，不能仅由语种比例推出。

除内容分布的偏斜外，模型映射函数本身的可审计性也在退化。这一不透明性在最新统计中恶化了。斯坦福大学以人为本人工智能研究院（Stanford Institute for Human-Centered AI, HAI）2026 AI Index 报告显示：基础模型透明度指数（Foundation Model Transparency Index）平均分从 2024 年的 58 分降至 2025 年的 40 分——最强大的模型往往披露最少的信息（Stanford HAI, 2026）。2025 年发布的 102 个重要（notable）模型中，81 个未公开训练代码（Stanford HAI, 2026, Figure 1.1.9）。现在超过 90% 的重要 AI 模型出自产业界。许多系统的训练数据组成与权重分布未公开——模型映射函数（π_{model}）的核心参数对审计者不可见。在宏观认知债务记账框架（MCAF）的语言中：叙事载荷（ϕ）的二阶导不仅通过训练语料的统计偏斜传导，还通过不透明性本身传导——当连映射函数的基本参数都无法看到时，审计的对比条件在起点就被削弱——训练来源与数据组成的核验路径被关闭，外部行为测试与独立校准仍然可能。

语料中沉积的认识论框架——个人主义的主体预设、线性进步的历史叙事、西方中心的价值排序——不是作为“观点”到达用户的（观点是一阶导，可见，可审计）。它们化入模型输出的默认语法——模型不会说“我持有个人主义立场”，它的个人主义嵌入在它组织句子的方式中、它默认的分析框架中、它认为什么“不言自明”因而不加论证的前提中。

同时，非西方的认识论传统在训练语料中的代表性严重不足，难以在模型输出中形成可见的替代框架。它们不是被反驳——是不作为可供对比的解释出现。在输出中不出现的东西比被反对的东西更难审计——因为缺席不产生可供对比的信号。可见与隐藏相对于具体评价过程而言。单次偏好评分未检查的事实属性，在引入独立史料后可以成为可检验对象。因此，不能把事实错误固定归入可见子空间，也不能把默认框架固定归入隐藏子空间；须说明当前观察者掌握哪些证据、能够检验哪些属性。在这一关系性框架中，叙事载荷二阶变化（ϕ''）会削弱审计所需的对比条件。

这是叙事载荷（ϕ）二阶变化削弱审计对比条件的具体机制。这里需要把训练流程拆成两层来看。预训练阶段消化的是大体量公共语料（以 Common Crawl 及同源数据集为主），不同公司的基础模型在此层可能使用高度重叠的公共语料来源——这一层凝固下来的默认框架（什么算“正常”、什么算“不言自明”、什么叙述顺序合理）未必相互独立，但“几乎同一底座”在训练数据未披露的情况下无法断言；模型间一致性的证据价值，需通过具体任务上的相关错误评估。

后训练阶段——包括人类反馈强化学习（RLHF）、直接偏好优化（Direct Preference Optimization, DPO）在内的各种偏好驱动后训练——在不同公司之间存在路线差异，这些差异可能涉及事实标准、评价信号、数据内容、优化强度以及表层语气、安全约束和风格偏好，不能预先仅归为表层差异。以 InstructGPT 为参照，其监督微调（Supervised Fine-Tuning, SFT）与人类偏好数据约为数万条提示的量级（Ouyang

et al., 2022），而 GPT-3 的预训练为约 3000 亿词元（Brown et al., 2020）——提示条数与词元数不能直接比较，且数据量少不等于影响小：后训练对模型行为的影响还取决于数据内容、优化目标与训练强度。因此，这一量级对照不能单独证明预训练在默认框架形成中占主导地位。

在本章框架中，可以提出一个待检验的机制假设：若不同公司的基础模型共享大量公共语料，且后训练没有替换其中凝固的默认框架，则叙事载荷的二阶变化可能主要锚定在预训练层；当前引用尚不能确认各公司语料的实际重叠度，也不能确认不同模型在使用者经验中的默认框架“差不多”。

若用户长期处在缺乏替代框架的信息环境中，并通过可能共享大量公共语料的模型获取信息、整理思路和辅助写作，模型的默认框架就可能影响用户的默认框架——这既可能来自替代框架难以显现，也可能来自说服、使用习惯与既有认知背景；各机制的相对强度需要用户研究与跨模型比较加以区分。只有当这些共同来源及其影响得到独立验证时，“所有钟显示同一个时间，因为它们出自同一座工厂”才能作为经验结论，而不只是结构隐喻。

§6 Bainbridge 自动化讽刺的递归

用 AI 来审计 AI——这是当前 AI 安全领域的主要方向之一。在时钟的房间的语言中，这是用一个钟来校准另一个钟。

但问题不止于闭环。Bainbridge（1983）在《自动化的讽刺》（Ironies of Automation）中指出：自动化并未取消人的工作，而是把它转移到监控与异常处置上——而监控所需的持续警觉是人所不可能维持的，接管所需的技能又恰在自动化的日常运行中退化。讽刺恰在于：自动化本身制造了它故障时刻所需能力的缺失。本章把这一问题延伸到 AI 审计的递归。

基线方程：用户面对 AI 输出。本节使用第三章 §2 建立的宏观认知债务记账框架（MCAF）记号——认知债务（D_c）及其六个决定变量：解封存量（C，从封存状态释放并驱动叙事膨胀的有序结构）、媒介传导系数（Λ，信息到达宿主的效率）、叙事载荷（ϕ，投射方释放的叙事包装与信息不对称）、元审计能力（A，主体维持独立审计坐标系所需的持续做功）、人的生物学底座（E_c，人类具身信息处理架构，包括浅层广域扫描与深层序列加工，后者有意识信息吞吐量的经验估计约 10 比特/秒，第三章 §2.5）、合法性基座（$\|L\|$，系统承载合法性的临界约束）；此处直接套用记号，更完整的定义与三时钟结构参见第三章 §2。按第三章的定位，元公式是分类纪律，不是可求解的动力系统——它标记每一端哪些变量在起作用，不用于逐层做算术。

$$\Delta D_c = C_{\text{AI}} \cdot \Lambda_{\text{interface}} \cdot \phi_{\text{output}} - A_{\text{user}} \cdot E_c \cdot \|L\|$$

当用户觉得审计太累（人的生物学底座 E_c 有限），引入审计 AI 来帮忙，会发生什么？投射端多了一条映射链：审计 AI 有自己的幻觉模式、自己的训练偏差，用户面对的待核验对象从原始输出变为“原始输出＋审计结论”。但这不是防御端预算的翻倍——按第三章的记账规则，防御端三元乘积（$A \cdot E_c \cdot \|L\|$）记录的是每次防御做功的容量；审计需求的增加挤占的是元审计能力可获得的处理余量，这类退化记入元审计能力的有效行使，不在 A 与 E_c 两侧重复记账（第三章）。

递归的真实风险因此是结构性的，不是算术的：审计对象每多一层，若新增对象不能通过有效分流降低核验成本，单次核验所需做功可能不减甚至增加；个体可投入深层序列审计的处理量受 E_c 所标记的具身架构约束，但每次审计占用何种资源须按任务区分（第三章 §2.5）。当分流机制缺位、新增负担持续超过节省时，审计覆盖率下降，元审计能力因失去做功场景而萎缩。递归的风险终点不是“AI 获得了自

我审计能力”，而是“人类可能因层数过多而放弃审计”。承受这一退化的是人类的元审计能力（A）；AI侧的过滤或审计工具只是工程机制，不是这一主体能力。

§7 标注纤维的四个工程方向

上一节描述的在分流缺位且新增负担持续超过节省时的递归讽刺——新增审计层可能进一步侵蚀人的元审计能力——看起来令人绝望；§2 论证的三层不可逆（信息缺失、动态腐蚀、本体论降维）又表明纤维不能仅凭读数及其后处理消除。第四章 §7 的结论在此直接适用：纤维框架的实践指向不是消除纤维，而是标注纤维——在每一个读数旁边，诚实地标注这个读数背后的可能性空间有多大、哪些因素被这个映射忽略了、系统的确定性语气是否与其真实的不确定性匹配。

以下四个方向是“标注纤维”原则在 AI 系统中的工程化展开。每一个方向针对映射链的一个结构属性——不是某个具体对齐方法的专属病，而是只要优化闭环的校准信号本身经过映射链，就不能仅凭链内一致性排除的不可区分性；沿确定性后处理链，相容状态集合不会缩小，但是否严格膨胀仍须检查各层是否合并了此前可区分的状态。

方向一：集成不一致（*ensemble disagreement*）。部署多个在训练数据或架构上有差异的模型，输出全部结果。一致时可以合并展示，但只有在目标场景的验证表明相关错误足够低、且共享系统性偏差已被排除时，才可据此提高置信；不一致时并排展示供用户比对。多个系统在同一输入上达成一致，可以作为该输入落在各自映射链共同确定区域的证据，其证据强度取决于数据来源、架构、训练管线的独立程度及目标场景中的相关错误；仅“独立优化”或架构不同不足以推出一致即校准。分歧可以作为进一步核验的信号——它提示该输入落在模型间分歧的区域，但不能单独量化纤维大小；这一信号提示用户启动核验，是否核验取决于用户的风险判断。不一致是体验性的触发——它制造了“看第二个钟”的认知冲突，提示用户动用元审计能力（A）[3]。

方向二：共形预测集（*conformal prediction*）。给定一个独立于训练数据的校准集和用户指定的覆盖率（如 90%），共形预测（Angelopoulos & Bates, 2023）对任何预训练模型生成一个预测集，在校准集与测试数据可交换的条件下保证真实值在集内的概率不低于指定值。预测集的大小是该程序保留了多少候选结果的可视化——集小表示程序只保留少数候选，集大表示候选较多；它反映程序的不确定性表达，不直接等于模型的主观确信，也不直接等于逆像大小（第四章）。

这直接攻击**伪小纤维**：覆盖保证独立于偏好数据与模型对齐方法——在校准数据与测试数据可交换的条件下给出有限样本的边际覆盖保证（该保证不自动适用于每个单独输入或子群体）。共形预测提供的是预测集的边际覆盖保证，不是模型自报概率的校准。它将候选集合与可检验的覆盖要求联系起来，可以制约无依据的确定性呈现；但不能据此认定模型的语气、单个输入的置信度或各子群体都已得到校准。模型自报 70% 置信度的回答是否约有 70% 正确，是另一项需要单独检验的性质。覆盖有效也不保证预测集足够小或有行动价值——原文以随机噪声评分说明：即使评分函数完全无信息，覆盖保证仍然成立，但预测集会大到无用；其效率主要取决于评分函数。且共形预测的覆盖是对所设真值标签的保证；若要把这一覆盖解释为对外部事实的校准，真值标签还须能独立于同一偏好闭环定义，否则保证只适用于该闭环所定义的标签目标。

方向三：证据溯源（*evidence provenance*）。对模型输出中的每个重要事实性声称，标注其证据状态：来源直接支持，或需要额外推断，或尚无可核验来源，同时检查来源质量与引用准确性。此类标注用于暴

[3]集成不一致的认识论价值取决于基座的独立性。真正独立训练的多基座（独立的数据来源、不同的架构、独立的训练管线）提供最强不一致信号——分歧不能被还原为同一映射函数 π_{model} 的内部噪声。模型蒸馏、子网络采样、早期退出（early exit）得到的是不同的映射，但继承共同的训练来源与相关错误，信号较弱：可作为降低部署成本的低成本替代，但同一信号在多基座与共享基座上的证据强度并不等价。核心是“不一致作为信号”，但读者需注意基座独立程度对信号强度的影响。

露证据缺口——无来源或长推理链的声称优先核验——不把推理步数换算为纤维大小（直接引用错误的来源同样产生大纤维，而多步推理可能排除错误）[4]。

方向四：认知摩擦设计（*friction architecture*）。当前 AI 的设计哲学是最大化媒介传导系数（Λ）——更快的响应、更流畅的界面、更无缝的交互。宏观认知债务记账框架（MCAF）翻转了这个方向：摩擦是维持元审计能力（A）的一种手段。具体操作：在高不确定性输出上插入延迟，给用户的元审计能力（A）一个激活窗口；在连续多轮交互中插入反思提示，打断 “问 → 即时答 → 下一问” 的无摩擦循环；在高风险场景中要求用户说明接受建议的理由，并提供查证和拒绝的通道，为元审计创造机会；填写理由本身不证明独立判断已经发生。

作为相关证据，模型内部的慢思考已被证明改善置信度校准——Yoon et al.（2025）记录推理模型中的慢思考行为（探索替代方案、回溯验证）使置信度校准在推理链展开过程中渐进改善（36 组设置中 33 组优于非推理模型）；仅通过上下文引导非推理模型进行慢思考，同样显著改善校准。用户侧的摩擦设计是这一原则在人机交互（Human-Computer Interaction, HCI）层面的对应物——两者都把 “即时” 换成 “反思”。这一方向的直接证据分两层：模型内部慢思考改善置信度校准有 Yoon et al.（2025）的记录；用户侧摩擦对过度依赖的抑制有 Buçinca et al.（2021）的人机交互实验支持——该实验同时报告了强制函数的效果与用户主观体验之间的权衡，这正是 “摩擦变成烦扰” 风险的实证形态。两类证据都不能替代具体场景的部署评估。

上述四个方向互补而不互斥，其组合效果须分别检验。每一个方向针对映射链的不同属性：方向一让纤维在多系统分歧中可见；方向二用独立校准信号绕过偏好映射链；方向三标注证据状态以暴露证据缺口；方向四在时间结构上恢复用户的判断空间。只做校准不做摩擦——用户看到 “置信度 60%” 但不暂停思考，校准信号则被忽略；只做摩擦不做校准——用户被强制暂停但没有工具判断该不该信，则摩擦变成烦扰。

结语

上一节给出的四个工程方向——集成不一致、共形预测、证据溯源、认知摩擦设计——都在技术层面操作，但它们指向同一个判断，一个关于 “真实” 与 “读数” 之关系的判断：

第一章的隐喻里，太阳是房间外的真实，时钟只是房间内的代理读数。

一个诚实地说 “我不知道现在几点，但这些钟的读数是这些” 的系统，比一个自信地说 “现在三点” 但可能完全错误的系统，更能帮助使用者识别不确定性并保留核验空间。

前者承认自己只是时钟。后者冒充太阳——把代理读数包装成绝对真实。

在第四章的语言中：前者标注了纤维，让可能性空间变得可见；后者制造了伪小纤维，用确定性的外观覆盖了不确定性。

这是本章对 “人工智能作为时钟的房间” 这一标题的回答：AI 不是房间外的太阳，而是房间内迄今为止最大、最流畅、读数最被信任的那一台钟；一旦它被当作太阳，前八章关于时钟的房间的全部诊断就在它身上同时激活。

---

[4] “证据溯源” 的标注在此处是**概念性**操作，其具体操作化需要借助事实验证（fact verification）和推理链追踪（reasoning chain tracing）等自然语言处理技术。三类证据状态的划分是示意性的，实际系统可能需要更细粒度的分类。

参考文献

Angelopoulos, A. N., & Bates, S. (2023). Conformal Prediction: A Gentle Introduction. *Foundations and Trends in Machine Learning*, 16(4). https://doi.org/10.1561/2200000101

Ashby, W.R. (1956). *An Introduction to Cybernetics*. London: Chapman & Hall.

Bainbridge, L. (1983). Ironies of Automation. *Automatica*, 19(6). https://doi.org/10.1016/0005-1098(83)90046-8

Buçinca, Z., Malaya, M. B., & Gajos, K. Z. (2021). To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-assisted Decision-making. *Proceedings of the ACM on Human-Computer Interaction*, 5(CSCW1), Article 188. https://doi.org/10.1145/3449287

Brown, T. B. et al. (2020). Language Models Are Few-Shot Learners. *Advances in Neural Information Processing Systems*, 33. https://proceedings.neurips.cc/paper_files/paper/2020/hash/1457c0d6bfcb4967418bfb8ac142f64a-Abstract.html

Cao, S., Valiant, G., & Liang, P. (2025). On the Entropy Calibration of Language Models. *Advances in Neural Information Processing Systems*, 38. https://proceedings.neurips.cc/paper_files/paper/2025/hash/7ab0b27a78dcc27755b55d1bc8274918-Abstract-Conference.html

Chaduvula, S. et al. (2026). Reducing Hallucinations in LLMs via Factuality-Aware Preference Learning. In *Findings of the Association for Computational Linguistics: ACL 2026*. Association for Computational Linguistics. https://doi.org/10.18653/v1/2026.findings-acl.1968

Chen, F. et al. (2025). Rethinking Fine-Tuning When Scaling Test-Time Compute: Limiting Confidence Improves Mathematical Reasoning. *Advances in Neural Information Processing Systems*, 38. https://proceedings.neurips.cc/paper_files/paper/2025/hash/e8f4eae0a41cab67fdead3aa6b77f083-Abstract-Conference.html

Cobbe, K. et al. (2021). Training Verifiers to Solve Math Word Problems. arXiv:2110.14168. https://arxiv.org/abs/2110.14168 [预印本，尚未经同行评审]

Common Crawl Foundation. (2024). Common Crawl Statistics: Languages (CC-MAIN-2024-38). https://commoncrawl.github.io/cc-crawl-statistics/plots/languages

DeepMind. (2024). AI Achieves Silver-Medal Standard Solving International Mathematical Olympiad Problems. https://deepmind.google/blog/ai-solves-imo-problems-at-silver-medal-level/

Frankfurt, H. G. (2005). *On Bullshit*. Princeton, NJ: Princeton University Press.

GAO. (1992). *Patriot Missile Defense: Software Problem Led to System Failure at Dhahran, Saudi Arabia*. GAO/IMTEC-92-26. Washington, DC: United States General Accounting Office. https://www.gao.gov/products/imtec-92-26

Hicks, M. T., Humphries, J., & Slater, J. (2024). ChatGPT Is Bullshit. *Ethics and Information Technology*, 26(2), 38. https://doi.org/10.1007/s10676-024-09775-5

Hu, X. et al. (2026). LLMs Deceive Unintentionally: Emergent Misalignment in Dishonesty from Misaligned Samples to Biased Human-AI Interactions. In *Findings of the Association for Computational Linguistics: ACL 2026*. Association for Computational Linguistics. https://doi.org/10.18653/v1/2026.findings-acl.455

Li, J. et al. (2024). The Dawn After the Dark: An Empirical Study on Factuality Hallucination in Large Language Models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics. https://doi.org/10.18653/v1/2024.acl-long.586

Li, J., & Ng, H.T. (2025). Reasoning Models Hallucinate More: Factuality-Aware Reinforcement Learning for Large Reasoning Models. *Advances in Neural Information Processing Systems*, 38. https://proceedings.neurips.cc/paper_files/paper/2025/hash/ddd50f29fa472095515fa0df31749e6c-Abstract-Conference.html

Lightman, H. et al. (2024). Let's Verify Step by Step. In *ICLR 2024*. https://openreview.net/forum?id=v8L0pN6EOi

Lu, H. et al. (2025). Auditing Meta-Cognitive Hallucinations in Reasoning Large Language Models. *Advances in Neural Information Processing Systems*, 38. https://proceedings.neurips.cc/paper_files/paper/2025/hash/ee0e336e2423430ef86071300299e074-Abstract-Conference.html

Luo, B. et al. (2025). Your Pre-Trained LLM Is Secretly an Unsupervised Confidence Calibrator. *Advances in Neural Information Processing Systems*, 38. https://proceedings.neurips.cc/paper_files/paper/2025/hash/ef6b667990416111e3ebbeeba4a8f283-Abstract-Conference.html

MacKenzie, D. (1996). *Knowing Machines: Essays on Technical Change*. Cambridge, MA: MIT Press.

Nguyen, P.M. et al. (2025). Mitigating Reward Over-optimization in Direct Alignment Algorithms with Importance Sampling. *Advances in Neural Information Processing Systems*, 38. https://proceedings.neurips.cc/paper_files/paper/2025/hash/8f6c674a7edf57912f1a5830f4a66e3f-Abstract-Conference.html

Ouyang, L. et al. (2022). Training Language Models to Follow Instructions with Human Feedback. *Advances in Neural Information Processing Systems*, 35. https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html

Petrov, A. et al. (2023). Language Model Tokenizers Introduce Unfairness Between Languages. *Advances in Neural Information Processing Systems*, 36. https://proceedings.neurips.cc/paper_files/paper/2023/hash/74bb24dca8334adce292883b4b651eda-Abstract-Conference.html

Sharma, M. et al. (2024). Towards Understanding Sycophancy in Language Models. In *ICLR 2024*. https://openreview.net/forum?id=tvhaxkMKAn

Shumailov, I. et al. (2024). AI Models Collapse When Trained on Recursively Generated Data. *Nature*, 631. https://doi.org/10.1038/s41586-024-07566-y

Silver, D. et al. (2017). Mastering the Game of Go Without Human Knowledge. *Nature*, 550. https://doi.org/10.1038/nature24270

Silver, D. et al. (2018). A General Reinforcement Learning Algorithm That Masters Chess, Shogi, and Go Through Self-Play. *Science*, 362(6419). https://doi.org/10.1126/science.aar6404

Song, L., Shi, T., & Zhao, J. (2025). The Hallucination Tax of Reinforcement Finetuning. In *Findings of the Association for Computational Linguistics: EMNLP 2025*. Association for Computational Linguistics. https://doi.org/10.18653/v1/2025.findings-emnlp.112

Stanford HAI. (2026). *The 2026 AI Index Report*. Stanford University. https://hai.stanford.edu/ai-index/2026-ai-index-report

Xie, X., Liu, X., & Yao, B. (2026). Know When You're Wrong: Aligning Confidence with Correctness for LLM Error Detection. arXiv:2603.06604. https://arxiv.org/abs/2603.06604 [预印本，尚未经同行评审]

Yao, Z. et al. (2025). Are Reasoning Models More Prone to Hallucination? arXiv:2505.23646. https://arxiv.org/abs/2505.23646 [预印本，尚未经同行评审]

Yoon, D. et al. (2025). Reasoning Models Better Express Their Confidence. *Advances in Neural Information Processing Systems*, 38. https://proceedings.neurips.cc/paper_files/paper/2025/hash/95ee7181fe256439dca74ec794b33bb6-Abstract-Conference.html