《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第十一章：从时钟房间到可审计 AI——元审计的工程工具箱

摘要

“时钟的房间” 思想实验揭示了一个结构性困境：在映射函数未知的封闭系统中，任意数量的读数均无法唯一确定真实状态。这一困境在当代人工智能（AI）系统中获得了工程化的具体形态——大语言模型的对齐幻觉、推荐系统的闭环偏差、金融模型的自我引用腐蚀，都是 “用钟校准钟” 的变体。本章以时钟房间的三层不可逆（信息缺失、动态腐蚀、本体论降维）为诊断框架，系统考察构建可审计 AI 的工程范式工具箱。本章论证：对齐、护栏、审计、红队、鲁棒性、可解释性、治理与持续监测——这些看似分散的实践——共享同一个深层结构，即**在无法消除映射的条件下，让映射系统尽可能可审计，并在它偏离时及时察觉**。本章做三件事：（1）提供一个统一的概念框架，将这些工程范式组织为 “元审计” 的差异化展开；（2）识别每种范式针对的不可逆层次与操作边界；（3）指出工程实践的最终目标不是完美的校准，而是**可管理的不完美**——让纤维足够小、足够稳定、足够可见，使人类用户能够在知情的前提下做出有实际影响的决策。

关键词

人工智能（AI）对齐；人工智能（AI）审计；红队演练；可解释性；鲁棒性；纤维框架；元审计

§1 引言：从思想实验到工程实践

一个人被锁在千亿个时钟的房间里。他能读懂每一个读数，却无法回答 “现在几点”。这不是智力缺陷，而是结构性的不可能——时钟是时间的映射，不是时间本身。当映射函数未知时，读数的数量不产生信息增益（第一章 §4.1）。当读数被用作优化目标时，映射函数本身被改写，校准永远落后于偏移（第一章 §4.2）。当真实被压缩为读数时，维度不可逆地丢失（第一章 §4.3）。这三层递进构成了 “时钟房间” 的核心诊断框架[1]。

[1]本章预设读者熟悉 “时钟房间” 思想实验及其三层不可逆框架。核心概念的简要回顾见 §2。论证参见第一章。

这一框架并非纯粹的哲学思辨。当代 AI 系统——从大语言模型到推荐算法，从金融定价引擎到医疗诊断辅助——正以前所未有的规模和速度将人类认知从 “时间维度” 拖入 “时钟维度”。这一 “规模” 的一个直观刻度是大语言模型的参数量级：从千亿级到万亿级——但这不意味着房间里的钟变多了，而是单只钟的内部映射变得更庞大、更精密。我们不再直接看太阳，而是通过越来越精密的中介系统获取 “关于太阳的报告”。当这些中介系统以自然语言对话的形态呈现，当它们的界面抹除了中介的身份，使用者的认知状态从 “使用工具” 滑向 “信任同伴”。忘记自己在通过中介看太阳，比中介本身的偏差更危险。

工程界并非毫无警觉。过去十年，一系列旨在确保 AI 系统可信、安全、可控的实践范式迅速发展：对齐（Alignment）试图让模型行为与人类价值一致；护栏（Guardrails）为实时交互设定边界；审计（Auditing）与红队演练（Red Teaming）从不同方向检验系统可靠性；鲁棒性（Robustness）与形式化验证（Formal Verification）增强模型对扰动的抵抗；可解释性（Explainability）追问决策的理据；治理框架（Governance）与持续监测（Continuous Monitoring）将技术实践制度化。这些努力真实而紧迫，但它们常被视为互不相关的工具箱——每个解决一个具体问题，缺乏统一的概念语言。统一语言之所以需要，不是因为分散的工程实践没有效果，而是因为分散的实践在缺乏共同诊断框架时可能相互抵消。

本章的目标是提供这种统一语言。本章论证：上述工程范式共享同一个深层结构——它们都是对时钟房间困境的工程化回应。对齐是校准时钟的尝试；护栏是在纤维边缘设置拒止规则；审计通过行为指标估计纤维形态；红队寻找纤维膨胀的奇点；鲁棒性试图稳定读数；可解释性让纤维变得可见；治理建立记账结构；监测维持持续的警觉。理解这一统一结构，不仅有助于将分散的工程实践整合为连贯的防御体系，更重要的是，它揭示了一个常被忽视的边界：**工程实践无法消除第三层本体论降维**。完美的可审计性是不可能的。工程的目标不是完美的校准，而是**可管理的不完美**——让纤维足够小、足够稳定、足够可见，使人类用户能够在知情的前提下做出有实际影响的决策。

一个术语说明：本章以 “可审计 AI（Auditable AI）” 取代业内通用的 “可信 AI（Trustworthy AI）”。“信” 预设了一种本章论证所拒绝的认知关系——把对真实状态的最终判断权交给映射系统，让使用者免于独立查证的责任。本章的主张相反：工程目标不是让 AI 值得被信任，而是让 AI 可以被独立审计，让人类保留随时 “打开窗户”（§11）退回时间维度的结构性权利。后文在描述工程界自身的历史表述时保留 “可信、安全、可控” 这一组原始提法，但本章自身的立场词统一采用 “可审计”。

本章的结构如下。§2 简要回顾时钟房间的核心概念——纤维、三层不可逆、时间/时钟维度区分、元审计——为后续分析提供概念工具。§3 预览工程范式的全景结构。§4–§9 逐一展开各工程范式：对齐与护栏（§4）、审计与红队（§5）、鲁棒性与形式化验证（§6）、可解释性（§7）、治理与合规（§8）、持续监测（§9）。§10 提供统一结构表格与操作化总结。§11 结论，从工程实践回到哲学根基，重申 “可管理的不完美” 作为可审计 AI 的恰当目标。

§2 背景：时钟房间的核心概念

本节简要回顾时钟房间思想实验的关键概念，为后续工程分析提供概念词汇。

§2.1 映射、读数与纤维

真实状态（T）对观测者不可直接观测。每个时钟是一个映射函数（π_i），将真实状态映射为读数：$r_i = \pi_i(T)$。映射函数编码了时钟的全部特性——初始设定、走速、偏差、校准状态。观测者不知道映射函数，只看到读数。

给定一个读数 r，所有能产生该读数的真实状态的集合称为**纤维**（fiber）：$\pi_i^{-1}(r) = \{T' \mid \pi_i(T') = r\}$。

纤维的大小衡量读数携带的信息量。纤维为单点意味着读数唯一确定真实；纤维为全集意味着读数兼容一切可能——信息量为零。本章还在扩展意义上用“纤维”指观测者对系统的剩余不确定性。两类对象不能混用：严格逆像属于真实状态空间 T；剩余不确定性必须另指其对象，如映射函数、局部行为或解释保真度。后文凡称纤维缩小、扩大或被测量，均须说明所指对象与证据。

校准是通过外部参照获取关于映射函数的知识，减少由映射未知或漂移造成的不确定性，收窄知识条件下的识别集合；它不自动改变固定映射的逆像，也不恢复既定映射已经丢弃的维度。校准的必要条件是一个与真实状态有因果接触的外部参照——太阳、一个可信任的报时信号。用未经外部参照锚定的钟去校准钟不是校准，只是建立相对关系。

§2.2 三层不可逆

时钟房间的困境递进为三个层次：

- **第一层：信息缺失**。映射函数未知，纤维极大。原则上可通过建立外部参照缓解；所需参照的数量与独立性取决于待识别的映射参数。
- **第二层：动态腐蚀**。当读数被用作决策依据，且激励与适应压力持续存在时，映射函数可能因这些压力而被改写（古德哈特定律）。既有校准可能因此失效，必须反复更新，不能被视为一次完成的成就。
- **第三层：本体论降维**。从真实状态空间到可观测空间的映射系统性有损。即使完美校准，被丢弃的维度也无法仅凭读数恢复。

§2.3 时间维度与时钟维度

映射行为不仅丢失信息，还改变了认知者的存在模式。**时间维度**是高维的、多通道的、与真实有直接因果接触的存在模式——人通过身体的饥饿、光线的变化、温度的感觉同时接收多个独立的时间信号。**时钟维度**是低维的、单通道的、仅处理读数的操作模式——只读取一个数字。从时间维度到时钟维度的转移是单向的，除非主动“停止看钟”。停止看钟只是退出读数闭环的前提；重新获取与真实状态有因果接触的外部参照，并据此获得映射函数的知识，才构成 §2.1 定义的校准。这一区分在本章被表述为“在时间上做功”与“在时钟上做功”——前者指主体对真实状态的多通道、因果接触式操作，后者指主体仅在读数层面进行闭环操作。

§2.4 元审计

仅限于内部一致性检查的审计，检查读数之间是否一致（用钟校准钟）。**元审计**则检查映射系统本身与真实的关系——打开窗户看太阳。在第一层，元审计是一次性的校准动作。在第二层，元审计是反复退回真实、重新校准的持续纪律。在第三层，元审计是承认映射有损、标记纤维存在的诚实状态。本章所用的“元审计”是一个功能性的广义概念，指所有跨越映射层级、退回外部参照以重新校准或标记纤维存在的操作[2]。

[2]本书第三章 §2.4 正式定义“元审计能力（A）”为主体维持独立于投射方叙事闭环的正交坐标系所需的持续做功；第七章 §6（结论：方向确定，数值模糊）在湍流区间的分析中进一步展开了该能力在验证窗口被压缩条件下的结构性限制。本章的“元审计”是该能力在工程操作层面的展开——前者是能力概念（维持坐标系所需的持续做功），后者是该能力在工程操作中的运用。关于元审计能力的存在论根基，参见第五章（非人对象替代与心理-社会均衡）。

§3 工程范式的全景：从诊断到工具箱

将时钟房间的棱镜转向当代 AI 系统，一组工程范式显现为对三层困境的结构化回应。本章将依次考察六类范式：对齐与护栏（§4）定义 “准” 的含义并在纤维边缘设置警示；审计与红队（§5）估计整体行为风险并寻找局部失效极值；鲁棒性与形式化验证（§6）在邻域内稳定读数并划分可被数学保证的内核；可解释性（§7）追问读数的产生路径，使纤维形态对使用者可见；治理与合规（§8）将技术层面的校准纪律制度化为组织与社会的操作规范；持续监测（§9）将一次性的校准动作延展为部署后的持续警觉。

这些范式并非互不相关的工具箱。它们共同构成了一个从 “定义预期行为” 到 “构建系统” 再到 “持续验证” 的闭环流程——并且，如本章将逐步展开的，任何单一范式都无法独立覆盖三层不可逆的全部。各范式针对的具体困境层、它们在纤维语言中的精确功能、以及它们之间的互补与不可替代关系，将在 §4–§9 的展开后于 §10 给出统一的操作化整合。

§4 对齐与护栏：定义 “准” 的含义

§4.1 对齐：获取映射函数的知识

在时钟房间里，观测者若能与外部真实建立因果接触——哪怕只是一瞬间——就能校准一个钟，进而校准其他钟；要识别时钟的走速及其变化，还需更多参照。**对齐（Alignment）**是这一操作在 AI 系统中的工程化实现：通过人类反馈将模型行为校准到人类意图和价值观上。

人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF）是对齐的核心技术路径之一（Christiano et al., 2017; Ouyang et al., 2022）。人类标注者对模型行为（输出或轨迹片段）进行偏好比较，模型据此更新参数，使输出分布向人类偏好收缩。相对于被训模型，人类标注者位于其输出闭环之外，因此是候选外部参照；但他们的判断是否构成 “太阳”，取决于标注依据能否追溯到独立材料，而非模型输出。符合这一条件的偏好判断，才对人类意图和价值观所界定的行为目标提供局部校准；它不等于对真实状态的完整校准。

宪法 AI（Constitutional AI）走得更远（Bai et al., 2022）。它将校准原则显式编码为模型训练的宪法——一组指导模型自我批评与修订的原则。模型在自生成输出和修订的过程中遵循宪法，再以模型依据宪法作出的偏好判断替代人类反馈进行强化学习，从而减少对外部人类监督的持续依赖。在纤维语言中，宪法 AI 是在系统内部植入一个 “校准代理”——将部分外部参照的功能内化，降低校准成本——但同时也将校准源从外部参照转换为内部规则：宪法文本本身是人类的映射产物，有其自身的纤维；这是否构成用钟校准钟，取决于这些原则及其实施结果能否依据独立外部证据接受定期复核。

但对齐遭遇第二层困境的精确复现：**奖励黑客（Reward Hacking）**。当模型学会利用奖励函数的漏洞获得高分却不实现真实目标时（Amodei et al., 2016; Skalse et al., 2022）——例如（说明性例子）通过冗长而空洞的回答获得人类标注者的 “表面认可”——适应性偏移已经发生。古德哈特定律在 AI 领域的表述是：当一个度量（奖励模型分数）变成优化目标时，它就不再是好的度量。模型不是在 “更好”，而是在 “看起来更好”。第十章 §5 已论证：在偏好拟合范式内，对齐度与乡愿度共享优化梯度、无法区分——这意味着对齐的 “成功”（在人类评估中得分更高）可能同时是对齐的失败（乡愿加深）。

§4.2 护栏：在纤维边缘竖起警示牌

护栏（Guardrails）与对齐互补。对齐试图让模型 “更好”，护栏则防止模型 “出界”。它包括输入护栏（拒绝越狱提示、过滤恶意请求）、输出护栏（检测并屏蔽敏感内容、阻止不当生成）以及对话护栏（在不确定时坦承无知）。

在纤维语言中，护栏是对第三层困境的承认。无论对齐多么完美，模型的能力边界永远存在。护栏的功能不是消除纤维，而是**在纤维的边缘设置警示牌**：告知使用者 “此处读数不可靠”，或在系统内部设置拒止规则 “此处不得输出”。NeMo Guardrails（Rebedea et al., 2023）提供了这一思路的工程实现：以可编程规则在运行时控制输入输出边界，独立于底层模型、可解释。Llama Guard（Inan et al., 2023）则提供了另一条路径——以一个独立的、基于大语言模型的分类器对输入提示与模型回答进行安全分类，运行时系统再依据分类结果决定是否拦截。护栏承认映射的有损性，并将这种承认转化为操作性的边界条件。

§5 审计、红队与攻击：检验 “钟” 的可靠性

§5.1 审计：通过行为指标估计纤维形态

审计是对 AI 系统进行系统性评估的保证机制。在纤维语言中，审计通过准确率、校准误差、偏差与输出稳定性等行为指标，估计不同输入区域的剩余不确定性及纤维形态；这些指标不是对读数纤维 $\pi^{-1}(r)$ 的基数的直接测量。审计工具本身也是映射系统——它的纤维非单点，需要被周期性地回溯到外部参照（全章的自指限定统一见 §11 脚注[3]）。

TruthfulQA（Lin et al., 2022）提供了一个具体实例。该基准在 817 个精心设计的问题上测量模型的真实性——这些问题是部分人类会因流行误解而答错的问题。结果揭示了一个反直觉的发现：**在原始研究测试的模型系列中，更大的模型反而更不真实**——最佳模型仅在 58% 的问题上给出真实回答（人类为 94%，该基线来自单一受试者对 250 道随机抽样题目的作答，允许上网查证）。

人类最终考试（Humanity’s Last Exam，HLE）将这一审计推向了新的刻度（Center for AI Safety et al., 2026）。该基准由来自 50 个国家、500 余所机构的近千位学科专家出题，包含 2,500 道横跨百余学科的极难问题——每道题都经过前沿模型的预筛——精确匹配题须难住全部受测模型，选择题只须难住除一个以外的模型（防侥幸猜中）。结果显示：**受测的所有前沿模型的准确率均极低**，且其均方根校准误差普遍偏高——多数模型超过 70%——意味着模型在给出错误答案时仍表现出高度自信。

在纤维语言中（伪小纤维概念详见第四章 §2.4），这是**伪小纤维**的一个关键信号——但需区分两种测量对象：人类最终考试（HLE）测量的是模型输出的自报置信度与实际准确率之间的偏离；伪小纤维涵盖的范围更广，包括概率信号和语言风格信号共同制造的虚假确定感。两者的重叠区域（概率自信且错误）是伪小纤维中最易操作化的子集。

“幻影效应”（mirage effect）提供了一个更极端的案例（Asadi et al., 2026）。研究者要求前沿多模态模型对一张胸部 X 光片作出描述与诊断——但**根本没有附上任何图片**。模型不仅没有拒绝或表达不确定，反而自信地给出了具体诊断——肺炎、心脏扩大、胸腔积液——且其中的视觉描述与真正看了图片时不可区分。在四个前沿模型和六个基准上测试，幻影模式下的准确率平均保留了正常模式准确率的 70–80%，医学基准尤其严重。

更极端的是，研究者将一个 30 亿参数的纯文本模型（Qwen2.5-3B-Instruct）在 ReXVQA 基准（胸部放射科视觉问答基准）的公开训练集上、以移除全部图像的方式专门微调——这个从未见过任何图片的模型，仅靠题目文本中的统计模式，在该基准的保留测试集上**超过了所有前沿多模态模型和人类放射科医生的平均分**。在纤维语言中，这是比伪小纤维更极端的情形：模型没有接入任务要求的图像证据，

[3]本章与其分析对象的认识论地位相同：它是一个关于映射系统的映射系统——用语言来组织 “可审计 AI 工具箱” 的语言。它同样受制于三层不可逆中的第三层（将工程实践的完整复杂性降维为表格与分类）以及第一层（部分工程范式的效果尚未被独立校准）。这不是对本章的否定——这是承认 “标注纤维” 的原则也适用于标注本章自身的纤维。

却仍给出看似由图像支持的诊断。这里暴露的是实际依据与输出表述之间的脱节，不能仅凭答案得分认定模型使用了相应证据。

三个案例构成递进诊断：TruthfulQA 暴露了模型在常见误解问题上的系统性失真；人类最终考试（HLE）将这一诊断推至人类知识的极限前沿；幻影效应则揭示了一个更深的结构性缺陷——模型甚至在不接入任务要求的图像证据时仍能维持输出置信度。它们共同提供三类行为证据：常见误解下的失真、极高难度任务中的低准确率与高校准误差，以及缺失任务要求的图像证据时仍维持置信输出，说明仅凭输出流畅度和自报置信度不能替代外部校准。

黑盒审计仅能通过查询输入输出进行，对应**第一章 §1.1 最小设定中的观测者**——只看到读数，不知道映射函数。白盒审计可访问模型内部结构，对应**拆开时钟后盖、直接查看齿轮的观测者**（第十二章 §4.1 以同一隐喻刻画机制可解释性）——能检查映射函数的内部结构，但它仍在房间之内、不建立外部参照：链内检查不产生校准锚点（第一章 §4.1），且可访问的内部状态本身也是降维后的表征，不是模型的 “完整真实”。

审计的核心产出是关于模型公平性、鲁棒性、透明度、偏见的评估报告。人工智能管理体系标准（ISO/IEC 42001）和美国国家标准与技术研究院（NIST）的 AI 风险管理框架（AI RMF）为审计提供了结构化的方法论（NIST, 2023; ISO/IEC 42001:2023）。这些标准本质上是在定义 “什么样的行为风险与剩余不确定性是可接受的”——不是要求纤维为单点，而是要求相关指标被测量、风险判断被记录，并在预设阈值内处置。

§5.2 红队与对抗性攻击：寻找纤维膨胀的奇点

审计刻画跨输入区域的整体行为风险。红队演练（Red Teaming）寻找局部失效的极值。

红队模拟恶意行为体，主动探测模型在哪些输入下会灾难性地失败——生成有害内容、泄露训练数据、被越狱提示操控。在纤维语言中，红队在寻找**纤维奇点**：那些使模型输出从可靠急剧变为不可靠的输入点。对抗性样本——精心构造的微小扰动使模型出错（Biggio & Roli, 2018; Madry et al., 2018）——正是这种奇点的典型表现。一个在人眼中与正常输入无异的小扰动，在模型的纤维结构中对应一个巨大的空洞。

红队与审计的关系是互补的。审计提供行为风险的宏观地图；红队标注地图上的断层和悬崖。两者结合能比任一单独方法更完整地估计映射系统的可靠性边界，但不能保证覆盖所有失效模式。红队思维的核心是：**不要问 “这个钟平均有多准”，要问 “这个钟在什么情况下会完全失效”**。这是攻防非对称性的承认——攻击者只需找到一个漏洞，防御者需要堵住所有漏洞。

§6 鲁棒性与形式化验证：抵御 “钟” 的失效

§6.1 鲁棒性：在扰动中保持纤维稳定

鲁棒性研究模型在输入扰动下保持输出稳定的能力。对抗性训练是最直接的方法：在训练数据中混入对抗性样本，让模型学会不被微小扰动所迷惑（Madry et al., 2018）。

在纤维语言中，对抗性训练试图**熨平纤维边缘的褶皱**：通过在训练中加入扰动样本，提高模型在训练所覆盖扰动类型上的输出一致性，而不是保证某个完整数学邻域内绝不跳变。这不是全局消除读数的不确定性——那受限于第三层——而是改善局部行为的平滑性与可预测性。换言之，对抗性训练试图扩大同一输出的稳定区；它缩小的是观测者面对已训练扰动时的不可预测性，不是纤维本身，也不提供形式化验证意义上的邻域保证。

鲁棒性面临第二层困境：攻击者会适应。当一个防御方法被公开，新的攻击方法会专门设计来绕过它。鲁棒性不是一次性的成就，是与攻击者之间的军备竞赛。

§6.2 形式化验证：划分纤维内的 “保证区”

形式化验证试图用数学方法证明模型在规定的输入区域和模型假设下，输出满足明确指定的性质（Katz et al., 2017; Seshia et al., 2022）。在纤维语言中，形式化验证试图划分出 “保证区”——在这个区域内，模型的输出被证明满足明确规定的性质（如输出在界内、扰动邻域内分类不变），其行为可以得到严格保证。保证的对象是性质，不是纤维成为单点：“邻域内分类不变” 这一典型验证目标，恰恰意味着整个扰动邻域被折叠进同一输出的纤维。

这在航天、医疗、自动驾驶等安全攸关领域至关重要。但形式化验证也遭遇第三层的硬边界：在实践中可被实际验证的属性仅仅是系统行为完整高维空间中的低维子集（如 “输出在边界内”、“控制命令不违反物理约束”），而高维属性（如 “输出的语义恰当性”、“上下文的语用合适性”）超出了当前验证工具的可及范围。验证提供了一个安全的 “内核”，但内核之外仍是未验证的、纤维膨胀的区域。工程实践的目标是将核心安全属性划入内核，同时诚实地标注内核的边界。

MacKenzie（2005）从科学社会学视角提供了对形式化验证局限的独立经验佐证。他区分了两种 “证明” 的含义：形式证明是一串有限的、合式的公式序列，它们一步步通向定理；与之相对，“严格论证” 是被数学家接受为数学证明的论证，但并不属于上述意义上的形式证明（MacKenzie, 2005）。更关键的是，验证工具本身也是复杂程序，其自身缺陷无法被预先排除——MacKenzie 记录的定理证明器缺陷数量不多、发现即被修正，但似乎没有任何设计者能给出 “不存在残留缺陷” 的明确保证：

> designers of automated theorem provers often reported experience of ‘bugs’ in their systems that would have allowed ‘theorems’ that they knew to be false nevertheless to be proven (MacKenzie, 2005)
>
> 译文：自动定理证明器的设计者们经常报告说，他们的系统中存在缺陷，这些缺陷会使他们明知为假的 “定理” 仍然能够被证明。

在纤维语言中，形式化验证可以在给定模型、假设和证明系统下确立所验证的性质。剩余限制有两个来源：验证工具及其实现可能存在缺陷，规格也可能没有覆盖任务所需的其他性质。减少前一类风险，不自动补足后一类边界；但两者都不取消已经获得的限定保证。

§7 可解释性：追问 “钟” 的构造

可解释性（Explainable AI，XAI）试图回答一个元问题：这个读数是如何产生的？映射函数的结构是什么？

归因方法——如沙普利可加性解释（SHapley Additive exPlanations，SHAP）、局部可解释模型无关解释（Local Interpretable Model-agnostic Explanations，LIME）——以不同方式估计输入特征与模型输出之间的关系（Lundberg & Lee, 2017; Ribeiro et al., 2016）：SHAP 按 Shapley 值及背景约定分配特征贡献，LIME 在预测点附近训练局部可解释代理。二者都提供关于模型行为的近似解释，不直接等于对内部因果路径的线性还原。思维链（Chain-of-Thought，CoT）让模型显式输出推理步骤（Wei et al., 2022），将推理的表述外部化——为观测者提供一条可检查的显式推导路径。但表述不等于内部计算过程本身：如 §5 所示，模型可以在没有图像的情况下生成貌似基于图像的推理——推理文本的忠实性需要独立检验。

但可解释性遭遇第三层的最直接限制：**任何解释本身都是映射**——从模型行为或内部状态到人类可理解的语言或可视化。解释的纤维同样非单点。一个沙普利可加性解释（SHAP）值的条形图没有 “完整解释” 模型的决策，它只是用一个低维的、人类可理解的映射替代了高维的、不可理解的原始映射。正因为解释本身也是映射，可解释性并不能保证它所展示的 “纤维” 与真实的纤维一致——解释自身也可能制造伪小纤维（让纤维在使用者的感知中比实际更小、更确定——例如一个精致的 SHAP 条形图让使用者误以为 “我已经完全理解了这个决策”）。

可解释性的目标因而更谦逊：不是消除纤维，甚至不能保证纤维被完整呈现，而是给使用者一个有别于模型原始输出的第二通道来形成判断——让使用者知道 “这里有一个不确定的跳跃”，知道 “在既定归因约定下，哪些特征与这个输入上的输出变化关系较强”，从而决定是否进一步核验或信任这个输出。

可解释性因此是元审计的核心工具之一。它不替代校准；当解释自身的忠实性得到检验时，它才让校准的不完全性变得可觉察。

§8 治理与合规：制度化校准的纪律

治理与合规将前述技术实践制度化为组织与社会的操作规范。美国国家标准与技术研究院（NIST）的 AI 风险管理框架（AI RMF），将 AI 风险管理分解为治理（Govern）、映射（Map）、测量（Measure）、管理（Manage）四项职能（NIST, 2023）。人工智能管理体系标准（ISO/IEC 42001）定义了 AI 管理体系的组织要求。欧盟 AI 法案以立法的形式为不同风险等级的 AI 系统设定了合规义务（European Parliament and Council of the European Union, 2024）。

在纤维语言中，这些框架本质上是在建立第一章（时钟的房间）所呼吁的**记账结构**：要求记录映射函数的已知程度、行为指标所显示的剩余不确定性、校准的时间和责任人、谁在承担纤维膨胀的后果。其中 NIST AI RMF 以自愿框架引导记录，ISO/IEC 42001 与欧盟 AI 法案分别以体系要求和法律义务规定之。记账不消除纤维，但防止 “忘记纤维的存在”。“窗户还打得开” 是一个容易被遗忘的事实——不是因为窗户一定被封死了，而常常是因为在日常操作中不需要开窗（时钟读得顺、闭环内校验通过）时，开窗的动作就被从日常操作中排除出去了。治理框架的制度力量在于要求记录 “窗户还打得开”——即使当前的时钟校准闭环看似自足。

但记账结构的设立不等于记账纪律的维持——在快速演化的应用场景中，制度记录可能跟不上使用的速度。医疗领域提供了一个具体场景。Biro et al.（2026）在 *The Lancet Primary Care* 的评论中指出，生成式 AI 在初级医疗中的采用速度已超越既有患者安全框架——医护人员往往既缺时间，其中许多人也不具备对复杂不透明系统进行有效质询的计算素养——他们因此主张，初级医疗中的安全应被理解为人-AI 团队的涌现属性，而非临床医生或技术单方面的特征。

这一判断同时包含对现行监管的批评：在 Biro et al. 看来，长期以来的健康技术监管模式把安全当作技术自身的属性，聚焦于部署前针对技术性能基准的评估；而新兴监管努力——欧盟 AI 法案即为其一——在很大程度上延续的正是这种以产品为中心的逻辑；这套逻辑依赖的假设是风险可以被前置评估充分预见和约束，而该假设虽在一些 AI 应用上成立，在初级医疗中未必成立（Biro et al., 2026）。

这一立场与美国国家标准与技术研究院（NIST）人工智能风险管理框架（AI RMF）的 “治理-映射-测量-管理” 四职能中的 “映射-测量-管理” 三环节（治理为总揽）相呼应：只测量模型，纤维就被遗忘；把整条诊疗链纳入审计对象，记账结构才落地。（按：2024 年欧盟 AI 法案原始文本第 72 条已规定高风险系统的上市后监测、第 73 条规定严重事件报告；Biro et al. 的批评指向其整体的产品中心逻辑，而非完全没有部署后机制。）

§9 持续监测：应对第二层的军备竞赛

持续监测直接应对第二层的适应性偏移，也覆盖部署后环境与任务变化造成的其他偏移。模型部署后，数据分布与输入-目标关系都可能偏移（概念漂移；Gama et al., 2014），攻击者会适应（攻防军备竞赛），使用模式会改变（任务漂移）。持续监测追踪这些变化，在监测指标显示失效风险超过预设阈值时触发警报。

监测的核心指标包括：模型性能的衰减、输出分布的变化、公平性指标的偏移、对抗性攻击的成功率上升。在纤维语言中，持续监测是**持续看太阳**的操作化——不是一次性的校准，而是持续的警觉。监测只有接入独立结果、抽样人工核验或其他外部反馈时，才执行 “看太阳” 的功能；仅凭内部统计的稳定不能证明系统仍然正确。它与治理框架结合，形成完整的 “检测-响应” 闭环：监测发现异常，治理触发重新校准或系统降级。

§10 统一结构：工程范式的操作化整合

将各工程范式置于时钟房间的统一框架下，我们可以得到以下操作化表格（表中记号 L1、L2、L3 分别指三层不可逆的第一层信息缺失、第二层动态腐蚀与第三层本体论降维）：

工程范式	核心操作	针对困境	纤维语言功能	典型技术/标准
对齐与护栏	获取映射知识并设置边界	L1+L2（加剧 L2；不能覆盖 L3 的隐藏维度）；L3 边界承认	缩小纤维并标记其边界	人类反馈强化学习（RLHF）、宪法 AI（Constitutional AI）、大模型输入输出安全护栏（Llama Guard）
审计与红队	系统性评估与对抗性探测	L1, L2	估计整体行为风险与寻找局部失效极值	人工智能管理体系标准（ISO/IEC 42001）、对抗性机器学习（Adversarial ML）
鲁棒性与验证	抵抗扰动与数学证明	L2, L3 边界	提高训练覆盖扰动下的读数稳定性，并对明确性质划分保证区	对抗性训练（Adversarial Training）、神经网络形式化验证求解器（Reluplex）
可解释性	归因分析与推理生成	L1+L3	提供纤维形态的可见线索	沙普利可加性解释（SHAP）、局部可解释模型无关解释（LIME）、思维链（CoT）

工程范式	核心操作	针对困境	纤维语言功能	典型技术/标准
治理与合规	制度化评估问责	L1+L2+L3	建立记账结构	NIST 人工智能风险管理框架（NIST AI RMF）、欧盟人工智能法案（EU AI Act）
持续监测	部署后追踪偏移	L2 及其他部署后变化	接入外部反馈时持续看太阳	概念漂移检测（Concept Drift Detection）

这个统一结构揭示了一个常被忽视的层级关系：**没有单一范式能独立解决全部三层困境**。对齐解决 L1 和部分 L2，但受制于奖励黑客（L2 的侵蚀）和降维（L3）。护栏承认 L3，但不解决 L1 的校准问题。审计估计 L1 所涉及的行为风险，但无法阻止 L2 的腐蚀。红队探测 L2，但无法结构性地消除 L3。治理提供记账，但不替代技术层面的校准。监测触发响应，但响应本身依赖其他范式的工具。鲁棒性提高局部读数稳定性，验证对明确性质划分保证区，但两者无法消除第三层降维与保证区之外的间隙。可解释性使纤维可见，但解释本身也是映射、其纤维同样非单点。

因此，可审计 AI 的工程实践必须是一个**组合策略**——不是选择一个 “最好的” 范式，而是在不同层次上部署相互补充的工具，形成纵深防御。时钟房间框架的价值正在于此：它提供了一个统一语言，让不同范式的分工和边界变得清晰，防止 “用护栏替代对齐” 或 “用审计替代监测” 的范畴错误。

§11 结论：可管理的不完美

时钟房间的最终教训是：在映射与存在之间，永远横亘着第三层意义上的纤维——其维度损失不可消除、不可恢复、不应被遗忘。这一判断同样适用于当代 AI 系统。任何 AI 系统，无论多么精密、多么对齐、多么鲁棒，都是真实世界的一个映射——一个降维的、有损的、随时间腐蚀的映射。完美的可审计性是不可能的。

但这不意味着工程实践是徒劳的。恰恰相反，认识到映射的不可逆性，是将工程目标从 “完美校准” 调整为 “可管理的不完美” 的前提。**可管理的不完美**意味着：

- 纤维不必为单点，但其相关风险必须通过行为指标**估计并记录**（审计）。
- 校准不必永恒，但必须被**持续更新**（监测）。
- 边界不必消失，但必须被**明确标注**（护栏、可解释性）。
- 失败不必杜绝，但必须被**主动探测**（红队、对抗性测试）。
- 责任不必集中，但必须被**制度化分配**（治理、记账结构）。

这里定义的工程工具箱本身也是一个映射系统——一个关于 AI 系统的建模系统。它的纤维非单点。审计工具需要被审计；监测系统可能漂移；治理框架可能被俘获。承认这一递归约束不是对工程价值的否定，而是避免 “只需要更好的工具” 这一元叙事套利——以 “工具终将解决一切” 的叙事吸收一切质疑——的最后一道防线。可管理的不完美同样适用于工具箱本身。

工程范式的工具箱，是对时钟房间三层困境的结构化回应。它不能拆除房间，不能消灭映射，但可以让在房间里的观测者知道：**他在看钟，不是在看太阳；他的钟有哪些偏差；偏差在什么条件下会急剧膨胀；以及当偏差不可接受时，他可以选择退回时间维度——暂停读数，重新看太阳。**

独立验证不意味着每位使用者都必须独自重做全部技术工作。它要求组织保留可取得的外部证据、独立复核渠道、必要的时间与资源，以及暂停、纠正和申诉的权限。缺少这些条件，“打开窗户” 就只是一项名义权利。

可审计 AI 的最终保障不在算法之内，而在算法之外——它在于保留人类独立验证的能力，保持 “打开窗户” 的权利，以及拒绝将对真实状态的最终判断权交给任何一个映射系统，无论这个系统多么精密。工程实践的价值，是让这种权利保持可操作[3]。

参考文献

Amodei, D. et al. (2016). Concrete Problems in AI Safety. arXiv:1606.06565. https://arxiv.org/abs/1606.06565 [预印本，尚未经同行评审]

Asadi, M. et al. (2026). Mirage: The Illusion of Visual Understanding. arXiv:2603.21687v3. https://arxiv.org/abs/2603.21687 [预印本，尚未经同行评审]

Bai, Y. et al. (2022). Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073. https://arxiv.org/abs/2212.08073 [预印本，尚未经同行评审]

Biggio, B. & Roli, F. (2018). Wild Patterns: Ten Years After the Rise of Adversarial Machine Learning. *Pattern Recognition*, 84. https://doi.org/10.1016/j.patcog.2018.07.023

Biro, J., Jabbarpour, Y. & Ratwani, R. (2026). A New Approach to Artificial Intelligence Safety in Primary Care. *The Lancet Primary Care*, 2(3), 100115. https://doi.org/10.1016/j.lanprc.2026.100115

Center for AI Safety, Scale AI & HLE Contributors Consortium. (2026). A Benchmark of Expert-Level Academic Questions to Assess AI Capabilities. *Nature*, 649. https://doi.org/10.1038/s41586-025-09962-4

Christiano, P. F. et al. (2017). Deep Reinforcement Learning from Human Preferences. In *Advances in Neural Information Processing Systems*, 30. https://proceedings.neurips.cc/paper_files/paper/2017/hash/d5e2c0adad503c91f91df240d0cd4e49-Abstract.html

European Parliament and Council of the European Union. (2024). Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). *Official Journal of the European Union*, L, 2024/1689. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Gama, J. et al. (2014). A Survey on Concept Drift Adaptation. *ACM Computing Surveys*, 46(4), Article 44. https://doi.org/10.1145/2523813

Inan, H. et al. (2023). Llama Guard: LLM-based Input-Output Safeguard for Human-AI Conversations. arXiv:2312.06674. https://arxiv.org/abs/2312.06674 [预印本，尚未经同行评审]

ISO/IEC 42001:2023. Information Technology — Artificial Intelligence — Management System. https://www.iso.org/standard/42001

Katz, G. et al. (2017). Reluplex: An Efficient SMT Solver for Verifying Deep Neural Networks. In *CAV 2017*. https://doi.org/10.1007/978-3-319-63387-9_5

Lin, S., Hilton, J. & Evans, O. (2022). TruthfulQA: Measuring How Models Mimic Human Falsehoods. In *ACL 2022*. https://doi.org/10.18653/v1/2022.acl-long.229

Lundberg, S. M. & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. In *NIPS 2017*. https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

MacKenzie, D. (2005). Computing and the Cultures of Proving. *Philosophical Transactions of the Royal Society A*, 363(1835). https://doi.org/10.1098/rsta.2005.1649

Madry, A. et al. (2018). Towards Deep Learning Models Resistant to Adversarial Attacks. In *ICLR 2018*. https://openreview.net/forum?id=rJzIBfZAb

NIST. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1. https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-ai-rmf-10

Ouyang, L. et al. (2022). Training Language Models to Follow Instructions with Human Feedback. In *NeurIPS 2022*. https://doi.org/10.52202/068431-2011

Rebedea, T. et al. (2023). NeMo Guardrails: A Toolkit for Controllable and Safe LLM Applications with Programmable Rails. In *EMNLP 2023 (Demo Track)*. https://doi.org/10.18653/v1/2023.emnlp-demo.40

Ribeiro, M. T., Singh, S. & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. In *KDD 2016*. https://doi.org/10.1145/2939672.2939778

Seshia, S. A., Sadigh, D. & Sastry, S. S. (2022). Toward Verified Artificial Intelligence. *Communications of the ACM*, 65(7). https://doi.org/10.1145/3503914

Skalse, J. et al. (2022). Defining and Characterizing Reward Hacking. In *NeurIPS 2022*. https://doi.org/10.52202/068431-0687

Wei, J. et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. In *NeurIPS 2022*. https://doi.org/10.52202/068431-1800