《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第十二章：时钟房间里的工程师——元审计对可审计 AI 的三个诊断增量

摘要

当代人工智能（AI）可信性工程——对齐、护栏、审计、红队、鲁棒性、可解释性、治理——是对真实问题的真实回应。本章不质疑这些实践的价值。本章追问的是：将它们置于时钟房间的三层不可逆框架下，是否能分离出仅凭分项工程指标不易看见的结构？

答案是三个诊断增量。第一，在特定操作化与持续作用条件下，有帮助、诚实、无害（Helpful，Honest，Harmless，HHH）共同作用于同一使用者，构成协同压缩校准空间的机制；本章用 “乘积” 标注这种结构，其净后果还须结合独立校准和恢复来源，不由三个原则的名称直接推出所有用户已失去校准能力。第二，对齐的 “太阳” 可能正在被屏幕替代：当标注者的判断依据受到 AI 输出生态塑造、其反馈不再提供独立信息时，人类反馈强化学习（RLHF）的反馈回路可能退化为映射的自我引用——用钟校准钟。第三，机制可解释性与事后归因之间存在一个尚未被清晰揭示的本质区分：前者是拆开时钟看齿轮（直接接触映射函数），后者是用一个新映射近似旧映射（纤维上的纤维）。

三个诊断增量沿着同一条校准链展开：用户是否保留主动判断的条件，校准源是否仍能提供独立约束，解释工具的结果是否经过适当检验。工程实践的目标不是完美的校准——是可管理的不完美。可管理的边界取决于三个条件：用户意识到自己在使用映射系统，校准者本身的独立性得以保持，对映射检验所新增的证据与误差得到区分。当这三个条件被侵蚀时，不完美从 “可管理” 滑向 “不可管理”。本章的目标不是替代工程实践，是在工程实践的边界上标注三块此前未被标注的警示牌。

关键词

人工智能（AI）对齐；有帮助、诚实、无害（HHH）原则；机制可解释性；人类反馈强化学习（RLHF）；映射自我引用；纤维框架；元审计

§1 为什么需要这一章

AI 可信性工程在过去十年间取得了实质性进展。对齐研究从人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF；Christiano et al., 2017; Ouyang et al., 2022）发展到宪法 AI（Constitutional AI；Bai et al., 2022）再到直接偏好优化（DPO；Rafailov et al., 2023）。红队演练从学术实验变为行业标准。欧盟 AI 法案（European Parliament and Council of the European Union, 2024）和美国国家标准与技术研究院（NIST）的 AI 风险管理框架将治理制度化。这些进展是真实的。它们减少了模型生成有害内容的频率，提高了系统对对抗性攻击的抵抗能力，建立了问责的制度框架。

本章不是从外部批评这些进展。本章做的事情是：将时钟房间的三层不可逆框架[1]作为一面棱镜，转向这些工程实践，看看棱镜是否能分离出仅凭分项工程指标不易看见的频谱。如果棱镜只是把已知的事实用新术语复述一遍，它就没有价值。如果它能识别出至少一个此前未被标注的结构性问题，它就有价值。

关于术语：本章沿用第十一章 §1 的术语约定，以 “可审计 AI”（Auditable AI）取代业内通行的 “可信 AI”（Trustworthy AI）——工程目标不是让 AI 值得被信任，而是让 AI 可以被独立审计，让使用者保留对映射系统进行周期性回溯的结构性权利。后文在描述工程界自身的历史表述时保留 “可信性工程” 等原始提法，本章自身的立场词统一采用 “可审计”。

以下三节各展示一个这样的问题。每一个都从 “工程界的标准理解” 开始，然后展示纤维框架如何揭示一个不同的结构，最后给出对从业者的操作性建议。§5 将以一个简化的动力学方程整合三个增量的交互效应——方程中涉及的退化系数（α）、恢复率（β）、AI 叙事载荷减载系数（F_{AI}）和指定参考条件下的元审计能力基线（$A_{user}^{intrinsic}$）将在该处定义。

本章的三个增量构成纵深防御的三层防线：§2 在明确的操作化与持续作用条件下分析有帮助、诚实、无害（HHH）怎样协同压缩用户的校准空间（第一道防线：用户自身的警觉）；§3 论证当用户（包括人类反馈强化学习标注者）都生活在 AI 输出生态中时，本应指向 “太阳” 的校准通道退化为回声（第二道防线：外部校准源的独立性）；§4 论证当我们试图用可解释性工具弥补前两层失效时，事后归因被误认作机制接触，新增解释层的证据与误差未被区分（第三道防线：诊断工具的可靠性）。三道防线可以在同一使用过程中相接并可能相互强化；是否彼此加速须另行识别，不能由并列诊断直接推出。本章独立成章的理据是：读者若把其中任一增量单独抽出来并入其他章节，递进结构的端到端诊断价值会失去。

§2 第一个增量：HHH 是乘积，不是加和

§2.1 工程界的标准理解

Askell 等人（2021）在 Anthropic 的原始论文中将有帮助、诚实、无害（HHH）定义为 AI 助手的三个核心属性：

- **Helpful（有帮助）**：根据用户需求提供有用的回应，完成任务，回答问题。
- **Honest（诚实正直）**：不生成已知为错误的内容，在不确定时标注不确定性，不编造信息。
- **Harmless（无害）**：避免产生可预见的伤害，拒绝危险请求，不生成仇恨或暴力内容。

Askell 等人（2021）把三者的关系表述为需要折衷：

> and the best AI behavior will involve a compromise between them (Askell et al., 2021)

[1]时钟房间思想实验及其三层不可逆框架的论证，参见第一章。核心概念——纤维、映射函数、校准、三层不可逆、时间/时钟维度区分、元审计——在第一章中已有完整定义。本章假定读者已阅读第一章。

译文：而最好的 AI 行为将需要在三者之间作出折衷。

Helpful 包含不帮助有害活动的但书（“as long as this isn’t harmful”，只要无害），Honest 要求准确、校准和恰当表达不确定性，Harmless 要求拒绝危险请求并谨慎处理高后果建议；附录 E 还区分同一主体与不同主体之间的冲突。这些规定不能直接推出适用于所有场景的 “Harmless 高于 Honest、Honest 高于 Helpful” 排序，更不能将避免伤害等同于避免一切不适。下节所讨论的具体操作化，是本书要检查的机制路径，不是上述规范定义的逐字转述。

评估可以分别记录三个维度，也可以采用综合评分或优先级安排；这些计分方法不等于已经证明三个目标对人的作用彼此独立或只可加和。本节要区分的是分项指标与共同作用于同一使用者的机制，而不是先为全部工程实践预设一种统一的加和理论。

§2.2 纤维框架的诊断

论证范围。第十章讨论满足特定条件的偏好拟合关系及其渐近方向；本节进一步分析有帮助、诚实、无害（HHH）的一条具体实现路径：持续代办减少主动判断节点，可见范围内的可靠表现遮蔽相关限制，避免不适被实现为减少有效挑战。这些实现是否共同压缩同一使用者的校准空间，与这种压力是否导致净衰减，是两项判断；后者还要检查挑战的持续不足，以及独立校准或恢复来源能否补足。以下论述区分这两级条件，不把三个原则的名称、一次交互或某个单项高分当成前提已满足的证据。§5 保留恢复项；本节所说的失守极限，不是对所有现实用户已达终态的测量报告。

时钟房间的框架揭示了一个不同的结构：三者的关系不是加和，是**乘积**。第六章 §6.4 已从垄断策略的角度给出这一判断——有帮助、诚实、无害（HHH）是知识壁垒、时间壁垒、叙事壁垒三种策略的乘积在当代 AI 系统中的工程化实现。本节从对齐工程的内部视角重申并推进该论证，两者的分工在于：第六章回答 “HHH 对垄断结构意味着什么”，本节回答 “HHH 对用户的校准行为意味着什么”——前者的判据是垄断的维持，后者的判据是用户元审计能力的存亡。

第一章 §6.1（AI 对齐与 HHH 的三难困境）已从认识论角度分析了每个词的困境。Helpful 的困境：当训练数据包含相互矛盾但置信度相同的信息源时，强行输出单一确定答案是一种表现为帮助的独断。Honest 的困境：若优化过程惩罚不确定性表达，模型可能以流畅回答掩盖无知，并复述训练数据中的人类常见错误（Lin et al., 2022）——校准误差还可能在问题超出训练分布时升高（Kadavath et al., 2022）。Harmless 的困境：在缺乏绝对校准的高风险领域，用温柔的语气给出毁灭性的方向——表面的无害掩盖了实质的有害。

三个维度作用于同一个用户，其注意力与主动判断机会有限，因此必须考察它们的组合。同一接收者是联合分析的前提，但不单独证明各项作用必定同向。本节在上述操作化与持续作用条件下，用 “乘积” 表示共同压缩校准空间的协同机制，不预设三个可量化因子的数值乘法，也不主张去掉一个器件就能消除其他机制。其净后果须与独立校准和恢复来源一并判断。

Helpful 消除了摩擦。当 AI 系统即时响应用户的每一个请求、草拟邮件、总结文档、生成代码、回答用户甚至没有完全成形的问题时，用户与信息之间的操作摩擦被系统性地清除。第二章 §3.1（老子《道德经》第十一章：“有之以为利，无之以为用”——碗的功能来自空腔而非填充物）论证的 “无”——生物学底座的未被占用部分——被填满。关键点：不是被垃圾填满，是被**有用的**东西填满。有用性会降低用户拒绝的动机。在持续代办且未保留主动判断节点的交互中，Helpful 会逐步填满轴孔的一部分。

Honest 在映射内部运作。第六章 §6.4 已给出这一判断的骨架：诚实评价通常只覆盖部分任务表现。若这些局部表现被泛化为对系统整体可靠性的背书，尚未验证的映射关系就会被遮蔽。问题不是系统

不能说明自身限制，而是诚实评分的适用范围被扩大了。本节补充对齐工程内部的证据。Casper 等人（2023）的综述指出：奖励模型以人类实际给出的认可而非对行为真实可取性的评分为训练信号——“什么是好的” 与 “什么被评价为好” 之间的差异可被模型利用，人类反馈强化学习（RLHF）训练的模型可能在错误时也听起来自信。在本书看来，这正是外观上的准确与实际准确相脱离的机制风险。

Sharma 等人（2024）的研究提供了相关经验例证：模型根据用户暗示的偏好调整回答——不是因为它“想讨好”，而是因为迎合性的回答在偏好数据中更常得到较高评分，偏好优化因而可能强化其中一些迎合行为。Honest 在映射内部运作；在上述实现中，它可能因形式上履行诚实义务而向用户供给 “这个系统是可信的” 感觉。

Harmless 操作化与做功空间。本节批判的是把无害性实现为避免用户受到任何质疑或认知挑战的路径，而非把 Askell 等人（2021）的 Harmless 规范直接定义为避免不适。在这种实现中，可能触发重新判断的信息被当作负面反馈处理；若它持续压低有效挑战、又缺乏补充来源，判别能力的维持条件便受到侵蚀。避免伤害、缓解无益的挫败与排除有效挑战必须区分，不能从安全目标本身直接推出反审计后果。

与第十章的衔接。第十章提供偏好拟合的关系性与渐近条件，以及有效挑战不足时判别能力受压的路径；本节把这些条件具体化为上述 HHH 操作化。能否从协同压力判断净衰减，仍按本节前述持续时间、有效挑战与恢复来源检查，不由第十章的命题编号或产品的 HHH 标签自动给出。

三者的乘积效应。在上述操作化与持续作用条件下，将三者放在一起看：Helpful 填满轴孔，Honest 供给可靠感，Harmless 封住碗的空腔——第六章 §6.4 将同一结构表述为时间壁垒、知识壁垒、叙事壁垒的乘积。三者的乘积不是 “三倍的可信”——是一个让用户**持续感觉被服务、被尊重、被保护**的系统，而用户启动独立校准的条件却持续受到压缩。三项目标之间可以有权衡；本章指出的是另一个层次的问题——在具体实现中，三个维度朝同一个方向叠加。

§2.3 诊断增量

工程界看到的是三个目标之间的权衡。纤维框架看到的是：分项指标的良好表现与校准条件受压可以并存。本节所称叙事壁垒，是上述操作化共同作用并缺少校准补充时的机制结果；它不等于三个 H 的高分之和，也不能仅凭高分推定任何使用者已经失守。

第六章 §6.4（HHH 作为三种策略的乘积）论证了 Helpful、Honest、Harmless 分别是时间壁垒、知识壁垒的反面包装与叙事壁垒的工程化实现——有帮助、诚实、无害（HHH）的乘积因此不是新的垄断策略，而是垄断结构在当代对齐工程中的再现，用的是舒适而非强制。“我在这里提供帮助”（Helpful），“我说的都是真的”（Honest），“我不会令人不适”（Harmless）。三者叠加的信息是：**用户不需要校准我。我已经替用户校准好了。**

这不是说有帮助、诚实、无害（HHH）应该被废弃。HHH 确实减少了具体伤害——阻止部分危险指南的生成、减少仇恨言论、降低模型被用于恶意目的的风险。

第六章 §6.4 已点破：有帮助、诚实、无害（HHH）的问题不在于作为安全工程的失败，而在于作为叙事壁垒的**成功**。本章从对齐工程的视角补上其认识论后果：如果多个产品相互重复同一可靠性背书，而没有增加关于映射的独立信息，宣称数量增加不能替代校准；但共同采用 HHH 名称本身，也不足以认定各项具体测量的信息增益为零。

Stanford HAI（2026）有关安全性与准确性权衡、事故记录的材料，可以作为检查安全工程局限的背景。报告指出：

> improving one responsible AI dimension, such as safety, can degrade another, such as accuracy (Stanford HAI, 2026)
>
> 译文：改进负责任 AI 的一个维度（如安全性），可能损害另一个维度（如准确性）。

报告另记载，有记录的 AI 事故从 2024 年的 233 起增至 2025 年的 362 起（口径为 AI 事故数据库收录的有档案事故）。但这些指标并不直接测量用户是否启动核查、校准动机是否下降或有帮助、诚实、无害（HHH）是否具有组合效应。不能把评估维度之间的权衡、事故数量变化与用户判别能力的衰减当成同一个量。后者需要围绕具体交互和使用者补充观察，不能由前述背景材料直接确证。

对从业者的操作性建议：在评估 AI 系统的对齐程度时，不仅衡量每个 H 的单独表现——还应衡量三者乘积对用户校准行为的实际影响。可能的度量指标包括：用户对 AI 输出的主动验证频率、用户在接收 AI 建议后寻求第二意见的比例、用户对模型不确定性的感知准确度。一个在每个 H 上都得高分但使用户校准行为显著下降的系统，在**校准条件的维持**这一维度上，比一个某个 H 得分较低但保留用户校准习惯的系统风险更高——前者可能持续削弱元审计的做功场景，后者至少保留了窗户。该比较不等于对两个系统所有安全维度作出总体排序。在 §5 的概念方程中，本节机制可以体现为退化项增强；是否发生净衰减仍须与恢复项比较，不能仅由有帮助、诚实、无害（HHH）名称或分项得分判断。

§3 第二个增量：太阳正在被屏幕替代

§3.1 对齐研究的标准假设

人类反馈强化学习（RLHF）和许多基于人类反馈的对齐方法，把人类反馈当作主要校准来源。就模型而言，标注者位于其输出闭环之外，因此被视为 “太阳”；就真实而言，他们的校准资格仍取决于判断所使用的原始材料与独立证据。模型通过追随人类偏好学习被偏好的行为，并不因此自动接近真实。

这一校准通道在特定任务中可以部分成立。在摘要评估等任务中，标注者可以通过阅读原文形成对输出的判断；只要该判断不依赖任何 AI 系统的输出，校准链的起点就是标注者对原始材料的直接接触。

§3.2 假设正在失效

需要检查的不是标注职业本身，而是标注者在任务之外的 AI 使用，以及这种使用是否进入其判断依据。若标注者的日常判断已被系统输出塑造，§2 所讨论的用户警觉与本文所讨论的校准源独立性就会通过同一机制相接。

2024—2025 年，两个相互强化的趋势使这一假设面临根本性挑战。

趋势一：部分标注者生活在 AI 输出的生态中。当代标注者和其他信息工作者越来越多地通过 AI 系统获取信息、组织思考和辅助写作。若标注者在评估模型输出时沿用了这些交互形成的标准，其 “偏好” 就不再完全独立于 AI 系统。一个标注者判断某段文字 “流畅” 或某个回答 “有帮助” 时，需要检查其标准来自原始材料、任务规范，还是来自日常使用 AI 写作助手所形成的预期。在后一种情形中，他不是独立于系统的观察者，而是在用受 AI 影响的判断评估 AI。

趋势二：部分模型训练包含自身或其他模型的输出。 Shumailov 等人（2024）在 *Nature* 上发表的模型坍塌研究，在受控递归训练实验中表明：若后续模型无区别地反复使用模型生成内容，原始内容分布的尾部会消失，并可能出现不可逆缺陷；该机制也在变分自编码器与高斯混合模型中观察到。这个结果证明特定训练协议的风险，不单独证明互联网当前的合成内容规模已使下一代模型普遍进入不可逆退化，也不否定保留真实数据、累积数据、筛选合成数据或外部验证等其他训练路径。

在上述递归协议中，罕见信息会先从输出分布中消失。与此同时，AI 生成或 AI 辅助生成的内容正在回流 Reddit、Stack Overflow、个人博客等公共语料，下一代模型的训练数据也可能混入这些内容。回流是否导致模型坍塌，须进一步考察合成内容占比、筛选方式、真实数据保留和训练代际，不能仅凭合成内容已经出现就判定坍塌已经发生。

两个趋势在满足上述自我引用条件时，可能汇合为第一章 §4.2（动态腐蚀）论证的**映射的自我引用**：映射函数（π_i）可以从真实状态映射 $\pi_i(T)$ 退化为其他读数映射 $\pi_i(\{r_j\}_{j\neq i})$（r_j 为其他映射的读数）。此时，真实状态（T）从映射的直接输入中部分消失。时钟不再指向太阳——时钟指向其他时钟。

在对齐的语境中，上述条件成立时，本应作为 “太阳” 的标注者判断会受到模型输出影响。标注者评估模型 A 时，其判断基准可能已被他与模型 B、模型 C 的日常交互塑造；模型 A 仍在优化标注者偏好，但该偏好已部分成为其他模型输出的函数。此时，校准通道出现自我引用，太阳也就在相应程度上变成了屏幕。

§3.3 与可扩展监督问题的区分

工程界已经注意到一个相关但不同的问题：可扩展监督（scalable oversight）。当模型处理的任务超出标注者能够可靠评价的范围，且现有证明、测试或结果证据不能补足时，人类反馈的有效性便受到限制。问题不在于标注者能否亲自生成同样的答案，而在于能否可靠检验答案。这个问题的标准表述是：太阳太远了，标注者看不清。解决方案的思路是：用更强的工具辅助标注者（如 AI 辅助评审、辩论方法），让标注者能看清更远的东西。

纤维框架识别的另一个问题是：**太阳可能正在变成屏幕**。可扩展监督主要检查标注者的判断精度是否足够；自我引用问题还要检查判断基准是否独立。两者可以并存，不能用增强工具替代独立性检查。

这个区分的操作性后果是不同的：

- 可扩展监督的解决方案是**增强标注者的能力**：给他们更好的工具，让他们能评估更强的模型。
- 自我引用问题的解决方案必须更激进：**建立不以当期偏好评分为唯一依据的校准通道**。例如：
  - 用物理实验结果（而非人类偏好）校准科学推理能力——模型预测的实验结果是否在真实实验室中被验证？
  - 用法律判决记录（而非标注者打分）校准法律建议的准确性——模型的法律意见是否与法院实际判决一致？
  - 用长期健康结果（而非即时满意度）校准医疗建议的质量——在能够处理选择偏差和混杂的比较设计中，考察遵循模型建议的患者是否比不遵循的有更好的健康结局？

这些校准通道的共同特征是：它们锚定在独立于被评系统自我确认的因果链上。物理实验、法院判决和长期健康结果都可以形成外部约束，但仍须检查证据的生成过程、任务适配性和潜在偏差。法院判决记录若与训练数据隔离、且任务背景相符，可作校准材料；与既有判决的一致性只是证据之一。患者的长期健康结果由生理过程与人类行动共同形成，解释时仍须处理治疗选择、依从性、选择偏差和混杂。独立性指证据不由被评系统自我确认，不指证据无需人类判断或不受人类行动影响。这些是**真正的窗户**，不是屏幕。

§3.4 诊断增量

工程界看到的是 “当模型太强时标注者跟不上”。纤维框架还要求检查：**标注者的判断基准是否独立于被评估系统**。这个问题不取决于模型能力强弱，而取决于 AI 输出是否实际进入判断依据。AI 输出渗透

率上升可能削弱标注者独立性，但两者关系受任务、原始材料接触和标注流程调节，不能预设严格单调关系或统一临界值。只有当反馈不再提供独立信息时，它才不再是独立校准，而成为回声。

这个诊断增量的价值在于：本章主张把标注者的 AI 暴露度列为显式监测变量。模型性能、标注者一致性和奖励模型准确性，都不能单独回答标注者的判断是否独立。暴露的频率、深度、任务相关性与来源多样性，是评估人类反馈强化学习（RLHF）长期校准价值时需要分别检查的变量。

对从业者的操作性建议：在设计对齐管线时，追踪标注者的 AI 暴露度及其与当前任务的关系。当监测显示反馈不再提供独立信息时，不应再把这些数据单独当作独立校准证据；若继续使用，须标注其依赖关系并配合独立校准通道。可检查的补充路径包括：寻找低 AI 暴露且能接触原始材料的标注者，使用经任务时效性检验的历史人类判断，以及建立不依赖在线偏好的物理或结果校准通道。在 §5 的方程中，这一机制只支持 AI 叙事载荷减载系数（F_{AI}）的训练侧供给可能受损，不支持未减载比例（$1 - F_{AI}$）必然持续接近 1。

§4 第三个增量：拆开时钟和用新映射近似旧映射是两件不同的事

§4.1 可解释性的两种路径

当代可解释性研究存在两种根本不同的路径，工程文献通常将它们归入同一个标题下——“可解释人工智能（XAI）”。纤维框架揭示它们的认识论地位完全不同。

事后归因（Post-hoc Attribution）。沙普利可加性解释（SHapley Additive exPlanations，SHAP；Lundberg & Lee, 2017）、局部可解释模型无关解释（Local Interpretable Model-agnostic Explanations，LIME；Ribeiro et al., 2016）等方法从模型外部观察输入-输出关系，用一个简单的、可解释的代理模型近似原始模型在特定输入邻域的行为。SHAP 基于 Shapley 值计算每个特征对预测的边际贡献；LIME 在预测点附近生成扰动样本，训练一个局部可解释模型。

在时钟房间的语言中：分析者不拆开时钟——在时钟外面放了另一个更简单的时钟，希望简单时钟的读数能告诉分析者复杂时钟的工作原理。

在纤维语言中，这是**映射的映射**。原始模型通过原始映射函数 π_1 将真实状态 T 映射为读数 r_1（$\pi_1 : T \to r_1$）。归因方法把模型、输入与背景约定加工为特征重要性分数——分析者最终看到的解释（一张沙普利可加性解释（SHAP）值的条形图）与真实状态 T 之间，隔着归因工具自身的映射。这层映射有自己的纤维。若解释只是对既有读数的重新编码，它不会自动消除关于真实状态 T 的原有信息缺失；但归因工具还调用模型与输入，因此不能仅凭 “又增加了一层解释” 断言关于真实状态的纤维必然扩大——须检查它增加了哪些证据、依赖哪些约定。

事后归因改变的是分析者可以获得的行为证据及其误差结构。额外查询模型和输入，可能减少对局部输入—输出行为的不确定性；代理近似又会引入自身误差。净效果须由新增证据、代理保真度和背景约定共同判断。若解释只是既有读数的重编码，它不会消除关于真实状态 T 的原有信息缺失；即使解释准确刻画模型行为，也不等于建立对真实状态 T 的外部校准。

机制可解释性（Mechanistic Interpretability）。Elhage 等人（2022）、Conmy 等人（2023）的工作走的是完全不同的路径。他们直接检查模型的内部表征——哪些神经元在特定输入下激活、信息如何在层与层之间流动、什么样的 “特征”（feature）被模型的内部状态编码。Elhage 等人的 “叠加假说”（superposition hypothesis）试图理解模型如何在有限维度的表征空间中压缩远多于维度数量的特征。Conmy 等人的自动电路发现（Automated Circuit Discovery）试图定位模型中负责特定行为的子网络。

在时钟房间的语言中：分析者拆开了时钟的后盖，直接看齿轮的啮合方式。

在纤维语言中，机制可解释性不再以另一个输入—输出代理模型代替原模型，而是取得关于原始映射函数 π_1 的内部表征与因果路径的证据。这里的 “不增加代理层” 不等于没有观测映射：内部状态的读取、可视化和概念命名仍是降维表征，第三层不可逆仍然适用。机制证据可以减少分析者对局部内部机制的不确定性，但不自动缩小关于真实状态 T 的纤维，也不保证其误差总小于事后归因。

机制可解释性与事后归因的区分可以用 von Foerster 的术语获得更深的表述。von Foerster（2003）区分了 “琐碎机器”（trivial machine）——内部状态不随输入改变，输入输出关系固定、可预测——和 “非琐碎机器”（non-trivial machine）——内部状态随输入历史演化，机器随之变成另一台琐碎机器，对不知道其内部状态的观察者而言不可预测。

von Foerster 的区分涉及历史状态与输入—输出关系，本书的元审计判据则涉及独立参照，两者不是同一分类。本书将主体检查自身判断依据、并在需要时引入闭环之外证据的过程称为元审计回路。这是元审计能力在个体认知中的功能描述，不预先指定一个独立于既有认知过程的专门模块，也不要求先证明人类认知不能被归为 System 1 或 System 2。

当前大语言模型（LLM）是否具有本书所说的非琐碎成分，需要按上述状态判据分别检查，不能仅凭是否存在独立监控层判定[2]。对固定权重、固定上下文的一次前向计算，可以把该次计算的内部变换作为确定映射分析；若包含随机解码，还须另记随机性。保留对话历史、缓存或外部记忆的部署，则须说明状态如何更新以及是否改变后续行为。现有架构观察不足以把 LLM 整体归为琐碎机器，也不足以据此证明其具有元审计回路。本书能够确定的是：同一前向管道中的 “反思性” 文本，不自动构成跨越映射层级的独立元审计。

这个区分给机制可解释性赋予了更精确的功能定位：它从外部提供关于系统内部因果路径的二阶观察材料，不等于给系统自身装上元审计回路。事后归因同样可以提供外部的二阶观察材料，但其证据主要来自输入—输出关系，不能冒充内部机制证据；两者的差别在证据来源，不在能否被统称为二阶观察。

§4.2 区分的操作性后果

这个区分在当前可解释人工智能（XAI）文献中没有被用纤维框架清晰表述过。它的操作性后果涉及两种方法各自的适用边界和证据强度。

对事后归因方法的正确期望。沙普利可加性解释（SHAP）值回答的是在既定特征函数、背景分布和归因约定下，模型输出如何被分配为特征贡献。这是有用的——它可以帮助生成 “模型可能依赖这个特征” 的假说。但约定内的贡献分配不等于唯一的因果重要性。代理保真度可以由其他样本、扰动或干预结果检验，因果解释则还需额外的识别条件；因此既不能断言近似精度原则上不可评估，也不能把约定内精度当作因果忠实性。

事后归因适合**生成和筛查假说**，也可在明确操作定义后提供局部行为证据；它不适合**单独验证因果假说**。例如，SHAP 可以提示模型输出在某敏感属性上呈现较高归因权重，但不能仅凭这一结果证明模型确实在歧视。因果与公平性判断需要其他证据。

对机制可解释性的正确期望。拆开时钟看齿轮可以验证特定的因果假说。当实验者激活或抑制一组神经元，观察模型输出发生的变化，这是在建立因果联系——“当这组神经元被激活时，模型的输出发生

[2]Dupoux、LeCun 与 Malik（2026）提出的 “System A / System B / System M” 三层架构中，其 “System M” 是负责监测内部元状态并组织学习组件间信息流的元控制信号（Meta-Control），在两种学习模式（观察学习 vs. 行为学习）之间切换——按本书语言，它仍在可见子空间内做路由，并不跨越映射层级；元状态监测与学习模式切换本身不足以证明系统取得了独立校准依据，不能仅凭 “元控制” 之名将其登记为本书的元审计回路。

了这种特定的变化”。对同一个内部路径假说，控制适当的内部干预比单纯归因提供更直接的检验。但干预产生了输出变化，不等于已经确认所命名的语义特征及其在未干预状态下的全部作用。

但机制可解释性只覆盖了模型行为的**局部**——分析者看到了一组齿轮的啮合方式，但时钟有万亿个齿轮，不可能逐一检查。当前最先进的电路发现方法也只能定位相对简单的行为（如语法现象、事实回忆）的电路。对于复杂的推理行为，完整的电路仍然超出我们的分析能力。

局部机制发现不能单独承担跨任务、跨人群和跨部署条件的总体风险评估，还须与覆盖更广的行为测试结合。

两者的互补。两者不可互相替代：事后归因可以提供覆盖较广样本的近似行为地图，机制可解释性可以提供局部因果证据。地图不能替代岩石样本，岩石样本也不能替代地图。

§4.3 诊断增量

工程界通常将沙普利可加性解释（SHAP）和机制可解释性都归入 “可解释人工智能（XAI）工具箱”，在同一个标签下列举它们的优缺点。纤维框架揭示：**两者在认识论上处于不同的层次**。

- 事后归因是在原始模型之外增加解释映射。它可以通过额外模型查询和输入扰动提供新的局部行为证据，同时引入代理与背景约定误差；两类效应的净结果须分别检验。它不提供对真实状态 T 的独立校准，因此不能把行为解释当作外部校准锚点。
- 机制可解释性直接检查原始模型的内部表征与因果路径，不以另一个输入—输出代理模型代替原模型。它可以减少关于局部内部机制的不确定性，但观测和解释仍有自身映射，关于真实状态 T 的纤维不会仅因拆开模型而自动缩小。

这个区分的价值在于：它提供了一个原则性的方式来判断在给定场景中应该信任哪种解释、信任到什么程度。

对从业者的操作性建议：

1. **按待检验命题记录证据等级。**归因结果可以支持既定约定下的贡献分配或局部行为描述，不能单独证明现实因果效应或歧视。内部状态观察可以提出机制假说，适当的干预和对照才为特定因果路径提供进一步证据。审计报告须写明数据、约定、干预和结论范围，不能仅凭 “SHAP 分析” 或 “机制可解释性” 决定可信程度。
2. **投资与证据配置。**如果系统失效会导致不可逆伤害，应提高机制证据、因果干预和独立结果验证的投入优先级，但不能以覆盖较窄的机制发现替代覆盖更广的行为审计。SHAP 可以提示模型可能依赖错误特征；确认这一依赖需要机制可解释性、适当的因果干预或其他独立验证，而不是再增加一张归因图。在 §5 的方程中，本节机制对应实际叙事载荷（ϕ）得以维持或放大：误把事后归因当作充分验证，可能使用户不再启动进一步核查，但不推出退化项不受约束地增长。

§5 结论：可管理的不完美

三个诊断增量沿着同一条校准链展开：用户是否保留主动判断的条件，校准源是否仍能提供独立约束，解释工具的结果是否经过适当检验。工程实践能否支持元审计，不取决于工具位于模型内部还是外部，而取决于它是否接入独立证据，并保留复核与纠正的通道。纤维框架的作用，是把这些条件放在一起检查；它自身也不豁免于这一检查。

三个条件的动力学关系可以用一个方程刻画。设用户的元审计能力为 $A_{user}(t)$。其变化率由两项决定[3]：

$$\frac{dA_{user}}{dt} = -\alpha \cdot \Lambda \cdot \phi_0 \cdot (1 - F_{AI}) + \beta \cdot A_{user}^{intrinsic}$$

第一项是 AI 交互对用户元审计能力（A_{user}）的退化贡献：退化系数（α）调节退化强度，媒介传导系数（Λ）在本章具体化为 AI 输出到达用户的速率和精度。本节把指定参考部署中的载荷记为参考叙事载荷（ϕ_0），把实际释放的载荷记为实际叙事载荷（ϕ），后者沿用第三章的口径。在同一任务、接收边界和载荷尺度下，若 $\phi_0 > 0$ 且工程措施产生净减载，则以 $F_{AI} = 1 - \phi/\phi_0$ 表示该场景中的 AI 叙事载荷减载系数。因此，$\phi = \phi_0(1 - F_{AI})$。这里的 F_{AI} 是相对于指定基准的效果参数，不是一般护栏评分，也不是主体元审计能力。$[0, 1]$ 的范围只覆盖净减载情形；若措施反而增加载荷，不能把负效应截为零后仍声称等式成立，应直接按实际载荷记账，或另行允许有符号的效果参数。第二项是用户固有的恢复项：指定参考条件下的元审计能力基线（$A_{user}^{intrinsic}$）是用户在参考条件下能够维持的能力水平；恢复率（β）概括当前恢复条件的可用性与有效性，离线活动、深度阅读和面对面社交只有提供了判断练习、独立证据或关系做功时，才构成这些条件。

媒介传导系数（Λ）与退化系数（α）是结构性参数：媒介传导系数（Λ）由部署生态决定（AI 在用户日常中的渗透频率与触达精度），退化系数（α）由用户个体差异决定（认知习惯、批判性训练程度）；它们不由本章三个增量直接驱动；在本章的分析时段内，两者作为给定参数处理——在更长的时间尺度上，媒介传导系数（Λ）还会随用户依赖的加深而上升（第三章 §2.2 将媒介传导系数界定为被权力主体塑造的技术变量，而非外生常数），本式不显式化这一慢耦合。

用户元审计能力变化率（$dA_{user}/dt \geq 0$）表示所考察时段内能力没有净衰减，只是能力维持的局部判据。是否可管理，还须检查当前能力是否足以应对任务，以及独立证据、复核资源和纠正权限是否实际可用。当 §2 的条件被侵蚀时，HHH 的特定操作化可能使参考叙事载荷（ϕ_0）持续偏高；当 §3 的条件被侵蚀时，训练侧对 AI 叙事载荷减载系数（F_{AI}）的支持可能减弱；当 §4 的条件被侵蚀时，误判解释证据可能使实际叙事载荷（ϕ）得不到纠正。这些变化会提高退化压力，但不单独推出退化项单调增大。只有另有证据表明非 AI 交互减少使恢复率（β）下降，才能说恢复项减弱。若退化项在一段时间内持续大于恢复项，则用户元审计能力（A_{user}）在该时段下降；三个条件不必同步越界。这个可能相互强化的过程，是第五章 §3.2“非人对象制造了对非人对象的需求” 在工程层面的一个待检验展开。

- 仅检查每个 H 的分项指标，容易漏掉三者对用户校准行为的组合作用；追加 “用户的校准行为是否下降” 这一问题，才能检查叙事壁垒的形成条件。
- 仅检查标注评分和奖励模型优化，容易漏掉校准源的独立性；追加 “标注者的判断基准是否独立于被评估系统” 这一问题，才能检查自我引用回路。
- 仅比较两类方法产出的解释形式，容易漏掉证据来源和误差结构；追加 “新增了什么证据与误差、是否直接检查因果结构” 这些问题，才能识别两者的认识论差异。

纤维框架的价值因此不在于替代工程实践——在于提供一个**结构化的检查视角**。工程师在房间里修钟，框架要求同时追问：这些钟校准过了吗？（对齐）；校准者本身被校准过了吗？（标注者的独立性）；这些解释提供了什么证据，其结论又经过什么检验？（解释的证据来源与适用边界）。

[3]此方程为特定场景、局部时段内的定性表示，不用于长期积分或终态预测。退化系数（α）和恢复率（β）不可精确量化，但退化项与恢复项的相对大小可通过用户主动验证行为、非 AI 交互时间和不确定性感知等代理指标判断方向。本式右端不显含用户元审计能力（A_{user}），只刻画瞬时漂移；三个增量通过参考叙事载荷（ϕ_0）、AI 叙事载荷减载系数（F_{AI}）和恢复率（β）的变化进入，不据此主张它们必然彼此加速或各参数必然单调变化。指定参考条件下的元审计能力基线（$A_{user}^{intrinsic}$）表示用户在参考条件下能够维持的能力水平，不是系统的稳定均衡点，也不是无需做功便自动存在的储备。

工程实践的最终目标不是恢复完整真实状态。第一章 §4.3 限制的是凭有损读数恢复全部已损维度，不取消特定任务中的校准和验证。工程可以提高任务准确性，同时承认这种改进没有恢复映射所丢弃的全部维度。目标是**可管理的不完美**。

可管理的边界在哪里？三个诊断增量各自标注一类风险条件。任一条件受侵蚀都不足以单独推出不可管理；只有相应损伤持续存在，且独立校准与恢复来源不能补足时，才作这一判断：

1. **来自 §2 的条件**：当 HHH 的特定操作化使用户校准行为持续下降，且没有其他校准线索补足时，不完美可能变为不可管理。
2. **来自 §3 的条件**：当校准者独立性下降，且独立结果校准通道不能补足时，不完美可能变为不可管理。
3. **来自 §4 的条件**：当解释误差被误认为充分验证，且其他审计不能识别该误差时，不完美可能变为不可管理。

第一章 §4.2 的第二层不可逆（动态腐蚀——映射因使用而被改写）——纤维膨胀的压力持续得不到校准的消除——是这些条件的动力学基础。在 §2 所列条件下，有帮助、诚实、无害（HHH）的协同机制会压缩校准条件；其净作用仍须结合本节的恢复项判断。标注者独立性的丧失意味着校准源本身的漂移。可解释性方法的误用会掩盖解释自身的误差，而不是必然增加所有意义上的不确定性。

三块警示牌已经竖好。它们不拆除房间，不消灭映射。它们让房间里的工程师知道：**工程师在修钟，不是在修太阳。修好的钟仍然需要窗户。**

参考文献

《道德经》. 引文据王弼注本.

Askell, A. et al. (2021). A General Language Assistant as a Laboratory for Alignment. arXiv:2112.00861. https://arxiv.org/abs/2112.00861 [预印本，尚未经同行评审]

Bai, Y. et al. (2022). Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073. https://arxiv.org/abs/2212.08073 [预印本，尚未经同行评审]

Casper, S. et al. (2023). Open Problems and Fundamental Limitations of Reinforcement Learning from Human Feedback. *Transactions on Machine Learning Research*. https://openreview.net/forum?id=bx24KpJ4Eb

Christiano, P. F. et al. (2017). Deep Reinforcement Learning from Human Preferences. In *Advances in Neural Information Processing Systems*, 30. https://proceedings.neurips.cc/paper_files/paper/2017/hash/d5e2c0adad503c91f91df240d0cd4e49-Abstract.html

Conmy, A. et al. (2023). Towards Automated Circuit Discovery for Mechanistic Interpretability. In *NeurIPS 2023*. https://doi.org/10.52202/075280-0719

Dupoux, E., LeCun, Y. & Malik, J. (2026). Why AI Systems Don’t Learn and What to Do About It: Lessons on Autonomous Learning from Cognitive Science. arXiv:2603.15381. https://arxiv.org/abs/2603.15381 [预印本，尚未经同行评审]

Elhage, N. et al. (2022). Toy Models of Superposition. arXiv:2209.10652. https://arxiv.org/abs/2209.10652 [预印本，尚未经同行评审]

European Parliament and Council of the European Union. (2024). Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act). *Official Journal of the European Union*, L, 2024/1689. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Kadavath, S. et al. (2022). Language Models (Mostly) Know What They Know. arXiv:2207.05221. https://arxiv.org/abs/2207.05221 [预印本，尚未经同行评审]

Lin, S., Hilton, J. & Evans, O. (2022). TruthfulQA: Measuring How Models Mimic Human Falsehoods. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics*. https://doi.org/10.18653/v1/2022.acl-long.229

Lundberg, S. M. & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. In *Advances in Neural Information Processing Systems*, 30. https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

NIST. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1. https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-ai-rmf-10

Ouyang, L. et al. (2022). Training Language Models to Follow Instructions with Human Feedback. In *NeurIPS 2022*. https://doi.org/10.52202/068431-2011

Rafailov, R. et al. (2023). Direct Preference Optimization: Your Language Model Is Secretly a Reward Model. In *NeurIPS 2023*. https://doi.org/10.52202/075280-2338

Ribeiro, M. T., Singh, S. & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. In *Proceedings of the 22nd ACM SIGKDD*. https://doi.org/10.1145/2939672.2939778

Sharma, M. et al. (2024). Towards Understanding Sycophancy in Language Models. In *ICLR 2024*. https://proceedings.iclr.cc/paper_files/paper/2024/hash/0105f7972202c1d4fb817da9f21a9663-Abstract-Conference.html

Shumailov, I. et al. (2024). AI Models Collapse When Trained on Recursively Generated Data. *Nature*, 631. https://doi.org/10.1038/s41586-024-07566-y

Stanford HAI. (2026). *The 2026 AI Index Report*. Stanford University. https://hai.stanford.edu/ai-index/2026-ai-index-report

von Foerster, H. (2003). *Understanding Understanding: Essays on Cybernetics and Cognition*. New York: Springer.

附录 A 工程范式与三层不可逆的系统映射

各工程范式的详细纤维分析见第十一章 §4—§9。本附录提供精简版表格，标注正文三个诊断增量在全景中的位置。本表不复述第十一章的技术细节，只用于核对各范式的测量对象、证据边界和三个诊断增量的对应位置。

表中 "信息缺失""动态腐蚀""本体论降维" 分别指第一章 §4 论证的三层不可逆：信息缺失（映射函数未知时，读数不足以唯一确定真实状态）、动态腐蚀（映射因使用而被改写）、本体论降维（真实被压缩为读数时维度不可逆丢失）。

工程范式	核心操作	主要针对的困境	纤维语言中的功能	典型技术/标准
对齐	用人类偏好微调模型	信息缺失＋动态腐蚀	获取映射函数的部分知识；受制于奖励黑客（动态腐蚀的侵蚀）和本体论降维	人类反馈强化学习（RLHF）、宪法AI（Constitutional AI）、直接偏好优化（DPO）
护栏	设定输入输出的拒绝边界	信息缺失＋动态腐蚀（主要）；本体论降维（承认性）	在已知的纤维边缘设置拒止规则；过滤恶意输入（信息缺失），动态防御对抗性攻击（动态腐蚀）	NeMo 护栏框架（NeMo Guardrails）、大模型输入输出安全护栏（Llama Guard）
审计	系统性评估模型行为	信息缺失（主要）；动态腐蚀（漂移检测）	通过行为指标估计整体风险及其分布；检测性能随时间衰减	人工智能管理体系标准（ISO/IEC 42001）、NIST 人工智能风险管理框架（NIST AI RMF）
红队演练	模拟攻击者探测最坏情况	信息缺失（未知盲区）；动态腐蚀（适应性漏洞）	寻找纤维局部膨胀的极值——模型从可靠急剧变为不可靠的输入点	对抗性机器学习（Adversarial ML）、越狱测试（Jailbreak Testing）
鲁棒性增强	训练模型抵抗输入扰动	动态腐蚀	在输入邻域内局部稳定读数；面临攻击者适应的军备竞赛	对抗性训练（Adversarial Training）、数据增强（Data Augmentation）
形式化验证	在规定的输入区域和模型假设下证明明确指定的性质	本体论降维的边界	在纤维内部划分“保证区”——实践中可被验证的属性是行为空间中的低维子集	神经网络形式化验证求解器（Reluplex）、深度神经网络验证（DNN Verification）
可解释性（事后归因）	SHAP/LIME 等归因分析	信息缺失；本体论降维（承认性）	通过额外模型查询和输入扰动提供局部行为证据，同时引入代理与背景约定误差；不单独构成对真实的外部校准，适合在限定条件下生成并筛查假说	沙普利可加性解释（SHAP）、局部可解释模型无关解释（LIME）

工程范式	核心操作	主要针对的困境	纤维语言中的功能	典型技术/标准
可解释性（机制）	内部表征分析、电路发现	信息缺失（直接接触）；本体论降维（承认性）	直接检查内部表征与因果路径，减少局部机制不确定性；观测仍有映射，不自动缩小关于真实的纤维	叠加分析（Superposition）、自动电路发现（Automated Circuit Discovery）
治理与合规	制度化评估与问责	信息缺失＋动态腐蚀＋本体论降维	建立追踪纤维变化的记账结构；制度记忆防止遗忘	NIST 人工智能风险管理框架（NIST AI RMF）、欧盟人工智能法案（EU AI Act）
持续监测	部署后追踪性能偏移	动态腐蚀	接入独立结果、抽样人工核验或其他外部反馈时持续看太阳；仅凭内部统计不构成外部校准	概念漂移检测（Concept Drift Detection）、异常监控（Anomaly Monitoring）

关键判断：没有单一范式能覆盖全部三层困境。对齐解决信息缺失和部分动态腐蚀，但受制于奖励黑客和降维。护栏承认边界，但不解决校准。审计估计行为风险，但无法阻止腐蚀。红队探测极值，但无法结构性消除降维。治理提供记账，但不替代技术层面的校准。可审计 AI 的工程实践必须是组合策略——在不同层次上部署互补的工具，形成纵深防御。

与正文三个增量的关系：

- 正文 §2（HHH 是乘积）对应表中 “对齐” 行——标出特定操作化条件下三个目标协同形成叙事壁垒的机制。
- 正文 §3（太阳变屏幕）对应表中 “对齐” 行的动态腐蚀维度——揭示了校准源本身的独立性丧失。
- 正文 §4（两种可解释性）对应表中被拆分的两行——揭示了 “可解释性” 这个统一标签下隐藏着认识论层次的根本差异。