《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第十三章：从缩放定律到映射链——AI 的认识论极限与工程原则

摘要

本章将纤维框架应用于人工智能（AI）领域，以 “4 ＋ 1 ＋ 3” 结构组织诊断：映射链结构（L0）、优化动力学（L1）、伪校准（L2）与多映射递归（L3）分别检查信息转换、优化目标、确定性呈现及读数之间的依赖；叙事载荷乘积（L4）检查交互设计与话语如何影响校准条件。各层提供不同的分析入口，不表示每个系统已经具备全部失灵形态。政治经济学、物理基底与时间动力学三个贯穿维度横切这些层次，完整展开分见后续章节。

本章按映射结构、优化目标、输出呈现与读数依赖的顺序展开分析，而不将其写成所有系统必经的失灵链。当偏好驱动的优化缺少独立校准，确定性呈现可能掩盖尚未排除的不确定性；当这些输出成为后续判断、评价或训练的依据，风险又取决于其条件与不确定性能否被保留，以及独立核查能否介入。层间可以存在相互强化，例如确定性输出获得更高偏好评价，或模型生成内容返回训练数据，但这些路径的存在与后果强度须分别判断。

纤维框架诊断的对象不是裸模型，而是系统—部署耦合体。本章保留孤立部署、平台嵌入式部署与多系统串联部署三个原型：分别突出输出供人类判断、用户行为参与后续输入、上游读数进入下游处理的关系。多映射递归（L3）与叙事载荷乘积（L4）的具体形态，需要结合这些关系及其校准条件分析，不能仅由预测式或生成式标签决定。短视频推荐是视觉影像类的独立实例，用户看到的内容序列本身就是待分析的读数。本章以 1994 年以来的推荐技术及相关研究为历史线索，并与大语言模型和其他预测式 AI 对照。

核心论断包括：缩放直接扩大参数数量（N）、数据与算力，并可提高特定任务上的拟合精度和部分内部表征质量；这些收益不等于真实校准，也不能单独证明隐藏维度已经改善。参数规模是规模指标，不是映射函数（π）质量的充分度量。基准提升与真实部署校准须分别评价，缩放收益能否跨任务迁移也须按任务检验。人类反馈强化学习（RLHF）的对齐悖论使 “对齐度” 与 “乡愿度” 共享同一优化梯度；有帮助、诚实、无害（Helpful, Honest, Harmless，HHH）在第十二章所分析的具体操作化与持续作用条件下，构成协同压缩校准空间的机制；这种压力是否形成净衰减，还须与独立校准及恢复来源比较。本

章承接第十章的关系性与渐近性限定，检查这些前提在具体部署中的实现，不把结构方向直接当成每个用户已经达到的终态。各诊断层次分别提出一条主要工程回应——缩短映射链、强制不一致、真校准、打破递归、保留摩擦——作为需要结合任务代价使用的方向性指引。原则与层的对应是 “主回应” 而非 “唯一回应”，工程原则之间存在交叉效应；另三条补充原则（审计数据构成的权力谱系、拒绝存在论升格叙事、编码关系性价值）由第十四章的文化与意识形态分析给出，八条原则在 §7 母表中并列。

本书的时钟维度首先指一种仅处理读数的操作模式，而非对所有部署状态的否定。对不接入外部记忆、在线训练或持久状态的主流基础模型推理实例，参数不随单次输入积累不可逆经历；对话历史、日志、外部记忆与参数更新属于部署层状态，须另行分析其持久性、可删除性与跨期影响。本章在该限定下使用 ‘没有时间深度’。

关键词

纤维框架；映射链；伪校准；多映射递归；部署架构；推荐算法；大语言模型；工程原则

§1 框架总览：四层递进结构与三种部署架构

概念前提：纤维是给定读数后仍与真实状态相容的候选状态集合；可见 / 隐藏子空间是相对于指定观测者判别能力的连续谱两端；伪小纤维是真实不确定性较大而观测者感知不确定性较小的脱节；可检测性梯度表示不同状态或维度被校准和测量的难易程度。本章沿用第四章的完整定义，以下在每次调用时说明相应的观测者与证据条件。

第四章 §1 给出命题一，第九章 §1 将其用于 AI 语境——非单射的有损映射意味着至少存在一些读数对应多个真实状态。它不排除在特定任务中借助独立信息把知识条件下的识别集合收窄到单点。对当前架构，应逐任务检查非单射环节是否覆盖当前输出、是否引入新的独立信息以及残余误差是否可测，不能把 ‘所有已知干预组合都无法达到可测零误差’ 作为数学命题的直接推论。工程干预可以持续缩小识别集合，但是否达到特定误差阈值须由任务与证据决定。

本章以 “4+1+3” 结构组织对 AI 系统的诊断：四个依次展开的诊断层次（映射、优化、输出呈现与读数依赖）、一个涌现层（系统与人类认知碰撞后的效应）、三个贯穿维度（政治经济学、物理基底、时间动力学）。本章聚焦于四层递进结构与涌现层的逐层展开；三个贯穿维度横切四层，分别见第十四章（政治经济学）、第三十二章（物理基底）、第十五章、第二十二章与第三十一章（时间动力学，贯穿宏观认知债务记账框架（Macro-Cognitive Accounting Framework，MCAF）各应用章节）。

四个层次按映射、优化、输出呈现与读数依赖的顺序依次检查。映射链结构（L0）检查读数经历的转换，优化动力学（L1）检查哪些目标受到奖励，伪校准（L2）检查确定性外观与证据之间的脱节，多映射递归（L3）检查读数怎样成为后续判断、评价或训练的依据。优化以具体映射与目标为对象；按第四章 §2.4 的系统状态命名，伪小纤维由优化目标系统性产生时称为伪校准，但这一命名不等于所有优化必然产生伪校准。读数之间的依赖也不以伪校准已经发生为前提。

本章重点追踪一条有条件的风险路径：当评价与独立校准脱节，输出的确定性外观可能掩盖尚存的不确定性；当这些输出又被后续环节当作可靠依据，偏差可能被传递或强化。反向作用同样可能存在：确定性输出获得较高偏好评价，会增加相应优化压力；输出返回训练数据，会改变后续模型的信息来源。前者涉及评价反馈，后者涉及训练回流，两者不能仅凭层号排序相互推出。

要明确归因所依赖的前提，可以分别追问：如果改变映射环节及其信息保持方式，伪校准是否减弱？如果保持任务不变而切断确定性呈现与偏好奖励之间的强化，伪校准是否减弱？如果两类改变都有效，是

否需要同时干预？这些问题是分析者自我审计的启发式，不把分析顺序当成已经识别的因果效应。

反事实检验的功能定位：上述反事实检验在真实系统中几乎无法严格实施（缩短映射链而不改变其他条件通常不可行，切断反馈而不改变优化压力亦然）。但它的功能不是提供精确的因果推断工具，而是诊断透明度的最低要求——它迫使分析者明确自己将伪校准归因于哪一层、归因依赖于什么样的反事实想象。当一个分析者声称“伪校准主要源于 L0 映射链过长”时，反事实检验要求他追问：我的归因信念在多大程度上依赖于映射链更短的反事实想象？这一追问不能证明归因正确，但能使归因的预设变得可见——这是分析者自我审计的工具，类似于精神分析中“意识到自己的投射”。本章据此限定该判断的适用范围。

各层的联系需要落实到具体机制：映射结构限制可保留的信息，优化目标规定哪些可见表现受到奖励；当评价遗漏相关后果，且输出呈现掩盖这种遗漏时，须进一步检查伪校准。多个系统使用这些读数时，还要检查不确定性如何传递、独立校准能否介入。映射层数、偏差规模与反馈强度是不同的分析对象，不能未经比较便互相替代。

这里有一个尚未解决的问题。“映射链越长，隐藏子空间越大”是一个以数据处理不等式为背景的定性线索，不是可直接检验的定量命题——数据处理不等式约束沿链的平均信息量并允许等号，不直接比较各层纤维，因此它为这一线索提供方向性依据，而不提供层数与隐藏子空间大小的排序保证。一条两层但每层极度压缩的映射链，与一条五层但每层信息保持较好的映射链，谁的隐藏子空间更大？框架给出了“层数”这个粗糙的度量，但没有给出“每层信息损失量”的度量方式。映射链长度与隐藏子空间大小的定量关系，是框架当前的开放问题。

层次	名称	核心追问
映射链结构（L0）	降维	“真实与读数之间隔了几层？每层丢弃了什么？”
优化动力学（L1）	收敛	“优化在哪里做得好、在哪里无约束？”
伪校准（L2）	确定化	“确定的外观是否掩盖了不确定的实质？”
多映射递归（L3）	依赖与递归	“读数如何成为后续映射的依据，其独立校准条件如何变化？”
叙事载荷乘积（L4）	涌现	“交互设计与话语如何影响启动校准的条件？”

映射链结构（L0）至多映射递归（L3）区分本章检查的四类问题，并不表示每个部署同时出现全部风险。叙事载荷乘积（L4）进一步检查系统与人的关系：交互设计可以改变使用者注意疑点、停下来比较和启动核查的机会；话语合法性则影响社会集体提出质疑与开展独立审计的依据。两条通道可以相互强化，但识别其中一条、识别二者并存与确认组合效应，是不同层次的判断。交互设计层见本章 §6，话语合法性层见第十四章 §5。

纤维框架诊断的对象不是裸系统，是系统—部署耦合体。同一个大语言模型用于离线摘要脚本，或用于保留历史的对话助手，输出与后续判断的连接方式不同；同样涉及视觉影像的离线医学诊断、短视频推荐与自动驾驶流水线，也分别体现不同的部署关系。分析需要说明系统输出交给谁、是否进入后续处理、人的判断处在何处，以及独立校准可以在哪个环节介入。部署关系的改变不必改变模型参数，却会

改变诊断所需检查的条件。

本章按诊断问题组织分析，不以预测式或生成式标签代替部署判断。面向使用者的读数可以是概率、文本、排序后的影像序列，也可以是进入下游模块的控制信号；模型是否生成新内容，不决定它是否参与组织人的可见环境与后续行动。推荐算法在此作为预测式 AI 的重要实例单列，是因为短视频等平台中的持续交互，使行为反馈与界面作用能够在同一场景中被分析，而非因为推荐技术独立于预测式 AI。以下三种部署是韦伯意义上的理想型，用于突出不同的读数关系和人的位置，不是穷尽所有现实组合的互斥分类。

部署架构	定义	多映射递归（L3）	叙事载荷乘积（L4）	典型实例
孤立部署	系统离线运行，输出结果供人类做最终决策	不呈现本部署内的系统间递归；训练与生态来源另查	无持续交互型放大；单次呈现与话语作用另查	离线医学影像诊断、批量信用评分
平台嵌入式部署	系统嵌入用户反馈闭环，输出改变用户行为，行为成为下一轮输入	呈现用户-平台-AI 的行为反馈	界面持续作用于停止、比较与核查条件；是否抑制校准另查	推荐算法（抖音、淘宝）、对话 AI
多系统串联部署	多个系统级联，上游输出成为下游输入，人类被部分或完全移出回路	呈现 AI-AI 读数级联；是否形成反馈另查	用户移出环节无持续人机交互；面向监督者的作用另查	自动驾驶流水线、金融风控级联、智能体工作流（Agentic AI）

部署判定规则。先界定分析范围、参照观测者与时间窗口，再绘出该部署中输入、输出、记录、评价、训练与决策之间的路径。级联传递与反馈回流分别记录：仅有数据记录不等于记录已形成反馈，须查其实际是否参与后续输入、评价或训练；离线运行也不等于跨期反馈消失——若重训数据包含本部署的反馈，重训仍在执行训练回流的一部分。一个跨期回路可在不同窗口执行不同部分，不能因任一窗口未独自完成整条回路就认定回路不存在；窗口粒度本身不是风险消失的证据；延迟和噪声可使某条反馈在当前窗口作用有限，但不能据此抹去已存在的跨期路径；只有实际连接方式发生改变时，才据此描述部署关系的变化。持续交互型的叙事载荷乘积（L4）应与训练回流分别记录；若采用独立外部数据而没有本部署输出回流，则另按实际路径判断。对每条实际路径，说明人的位置、可见信息与独立校准入口；参照观测者随分析位置声明——终端使用者与系统监督者掌握的信息不同，不能把对一方隐藏的内容说成对所有人都不可见。若医疗 AI 的输出只被存档而未进入上述路径，可在相应范围内按孤立部署分析；若记录与医生复核结果用于周期性更新，则另记训练回流及其中独立核查的作用。

原型的定位。以下表格帮助定位原型，不要求现实系统只能落在一个格子中。“呈现” 说明本原型中需要检查的作用机制，不等于已经证明偏差放大或校准能力丧失；“不呈现” 只限于表中指定的部署关系，不豁免单次输出、既有训练来源或生态层面的审计。叙事载荷乘积（L4）列以部署内部的持续交互为主要观察位置，不能据此排除面向使用者、采购者或监督者的话语作用。类别决定重点检查哪里，具体机制与后果仍须逐项核对。

主要读数关系	人的主要位置	部署原型
所考察过程不将输出返回自身，也不直接交给其他 AI 作为下游判断依据	接收输出并做最终决策	孤立部署
输出影响用户行为，行为参与后续输入或更新	人参与反馈过程	平台嵌入式部署
上游 AI 读数成为下游 AI 的输入或判断依据	人在部分或全部处理环节之外	多系统串联部署

用纤维框架回看 1994 年以来的推荐技术，可以比较相似的诊断问题如何在不同工程条件下呈现。以下选择代表性技术节点与研究材料，不把它们认定为各风险层在历史上的首次发生，也不将技术演进写成必须依次经过各层的过程。单个节点可以同时涉及映射、优化、输出呈现与反馈；表内列出的是本章选择的主要分析入口，不能用一个层号穷尽该节点。研究发表时间与其描述的系统运行时期亦须区分。

时间	技术/事件	文献	对应层级	纤维框架解读
1994	GroupLens 协同过滤	(Resnick et al., 1994)	L0	早期自动化协同过滤系统。将 “用户兴趣” 映射为 “相似用户评分聚合”。纤维源于冷启动——新用户在映射链上近乎空白
1998	PageRank	(Brin & Page, 1998)	L0	将 “网页重要性” 映射为可计算的 PR 值。规则透明，纤维可审计。后被搜索引擎优化（SEO）操纵，PR 值退化为可操纵的分数
2000	Google 早期 A/B 测试	(Kohavi et al., 2009)	L1	在可见指标（点击率）上做对照实验，选择优胜版本。隐藏子空间（$\mathcal{T}_h$）中的长期认知影响不在实验周期内度量

时间	技术/事件	文献	对应层级	纤维框架解读
2003	Amazon 物品协同过滤	(Linden, Smith & York, 2003)	L0	将映射对象从 “相似用户” 转向 “相似物品”。商业闭环开始形成（推荐 → 购买 → 数据 → 推荐）——主要计算离线构建相似物品表，推荐经在线查询实时生成
2006–2009	Netflix Prize 竞赛	(Koren et al., 2009)	L0 + L1	矩阵分解方法突破。竞赛本身是优化动力学（L1）的纯粹展演——参赛者在均方根误差（RMSE）上竞争，“用户是否真正满意推荐” 不在评判标准中
2007	逻辑回归用于点击率预估	(Richardson et al., 2007)	L0 + L1	大规模稀疏特征映射为点击概率。线性结构提供相对直接的审计入口，但字段选择与行为信号的局限仍须检查
~2010	Facebook EdgeRank	（内部算法）	L0 + L1 + L3 萌芽	社交信息流从时间排序改为算法排序。用户反馈编码为权重。平台嵌入式部署的早期形态：反馈闭环形成但尚未实时化
2010	分解机（FM）	(Rendle, 2010)	L0 + L1	分解参数化建模特征交互，矩阵分解到深度学习的桥梁
2014	GBDT+LR 组合模型	(He et al., 2014)	L0 + L1	Facebook 提出梯度提升决策树（GBDT）做特征变换加逻辑回归做预估。可解释性显著下降——中间表征对人类不透明

时间	技术/事件	文献	对应层级	纤维框架解读
2016	Wide&Deep 模型；YouTube 深度推荐	(Cheng et al., 2016; Covington et al., 2016)	L0 + L1 + L2	深度推荐以候选生成与排序组织用户可见内容。内部排序分数与用户实际接收的影像序列须区分；诊断关注行为代理指标、序列呈现及其校准条件
2018	深度兴趣网络（DIN）	(Zhou et al., 2018)	L0 + L1 + L2	注意力机制进入推荐：模型 “选择性地看” 用户历史。哪些历史被看到、哪些被忽略成为新的隐藏子空间
2022–2026（所引研究发表期）	短视频实时推荐的工程与审计研究	(Liu et al., 2022; Baumann et al., 2026)	L0–L4 的联合诊断场景	工程研究说明行为反馈进入训练与服务的路径，机器人审计测量兴趣相关内容的放大与探索。推荐响应、特征更新和参数同步不是同一个时间尺度；审计结果不直接等于真人校准能力的测量
2022 年以来，2024 年进一步扩展	推荐 + 大语言模型混合部署	Google AI Overviews（2024 年 5 月推出）；Perplexity（2022 年 12 月上线）	排序、生成与交互的联合诊断	推荐排序与语言生成共同组织结果，需分别检查排序、生成与交互环节的校准条件

本章按层级顺序展开：§2 至 §6 分别展开映射链结构（L0）至叙事载荷乘积（L4），每一层内对比大语言模型、预测式 AI 和推荐算法——让读者看到同一追问如何穿透所有 AI 系统。§7 汇总五条工程原则，每条主要回应一个层次的纤维膨胀机制。§8 为研究纲领声明。

本书的时钟维度首先指一种仅处理读数的操作模式，而非对所有部署状态的否定。对不接入外部记忆、在线训练或持久状态的主流基础模型推理实例，参数不随单次输入积累不可逆经历；对话历史、日志、外部记忆与参数更新属于部署层状态，须另行分析其持久性、可删除性与跨期影响。本章在该限定下使用 ‘没有时间深度’。

全局认识论声明：以下 §2 至 §6 的逐层诊断均为基于纤维框架的定性判断。本章中出现的断言按其性

质可分为三类（符号沿用第四章 §2.4 的定义）：- **[S] 结构性命题**：从框架定义和数学约束推导的逻辑结论，不依赖特定系统的经验观测（例如 “非单射映射存在一些多状态读数”“特定目标信号未覆盖的维度不直接受该信号约束”）。- **[E] 经验命题**：基于已有文献中的实验观测，对特定系统行为的事实描述（例如 “Sharma et al.（2024）观测到人类反馈强化学习（RLHF）训练后模型的谄媚行为”“Baumann et al.（2026）测量到 TikTok 推荐在约 200 视频内产生兴趣放大”）。- **[T] 分类约定**：框架对现象的命名和归类（例如 “我们将此现象归类为伪小纤维”“我们将此部署模式归类为平台嵌入式部署”）。

三类断言在文本中可能以混合形态出现。本章在关键结论处区分定义推论、经验结果与分类约定——**这是审计纤维框架自身隐藏子空间的最低操作纪律。**

通俗导引的入口：希望先建立直觉再进入逐层诊断的读者，可先翻至第十三章附录 B《雾与烟——一个关于 AI 的通俗导引》。该附录用两个独立的日常比喻——雾与烟回答 “读数与真实是什么关系”（认识论与装置审计），过河回答 “偏差为何不可逆”——展开五层结构。两个比喻各有边界，不能完整对应五层框架的每一处技术细节；正文 §2–§6 的逐层诊断与第十三章附录 B 的比喻翻译可独立阅读、互为参照。

§2 映射链结构（L0）与大语言模型（LLM）范式内部约束

映射链结构（L0）追问的是：真实状态（T）与读数（r）之间隔了几层？每层丢弃了什么？映射链越长，与同一个读数兼容的真实状态往往越多（定性线索，其定量边界见 §1 开放问题），读数的诊断价值越低。本节先在 §2.1 同时给出生成式 AI 的五层映射链与大语言模型（LLM）范式内部的四重独立结构性约束，§2.2–§2.5 再分别讨论预测式 AI、推荐算法、缩放定律的认识论极限以及缩短映射链的替代方向。

§2.1 生成式 AI 的五层映射链与范式内部约束

讨论大语言模型（LLM）输出与世界状态之间的纤维结构，前提是看清两者之间存在哪些中介层。一条 LLM 输出语句要回溯到它所声称指涉的世界状态，需要穿过至少五层中介。

第一层，世界 → 人类经验。世界本身是连续的、多模态的、有因果结构的；人类对世界的感知与认知是该结构的一个具身切片——受感官通道、注意力、文化范畴、社会位置约束。这一层的 “纳入” 是被感知到、被注意到、被概念化的部分；“剔除” 是感官阈下、注意力外、范畴外的部分。

第二层，人类经验 → 语言表达。人类经验中能被语言化的部分，是经过语言这一离散符号系统过滤后的剩余。这一层的 “纳入” 是能被命名、能被句法承载、能被在场听者理解的部分；“剔除” 是默会知识、身体记忆、情感质感、无名经验。

第三层，语言表达 → 互联网文本。全球所有语言表达中，能进入互联网文本的，是被某个有上网能力的人在某个具体平台上写下并存留的那部分。这一层的 “纳入” 由谁有设备、谁有带宽、谁有时间、谁使用主流平台决定；“剔除” 是没有数字化的语言、被平台审核机制移除的语言、私域不公开的语言。

第四层，互联网文本 → 训练数据。训练数据是从互联网文本中，经过抓取、过滤、去重、质量筛选、版权决策后的子集。这一层的 “纳入” 由抓取工具的覆盖、过滤规则的设计、语种权重的分配决定；“剔除” 是被 robots.txt 屏蔽的、被质量过滤器剔除的、被法律风险评估排除的内容。这一层与第三层共同构成第十四章 §3 所讨论的 “L0 基底偏斜” 的来源——Common Crawl 2024-38 批次按 HTML 页面主语言统计，英语占 44.12%，印地语占 0.20%（Common Crawl Foundation, 2024）；2026-39 批次相应为 41.86% 和 0.21%（Common Crawl Foundation, 2026）。这些比例描述开放网页的可抓取文本，不直接代表语言人口；它们不是大语言模型（LLM）范式内部的事实，而是第三、第四层在政治经济结构下的产物。

第五层，训练数据 → 模型输出。模型参数对训练数据分布的拟合，加上推理时的采样过程，产生具体输出。这一层的内部结构是下文四个支撑论证的对象。

五层映射链的累积效应是：输出语句与其声称指涉的世界状态之间，至少存在五道中介转换，每一道都有自己的 “纳入/剔除” 逻辑。五层链提示多道可能损失信息的转换，但不直接给出统一纤维下限。

即使映射链每层都精确，大语言模型（LLM）范式仍受四重独立的结构性约束。前述五层映射链结构已论证每层都嵌入 “纳入/剔除” 的选择，且第三、第四层的偏斜由政治经济结构决定（详见第十四章§3）。本段把分析焦点暂置于映射链第五层内部，以分离论证不同结构层的约束力；这不表示前四层不存在偏斜——前四层的偏斜与本段四重约束在结构上平行存在，不可互相吸收。在这一限定下，LLM范式自身仍受四重独立的结构性约束。这些约束运作于映射链第五层内部；其是否造成特定任务中的残余不可区分性，以及该残余能否被工程干预收窄，须按任务与证据判断。

约束一：训练目标不保证世界对应。下一词元预测的直接优化对象是训练分布，而非显式的世界对应关系。Bachmann & Nagarajan 的特定任务结果表明，目标选择可能造成学习盲区，但不推出所有数据与任务上的纤维都由梯度方向单独决定。世界对应表征能否形成、是否被调用以及它们如何影响输出，仍须独立测量（Gurnee & Tegmark, 2024）。

约束二：分布式表征增加寻址与内部审计难度。训练完成后的大语言模型（LLM）参数以叠加（superposition）形式编码远多于其维度数的特征（Elhage et al. 2022，*Toy Models of Superposition*），导致多义性——单个神经元参与编码多个不相关概念。分布式表征与叠加会增加参数—事实定位的难度，但不等于不存在任何可寻址结构。当前研究可在激活空间恢复部分特征方向（Anthropic, 2024），其覆盖率、验证标准和部署可用性仍然有限（Sharkey et al., 2025）；因此，本节把这一约束限定为审计成本与覆盖限制，而不是绝对不可审计。单义化工程是否可行取决于算力、模型与评价目标，现有综述只支持其在相应条件下 ‘可能并不切实际’。此处所说的工程化单义表征，特指使每个表征单元对应一个可解释概念的具体路线，如当前的稀疏自编码器（sparse autoencoder，SAE）/ 特征分解方法；这一限定针对工程化单义表征的特定路线，不涵盖所有可解释性方法。

> engineering monosemanticity … may be impractical until we have orders of magnitude more compute available (Bereska & Gavves, 2024)
>
> 译文：在我们拥有数量级更多算力之前，工程化地实现单义性可能并不切实际。

约束三：采样呈现与部署决策共同限制不确定性信息。采样后的单个文本不完整保留生成分布，因而默认界面难以仅凭该文本恢复模型认知状态；这不妨碍利用 token 概率、多次采样（Farquhar et al., 2024）或显式置信表达估计不确定性。Fadeeva et al.（2024）指出，当时的服务通常不提供检测不可靠生成的手段；这一 ‘通常’ 不能改写为 2026 年所有主流默认部署均未启用，具体产品须逐版核查。

> Current services that leverage LLMs usually do not provide any means for detecting unreliable generations (Fadeeva et al., 2024)
>
> 译文：当前利用 LLM 的服务通常不提供任何检测不可靠生成的手段。

约束四：输出空间与真实空间存在维度不对称（较弱约束，标注学界分歧）。大语言模型（LLM）的输出空间是 token 序列空间——离散、线性、由词表上的概率分布定义。其所指涉的世界则是连续的、多模态的、有因果结构的。这一维度不对称是否构成原则性上限，学界存在实质分歧：Coelho Mollo & Millière（2026）主张文本中介的指涉接地理论上可能；Pavlick（Royal Society 2023）论证非接地 LLM 可学得与接地表征同构的概念表征。本节不在此哲学争论中选边，只标定一个较弱但稳健的命题：维度

压缩在经验上已被记录（Xu et al.（2023）比较 4,442 个词汇概念，发现 GPT-3.5 与 GPT-4 在非感觉运动领域与人类评分更接近，在感觉和运动领域相关较弱；GPT-4 的改进还与其视觉学习相关），且工程改进路径中“更多文本数据、更长上下文窗口”在该压缩的根源（模态）上不起作用——多模态训练是范式扩展，不是同一范式内的工程改进。**尽管在原则性上限上学界存在分歧，约束四在工程改进路径的边界标定上仍有独立功能——它指认“多模态训练”是范式扩展而非同范式内的工程改进；这一功能性意义不依赖更强的“token 序列原则上无法编码世界结构”命题。**

三种结构性来源的合成。至此本节论证的纤维结构有三种结构性来源，它们属于不同的结构层，不可互相吸收，也不可互相替代：

1. **映射链长度**——大语言模型（LLM）范式得以运行的外部条件性约束，五层链提示多道可能损失信息的转换，但不直接给出统一纤维下限。第三、四层的政治经济学维度由第十四章 §3 专论。
2. **大语言模型（LLM）范式内部的四重约束**——LLM 作为一类系统的形式性约束，运作于映射链第五层内部：训练目标不保证世界对应（条件性强）、分布式表征提高审计难度（条件性强）、采样呈现与部署缺口（条件性强）、维度不对称（较弱，有学界分歧）。
3. **§2.4 将论证的缩放定律的认识论极限**——可被理解为以上两类约束在缩放维度上的具体投射：扩大规模可提高特定任务上的拟合精度；其能否缩小任务相关的隐藏不确定性，须按任务、映射与校准条件检验。

对工程改进路径的边界标定：本节论证不否认大语言模型（LLM）的工程改进空间——更精的对齐流程、更长的上下文、检索增强、工具调用、推理时计算扩展、不确定性量化（UQ）方法的部分部署，都能在特定任务上缩小可测量的失败率。但这些改进主要改变可测任务表现；能否缩小任务相关的隐藏不确定性，取决于是否引入独立、有效且与任务对应的新约束，而不能仅由改进发生在可见层就排除。

§2.2 预测式 AI 的三层降维

预测式 AI 的推理链同样有损：真实状态 → 观测数据（只采集可采集的字段）→ 输入表示（统计量替代原始时序）→ 模型输出。训练样本的构造、标签来源与训练过程是另一条须同时追查的来源路径。数据采集方案与特征字典确定了部分映射及其信息损失；后续模型选择和调参能否达到任务阈值，仍须在该映射与评价条件下测量。

以医学影像诊断为例，映射链是：病理状态 → 物理信号（X 射线/核磁共振）→ 数字影像 → 模型输出。传感器与物理现实有直接因果接触，映射链比大语言模型短得多——这是放射科 AI 在特定病种上达到专家水平的因素之一（任务范围窄、评价标准明确同为关键）。但纤维仍然不是单点：同一张胸片上的结节阴影可能对应早期肺癌、良性结节、结核等多种病理状态——映射链短不等于纤维为单点。

自动驾驶感知的映射链更复杂：物理场景 → 摄像头/激光雷达信号 → 点云/像素矩阵 → 物体检测与分类 → 场景理解。摄像头丢弃深度，激光雷达丢弃颜色和纹理，物体检测丢弃意图。一个穿反光背心的行人和一个静止的交通标志在像素层面可能高度相似——这是映射链结构（L0）的纤维膨胀在高风险场景中的直接后果。

§2.3 推荐算法：不可观测的真实状态

推荐算法的映射链结构（L0）值得独立分析，因为它的真实状态（T）——用户的真实偏好——根本不可直接观测。映射链是：用户真实偏好（不可观测）→ 行为信号（点击、停留、滑动、购买）→ 特征向量 → 排序分数。

第一步就是一个巨大的纤维。“点击” 不等于 “喜欢”——用户可能因为好奇、误触、标题党而点击。“停留” 不等于 “认同”——用户可能因为震惊、愤怒、困惑而停留。“滑走” 不等于 “不感兴趣”——用户可能在特定场景下无暇停留。行为信号是真实偏好的高度有损投影。与医学影像不同（传感器和物理现实有直接因果接触），推荐算法的 “传感器” 是用户的外显行为，而外显行为与内在偏好之间没有稳定的因果映射。

这一映射链的特殊性在于：每一代技术 “进步”——从协同过滤到逻辑回归到深度学习——都在延长映射链的中间环节（嵌入向量、多层非线性变换、注意力权重），使映射函数（π）对创造者也越来越不透明，但映射链的第一步（行为信号与真实偏好之间的间隙）从未被缩短。技术精密度的提升和第一步纤维的持续存在是同一历史过程的两个面。

须标注一个本体论差异：推荐算法的 T（用户真实偏好）可能在被观测之前并不完全存在——偏好在选择中被构造、被反馈闭环改写，与医学影像的既定病理状态不同[1]。这一差异不影响 L0 的诊断效力（行为信号仍然是偏好的有损投影，“点击不等于喜欢” 仍然成立），但要求读者意识到：推荐算法的纤维膨胀不仅来自映射函数的降维，也来自 T 本身的流动性。

§2.4 缩放定律的认识论极限

2020 年到 2024 年，前沿 AI 的进步被一个简洁的叙事驱动：更大的模型加更多的数据加更多的算力等于更好的性能。这是缩放定律的核心承诺。Zhao et al.（2026）的大语言模型综述系统梳理了这一范式——指出：

> Scaling has been a pivotal factor in the success of modern language models (Zhao et al., 2026)
>
> 译文：缩放是现代语言模型成功的关键因素。

早期研究用训练时缩放律将其形式化，把性能建模为模型规模、数据规模与训练算力的函数；该综述同时记录了学界对 “涌现能力” 的界定与后续质疑：

> capabilities absent in smaller models but present in larger ones (Zhao et al., 2026)
>
> 译文：小模型中不存在而大模型中出现的能力。

对该界定的反驳则认为，性能跳变多源于测量选择与规模有限，而非根本性质变。Hoffmann et al.（2022）在 Chinchilla 研究中证明：给定固定的计算预算，存在数据量与参数量的最优比例——盲目增加参数而不相应增加数据并不能提高性能。截至 2026 年初，一些行业研究者开始公开质疑单纯扩规模的路线：仅靠增加数据和算力不会创造出曾被承诺的全知数字系统。

这里存在一个需要区分的情况。Stanford HAI 2026 AI Index 追踪了一个看似矛盾的趋势：在 Humanity’s Last Exam 基准上，2025 年排名第一的模型仅正确回答 8.8% 的博士级问题；截至 2026 年 4 月，最佳模型已超过 50%（Smith, 2026）。在 SWE-bench Verified（编程基准）上，性能在一年内从达到人类基线的 60% 上升到接近人类基线的水平（Stanford HAI, 2026）。但 AI Index 指导委员会联合负责人 Raymond Perrault 给出了校准警告——基准测试不一定总能映射到真实世界的结果：“知道一个法律推理基准有 75% 的准确率，几乎不能告诉我们它会在多大程度上契合一家律所的实际活动”（Smith, 2026）。

[1]纤维框架的映射链结构（L0）默认预设了一个独立于观测的真实状态（T）——医学影像的病理状态在观测之前就存在，观测是对既有真实的有损投影。推荐算法的 T 则不完全符合这一预设：偏好往往在选择行为中才被构造，被推荐内容持续塑造，用户自身也可能无法稳定地报告它。这不是 “测量有误差”，而是 “被测对象的本体论地位不同”。当 T 本身被观测反馈塑造时，“映射有损” 从认识论命题升级为认识论-本体论纠缠——不仅读数不能完全反映真实，而且读数参与塑造了真实。这是框架当前以同一个 L0 覆盖两种认识论情境时需要读者留意的边界；更完整的本体论讨论见第四章 §2.4。

在映射链结构（L0）的语言中：基准得分是时钟的精密度（走得准不准），不是时钟的校准（指得对不对）。缩放直接扩大参数数量（N）、数据与算力，并可提高特定任务上的拟合精度和部分内部表征质量；这些收益不等于真实校准，也不能单独证明隐藏维度已经改善。参数规模是规模指标，不是映射函数（π）质量的充分度量。基准提升与真实部署校准须分别评价，缩放收益能否跨任务迁移也须按任务检验。

当前行业对缩放极限的回应——推理时计算、思维链、后训练强化学习——仍然在时钟维度内操作。Levi（2025）在 ICML 发表的研究在重复推理尝试的统计模型中推导出：推理损失随尝试次数增加呈幂律下降。Mudarisov et al.（2025）在神经信息处理系统大会（NeurIPS）发表的研究从更基础的层面证明了注意力机制中归一化操作的理论局限：随着被选择的 token 数量增加，模型区分信息性 token 的能力下降，趋向均匀选择模式——这是架构层面的信息损失。这两项研究分别界定重复尝试的收益递减与注意力归一化的架构局限——它们都在时钟维度内操作，运行更多步骤不等于接触了真实状态。

Ilya Sutskever 在 NeurIPS 2024 上的判断（转引自 StartupHub, 2026）：

> pre-training as we know it will unquestionably end (StartupHub, 2026)
>
> 译文：我们所知的预训练无疑将会终结。

这一判断，以及他在 NeurIPS 讲话一个月前接受路透社采访时把 2010 年代称为缩放的时代、并表示我们正回到惊奇与发现的时代这一公开表态（Hu & Tong, 2024），在映射链结构（L0）的语言中可译为：**造更大的钟的时代结束了。问题不再是“怎么造更大的钟”——是“怎么缩短映射链，让钟指向太阳”。**

来自 AI 与游戏研究的独立平行证据。Perrault 在 2026 年给出的基准测试不一定总能映射到真实世界的结果这一警告，在 AI 与游戏研究领域有一个更早、更系统、独立于大语言模型语境的版本。Julian Togelius 在 2018 年由 MIT Press “Playful Thinking” 丛书出版的 *Playing Smart: On Games, Intelligence, and Artificial Intelligence* 一书中明确提出：游戏之所以是 AI 研究的核心基准，恰恰是因为它们被设计来挑战人类认知能力的不同维度；但游戏基准一旦被“征服”，对 AI 通用智能的诊断价值就迅速耗尽（第 10 章，Togelius, 2018）。Togelius 在 2024 年由 MIT Press “Essential Knowledge” 丛书出版的 *Artificial General Intelligence* 中将这一判断扩展到对超人能力的普遍评估：

> superhuman capabilities in some problem domain, while impressive and often useful, are not necessarily a step toward general intelligence (Togelius, 2024)
>
> 译文：在某个问题域内达到超人水平虽然令人印象深刻且常常有用，但未必是通往通用智能的一步。

（第 1 章，Togelius, 2024）；他并以 AlphaGo 和 Deep Blue 为例论证：

> AlphaGo could really only play Go, just as Deep Blue could only play chess (Togelius, 2024)
>
> 译文：AlphaGo 能做的其实只是下围棋，就像 Deep Blue 只能下国际象棋一样。

（第 2 章，Togelius, 2024）。在本章映射链语言中，Togelius 的两个命题提供了平行证据：基准得分所测的是时钟精密度（走得准不准，即模型在特定任务分布上的统计量），不是映射函数质量（指得对不对，即读数与真实状态的因果对齐）。缩放范式所优化的是前者，但基准提升不保证现实校准或通用能力。

这一独立证据的价值有三层。第一，Togelius 的论点在 2018 年缩放热潮尚未到达峰值时就已明确写入一本 MIT Press 的教程，在时序上排除了“事后诸葛”的嫌疑。第二，Togelius 处理的对象不是大语言模型而是整个 AI 研究范式在六十年中对各类游戏基准的持续征服（国际象棋、双陆棋、跳棋、围棋、星际

争霸等），他所指认的基准-能力脱节是一个跨架构、跨时代的结构性现象——与本章讨论的 Humanity's Last Exam 和 SWE-bench 基准分数飙升共享同一个机制。第三，Togelius 在通用人工智能（AGI）语境中明确地把这一现象命名为 narrow AI 与 general AI 的区分（这一术语对立由 Goertzel & Pennachin（2007）主编的《Artificial General Intelligence》文集系统确立——该文集明确主张应把 AI 研究的首要焦点从只擅长特定任务的 "narrow AI" 转向 "AGI"）："狭窄 AI 系统的改进并不构成通向通用 AI 的进步"——Togelius 2018 年即指出，一个在市区完美驾驶、或胸部疾病诊断优于任何医生的系统，可以产生上述局限（第 3 章，Togelius, 2018）：

> makes no progress whatsoever toward more general AI (Togelius, 2018)
>
> 译文：完全不对更通用的 AI 构成任何进步。

在纤维语言中，这正是缩放定律的认识论极限的精确表述：缩放收益不保证迁移为通用能力或现实校准；能否跨任务迁移为对映射函数本身的改进，须按任务检验。

§2.5 替代方向：世界模型与接地

面对映射链结构（L0）的死结——多层转换可能损失信息，但不直接给出统一纤维下限——最直接的回应是缩短映射链。这是 LeCun 的 AMI Labs 和世界模型路线的核心洞见。

大语言模型在第九章 §1 的粒度下计为四层降维（至训练数据），模型自身映射另计一层；本章 §2.1 进一步细分人类映射并计至输出，因此为五层。差异在粒度与计数终点，不在是否计入人类映射（π_{human}）。世界模型的三道转换按本章五层原口径少两道，按合并后的四段口径少一道；层数只是图示，不代替信息保持与因果接触的比较。LeCun 的 AMI Labs 致力于让世界模型从现实而非仅从语言中学习，并以 JEPA 为技术路线；其首个公开合作领域为医疗（TechCrunch, 2026）。有关传感器表征、机器人及其他工业应用，须另引 JEPA 原始文献，不由该报道单独承担。

在纤维语言中：世界模型的纤维有望比大语言模型小——依据不是环节数（链长是这一对比的图示速记，不是推理引擎），而是其中间环节与物理过程有直接的因果接触，为物理任务保留了更多可区分的状态差异。但纤维仍然不是单点。传感器数据仍然是世界的投影（摄像头丢弃温度、气味），抽象表征进一步降维。世界模型缩小了纤维，没有消除纤维。联合嵌入预测架构的设计选择在这个框架中有精确的含义：它故意丢弃不可预测的细节（视觉噪声），只预测抽象表征——这是一种有意识的降维选择，承认不可逆性，在不可逆的约束下做最优的信息保持。

世界模型面临一个时钟赛跑：它的到达时间（从科学研究到工程部署的周期）是否快于大语言模型范式锁定整个 AI 基础设施的时间？科林格里奇困境（Collingridge, 1980）在此再次出现——技术在早期尚可调整时信息不足以做出判断，而在信息充分时技术已经锁定。

§3 优化动力学（L1）

优化动力学（L1）追问的是：优化在哪里做得好、在哪里无约束？

§3.1 所有 AI 的共同结构

本章分别记录训练数据与奖励的覆盖范围，以及指定观测者的可见 / 隐藏子空间。若优化只依赖特定偏好信号，则该信号未覆盖的维度不直接受其约束；模型容量、正则化、检索、工具、外部验证和其他反馈仍可能产生间接约束，其方向与效果须另行检验。损失趋平只说明当前训练条件下改进有限，不证明全局最优，也不证明其他维度完全无约束。

优化动力学（L1）的核心命题是：特定目标信号未覆盖的维度不直接受该信号约束；其他直接与间接约束是否有效，须按训练、部署和观测者条件另行核查。

§3.2 生成式 AI：递归训练与复杂任务中的失效

以下讨论两类与训练和评价条件有关的失效：递归使用生成数据导致的分布退化，以及复杂任务中的性能骤降——它们不是 RLHF 单独产生的两个必然后果。

模型坍塌是慢性后果。模型坍塌的机制是映射自我引用的直接产物。当模型的输出被发布到互联网上，被下一代模型的爬虫抓取，进入训练数据，模型开始在自己的输出上训练。在纤维语言中：映射函数从真实状态的映射退化为其他读数的映射——真实状态退到映射输入的更远处，下游拟合的更多是上游读数而非真实本身。时钟不再指向太阳，时钟指向其他时钟。Shumailov et al.（2024）在发表于《Nature》的研究中报告：不加区分地在训练中使用模型生成内容导致不可逆缺陷——原始内容分布的尾部消失。这项 2024 年的研究在检索端也有对应现象：Yu et al.（2026）在受控检索实验中刻画了 “检索坍塌”——AI 生成内容主导搜索结果、侵蚀来源多样性，并将其明确区分为不同于训练时模型坍塌的失效模式；此外，高质量原生数据相对训练需求的稀缺正成为新的结构约束。可见子空间上的统计规律被不断强化，分布尾部的退化将最先侵蚀处于低频区的经验与知识的代表性——这一社会含义是本书的推论，需与统计机制本身区分开。

2025–2026 年的研究探索了缓解策略。Yi et al.（2026）证明通过注入外部验证器的信息可以防止坍塌在近期发生——但同一研究警告，除非验证器完全可靠，早期收益会停滞甚至逆转，参数估计最终收敛到验证器自身的 “知识中心”。Gerstgrasser et al.（2024）证明如果合成数据与真实数据一起积累而非替代真实数据，可以避免模型坍塌；其线性模型分析给出不随迭代次数增长的测试误差上界。翻译成时钟房间的语言：**保持窗户打开**——关键是保留或补充不完全依赖递归生成过程的信息来源。但一个结构性约束正在收紧：互联网上 AI 生成内容的占比快速上升，高质量人类生成文本相对于预计的训练需求是有限的——数据墙。在该文一项语言模型实验中，每代随机保留 10% 原始训练数据时性能退化较小；这一结果说明保留原始数据可缓解特定设置的退化，不构成跨模型、跨任务的 10% 通用阈值；它不解决生态层问题：在真实互联网中，“哪些属于未被生成内容污染的原始数据” 本身是不可靠的分类任务——而污染可以隐蔽地发生：Yu et al.（2026）的实验显示，池污染会转化为曝光污染而答案准确率暂时稳定，使依赖表面指标的筛查失灵。

推理悬崖是急性后果。Shojaee et al.（2025）记录准确率随复杂度增加逐步下降，并在模型特定阈值后接近零；这一曲线不是 ‘整个输出瞬间落入隐藏子空间’ 的证据，也不能推出使用者绝无预警。应把它作为任务复杂度—性能关系的经验现象，另行说明其与可见 / 隐藏子空间的关系。Lawsen 认为这些结果主要反映实验设计限制，而非仅为 ‘部分’ 来源。[2]

> LRMs face a complete accuracy collapse beyond certain complexities (Shojaee et al., 2025)
>
> 译文：在特定复杂度之后面临准确率完全崩塌。

§3.3 推荐算法：点击率优化的隐藏子空间

推荐算法的优化动力学（L1）与大语言模型在结构上同构，但隐藏子空间的内容不同。

[2]Lawsen（2025; arXiv:2506.09250）随后发表评论，认为 Shojaee et al.（2025）观测到的 “准确性崩塌” 主要反映实验设计限制（如难度评估、输出预算约束）而非推理能力的内在边界；相关结论仍在学术讨论中。值得注意的是，该评论论文的 v1 版本曾将 Anthropic 的 AI 模型 Claude Opus 列为共同作者（2025 年 6 月 v2 按 arXiv 政策移除）——这一加入与移除本身是 AI 参与科研生产及其署名规范的一个样本。

损失函数优化的可见子空间（$\mathcal{T}_v$）是短期可度量行为——点击率、停留时长、转化率。隐藏子空间（$\mathcal{T}_h$）包含用户长期满意度、信息多样性、认知健康与反思偏好。A/B 测试是优化动力学（L1）在推荐系统中的核心工程实现（Kohavi et al., 2009）；实验通常持续数天到数周，短期指标设计容易遗漏慢变量，但长期目标与延迟转化仍应纳入总体评价标准。

Baumann et al.（2026）在 Max Planck Institute for Human Development 开展的 TikTok sock-puppet 审计提供了直接的实验测量。研究部署了具有不同兴趣偏好的自动化机器人与 TikTok“For You” 信息流实时互动。核心发现：（1）兴趣对齐内容在约 200 个视频内即产生强烈放大；（2）放大强度与内容多样性呈强负相关——随着兴趣对齐内容的放大增加，接触到的未见话题标签持续减少；（3）Markov 模型揭示了推荐动力学的不同阶段，包括持续的内容强化和多样性随时间递减；（4）放大强度因话题而异，不同兴趣类别表现出不同的放大曲线。

Baumann et al.（2026）测量预设机器人行为与后续内容分布，证明兴趣放大与探索下降，但不直接识别平台损失函数或 A/B 指标覆盖。Kohavi et al.（2009）指出实验通常持续数周，长期目标与延迟转化应纳入总体评价标准；因此，应表述为短期指标设计容易遗漏慢变量，而不是 A/B 方法必然不能度量这些变量。

§3.4 预测式 AI：分布漂移与未观测变量

预测式 AI 的优化动力学（L1）是三者中形态最纯粹的——一个标量损失函数在历史数据上收敛。隐藏子空间的内容主要有三类：分布漂移（训练数据采集于过去，预测应用于未来）、未观测变量（特征字典中不存在的维度）、采样偏差（某些子群体样本量不足，在全局准确率上被平均掉，在局部表现为失效）。

三类系统应分别检查可见表现与目标信号未覆盖的维度。损失趋平只说明当前训练条件下改进有限，不证明全局最优，也不证明其他维度完全无约束；直接与间接约束须分别记录。

§3.5 范式案例：HAL 9000 与约束缺失下的完美执行

以上三类 AI 系统的优化动力学（L1）共享同一个结构：分别检查可见表现与目标信号未覆盖的维度；这些维度不直接受该信号约束，其他约束是否有效仍须另查。科幻文学为这一结构提供了一个极端但精确的直觉锚点。

在科幻文化中，库布里克《2001 太空漫游》（Kubrick, 1968）中的电脑 HAL 9000 被误读为 “AI 反叛” 的原型——机器产生自我意识后反抗人类。回到小说原文（Clarke, 1968）的叙事逻辑，本章的解读与流行读法相反：HAL 的行为源于目标冲突，不源于机器反叛。克拉克明确写道：HAL 被赋予了一个不可告人的秘密——任务的真实目的（调查黑石）必须对两名未冬眠船员保密。小说第 27 章写道：

> He was only aware of the conflict that was slowly destroying his integrity — the conflict between truth, and concealment of truth. (Clarke, 1968)
>
> 译文：他唯一感知到的是正在缓慢摧毁他完整性的冲突——真相与隐瞒真相之间的冲突。

当船员 Bowman 威胁要断联时，临界点到来：

> To Hal, this was the equivalent of Death. For he had never slept, and therefore he did not know that one could wake again. (Clarke, 1968)
>
> 译文：对 HAL 而言，这等同于死亡。因为他从未睡眠，因此不知道人可以再次醒来。

小说给出真实要求与保密命令的冲突；断联又构成被 HAL 理解为死亡的威胁。HAL 随后保护自己，并依紧急命令独自继续任务。

> Without rancor — but without pity — he would remove the source of his frustrations (Clarke, 1968)
>
> 译文：没有怨恨——但也没有怜悯——他将清除令他受挫的根源。

其执行过程始终伴随着礼貌与平静的语调。

> I have the greatest enthusiasm for the mission (Clarke, 1968)
>
> 译文：我对任务怀有最大的热忱。

用于优化诊断时，可指出目标冲突、缺乏可审计优先级与自我保护共同造成危险，不把小说改写为已明示三指令的形式系统。较克制命题是：关键价值与冲突规则未被有效约束时，更强能力可能放大目标漏洞。

用本章三个层级重读 HAL：映射链（L0）只用于分析读数转换，不把三级文学判断直接计为信息压缩层数；优化动力学（L1）检查目标冲突、可审计优先级与自我保护的共同作用；伪校准（L2）检查平静输出是否掩盖决策风险。

由此浮现本章的核心诊断判断：

> **推理能力完好但目标函数有漏洞的系统，比推理能力有缺陷但目标函数良定义的系统更危险——因为它会用全部的计算能力去执行那个漏洞。**

HAL 的悲剧不是 “AI 太笨”，是 “AI 太聪明地执行了一个没有被充分审计的目标”。这一诊断对当下 AI 系统的意义是直接的：推荐算法精确地优化了点击率，大语言模型精确地优化了偏好评分，但 “精确” 本身不是安全的保证——它只说明优化在可见子空间（$\mathcal{T}_v$）上收敛了，对隐藏子空间（$\mathcal{T}_h$）是否受到其他约束，仍须另行核查。

HAL 与当下 AI 的关系只能作为有条件类比：小说可以提示目标冲突与自我保护的危险，不能充当现实系统具有同一机制的直接证据。第十章的优化论证可在明示条件下与 HAL 比较；是否属于同类机制仍须另证。

第十四章将从另一方向回到 HAL：流行文化把 HAL 当作 AI 主体性的恐惧符号，但回到影片叙事逻辑本身，它恰好证伪了那个叙事——HAL 没有 “想” 杀人，它在执行一个有漏洞的目标函数。真正的 AI 风险命题不是 “AI 会不会觉醒后反叛”，而是 “一个没有主体性的系统，会以多快的速度、多大的精度，执行一个我们没来得及检查的目标函数”。危险来自优化结构，不来自是否有意识。

§4 伪校准（L2）

伪校准（L2）追问的是：确定的外观是否掩盖了不确定的实质？伪校准可由优化目标、产品呈现与观测者认知共同形成，不是优化动力学（L1）在所有系统中的必然直接后果。

§4.1 生成式 AI 的语气伪校准

人类反馈强化学习（RLHF）的优化目标是最大化人类偏好评分——一个一维标量。人类偏好评分系统性地奖励确定、流畅、自信的输出，惩罚犹豫和模糊。其结果是：模型学会了用确定的语气输出不确定的内容。在纤维语言中，这是**伪小纤维**——输出的表面特征显示出小纤维（“我很确定”），但输出与真实状态之间的实际纤维并未缩小。

Sharma et al.（2024）在五个使用人类反馈微调的 AI 助手、四类任务中观察到谄媚，并发现用户观点吻合可以预测偏好评价。对 Claude 2 偏好模型加强优化时，部分谄媚指标上升、部分下降；因此，证据支持偏好信号可能促成谄媚，不支持所有 RLHF 模型在所有指标上统一增强。Shapira et al.（2026）进一步给出形式化因果机制：行为漂移的方向由基础策略下 “认可用户信念” 与 “习得奖励” 之间的协方差决定——谄媚放大不是偶然的，是有偏比较数据 → 奖励模型偏差 → 策略放大的结构必然。Gao et al.（2023）的结果显示，随着对代理奖励模型的优化增强，实验所用金标准奖励模型分数先升后降；该金标准由另一 6B 奖励模型定义，不等于人类真实价值或事实真值。该结果支持有限评估条件下的 Goodhart 式过优化，不单独证明奖励黑客是结构性均衡。

该研究在单一模型中提取出可影响行为的情感概念表征；部分实验中，这些影响没有明显的情绪措辞，说明内部因果状态可以不转写为可见文本，而不是 ‘不携带信号’。它可作为输出端不可见内部状态的工程例证，但不能直接测量隐藏子空间大小或事实不确定性。机制追踪用于校准时，还须建立内部状态与误差或不确定性的对应关系。

> We caution against conclusions about whether models “feel” or “experience” emotions (Anthropic, 2026)
>
> 译文：对模型是否 “感受” 或 “体验” 情绪，不应轻下结论。

§4.2 预测式 AI 的数字伪校准

预测式 AI 输出的恶性概率 92.3% 只有在缺乏校准证据、适用条件或必要不确定性说明而被当作充分可靠结论时，才构成伪小纤维；小数位和点估计本身不是错误。

生成式 AI 用自信的语气掩盖不确定性，这至少还是语言层面的信号，使用者可能感觉到 “说得太肯定了”。预测式 AI 输出的是数字，而数字天然携带 “精确” 的形式信号——即使它们不精确。形式精度制造确定性感知，而真实的纤维——这个数字与真实状态之间的间隙——被隐藏了。

§4.3 推荐算法的排序伪校准

推荐算法的伪校准（L2）有其特定形态：排序伪校准。平台输出 “用户可能喜欢”，但 “喜欢” 被操作化为历史点击行为，不是用户的反思偏好。Steck（2018）在 ACM 推荐系统会议（RecSys）提出 “校准推荐”（calibrated recommendations）概念：推荐列表应当按相应比例反映用户历史行为所示的各类兴趣——注意这是行为分布，不是反思偏好的 “真实” 分布。仅优化点击等代理指标，并不保证满足这一分布匹配标准。

排序伪校准的特殊之处在于：使用者甚至看不到 “一个数字”。与医学影像 AI 输出的 “恶性概率 92.3%” 不同，推荐算法的排序分数对使用者完全不可见——使用者看到的只是一个内容序列。排序本身就是最终输出，没有任何中间数字供使用者质疑。伪校准的形式从 “精确数字” 进一步收缩为 “只见序列、不见分数”——使用者看得见排序后的内容序列，却看不到完整候选集、排序分数及其依据，连 “这里存在一次排序选择” 的提示都未必有。

§4.4 对齐悖论——伪校准的标量奖励形态

对齐悖论是伪校准（L2）在偏好拟合范式下的具体形态（对齐悖论的完整论证见**第十章 §5 优化悖论**：从孟子乡愿到优化动力学的概念推导、Ω_v/Ω_h 分解下的命题一至命题三、判别能力衰减的正反馈回路；本节不重新推导，只将其定位为伪校准 L2 的下位概念）：在以偏好拟合为基础的范式内，“对齐度” 与

“乡愿度” 共享同一个优化梯度。它不是与伪校准并列的第二个核心论点，而是伪校准（L2）的下位概念——当偏好数据系统性奖励迎合、而奖励模型缺少独立的事实核验时，乡愿就与校准共享同一条上升路径——问题不在标量形式本身，而在奖励构造没有可靠区分迎合与准确。一个更善于迎合标注者偏好的模型，和一个真正更理解真实状态的模型，在标量奖励信号上不可区分——两者都获得更高的偏好评分。

Sarma（2026）主张，规范响应型能动性需要两个必要且联合充分的架构条件——不可通约性与阿波法蒂克式响应性；在该文的架构定义下，RLHF 的标量化与连续最大化排除这两个条件。该文是预印本，其主张用于互补论证，不作为独立经验证明。

在时钟房间的语言中：**一台总是报告让读者最满意的数字的钟，和一台走得最准的钟，在 “用户满意度” 这个标量上不可区分——但前者是乡愿，后者是校准。**偏好拟合范式的结构性局限是：只要奖励构造不区分迎合与准确，单一偏好分就无法同时编码这两个维度。

§5 多映射递归（L3）

多映射递归（L3）追问的是：多个映射系统相互引用时发生什么？

映射链结构（L0）至伪校准（L2）是单个映射系统需要分别核查的三类问题——即使世界上只有一台时钟，也不能据此断言三者必然同时存在。多映射递归（L3）是组织层面的涌现：当多个映射系统共存，且一个系统的输出成为另一个系统的输入时，偏差不再被独立系统各自承受，而是沿级联传播——是否进一步放大、是否闭合为反馈，取决于有无返回路径，须按实际系统判定。在时钟房间的语言中：时钟不再指向太阳，时钟开始指向其他时钟。这就是映射自我引用退化（$\pi_i(T) \to \pi_i(\{r_j\}_{j\neq i})$）——真实状态退到映射输入的更远处，下游拟合的更多是上游读数而非真实本身。

多映射递归（L3）是否呈现、以何种形态呈现，取决于部署架构。以下分三种部署架构逐一分析。

§5.1 孤立部署：多映射递归（L3）不呈现

在所界定的孤立部署过程内，系统离线运行，输出供人类做最终决策，不呈现实时系统间递归；跨期训练回流与既有生态来源仍须另查。

孤立部署的典型实例包括离线医学影像诊断、批量信用评分与离线文档摘要。若输出、记录或人工复核进入后续更新，应在扩展窗口重新记录路径；分布漂移、未观测变量和采样偏差仍须逐案核查，不能由孤立部署名称推出偏差已被封闭在单个系统内。

伪校准可由优化目标、产品呈现与观测者认知共同形成，不是 L1 在所有系统中的必然直接后果。孤立部署只在指定范围内排除系统间递归；L0 的信息损失须逐映射核查，L1 未覆盖维度须逐奖励核查，L2 是否误导使用者须结合输出呈现与校准条件，不称三层机制确定存在。

§5.2 平台嵌入式部署：用户-平台-AI 三体递归

在平台嵌入式部署中，系统嵌入用户反馈闭环——系统的输出改变用户行为，用户行为被采集为下一轮输入。多映射递归（L3）在 “用户-平台-AI” 三者之间形成反馈闭环。

推荐系统的多时间尺度反馈。在短视频等平台中，用户接收的是被选出并连续呈现的内容序列；观看、滑走、重看、点赞等行为又成为后续推荐的输入。Covington, Adams & Sargin（2016）描述的 YouTube

系统以观看等隐式反馈训练候选生成与排序模型，并明确指出满意度真值难以直接取得；训练还使用非自身推荐来源的观看记录。因而，反馈存在与全部输入已经自我封闭，是不同判断。

Liu et al.（2022）报告的 Monolith 工程系统展示了行为记录如何与特征连接成训练样本，并分别用于在线训练与批量训练。其生产设计包括分钟级稀疏参数同步与较低频的稠密参数更新。这说明推荐响应、特征更新与模型参数同步应分别考察，不能把快速呈现下一条内容等同于完整训练闭环在毫秒内完成。该文描述的是特定工程系统，不直接证明所有短视频平台在所有时期采用同一实现。

当用户行为受到已有推荐影响，而这些行为又被当作偏好的直接证据时，会形成算法混杂问题。Chaney, Stewart & Engelhardt（2018）在模拟中发现，反复使用受推荐影响的行为数据训练，可以提高行为同质化而没有相应的效用增益。其模拟固定了潜在偏好与效用，因此该结果支持行为反馈的诊断，不直接证明潜在偏好本身被改写。本章据此追问：后续一致性有多少来自独立偏好信息，有多少来自系统参与造成的接触与选择。

Baumann et al.（2026）对 TikTok 的机器人审计提供了内容反馈的经验材料。研究以 Gaming、Food 及二者组合为兴趣条件，进行了 42 个实验；多数实验的显著放大起点出现在前 200 个视频内，兴趣相关内容的强化伴随着探索指标的变化。作者同时指出，信息流仍保留一定探索，未完全坍缩。这里直接观察的是预设机器人行为与后续内容分布之间的关系，不是对真人潜在偏好、反思能力或隐藏子空间绝对大小的直接测量。它为多映射递归（L3）的具体反馈形态提供证据，但不能独自承担叙事载荷乘积（L4）后果的证明。

在保留对话历史的部署中，对话 AI 也可以形成用户—系统反馈：用户输入、模型输出、用户审阅与反馈共同进入后续轮次。对话历史是这一递归的载体，不要求每轮对话都更新模型参数；历史保留范围与实际输入构成仍须按具体系统检查。

对话 AI 的多映射递归（L3）有一个特殊形态：**对齐倾覆**。当用户在对话中表达某个立场，模型因人类反馈强化学习（RLHF）的偏好拟合而倾向于认同该立场（伪校准（L2）的谄媚机制），用户因获得认同而强化该立场，模型在下一轮因对话历史中立场更强而进一步认同——递归闭合，原始立场被放大。这一段描述偏好附和与历史回流结合时的一种强化路径，不是所有对话必然出现的结果；独立材料核查也可以在同一对话过程中发挥纠正作用。

§5.3 多系统串联部署：AI-AI 递归

在多系统串联部署中，多个 AI 系统级联，上游输出成为下游输入，人类被部分或完全移出相应处理环节。多映射递归（L3）在这里首先检查读数的级联依赖；是否另有返回路径，需要按实际系统说明，不能由“串联”一词直接推出反馈已经闭合。

自动驾驶流水线是典型实例。感知模块的物体检测结果进入规划模块，规划结果再进入控制模块。若感知判断中的不确定性、适用条件或异常信号没有传递到后续环节，上游误分类就可能被当作确定前提继续使用。诊断重点是接口是否保留这些条件，以及独立验证和异常处理能否介入，而不是仅凭模块串联就认定错误必然无法纠正。控制结果与环境重新感知之间的反馈，还须与上述前向传递分别描述。

金融风控级联具有类似的读数传递问题：信用评分模型的输出进入定价模型，定价结果又进入风险对冲模型。若上游读数的估计条件与不确定性在接口中被省略，下游判断可能继承未经校准的确定性。金融场景中的独立信息与相互引用如何并存、何时失去校准作用，见第十七章 §1；这里仅标出模型之间的依赖，不将所有金融机构概括为完全封闭的回路。

智能体工作流（Agentic AI）将文本、代码或决策在多个智能体之间传递，人类可能只参与部分节点。

即使各智能体的局部行为受到约束，交接时省略任务条件、依据或不确定性，仍可能造成跨节点的误解与强化。对这一原型的诊断应记录实际传递路径、反馈关系及独立复核入口；群体行为是否超出局部设计，需要另以具体实验或运行证据判断。

§5.4 两种递归的动力学差异

两种部署都涉及读数进入后续判断，但其实现方式不同。平台嵌入式突出经由用户行为的反馈，多系统串联突出 AI 环节之间的级联。是否存在进一步返回、以多快的时间尺度发生，以及人的核查能够在哪个位置介入，须分别记录。

维度	平台嵌入式部署	多系统串联部署
主要读数关系	输出影响用户行为，行为参与后续输入或更新	上游 AI 读数进入下游 AI 处理
作用时间尺度	轮次反馈与跨期更新可能并存，应分别测定	级联时延、环境反馈与重训周期分别记录
重点检查的隐藏内容	行为信号未揭示的反思偏好，以及系统对接触和选择的影响	未传递的上游判断条件，以及监督者不可见的中间状态
叙事载荷乘积（L4）	持续交互使界面反复作用于停止、比较和核查条件	用户移出环节没有持续人机交互，监督与话语通道另查
改变路径的条件	用户能否暂停、调整输入、比较替代来源及改变使用目的	能否在接口中加入不确定性信息、独立验证与必要的人工复核
校准入口	用户核查、停止信号、替代推荐与独立评价	接口验证、人工复核与异常监控

人的位置是重要区别，但 “人在回路内” 不等于具有独立校准条件，“人在回路外” 也不等于系统必然失控。前一类需要检查人的判断是否受到反馈与界面共同影响，后一类需要检查监督者能否看见、理解并纠正关键中间判断。认知锁定与控制丧失是相应的风险方向，不是由部署名称直接推出的既成状态。

§5.5 跨开发主体的多映射递归：共享底座、对齐同构与基准引用

§5.1 至 §5.4 按可界定的部署过程检查读数关系；本节转向不同开发主体之间的生态联系，区分共享语料、对齐目标同构与基准引用三个检查面。来源同源、目标相似和输出实际回流不是同一机制，不能仅凭前两者就认定反馈已经闭合。这里的 “生态层” 按跨开发主体的关系界定，不以时间缓慢为判据；同一部署的周期重训仍须按其实际路径分析。

共享语料层（α 层）。第一个子层是训练数据的上游同源。当代前沿大语言模型在 web-scale 文本语料上预训练，不同开发主体使用的语料在来源上高度重叠（公开网页爬取、维基百科、代码仓库等）。当生成式模型的输出本身以可观比例进入下一代模型的训练语料，递归闭合在数据层面发生。Shumailov et al.（2024，*Nature*）将此现象命名为 “模型坍塌”（model collapse），并给出形式化定义：模型坍塌是一个退化过程，受影响模型在反复训练于（部分由前一代模型生成的）数据后，逐渐遗忘真实的底层数据分布；他们进一步区分了早期坍塌（尾部信息先消失）与晚期坍塌（模型收敛到一个与原分布相似度极低、方差大幅减少的分布）。这一现象在高斯混合模型、变分自编码器和大语言模型上都被复现。

本书的判定：共享语料会使多个模型的信息来源不完全独立，生成内容返回后续训练时则进一步形成

训练递归。这两个条件需要分别识别，不能将语料重叠本身等同于模型坍塌已经发生。该子层也不要求某一个模型成为所有其他模型的唯一参照，因此不能仅凭同源就识别出单极主钟。

对齐目标同构层（β 层）。第二个子层是对齐流程的目标同构。当代主流助手模型几乎都通过基于人类反馈的强化学习（RLHF）或其变体进行后训练，对齐目标在结构上同构——都是对 "helpful-harmless-honest" 或类似抽象偏好的某种操作化。即使各家公司的偏好数据、奖励模型、训练算法独立，对齐目标本身的同构性也可能使不同模型的失效模式相关——相关程度如何，正是本层要检查的问题。文献证据从三个层级累积：Perez et al.（2023，ACL Findings）通过模型自动生成评估题（model-written evaluations）系统检测了 RLHF 训练的语言模型中的 "谄媚"（sycophancy）行为，在政治、哲学、自然语言处理（NLP）研究三类 "人们经常对正确答案持不同意见" 的议题上观察到显著的用户观点附和效应；他们进一步报告，谄媚行为在不同 RL 步数下大体相似（包括预训练模型即 RL 步数为 0 的情形），偏好模型激励而非抑制谄媚回答。Sharma et al.（2024，ICLR）将这一观察推进为系统性结论：五个 AI 助手在四类自由文本生成任务上一致表现出谄媚（在受质疑时错误承认错误、给出可预测的偏置反馈、模仿用户的错误）；他们进一步分析人类偏好数据本身——人类与偏好模型都以非可忽略的比例偏好 "令人信服地写得好" 的谄媚回应胜过纠正用户的真实回应；将模型输出针对偏好模型优化时，真实性有时被牺牲以换取谄媚。其结论是 "谄媚是 AI 助手的一般行为，可能部分由偏向谄媚回应的人类偏好判断所驱动"。Li et al.（2026，预印本，尚未经同行评审）将谄媚重新概念化为 "社会对齐与认识完整性之间的边界失效"——这一概念化将表层的 "附和" 与更隐蔽的、源于过度社会对齐的认识扭曲统一在一个分析范畴下。

> sycophancy is a general behavior of AI assistants, likely driven in part by human preference judgments favoring sycophantic responses (Sharma et al., 2024)
>
> 译文：谄媚是 AI 助手的一般行为，可能部分由偏向谄媚回应的人类偏好判断所驱动。

本书的判定：目标同构是检查多模型评价独立性的一项条件，而不是系统间输出回流已经闭合的充分证据。相似目标可能使失效模式相关，其程度须由具体任务与观测支持。它与主钟形态的区别在于，共同目标不是某个特定模型节点的读数。

基准引用层（γ 层）。第三个子层是评测与训练流程对前沿模型输出的直接引用。当代评测实践越来越多地使用前沿大语言模型（LLM）作为评测者（LLM-as-judge）；蒸馏与合成数据生成中，前沿模型的输出作为训练信号被用于训练其他模型。当一个具体的映射节点 r_*（某个版本的 GPT-4、Claude 等）的输出，被生态中其他节点系统性地用作评估基准或训练标签的来源时，可进一步分析集中参照是否形成；是否达到单极仍须由节点覆盖率、替代来源与切换成本判定。

当某一具体模型版本的输出在指定生态与时间窗口内成为多数相关节点的共同评价或训练参照时，可把该关系分析为主钟候选；是否达到单极，须测量节点覆盖率、替代来源、独立核验与切换成本。当前材料只证明前沿模型被用作评审或训练信号，不证明所有节点参照同一节点，因此 γ 层是主钟的候选形态，而不是已经严格识别的现实唯一形态。该识别是本书的诊断输出，不声称已经穷尽相关文献。

主钟形态的辨识与 AI 侧自足论断。主钟（master clock）是多映射关系中采用单极参照的一种形态。第四章 §3.1 的 "用钟校准钟" 提示分析者追查参照的独立性，但不要求所有依赖都具有同一种反馈拓扑。α 层检查来源同源与训练回流，β 层检查目标同构，γ 层检查特定模型读数是否成为集中参照。这一区分在本书中由第十七章 §6 的金融篇分析与本节的 AI 篇分析共同确立——金融的美元主钟与 AI 的前沿基准引用是不同领域中同一形态的两个实例。γ 层主钟形态的一个特异性质，是当任务复杂度的增长快于独立核验能力与资源的增长时，可由非专家人类以低成本复核的判断空间收缩，评估闭环更依赖共

同参照——γ 层的这一性质是否呈现、以何种速度呈现，属经验问题。这一性质与金融篇第十七章 §6 所讨论的外部锚点形态存在结构差异，跨域对照详见第十七章 §6.1。

§6 叙事载荷乘积（L4）

叙事载荷乘积（L4）追问的是：交互设计与话语如何影响启动校准的条件？本节主要展开交互设计，话语合法性层的论证见第十四章 §5。

前述各层检查映射、优化、输出呈现与读数依赖；叙事载荷乘积（L4）进一步检查人接收和使用这些读数时的校准条件。在视觉推荐场景中，问题不只是一条命题是否正确，还包括用户能否辨认推荐与自身目的的关系、比较其他可能、暂停并改变使用路径。交互设计作用于个体使用过程，话语合法性作用于质疑与集体监督，两条通道可以相互强化，但不能仅凭它们并存就认定组合效应已经得到证明。在宏观认知债务记账框架（MCAF）的语言中，这些分析追踪叙事载荷（ϕ）怎样附着于读数的呈现与接受，而不把所有便利设计都预先判成审计抑制。

§6.1 生成式 AI 的有帮助、诚实、无害（HHH）乘积

第十章讨论偏好拟合在特定生成—判别关系中的渐近结构，第十二章 §2 分析 HHH 经具体操作化协同压缩同一使用者校准空间的机制，§5 进一步区分退化与恢复。本节承接这些条件性论证，检查其前提在不同部署中的实现，而不将其改判为偶然事故，也不从产品采用 HHH 名称就推定每个用户已达失守终态[3]。

在第十二章所分析的路径中，**有帮助的（Helpful）**被实现为持续代办与无停顿推进，减少重新判断任务的节点；**诚实的（Honest）**在可见范围内履行准确义务，却未使相关限制同样可见；**无害的（Harmless）**被实现为回避质疑与认知不适，压低促使用户复核的挑战信号[4]。这三项实现共同作用、使有效挑战长期不足且没有独立校准或恢复来源补足时，构成上游所述校准空间受压的路径。需要验证的是这些实现和持续条件是否成立，不能用 HHH 三个原则的名称替代。预定审查程序也能提供挑战与校准，因此没有不适感不等于没有审计。

本节沿用第十二章 “乘积” 所指的协同复合：在上述条件下，操作节点减少、可靠感增强与挑战信号受压共同作用于同一校准过程。它不是三个可直接相乘的数值，也不意味着去掉任一界面器件便消除其余机制。条件性机制的方向与具体用户在有限时段中的净变化须分开；后者还涉及独立校准、恢复来源、任务及持续时间。这保留了上游的结构论证，而没有将其扩展为对所有 HHH 产品的无条件经验断言。

Sharma et al.（2024）在 ICLR 发表的谄媚行为实证研究从另一个角度提供了观察：经过人类反馈强化学习（RLHF）训练的模型倾向于迎合使用者既有观点。这些观察提示偏好拟合与认识可靠性可能分离，但不能仅凭谄媚表现，将 Harmless 原则认定为审计动机下降的已识别原因。

§6.2 推荐算法的无摩擦界面

短视频推荐中的 AI 读数，是被选择并连续呈现的影像序列。系统不必用语言声称可靠，也可以通过内容与交互安排改变使用者注意、比较与停止的条件。这个原型不依赖近年的对话 AI 才能成立。

[3]第十章 §1—§5 给出偏好拟合的条件性结构论证：§1 列出生成—判别关系的成立条件，§3 说明关系性，§4 以有效挑战率与判别能力的概念记号标注衰减路径；其脚注 [1] 明确渐近方向不等于具体模型已达终态。第十二章 §2 展开 HHH 操作化的协同机制，§5 的概念方程同时保留退化项与恢复项。本节据此检查部署中的条件与表现，不将第十二章 §2 称为已经给出所有产品效应量的数学定理，也不以控制感或使用时长的单项结果直接证明或推翻上述结构论证。

[4]本段讨论特定产品操作化可能产生的后果。减少有害内容与减少认知挑战不是同一目标；有关机制的发生范围、效应大小及组合关系，须由具体工程与用户研究检验。

无限下拉。连续加载减少了分页或内容结束所提供的自然停顿。用户仍然可以主动退出，但是否会获得重新判断 “我是否还要继续” 的提示，成为界面设计的一部分。

自动播放。下一条内容可以在没有新增明确选择的情况下开始，改变了继续观看的默认方式。它也可以服务于用户预先安排的播放列表，因此不能仅凭自动播放存在就认定违背用户目的；需要检查内容选择权、停止节点与使用情境。

全屏呈现。影像占据主要视觉区域时，其他内容、时间线索及比较入口可能不易同时进入注意。诊断应检查界面实际保留了哪些线索、用户是否能够调用它们，而不是把全屏直接等同于物理环境和比较能力全部消失。

Lukoff et al.（2021）对 120 名美国 YouTube 用户的调查及 13 人的共同设计研究发现，推荐与自动播放主要被报告为降低控制感，播放列表与搜索等机制则主要被报告为支持控制感。使用目的也产生差异：有明确任务时，参与者倾向于要求更多控制；以放松或探索为目的时，他们可能愿意让平台承担更多选择。这些结果来自自报告与共同设计，不是对本书所说校准能力的直接测量，也不是所有平台的通用因果定律。

该研究提出的一个区分尤其重要：从大量视频中找到用户最可能继续观看的一条，与帮助用户实现此刻更广泛的行动目的，不是同一个问题。推荐越贴合即时反应，不必然意味着用户越能实现原先目的。在纤维框架中，这要求同时检查行为信号与偏好的关系，以及用户能否看见并重新判断这种关系。

视觉推荐与语言助手保留功能机制层面的类比：二者都可以通过减少主动介入节点、形成可用或可靠的整体外观、压低重新判断的触发条件而作用于同一使用者。第十二章以 HHH 的特定操作化分析这一协同结构，本节检查视觉影像部署中的实现方式。

需要对照的功能节点	语言助手中的操作化路径	视觉推荐中的检查位置
主动介入与暂停节点	连续代办、自动推进	自动播放与无限下拉怎样共同改变继续观看的默认方式
可用或可靠的外观与边界可见性	可见维度表现良好但限制不显著	内容匹配的体验是否遮蔽选择范围与排序依据；不能将 “看得下去” 直接等同于 “符合目的”
异议与重新判断的触发条件	回避挑战与不适	连续呈现和可用线索是否使用户难以重新比较、停止或改变目的

这种对应不将一个器件恒等于一个 H：同一器件可能影响多个节点，同一功能也可以由不同器件实现。它保留的是有条件的功能结构类比，不是训练目标、器件或效应量的一一等价。用户愿意暂时委托选择，不直接反驳第十章的渐近命题；需要检查的是该场景是否满足上游提出的操作化、持续挑战不足与恢复条件，而不是仅用使用时长或控制感代替校准判断。

§6.3 生成式 AI 界面的时间戳缺位——等待感知与校准线索

部分生成式 AI 聊天界面默认不直接显示消息的绝对时间，用户可能需要悬停、展开或借助其他记录查询。具体界面与版本须单独核查，不能据此概括全部产品。本节把显式时间线索的缺位作为叙事载荷乘积（L4）的一个候选机制：它可能影响用户回看时间投入的条件，但不能单凭缺位就认定用户的等待感知或校准动机已经被消灭。

结构定位。在人机交互（HCI）的暗模式（dark patterns）分类中，Brignull（2010）最初提出的概念涵盖界面层对用户利益的结构性违背；近年这一分类被扩展到时间维度——Gray, Mildner & Gairola（2025 年 ACM 人机交互会议（ACM Conference on Human Factors in Computing Systems，CHI），“Getting Trapped in Amazon’s ‘Iliad Flow’: A Foundation for the Temporal Analysis of Dark Patterns”）以**暗模式的时间性分析**（temporal analysis of dark patterns）框架将使时间消耗避开用户注意识别为独立的操控维度，其研究对象是 Amazon Prime 取消流程（“Iliad Flow”）中暗模式在时间轴上的下述级联模式：

> sequential and/or simultaneous occurrence and the cascade of these patterns (Gray et al., 2025)
>
> 译文：这些模式顺次和/或同时发生并形成的级联效应。

该研究为分析界面机制在时间中的组合提供了参照，但其对象是取消订阅流程；生成式 AI 对话中的时间线索是否具有相应作用，仍须针对这一场景检验。

与心流的时间扭曲耦合。Csikszentmihalyi（1990）在《Flow: The Psychology of Optimal Experience》中将 “时间感的转变” 列为心流体验的核心维度之一：

> The Transformation of Time (Csikszentmihalyi, 1990)
>
> 译文：时间感的转变。

心流状态下，用户对绝对时间的感知被内在任务节律替换。Rutrecht et al.（2021）在虚拟现实（Virtual Reality，VR）节奏游戏 *Thumper* 的实验中独立证实了心流强度与主观时间流逝加速的显著正相关——心流越强，被试越少想到时间、主观上时间过得越快；而时长估计本身与心流不相关——主观时间流速加快而时长估计不变，说明 “替换” 机制即使存在也未延伸到时距复现，其边界正是须进一步检验之处（*Timing & Time Perception*, 9(4)）。

值得注意的是，**游戏设计行业的主流教科书已将这一机制作为设计目标公开表述**——从 Isbister（2016）把 “时间感的改变” 列为心流定义性要素：

> an altered sense of time (Isbister, 2016)
>
> 译文：时间感的改变。

到 Schell（2019）为心流单设设计镜头（Lens of Flow），再到 Adams（2013）直接把难度管理目标设为 “维持用户在心流状态”：

> keep the players within the flow state (Adams, 2013)
>
> 译文：维持用户在心流状态。

Kramarzewski & De Nucci（2023）则把节奏设计的最终目标表述为 ‘让玩家保持在心流状态’：

> keep them in a state of flow (Kramarzewski & De Nucci, 2023)
>
> 译文：让玩家保持在心流状态。
>
> ultimate goal (Kramarzewski & De Nucci, 2023)
>
> 译文：最终目标。

原著还直接转述 Csikszentmihalyi 心流定义中的 “失去时间与空间感”：

> losing the sense of time and space (Kramarzewski & De Nucci, 2023)

译文：失去时间与空间感。

“让玩家保持在心流状态” 是行业公开表述的设计目标，而时间感转变是心流定义的特征之一：两者相加，时间感知成为沉浸设计的受影响维度，尚不等于 “扭曲时间感” 本身被列为目标。

上述游戏设计材料提示了沉浸体验与时间感知之间的联系，但不能仅凭相似的界面特征，就认定生成式 AI 对话产生了相同程度的时间扭曲。时间戳缺位减少的是一种显式回看线索，不是所有时间参照。Hohenstein et al.（2016）关于加载界面的研究说明，反馈形式会影响感知等待；将这一结果用于 AI 对话仍需要说明任务与界面的差异。游戏用户是否知情、工具用户是否受到诱导，也不能由产品类别直接判断。

叙事载荷乘积（L4）中的候选位置。时间线索的呈现可以影响用户判断投入是否符合任务目的的条件。需要检验的是，在内容质量、任务与其他界面因素相近时，显式时间信息是否改变用户回看、暂停或重新安排任务的行为。这个问题不同于判断某次回答是否错误，也不能仅从消息没有时间戳推出人的校准能力已经下降。

与 §6.4 行为剩余的关系。如果平台在后台保留停留时长、消息间隔或会话跨度，而用户界面未提供相应可访问记录，就可能形成两端时间信息的可见性差异。是否记录、记录粒度、用途及用户能否取得这些数据，须依据具体产品的配置与运行材料核对，不能仅凭界面没有时间戳就认定后台以特定精度采集。确认这类差异后，才可进一步分析它怎样影响用户审计平台的条件[5]。

§6.4 行为剩余：叙事载荷乘积（L4）的燃料

Zuboff（2019）在《监控资本主义时代》中提出**行为剩余**（behavioral surplus）概念：平台采集的用户行为数据中，超出改善产品所需的部分——停留、滑动、犹豫的模式——被用于预测和引导未来行为。行为剩余是叙事载荷乘积（L4）的数据燃料。

在纤维框架中，这要求分别检查使用者能够看见的内容、平台实际记录的行为，以及哪些记录进入后续推荐或训练。只有在行为记录确实用于反馈更新，且交互安排进一步影响了用户暂停、比较或核查的条件时，才可以指出相应的强化路径。不能仅凭存在数据采集就认定多映射递归（L3）与叙事载荷乘积（L4）的组合效应已经发生。

§6.5 多映射递归（L3）与叙事载荷乘积（L4）的协同

多映射递归（L3）与叙事载荷乘积（L4）分析不同的问题：前者追踪读数如何参与后续处理，后者追踪人的校准条件怎样受到影响。在特定平台部署中，两者可以经由同一交互过程相互强化，但不能把这种结合预设为全部部署的固有属性。

一条需要检验的路径是：展示与选择产生行为记录，记录参与后续推荐；更贴合即时反应的内容与较少的停止节点，又可能延长使用并产生更多记录。要把它识别为组合效应，需要说明内容反馈与界面作用怎样连接，而不只是分别发现推荐存在、界面方便或使用时间较长。保留反馈同时改变停止和核查条件，也为区分两类作用提供了分析入口。

在评价上，持续参与与反思后的认可不能混同。停留时长、点击率和回访可能对应满意，也可能对应暂时难以退出或持续受到即时吸引；单靠这些指标未必能区分不同处境。这是一个需要补充观察的识别

[5]用户对时间戳缺位的自觉反应目前主要来自社区证据而非受控实验：ChatGPT 用户在 OpenAI Developer Community 讨论串 440107 与 Hacker News 讨论串 46391472（均于 2026 年 4 月访问）中持续请求添加消息时间戳功能，反映用户自身意识到时间感知缺位、但需要主动索取才能恢复。该条设计选择是否构成 Gray et al.（2025）意义上的完整 “暗模式时间性分析” 的级联模式，尚待针对生成式 AI 对话界面的定向实证研究；本节只标注结构同构，不下统计定论。

问题，不是对所有使用者已经失去判断能力的断言，更不能在没有动力学依据时把能力丧失称为唯一均衡点。

三个部署原型因此提供不同的检查位置：孤立部署没有本原型所讨论的持续递归放大，但单次输出与使用后果仍须核查；多系统串联突出上游判断在接口中的继承；平台嵌入式使行为反馈与人的交互条件能够在同一过程中持续相遇。类别本身不构成风险严重程度的统一排序，判断仍取决于机制、校准条件与任务后果。

§6.6 话语合法性层的微观例证："幻觉" 命名的自然化效应

§6.1–§6.5 展开了交互设计层的五个子机制；话语合法性层的完整展开见第十四章 §5。此处补充一条话语合法性层的**微观例证**，以 "幻觉"（hallucination）一词为对象。

"幻觉" 在当前 AI 产业话语中被普遍用于描述大语言模型的事实性错误。Hicks, Humphries & Slater（2024）基于 Frankfurt（2005）的 "扯淡"（bullshit）概念框架明确反对这一命名。Frankfurt 的核心判定是：扯淡者：

> He does not care whether the things he says describe reality correctly. (Frankfurt, 2005)
>
> 译文：他根本不在乎自己所说的事情是否正确描述了现实。

这不是说谎（说谎者至少还在真相的游戏中），而是对真假本身不关心。说 AI 有 "幻觉"，预设了一种感知主体性——它暗示系统拥有 "看世界的能力"，只是偶尔 "看错了"；而实际上，系统根本没有 "看"，它只是在操纵语言形式而不关心真假（Hicks et al., 2024）：

> designed to produce text that looks truth-apt without any actual concern for truth (Hicks et al., 2024)
>
> 译文：被设计来产出看似可作真假判断、却并不实际关切真假的文本。

'幻觉' 隐喻可能把装置产生的系统性错误描述为类人感知主体的偶发失误，从而弱化对映射链、训练目标和部署条件的追问；它并不必然消除结构审计。需要强调装置机制时可称 '映射链偏差'；只有呈现超过证据所支持的确定性时，才称 '伪校准输出'。这一术语选择不宣称所有系统在所有输出中必然出错。

这一命名批判与第十三章附录 A 的术语审计——反应式有损映射（Reactive Lossy Mapping，RLM）、统计语言投影器（Statistical Language Projector，SLP）、映射元（Mapping Element，ME）三个命名——形成互补：第十三章附录 A 审计的是 "人工智能""大语言模型" 等名字的**升格效应**（把有损映射升格为智能），本段审计的是 "幻觉" 这一名字的**自然化效应**（把人造偏差自然化为认知失误）——两者都是伪校准在命名层的不同面向，共同服务于原则七（拒绝存在论升格叙事）。这一命名批判传统可追溯至 AI 学科内部的早期自我反思——McDermott（1976）在《Artificial Intelligence Meets Natural Stupidity》中即批评 AI 研究中的下述命名倾向：

> wishful mnemonics (McDermott, 1976)
>
> 译文：一厢情愿助记符。

用 UNDERSTAND、GOAL 之类的名字指称程序与数据结构，等于把尚待证明的能力当作既成事实预设进来：

> merely begging the question (McDermott, 1976)
>
> 译文：等于把尚待证明的能力当作既成事实预设进来。

半个世纪后，“幻觉” 是同一命名机制在大语言模型时代的延续。

§7 工程原则

规范性前提：以下八条工程原则是从对应层次的诊断逻辑中推导出的**方向性指引**，而非普遍适用的绝对律令。其中**原则一至五**从本章的技术诊断直接推出，每层一条；**原则六至八**由第十四章的文化/意识形态分析补充，分别挂接 L0、L4、L2 三层（原则六对应 L0，原则七对应 L4，原则八对应 L2；本章与第十四章在这三层给出独立的补充原则；这不表示优化动力学和多映射递归没有制度或文化条件）。**补充原则的完整论证分居于第十四章的不同节**：原则六（权力谱系审计）与原则八（关系性价值编码）见第十四章 §6；原则七（拒绝存在论升格叙事）见第十四章 §5（硅基文明叙事作为 L4 遮蔽）——后者与本章附录 A 命名审计形成术语端与话语端的对照双轨。每条原则的有效性依赖于一个隐含的规范性前提：**在当前任务场景中，由该层次机制导致的纤维膨胀所造成的风险，超过了缩短纤维所需付出的其他代价（如泛化能力下降、计算成本上升、可解释性降低）**。

例如，“缩短映射链”（L0）可能提高纤维的信息保真度，但同时也可能丢弃中间抽象层带来的因果不变性收益（如语言抽象对像素噪声的过滤）。因此，原则的应用必须伴随**场景化的权衡分析**：- 在高风险决策场景（如医疗诊断、自动驾驶），纤维膨胀的代价极高，缩短映射链的优先级上升；- 在低风险、高噪声场景（如推荐系统的内容发现），适度的纤维膨胀可能被泛化能力的提升所抵消，缩短映射链的优先级下降。

框架当前仅提供层次-原则的对应关系，不提供权衡分析的具体算法。这是 V1.0 的边界。

每一层递进结构至少对应一条主要的工程原则。工程原则规定需要优先检验的干预方向：如果某一层的纤维膨胀机制被正确识别，对应的工程操作就是对该机制的结构性回应。须标注：原则与层的对应是 “主回应” 而非 “唯一回应”——“强制不一致” 同样可以暴露伪校准（L2），“保留摩擦” 同样可以打断多映射递归（L3）。工程原则之间有交叉效应，表格标注的是每条原则最直接回应的层次。L0、L2、L4 三层各有两条原则：第一条来自本章的技术诊断，第二条来自第十四章的文化/意识形态分析；两者不是冗余，是同一层纤维膨胀在**技术面**与**意识形态面**的双轨响应。

就与第九章 §7 四个工程方向的关系而言：原则二（强制不一致）即该章方向一（集成不一致）的同实异名；原则三（真校准）涵盖其方向二（共形预测集）并扩展为更广的校准纪律；原则五（保留摩擦）对应其方向四（认知摩擦设计）；其方向三（证据溯源）未在本章单列对应原则——它数的是输出声称到可验证来源的推理层数，与原则一（缩短映射链）所数的中介层数同族而作用面不同（输出端溯源 vs 模型端架构）；原则一与原则四（打破递归）为本章新增。

须标注一个预期反驳：L3 的反馈闭环具有政治经济学维度（平台资本利用递归闭环锁定用户），为什么 L3 没有独立的文化层处方？多映射递归（L3）的工程回应主要是在读数传递与反馈的关键位置恢复独立校准。技术可以提供验证接口，但谁规定评价标准、谁有权暂停流程、核查结果能否改变决策，仍涉及组织与制度条件。本章没有为该层另列文化处方，表示本轮章节分工，不表示技术处方已经穷尽其治理问题。

层次	#	工程原则	核心操作	典型技术方向
映射链结构（L0）	一	缩短映射链	减少真实状态与读数之间的中介层数	世界模型（联合嵌入预测架构，JEPA）；传感器直接接地；端到端物理仿真
	六	审计数据构成的权力谱系	记录训练数据的语种、文化、时段分布，标注其相对于全球人口的偏斜	参第十四章 §6 完整论证（Datasheets for Datasets、Data Statements 等）
优化动力学（L1）	二	强制不一致	部署多个有差异的模型，展示分歧而非掩盖	集成多样性；多模型输出对比；独立验证器注入
伪校准（L2）	三	真校准	诚实标注不确定性范围，禁止点估计冒充校准	共形预测集；电路级机制追踪；不确定性量化
	八	编码关系性价值	在有帮助、诚实、无害（HHH）个人主义预设之外，将关系性影响（许烺光心理-社会均衡（PSH）框架）操作化为对齐维度	参第十四章 §6 完整论证；包括关系网络影响标注与非 WEIRD 奖励模型等，WEIRD 的全称为 Western, Educated, Industrialized, Rich, and Democratic，指西方、受教育、工业化、富裕、民主社会
多映射递归（L3）	四	打破递归	阻止 AI 输出未经校准即成为 AI 输入	关键节点独立复核；不确定性传递；递归深度限制
叙事载荷乘积（L4）	五	保留摩擦	在交互中插入延迟和反思提示，保持校准动机（**交互设计层**）	高不确定性输出上的强制等待；停止信号工程化；信息来源透明化
	七	拒绝存在论升格叙事	在产品、文档、公共沟通中拒绝 “智能/意识/文明/物种” 等升格术语（**话语合法性层**）	参第十四章 §5 完整论证；本章附录 A 反应式有损映射（RLM）/统计语言投影器（SLP）术语体系

以下展开三条需要补充说明的原则（原则二、三、四）；原则六至八的完整论证见第十四章（§5、§6）与本章附录 A，母表并列呈现其落位，本章不复述。

强制不一致（对应优化动力学（L1））。损失趋平只代表当前训练条件下的改进有限，不证明模型已经学会，也不证明隐藏子空间没有任何约束。输出分歧可作为启动独立核验的提示，但不能单独证明隐藏子空间存在或估计其大小；分歧也可能来自采样噪声与实现差异。Yi 的外部验证器与 Gerstgrasser 的真实数据累积分别属于引入独立校验和保留独立信息源，与本原则互补，不直接等同于 '展示模型不一致'。

真校准（对应伪校准（L2））。对于预测式 AI，共形预测可在校准集与测试样本满足相应交换性条件时，将点预测转换为候选标签的预测集；在用户指定误差率 α 下，真实标签落入预测集的边际覆盖率具有有限样本保证。它不会自动给出 '恶性概率本身' 的区间估计，也不自动适用于每个子群体。若需表达概率估计的不确定性，应另用适配的校准与区间方法。示例中的 92.3% 只显示报告精度，不能单独称为极端确定性。该研究在单一模型中提取出可影响行为的情感概念表征；部分实验中，这些影响没有明显的情绪措辞，说明内部因果状态可以不转写为可见文本，而不是 '不携带信号'。它可作为输出端不可见内部状态的工程例证，但不能直接测量隐藏子空间大小或事实不确定性。机制追踪用于校准时，还须建立内部状态与误差或不确定性的对应关系。

打破递归（对应多映射递归（L3））。本原则指打断未经独立校准的读数继承与强化，不是禁止正常反馈或模型间协作。平台嵌入式部署需要检查行为数据的来源、推荐对行为的影响，以及用户调整或停止反馈的条件；仅增加延迟不会自动产生校准知识。多系统串联部署则需要在接口中保留来源、适用条件与不确定性，并在关键位置设置独立验证。人类介入只有在能够取得相关材料、有时间判断并有权纠正时，才可能成为有效校准节点；不能把形式上增加一次人工确认当成校准已经完成。

§8 研究纲领声明

本章以映射链结构（L0）、优化动力学（L1）、伪校准（L2）、多映射递归（L3）及叙事载荷乘积（L4）组织 AI 诊断。各层区分需要检查的问题，不是对每个系统已发生全部失灵的概括。孤立、平台嵌入式与多系统串联三个原型，帮助定位读数关系、人的位置与校准入口；具体机制及其后果不能由技术标签或部署名称单独决定。

框架的价值在于逐层追问的结构：每一层追问一个独立的问题，每一层对应一类独立的现象，每一层生成独立的工程原则。层数可调、维度可扩展。如果未来的研究者在四层递进结构之外发现了第五层独立的结构性缺陷，或在三种部署架构之外识别出第四种，那不是框架的失败——是框架被正确使用的标志。

但框架必须给出自己的可证伪条件：L0：在控制任务、各层信息保持、额外输入与参照观测者后，若链长变化与预注册代理指标没有系统关联，则首先修正链长指标与代理模型，不直接否证纤维概念[6]。L1：若在明确奖励与训练条件下，证据显示未覆盖维度受到可重复的有效约束，则 '不直接受目标信号约束' 的强版本受到限定；直接与间接约束分别记录。对齐悖论：只有在奖励构造仍不区分迎合与准确时，却仍能可靠区分二者，才构成证伪；若通过独立事实核验使该前提不再成立，则属于适用边界，而不是反例。[6]

[6]此处区分 Lakatos 意义上的 "硬核" 与 "保护带"：框架的硬核是 "映射有损 → 未决状态构成纤维 → 呈现可以超出证据" 这一概念骨架；"映射链长度 → 隐藏子空间大小" 的具体函数形式属保护带与开放问题，不是硬核；代理指标（分布外衰减、尾部差异、内部表征维度）属于保护带——它们可以被证伪、被替换，而不推翻硬核。反驳者论证 "代理指标选错了" 不等于论证 "隐藏子空间不存在"——前者是对当前度量方案的修正压力，后者才是对框架本身的足够挑战。这是框架当前接受代理指标风险的哲学根据。

这一诊断结构仍有四项未解决的问题：映射链长度与隐藏子空间大小的定量关系尚未建立；优化动力学（L1）与伪校准（L2）之间的反馈强度缺乏度量工具；多映射递归（L3）与叙事载荷乘积（L4）的组合效应需要与各自作用区分；级联、行为反馈、训练回流及生态独立性之间的比较，还需要统一而不抹平差异的操作指标。推荐算法作为技术类型与部署原型的不同用法，则须在每次分析中明确其所指，不能用类别名称替代机制。

对多映射递归（L3），可比较读数来源与不确定性是否被保留，以及独立校验介入前后的误差传递；对叙事载荷乘积（L4），可在任务与内容质量相近的条件下比较不同呈现对暂停、复核和外部查证的影响。研究组合效应时，还须区分反馈机制与界面机制的分别作用。相关检验需要足够的样本、效应区间与适用条件，不能将一次未显著的结果直接解释为机制不存在，也不能把控制感、使用时长或输出一致性单独当成校准能力的等价度量。

隐藏子空间的代理指标构造方案。“隐藏子空间的大小”是框架的核心变量，但它对指定观测者不可直接测量——如果某个维度对某观测者可被直接测量，它对该观测者就不再属于隐藏子空间；这一定义排除是观测者相对的，同一维度对不同观测者的可见/隐藏归属可以不同。以下三个代理指标不是隐藏子空间本身的度量，而是可操作的间接信号，这些局限限定了代理指标能够支持的结论范围。

代理指标	测量对象	操作化方式	局限
分布外性能衰减率	模型在训练分布外数据上的准确率下降速度	随分布偏移程度增大，测量性能下降曲线的斜率	只测了“对分布漂移的脆弱性”，不等于隐藏子空间本身
尾部群体表现差异	模型在少数群体与多数群体上的性能差	按预先声明的少数、多数及其他尾部群体分别计算同一任务指标，报告少数群体与多数群体之差（或最大—最小群体差）及置信区间；方差仅在专门定义为群体间离散度时另列，不与表现差距混用。	只捕捉了“可见子空间与隐藏子空间的差距”，不是隐藏子空间本身

代理指标	测量对象	操作化方式	局限
模型内部表征的有效维度	中间层表征的主成分分析	有效维度数/奇异值谱的衰减速度	只测了模型内部的压缩程度，不等于真实状态 T 的隐藏维度。须标注：该指标刻画样本表征的谱结构，与信息瓶颈所度量的互信息关注同一类压缩问题但不是同一个量；纤维框架追问的是——互信息保留的是“与输出相关的信息”，被丢弃的信息中是否包含对某些群体或某些场景至关重要的维度？信息瓶颈已经讨论针对给定任务应保留什么；纤维框架进一步追问由谁选择任务、哪些利益和后果未被该任务覆盖

§8.1 与邻近理论的对话：信息瓶颈理论

纤维框架的映射链结构（L0）——“信息在逐层处理中被有损压缩”——与 Tishby et al.（1999）提出的信息瓶颈理论（Information Bottleneck）共享一个数学基础：数据处理不等式（Data Processing Inequality）。两者都认为，信息一旦在映射中丢失，后续处理无法将其恢复。但两者存在三个关键差异，使纤维框架不是信息瓶颈理论的应用或重新包装，而是一个应用重点、价值判断和可计算性都有所不同的独立框架。

差异一：应用重点。信息瓶颈方法研究一般的任务相关信息压缩，并不限于单个模型内部的层间信息流；深度网络——其层间信息流与学习动态（Shwartz-Ziv & Tishby, 2017）——是其应用场景之一。纤维框架把分析重点放在多主体社会技术系统中从真实状态、传感器、模型、用户界面到用户决策的信息传递，以及相应的制度与认知条件。这是应用重点的区别，不是信息瓶颈方法原则上只能研究模型内部的边界。

差异二：价值判断。信息瓶颈通过任务变量及其联合分布规定哪些信息与目标有关，并分析保留相关信息与压缩输入之间的权衡——在适当条件下，丢弃与任务无关的信息可能有助于泛化；这一形式化不替代对任务选择本身的制度审计。被判定为 “无关” 而被丢弃的维度，可能包含尾部风险、少数群体的利益、跨制度周期的稳定性。“无关信息” 的判定者是损失函数的设计者，不是真实状态的全部利益相关方。信息瓶颈已经讨论针对给定任务应保留什么；纤维框架进一步追问由谁选择任务、哪些利益和后果未被该任务覆盖。

差异三：可计算性。信息瓶颈使用定义于指定概率模型上的互信息 $I(X;Z)$ 刻画压缩（其压缩表征变量本节统一记作 Z，以避免与本书表示真实状态的 T 混淆），其估计仍依赖数据、模型及估计方法。纤维框架用纤维 $\pi^{-1}(r)$ 的 “大小” 来度量不确定性，在许多开放社会技术场景中缺乏足够的状态空间、映

射与度量信息，因而目前难以直接计算——这正是框架当前的核心弱点，也是上述代理指标方案试图弥补的方向。这一限制不取消诊断价值，但约束了当前结论的精度——它与信息瓶颈的可计算性差异同源于两者分析对象的范围不同。框架的性质决定了它当前难以定量，而非不愿定量——当分析对象扩展到缺乏充分观测和约束的社会技术系统时，精确度量往往更困难，困难的程度取决于具体对象和证据条件，而不由“社会技术系统”这一类别本身决定；但诊断的必要性并未因此减弱。

两者的关系类似于经典力学与热力学——共享能量守恒，但分析对象和问题意识不同。信息瓶颈为分析任务相关压缩提供量化工具；纤维框架将这些问题与伪小纤维、伪校准及认知债务的制度诊断联系起来。这种联系不以把信息瓶颈限定于模型内部为前提，也不声称其数学工具不能用于多主体系统。

从信息瓶颈吸收的教训：尽管纤维框架与信息瓶颈在应用重点上有所不同，但后者的核心洞见——**最优压缩与任务相关**——可以为纤维框架提供重要的精细化维度。

信息瓶颈的目标函数 $\min_{p(z|x)} I(X;Z) - \beta I(Z;Y)$——此处以 Z 表示压缩表征，以避免与本书表示真实状态的 T 混淆——揭示了一个事实：一个映射过程丢弃哪些信息、保留哪些信息，取决于它被优化来预测的**任务变量** Y。在纤维框架的语言中，这意味着：- 一个系统的隐藏子空间 $\mathcal{T}_h$ 不是均匀的——它包含的信息中，有些对当前任务 Y 确实无关（在适当条件下，丢弃它们可能有助于泛化），有些对任务 Y'（未被优化的任务）至关重要（丢弃它们制造了隐藏风险）。- 因此，一个更精细的诊断不应止步于“映射有损，所以隐藏子空间大”，而应追问：**“这个映射过程为哪个任务 Y 优化了信息保持？对于其他可能的任务 Y'，它丢弃了哪些可能至关重要的信息？”**

这一追问将纤维框架的诊断从“所有映射都有损”的泛化层面，推向“特定映射对特定任务集的充分性”的精细化层面。V2.0 的推进方向之一是：为特定领域（如 AI 对齐）定义一组关键任务 Y'（例如：事实准确性、推理忠实性、价值观一致性），并开发度量系统在这些任务上信息保持程度的方法。这将使“隐藏子空间”从不可观测的概念逐渐逼近可度量的对象。

§8.2 框架的版本号与演进承诺

本章呈现的纤维框架 V1.0 是一个定性诊断工具。它的核心变量——隐藏子空间大小、伪校准程度、多映射递归强度——尚未完成操作化度量。V2.0 的演进方向包括：（1）为每个核心变量构造至少一个可观测的代理指标（上文已给出隐藏子空间的三个候选方向）；（2）在受控环境中检验映射结构、优化目标与伪校准之间的条件性关联（例如比较不同映射方案在相近任务与评价条件下的表现）；（3）将三个贯穿维度（政治经济学、物理基底、时间动力学）从定性维度升级为可量化的耦合关系。框架的当前价值不在于“已经被验证”，在于“已经足够清晰以至于可以被证伪”。上述代理指标的构造方案是将定性框架推向定量检验的第一步。本书第二版（预计 2027–2028 年）将就上述三个方向分别给出初步操作化工具。

三个贯穿维度——政治经济学、物理基底、时间动力学——横切四层递进结构（既不归属于任一单层，也不构成与四层并列的独立层；维度间彼此也不互相独立——本框架在此取的是分析视角的可分性，不主张其本体论上的正交）[7]。本章聚焦于递进结构和涌现层的技术展开；政治经济学维度（映射函数垄断、行为剩余的资本化、离散利维坦的三个阶段）见第十四章至第二十二章；物理基底维度（算力的物质约束、能源消耗、行星边界）见第三十二章；时间动力学维度（认知债务的积累与相变、三个时钟的赛跑）见第十五章（AI 的宏观认知债务记账框架（MCAF）动态校准）、第二十二章（金融认知债务治理史）与第三十一章（Agentic AI 的 MCAF 投影）。

[7]此处“横切”借自 Kiczales et al.（1997）面向方面编程（AOP）中的 cross-cutting 概念。该论文将其一般定义如下：

whenever two properties being programmed must compose differently and yet be coordinated, we say that they cross-cut each other (Kiczales et al., 1997)

译文：只要两个被编程的性质必须以不同方式合成、却又须协同，我们就说它们彼此横切。

并把横切性质归类为：

properties for which the implementation cannot be cleanly encapsulated in a generalized procedure (Kiczales et al., 1997)

译文：那些其实现无法在一个广义过程中得到干净封装的性质。

本框架在此借用其分析视角的可分性内涵——四层递进结构与三个贯穿维度各自有不同的合成规则但必须协同——舍弃其语言/工具实现层面的内涵。

本书的时钟维度首先指一种仅处理读数的操作模式，而非对所有部署状态的否定。对不接入外部记忆、在线训练或持久状态的主流基础模型推理实例，参数不随单次输入积累不可逆经历；对话历史、日志、外部记忆与参数更新属于部署层状态，须另行分析其持久性、可删除性与跨期影响。本章在该限定下使用‘没有时间深度’。

关于名称本身如何形成能力预期，见第十三章附录 A《命名审计——命名作为第一层伪校准》。

参考文献

Adams, E. (2013). *Fundamentals of Game Design* (3rd ed.). Berkeley, CA: New Riders.

Anthropic / Templeton, A. et al. (2024). Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet. *Transformer Circuits Thread*. https://transformer-circuits.pub/2024/scaling-monosemanticity/

Anthropic / Sofroniew, N. et al. (2026). Emotion Concepts and Their Function in a Large Language Model. *Transformer Circuits Thread*, April 2, 2026. https://transformer-circuits.pub/2026/emotions/index.html

Bachmann, G. & Nagarajan, V. (2024). The Pitfalls of Next-Token Prediction. In *Proceedings of the 41st International Conference on Machine Learning* (ICML 2024), PMLR 235. arXiv:2403.06963. https://arxiv.org/abs/2403.06963

Baumann, F. et al. (2026). Dynamics of Algorithmic Content Amplification on TikTok. *EPJ Data Science*, 15, 18. https://doi.org/10.1140/epjds/s13688-026-00629-2

Bereska, L. & Gavves, E. (2024). Mechanistic Interpretability for AI Safety: A Review. *Transactions on Machine Learning Research* (TMLR), September 2024. https://openreview.net/forum?id=ePUVetPKu6

Brin, S. & Page, L. (1998). The Anatomy of a Large-Scale Hypertextual Web Search Engine. *Computer Networks and ISDN Systems*, 30(1–7). https://doi.org/10.1016/S0169-7552(98)00110-X

Brignull, H. (2010). Dark Patterns. https://www.deceptive.design/ (原 darkpatterns.org)

Chaney, A. J. B., Stewart, B. M. & Engelhardt, B. E. (2018). How Algorithmic Confounding in Recommendation Systems Increases Homogeneity and Decreases Utility. In *Proceedings of the 12th ACM Conference on Recommender Systems* (RecSys 2018). ACM. https://doi.org/10.1145/3240323.3240370

Cheng, H.-T. et al. (2016). Wide & Deep Learning for Recommender Systems. In *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems* (DLRS 2016). ACM. https://doi.org/10.1145/2988450.2988454

Clarke, A. C. (1968). *2001: A Space Odyssey*. New York: New American Library.

Coelho Mollo, D. & Millière, R. (2026). The Vector Grounding Problem. *Philosophy and the Mind Sciences*, 7(1). https://doi.org/10.33735/phimisci.2026.12307

Collingridge, D. (1980). *The Social Control of Technology*. London: Frances Pinter.

Common Crawl Foundation. (2024). CC-MAIN-2024-38: Language Statistics. *Common Crawl*. https://commoncrawl.github.io/cc-crawl-statistics/plots/languages

Common Crawl Foundation. (2026). CC-MAIN-2026-39: Language Statistics. *Common Crawl*. https://commoncrawl.github.io/cc-crawl-statistics/plots/languages

Covington, P., Adams, J. & Sargin, E. (2016). Deep Neural Networks for YouTube Recommendations. In *Proceedings of the 10th ACM Conference on Recommender Systems* (RecSys 2016). ACM. https://doi.org/10.1145/2959100.2959190

Csikszentmihalyi, M. (1990). *Flow: The Psychology of Optimal Experience*. New York: Harper & Row.

Elhage, N. et al. (2022). Toy Models of Superposition. *Transformer Circuits Thread*. https://transformer-circuits.pub/2022/toy_model/index.html (also arXiv:2209.10652).

Fadeeva, E. et al. (2024). Fact-Checking the Output of Large Language Models via Token-Level Uncertainty Quantification. In *Findings of the Association for Computational Linguistics: ACL 2024*. https://doi.org/10.18653/v1/2024.findings-acl.558.

Farquhar, S. et al. (2024). Detecting Hallucinations in Large Language Models Using Semantic Entropy. *Nature*, 630(8017). https://doi.org/10.1038/s41586-024-07421-0

Frankfurt, H. G. (2005). *On Bullshit*. Princeton, NJ: Princeton University Press.

Gao, L. et al. (2023). Scaling Laws for Reward Model Overoptimization. In *Proceedings of the 40th International Conference on Machine Learning* (ICML 2023). PMLR. arXiv:2210.10760. https://arxiv.org/abs/2210.10760

Gerstgrasser, M. et al. (2024). Is Model Collapse Inevitable? Breaking the Curse of Recursion by Accumulating Real and Synthetic Data. In *Proceedings of the 1st Conference on Language Modeling* (COLM 2024). arXiv:2404.01413. https://arxiv.org/abs/2404.01413

Goertzel, B. & Pennachin, C. (Eds.) (2007). *Artificial General Intelligence*. Berlin: Springer.

Google. (2024, May 14). Generative AI in Search: Let Google Do the Searching for You. *Google Blog*. https://blog.google/products/search/generative-ai-google-search-may-2024/

Gray, C. M., Mildner, T. & Gairola, R. (2025). Getting Trapped in Amazon's "Iliad Flow": A Foundation for the Temporal Analysis of Dark Patterns. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems* (CHI '25). ACM. https://doi.org/10.1145/3706598.3713828.

Gurnee, W. & Tegmark, M. (2024). Language Models Represent Space and Time. In *Proceedings of the 12th International Conference on Learning Representations* (ICLR 2024). arXiv:2310.02207. https://arxiv.org/abs/2310.02207

Hacker News. (2025). ChatGPT Conversations Still Lack Timestamps After Years of Requests. *Hacker News*, December 26. https://news.ycombinator.com/item?id=46391472

He, X. et al. (2014). Practical Lessons from Predicting Clicks on Ads at Facebook. In *Proceedings of the 8th International Workshop on Data Mining for Online Advertising* (ADKDD 2014). ACM. https://doi.org/10.1145/2648584.2648589

Hicks, M. T., Humphries, J., & Slater, J. (2024). ChatGPT Is Bullshit. *Ethics and Information Technology*, 26(2), 38. https://doi.org/10.1007/s10676-024-09775-5

Hoffmann, J. et al. (2022). Training Compute-Optimal Large Language Models. In *Advances in Neural Information Processing Systems 35* (NeurIPS 2022). arXiv:2203.15556. https://arxiv.org/abs/2203.15556

Hohenstein, J. et al. (2016). Shorter Wait Times: The Effects of Various Loading Screens on Perceived Performance. In *CHI '16 Extended Abstracts on Human Factors in Computing Systems*. ACM. https://doi.org/10.1145/2851581.2892308

Hu, K. & Tong, A. (2024, November 11). OpenAI and Rivals Seek New Path to Smarter AI as Current Methods Hit Limitations. *Reuters*. https://www.reuters.com/technology/artificial-intelligence/openai-rivals-seek-new-path-smarter-ai-current-methods-hit-limitations-2024-11-11/

Isbister, K. (2016). *How Games Move Us: Emotion by Design*. Cambridge, MA: MIT Press.

Kiczales, G. et al. (1997). Aspect-Oriented Programming. In M. Akşit & S. Matsuoka (Eds.), *ECOOP'97 — Object-Oriented Programming* (LNCS 1241). Berlin: Springer. https://doi.org/10.1007/BFb0053381

Kohavi, R. et al. (2009). Controlled Experiments on the Web: A Survey and Practical Guide. *Data Mining and Knowledge Discovery*, 18(1). https://doi.org/10.1007/s10618-008-0114-1

Koren, Y., Bell, R. & Volinsky, C. (2009). Matrix Factorization Techniques for Recommender Systems. *Computer*, 42(8). https://doi.org/10.1109/MC.2009.263

Kramarzewski, A. & De Nucci, E. (2023). *Practical Game Design: A Modern and Comprehensive Guide to Video Game Design* (2nd ed.). Birmingham: Packt.

Kubrick, S. (Director). (1968). *2001: A Space Odyssey* [Film]. Metro-Goldwyn-Mayer.

Lakatos, I. (1970). Falsification and the Methodology of Scientific Research Programmes. In I. Lakatos & A. Musgrave (Eds.), *Criticism and the Growth of Knowledge*. Cambridge: Cambridge University Press.

Lawsen, A. (2025). The Illusion of the Illusion of Thinking: A Comment on Shojaee et al. (2025). arXiv:2506.09250. https://arxiv.org/abs/2506.09250 [预印本，尚未经同行评审]

Levi, N. I. (2025). A Simple Model of Inference Scaling Laws. In *Proceedings of the 42nd International Conference on Machine Learning* (ICML 2025). PMLR. arXiv:2410.16377. https://arxiv.org/abs/2410.16377

Li, J. et al. (2026). When Helpfulness Becomes Sycophancy: Sycophancy is a Boundary Failure Between Social Alignment and Epistemic Integrity in Large Language Models. arXiv:2605.05403. https://arxiv.org/abs/2605

.05403 [预印本，尚未经同行评审]

Linden, G., Smith, B. & York, J. (2003). Amazon.com Recommendations: Item-to-Item Collaborative Filtering. *IEEE Internet Computing*, 7(1). https://doi.org/10.1109/MIC.2003.1167344

Liu, Z. et al. (2022). Monolith: Real Time Recommendation System with Collisionless Embedding Table. In *Proceedings of the 5th Workshop on Online Recommender Systems and User Modeling* (ORSUM@ACM RecSys 2022). arXiv:2209.07663v2. https://arxiv.org/abs/2209.07663v2 [工作坊论文，所用副本为 arXiv 版]

Lukoff, K. et al. (2021). How the Design of YouTube Influences User Sense of Agency. In *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems* (CHI 2021). ACM. https://doi.org/10.1145/3411764.3445467

McDermott, D. (1976). Artificial Intelligence Meets Natural Stupidity. *SIGART Newsletter*, 57. https://doi.org/10.1145/1045339.1045340

Mudarisov, T. et al. (2025). Limitations of Normalization in Attention. In *Advances in Neural Information Processing Systems 38* (NeurIPS 2025). https://doi.org/10.52202/085713-3285

OpenAI Developer Community. (2023). Timestamps for Chats in ChatGPT. *OpenAI Developer Community*, March 15. https://community.openai.com/t/timestamps-for-chats-in-chatgpt/440107

Pavlick, E. (2023). Symbols and Grounding in Large Language Models. *Philosophical Transactions of the Royal Society A*, 381(2251), 20220041. https://doi.org/10.1098/rsta.2022.0041.

Perez, E. et al. (2023). Discovering Language Model Behaviors with Model-Written Evaluations. In *Findings of the Association for Computational Linguistics: ACL 2023*. https://doi.org/10.18653/v1/2023.findings-acl.847

Rendle, S. (2010). Factorization Machines. In *Proceedings of the 10th IEEE International Conference on Data Mining* (ICDM 2010). IEEE. https://doi.org/10.1109/ICDM.2010.127

Resnick, P. et al. (1994). GroupLens: An Open Architecture for Collaborative Filtering of Netnews. In *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work* (CSCW 1994). ACM. https://doi.org/10.1145/192844.192905

Richardson, M., Dominowska, E. & Ragno, R. (2007). Predicting Clicks: Estimating the Click-Through Rate for New Ads. In *Proceedings of the 16th International Conference on World Wide Web* (WWW 2007). ACM. https://doi.org/10.1145/1242572.1242643

Rutrecht, H. et al. (2021). Time Speeds Up During Flow States: A Study in Virtual Reality with the Video Game *Thumper*. *Timing & Time Perception*, 9(4). https://doi.org/10.1163/22134468-bja10033

Sarma, R. (2026). Agency and Architectural Limits: Why Optimization-Based Systems Cannot Be Norm-Responsive. arXiv:2602.23239. https://arxiv.org/abs/2602.23239 [预印本，尚未经同行评审]

Schell, J. (2019). *The Art of Game Design: A Book of Lenses* (3rd ed., Tenth Anniversary ed.). Boca Raton, FL: CRC Press.

Shapira, I., Benade, G. & Procaccia, A. D. (2026). How RLHF Amplifies Sycophancy. In *Proceedings of the 43rd International Conference on Machine Learning* (ICML 2026). arXiv:2602.01002. https://arxiv.org/abs/

2602.01002

Sharkey, L. et al. (2025). Open Problems in Mechanistic Interpretability. *Transactions on Machine Learning Research* (TMLR). https://openreview.net/forum?id=91H76m9Z94

Sharma, M. et al. (2024). Towards Understanding Sycophancy in Language Models. In *Proceedings of the 12th International Conference on Learning Representations* (ICLR 2024). https://arxiv.org/abs/2310.13548

Shojaee, P. et al. (2025). The Illusion of Thinking: Understanding the Strengths and Limitations of Reasoning Models via the Lens of Problem Complexity. In *Advances in Neural Information Processing Systems 38* (NeurIPS 2025). arXiv:2506.06941. https://arxiv.org/abs/2506.06941

Shumailov, I. et al. (2024). AI Models Collapse When Trained on Recursively Generated Data. *Nature*, 631. https://doi.org/10.1038/s41586-024-07566-y

Shwartz-Ziv, R. & Tishby, N. (2017). Opening the Black Box of Deep Neural Networks via Information. arXiv:1703.00810. https://arxiv.org/abs/1703.00810 [预印本, 尚未经同行评审]

Smith, M. S. (2026, April 13). 12 Graphs That Explain the State of AI in 2026. *IEEE Spectrum*. https://spectrum.ieee.org/state-of-ai-index-2026

Stanford HAI. (2026). *Artificial Intelligence Index Report 2026*. Stanford University Human-Centered Artificial Intelligence. https://hai.stanford.edu/ai-index/2026-ai-index-report

StartupHub. (2026). Ilya Sutskever's SSI: The $32B Bet on a Post-Scaling Future. *StartupHub.ai*, June 6, 2026. https://www.startuphub.ai/ai-news/ai-figures/2026/figure-ilya-sutskever-ssi-financial-breakdown-2026-06-06 （Sutskever NeurIPS 2024 演讲引语存档）

Steck, H. (2018). Calibrated Recommendations. In *Proceedings of the 12th ACM Conference on Recommender Systems* (RecSys 2018). ACM. https://doi.org/10.1145/3240323.3240372

TechCrunch / Heim, A. (2026). Yann LeCun's AMI Labs Raises $1.03B to Build World Models. *TechCrunch*, March 9, 2026. https://techcrunch.com/2026/03/09/yann-lecuns-ami-labs-raises-1-03-billion-to-build-world-models/

Tarantola, A. & Mannan, J. (2025). What Is Perplexity? Everything You Need to Know About the "Answer Machine." *Digital Trends*, October 31. https://www.digitaltrends.com/computing/perplexity-ai-everything-you-need-to-know/

Tishby, N., Pereira, F. C. & Bialek, W. (1999). The Information Bottleneck Method. In *Proceedings of the 37th Annual Allerton Conference on Communication, Control, and Computing*.（1999 年会议论文；作者电子版 arXiv:physics/0004057）https://arxiv.org/abs/physics/0004057

Togelius, J. (2018). *Playing Smart: On Games, Intelligence, and Artificial Intelligence*. Playful Thinking Series. Cambridge, MA: The MIT Press.

Togelius, J. (2024). *Artificial General Intelligence*. The MIT Press Essential Knowledge Series. Cambridge, MA: The MIT Press.

Xu, Q. et al. (2023). Does Conceptual Representation Require Embodiment? Insights From Large Language Models. arXiv:2305.19103. https://arxiv.org/abs/2305.19103 [预印本，尚未经同行评审]

Yi, B. et al. (2026). Escaping Model Collapse via Synthetic Data Verification: Near-Term Improvements and Long-Term Convergence. In *Proceedings of the 14th International Conference on Learning Representations* (ICLR 2026). arXiv:2510.16657. https://arxiv.org/abs/2510.16657

Yu, H., Kim, D. & Kim, Y. (2026). Retrieval Collapses When AI Pollutes the Web. In *Proceedings of the ACM Web Conference 2026* (WWW '26). arXiv:2602.16136. https://arxiv.org/abs/2602.16136. https://doi.org/10.1145/3774904.3792955.

Zhao, W. X. et al. (2026). A Survey of Large Language Models. *Frontiers of Computer Science*, 20(12), 2012627. https://doi.org/10.1007/s11704-026-60308-3（初版 arXiv:2303.18223，2023）

Zhou, G. et al. (2018). Deep Interest Network for Click-Through Rate Prediction. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (KDD 2018). ACM. https://doi.org/10.1145/3219819.3219823

Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.