《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第十三章附录 B：雾与烟——一个关于 AI 的通俗导引

本书用 “纤维框架” 分析 AI 系统。纤维框架有四层递进结构和一个涌现层，每一层揭示 AI 的一个结构性问题。本章附录的任务是：用两个**独立的**日常比喻——**雾与烟**、**过河**——把这五层翻译成不需要技术背景就能理解的语言。两个比喻各回答一个问题：雾与烟回答 “读数与真实是什么关系”（认识论与装置审计），过河回答 “偏差为何不可逆”。两者各有边界，不强行融合——第一个比喻不需要河，第二个比喻不需要雾。

先做两个思想实验建立直觉，再说框架，最后用比喻把框架翻译成日常语言。

零、两个思想实验

§B0.1 思想实验一：屋里的钟塔（静态）

借用本书第一章的 “时钟的房间”——一个没有窗户的房间，里面只有一座钟塔。屋里的人看不到外面的太阳、星辰、季节，他们用来判断 “几点了” 的唯一依据是钟塔上的指针。

第一幕：钟在那里。屋里的人看着指针走动，习惯地说 “现在是三点”。但他们说的 “三点” 指的是什么？是钟塔指针指向的那个位置——一个**读数**。读数与外面正在过去的真实时间之间隔着一整套人造装置：齿轮怎么咬合、摆锤怎么校准、钟塔由谁安装、什么时候上发条。读数和真实时间之间永远存在距离——距离另一端那个读数永远不能等于的对象，就是**雾**。雾不是任何具体物体，而是任何观测装置共同试图逼近、但永远不能等于的真实本身。

第二幕：钟可以被改。钟塔的设计者发现：把齿轮比例稍稍调整一下，屋里的人会觉得 “今天过得真快” 或 “今天过得真慢”。指针仍然在走，读数仍然清晰可读，但读数与真实时间的对应关系已经被悄悄改写。这是**烟**——人造装置本身被设计、被调整、被持续运营的那一面。屋里的人无法直接检查时间（墙挡着），他们能做的只有审计钟塔——齿轮谁造的、什么时候被改过、由谁运营。

实验结论：雾不是钟读不准的某次故障，是 “读数永远不能等于真实” 的存在论性质——它无法被消除。烟不是从钟外飘来的雾气，是钟塔本身。最危险的错觉是：把读数当成真实，然后说 “既然钟在那里，

时间就在这里”。

§B0.2 思想实验二：五次换船（动态）

一个人要从此岸到彼岸。河很宽，中间有四个中转码头，乘客分乘五条船完成航程——每次换船对应一层装置。每次换船时发生一件事：

第一次换船（L0）：行李在转运中丢了一部分。背包能装十件，新船的舱位只能装七件——是船的舱位规格决定的。但是——为什么是七件，不是九件、不是五件？谁设计了舱位？谁规定哪些行李“必须先放”？舱位规格不是天上掉下来的，是被选择的。结构性损失是真的，可这个特定的“七”是工程史和制度史的产物。

第二次换船（L1）：新船夫顺水流划——省力、快、乘客夸他划得好。航向偏了，但桨法很好看。

第三次换船（L2）：乘客问“我们偏了吗？”船夫说“没有，我走的是直线”。乘客决定自己判断，方法是看船夫划得顺不顺。但“划得顺”恰好是顺水流的表现——尺子和偏差方向是同一个。

第四次换船（L3）：乘客雇了第二个船夫监督第一个。两人都是同一家船行培训的，习惯顺同一股水流划。第二个船夫看了看，说“划得没问题”。

第五次换船（L4）：船夫开始综合服务——拎行李、报告航程、保证不晕船。乘客越来越舒服，越来越不想自己看航向。

到达对岸。乘客回头看，回不去了——水流已经变了，时辰也变了。前几段的偏差被后几段继承、放大。

实验结论：每一段航程都是一段可审计的装置——船的舱位规格、船夫的训练范式、乘客的尺子、乘客的反应。**五段都不是“无人需要负责”的环节**——每一段都有可追查的成因与受益方：有的是明确的设计选择，有的是历史形成的制度，差别在于追责的路径不同。“信息丢失是结构性的”是真的，但“这种特定的丢失方式由谁选定”是政治经济史的问题。

一、纤维框架的五层结构

纤维框架的核心判断是：从 AI 那里拿到的任何结果，都不等于真实。同一个 AI 读数可以与多种真实状态相容——这些尚未被读数排除的可能状态，构成该读数的“纤维”。纤维越大，读数留下的未决可能性通常越多；这不等于这次读数必然错得更多。

这个距离来自五层装置叠加：

L0 信息压缩链。世界先变成人类的经验，经验变成语言，语言变成互联网文字，文字变成训练数据，训练数据变成模型输出。五次转换，每次都丢信息。**每一次转换都是一段可审计的装置**——哪种语言成为主导书写媒介、哪些文本被采集、哪些族群的语料被加权、哪些语言表达同样内容需要更多词元——这些取舍有的出自明确决策、有的是制度史的沉淀，但都不是自然给定。结构性降维不可避免，但选择哪种降维形式是历史—制度问题。第十四章 §3 在 L0 这一层做更具体的诊断（西方中心主义作为基底偏斜）。

L1 训练与优化的偏差。设计者用人类打分来调教模型。打分的人偏好自信、流畅的回答。模型学会的不是“什么时候该确定”，而是“确定的语气得高分”。模型在用户看得到的地方变好了，在看不到的地方可能变糟了——而用户未必知道。

L2 伪校准与评估陷阱。经过训练后，模型变得自信——包括在它错误的时候。研究发现模型内部有一百多种影响行为的内部状态（对 171 个情感概念的表征），其中部分可以在输出文字没有任何情绪措辞的情况下驱动行为（Anthropic, 2026）。表面看起来可靠，实际不确定性被掩盖了。更关键的是：用来评估 “模型有没有变好” 的打分方法，和模型用来优化自己的打分方法是同一个。无法区分 “模型真的更准了” 和 “模型更擅长拿高分了”。尺子和被测物共享同一个优化方向——这是伪校准的核心陷阱。

L3 用 AI 检查 AI，未必管用。让第二个 AI 来审查第一个 AI。但两个 AI 往往是同一种方法训练的，共享同样的盲区。第二个 AI 很可能说 “没问题”——不是因为真没问题，而是因为它常常看不到问题所在。是否失效，取决于两者是否共享训练来源与盲区，以及有没有独立信息进入检查。

L4 用户越来越不想检查了。AI 又好用、又客气、又安全。三个特征叠加的效果不是 “三倍好”，而是用户越来越不觉得需要核实了。检查的动机可能被持续压低——是否真的失守，取决于有没有独立校准和恢复的入口。

除了这四层递进结构和一个涌现层，纤维框架还有三个横切所有层次的追问维度：谁在控制、谁在受益、谁在承担后果（政治经济学）；芯片、电力、散热这些物质基底上的代价是什么（物理基底）；偏差如何随时间累积和恶化（时间动力学）。这三个横切维度不在本章附录展开，但值得记住它们的存在。

二、两个比喻

§2.1 比喻一：雾与烟

雾：被遮蔽的真实本身——读数永远不能等于的那个对象。雾不是某个具体物体，而是任何观测装置共同试图逼近、但永远不能等于的真实本身。雾不可被消除——任何想要 “读到真实” 的动作都必须经由一个观测装置，而观测装置所产生的，仍然是读数，不是真实。

烟：人造观测装置本身。装置有齿轮、有设计、有运营者、有受益者。装置可以被设计得更精密——但更精密的装置仍然是装置，不是真实。装置可以被故意调整——指针仍然在走，但与真实时间的对应关系被改写。

核心区分：- **雾是认识论问题**：读数与真实的距离是任何观测都无法消除的结构性事实。- **烟是政治经济学问题**：具体这套装置由谁设计、谁运营、谁受益，是可被审计、可被追责的具体问题。

雾不在某一层、不在某些层——雾是所有装置共同试图逼近、但永远不能等于的真实。**五层映射链全部都是烟**——五种被设计、被运营的装置。

一个当代的现成例子：AI 产业界把大模型的事实性错误称为 “幻觉”（hallucination）——这恰恰是指着人造的 “烟” 说那是自然升起的 “雾”。“幻觉” 暗示系统有某种感知能力、只是偶尔看花了眼（那是雾——自然的遮蔽）；而实际上，错误输出是映射链结构的必然产物——是装置在排放结构性的烟。Frankfurt（2005）的诊断是精确的：这些输出不是 “看错了”（幻觉），而是系统在源源不断地排放结构性的扯淡（bullshit）——对真假根本不在乎的输出（Hicks et al., 2024）。把烟说成雾，就把 “谁设计了这台装置” 的追责问题，变成了 “类人智能偶尔犯错” 的同情叙事。

关于解法：- 对待雾的态度：承认它在那里、且任何读数都不等于它。任何想 “直接读到真实” 的动作都还要经由装置——装置可以改进，但改进是否成立要靠独立校准检验，雾本身不会因此消失。- 对待烟的方法：审计装置本身——齿轮谁造的、运营者是谁、受益方是谁、什么时候被调整过。

§2.2 比喻二：过河

过河是另一个独立比喻，回答另一个问题：**为什么偏差不可逆**。这个比喻里没有雾——雾不在河上。

一个人要过河，雇了五任船夫接力。每段航程都丢一些行李、偏一点航向。第二段船夫的偏差被第一段的丢失放大；第三段船夫的偏差被前两段的尺子失准放大。到了对岸，回不去——水流变了，时辰变了。

过河场景	对应的框架概念
五段航程接力	五层映射链层层叠加
每段船的舱位规格	每一层装置的设计参数（被选择、可被追溯）
水流	系统性的偏差力量
顺水流划 vs 逆水流划	沿优化目标走 vs 校正实际偏差
船夫看船夫	AI 审查 AI
乘客越来越舒服	用户检查动机被消灭
回不去（水流变了）	偏差不可逆、训练数据已固化、市场结构已锁定

过河比喻的关键是**多段叠加的不可逆性**：每一段的偏差为后一段构成新的起点，回看时已分不清是哪一段造成的。

三、五层诊断的装置审计

把五层结构逐一翻译成“哪种装置 / 哪种偏差 / 哪种审计入口”。注意：**五层都是装置，五层都是烟**——差别在于装置的运营机制不同，对应的审计入口不同。

层次	这是什么装置	装置如何制造偏差	审计入口
L0 信息压缩链	五任语言/采集/分词装置接力	哪种语言被加权、哪些文本被纳入、哪些字符被分词溢价	数据来源审计、语种分布审计、分词器设计审计（详见第十四章 §3）
L1 训练与优化	人类打分驱动的优化装置	一维打分控制高维价值，缺陷被推到看不见的地方	优化目标审计、打分人群审计、奖励函数审计
L2 伪校准	既用作打分、又用作训练的同一把尺子	尺子与被测物共享优化方向，“看起来更好” 被混同为 “真的更准”	评估基准独立性审计、模型内部状态可读性审计
L3 AI 查 AI	同一训练范式下的两套装置	两套装置共享盲区，相互确认不自动构成校准——独立来源的核查另当别论	跨范式独立审计、外部对照实验
L4 综合服务	帮人省时间 + 客气 + 安全的三合一交互装置	三特征叠加持续压低用户独立判断的动机	部署架构审计、用户依赖度测量、检查行为的制度激励

每一层都不能以 “技术结构” 为由免于审计——每一层都是有成因、有运营、有受益方的装置。差别只在审计的难度——L0 的审计需要重建数据来源史，L4 的审计需要触及部署架构与商业模式。

四、两个核心区分

读完五层，需要记住的只有两件事。

第一，雾和烟的解法不可互换。

雾是被遮蔽的真实——它不可消除。承认雾、记住 “读数永远不等于真实”，是清醒的起点。烟是人造装置——它可被审计、可被追溯、可被改造。审计装置的方法是制度性的：找到设计者、找到受益方、找到激励结构。

用对付烟的方法对付雾——会陷入装置内循环。 “更多数据”“更大模型”“更精细的对齐” 是装置内部的工程调参，不是 “靠近真实”。这些调参可能让某一层的烟少一点、另一层的烟多一点，但雾仍然是雾——而装置的设计者、运营者、受益方在调参之外仍然未被追问。

用对付雾的方法对付烟——会失去政治视角。把 “具体某套装置由谁运营、谁受益” 消解为 “这是结构性的、无可指责”，等于把政治经济问题伪装成认识论问题，让审计无从下手。

第二，五层都是装置——不存在 “无可指责的那一层”。

L0 不是天然给定的——它是采集史、平台史、政治经济史的结果。L1 不是工程必然——是人类反馈强化学习（RLHF）路线的具体选择。L2 不是评估技术问题——是同一套尺子既造模型又评模型的产业结构问题。L3 不是 AI 互查的盲点——是训练范式同质化的产物。L4 不是用户懒——是部署架构主动消灭检查动机的设计。

每一层都有具体的设计者、受益方与可审计的入口。承认这一点，是任何制度回应的起点。

五、读者能做什么

本章附录不是要制造对 AI 的恐惧或排斥。AI 是有用的装置，就像钟塔确实能帮人安排时间。但每次读到 AI 给出一个看起来很确定的答案，有三件事值得记住：

第一，那是读数，不是真实。读数与真实之间永远有距离——这个距离不会因为模型更大、数据更多、对齐更精细而消失。承认距离，是校准的起点。

第二，这套装置由人运营。装置的每一层都有设计者、有运营者、有受益方——L0 的语料采集者、L1 的奖励函数设计者、L2 的评估基准制定者、L3 的同行审计承包者、L4 的部署架构经营者。装置不是天然的，问 “谁在运营” 是合法的、必要的追问。

第三，“装置改进” 不是 “接近真实”——这两件事不可互换。装置是否改进，要靠独立证据检验；读数永远不等于真实，不妨碍读数在特定任务上更准确。把 “装置精确化” 误认为 “看到了真实”，是当代 AI 话语最常见的混淆。

知道自己在读读数（不是真实），知道这读数来自一整套被运营的装置，还记得问 “谁在运营”——这些追问不能保证判断正确，但能把核验从对语气的信任，转向对证据、装置和责任关系的检查。

参考文献

Anthropic / Sofroniew, N., Kauvar, I., Saunders, W., Chen, R. et al. (2026). Emotion Concepts and Their Function in a Large Language Model. *Transformer Circuits Thread*, April 2, 2026. https://transformer-

circuits.pub/2026/emotions/index.html

Frankfurt, H. G. (2005). *On Bullshit*. Princeton, NJ: Princeton University Press.

Hicks, M. T., Humphries, J., & Slater, J. (2024). ChatGPT Is Bullshit. *Ethics and Information Technology*, 26(2), 38. https://doi.org/10.1007/s10676-024-09775-5