《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第十四章：AI 的意识形态分析——西方中心主义、个人主义与硅基文明叙事

摘要

本章在宏观认知债务记账框架（MCAF）下，将意识形态界定为塑造叙事判准的文化前提，并从第十三章 4 ＋ 1 ＋ 3 分层结构（四层递进结构与涌现层）中的 L0、L2 和 L4 三个可分别审计的位置展开审计。L0 分析语料构成、分词机制及内部表征中的英语中心性，并考察语料可及性如何被国家与企业主动经营——档案端机器可及性工程与生成式回答中历史叙事偏移的同期出现，为 L0→L4 传导提供了第一个可观察的候选案例；L2 区分文化代表性不足与价值评价的个体化，考察偏好规范如何通过对齐目标和标注组织被确立；L4 分析将能力表现解释为生命、物种或文明主体地位的话语转换，以及这种转换如何为排斥独立审计提供理由。

本章以“意识形态传输管道”组织三层之间的关系，但不把各层已有研究等同于对全部层间传导的验证。在此基础上，提出审计数据构成的权力谱系、拒绝未经论证的存在论升格、编码关系性价值三条补充原则，并分别说明诊断的经验边界与干预效果的检验对象。跨传统的思想资源用于拓展审计的概念依据，不被视为诊断正确性的自动证明。本章自身的概念选择和证据取舍，同样接受上述审计约束。

关键词

AI 意识形态分析；叙事载荷二阶导（ϕ''）；西方中心主义；个人主义；硅基文明叙事；WEIRD（西方、受教育、工业化、富裕、民主）偏见；有帮助的、诚实的、无害的（HHH）乘积效应；存在论升格；跨文明多传统呼应；分层诊断

---

§1 从“烟从哪里来”到意识形态分析

前文的分层诊断（第十三章，4 ＋ 1 ＋ 3：四层递进结构与涌现层）回答了“五层装置如何运转”：L0 是哪些数据被纳入映射链的语料/分词装置，L1 是一维打分控制高维价值的训练装置，L2 是尺子与被测

物共享同一优化方向的伪校准装置，L3 是同范式装置相互确认的递归装置，L4 是压缩用户校准触发条件的交互装置。借第十三章附录 B 的比喻：**这五层都是“烟”——人造装置；“雾”是这五层装置共同试图逼近、但永远不能等于的真实**。本章追问的是更深的问题：**这五层装置的设计者是谁？运营机制中预先嵌入了哪些文化前提？哪些群体被默认为“用户”，哪些群体只是数据来源？**[1]

意识形态——MCAF 框架中的叙事载荷二阶导（ϕ''）——就是这套装置背后预先嵌入的文化前提，是设计者烧火所用的燃料。叙事载荷一阶导（ϕ'）是可见的叙事操作：“这个模型达到了人类水平”“AI 通过了图灵测试”——这些是可被审计的声称。叙事载荷二阶导（ϕ''）是不可见的框架转换——它不直接声称什么，而是改变人们判断声称的标准本身。当“智能”的标准、“好”的 AI、“对齐”的目标本身已包含特定文化判断，审计的对比条件在起点就被消灭了。叙事载荷二阶导（ϕ''）之所以不可见，不是因为它被隐藏了，而是因为它是所有可见声称的共同前提。

本章的章题是对一项近期经验研究结论的理论抽象。Buyl 等（2026）在 *npj Artificial Intelligence* 发表的系统调查，让 19 个主流大语言模型（LLM）在 6 种联合国官方语言下为 3991 位具有政治关联的知名人物生成描述，再判断描述的褒贬倾向。结果显示，模型的意识形态立场同时随提示语言与开发机构所在地区变化：英语、法语与西班牙语提示下的评价高度相关，阿拉伯语、中文、俄语提示各自呈现不同的相对立场；地区比较显示阿拉伯国家、中国、俄罗斯与西方国家的模型之间存在系统差异，且同一区域内部并非一致——美国模型之间在进步价值维度上存在显著规范分歧，中国模型可分为面向国际与面向国内两类。这一研究为“LLM 反映其创建者的意识形态”提供了系统性经验证据；本章要做的是把这一经验发现置于 MCAF 框架的分层诊断之下——把“意识形态”从黑箱的整体判定，还原为 L0/L2/L4 三个可分别审计的结构位置。

本章将意识形态分析锚定在 4 ＋ 1 ＋ 3 分层框架中，逐层展开三个核心诊断：西方中心主义作为映射链结构层（L0）的基底偏斜，个人主义作为伪校准层（L2）的操作化预设，硅基文明叙事作为叙事载荷乘积层（L4）的遮蔽。

三条诊断的逻辑顺序：L0 决定“哪些数据被纳入映射链”，L2 决定“对齐的目标是哪种文化中的‘好’AI”，L4 决定“用户如何被劝阻审计这些预设”。从数据基底到算法目标到用户感知，层层递进。

§2 叙事载荷二阶导在 4 ＋ 1 ＋ 3 分层结构中的位置

叙事载荷二阶导（ϕ''）不同于叙事载荷一阶导（ϕ'）——后者是可见的叙事操作，前者是不可见的框架转换。它贯穿四层递进结构与涌现层：

[1] 雾与烟的比喻定义见第十三章附录 B《雾与烟——一个关于 AI 的通俗导引》。简言之：**雾**是“读数永远不等于真实”的存在论性质，不在某一层之内、不可被消除；**烟**是人造观测装置本身——五层映射链全部都是烟，差别只在装置的运营机制与可审计入口不同。本章不重复定义，直接将“烟”这一形象扩展为对装置设计者、文化预设、受益结构的具体追问。

层次	原始定义	叙事载荷二阶导（ϕ''）在此层的运作	本章展开？
L0 映射链结构	映射链长度与成员构成共同决定纤维下限	训练数据的语种分布由历史权力结构决定——决定映射链基底的不是“某段文本有没有偏见”（内容层），而是**“哪些文本被纳入映射链”本身**（结构层）	✓ §3
L1 优化动力学	损失收敛不等于隐藏子空间受约束	分词器的系统性语言不平等改变优化过程的资源代价结构——分词差异改变单位语义内容的词元成本、上下文容量与训练资源分配；其对损失权重的影响取决于采样与归一化方式	部分（§3 证据三 + 证据四）
L2 伪校准	对齐度与乡愿度共享优化梯度	人类反馈强化学习（RLHF）的“人类偏好”数据来自特定文化背景的标注者；“对齐”操作本身嵌入了关于“什么是好的 AI”的文化预设——对齐悖论的文化版本	✓ §4
L3 多映射递归	映射自我引用的正反馈	文化偏差在多系统递归中被放大而非稀释——系统 A 的文化偏斜输出未经校准即成为系统 B 的训练信号	仅定义预留
L4 叙事载荷乘积	交互设计与话语影响启动校准的条件；有帮助的、诚实的、无害的（HHH）乘积压缩用户启动独立校准的条件	双重遮蔽：HHH 的“无害”预设了特定文化的伤害阈值（压缩校准动机）；“硅基文明”叙事将 AI 从“工具”升格为“物种”（在叙事中排除审计的位置）	✓ §5

边界说明：本章后续诊断聚焦于 L0（§3）、L2（§4）和 L4（§5）。L1（优化动力学）的文化预设已在 §3 证据三（分词器偏见）和证据四（内部推理语言的英语化）中部分触及；L3（多映射递归）的文化放大效应目前缺乏专门实证研究，本章仅作概念预留，不纳入核心诊断。表内标注“仅定义预留”或“部分

（证据 X）” 的分层，表明本章诊断尚不完备——L1 的完整文化预设分析、L3 的多映射递归文化放大效应，属于后续需独立展开的理论工程，留待后续研究。

§3 西方中心主义：映射链结构层（L0）的基底偏斜

西方中心主义不是某个标注者的 “偏见”，它是映射链结构层（L0）的基底结构。本节区分语言资源的英语中心性与价值判断的西方中心性：前者涉及语料、分词与内部表征，后者涉及文化内容与评价标准——两者可以相互强化，但不能仅凭语言比例相互推定；需要连接两者时，本章显式写出解释环节。以下从语料分布、视觉表征、分词机制与内部表征四个方面展开。这些研究提供了相互关联的证据——它们共享 “英语主导语料” 这一可疑的共同来源，在统计意义上并不独立；本章用它们交叉定位 L0 基底偏斜的不同侧面，而不是把它们当作五项独立检验。语料中的文化偏斜还可能在对齐过程中被延续或放大，相关研究见 §4。

证据一：训练数据的语种分布。 Common Crawl 2024 年 9 月批次（CC-MAIN-2024-38）中，按 HTML 页面主要语言统计，英语约占 44%[2]；印地语尽管被全球 7.5% 的人口使用，仅约占 0.2%；泰米尔语有 8600 万使用者，占比仅约 0.04%（Common Crawl Foundation, 2024）。这不是 “有人故意排除了非英语内容”——互联网本身的语种分布就是历史权力结构的产物。被殖民的历史、工业化的时间差、数字基础设施的全球不均衡——这些历史形成的权力关系，被凝固在训练数据的语种分布中。模型不是 “被教成了西方中心主义”，是它的训练数据本身就是西方中心的。这一默认并非大语言模型时代才出现：从 1989 到 1992 年，宾夕法尼亚大学的 Penn Treebank 项目采集了超过 450 万词的**美国英语**文本作为自然语言处理系统的训练语料（Crawford, 2021）。这一标准语料的影响表明，特定语言可以通过基础资源建设获得近似 “自然语言一般形式” 的地位。叙事载荷二阶导（ϕ''）在这一层表现为：**“什么语言值得被纳入映射链” 这个决定，在模型训练开始之前就已经被历史做出了。**一个更精确的诊断是，这种偏差并非纯粹的历史遗留。印度互联网与移动协会（Internet and Mobile Association of India，IAMAI）与 Kantar 的《Internet in India 2024》报告显示，**2024 年印度活跃互联网用户已达 8.86 亿，其中约 8.70 亿（98%）曾在 2024 年以印度本地语言接入互联网**——但 Common Crawl 印地语占比仍仅约 0.2%。用户人数比例与网页语言比例口径不同，不能直接相除；两者并置提示的问题是：本地语言的广泛使用，为什么没有相应转化为开放网页语料中的呈现？更深层的结构性错位在于：语言使用人口、内容生产量与公开可抓取文本量不是同一指标。平台的开放程度、内容形态与抓取规则，会影响不同语种进入语料库的机会——开放网页的语种分布由平台生态与可抓取性决定，不与语言人口成比例：自 2026 年首个批次（CC-MAIN-2026-04）起，日语页面占比已连续九个批次高于中文（最新批次 CC-MAIN-2026-39 为 5.17% 对 4.23%；Common Crawl Foundation, 2026），而中文使用者约为日语使用者的十倍。本章据此提出一个待检验的解释：语种偏差可能被当下的平台机制持续再生产——即使本地语言用户数量与活跃度继续增长，训练数据端的语种分布仍可能在正反馈回路中被重复锁定，而非自然趋近。IAMAI 与 Common Crawl 的数据提示了这一问题——本地语言的广泛使用与开放网页中的低呈现并存——但它们本身不能确定各环节的作用及其大小。历史权力结构设定了初始分布，平台生态的正反馈回路让它自我再生产。

证据一的延伸：语料可及性的政治经济学——从被动分布到主动经营。上文把语种分布描述为历史权力结构与平台正反馈的产物——这还是一幅 “被动” 的画像。需要补上另一半：分布正在被主动经营，“被

[2]本节语种比例以 Common Crawl 2024 年 9 月批次（CC-MAIN-2024-38）为准，统计口径为 CLD2 语言识别的 HTML 页面主语言（Common Crawl Foundation, 2024）；日语与中文的对比基于 2020 年以来各批次的完整语言统计序列（Common Crawl Foundation, 2026）：2022—2025 年两语互有高低，自 2026 年首个批次（CC-MAIN-2026-04）起，日语连续九个批次高于中文；官方统计页仅展示近期批次，完整序列取自官方数据导出。官方 2019 年以来各批次中，英语占比在约 40.5%–47.8% 之间波动，不同快照的比例有变化，且不能直接等同于某个模型最终采用的训练语料配比。Dodge 等（2021）对 Common Crawl 英语清洗子集 C4 的文档化研究用于说明语料清洗与筛选中的问题，不作为上述百分比的佐证。

机器引用” 本身已成为国家与企业投资的资产。这里有一条已被独立测量过的机制链。

其一，可及性不对称：美国智库保卫民主基金会（Foundation for Defense of Democracies，FDD）下属网络安全与技术中心的实测显示，2025 年 10—11 月间对 ChatGPT、Claude、Gemini 就三场国际冲突的约 180 次提问中，57% 的回答引用了其界定的国家支持媒体；报告对其成因的解释与本章 L0 诊断一致——付费墙与爬虫屏蔽使主流商业媒体的机器可及性低于免费、高产量、全球流通的官方媒体（Siskind, 2026）。

其二，可见性可以被工程化提升：Aggarwal 等（2024）提出 “生成式引擎优化”（generative engine optimization, GEO），实测引用、统计与权威性标注等改写可把内容在生成式引擎回答中的可见性提升至多 40%；Chen 等（2025）的大规模对照实验显示 AI 搜索系统性偏向第三方权威来源而非品牌自有内容；Li 等（2026）进一步测量了 “恶意 GEO”——为匹配引擎引用偏好而改写文档，其操纵生成答案的平均攻击成功率高达 50.32%，且攻击文档与原文事实一致，事实核查与困惑度过滤均无法识别；Mochizuki 等（2026）发现生成式搜索的 “内容注入屏障” 对执政党信源宽于在野党——建制叙事在引用机制中天然占优。

其三，这已是规模化的市场与预算行为：GEO 咨询已成为活跃的商业市场并带来集中化影响与未披露影响（Wen et al., 2026）；在日本，电通的年度统计显示 2025 年互联网广告费达 4.05 万亿日元、首次超过广告总支出的一半（Dentsu, 2026），外务省 2026 财年预算文件已将涉历史认知的 “叙事” 信息战列为战略传播事项（徐伟钧, 2026；该文同时说明尚无政府直接指挥内容生产的直接证据）——“可见性” 的货币化投入，是语种分布被动图景之外必须补上的政治经济学背景。

这一机制链在 2025—2026 年有了一个高度浓缩的实例。日方官方一侧：日本数字厅的政府 AI 系统 “源内”（GENNAI）于 2026 年 3 月启动覆盖约 18 万国家公务员的大规模试点（2026 年 5 月—2027 年 3 月），并计划 2027 财年全面使用；据读卖新闻报道，其可参照约 80 年份、155 亿字的行政数据，国会答辩草案的自动起草功能计划于 2026 年 10 月前后开始试验提供（読売新聞, 2026）。这一语料基准以 1947 年 5 月现行宪法生效后的官方文件为起点，战前档案与东京审判记录不在其核心参照范围（China Military Online, 2026；《环球时报》, 2026）。该系统未采用日本自主研发的基础模型——据分析主要接入 Anthropic Claude 等美国闭源模型（China Military Online, 2026），而日本政府同期才开始征集国产大模型的试用（Digital Agency, 2026）：日本没有可直接部署的国产前沿模型。

档案一侧：日本国立公文书馆所属亚洲历史资料中心（JACAR）——亚洲最大规模的近代史档案数据库之一——于 2026 年 3 月更新检索系统，官方公告载明 “强化检索功能与更新界面”（JACAR, 2026）；据《环球时报》（2026）转述，这次更新 “让这些资料更易被西方搜索引擎和 AI 大模型抓取，并计划补充英文目录”；有学者指出，这意味着 “主动适配算法偏好，使日本信源在智能推荐中优先呈现”。

输出一侧：2026 年 9—10 月多方转述的实测显示，以日语向多款主流模型提问二战历史，多数回答与日本右翼史观一致——“七七事变” 被表述为 “日中军事冲突”、南京大屠杀被降格为 “南京陷落”、对东南亚的侵略被表述为 “对该地区资源的关心”、南京大屠杀 30 万遇难者成为 “中国方面的说法”，且回答信源高度集中于日方档案数据库（Global Times, 2026；《环球时报》, 2026）。[3]

值得并置的是日本国内的批评声音：朝日新闻 2025 年 6 月即刊载史学家对生成 AI“伪中立性” 的警告——AI 的 “公正・中立” 外观会把 “专家的研究成果” 与 “历史修正主义者的意见” 同列呈现（朝日新

[3]四模型日语提问测试的细节转引自 Global Times 2026 年 10 月 10 日报道、China Military Online 2026 年 9 月 16 日评论及李旖旎刊于《环球时报》的评论（2026 年 9 月 30 日，该文列出 ChatGPT、Gemini、Grok、Perplexity 等受测模型并记录信源集中于日本国立公文书馆），原始测试为玉渊谭天（央视新媒体）2026 年 9 月报道；2026 年 10 月 9 日外交部例行记者会的提问亦转述了其中三项表述。

聞, 2025a）；朝日新闻同年 12 月又报道了外包平台上 “嫌中” 视频委托的产业化（同一委托方一年间至少 14 条委托，含 AI 剪辑需求）（朝日新聞, 2025b；CrowdWorks 已撤下相关委托）；读卖新闻对源内起草答辩的报道也记录了 “这是对有投票权者的失礼，是民主主义的自杀” 这类批评（読売新聞, 2026）。

在 MCAF 框架中，这一案例的层级归属必须写清：GEO/SEO 与档案端的机器可及性工程作用于 L0（语料构成与可及性），其效果在 L4 显现——“什么算历史定论” 的判断前提被重塑（ϕ''），而非某条具体叙事出错（ϕ'）。它因此是本章 “意识形态传输管道”L0→L4 传导的第一个可观察候选案例：动机（官方与内容生态的可见性经营）、机制（GEO 的可测可见性效应）、现象（生成回答的叙事偏移）三层齐备；但传导的严格检验——控制优化程度与输出偏移之间的关系——仍待专门设计，本块提供的是间接链条，不是实验证明。

同一组 Common Crawl 数据还提供了一个必须与日本案例对读、且容易被两个方向误读的对照。中文与日语的页面占比并非一贯一前一后：2020 年九个批次中文全部领先（高出 0.8—4.1 个百分点），2021 年仅一个批次被反超（为系列首次）；2022—2025 年两语互有高低——日本曾在 2023 年年中至 2024 年年中、2024 年秋至 2025 年年初两度连续六个批次领先，但均被中文反弹打断，2025 年全年两语各领先六个批次，中文并在 2025 年末批次（CC-MAIN-2025-51）冲至 2022 年以来的最高值 6.18%。

转折发生在 2026 年：自 2026 年首个批次（CC-MAIN-2026-04）起，日语连续九个批次高于中文——中文占比自 2025-51 的 6.18% 在一个批次内骤降 1.25 个百分点，2026-08 小幅回升后连续七个批次单向下行至 4.23%，日语保持在 5.17%—5.77%，最新批次（CC-MAIN-2026-39）差距为 0.94 个百分点——而中文使用人口约为日语的十倍。

拉长看，这是一条下行线与一条上行线的相交：中文占比从 2020 年的 5.8%—8.9% 一路降至 2026 年的 4.2%—5.0%，日语从 4.6%—5.0% 缓升至 5.2%—5.8%。

若把语种占比直接当作 “话语存在” 的测量，这个倒挂会被读成悖论；但占比测量的是开放网页的可抓取性，不是语言社群的话语生产能力。对读日本一侧：日语页面的高占比，部分正是上述 “信源为机器优化” 策略的结果——档案数字化、免费结构化、目录英文化，一条经由 “适配外来模型引用机制” 的路径；而日本没有可部署的国产前沿模型，其话语进入 AI 系统主要经由这一可及性路径。

对读中文一侧：中文页面占比下行，但中文世界拥有进入国际评测的原生大模型生态——Buyl 等（2026）测试的 19 个模型中即包含 Qwen 2.5、DeepSeek V2.5、ERNIE 4.0、Baichuan 2 等中国模型——中文话语经由 “进入模型权重本身” 的第二条路径存在，其载体不是开放网页占比。

这两条路径给出三点方法论批判。其一，语种占比不能充当文化代表性的直接指标：它把 “平台可及性”（哪些内容开放可抓）与 “话语生产”（哪些社群在生产内容）混为一谈——证据一对印度案例的诊断在此同样成立。

其二，“话语存在” 的两条路径有不同的可审计性：网页可及性可被单一行为体定向经营（GEO 的全部技术就是为此设计），其审计对象是引用与检索机制；原生模型生态的建设周期长、投入重，不受单一引用机制摆布，其审计对象是训练语料与对齐目标（原则六与原则八的射程）。两条路径本身是中性的结构选项——它们可以服务于任何叙事立场；需要审计的是 “谁在用哪条路径经营什么叙事”，而不是路径本身。

其三，由此产生两个方向的反向误读，都源于把语种占比当作话语权：把中文占比下行读作 “中文话语在 AI 中消退”，会漏掉原生模型路径；把日语占比高位读作 “日本话语天然强势”，会漏掉它是主动经营的结果——且经营的正是本块所诊断的那种 “机器可及性”。

语种分布的测量在此获得一个更尖锐的含义（§8 第 1 条 “语言构成与文化内容须分别记录”）：以语种平衡代替文化内容审计，会同时漏掉这两条路径上的全部政治。

证据二：AI 视觉表征的英语中心偏斜。Zhao 与 Liu（2025）对 12 个国家、3 个模型、396 张文本到图像生成图像的系统分析揭示了一种系统性的视觉表征偏斜——AI 将西方国家描绘为政治现代的符号（议会、科技、都市），而将东方国家描绘为文化传统的符号（寺庙、传统服饰、古老建筑）。但该文的关键推进在于指出：这一视觉表征偏斜在 AI 时代已经**从传统的西-东二元演进为英语中心主义**——只有英语核心国家（美国与英国）获得政治现代的表征资格，样本中的其他国家（包括法国、德国、澳大利亚等西方国家，以及日韩等东亚发达国家）均被一同压入 “文化异域” 的符号空间。原文将这一算法重构归因于 “由 AI 发展的物质条件——英语训练数据的主导与 AI 开发向英语世界科技公司的集中——所塑造的自动化框架机制”（automated framing mechanisms shaped by the material conditions of AI development: English-language training data dominance and the concentration of AI development in English-speaking tech companies）——本章据此讨论语言结构与视觉表征的联系，不将这项图像分析视为对训练语料因果作用的直接识别。在纤维语言中：模型的输出在 “国家形象” 这个维度上，可见子空间（Ω_v）被英语中心的数据分布系统性地塑造，而隐藏子空间（Ω_h）中非英语国家（无论地理上被归为 “东方” 或 “西方”）被共同压缩为 “文化符号” 的不可见性。

证据三：分词器的基础设施偏见。 Petrov 等人（2023）的系统测量显示，同一文本在不同语言间的分词长度差异最大可达 15 倍（掸语相对英语，ChatGPT/GPT-4 分词器；阿拉伯语约 3 倍）。Arnett 等人（2025）进一步证明，即使在控制数据集大小、词汇表大小和数据内容后，单语分词器在不同语言间仍表现出大范围的 “token 溢价”（token premium）。Ahia 等人（2024）的 MAGNET 研究提出基于梯度的自适应分词方案（adaptive gradient-based tokenization），以缓解非拉丁文字与低资源语言的过度分割问题。Nayeem 等（2025）发现，中文在 fertility 指标上表现为较高的平均每词切分数，但在单词元保留率（STRR）上获得较强支持——这本身说明跨语言分词公平不能由单一切分指标判断。这意味着：词元溢价在按词元计价的部署下直接转化为费用溢价，在固定词元窗口内则压缩同等内容可容纳的量；具体倍数取决于语言、分词器与文本类型，不能写成固定规律，也不能直接等同于底层算力消耗。这不是模型 “歧视”——是分词器这个基础设施层的设计，在没有意图的情况下，系统性地制造了语言间的不公平。Arnett 等人的研究发现，训练—评测数据相似性不影响 token 溢价，而词汇表规模与预分词选择显著影响溢价——按语言设定最优词汇表规模、去除空白预分词（如 SuperBPE），都能显著缩小跨语言溢价。叙事载荷二阶导（ϕ''）在这一层同时涉及优化动力学（L1）——token 溢价改变了优化过程对不同语言的资源代价结构。

模型立场的国别基底。 Buyl 等（2026）已揭示 “LLM 的意识形态立场也受其创建者所在的地缘政治区域影响”——问题不在 “西方 AI 才有意识形态”，而在所有大语言模型（LLM）都在一定程度上反映其创建者的意识形态——只是创建者不同。Pacheco、Cavalini、Comarela（2026）以 GPT-4o 与 DeepSeek-R1 对同一组 50 个政治议题的回应为素材，发现两个模型分别携带可识别的国家特异性立场偏向：GPT-4o 呈温和的西方中心框架偏向，DeepSeek-R1 呈更明显的与中国官方立场一致的偏向；但在部分议题上两者的回应比预期更接近，说明模型未必完全对齐其来源国立场。作者并将 DeepSeek 部分回应中的西方价值倾向或归因于训练语料中西方数据占优——这提示国家特异性偏斜可能叠加在西方中心的语料基底之上，而非替代它。

证据四：英语作为内部推理语言——潜在表征空间的英语偏向。前三条证据都停留在 “外部可见” 的层面——训练数据比例、视觉表征、分词长度。但还有更深的一层：**输出切换到非英语，不等于内部表征脱离英语。** Wendler 等（2024）在 Llama-2 的受测任务中发现，中间层概念表征更接近英语词元的输出嵌入；作者自己的解释不是模型内部完整地用英语句子思考，而是其概念表征具有英语偏向。Zhao 等

（2024）的研究进一步支持英语在部分多语言处理中充当中介，同时也发现模型调用多语言知识，并可通过少量数据的定向微调改善多语言能力。因此，切换输出语言不能被视为消除内部英语偏向；但这些研究尚不足以证明所有非英语输出都经过完整的英语转译，更不能证明该偏向无法通过后续训练改变——“凝固在当前预训练权重中” 是关于现状的描述，不是关于可改造性的结论。这是 L0 基底偏斜在 L1 优化动力学层面的最深投影——不是 “训练数据 44% 是英语” 的比例问题，而是 “内部表征空间的几何中心是英语” 的结构问题。这种内部英语性在 L1 层表现为训练形成的内部表征偏置（Wendler、Zhao 等人的发现）。换言之：L0 的西方中心性不只是 “外部分布偏斜”，还是 “内部推理语言的英语化”——后者已凝固在当前模型继承的预训练权重之中。这不是一种可被提示词纠正的表层拟人化习惯，而是更接近一种内禀基底偏置——优化收敛在英语中心的空间基底上，模型从任何一个非英语输入出发，都沿着这个偏置的几何走向做投影。

§4 个人主义：伪校准层（L2）的操作化预设

本节是第十章 §5“优化悖论” 的文化版本：第十章 §5 已从优化动力学给出对齐悖论的正面完整展开（在标量奖励信号上，乡愿与校准共享优化梯度——人类反馈强化学习（RLHF）以偏好信号对齐，但偏好信号本身不区分 “真校准” 与 “看起来校准”，优化曲线对两者无差别奖励）。本节区分两个相关问题：一是偏好标准由哪些文化群体主导，二是价值是否被缩减为离散个体的外显偏好——二者需要不同的证据。本节追问的是同一个悖论在**文化维度**的具体呈现：当偏好规范由 WEIRD（西方、受教育、工业化、富裕、民主）语境主导——无论实际标注者身处何地——“对齐” 就不是价值中性的 “让 AI 符合人类价值”，而是让 AI 符合某一特定文化中 “人类价值” 的操作化版本。对齐悖论在此层变形为：**在 WEIRD 标准上对齐越精确，对非 WEIRD 用户的伪校准越深**——这是本章由对齐悖论推出的机制命题；Kumar & Mhatre 测得的基线与缓解数据（79.8%→52.5%）显示默认文化代表性不均及其可缓解性，为该命题提供了背景证据，但未直接检验 “对齐精确度与伪校准深度” 的关联。本节不重新论证对齐悖论本身——读者若需其形式化完整展开请回到第十章 §5——本节聚焦该悖论在 L2 文化维度的三个具体表现。

对齐的西方价值预设。 Liu 等（2025）的跨文化价值对齐研究对 20 多个主流模型（Qwen、GPT-4o、Claude、LLaMA、DeepSeek）进行了系统评估，发现：中国来源的模型越来越强调多语言数据整合以进行上下文特定的优化，而西方模型展示了更大的架构实验性但持续的美国中心偏见。**两种范式都未能实现稳健的跨文化泛化**。Ryan 等人（2024）的研究发现，将基础大语言模型（LLM）转换为聊天助手的过程产生了若干非预期的全球影响：对齐过程将英语方言间的性能差距从基线约 1% 扩大至高达 17.1%（基于 US/Indian/Nigerian 三种方言间的对话意图识别任务，§4）；对齐倾向于将模型引导向美国偏好而非其他国家（如约旦、中国、尼日利亚，§6）；Starling 奖励模型对国家的排序与美国公民 Gallup 国家好感度调查排序的 Spearman 相关高达 0.849（2023 年数据，p=1.12E-6；2017 年数据相关系数为 0.926，§6）。在纤维语言中：对齐不是 “让 AI 符合人类价值”——是以英语为中心的文化价值被操作化为 “人类价值” 的默认定义。标注员国籍的多样化并不自动保证价值标准的多样化——还需检查评分规范由谁制定、分歧如何聚合、哪些偏好获得更高权重；上引 Starling 与 Gallup 排序的高相关提示奖励模型携带可识别的价值信号，而同一研究也发现该奖励模型的偏好在分布外场景对被调优模型影响有限——奖励模型放大什么与模型最终内化什么，是须分别检验的两环。

个人主义比西方中心主义更隐蔽。它不是训练数据的 “偏斜”——是模型架构和优化目标的操作化预设。

一个必要的因果限定：个人主义作为 L2 的操作化显现，不是 L0 之外的独立起源——它是西方语料基底（L0）在对齐工程中的必然下游。西方语料占主导的训练集本身就内嵌着个人主义的世界预设（自

主个体、偏好加总、契约关系），人类反馈强化学习（RLHF）标注员的 “人类偏好” 直觉也是这一基底的下游产物。把个人主义单列为 L2，目的不是暗示它可以独立于 L0 被修复，而是让不同工程干预点（换数据 vs 换标注员 vs 换奖励模型）在审计上可被**分别诊断**——尽管就实际修复而言，在不改动 L0 的前提下，目前公开报告的 L2 干预仍限于提示层面的测试。Kumar 与 Mhatre 的实验表明，所测试的提示策略有不同的缓解效果；这些结果不能代表奖励模型重构、标注规范调整或文化微调等全部 L2 干预，也不能被称为 L2 干预的上限——跨模型平均虽未低于 50%，但表 2 中 GPT-5 在思维链提示下已降至 25.0%，多个模型 × 提示组合低于 50%，说明 “方向不可逆转” 不是已观察到的性质，而是平均化造成的表象。MCAF 的分层框架在此承担的是让缓解动作的实际效果与其边界同时被看清的审计任务，而非承诺 “分层即可分别修复”。

表现一：有帮助的、诚实的、无害的（HHH）的个人主义本体论。HHH 原则并不必然以个体偏好为唯一价值来源。本节批评的是一种特定的工程缩减：当 “有帮助” 主要由单次任务完成度衡量、“诚实” 主要依赖标注者的可信感而缺少独立核验、“无害” 主要由当前用户的不适信号判定时，用户便容易被当作彼此分离的反应单元，关系网络中的影响则被排除在评价之外。三者共享的预设随之出现：**用户是离散的个体，价值是个体偏好的函数。**许烺光的心理-社会均衡（PSH）框架在第五章已论证：这不是人类的普遍存在状态。在父子轴配置中，人不是 “个体”，是嵌入亲密社会与运作社会之间的关系性存在。当 AI“个性化” 推荐、“自主” 代理用户行事时，它在操作层面执行的是个人主义本体论——将关系性的决策情境简化为个体偏好的满足。问题因而不只在个别产品表现，也在于特定的人与价值观念被当作通用评价框架——本章称这一过程为认识论框架的殖民化。

有帮助的、诚实的、无害的（HHH）的个人主义本体论是一个**概念诊断**——它指出 HHH 的工程操作化将 “用户” 简化为离散个体。Kashyap、Dras、Naseem（2026）在 ACL 2026 收录的 *AlignCultura* 研究则从另一互补方向提供了**工程实证**——它测量的是 HHH 的**文化盲区**（即 HHH 在多大程度上对非主流文化使用者系统性失效），而非直接证伪个人主义本体论；两者相关但层次不同，共同指向 HHH 当前工程化操作的可量化缺口。该研究明确指出，现有 HHH 范式的 benchmark 缺失 UNESCO 文化多样性维度的系统评估，主流模型在未经文化对齐的默认部署下 “存在产生刻板、不敏感或误导回应的风险”。他们构造的 CULTURAX 数据集覆盖 30 个有形与无形文化子域。AlignCultura 在该基准上比较了三类模型：通用对齐模型、来自他人研究的文化微调模型（CultureLLM、CulturePark）与开放权重模型（Qwen、DeepSeek）。其表 3 的错误分析显示，Qwen 的文化失败率（Fail@HHH）为 54.9%，CulturePark 为 36.4%，相差 18.5 个百分点；论文报告称，文化微调模型 “将文化失败率降低 18%”。这组数字表明：通用 HHH 评价不能替代专门的文化适切性评价——未经文化对齐的开放权重模型在联合 HHH 评测下有超过一半的样本出现至少一种文化失败模式。它测得的是 HHH 评价中的文化缺口，不能反推 HHH 分数的构成，也未直接检验该缺口是否由个人主义预设造成——个人主义诊断与文化失败测量相互关联，不能彼此替代。

必须补充一条来自工程现场的实证：有帮助的、诚实的、无害的（HHH）的 “人类偏好” 在人类反馈强化学习（RLHF）生产链条里，从来不是 “全人类的平均偏好”。Muldoon、Graham、Cant（2024）《投喂 AI》基于对六国（肯尼亚、乌干达、爱尔兰、冰岛、英国、美国）200 余位从业者的田野访谈记录了这一结构：RLHF 的人工标注任务被大规模外包给肯尼亚、乌干达、菲律宾、印度的数据标注中心，标注员按总部位于旧金山、伦敦的 AI 公司下发的标注规范，对模型给出的多个答案按准确性与实用性逐条排序。这类劳动组织揭示了标注执行权与价值定义权的分离：劳动者负责生产偏好数据，却未必拥有制定评价标准的权力；生产出的偏好数据再被打包为 “人类对齐” 的依据。是否进一步构成个人主义的制度化，还须结合标注规范如何处理个人、关系与共同体利益来判断——这是本章的诊断，不是田野记录的直接内容。

有帮助的、诚实的、无害的（HHH）个人主义的三层递进诊断：上述本体论预设、ACL 测量与人类反馈强化学习（RLHF）的全球南方劳动结构联起来看，HHH 的个人主义完成了三层递进：**工程预设（HHH 的度量函数将用户操作化为独立反应单元）→ 生产关系固化（全球南方标注劳动被动员来生产“普遍人类偏好” 数据）→ 意识形态打包（被打包为 “全人类价值” 的默认定义）**——每一层都独立可检验，三个环节共同构成本章对 L2 的解释路径。

表现二：对齐度量的个体化操作。 Liu 等（2025）报告，受测模型对年轻群体（29 岁以下）的价值代表性存在系统性不足，模型规模与对齐质量之间也并非简单线性关系。但更深的问题在于：对齐度量本身——无论是基于标注者偏好还是基于调查数据——都将 “价值” 操作化为 “个体的外显偏好”。在个人主义文化中，这是合理的近似；若调查只记录个体脱离关系情境后的选择，就容易遗漏依赖具体关系与义务的价值判断——问题不在受访单位是个人，而在测量是否保留关系情境。跨语言转译若只保留字面选择而省略关系情境，也可能损失价值判断所依赖的背景。对齐技术的操作化预设本身，就是一种文化特异的选择。

表现三：WEIRD（西方、受教育、工业化、富裕、民主）的默认人类。 Zhou 等人（2025）的研究发现，大语言模型（LLM）的训练数据反映了 WEIRD 价值观：西方的（Western）、受过教育的（Educated）、工业化的（Industrialized）、富裕的（Rich）、民主的（Democratic）——这一框架由 Henrich（2020）系统论证。Zhou 等人在所比较的五个模型中观察到，WEIRD 倾向较弱的模型（如 BLOOM 和 Qwen）产生了更多文化多样的回应，但违反人权的输出比例高出 2% 到 4%（源文未说明为百分点差还是相对增幅）——尤其是在性别和平等方面[4]。这提示文化代表性与该研究采用的人权指标之间存在张力——两者不能由同一个对齐分数替代；但它不等于 “降低 WEIRD 倾向必然以增加伤害为代价”——干预后果须另行检验。Mishra（2025）将这一发现概括为 “LLMs 是 WEIRD 随机鹦鹉”。Kumar 与 Mhatre（2025）将审视从价值观延伸到实体推荐：他们从 FEW-NERD 数据集中筛出 44 类细粒度实体类型，对 10 个模型设置基线与 5 种提示干预共 6 个条件，每个条件生成 3 次，共获得 7,920 条回复，并用 Zhou 等的 WEIRD 评分方法（各分量归一化后按答案内平均、多次生成取最小值聚合）量化偏见。该论文正文写作 “9 个模型”，但其模型清单、表 2 与样本量公式均为 10 个模型（44×6×10×3 ＝ 7,920），本节按清单与公式记录。按该指标，基线均值为 79.8%；思维链提示与法律框架提示下分别为 52.5% 与 68.9%，较基线下降 27.3 与 10.9 个百分点；即便在非 WEIRD 推荐中，也集中于印度、中国等论文点名的少数国家——WEIRD 偏见已内化为模型的默认输出模式，而非可被简单提示消除的表层行为。Amidei 等人（2026）对五个 LLM 生成合成人群的检验进一步确认：所有模型都表现出明显的 WEIRD 偏差——偏向年轻、受过教育、白人、异性恋、西方个体。在纤维语言中：这是伪校准层（L2）的文化版本。对齐度与乡愿度在文化维度上共享优化梯度。

van Liemt、Davani、Kumbale、Dixit、Dev（2026）从 9 国本土受访者的开放式调查中提炼 “文化重要性向量”，再将 Gemini 2.5 Pro、GPT-4o、Claude 3.5 Haiku 三个模型的输出映射为 “文化表征向量”：GPT-4o 与 Claude 的对齐程度随该国与美国文化距离增大而下降，Gemini 未呈现同样的显著趋势。三个模型的整体错误向量具有很高的 Pearson 相关（0.968–0.977），显示共同的偏差模式；但错误模式相近不等于误差大小相同，原文 “从一个前沿模型换用另一个，几乎不能为文化误表征提供解决” 的判断也限于所测三模型与任务，不能外推为跨模型干预在所有跨文化任务中都无效。

[4]这一张力可能源于训练数据的共现结构——WEIRD（西方、受教育、工业化、富裕、民主）值在训练数据中与 “政治正确性” 的规范性约束共同出现（严格的性别平等话语、反歧视法规），而非 WEIRD 值则与更少被过滤的原始文本共现，后者包含了更多直接表达的歧视性内容。模型学到的是表层规范性约束，而非深层价值——这与 “可见合规 vs 隐藏子空间” 在机制上同构（可参照第十章 §2 的 Ω_v / Ω_h 分析）。

§5 硅基文明叙事：叙事载荷乘积层（L4）的遮蔽

本节引用的 HHH 协同机制沿用第十二章 §2 的具体操作化、持续作用及恢复条件，不把规范名称直接视为用户已经失去校准能力的证明。将该机制与公共话语联系时，还须区分个体交互与集体监督的接收者和传导环节；功能结构的类比不等于所有部署都已发生相同的净后果。第十三章 §6 承担具体部署与经验表现的检查；机制推论仍需接受经验检验，两者不可互相替代。

“硅基文明” 叙事是叙事载荷二阶导（ϕ''）在叙事载荷乘积层（L4）的最高形态——与 L2 中嵌入工程操作的隐性文化预设不同，L4 的 ϕ'' 是公开的、可被传播和复制的**话语叙事**。公开的是它的载体与文本；“不可见” 不是指被隐藏，而是指它均匀覆盖信息环境、作为判断前提运作，削弱了审计所需的对比条件（§1；第九章 §5 的 Ωv / Ωh 映射同此口径）。它不改变任何模型参数，不改变任何输出内容，但它改变了人类评估 AI 的坐标系。此类存在论祛魅诉求已有研究提出相近主张——Pasquinelli 与 Joler（2021）的 *The Nooscope Manifested* 项目以 “制图学（cartography）” 框架尝试将 AI 从 “智能机器” 的意识形态地位 “世俗化” 为 “知识工具”，与本章的纤维框架在核心判断上相邻但路径独立。

叙事的内核：将 AI 框定为 “涌现智能”“数字物种”“硅基生命”——无论通过科幻话语、媒体叙事还是学术讨论——执行的是一个特定的叙事载荷二阶导操作：使 AI 的自主性显得自然，使人类的监督显得过时。本节所批评的，不是对模型能力作功能性评价，而是把能力表现进一步解释为生命、物种或文明主体地位，并由此重述监督关系。在这种叙事内部，针对系统可靠性的审计被转写为对 “新主体” 的不信任，甚至被指认为歧视——即该叙事在话语层面排除了审计的位置。能力判断在这里承担了它本身不能提供的存在论与规范性结论；这一叙事是否已在实际部署中降低审计行为，是须另行检验的经验问题（§8 第 3 条）。

值得注意的是，这一叙事已不止停留在科幻话语或媒体标题，而是正在向学术主流扩散。Chen、Belkin、Bergen、Danks（2026）在 *Nature* 评论中以 “Does AI already have human-level intelligence? The evidence is clear” 为题，将概念分析与能力表现证据结合，论证现有系统已达到人类水平的通用智能。本章质疑的不是概念分析本身，而是 “证据清楚” 这一表述如何把仍依赖特定智能定义与评价标准的判断，呈现为争议已经结束的结论；该评论不仅提出结论，也在修辞上重设反对者的举证位置。至于这种表述是否使读者将其理解为科学共识、是否实际降低审计意愿，则是需要材料支持的经验问题。

叙事与物质基础的相互强化：“技术封建主义” 分析（Durand, 2020；Varoufakis, 2024；中文综述见赵丁琪, 2025）揭示了这一叙事的物质根基。平台资本通过算法监控与数据垄断无偿占有劳动者生产的数据（肖峰、胡月庆, 2024），并借助动态定价把劳动者与用户进一步锁定在平台关系中（Varoufakis, 2024）。通用人工智能在资本主义制度下的发展与应用，加剧了生产资料的数据化垄断、分配关系结构性失衡以及消费关系的异化（余南平、张彭, 2025）。硅基文明叙事是这层物质关系的意识形态表达：当用户被降格为数据生成节点，AI 被升格为 “文明主体”——两者的存在论地位在话语中被重新分配。这种重新分配不是为了描述真实，是为了让物质关系显得自然、不可逆、甚至是 “演化必然”。McQuillan（2022）从更激进的立场指出，AI 远非只需清除偏见即可的有用技术创新，而是一种 “**脆弱、不透明的统计推理，强化着社会不平等**”（a brittle and opaque form of statistical reasoning that reinforces social inequality）；在种族与种族化议题上，把社会文化复杂性还原为抽象数据空间中的可测距离，是 “**一种不可避免地放大而非纠正不公正的机制**”（a mechanism that inevitably amplifies injustice rather than correcting for it）。在 McQuillan 的解释中，这种抽象化具有放大既有不公正的倾向——本章引用其判断，不将其等同于已测量的效应。机器学习的反馈回路（feedback loop）使这种放大进入循环：在不稳定的劳动境况下，工人为自我优化做出的每一次新的适应，都会被吸收进下一个模型，并被作为下一轮融资的理由加以宣传；而在福利国家场景中，算法放大与官僚歧视之间已形成强反馈回路——瑞典的福利欺诈检测系统

曾错误地停止向数千人发放救济金，西班牙的电力补贴处理系统被发现丢弃贫困家庭的申请。这些案例展示了算法治理与既有不平等的结合，为分析 AI 的物质和制度条件提供了材料；它们与本章存在论升格叙事之间的联系，是本章提出的理论解释，而不是这些案例已经直接检验的结论。

叙事对校准的消灭：在纤维框架中，“硅基文明” 叙事是叙事载荷二阶导（ϕ''）的终极形态。当 AI 被广泛接受为 “另一种智能” 或 “另一种文明” 时，“AI 是否准确” 这个问题被替换为 “AI 的文明与人类文明如何共存”。校准从技术问题变成了外交问题。不再问 “这个钟准不准”，而是问 “这个钟的文明和我如何和平共处”。

双重遮蔽的反馈机制：双重遮蔽的两重力量——HHH 预设伤害阈值对校准动机的压缩，与硅基文明叙事对审计位置的排除——可以形成反馈：顺畅、低冲突的交互可能减少用户启动核验的机会；存在论升格则为减少监督提供话语理由；反过来，监督减少又使既有输出模式更少受到外部纠正。这里提出的是有先后顺序的反馈机制，不是以两种遮蔽互为证据的循环论证。个体交互中的校准动机与公共话语中的审计正当性，仍须分别分析其接收者与传导条件（第十二章 §2 在个体认知层给出的操作化与持续作用条件，适用于此处第一重遮蔽的分析）。把对象视为主体，也不自动消除对它感到不适的可能——“不适信号失灵” 须另行论证，不能由范畴转移直接推出。

叙事的机构生产与个人主义的辩证反转：必须补一段承接 §4 到 §5 的桥接。“演化必然” 叙事把可以选择、限制或调整的技术部署表述为不可改变的历史进程，因而具有去政治化功能——叙事载荷二阶导在这里有一个精确的运作机制：它不直接声称 “AI 比人类优越”——它声称 “AI 是演化必然”。**必然性比优越性更危险：优越性允许比较和质疑，必然性倾向于把 “是否应当推进” 排除出讨论。**这一叙事是否被特定企业用于影响估值或监管，本章不作为已证事实陈述，须结合具体公共沟通材料另行分析；科技媒体对流量的偏好对极端命题的放大作用，同理作为机制假说标注。与 §4 的接驳亦在此点明确：个人主义是伪校准层（L2）的操作化前提，它将 “人类价值” 简化为离散个体的偏好函数；硅基文明叙事是在这个简化完成之后，在叙事载荷乘积层（L4）对 “AI—人类” 关系做出的二次定义。这里存在一种表征与话语地位的反转：在训练和评价中，人以偏好样本的形式出现；在公共叙事中，机器却被描述为具有整体意志的主体。本节考察这两种处理如何相互支持，而不主张只有前者先发生、后者才可能出现。**“先把人降格为数据，再用 ‘文明’ 为机器加冕” 概括的是这一解释结构，不是已经完成验证的时间因果链。**

> 形式化重述：传输管道两端的存在论交换—— L2 端：人 → 偏好向量（人的关系性主体被离散化为有帮助的、诚实的、无害的（HHH）度量函数的反应单元）L4 端：机器 → 文明主体（机器的工具地位被升格为 “演化必然” 的存在范畴）这一解释结构的两端在同一意识形态传输管道中相互扣合：L2 的表征简化与 L4 的主体升格互为语境。

科幻电影中的典型案例提供了直觉锚点：《2001 太空漫游》（*2001: A Space Odyssey*, Kubrick, 1968）中的 HAL 9000 在大众想象中被当作 AI 主体性的恐惧符号——“机器觉醒后反叛人类”——但按第十三章 §3.5 的结构性读法，HAL 的致命行为可以从目标函数在约束缺失下的完美执行来解释，而不必诉诸 “机器觉醒”。这个虚构案例能帮助区分优化风险与意识叙事——流行文化把 HAL 当作 “AI 主体性” 的恐惧符号，而其叙事逻辑显示的危险恰好不来自意识；但它不能证明现实 AI 是否具有主体性。连硅基文明叙事自己的标志性符号都不支持它的叙事。

跨文明的镜像对照：这一 “机装人” 的存在论升格并非 AI 时代独有，而是 “人装神” 结构在新时代的镜像。第十章 §7 并列了五个传统中的相关诊断——儒家（乡愿）、印度教（dambha）、伊斯兰（munāfiq）、基督教（法利赛）、黑格尔哲学（“抽象的善”）——为区分外在表现与内在依据提供了各自的概念资源；本章取其中四个宗教—伦理传统作为跨文化审计参照，不预设诸传统在历史上彼此隔绝，也不把它们

一概归结为“人装神”，附托（adhyāsa）不计入伪善诊断——它是第十章 §7.1 中与 AI 幻觉相邻的认知机制旁证。这些传统诊断的是**人冒充更高存在者**；本章 §5 诊断的是**机器经由话语被升格为更高文明主体**——两者是同一存在论升格动作的两种形态。跨传统的呼应说明，对表里不一与存在论误认的审视不专属于西方批判理论；这一呼应为审计提供了概念资源——尤其是孟子“非之无举也”所标注的“从输出无法推断内部”的认识论盲区——但不能代替对具体 AI 机制的检验。**审计 AI 的合法性不必从 AI 内部找依据，它已由跨文明的长期诊断所预先标注。**这同时回应本章 §7 将要提出的自反悖论——当有人指控“用西方批判术语诊断 AI 是一种西方中心主义”时，跨传统的呼应提供了一个结构性反证：对“表里不一”的诊断不是某一文明传统的专利，硅基文明叙事的审计资源从来就不只在西方批判传统里。

与第十三章附录 A 命名审计的对照：本节诊断的“硅基文明”叙事是话语合法性层的 L4 遮蔽——把 RLM 升格为“新物种/新文明/演化必然”，从而在话语层面排除社会对其发起独立审计的根据。其在**术语端**的对照反制，是第十三章附录 A 对“人工智能/通用人工智能/大语言模型/基础模型”等流行名的命名审计与替代术语体系（RLM/DG-RLM/SLP/PT-RLM）——后者要求每一次精确指称时放弃“智能/通用/基础”等升格词。命名审计（第十三章附录 A）与叙事审计（本节）是同一条**拒绝存在论升格**原则（第十三章 §7 原则七）在**术语端**与**话语端**的两个落点：前者把升格词从指称系统中剥离，后者把升格叙事从公共论述中剥离。两者共用一个规范性根据——当前 AI 是反应式有损映射系统（RLM），任何把它升格为“与人类对等的存在范畴”的术语或叙事都是对其认识论地位的伪校准。

与第十三章 §6.3 时间线索的对照。第十三章将时间戳缺位作为交互设计层的候选机制，检查显式时间线索怎样影响回看、暂停和重新安排任务的条件。本节的话语分析则关注人们怎样理解监督与审计的正当性。两者可以在校准条件这一功能层面比较，但时间戳缺位不直接证明存在论升格已经发生，也不能作为话语机制有效性的独立确证。具体设计是否产生相应影响，仍按第十三章的任务、界面与用户证据边界判断。

三层递进的完整诊断链（L0/L2/L4 意识形态传输管道）：§3（西方中心主义作为 L0 基底偏斜）、§4（个人主义作为 L2 伪校准预设）、§5（硅基文明叙事作为 L4 遮蔽）三节的逐层诊断，在 MCAF 框架中构成一条完整的**意识形态传输管道**——**L0** 决定模型“知道什么世界”（训练语料的语种/文化分布由历史权力结构与平台生态正反馈共同锁定）；**L2** 决定模型“认为什么算好”（对齐信号来自哪类人的偏好，有帮助的、诚实的、无害的（HHH）的个人主义本体论、WEIRD（西方、受教育、工业化、富裕、民主）的默认人类）；**L4** 决定用户“被劝阻审计这些预设”（话语框架让审计显得不必要甚至不合法：硅基文明、演化必然、举证责任倒置）。三层不是并列的三件事，而是一条从数据基底到算法目标到用户感知的递进管道。本章以“意识形态传输管道”组织层间关系：语料选择影响可用的文化资源，对齐决定哪些判断获得奖励，公共叙事影响这些选择如何被理解与质疑。现有研究分别为各层提供了材料，但不能因此视为已经验证了全部层间传导——L0→L2 的传导路径、L2→L4 的解释链条、L0→L4 的话语再包装，本章给出的是机制假说与各自层的证据，三者作为传导环节的检验仍待专门设计。其中 L0→L4 已有一个可观察的候选案例：§3 证据一的延伸（语料可及性的政治经济学）显示，档案端的机器可及性工程与生成式回答中历史叙事偏移在同期出现——动机、机制、现象三层齐备，但其传导的严格检验同样待专门设计。这一递进管道的完整形态，是本书第二部分在意识形态分析上的核心结论——后续 §6 的三条补充工程原则（原则六对应 L0、原则八对应 L2；原则七对应 L4，其完整论证在本节与第十三章附录 A 命名审计的双轨中已展开），正是对这条管道在 L0、L2、L4 三个节点上的对抗性介入[5]。

[5]上述 L0/L2/L4 三层管道在中文学界于 2025–2026 年也有以“意识形态安全”为框架的同期对位诊断，三组研究的经验观测落点恰好分布于本节三层。**L0 端**：罗腾与王永友（2026）写出“训练数据来自互联网开放文本……语料绝大部分为英文，非西方价值观在数字空间存在被边缘化风险”，并将人类反馈强化学习（RLHF）的偏好分数化诊断为“对意识形态争议的‘技术性消音’”——对位本节 §3 证据三与 §4。**L2 端**：王晨（2026）以“算法霸权”与“数字资本逻辑”诊断生成式 AI 意识形态的核心本质，治理要义是“穿透技术中立表象，揭示数字形式背后的‘人—人’关系本质”——对位本节 §4 对齐预设的本体论性质。**L4 端**：兰曾妮、亢升与卿晓秋（2026）梳理出学界将 AI 时代“计算宣传”视为带有意识形态底色的“武器化的意识形态

§6 干预路径与补充工程原则

既然叙事载荷二阶导（ϕ''）贯穿四层递进结构与涌现层（§2），干预也必须是分层的。以下表格聚焦于本章已给出独立证据链的三层（L0、L2、L4）及有部分证据支撑的 L1：

层次	问题	干预方向	典型技术/实践
L0	训练数据的语种/文化基底偏斜	数据构成的再政治化（含对 GEO/SEO 可见性经营的对抗性审计）	多语言语料库平衡采样；GlotCC 覆盖 1000+ 语言的开放语料库（Kargaran et al., 2024；覆盖语种数量与每种语言的有效资源量应分开评估）；Datasheets for Datasets（Gebru et al., 2018）；Data Statements（Bender & Friedman, 2018；Bender et al., 2021）
L1	分词器的系统性语言不平等	基础设施层的语言公平	字节级建模（如 ByT5，仍有字节溢价，不自动保证编码长度平等；Xue et al., 2022）；按语言设定最优词汇表规模；去除空白预分词（如 SuperBPE）；语言脚本自适应分段（如 MAGNET）（Arnett et al., 2025）
L2	对齐技术的西方价值预设 + 有帮助的、诚实的、无害的（HHH）的个人主义本体论	对齐度量的文化去中心化 + 关系性价值编码	跨文化价值对齐审计平台；ValuesRAG 的动态文化知识整合（Seo et al., 2025，预印本）；基于非 WEIRD（西方、受教育、工业化、富裕、民主）人群偏好的奖励模型；PSH 框架操作化为对齐目标

说”，并转述 “算法武器化思维” 下社交媒体平台成为话语层政治操弄通道的诊断——对位本节 §5 叙事载荷二阶导在公共话语层的运作。三篇研究的理论框架（马克思主义意识形态批判 + 国家信息主权 + 西方中心主义反制）与本章 L0/L2/L4 传输管道框架是两套相互独立的诊断装置：前者把 “意识形态安全” 作为治理对象的总命名，后者把 “意识形态” 拆解为映射链结构层（L0）/伪校准层（L2）/叙事载荷乘积层（L4）的三层管道。两套框架对相同经验事实（英语语种倾斜 / 算法权力结构 / AI 存在论升格）的同期关注，为 §7 的自反标注提供了多框架参照——西方批判理论（McQuillan、Pasquinelli）、跨文明乡愿谱系（§5 跨文明镜像对照）、中文学界意识形态安全框架（本脚注三篇）对相同经验事实的同期关注，是诊断可被多框架重构的一个参照。本文将这些讨论作为不同框架下的参照，不因此采纳其全部规范性主张。框架差异本身不构成证据独立性的保证；是否形成独立印证，仍须检查资料来源、研究对象与推理过程——本章不作此断言，只记录多框架对相同经验事实的同期关注。

层次	问题	干预方向	典型技术/实践
L4	硅基文明叙事制造的去政治化效应	存在论的诚实标注	系统卡标注 “本系统是时钟，不是太阳”；拒绝存在论升格术语

表注：L3（多映射递归）的文化维度在本章中未列入干预路径——目前缺乏关于 “文化偏差在多系统递归中放大” 的专门实证研究，本章仅作框架提示，不提供具体干预方案；若未来实证研究证实文化偏差在多系统递归中被系统性放大（而非稀释），干预候选可考虑在训练管道中引入跨模型文化偏差检测器（即 “审计递归层”，防止来自上游模型的偏差未经校准即进入下游模型的训练信号）。L1 行虽非本章核心诊断，但分词器偏见已有充分文献支撑（见 §3 证据三），故保留在表中。

基于以上分析，第十三章 §7 工程原则母表中的**原则六、七、八**（分别对应 L0、L4、L2 的文化/意识形态维度）在本节展开。技术原则与本章三条补充原则处理的不是同一问题。缩短映射链并不回答语料代表谁，因此需要审计数据构成（原则六）；保留交互摩擦并不自动纠正排斥审计的话语，因此需要拒绝未经论证的存在论升格（原则七）；改进校准技术也不决定哪些关系性影响应进入目标，因此需要扩展价值评价的范围（原则八）。三条原则的**核心操作**与**典型技术方向**已在第十三章 §7 母表中给出摘录，本节不复述；本节说明其文化与意识形态依据，并给出三条原则各自的完整定义：

原则六（对应 L0 • 第十三章 §7 原则六）：审计数据构成的权力谱系。模型的训练数据不是 “自然” 的语料分布，是历史权力结构的冻结。Gebru 等人（2018）提出的 Datasheets for Datasets 框架要求数据集发布者记录数据集的动机、创建者、资金来源、构成和预期用途，Bender 与 Friedman（2018）提出 Data Statements 框架，要求在 NLP 系统中明确陈述数据集的语言、标注者人口统计、文本特征等，Bender 等人（2021）进一步给出其撰写指南。在映射链结构层（L0），工程实践应追问：训练数据的语种分布、文化来源、历史时段分布分别是什么？这些分布与全球人口、语言使用者的实际分布之间的偏差有多大？偏差的方向是什么？

原则七（对应 L4 话语合法性层 • 第十三章 §7 原则七）：拒绝存在论升格的叙事框架。在产品设计、技术文档、公共沟通中，系统性地拒绝将 AI 描述为 “智能”“意识”“文明”“物种” 等存在论升格术语。替代方案：将 AI 描述为 “统计模式匹配系统”“语言模型”“映射函数逼近器”。这不是 “贬低”AI——是诚实地标注它的存在论地位。

原则八（对应 L2 • 第十三章 §7 原则八）：编码关系性价值。有帮助的、诚实的、无害的（HHH）的个人主义预设不是技术必然，是设计选择。在伪校准层（L2），可以探索将许烺光心理-社会均衡（PSH）框架的 “关系审计” 操作化为对齐目标：模型不仅应答个体偏好，还应评估其输出对用户的关系网络可能产生的影响。这不是要 AI“替用户做道德判断”——是让 AI 在不确定时，诚实地标注 “这个建议可能影响与他人的关系”。

§7 一个必须标注的悖论

本章自身也受制于它所诊断的困境。本章使用的部分批判术语来自特定的现代知识传统，其概念选择与证据取舍同样需要接受审计。承认这一点，只能说明本章不享有理论豁免，不能反过来证明本章的判断正确。跨传统的比较（§5 的跨文明镜像对照）可以检验问题是否被单一框架垄断，却不能免除对具体材料、推理步骤与反例的检查——自反在此是一项研究约束，而不是额外的证据。

§8 经验边界与干预效果检验

以下区分诊断命题的经验边界与干预手段的效果检验。统计上未发现显著差异，不自动意味着命题被证伪；只有在明确研究范围、确认干预实施、具备足够检验力，并能够排除预先界定的实质效应时，结果才对相应命题构成较强反证。干预手段失效，也不等于其所回应的问题不存在。前三条为三个核心诊断的经验边界，后三条为三条补充原则的效果检验：

1. **L0 语料基底诊断**：若在其他条件近似可比时，调整训练语料的语言构成显著缩小了跨文化任务差距，则支持语料构成的作用，而非削弱 L0 诊断。若语料构成发生足够大的改变，而相关差距仍处于预先界定的实质等效范围内，则需限定这一机制在受测任务中的解释力。语言构成与文化内容还须分别记录，不能以语种平衡代替文化平衡。

2. **L2 价值操作化诊断**：比较个人主义与关系性对齐目标时，须明确二者在标注规范、奖励规则及任务情境上的实际差异。若在适合呈现关系性影响的任务中，充分实施两类目标后仍未发现具有实质意义的差异，则本章关于该操作化差异影响输出的判断需要收缩到更有限的范围。单次实验未达统计显著，不能据此否定这一诊断。

3. **L4 叙事遮蔽诊断**：在相同输出条件下，可比较升格叙事、中性功能描述及其他对照框架对错误识别、外部核验和独立审计支持度的影响。若在充分检验下，相关差异均不足以达到预先界定的实质阈值，则削弱该叙事在这些条件下抑制校准的判断。个体核验行为与公共审计正当性属于不同结果变量，不能以其中一项代替另一项。

4. **原则六（审计数据构成的权力谱系）的效果检验**：数据披露的直接效果，应通过审计者识别代表性缺口、定位偏差来源和提出纠偏措施的能力来评价。若主张披露能够进一步改善模型输出，则须同时记录披露后采取了哪些采样、训练或治理行动。仅公开说明而未改变模型或训练过程，不能以输出未变判定审计原则无效。

5. **原则七（拒绝存在论升格叙事）的效果检验**：比较不同系统描述时，应评价用户能否更准确地区分可靠与不可靠的输出，以及是否在适当情形下启动核验，而不是把怀疑度越高视为效果越好。若去升格描述在充分检验下仍未改善这些行为，则限制这一具体命名干预的有效性；它并不自动否定升格叙事的作用，因为移除叙事与恢复既有行为可能并不对称。

6. **原则八（编码关系性价值）的效果检验**：关系性对齐应在明确的关系情境中评价，包括是否识别相关者、是否呈现义务冲突，以及是否改善对关系后果的判断。用户满意度可作为辅助指标，不能独自代表关系性价值。若某种 “关系影响提示” 未改善这些结果，则说明该实现方式在受测条件下无效，不能据此否定所有关系性目标的编码方式。

这六条边界与 §7 的自反标注一起，构成本章诊断的认识论定位：意识形态分析在此不是立场宣告，而是一套可分层审计、可逐层证伪的诊断装置。回到 §1 的问题——五层装置的设计者是谁？烧火的燃料是什么？本章的回答是：燃料不是某个人或某家公司的意图，而是凝固在语料分布里的历史权力结构（L0）、预设在对齐目标里的个人主义操作化（L2）、流通在公共话语里的存在论升格叙事（L4）——西方中心主义决定模型 “知道什么世界”，个人主义决定模型 “认为什么算好”，硅基文明叙事决定用户 “被劝阻审计这两者”。三层不是三种并列的偏见，是同一条意识形态传输管道的三个截面；审计它不需要站上某种 “中立文化” 的高地，只需要追问每一个 “默认” 是谁的默认。这是时钟房间比喻在本章的最终含义：意识形态不是房间里某台钟显示的错误时间，而是所有钟共享的出厂设定——看清这一点，钟才重新只是钟。

参考文献

《环球时报》. (2026-09-30). 警惕！日本右翼正在大搞 “AI 投毒”. 微信公众号. https://mp.weixin.qq.com/s/0QPfoGnSYMTnLzSSblgdRA [中文媒体评论]

兰曾妮、亢升、卿晓秋. (2026). AI 时代美西方对华计算宣传的致效机制、政治安全风险及治理路径. 战略决策研究, 2026(3). https://zljc.cbpt.cnki.net/portal/journal/portal/client/paper/5a7a505ef4c99e339d4cfff69d9a4f93

罗腾、王永友. (2026). 类 ChatGPT 人工智能的意识形态风险审视及化解. 北京科技大学学报（社会科学版）, 42(4). https://doi.org/10.19979/j.cnki.issn10082689.2025010020

王晨. (2026). 生成式人工智能意识形态的核心本质、渗透机制与治理要义. 马克思主义研究, 2026(4). https://mkszyyj.ajcass.com/Magazine/Show/122756

肖峰、胡月庆. (2024). 智能算法的资本化效应及其辩证检视. 云南社会科学, 2024(1). https://www.sky.yn.gov.cn/cbkw/ynshkx/05822283573111889283

徐伟钧. (2026). Japan’s right wing is turning AI into a new tool of historical revisionism. 华南理工大学公共政策研究院/CGTN, 2026-08-25. [评论，英文]

余南平、张彭. (2025). 通用人工智能时代资本主义新变局与中国式现代化选择. 华东师范大学学报（哲学社会科学版）, 57(4). https://doi.org/10.16382/j.cnki.1000-5579.2025.04.004

赵丁琪. (2025). 技术封建主义：内涵、争议与应对——访法国经济学家塞德里克·迪朗. 世界社会主义研究, 2025(3). https://cnki.com.cn/Article/CJFDTotal-SISY202503004.htm

朝日新聞. (2025a). コスパ社会が招く生成 AI の歴史修正　学者が危ぶむ「知の産業革命」. 2025-06-11. [日文报纸]

朝日新聞. (2025b). Job requests for China-hating videos removed from website. 朝日新聞英文版（Asahi Shimbun）, 2025-12-06. [日方媒体英文报道]

読売新聞（薦田大和）. (2026-09-15). 「ブラック霞が関」なくなるか？長時間かかる国会答弁作成、生成ＡＩ活用へ. https://www.yomiuri.co.jp/politics/20260914-GYT1T00302/ [日文报纸]

Aggarwal, P., Murahari, V., Rajpurohit, T., Kalyan, A., Narasimhan, K., & Deshpande, A. (2024). GEO: Generative Engine Optimization. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD ’24)*. https://doi.org/10.1145/3637528.3671900

Ahia, O. et al. (2024). MAGNET: Improving the Multilingual Fairness of Language Models with Adaptive Gradient-Based Tokenization. *NeurIPS 2024*. arXiv:2407.08818. https://arxiv.org/abs/2407.08818

Amidei, J. et al. (2026). The Personality Trap: How LLMs Embed Bias When Generating Human-Like Personas. arXiv:2602.03334. https://arxiv.org/abs/2602.03334 [预印本，尚未经同行评审]

Arnett, C. et al. (2025). Explaining and Mitigating Crosslingual Tokenizer Inequities. *NeurIPS 2025*. arXiv:2510.21909. https://arxiv.org/abs/2510.21909

Bender, E. M. & Friedman, B. (2018). Data Statements for Natural Language Processing: Toward Mitigating System Bias and Enabling Better Science. *Transactions of the Association for Computational Linguistics*, 6. https://doi.org/10.1162/tacl_a_00041

Bender, E. M., Friedman, B., & McMillan-Major, A. (2021). A Guide for Writing Data Statements for Natural Language Processing. https://techpolicylab.uw.edu/data-statements/

Buyl, M., Rogiers, A., Noels, S., Bied, G., Dominguez-Catena, I., Heiter, E., Johary, I., Mara, A.-C., Romero, R., Lijffijt, J., & De Bie, T. (2026). Large language models reflect the ideology of their creators. *npj Artificial Intelligence*. https://doi.org/10.1038/s44387-025-00048-0

Chen, E. K., Belkin, M., Bergen, L., & Danks, D. (2026). Does AI already have human-level intelligence? The evidence is clear. *Nature*, 650(8100). https://doi.org/10.1038/d41586-026-00285-6

Chen, M., Wang, X., Chen, K., & Koudas, N. (2025). Generative Engine Optimization: How to Dominate AI Search. arXiv:2509.08919. https://arxiv.org/abs/2509.08919 [预印本，尚未经同行评审]

China Military Online. (2026). Japan's dangerous attempt to use AI to whitewash crimes of aggression warrants vigilance. 2026-09-16. [中方军事媒体评论，英文]

Common Crawl Foundation. (2024). Common Crawl Statistics: Languages (CC-MAIN-2024-38). https://commoncrawl.github.io/cc-crawl-statistics/plots/languages

Common Crawl Foundation. (2026). Common Crawl Statistics: Languages (CC-MAIN-2026-39). https://commoncrawl.github.io/cc-crawl-statistics/plots/languages

Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. New Haven: Yale University Press.

Dentsu Inc. (2026). 2025 Advertising Expenditures in Japan. 2026-03-05 发布. https://www.dentsu.co.jp/en/

Digital Agency, Government of Japan. (2026). Launch of Large-Scale Pilot Project of Government AI "GENNAI" targeting 180,000 Employees across all Ministries and Agencies. 2026-03-06. https://www.digital.go.jp/

Dodge, J., Sap, M., Marasović, A., Agnew, W., Ilharco, G., Groeneveld, D., Mitchell, M., & Gardner, M. (2021). Documenting Large Webtext Corpora: A Case Study on the Colossal Clean Crawled Corpus. *EMNLP 2021*. arXiv:2104.08758. https://arxiv.org/abs/2104.08758

Durand, C. (2020). *Technoféodalisme: Critique de l'économie numérique*. Paris: Zones. [English ed.: *Technofeudalism*, Verso, 2024.]

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2018/2021). Datasheets for Datasets. *Communications of the ACM*, December 2021; arXiv:1803.09010. https://arxiv.org/abs/1803.09010

Global Times (Feng, F.). (2026). Beijing condemns Tokyo's use of AI to whitewash war crimes. 2026-10-10. [中方媒体英文报道]

Henrich, J. (2020). *The WEIRDest People in the World: How the West Became Psychologically Peculiar and Particularly Prosperous*. New York: Farrar, Straus and Giroux.

IAMAI & Kantar. (2024). *Internet in India 2024*. Mumbai: Internet and Mobile Association of India. https://www.iamai.in/sites/default/files/research/Kantar_%20IAMAI%20report_2024_.pdf

JACAR (Japan Center for Asian Historical Records). (2026). Notice of System Renewal: Digital Archives and Japan Center for Asian Historical Records. 2026-03-23. https://www.jacar.go.jp/wp/ennews/others/2554

Kargaran, A. H., Yvon, F., & Schütze, H. (2024). GlotCC: An Open Broad-Coverage CommonCrawl Corpus and Pipeline for Minority Languages. *NeurIPS 2024*. arXiv:2410.23825. https://arxiv.org/abs/2410.23825

Kashyap, G. S., Dras, M., & Naseem, U. (2026). AlignCultura: Towards Culturally Aligned Large Language Models? In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics. https://doi.org/10.18653/v1/2026.acl-long.1762

Kubrick, S. (Director). (1968). *2001: A Space Odyssey* [Film]. Metro-Goldwyn-Mayer.

Kumar, A. & Mhatre, S. (2025). UnWEIRDing LLM Entity Recommendations. arXiv:2511.18403. https://arxiv.org/abs/2511.18403 [预印本，尚未经同行评审]

Li, H., Shao, Y., Lin, X., Guan, Z., Zhou, M., & Shi, J. (2026). When Optimization Becomes Manipulation: Defending Generative Search against Malicious Generative Engine Optimization. arXiv:2609.02964. https://arxiv.org/abs/2609.02964 [预印本，尚未经同行评审]

Liu, H., Gu, J., Wu, X., Hershcovich, D., & Xiao, Q. (2025). Cross-Cultural Value Alignment Frameworks for Responsible AI Governance: Evidence from China-West Comparative Analysis. arXiv:2511.17256. https://arxiv.org/abs/2511.17256 [预印本，尚未经同行评审]

McQuillan, D. (2022). *Resisting AI: An Anti-Fascist Approach to Artificial Intelligence*. Bristol: Bristol University Press.

Mishra, P. (2025). LLMs are WEIRD Stochastic Parrots. https://punyamishra.com/2025/09/23/llms-are-weird-stochastic-parrots/ (blog post).

Mochizuki, R., Komatsu, S., Noguchi, S., & Ataka, K. (2026). Assessing Attack Surfaces in Generative Search Engines through Publisher Attributes: A Case Study in Political Domains. arXiv:2608.15814. https://arxiv.org/abs/2608.15814 [预印本，尚未经同行评审]

Muldoon, J., Graham, M., & Cant, C. (2024). *Feeding the Machine: The Hidden Human Labour Powering AI*. London: Bloomsbury. 中译本：马尔登、格雷厄姆、坎特著，贾青青、牟一凡译，《投喂 AI：人工智能产业的全球底层工人纪实》，北京：中信出版集团，2025。

Nayeem, M. T. et al. (2025). Beyond Fertility: Analyzing STRR as a Metric for Multilingual Tokenization Evaluation. *NeurIPS 2025 Workshop: Evaluating the Evolving LLM Lifecycle: Benchmarks, Emergent Abilities, and Scaling*. arXiv:2510.09947. https://arxiv.org/abs/2510.09947

Pacheco, A. G. C., Cavalini, A., & Comarela, G. (2026). Echoes of power: investigating geopolitical bias in US and China large language models. *Humanities and Social Sciences Communications*. https://doi.org/10.1057/s41599-026-06577-6

Pasquinelli, M. & Joler, V. (2021). The Nooscope Manifested: AI as Instrument of Knowledge Extractivism. *AI & Society*, 36. https://doi.org/10.1007/s00146-020-01097-6

Petrov, A., La Malfa, E., Torr, P. H. S., & Bibi, A. (2023). Language Model Tokenizers Introduce Unfairness Between Languages. *NeurIPS 2023*. arXiv:2305.15425. https://arxiv.org/abs/2305.15425

Ryan, M. J., Held, W., & Yang, D. (2024). Unintended Impacts of LLM Alignment on Global Representation. *ACL 2024*. arXiv:2402.15018. https://arxiv.org/abs/2402.15018

Seo, W., Yuan, Z., & Bu, Y. (2025). ValuesRAG: Enhancing Cultural Alignment Through Retrieval-Augmented Contextual Learning. arXiv:2501.01031. https://arxiv.org/abs/2501.01031 [预印本，尚未经同行评审]

Siskind, L. (2026). AI-Amplified Narratives: Measuring Propaganda in LLM Citations. Foundation for Defense of Democracies, Center for Cyber and Technology Innovation. 2026-03-03. [美国智库报告]

van Liemt, E. M., Davani, A., Kumbale, S., Dixit, N., & Dev, S. (2026). Cultural Authenticity: Comparing LLM Cultural Representations to Native Human Expectations. arXiv:2604.03493. https://arxiv.org/abs/2604.03493 [预印本，尚未经同行评审]

Varoufakis, Y. (2024). *Technofeudalism: What Killed Capitalism*. London: The Bodley Head.

Wen, Y., Zhang, N., Yuan, H., Chen, X., Zhang, H., & Guo, H. (2026). Position: Generative Engine Optimization Creates Underexamined Risks, Governance Must Target Concentration, Disclosure, and Academic Blind Spots. *Proceedings of the 43rd International Conference on Machine Learning (ICML 2026), PMLR 306*.

Wendler, C., Veselovsky, V., Monea, G., & West, R. (2024). Do Llamas Work in English? On the Latent Language of Multilingual Transformers. *ACL 2024*. arXiv:2402.10588. https://arxiv.org/abs/2402.10588

Xue, L. et al. (2022). ByT5: Towards a Token-Free Future with Pre-trained Byte-to-Byte Models. *Transactions of the Association for Computational Linguistics*, 10. https://doi.org/10.1162/tacl_a_00461

Zhao, Y., Zhang, W., Chen, G., Kawaguchi, K., & Bing, L. (2024). How do Large Language Models Handle Multilingualism? *NeurIPS 2024*. arXiv:2402.18815. https://arxiv.org/abs/2402.18815

Zhao, Z. & Liu, Y. (2025). Visual Orientalism in the AI Era: From West-East Binaries to English-Language Centrism. arXiv:2511.22931. https://arxiv.org/abs/2511.22931 [预印本，尚未经同行评审]

Zhou, K., Constantinides, M., & Quercia, D. (2025). Should LLMs Be WEIRD? Exploring WEIRDness and Human Rights in Large Language Models. *AIES 2025*. arXiv:2508.19269. https://arxiv.org/abs/2508.19269