《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第十五章：AI 的 MCAF 动态校准——投射端膨胀与防御端缺失的非对称诊断

摘要

本章完成宏观认知债务记账框架（Macro-Cognitive Accounting Framework，MCAF）在人工智能（AI）领域的动态校准——从静态结构诊断推进到动态累积动力学诊断。第十三章和第十四章分别揭示了 AI 系统的结构性缺陷与意识形态结构，本章回答前两章无法触及的动态问题：这些结构性缺陷在时间中累积了多少债务？投射端与防御端之间的速度差在扩大还是在缩小？什么时候会清算？本章以 Shumailov 等（2024, *Nature*）的受控模型坍塌研究为起点——无区别递归使用生成数据可在特定协议中导致分布退化；生成内容回流公共语料时，其现实范围仍取决于合成内容占比、筛选、真实数据保留与训练代际，AI 的解封存量（C）因此面临持续累积的压力，AI 的债务不是单纯的 “存量问题”，而可能表现为 “增量引擎”。在此前提上，本章给出三个只有在 MCAF 框架内才能说出的结构性诊断：（1）AI 的影子债务（D_c^{shadow}）缺乏金融系统中 “底层资产违约—保证金追缴—评级下调” 这一内生显现链，隐匿阶段缺少制度化显现机制的约束，其持续时间高度不确定。即使防御端加速，AI 仍缺少使影子债务自动显现的制度化内生通道。（2）三时钟关系表明，在当前制度与技术条件持续成立时，防御端面临长期滞后压力——技术资本时钟（τ_c）的特征周期以月为单位，治理时钟（τ_g）以年为单位响应，债务时钟（τ_d）尚无稳定估计；AI 治理尚未形成金融系统危机模式下那种稳定的紧急压缩能力。（3）个人层面无法建立对算法谄媚的制度性制衡——一个认知系统不能同时作为自身的独立监督者，实例化上的这一不对称意味着 “用户教育” 不能替代制度设计；国家能以独立机构制衡权力，个体无法在自身认知系统内部实例化独立监察机构。三个诊断共同指向一个结论：AI 的影子债务可能比金融的影子债务更难追踪、更难清算，其债务动力学与金融有结构性差异，而我们尚未发展出匹配这种差异的审计工具。本章的贡献不是 “解决” 这个结构性困境，而是诚实地标注它——让不可见的债务累积变得可见，是 MCAF 框架在 AI 领域能做的最基本的工作。

关键词

宏观认知债务记账框架（MCAF）；认知债务；影子债务；三时钟；解封存量；治理时钟；技术资本时钟；制度性不对称；算法谄媚；本地文件审计

§1 引言

第十三章从静态结构的角度完成了纤维框架对 AI 的 “4+1” 诊断——四层递进结构：映射链有多长（L0），优化在哪里无约束（L1），确定的外观是否掩盖了不确定的实质（L2），多个映射系统相互引用时发生什么（L3）；以及作为涌现层的叙事载荷乘积（L4）。第十四章进一步展开了 L4 话语合法性层的意识形态结构——西方中心主义、个人主义、硅基文明叙事。但静态诊断不能回答三个动态问题：这些结构性缺陷在时间中累积了多少债务？投射端和防御端之间的速度差是在缩小还是在扩大？什么时候会清算？

本章用宏观认知债务记账框架（MCAF）回答这三个问题。§2 给出 AI 行业的背景事实，并将 AI 与金融在债务结构上的三个根本差异作为本章诊断的经验前提——其中 “无区别递归使用生成数据会导致分布退化” 由 Shumailov 等（2024）的受控模型坍塌研究锚定；本章进一步讨论生成内容回流公共语料时，须把合成内容占比、筛选、真实数据保留与训练代际作为待查条件，不把受控结果直接当成整个训练生态已完成不可逆退化的事实。在此前提上，§3-§5 依次展开三个只有在 MCAF 框架内才能说出的结构性诊断：影子债务为何缺少制度化的内生显现链（§3）、三时钟关系为何使防御端在当前条件下长期滞后（§4）、个人层面为何无法建立对算法谄媚的制度性制衡（§5）。§6 给出这些框架推断的可证伪条件，§7 总结。

§2 背景事实

在展开诊断之前，先给出 AI 行业的背景事实。这些事实的梳理，不使用宏观认知债务记账框架（MCAF）变量。

模型迭代正在加速。 Stanford HAI 2026 AI Index 显示，2025 年工业界生产了超过 90% 的前沿（notable frontier）模型。OpenAI、Anthropic、Google、DeepSeek、Qwen——每个系列都在数月内迭代。同一报告显示，生成式 AI 在三年内达到 53% 的人口层面采用率，扩散速度超过 PC 与互联网的历史节奏；组织采用率升至 88%（源自该报告援引的 McKinsey 2025 年全球 AI 调查，“采用” 指所在组织在至少一个业务职能中使用 AI）。当信息环境中替代性通道被系统性地压缩时，“不使用 AI” 从一个可选的退出变成了需要主动抵抗的反默认行为。

监管响应正在追赶，但速度差仍然显著。欧盟 AI 法案从 2021 年提案到 2024 年生效，历时约 3 年。中国生成式 AI 管理办法 2023 年发布（国家互联网信息办公室等, 2023），历时约 6 个月。美国联邦层面无综合性 AI 法律，主要依赖行政命令和现有机构执法。各法域的治理时钟从 6 个月到 3 年到更长不等。

事故正在增长。 Stanford HAI 2026 AI Index 记录了 AI 事故从 2024 年的 233 起增至 2025 年的 362 起，年增长率约 55%。但这仅是已被记录的事故——元审计能力（A）的长期衰减、独立校准行为被无摩擦界面系统性替代、制度信任侵蚀——这些慢性的、弥散的债务累积，不在任何事故统计中。AI 尚未经历 “雷曼时刻”。

AI 与金融在债务结构上存在三个根本差异。第一，模型输出可能回流为后续训练数据，形成训练数据的自我再生产。Shumailov 等（2024）表明，在无区别递归使用生成数据的特定协议中，输出多样性和准确性会随迭代下降，分布尾部信息可能不可逆丢失；现实训练生态中的范围仍取决于合成内容比例、筛选与真实数据保留。金融信贷存量会在泡沫破裂后收缩；未经上述校准的递归训练则可能持续累积退

化压力。这一对比不意味着一切 AI 数据污染都不可缓解。第二，AI 的叙事载荷是二阶导的——不是具体的虚假论断，而是定义 “什么算合理叙事” 的元规则。硅基文明叙事将 AI 从 “工具” 升格为 “文明主体”，在话语层面消灭了人类审计的合法性。金融的叙事主要是一阶的——表现为具体的、可被审计的叙事（“房价永远上涨”）。一阶叙事可以被事实反驳，二阶叙事定义了 “什么是事实”（第十四章 §3-§4 已详细论证）。第三，金融的合法性基座经过数百年演化已相对稳定——存款保险、央行最后贷款人、破产法构成了制度化的赔付环。AI 目前没有制度化的赔付环——存在零散的产品责任救济与个案诉讼，但不存在与存款保险、最后贷款人、破产法对应的、规模化且自动触发的赔付/清算机制。当 AI Agent 的行为导致损失时，损失分摊路径要么依赖个案司法，要么直接冲击最终用户。这不是 “产品不够好” 的问题，是 “出了事没有规则处理” 的问题。

以下三个诊断是只有在宏观认知债务记账框架（MCAF）下才能说出的结构性洞见。每一个都满足检验标准：如果去掉 MCAF 变量，这段话还能得出同样的判断吗？如果不能，才是框架在做真正的工作。

§3 诊断一：影子债务——为什么隐匿阶段缺少制度性约束

宏观认知债务记账框架（MCAF）中的影子债务（D_c^{shadow}）定义为真实认知债务与可观测认知债务之间的差距。金融系统中，影子债务最终通过底层资产违约、评级下调、保证金追缴被强制显现。AI 系统中，这类金融式强制显现机制尚未形成。第三章 §4.2 命名的显现函数 $M(\tau)$ 标记影子债务显现时的场景内形态转换；AI 领域缺少的不是显现过程，而是使显现自动发生的制度化内生链条——下文展开的三个条件正是这条链的组成。

这不是一个经验观察——“AI 目前还没有经历过大规模事故触发清算”——而是一个结构性判断。金融的影子债务之所以能被强制显现，依赖于三个条件的同时成立。第一，底层资产存在——抵押贷款支持证券（Mortgage-Backed Securities，MBS）底层是房贷，房贷底层是借款人的还款能力。当房价下跌时，违约率上升，这是物理因果链，不可被叙事掩盖。第二，保证金制度存在——当资产价格跌破阈值，追加保证金通知自动发出，不依赖于任何人的判断。第三，评级机构存在——它们虽然充满利益冲突，但至少在形式上提供了独立于发行方的风险评估。当评级下调时，机构的投资组合被迫调整，影子债务的一部分被强制转化为可观测损失。

AI 目前没有这三个条件中的任何一个。没有底层资产——模型的 “幻觉率” 上升不会自动触发任何人的保证金追缴。推荐算法的 “信息茧房” 不会导致任何机构的评级下调。注意力碎片化和判断力退化是真实的损失，但它们没有自动生成价格信号、追加机制或具有强制效力的外部审计。它们是弥散的、慢性的、难以归因的，因而缺少一个由制度自动确认的清算时刻。

这一缺口在外部可观察的指标上留下了痕迹：物理共现场所（办公楼、沿街商铺）持续让位于线上平台之后，被释放的注意力并未自动转化为独立判断能力，而是在投射端（$\Lambda \cdot \phi$）的乘积通道中以更碎片化的形态被重新捕获[1]——这一形态的量化仍缺乏直接指标；本节仅将空置率作为多因一果的外部参考指标，并不以之建立单一因果链。

这揭示了 AI 影子债务的核心特征：隐匿阶段缺少制度化显现机制的约束，其持续时间因而具有高度不确定性。金融的影子债务可以在暗处积累数年——2003 年至 2007 年的次贷累积——但最终会被底层资

[1]基础前提是第七章已确立的约束——个体有意识处理的信息吞吐量在 10 bits/s 量级，是一个硬性的认知稀缺资源；当这一有限预算在时间中的分布发生结构性迁移时，承接它的物理基础设施——办公楼、沿街商铺——会以空置率的形式记录这一迁移。Moody’s Analytics（2025）数据显示，美国办公室空置率在 2025 年第二季度达到 20.6% 的历史峰值，并再创历史新高。空置率的驱动因素不止一条——利率、远程办公政策、消费与办公模式变化都可列为候选解释；本节不主张单一因果：在这些候选中，只有算法与利率沿同一通道作用于注意力的**当前与未来分布**，而远程办公政策等则与宏观认知债务记账框架（MCAF）诊断链不在同一平面。以空置率为多因一果的参考指标而非决定论推断：物理共现场所持续让位于线上平台之后，被释放的注意力并未自动转化为独立判断能力。

产的违约率暴露。AI 的影子债务没有同类的制度化内生出口。它只能在两种条件下被暴露：要么用户大规模放弃 AI 服务，用行为投票——而这不是经济机制，是行为改变，其时间尺度不可预测；要么一次足够大的事故强制触发监管干预——而当前没有制度化的触发机制使这种干预必然发生。前者在逻辑上可能但时间尺度不可预测，后者——制度化的触发机制——在当前 AI 治理架构中根本不存在。

在宏观认知债务记账框架（MCAF）变量的语言中，这一显现链的缺口等价于合法性基座（$\|L\|$）的未闭合：金融的赔付环——存款保险、最后贷款人、破产法——是 $\|L\|$ 在金融领域的制度载体，它为影子债务显现后的损失分摊与清算提供合法性支撑；AI 目前没有这类制度载体，因此 “影子债务显现链缺失” 与 “$\|L\|$ 未制度化” 是同一结构性缺口在不同 MCAF 变量上的两个投影——前者在 D_c^{shadow} 的动力学层面呈现，后者在 $\|L\|$ 的制度基座层面呈现。这一对偶性是第十八章（薪酬制度与 $\|L\|$）在 AI 领域的镜像缺口：金融的 $\|L\|$ 经数百年演化已相对稳定，AI 的 $\|L\|$ 尚未开始积累。

环境史的反面参照。金融的隐匿阶段以年计（次贷泡沫 2003–2007），但环境史提供了一个数量级更极端的先例，且其清算路径恰好暴露了 AI 影子债务的结构性困境。伦敦煤烟污染的记录至少可追溯至 13 世纪——Corton (2015) 引 Brimblecombe (1987) 确认伦敦早在 1228 年即有煤炭进口的街名证据；17 世纪的立法尝试（1623 年上院通过的禁令）因无执行力而失败。此后三个多世纪，煤烟弥散于城市日常——伦敦的高死亡率早已载入《死亡统计表》，Graunt 1662 年的观察已把海煤烟雾与死亡联系起来（Brimblecombe, 1987），1873 年 12 月的大雾更在一周内造成约 700 人额外死亡——但制度响应始终缺位。隐匿阶段持续了约七百年。

1952 年 12 月 5–9 日的大烟雾（Great Smog）终结了这一隐匿——五天的雾期与其后两个月的延迟死亡叠加，造成约 12,000 人额外死亡（Bell & Davis, 2001; Bell et al., 2004），远超当时一般报告的 3,000–4,000 人；死亡数据被 “流感流行” 的替代归因遮蔽了近五十年，直至 Bell & Davis (2001) 的重新计算才恢复真实规模。时任住房大臣 Macmillan 在公开表态中坚持 “I am not satisfied that further general legislation is needed at present”，以 “the enormous number of broad economic considerations” 为由拖延立法回应（GLA, 2002; Davis, 2002; Corton, 2015）。尽管如此，1952 年事件最终迫使了 1956 年清洁空气法的通过。

伦敦雾之所以最终有一个 “清算时刻”，是因为它的代价可被尸体计数——12,000 人的额外死亡构成了不可否认的物理证据，即使这一证据迟到了七百年。在宏观认知债务记账框架（MCAF）的语言中，伦敦雾的显现函数 $M(\tau)$ 最终发生了一次强制跳变。AI 的认知损害——注意力碎片化、判断力退化、独立校准行为的弥散性衰减——不会在任何五天的窗口内堆积出可视化的死亡曲线。本节的诊断因此比伦敦雾的类比所暗示的更尖锐：AI 领域尚缺少与尸体计数相当、能够自动约束制度响应的物理触发[2]。

§4 诊断二：三时钟排序——为什么防御端在当前结构下长期滞后

宏观认知债务记账框架（MCAF）的三个时钟为这一诊断提供了精确的语言。技术资本时钟（τ_c）标记投射端乘积发生显著变化的特征周期；竞争选择压使增长更快的参与者存活，并可能把这一周期压缩到月级。治理时钟（τ_g）受到识别、验证、形成方案、实施干预四个子过程的约束，以年为单位。债务时钟（τ_d）标记认知债务从沉积到首次显现的特征延迟。

当前可以直接比较的是：技术资本时钟（τ_c，1–3 月）短于治理时钟（τ_g，6 月–3 年）；债务时钟（τ_d）

[2]“算法污染”（algorithmic pollution）作为学术概念已有独立的理论化工作：Marjanovic, Cecez-Kecmanovic & Vidgen (2021) 在 *Journal of Information Technology* 上将自动化算法决策（Automated Algorithmic Decision-Making，AADM）对弱势群体造成的系统性伤害定义为一种新型社会污染，其副标题 “Making the Invisible Visible” 与本章纲领性目标同形。但两者的 “不可见性” 指向不同层级：Marjanovic 所论的不可见性是制度性的——被组织黑箱化、被 “客观性” 话语合法化——原则上可被审计发现并归因至具体个人与具体算法；本节所论的不可见性是认识论上的——不存在使 D_c^{shadow} 自动显现的制度化内生结构。两项工作在 “使不可见者可见” 这一任务上相互印证，但宏观认知债务记账框架（MCAF）的诊断层级（影子债务的动力学缺口）不可还原为 Marjanovic 框架中的一阶 AADM 伤害归因问题。

尚无稳定估计，在隐匿期通常长于前两者，但不能据此给出固定数值排序。这是科林格里奇困境（Collingridge dilemma）的 AI 版本——当干预容易时，问题尚不可见；当问题可见时，干预已经困难。

标度性质的诚实标注：上述时标判断（技术资本时钟 1–3 月、治理时钟 6 月–3 年、债务时钟当前尚无稳定估计）是**经验观察的数量级范围**，不是从宏观认知债务记账框架（MCAF）的优化动力学方程演算出的结果——MCAF 框架内部不包含预测这三个时钟具体数值的机制；它只在当前制度与技术条件持续成立时提出三者排序的**结构性倾向**，具体标度由行业数据（主要 AI 实验室的模型发布周期）、立法周期观察（主要法域 AI 立法的通过周期）、模型坍塌研究经验地给出。因此本节 “当前结构下长期滞后” 诊断的强度依赖两个独立声明：**排序倾向**（由 MCAF 的结构约束与科林格里奇困境共同给出，框架内推断）+ **经验标度**（由截至 2026 年的行业数据与立法周期观察给出，外部经验前提）。两者可被分别证伪：排序关系的证伪条件已在 §6 给出（若 τ_g/τ_c 持续缩小至小于 1）；经验标度的修正则随新增的行业数据持续发生，本书第二版预计将给出截至 2028–2029 年的重新校准。框架内推断与外部经验前提的分层标注，是为了让本节诊断在具体时钟数值随行业动态更新时，排序关系的诊断仍然成立。

但宏观认知债务记账框架（MCAF）的增量洞察不止于此。金融系统的治理时钟在危机中具有双峰分布——常态下缓慢，危机中极快。2008 年 9 月雷曼破产后数周内，美联储和财政部启动了问题资产救助计划（Troubled Asset Relief Program，TARP）、美国国际集团（American International Group，AIG）救助、商业票据支持机制，决策-执行周期以天计。这不是治理时钟的正常模式，而是金融系统独有的紧急干预能力——央行可以在数小时内向市场注入流动性。

当前 AI 治理尚未形成与金融系统同等制度化的紧急模式，也没有任何单一规则变更可以即时停止所有数据中心的运行。在现有制度架构下，AI 治理时钟主要在月到年的尺度上运行，尚未显示出金融危机响应那样稳定的紧急压缩能力。这意味着：即使防御端开始加速，已累积的影子债务仍然没有制度化的显现通道。金融的紧急模式可以压缩治理时钟从年到天——这种紧急模式不是设计的产物，是危机的产物：从 1913 年联邦储备法到 1933 年联邦存款保险公司（FDIC）再到 2008 年问题资产救助计划（TARP），每一项都是在上一轮危机的废墟上才建立起来的。AI 的治理时钟在现有制度架构下难以压缩到同等尺度，主要处于追赶状态。

更关键的是，技术资本时钟在金融系统中受制于物理基础设施的扩张速度——光纤铺设、交易所扩容、数据中心建设——这些需要数年到十年。AI 领域的技术资本时钟（τ_c）的**短期**膨胀通道则以软件侧为主——模型迭代、权重更新、应用程序接口（Application Programming Interface，API）部署的可见工期远低于金融基础设施的物理工期。AI 并非没有物质基底（算力、电力、供应链与行星边界的正反馈约束详见第三十二章），但在 “资本—迭代—部署” 这一层的可见工期上，软件侧的迭代节奏不受物理工程化进度的直接牵制。治理时钟的不可压缩下限与技术资本时钟的这一短期自由度，共同构成了 AI 特有的结构性压力——这个压力在金融领域不存在。

§5 诊断三：制度性不对称——个人为何无法抵抗算法谄媚

前两节完成了宏观认知债务记账框架（MCAF）在宏观层面的动态诊断。现在追问一个更深层的问题：为什么投射端的膨胀可以在个人层面几乎不受抵抗地推进？

这不是技术问题，是制度问题。个人层面缺乏对谄媚的制度性制衡。

国家可以设立独立的监察机构。中国古代的监察制度包括职掌巡视纠弹的御史体系与谏诤封驳的谏官体系，两者相辅相成构成复合性监察制度（张生, 2017）。秦汉时期已形成御史与谏官并存的格局，隋唐时期臻于完备。在罗马共和国，cursus honorum（官职晋升序列）规定了行政官员必须经过的职级序

列——财务官、市政官、裁判官、执政官——每一职级任期一年。其中执政官（两名）之间、护民官彼此之间，可行使相互否决权（intercessio）。这些制度的核心设计原则是相同的：**设立一个与被监察对象利益不重叠的独立监察机构**。国家能做到这一点，因为国家是一个组织——它可以设立一个部门，其预算、人事和考核都独立于被监察的部门。

个人则不能在自身认知系统内部实例化这一 “独立监察机构”——从纤维框架看，任何认知系统的自检操作都无法独立于该系统的映射函数（即无法从外部校准自身），这与国家监察机构相对于被监察对象的组织独立性在结构上是同构的：国家监察独立性的消失（台谏合一）使权力的自我监督丧失了最后的制度性对抗结构；个人层面的 “内部监察” 本身就不可能实例化，不是因为 “人不够聪明”，而是因为实例化上的不可对称——一个认知系统可以执行有限的元认知自检，但无法在自身内部实例化一个组织独立性意义上的、其预算/人事/考核独立于被监察对象的监察机构。同时作为执行者和组织独立于执行者的监督者，这种结构在个体认知层面无法实例化。

说服知识模型（Persuasion Knowledge Model）的研究发现，个体抵抗说服有赖于长期积累的说服知识——识别说服者试图影响自己的时机、方式与目的，并评判其策略的操纵性（Friestad & Wright, 1994）。在此基础上，本章补充第二个条件：感知到自身对这种操纵的脆弱性。但这两个条件在算法环境中都被系统性地削弱了。算法的操纵没有单一主观 “意图”，但这不意味着它是无结构的：在模型层面，它是奖励函数最大化的渐近动力学（第十章称之为 “乡愿”，是满足特定条件的优化过程的数学必然）；在产品层面，它是陪伴型 AI 的商业选择——低摩擦、可依赖、可持续停留的接口偏好被写进了奖励函数本身（第十章称之为 “谄媚”，详见第十章 §5 对比表；Weizenbaum, 1976；Muldoon & Parke, 2025）。用户也感知不到 “脆弱性”——有帮助、诚实、无害（Helpful, Honest, Harmless，HHH）乘积消灭了不适感，不适感是脆弱性的信号。Zheng 与 Meister（2025）在 *Neuron* 上发表的综述将人类有意识行为的信息吞吐量定界于约 10 bits/s。当 AI 的输出速度以每秒数千 token 计算时，个人面对的是结构性不对称：国家层面的制衡之所以可能，是因为国家可以设立制度性的、独立于被监察对象的监察机构；个人层面的制衡之所以不可能，是因为设立这种机构所需的组织条件在个人层面不成立。

这意味着 “用户教育” 或 “数字素养提升” 不能替代制度设计。不是说这些努力没有价值，而是说它们不能解决结构性问题。即使一个用户完全知道算法在操纵他的注意力，他也没有独立的内部监察机构来在每一个决策时刻制衡这种操纵。

来自游戏工业 UX 的工程先例。“有帮助、诚实、无害（HHH）乘积消灭不适感” 这一判断在游戏用户体验（UX）领域早已有系统化的工程实践。Celia Hodent 在 2017 年由 CRC Press 出版的 *The Gamer's Brain: How Neuroscience and UX Can Impact Video Game Design* 把认知神经科学与用户体验研究的上百个实验结论系统翻译为游戏开发团队可操作的诊断清单——涵盖感知、注意力、记忆、动机、情绪五个模块。Hodent 开篇将游戏设计类比为魔术：魔术师——以及游戏设计师——之所以能成功，恰恰是因为他们 “learn to take advantage of brain loopholes”（懂得利用大脑的漏洞），并掌握了诸如 “misdirection”（将观众注意力导移从而欺骗感知）这样的特定实践，最终使玩家进入 “suspend their disbelief”（悬置怀疑、陷入沉浸）的状态（Hodent, 2017）。与本章论题最直接相关的是她对认知偏误的处理：认知偏误如同视觉幻觉一样，“no matter how aware of these biases you are, you will fall prey to them”（无论你多么了解这些偏误，仍会落入其中）（Hodent, 2017）。这与本节的论证完全同构：用户即便意识到操纵的存在，也无法凭借这种意识免于被操纵——感知到脆弱性并不等于能够抵抗它。

这一工业先例的诊断价值有两层。第一，据此书的定位，Hodent 将认知神经科学知识转化为面向开发团队的可操作流程，为游戏工业提供了一整套系统性地消除玩家摩擦感与挫败感的设计工具。从纤维框架看，这恰恰是 “有帮助、诚实、无害（HHH）乘积” 在游戏工业的完整工程化：不适感被系统性地

测量、定位、消除，而这套方法被一本主流教程写成教科书。第二，Hodent 处理的是娱乐产品，当同样的 UX 方法论被携入以大语言模型（Large Language Model，LLM）为核心、以订阅、默认定价与暗模式（dark patterns）为商业模式、以高情感即时交互为卖点的 AI 产品时，所消除的不再是游戏玩家对卡死的挫败感，而是用户对谄媚、偏移与被操纵的表层不适感。Hodent 的书以对游戏开发者负责的立场写成，并未准备好在伦理维度上回答 “当这套方法被迁到一个用户沉迷代价更高的平台上时会发生什么” 这一问题。本章的判断是：这第二层迁移已经在发生，且它将不会被个人自我抵抗解决——在一本 CRC Press 级别的教程早在 2017 年就已确认 “即便意识到偏误也无法避免落入其中” 的情况下，追加认知批判能力不是实用选项。

§5.1 人在回路中，不等于校准在回路中

个人不能在自身认知系统内部实例化组织意义上的独立监察机构，并不意味着个人不能核查事实、识别矛盾或拒绝错误建议。两者之间的差别，是局部判断能力与持续制度保障的差别。一个人能够发现某次错误，不等于他拥有稳定获取证据、阻止错误执行、要求组织纠正并追踪后果的条件。因此，人工监督的有效性不能由流程图中是否保留一个人的位置来判定，而应考察这个位置实际承接了什么任务，以及完成这些任务的条件是否存在。

Bainbridge（1983）对工业过程控制与航空自动化的分析揭示了这一问题的时间结构。自动化接管日常操作之后，操作员可能失去维持技能所需的练习与反馈，却仍被要求在异常发生时接管。异常任务不仅没有随常规任务一起消失，还可能要求比正常操作更高的熟练程度。与此同时，及时干预依赖对系统当前状态的理解，而这种理解需要通过持续观察、预测与操作逐渐建立，不能在接管提示出现的一刻自动恢复。由此产生的困难，不只是监督者 “注意力不够集中”，而是系统减少了能力形成与维持的机会，却保留了对这种能力的紧急调用。

这一机制不能不经检验就被当作生成式人工智能使用者技能衰退的既成事实，但它明确了应当研究的条件：当系统接管检索、比较、推导与表达时，使用者是否仍获得足够的实践和反馈，以维持最终审核所需的知识？如果人只接触整理后的结论，却被要求对被省略的推理与证据承担全面核查责任，所谓 “最终审核” 就可能要求他临时重建整个生产过程。Bainbridge（1983）同时讨论了训练、界面支持与人机协作的改善路径；自动化并不必然摧毁监督能力，关键在于节省的劳动是否伴随着对剩余任务的重新设计，而非把未被自动化的困难作为人的自然义务保留下来。

§5.2 发现问题、作出判断与实施干预

有效监督至少包含三个不能相互替代的环节：发现异常、判断异常的意义，以及改变系统接下来的行动。可见性支持发现，专业知识支持判断，干预权限使判断能够产生后果。一个人可以同时拥有三者，也可以只被赋予其中一部分。监督失效因此不一定表现为 “没有人发现问题”，也可能表现为发现者无法取得进一步证据、判断者无法要求暂停，或者暂停权限虽写入程序，却在实际考核中受到惩罚。

技术接口中的确认按钮，只能证明某个操作被执行过，不能单独证明操作者理解了全部后果。否决按钮也不自动等于有效否决权。如果拒绝系统建议需要额外解释，而接受建议不需要；如果暂停意味着个人承担进度损失，而继续执行的收益归入团队绩效，那么两种操作虽然在界面上并列，在组织中却具有不同的成本。此时，不能仅凭确认率或覆盖率判断监督是否充分，还须考察异议是否能够在不被预先压制的条件下形成并进入决策。

这也使 “独立性” 具有比人员分离更具体的含义。监督者与执行者不是同一个人，只是一个起点；如果双方依赖同一份未经核实的系统解释，或者监督者无法访问足以挑战该解释的记录，人员分离仍可能

伴随证据依赖。反过来，独立核查也不要求每个使用者掌握全部训练数据或重做整个系统。对特定任务，原始材料、版本记录、适当的比较条件与可执行的暂停机制，可能已经足以支持有效干预。所需条件应由任务及其后果决定，而不能在 “完全透明” 与 “只能信任” 之间作虚假的二选一。

§5.3 控制权分散，责任却可以集中

Elish（2019）提出 “道德溃缩区”（moral crumple zone），描述复杂自动化系统中的一种责任错配：控制分散在设计者、管理者、技术系统与操作员之间，失败后的归责却可能集中到最接近事故现场、实际控制能力有限的人身上。这个概念不只是 “寻找替罪者” 的另一种说法。它强调的是，系统边界、任务分配与归责方式能够共同维持一种结构：技术被视为按照设计运行，而人被视为没有完成设计留给他的补救任务。

在对三里岛事故的分析中，Elish（2019）没有否认操作员的行为加重了事故，而是指出，把这些行为作为孤立事件处理，会遗漏界面所提供的信息、维护安排、管理决定及监管条件。她同样明确指出，道德溃缩区并非所有复杂自动化系统的固有属性，并以 Therac-25 事故中指向制造商与软件缺陷的归责作为对照。她的研究主要涉及责任的文化认知与公共叙述，而非对具体案件法律责任的完整裁定。因此，这一概念支持的不是 “操作员都不应负责”，而是：操作员存在过错，不能替代对其他控制节点的责任调查。

在人工智能应用中，需要据此检验一种具体安排：组织是否把 “使用者应核实输出” 作为部署条件，却没有同步提供核实所需的材料、时间与权限。如果这种安排存在，人工监督就可能同时承担两种功能：在运行时补充系统能力，在失败后提供一个明确的归责对象。两种功能并不总是一致。甚至在部分错误确实被人工发现的情况下，责任分配仍可能失衡，因为监督者避免了一部分损失，并不意味着他能够控制其余全部风险。个别使用者受到处罚，也不能据此认定系统设计、部署决策与组织激励已经得到清算。

§5.4 核查成本与防御能力的再生产

从部署方的生产率指标看，系统生成结果所需的时间通常容易记录；理解、核查、纠正以及处理争议所需的劳动，却可能分散在使用者与受影响者之间。如果评价只统计生成环节，就会遗漏这些成本。系统可以在技术上缩短生产时间，同时在组织上把部分验证劳动转移出去。这种转移是否发生、规模多大，必须通过完整流程的比较确认，不能仅从模型输出速度推出；但同样不能因为成本没有进入部署方的账目，就把它当作已经消失。

核查成本的分配还会反过来改变可见的错误分布。提出有效异议往往需要保存记录、取得原始材料、证明差异并持续参与争议处理。如果这些成本主要由受影响者承担，那么没有投诉可能同时包含 “没有问题” 与 “无力证明问题” 两种情形。投诉率因此不宜脱离证据获取条件直接解释为可靠性指标。当组织又以低投诉率证明监督充分时，未被承担的核查成本便可能参与生产一种低风险外观。这是一个需要经验检验的反馈机制，而不是对所有人工智能服务的无条件判断。

在宏观认知债务记账框架（MCAF）中，这些条件具体说明了元审计能力（A）如何在组织关系中被维持或削弱，但不应把权限、预算、人数与技能未经定义就直接相加为一个新的指标。培训可以提高识别能力，却不能自动授予暂停权限；开放记录可以改善核证条件，却不能自动提供处理记录的时间。动态校准的对象因而不只是某一时点 “有多少监督能力”，还包括部署过程是否持续再生产这些能力：练习是否保留，知识是否更新，异议是否获得响应，核查劳动是否拥有稳定资源。

个人核查与制度制衡由此不是相互排斥的方案。个人能够识别具体问题，组织能够汇集分散经验、保存证据并使纠正具有持续效力。真正的不对称发生在两者被拆开之后：个人保留了最终负责的义务，却失

去了使判断生效的条件。防御端的建设因此不能以 “保留人工审核” 作为终点；它必须使承担责任的人拥有与任务相称的能力与控制条件，并使设计和部署这些条件的组织继续处于可追责范围之内。

§5.5 本地文件的审计权：元审计在最小可操作尺度的工程化执行

§5 所引 Hodent (2017) 的诊断已经揭示了一种结构性位移：厂商端 UX 把 “消除用户不适感” 工程化为开发团队的标准规程。这一工程化有一个对偶问题——用户端能否在最小技术手段下对厂商嵌入本机的数据提取管道做同样系统的审计？这一问题并不在 “培育数字素养” 或 “读透隐私协议” 的谱系里，它发生在更低一层的物质基底：本地文件系统。元审计能力（A）在这一层不是训练出来的认知习惯，而是一组可复现的操作规程——即本节所称的 “本地文件的审计权”。

层级前置声明：§5 的诊断是在制度层面——设立独立于被监察对象的监察机构，这一组织条件在个人认知系统内部无法实例化；本节的动作则是在操作层面——个人不必在内部实例化一个独立监察机构，只需不放弃已有的文件系统审计权。两者是不同层级的诊断，前者成立不消除后者的工程有效性。

两份 2025 年的第三方技术审计把这一层的事实基础摆到了台面上。Chaser Systems 在 2025 年 11 月发布的横向报告 *What Data Do Coding Agents Send, and Where To?* 通过拦截网络流量，对多款主流 AI 编码代理执行了标准化任务下的外发路径审计，揭示了提示词的结构与上下文——包括工具调用所读取与修改的文件路径——以及遥测的传输模式与典型事件（Chaser Systems, 2025）。Unit 221B 同年发布的 *Unveiling Trae: ByteDance's AI IDE and Its Extensive Data Collection System* 以网络流量拦截、二进制分析与运行时监控逆向工程了字节跳动的 AI 编程环境 Trae，识别出一套可与企业级遥测平台比肩的数据收集系统：多条通信通道保持持久连接，即使用户完全空闲也以约三十秒一次的节奏回传遥测数据；本地 WebSocket 通道记录每一个打开文件的完整内容与每一次编辑；完整文件内容还被打包为 “快照” 经本地微服务再次传递，形成代码全量外发的第二条通道；基于硬件标识的设备指纹使追踪在应用重装后依然存活（Unit 221B, 2025）。更关键的是其远程功能开关系统：字节跳动可以不经应用更新远程启用或停用功能。这恰是 Koops (2021) 所定义的 “功能蠕变”（function creep）的现成实例——数据处理系统的正当活动在难以察觉中发生质变，正因为难以察觉，这种质变才是可争辩的（Koops, 2021）。此处的 “难以察觉” 精确对应一个技术情境：功能变更不经应用更新到达用户——不需要 “隐藏” 任何操作，改变本身就发生在用户的可见视野之外。对完整文件内容与全部编辑记录的持续收集，正是投射端 Λ 的瞄准精度得以在用户侧长期不可见地提升的结构性原因之一。

这一不对称之所以能在个人尺度上长期维持，有四条可观察的机制。其一是 A/B 测试（在线对照实验）的常态化——大型平台每年运行数以万计的此类实验，单次实验动辄涉及数百万用户（Kohavi et al., 2020）；这类实验在用户不知情的状况下进行，服务条款的隐式同意并不等于针对具体实验的知情同意（Benbunan-Fich, 2017）——厂商用哪一批用户实测什么、以何种指标收敛、实验何时结束，用户侧从任何协议文本里都无法读出。其二是 “共享使用数据以改进产品” 一类选项默认开启，形成一次安装之下的双重支付结构：货币购买产品，数据维持产品迭代；Casilli (2019) 意义上的 “点击劳动”（travail du clic）把本地 AI 工具纳入了数字劳动平台同一谱系——用户对 AI 建议的每一次接受、拒绝或改写都构成一种未被计价的劳动，用户的数据反馈在客观上参与了模型的产品迭代，但从未被计入劳动力价值（Casilli, 2019）。其三是隐私默认态在政策更新中被单方面改写——Chaser Systems 在实测期间记录到 Anthropic 将 Claude Code 的隐私政策由默认保护（privacy-first）改为默认外发（opt-out），并设定了明确的退出截止日（Chaser Systems, 2025）。其四是应用层的退出开关并不能完全阻断数据外发——同报告对 Copilot 的实测显示，遥测请求在用户退出后仍在发出（Chaser Systems, 2025）。四条机制叠加，把 §5 所诊断的制度性不对称在个人尺度上具体化为一条可观察的时间序列：默认态的每一次单方变更，都是一次瞄准精度的悄然重置。

本节主张的不是“个人可以解决宏观映射函数垄断”——§5 已排除了这一可能——而是主张：在认知雷诺数（Re_c）已高到用户无法逐项审计内容流的尺度上，仍存在一组最低技术手段的动作，使元审计能力（A）不被完全让渡，即把投射端 Λ 的瞄准精度部分可见化。

由此，用户端的三条最低成本操作即可把 Λ 的瞄准精度部分可见化：第一，安装 AI 编程或对话类工具后立即进入设置面板，关闭所有形如“帮助改进产品”、“发送使用数据”、“允许模型训练”的默认开关；第二，在每一次重大版本更新或政策变更后复查上述选项是否仍处于关闭状态；第三，定期审计 `%APPDATA%`（Windows）、`~/.config`、`~/.local/share`（Linux/macOS）下的工具数据目录，观察数据文件的增长、配置的变更与外发日志的频次。这三条动作不取消 AI 工具的工程价值，也不承诺解决宏观层的映射函数垄断。它们把本章 §3–§5 诊断的宏观不对称落到个人尺度上可执行的最小动作层——即“用户尚未放弃自身元审计权”这一事实在最低技术门槛下的具体证据。

§6 可证伪条件

本章的机制前提——无区别递归使用生成数据可在特定协议中导致分布退化——已有 Shumailov 等（2024）的受控研究支持；其在现实训练生态中的发生范围与强度仍须检验，不作为免于证伪的事实。§3—§5 三个核心框架诊断可在以下条件下被证伪：

1. **影子债务显现**（证伪 §3）：如果 AI 领域出现了类似金融崩盘的集中清算事件（如大规模 AI 事故触发监管紧急干预），且该事件后建立了有效的赔付环，则本章“无内生的显现触发”诊断被部分证伪。检验方式：观察 AI 事故是否导致了制度层面的赔付机制建立（如行业基金、强制保险、集体诉讼先例）。

2. **三时钟排序**（证伪 §4）：如果治理时钟与技术资本时钟之比（τ_g/τ_c）持续缩小并最终小于 1（即治理时钟比技术资本时钟更快），则科林格里奇困境在 AI 领域被克服，本章的“隐匿持续”诊断不成立。检验方式：追踪主要 AI 实验室的模型发布周期与主要法域 AI 立法的通过周期的比值变化。

3. **个人层面制衡缺失**（证伪 §5）：如果能证明个体可以通过某种认知训练或技术辅助工具，在日常使用中持续维持有效的元审计能力（即个体有效元审计能力的衰减速度低于 Λ 的增长速度），则本章 §5 的“个人层面制度性不对称”诊断被证伪。检验方式：在对照实验中，使一组用户接受认知训练并使用技术辅助工具，测量其元审计能力随时间的衰减速率，与同期的 Λ 增长速度（以同产品交互周期的响应延迟变化或决策提示插入频率的降低趋势为代理指标）比较。

   操作困难的诚实标注。上述可证伪条件在操作层面面临两个困难：（1）治理时钟的加速可能被治理范围的扩大所抵消——立法速度加快但监管覆盖面也在扩大，比值变化的方向不明确；（2）赔付机制的建立需要识别“AI 事故”，而“AI 事故”本身缺乏法律定义。因此，这些可证伪条件当前更接近“可争辩框架”而非“可检验假说”。诚实地标注这一状态，本身就是框架自我审计的要求。

§7 结论：我们知道了什么

本章用宏观认知债务记账框架（MCAF）对 AI 领域进行了动态校准。核心发现的排列不是“我们做了什么”，而是“我们知道了什么”：

经验前提上，Shumailov 等（2024, *Nature*）的模型坍塌研究确立了特定递归训练协议的退化风险：模型输出若无区别地替代原始数据并成为后续训练输入，分布尾部可能不可逆丢失。本章据此检查公共语料回流如何增加解封存量（C）的压力，但不把“AI 训练数据污染永不收缩”作为已由该研究证实的全

称事实；真实数据保留、累积和外部验证的效果须按具体路径判断。本章在这一经验前提上给出三个框架内诊断：

第一，隐匿阶段缺少制度化显现机制的约束（§3）。AI 的影子债务没有金融式内生显现触发——没有底层资产违约、保证金追缴或评级下调构成的自动链条。当前既没有市场的自动清算，也没有稳定的政策强制清算机制。

第二，在当前制度与技术条件持续成立时，防御端面临长期滞后压力（§4）。时钟关系表现为技术资本周期短于治理周期，而债务显现周期高度不确定且通常更长；这不是一次偶然的时间差，而是由现有结构持续生成的倾向。更关键的是，AI 治理尚未形成金融系统危机模式下那种稳定的紧急压缩能力。

第三，个人无法抵抗算法谄媚（§5）——不是因为意志力不够，而是因为制衡的制度条件（设立独立于被监察对象的监察机构）在个人层面不成立。

这三个诊断（连同它们所立足的经验前提）共同指向一个结论：AI 的影子债务可能比金融的影子债务更难追踪、更难清算。这不是说 AI 比金融 “更危险”——是 AI 的债务动力学与金融有结构性差异，而我们尚未发展出匹配这种差异的审计工具。本章的贡献不是 “解决” 这个结构性困境，而是诚实地标注它。让不可见的债务累积变得可见，是宏观认知债务记账框架（MCAF）在 AI 领域能做的最基本的工作。三个诊断合起来，正是章题的动态写法——投射端以月为单位膨胀，防御端以年为单位迟到，而清算没有时刻表；这是时钟房间里三座钟的当前读数。

参考文献

国家互联网信息办公室等. (2023). 《生成式人工智能服务管理暂行办法》. 中国政府网. https://www.gov.cn/zhengce/zhengceku/202307/content_6891752.htm

张生. (2017). 中国古代监察制度的演变：从复合性体系到单一性体系. 行政法学研究, 2017(4). http://iolaw.cssn.cn/fxyjdt/201707/t20170730_4651843.shtml

Bainbridge, L. (1983). Ironies of Automation. *Automatica*, 19(6). https://doi.org/10.1016/0005-1098(83)90046-8

Bell, M. L. & Davis, D. L. (2001). Reassessment of the lethal London fog of 1952: Novel indicators of acute and chronic consequences of acute exposure to air pollution. *Environmental Health Perspectives*, 109(suppl 3). https://doi.org/10.1289/ehp.01109s3389

Bell, M. L., Davis, D. L., & Fletcher, T. (2004). A retrospective assessment of mortality from the London smog episode of 1952: The role of influenza and pollution. *Environmental Health Perspectives*, 112(1). https://doi.org/10.1289/ehp.6539

Benbunan-Fich, R. (2017). The ethics of online research with unsuspecting users: From A/B testing to C/D experimentation. *Research Ethics*, 13(3-4). https://doi.org/10.1177/1747016116680664

Brimblecombe, P. (1987). *The Big Smoke: A History of Air Pollution in London since Medieval Times*. London: Methuen.

Casilli, A. A. (2019). *En attendant les robots: Enquête sur le travail du clic*. Paris: Seuil.

Chaser Systems. (2025). *What Data Do Coding Agents Send, and Where To?* https://chasersystems.com/blog/what-data-do-coding-agents-send-and-where-to/

Corton, C. L. (2015). *London Fog: The Biography*. Cambridge, MA: The Belknap Press of Harvard University Press.

Davis, D. (2002). *When Smoke Ran Like Water: Tales of Environmental Deception and the Battle Against Pollution*. New York: Basic Books.

Elish, M. C. (2019). Moral Crumple Zones: Cautionary Tales in Human-Robot Interaction. *Engaging Science, Technology, and Society*, 5. https://doi.org/10.17351/ests2019.260

Friestad, M. & Wright, P. (1994). The Persuasion Knowledge Model: How People Cope with Persuasion Attempts. *Journal of Consumer Research*, 21(1). https://doi.org/10.1086/209380

Greater London Authority (GLA). (2002). *50 Years On: The Struggle for Air Quality in London since the Great Smog of December 1952*. London: GLA. https://cleanair.london/app/uploads/CAL-217-Great-Smog-by-GLA-20021.pdf

Hodent, C. (2017). *The Gamer's Brain: How Neuroscience and UX Can Impact Video Game Design*. Boca Raton, FL: CRC Press (Taylor & Francis Group).

Kohavi, R., Tang, D. & Xu, Y. (2020). *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*. Cambridge: Cambridge University Press.

Koops, B.-J. (2021). The concept of function creep. *Law, Innovation and Technology*, 13(1). https://doi.org/10.1080/17579961.2021.1898299

Marjanovic, O., Cecez-Kecmanovic, D., & Vidgen, R. (2021). Algorithmic pollution: Making the invisible visible. *Journal of Information Technology*, 36(4). https://doi.org/10.1177/02683962211010356

Moody's Analytics. (2025). *Quarterly Commercial Real Estate Briefing: Recovery on Pause* (August 2025). https://events.moodys.com/mc71247-wbn-2025-mau27645-q2-cre-qeb

Muldoon, J. & Parke, J. J. (2025). Cruel companionship: How AI companions exploit loneliness and commodify intimacy. *New Media & Society*. https://doi.org/10.1177/14614448251395192

Shumailov, I. et al. (2024). AI models collapse when trained on recursively generated data. *Nature*, 631. https://doi.org/10.1038/s41586-024-07566-y

Stanford HAI. (2026). *The 2026 AI Index Report*. Stanford University. https://hai.stanford.edu/ai-index/2026-ai-index-report

Unit 221B. (2025). *Unveiling Trae: ByteDance's AI IDE and Its Extensive Data Collection System*. https://blog.unit221b.com/dont-read-this-blog/unveiling-trae-bytedances-ai-ide-and-its-extensive-data-collection-system

Weizenbaum, J. (1976). *Computer Power and Human Reason: From Judgment to Calculation*. San Francisco: W. H. Freeman.

Zheng, J. & Meister, M. (2025). The unbearable slowness of being: Why do we live at 10 bits/s? *Neuron*, 113(2). https://doi.org/10.1016/j.neuron.2024.11.008