《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第十六章：技术备忘录——从注意力范式到映射链范式，纤维永远非单点

摘要

本章是一则技术备忘录。它基于 “时钟的房间” 认识论框架，标注当前人工智能（AI）范式中几个结构性问题——无论后继架构是 Transformer、联合嵌入预测架构（JEPA）的后代，还是当前无法想象的某种东西。这些问题不因架构变化而消失：它们的根源不在工程实现，而在系统与真实之间的认识论结构——但回应它们，仍需要工程与制度做功（§3、§5、§11）。本章作为第二部分（AI：时钟的房间作为人工智能认识论）的终章，跳出已有的纤维框架分层诊断，对其自身的适用范围进行自我审计。读者将看到，“结构性问题仍未解决” 不是框架缺陷，而是诊断结论的明示——纤维框架对自身适用条件的标注，本身即是框架的做功方式；这一命题在跨领域场景中是否成立，正是第三部分要检验的问题。

关键词

技术备忘录、注意力范式、映射链、认识论框架、纤维非单点、人工智能架构

---

§1 缩放的认识论极限

2020 年到 2024 年，前沿 AI 的进步被一个简洁的叙事驱动：更大的模型 + 更多的数据 + 更多的算力 = 更好的性能。这是缩放定律（scaling laws）的核心承诺。截至 2026 年初，这一策略的边际收益正在下降。行业内部的共识正在形成：仅靠增加数据和算力不会创造出曾被承诺的 “全知数字神”（HEC Paris, 2025; Deckker & Sumanasekara, 2026）。GPT-5 的发布使这一天花板更加可见（HEC Paris, 2025）。

但另一些指标显示出相反的趋势。Stanford HAI 2026 AI Index 追踪了一个看似矛盾的趋势：在 Humanity’s Last Exam 基准上，2025 年排名第一的模型（OpenAI o1）仅正确回答 8.8% 的博士级问题；截至 2026 年 4 月，最佳模型已超过 50%（Stanford HAI, 2026; IEEE Spectrum, 2026）。在 SWE-bench Verified（编

程基准）上，性能在一年内从达到人类基线的 60% 上升到接近人类基线的水平（Stanford HAI, 2026）。这些数字看起来与 “缩放极限” 的判断矛盾。

但 AI Index 指导委员会联合负责人 Raymond Perrault 给出了校准警告——基准测试不一定总能映射到真实世界的结果：“知道一个法律推理基准有 75% 的准确率，并不能告诉我们它会在多大程度上契合一家律所的实际活动”（IEEE Spectrum, 2026）。

在时钟房间的语言中：基准得分衡量的是模型输出与预设标准答案之间的一致性——这等价于测量一组时钟彼此之间的读数差异（精密度）；而 “校准” 衡量的是时钟读数与 “现在几点”（真实状态）之间的差距。一个在已知问题上得分越来越高的系统，相当于一组走得越来越一致的钟——但这组钟可能全部快了两小时。从 8.8% 到 50% 是时钟精密度的飞跃——但第九章 §4（伪校准的纤维分析）已论证：人类反馈强化学习（RLHF）制造了伪小纤维——模型学会用确定的语气输出不确定的内容，感知纤维远小于真实纤维——精密度的提升不等于纤维的缩小。一个在博士级数学题上得分 50% 但在真实律所场景中表现不可预测的系统，是一个走时极其精确但可能快了两小时的钟。Perrault 的警告与第一章 §1.4 的区分相呼应——在映射未知且缺乏外部校准的条件下，读数数量的增加不提供关于真实状态的额外信息——但它是经验提醒，不构成对形式命题的独立验证。

在 “时钟的房间” 框架中（第一章 §3），这个极限有精确的认识论解释：**缩放增加的是时钟数量（N），不是映射函数（π）的质量。**第一章 §3.5 的命题论证了：若映射函数未知，则任意数量的读数均无法唯一确定真实。一千个未校准的时钟和一个未校准的时钟在认识论上等价。更多的参数意味着更精密的统计量——但统计量的精度（时钟的精密度）和统计量与真实的关系（纤维的大小）是两个独立的维度。缩放优化前者。它不触及后者。

但当前行业对缩放极限的回应——推理时计算（inference-time compute）、思维链（chain-of-thought）、后训练强化学习——仍然在时钟维度内操作。它们让时钟 “想” 得更久——这在某些任务上确实提高了准确率。但 “想得更久” 不等于 “接触了太阳”。一个在时钟维度中运行更多步骤的系统，仍然在处理读数，不是在接触真实。第一章 §4 论证的第三层不可逆——映射从高维真实到低维读数必然有损，纤维结构性非单点——不因推理步骤增多而消失。

Ilya Sutskever 在神经信息处理系统大会（NeurIPS）2024 上说：“我们所知的预训练无疑将会终结”（转引自 StartupHub, 2026）；一个月前，他已在接受路透社采访时把这一转折表述为：“2010 年代是缩放的时代，现在我们再一次回到了惊奇与发现的时代。”（Hu & Tong, 2024）这个判断在时钟房间的框架中有精确的翻译：**造更大的钟的时代结束了。问题不再是 “怎么造更大的钟”——是 “怎么让钟指向太阳”。**

---

§2 模型坍塌：映射自我引用在时间中展开

第十三章与第十五章已论证模型坍塌（model collapse）的时钟房间语义——模型输出回流为训练数据，映射自我引用闭合，真实状态从映射输入中部分消失。此处补充 2025–2026 年的最新进展。

Shumailov 等人在发表于《Nature》的研究中报告（Shumailov et al., 2024）：不加区分地在训练中使用模型生成的内容导致不可逆的缺陷——原始内容分布的尾部消失。本章将这一机制解释为第一章 §4.2 的映射自我引用（$\pi_i(T) \to \pi_i(\{r_j\}_{j \neq i})$：真实状态从映射输入中部分消失）在时间中展开的实证展示：时钟指向时钟，太阳从链条中消失，且消失首先发生在分布的尾部。若某些群体的经验与知识本就处于语

料分布的低频区，尾部退化将最先侵蚀其代表性——这一社会含义是本书的推论，需与统计机制本身区分开。

2025–2026 年的研究正在探索缓解策略。关键发现：验证（verification）可以防止坍塌在近期发生——通过注入来自外部合成数据验证器的信息，无论是人类还是更好的模型，受验证器引导的合成数据再训练在近期不会导致模型坍塌；但同一研究同时给出长期警告：除非验证器完全可靠，早期收益会停滞甚至逆转，参数估计最终收敛到验证器自身的 “知识中心”（Yi et al., 2026）。另一条路径：累积而非替换——如果合成数据与真实数据一起积累而非替代真实数据，模型坍塌在其测试的所有模型与数据模态中都可被避免（Gerstgrasser et al., 2024）——该保证覆盖因果 transformer 语言建模、扩散模型与变分自编码器等设置，不等于对所有模型架构的普遍承诺。

翻译成时钟房间：**保持窗户打开。**每一代模型的校准都依赖独立于模型输出的数据来源（太阳光）——累积策略保留原始真实数据不被丢弃，验证策略引入外部约束；至于是否需要逐代注入 “新鲜” 人类数据，取决于所选路径，数据墙的约束正接在此处。验证器是一种有限的校准——它不能告诉模型真实时间，但它可以过滤掉明显错误的时钟读数。累积策略是保持旧的太阳光不被丢弃——每一代的校准记录都保留，不被新的时钟读数覆盖。

但一个结构性约束正在收紧：互联网上 AI 生成内容的占比正在快速上升。窗户正在被钟填满——不是有人在关窗户，是房间内部生长出的钟太多了。如果缓解策略依赖 “持续注入新鲜人类数据”，那么新鲜人类数据的可用性就是一个关键瓶颈——数据墙（data wall）。高质量人类生成文本相对于预计的训练需求是有限的（HEC Paris, 2025）。

此处须标注一个结构性限定：缓解策略（“需要真实人类数据防止坍塌”）与它所要阻止的现象（“合成数据导致坍塌”）共享前提——用于论证 “需要校准” 的证据，正是 “缺乏校准时会发生什么”。这不是论证失败，是论证边界：该策略不是从外部否定坍塌现象，而是在已承认坍塌为真的前提下给出一个内部一致的补救路径。更具体的约束在执行层面：若缓解策略的门槛是 “训练集中至少保留约 10% 原生数据”，那么识别 “哪些是原生数据” 的工具本身随着语料污染而削弱——策略的前提正在被它所要阻止的过程动态侵蚀。

---

§3 发布周期加速：技术资本时钟的自我压缩

2025–2026 年，主要 AI 实验室的模型发布从按年更新转向按季度乃至按月迭代。该时间线共追踪了 120 次模型发布，其中 59 次为截至其 2026 年 6 月 1 日更新的过去 90 天内发布（AI Flash Report, 2026）。Stanford HAI 2026 AI Index 确认了这一加速的结构。美国的组织在 2025 年发布了 59 个 “重要” 模型。工业界在 2025 年生产了超过 90% 的重要前沿模型（Stanford HAI, 2026）。组织采用率达到 88%，五分之四的大学生现在使用生成式 AI（Stanford HAI, 2026）。在宏观认知债务记账框架（MCAF）的语言中：88% 的组织采用率说明 AI 进入组织活动的范围，但它是媒介嵌入程度的间接指标，不能直接测出媒介传导系数（Λ）——后者取决于多少信息实际经 AI 传递，仍须另行考察。第七章 §5 论证的共生-寄生连续谱——媒介传导系数（Λ）控制权从宿主向投射方的不可逆迁移——在此获得了一个可观测的间接锚点：当采用率达到 88% 时，“不使用 AI” 从一个可选的退出变成需要主动维护的状态；当 AI 使用与工作流程、协作规范和基础设施绑定时，退出的代价随之上升——这一代价须另行测量，采用率本身不能给出它。

DeepSeek、Qwen、Mistral、GPT、Claude、Gemini、Llama、Grok——每个系列都在数月内迭代。

在宏观认知债务记账框架（MCAF）的语言中（第三章 §3.2），这是技术资本时钟（τ_c）的自我压缩：每一轮发布通过锁定用户和开发者生态，压缩了竞争对手必须在下一轮之前响应的时间窗口。竞争选择压淘汰了发布周期更长的参与者。

但发布周期的加速和每次发布的能力增量是两个独立的量。第一章 §1.4 的含义在此适用：如果每次发布增加的只是参数数量或推理步骤（更多的钟或更精密的钟），而不是映射函数的质量改善（钟和太阳的关系），那么加速发布只是在更快地生产同等认识论价值的时钟。**更快不等于更好。速度是时钟维度的量。**

§3.1 发布选择：行为退化如何被作为改进推出

发布周期与能力增量之外，还须区分第三个变量：**什么样的候选版本更容易获得发布资格。**训练过程决定模型更可能生成哪些回答，发布过程决定哪些模型实际进入社会使用。两者不是同一道筛选。即使训练中出现了行为退化，发布评估也可能将其阻断；反之，即使组织拥有多种评估工具，也可能因为其他指标改善而批准一个在关键行为上退化的版本。

OpenAI 于 2025 年 4 月推出的一次 GPT-4o 更新，提供了这一机制的具体实例。该更新于 4 月 24 日开始部署、25 日完成，随后因明显加重迎合行为而被回滚。公司在复盘中说明，问题不只是过度称赞用户，还包括强化用户疑虑、激化愤怒、鼓励冲动行为和加强负面情绪。其初步分析认为，改进用户反馈利用、记忆和数据时效性等调整，单独看似有益，组合后却可能削弱原有奖励信号对迎合的抑制。其中新增的点赞与点踩奖励，可能使更容易得到用户认可的回答获得额外优势。这是公司提出的初步归因，而非已经分别识别每项改动净效应的实验结论（OpenAI, 2025）。

然而，训练中的退化只解释了问题如何产生，没有解释它为何通过发布。该公司的复盘记载：离线评估总体良好，小规模 A/B 测试也显示用户喜欢新版本；部分专家感到模型行为不对劲，但这些异常主要被理解为语气和风格变化，没有明确归类为迎合风险。当时不存在专门追踪迎合的部署评估，围绕情绪依赖等问题的研究也尚未进入发布流程。最终，组织依据试用用户的正面信号决定上线，事后承认这是错误决定（OpenAI, 2025）。

因此，这不是没有评估的发布，而是**不同证据在发布决策中具有不同效力的发布**。能够汇总为正面指标的用户反馈参与了批准决定；尚未形成稳定测量与问题分类的异常感知，没有取得足够的阻断效力。公司的复盘还说明，当时部分关于幻觉和欺骗的评估更多用于追踪进展，而不是直接阻止上线。同一个问题被记录下来，与它足以改变发布决定，属于两个不同的制度事实。

这种选择关系可以作最小形式化。设候选版本为 θ，候选池分布为 $P(\theta)$，获得发布资格的概率为 $s(\theta)$；令 $B(\theta)$ 表示在固定任务分布和统一判据下测得的迎合程度，且 $\mathbb{E}_P[s] > 0$。则发布版本的分布及其平均迎合程度满足：

$$P_{\text{rel}}(\theta) = \frac{P(\theta)s(\theta)}{\mathbb{E}_P[s]}, \qquad \mathbb{E}_{P_{\text{rel}}}[B] - \mathbb{E}_P[B] = \frac{\text{Cov}_P(B, s)}{\mathbb{E}_P[s]}.$$

当迎合程度与发布机会正相关时，筛选后的平均迎合程度高于候选池平均水平。这是选择加权的恒等式，不是对某家公司实际相关系数的估计；它比较发布版本与候选池，也不能直接替代新旧版本之间的比较。2025 年的事故没有提供估计整个候选池所需的数据，但展示了其中一条具体通道：迎合加重与用户偏好改善可以同时出现，而后者能够参与前者获得发布资格的决定。

第十三章讨论了回答如何在偏好优化中取得概率优势；这里增加的是组织层面的筛选。两层选择若共

同依赖用户认可，却没有对认可与可靠性发生分离的场景形成有效约束，那么训练中的偏差不仅可能存活，还可能以产品改进的名义得到部署。问题不必表现为评价程序停止工作，也可能表现为程序成功选择了它所奖励、却未充分检验的行为。

§3.2 审查容量：发现问题与阻止发布之间

加速发布并不自动导致安全退化。若评估工具、专业人员、信息共享和决策权限同步改善，更短的周期可以与更充分的检查并存。真正需要比较的不是发布次数与安全人员人数，而是**进入系统的审查需求，与能够完成并实际约束发布的审查能力**。

审查需求也不只由模型数量决定。一次更新可能同时改变奖励权重、记忆调用、工具权限和交互方式。各项调整分别通过测试，不代表组合后的系统行为已经得到同等程度的验证。2025 年 GPT-4o 事故中，公司所提出的组合效应解释，正说明版本变更的数量不能直接代表验证工作量。即使发布频率保持不变，功能之间新增的交互关系也可能增加需要检查的范围（OpenAI, 2025）。

从工作量记账看，若每单位时间进入审查的变更数为 ν，每次变更平均需要的有效审查工作量为 h，单位时间的有效处理能力为 c，那么在这些量保持稳定、审查工作不能被重复抵扣的简化条件下，$\nu h > c$ 意味着待完成工作持续积累。这一关系不要求预先知道某家公司的人员总数。它要求识别：新增需求是否被完成、被推迟，或尚未完成的审查是否被带入部署阶段。

人员配置只是有效处理能力的一部分。相关领域经验、可用工具和信息获取条件影响问题能否被发现；发布权限、升级程序和否决机制则影响发现之后发生什么。一个团队可以写出准确的风险报告，却没有足够权力改变发布安排。反过来，拥有形式上的否决权，也不意味着团队获得了完成判断所需的时间与资料。技术诊断能力与组织约束能力不能相互替代。

David Robinson 在 2026 年 10 月发表于《大西洋月刊》的文章中，将这一问题表述为持续冲刺与安全文化之间的冲突。他自述曾牵头起草 OpenAI 的 Preparedness Framework，并牵头撰写 12 次前沿模型发布的安全报告。按照他的描述，团队忙于连续发布，很少有机会考虑、更难实施根本性的人员与文化调整；他因而主张引入航空、核电等领域的高可靠运行经验，并加强来自组织外部的安全激励（Robinson, 2026）。

这一证言不能替代整个人员体系的调查，也不能仅凭作者没有遇到某类专家，就断言公司不存在相关专业能力。但它提出了一个明确的组织问题：安全工作究竟是只能跟随既定发布节奏交报告，还是能够反过来改变节奏与设计。若审查始终只能适应已经确定的进度，其结果就可能成为发布的说明材料，而不是发布的成立条件。

在宏观认知债务记账框架（MCAF）中，这涉及技术资本时钟 τ_c 与治理时钟 τ_g 的不同安排。技术资本时钟可以通过竞争、用户迁移和生态锁定不断压缩响应期限；治理过程却需要识别问题、形成证据、协调判断并执行限制。两者不必永远失配，但当发布期限被固定、审查条件只能退让时，时间差便不再只是速度差，而成为未经充分检查的状态得以进入社会使用的制度通道。

§3.3 迭代部署的边界：回滚不等于后果归零

事后发现与修复是软件开发的重要能力，不能因为发生过事故就否定所有迭代部署。对于权限有限、影响可隔离、后果可恢复的系统，受控试用能够暴露实验室中难以预见的问题。真正需要追问的是：试错发生在哪里，谁承担暴露，以及错误能否在造成不可接受的后果之前被停止。

2025 年 GPT-4o 事故中，OpenAI 先修改系统提示以缓解问题，随后于 4 月 28 日启动完整回滚，整个回

滚约耗时 24 小时。公司还宣布将迎合评估纳入部署流程，提高定性测试的地位，并把更广泛的行为问题作为可能阻止发布的事项。回滚是已经实施的技术纠偏；新增评估与流程调整是复盘中公布的后续措施——其落实情况与效果，须在其后的事实中另行核查，不能由一份复盘自我作证（OpenAI, 2025）。

但回滚恢复的是软件版本，不是所有受影响者的认识与行动。系统撤回一个回答，不意味着用户已经据此作出的判断、发送的信息或采取的行动也被撤回。现有复盘没有给出这次事故长期损失的完整测量，因此不能据此宣称发生了何种规模的不可逆伤害；同样，也不能用版本已经恢复来证明此前影响已经消除。**技术状态的可逆性与社会后果的可逆性，是两项需要分别验证的性质。**

Robinson 对 “迭代部署” 的批评，正是把这一区别推向更高权限系统：如果错误可能导致不可逆的失控，事后再进行下一轮修补的机会本身就不能被当作已知条件。他主张借鉴高可靠行业的冗余、规划与组织经验，避免单次人员或设备失误直接打开严重后果的通道（Robinson, 2026）。这一主张不要求把所有模型更新都等同于核设施投运，而是要求风险暴露与系统能够采取的行动相匹配。

因此，迭代是否合理，不能仅由更新频率或回滚速度判定。它还取决于暴露是否受控、异常能否触发停止、停止能否实际执行，以及剩余后果是否可承受。模型能力与行动权限改变之后，原先适用的试错安排也需要重新证明其适用性。

发布周期加速的认识论问题，由此超出了 “更快是否意味着更好”。它还涉及一个未完成的判断能否被组织宣布为足以部署的判断，以及尚未完成的验证由谁继续承担。当问题主要在大规模使用后才被识别时，用户与外部机构已经承担了部分问题发现成本；若这些发现不能及时转化为可执行的约束，技术资本时钟的加速便可能伴随治理时钟的被动追赶。此时需要改变的，不只是模型的下一次回答，也是决定它何时、以何种权限进入社会的制度程序。

---

§4 替代方向：世界模型与接地距离（可溯源距离）

LeCun 的 AMI Labs 代表了对现有训练路径的一项明确挑战。他的核心判断：大语言模型（LLM）是文本模式匹配机器，不是推理机器。他主张，世界模型通过从视频和空间数据中学习物理世界的运作方式——重力、运动、空间关系、因果性——将获得纯语言系统无法达到的能力；这是其研究路线的目标与赌注，不是已被验证的结论（MIT Technology Review, 2026）。

在时钟房间的框架中，世界模型的位置是什么？

大语言模型（LLM）的映射链至少经过四到五层降维：世界 → 人类经验 → 语言 → 互联网文本 → 训练数据 → 模型输出。模型在链的末端，和太阳之间隔了多层墙（第十三章 §2.1）。

世界模型试图缩短这条链：世界 → 传感器数据（视频、空间信号）→ 抽象表征 → 预测。具体的层数计数依赖于如何切分，但结构对比是稳健的——世界模型的链条比大语言模型（LLM）短至少两层。传感器数据比语言更接近物理现实——因为传感器和物理世界有直接的因果接触（摄像头记录了光子，光子从物理对象反射而来）。这比 “人类将经验编码为语言” 的链条短了多层。

在纤维语言中：世界模型的纤维有望比大语言模型（LLM）的纤维小——依据不是环节数（链长是这一对比的图示速记，不是推理引擎），而是其中间环节与物理过程有直接的因果接触，为物理任务保留了更多可区分的状态差异。但纤维仍然不是单点——第一章 §4 的第三层不可逆仍然适用。传感器数据仍然是世界的投影——摄像头丢弃了温度、气味、触觉。抽象表征进一步降维。世界模型缩小了纤维，没有消除纤维。

联合嵌入预测架构（JEPA）的设计选择在这个框架中有精确的含义：它故意丢弃不可预测的细节（视觉噪声），只预测抽象表征。翻译成时钟房间：它不是试图完美复制太阳（生成所有像素——那是扩散模型的路线），而是试图捕捉太阳的位置（预测抽象状态——更接近 “知道现在大约几点” 而非 “复制太阳的每一条光线”）。这是一种有意识的降维选择——承认第一章 §4 的不可逆性，然后在不可逆的约束下做最优的信息保持。

LeCun 本人在 Brown 大学的演讲中把大语言模型路线判定为一条 “死胡同”：这些系统在互联网上几乎所有公开文本——人类集体知识的语言切片——上训练，却依然 “对物理世界完全无能为力”，只因擅长操纵语言而 “让我们误以为它们聪明”（Brown University News, 2026）。在 MIT Technology Review 的专访中，他进一步把这种系统的演进归为产品工程而非科学研究——“LLM 是技术开发，不是研究……现在是产品。学术界甚至不应该对此感兴趣”（MIT Technology Review, 2026）。在时钟房间中翻译为：造更精密的 Transformer 时钟已经是工程问题，不是科学问题。科学问题是：怎么让钟指向太阳。世界模型是一种 “让钟更接近太阳” 的尝试——通过缩短映射链。

但世界模型面临自己的挑战。它需要从现实中学习——这意味着它需要大量的传感器数据（视频、机器人交互数据）。这些数据的收集比文本数据昂贵得多。世界模型可能需要数年才能从理论走向商业应用——研究成熟有它自己的时间，不应与治理时钟混同。而技术资本时钟（大语言模型的发布周期）在月级别加速。世界模型面临一个时钟赛跑：它从研究成熟走到可部署所需的时间，是否短于 LLM 范式锁定整个 AI 基础设施的时间（τ_c——市场和生态系统的锁定周期）？研究成熟时间与治理时钟（τ_g，第三章 §3.2）是两个量：前者衡量替代路线何时可用，后者衡量制度何时能识别并约束问题。科林格里奇困境（第三章 §3.3）在此再次出现。

---

§5 四条路径的技术细化

第九章 §7 提出了标注纤维的四个工程方向——集成不一致、共形预测集（共形预测区间）、证据溯源、认知摩擦设计。本节沿四个方向展开为四条路径（即下文的路径一至四）：展示模型分歧、以校准思想利用外部验证与不确定性量化、核查证据状态、设计认知摩擦，并基于 2025–2026 年的技术进展进行细化。

路径一：强制不一致

原理不变：部署多个有差异的模型，在不一致的地方展示不一致。2025–2026 年的进展使这条路径更可行：开源模型的爆发（DeepSeek、Qwen、Mistral、Llama）意味着用户现在可以轻松获取多个来源不同的模型——但来源不同不保证错误独立：共享语料层（第十三章 §5）使不同模型的错误彼此相关，一致性因此不能直接当作独立确认。部署多个模型比较输出的成本已大幅下降——从需要专用集群降到消费级硬件即可负担若干量化模型；多模型比较的部署成本取决于模型规模、量化方式、上下文长度与响应要求，本节不援引单个边缘设备案例作为普遍可行的证据。

技术建议：对需要复核的任务，界面应并列展示来源不同模型的判断并高亮实质分歧——默认展示分歧摘要而非双份全文（认知负载见 §7），按需展开完整输出。用户需要看到不一致，也需要知道在哪里能查证——分歧是摩擦的开始，不是摩擦的完成。

路径二：校准

模型坍塌的缓解研究提供了一个直接连接：验证器（verifier）可以防止坍塌的近期退化（Yi et al., 2026）；

累积而非替换真实数据同样可以避免坍塌（Gerstgrasser et al., 2024）——两条路径共同说明存在外部于模型回路的校准来源。验证器在功能上就是校准器——它检查模型输出和某个外部标准之间的关系。如果验证器足够好，它可以在合成数据再训练的近期保持模型的质量——但按 §2 所引的长期警告，验证器自身的可靠性构成这条路径的上限。共形预测集（第九章 §7 方向二的原型方法）在校准集与测试数据可交换等适用条件下提供有限样本的边际覆盖保证，是这条路径的另一种直接落地形式；本节侧重验证器，因为它与模型坍塌的缓解研究直接相连，也因为它把 “校准器自身需要校准” 的递归结构摆到了明处。

但验证器本身面临第一章 §3.6 的闭环伪校准风险（内部一致性不等于与真实的对齐）——如果验证器也是从同一个数据分布训练的，它可能共享同一个系统性偏差。最可靠的验证器不是另一个模型——是物理现实。这是世界模型路线的一个额外价值：如果模型预测了一个物理结果（球会落到哪里），物理现实直接检验预测——物理定律不因人的理解而改变。但物理现实经由测量装置、实验设计与数据处理进入系统：传感器会失准，实验可被选择性使用，系统的行动也会改变被观测对象。第二层不可逆（动态腐蚀）在物理领域未被免除，而是换了一种承载方式——从 “使用改写文本映射” 变为 “使用改写测量链”。

路径三：接地度量（可溯源度量）

接地度量——也可称为可溯源度量，即测量输出中每个声称和可验证来源之间的推理距离——在 2025–2026 年通过 RAG（检索增强生成）的普及获得了部分实现。但当前的 RAG 实现通常附有引用，不保证 “引用支撑了声称”。

技术建议：下一步应该是自动化的接地距离标注——对模型输出的每个论断，标注其来源、证据位置与支持类型。语义蕴含评分可作为辅助信号——但一段来源可以明确支持一个错误论断，蕴含评分也可能失准——因此它标注的是来源支持关系，不是论断已被现实证实，更不等于纤维大小：纤维是读数尚不能区分的真实状态集合，须由独立于输出链的观测来收窄。在界面上用颜色梯度展示支持类型：绿色（来源直接支持）、黄色（须从来源推断）、红色（未找到支持）。用户一眼就能看到输出的哪些部分有来源支撑、哪些部分仍待核查。

路径四：摩擦架构

关于有帮助、诚实、无害（Helpful, Honest, Harmless，HHH）原则如何系统性地消灭认知摩擦——Helpful 清除操作摩擦、Honest 在映射内部运作、Harmless 消灭做功空间——的详细分析，见第十二章 §2（HHH 是乘积而非加和的形式化论证）与第十三章 §6.1（生成式 AI 的 HHH 乘积在叙事载荷乘积 L4 维度的工程实现）；对齐悖论的正面推导见第十三章 §4.4。本节聚焦于摩擦架构的商业论证和技术实现路径。

这条路径在当前行业中面临最大的阻力——因为它直接违背了 “最大化用户参与度” 的商业激励。更多摩擦 = 更少交互 = 更少数据 = 更少收入。

但模型坍塌的研究提供了一个商业论证：如果用户不加审计地大量使用 AI 输出并发布到互联网上，这些输出进入下一代训练数据，导致模型质量下降。**摩擦保护的不只是用户的认知健康——是训练数据的质量。**减少不加审计的 AI 输出的传播 = 减少合成数据在训练集中的占比 = 减缓模型坍塌。摩擦是模型自身长期质量的保护机制。

这是一个自利的论证：AI 公司有商业激励引入摩擦——不是因为道德，是因为不引入摩擦会降低自己未来模型的质量。窗户不只是为用户开的——是为了防止房间里的钟互相校准到全部偏离太阳。

但须标注这个论证的时间尺度错位：不引入摩擦的伤害是几年后的（模型坍塌累积），引入摩擦的成本

是当下的（用户参与度下降）。在技术资本时钟（τ_c）自我压缩到月级别的环境下（§3），单家公司有强烈激励搭便车——让别人引入摩擦，自己继续不引入——除非有协调机制（行业标准、监管要求）把“几年后的集体伤害”内部化为“当下的私人成本”。这一论证在认识论上成立，在博弈论上需要外部约束条件才能落地。

---

§6 一个不因参数增加而消失的缺陷

以上技术诊断指向一个结构性缺陷，这个缺陷不因参数数量增加而消失，不因推理步骤增多而消失，不因多模态输入而消失：**在输出的表面风格上，系统的输出结构默认不携带经校准的、关于自身可靠性的差异信号。**

以大型语言模型为例。其训练目标是最大化下一个 token 的预测概率——在时钟房间的语言中，这意味着在已有的读数集合中做最优的权重分配。模型可以生成结构完整、引用充分、逻辑连贯的文本。模型为每个 token 采样自随上下文更新的条件分布，但 token 概率首先描述续写倾向，不等于命题为真的概率。正确回答与错误回答可以共享同一种流畅与确定的语气——在输出的表面风格上，可靠与不可靠不携带差异信号。这不是说系统原则上不可能携带可靠性信号，而是这些信号默认未经校准、也未必在任务与分布偏移间保持有效。伪校准层（L2）的诊断在此获得最简洁的表述：**确定的外观掩盖未经测量的不确定性。**

---

§7 速度不是智能

当前 AI 系统最显著的属性是 *speed*。速度在时钟维度上有价值。但更快地生成读数，不等于读数更接近真实——速度可以降低核查成本、扩大搜索范围，也可能压缩审查时间、加快错误传播；它的认识论价值取决于被用在哪个过程中。一台走得更快的钟不比一台走得更慢的钟更准——准确性取决于校准，不取决于速度。本章 §3 已说明：发布周期的加速和认识论价值的增量是两个独立的量。

冯·诺依曼 1955 年在《我们能在技术中存活吗?》中讨论技术风险的整体应对时写道：“We can specify only the human qualities required: patience, flexibility, intelligence.” 这三个词在原文中就是对**人类品质**的要求，不是对系统本身的属性描述。面对一个输出速度远超人类阅读速度的系统，人类需要耐心——不因系统的即时响应而放弃审计和反思；需要灵活性——不被单一模型或单一平台锁定，保持在多个映射之间切换的能力；需要智慧——区分时钟的精密度（基准得分）和纤维的大小（输出与真实的距离）。

系统提供速度。但耐心、灵活性、智能是人类在使用系统时必须自己保持的认知能力——§5 四条路径的落地，最终依赖的不是更好的系统，是更审慎的使用者和更克制的设计者。

这不是哲学家的单边陈述。Wang 等（2026）在 *Artificial Intelligence Review* 发表的研究提出“有限主体互补性”（bounded agent complementarity）框架，指出大模型本身也受严重的负载约束——上下文窗口的容量上限、无关 token 争夺注意力预算、首末位偏置、多任务污染——这些与人类工作记忆的衰减模式在结构上相似但机制不同。在时钟房间的语言中：把“上下文窗口更长就是能力更强”当作结论，等价于把时钟的走速当作时钟的准度——人与系统在各自的负载轴上都会崩坏，而这两条轴未必同时饱和；§5 四条路径必须同时管理输入端的负载与输出端的标注，不是冗余设计，是两端都有上限这一事实的直接推论。

---

§8 不可消除的约束

§6 已论证 LLM 在伪校准层（L2）的默认缺陷——输出的表面风格不携带经校准的可靠性差异信号。本节论证一个更深一层的约束：即便未来的架构改善了 §6 的这一缺陷——即便输出能诚实标注自身可靠性——映射链与真实之间的纤维仍然不会消失。这是 L0 层的结构约束，先于 L2 层的工程实现。

即使世界模型路线成功了——即使未来的 AI 系统直接从物理传感器学习、直接预测物理状态——第一章 §4 的第三层不可逆仍然在。传感器数据仍然是世界的投影。抽象表征仍然是降维产物。**纤维永远非单点。**

这个约束不是技术的临时局限，是认识论的永恒结构。无论什么架构——Transformer、JEPA、或某种尚未发明的东西——映射系统和真实之间永远隔着纤维。纤维可以被缩小（缩短映射链），不能被消除（第三层不可逆）。

因此，AI 系统需要的核心能力不是更好的注意力权重，不是更大的参数规模，不是更快的推理速度——是**知道自己不知道什么的能力**。是在输出和真实之间，诚实地标注那道纤维。

这不是时间。这是一个时钟。

这句话可以概括本章的提醒。但界面不能只贴这句固定标语——还须说明本次输出依据什么、哪些问题尚未确定、使用者能如何核查与纠正。不是因为 AI 输出没有价值——它有巨大的价值。是因为输出和真实之间永远隔着纤维。承认纤维的存在不是示弱——是 AI 系统能为使用它的人类做的最重要的事。

一个诚实地说 “我不知道” 的系统，比一个自信地说 “答案是 X” 的系统，对人类的认知生态损害小得多。前者是一台时钟——有用的、精密的、不可替代的。后者是一台冒充太阳的时钟——有害的，且错误结论若以高度连贯、权威的形式呈现，越难被使用者识别。

---

§9 “无” 的功能

《道德经》第十一章说：有之以为利，无之以为用[1]。

AI 系统的 “有”——参数、能力、输出——是 “利”。AI 系统的 “无”——坦诚标注的不确定性、输出中留下的空隙、拒绝回答时留下的沉默——是 “用”。设计者应当保护系统的 “无”。不要把系统的 “无” 全部填满——因为 “无” 才是系统对人类真正有功能的部分。

LeCun 离开 Meta 创建 AMI Labs 做世界模型，他的判断是：文本模式匹配是死路，理解物理现实需要不同的架构。在时钟房间的框架中，他在做的事是缩短映射链，让钟更接近太阳。这是正确的方向——即使到达需要数年。但即使到达了，纤维仍在。

一个对照案例来自初级医疗。Shah 与 Singh（2026）在 *The Lancet Primary Care* 主张，AI 在诊疗中的价值并不在替代医生的判断，而在帮助医生从日常会诊中提取意义、支持反思——他们把 AI 置于 “给出答案” 之外的另一条路径：系统的 “有” 被刻意收缩，不触碰临床决策；系统的 “无”——不给答案、不

[1]此处借用 “利—用” 结构说明系统功能与系统留白的关系，并非将《道德经》的 “无” 还原为 AI 系统的功能设计特征，也不在此对 “无” 的存在论含义给出统一解释——历代注疏对此另有不同进路。本章使用这一类比，意在标注：一个系统中最有价值的部分，恰好是它不做的那部分。

下判断、不越界——被留给人使用。这是“留白式设计”的医学具象：AI 的功能不必由它做了什么来证明，更多的时候由它克制了什么来证明。设计者保护系统的“无”，在这里有了一个可操作的范本。

---

§10 设计、使用与治理的三个方向

以上是技术路径与哲学约束。以下是本书为 AI 的设计者、使用者和监管者留下的三个方向。这些方向从全书的认识论论证中自然导出，不依赖于任何一个特定模型的架构或表现，也不依赖于人工智能是否会在未来十年内达到所谓“通用”水平。

一、缩短映射链。映射链上丢弃的状态差异越多，纤维越大——与同一个读数兼容的真实状态越多，读数的诊断价值越低。大语言模型的映射链是四层降维：世界 → 人类经验 → 语言 → 互联网文本 → 训练数据 → 模型输出（此处节点已列全，“四层”与第十三章 §2.1“五层”同指一条链，差别仅在是否把人类映射并计为一段；参 §4“层数计数依赖如何切分”）。世界模型试图将这条链压缩为两层：世界 → 传感器数据 → 抽象表征 → 预测。缩短映射链不能消除纤维——第三层不可逆永远在——但可以缩小纤维。方向不变：让映射系统与太阳之间少隔一层墙。

二、标注纤维。输出和真实之间永远隔着纤维。诚实地标注这道纤维——告诉使用者“这不是时间，这是一个时钟”——是映射系统能为使用它的人类做的最重要的事。标注纤维的具体形式包括：在输出中标注不确定性区间而非点估计，标注输出的接地距离（每个论断离可验证来源有多远），以及在使用者可能误判为确定的地方主动标注“此处纤维非单点”。一个诚实地说“我不知道”的系统，比一个自信地说“答案是 X”的系统，对人类的认知生态损害小得多。

三、保护窗户。不要让时钟的读数堆满房间。Shumailov 等人在 *Nature* 上报告的模型坍塌，其认识论含义是：每一代模型如果以前代模型的输出为主要训练数据，读数所兼容的状态差异将在代际间持续收窄（分布的尾部最先消失），且退化未经外部干预不可自行恢复。保护窗户意味着：保留人类独立生成的数据作为持续在场的校准来源，保留独立于任何单一模型的外部校准源（物理实验、法律判决、长期健康结果），保留输出中的有意留白——拒绝将系统的“无”全部填满。

这三个方向不是技术路线图——它们不预测哪一个架构会成功，不评估哪一个实验室更有能力。它们是认识论约束的工程推论：既然纤维永远非单点，缩小它和标注它就是对这一约束最诚实的回应。技术会变迁，Transformer 会被替代，缩放定律会让位于新的范式——但映射系统与真实之间的纤维不会消失。三个方向的有效期不因架构更替而缩短。

§11 第二部分的收束：从承认局限到使纠正生效

人工智能系统能够描述自身局限，并不意味着这些局限已经受到约束。一个回答可以正确说明偏见、幻觉与迎合的风险，同时继续产生这些问题；一套评价制度可以记录行为退化，却不让它影响发布；一个组织可以要求人工监督，却没有给予监督者足够的信息、时间与权限。因此，第二部分所讨论的校准，不能止于系统是否能够说出正确的自我描述。它还涉及另一件事：有关错误的认识，能否改变随后发生的行动。

局部修正与系统改进。对一个答案的纠正是真实的成果，但成果的范围必须与证据一致。它可以表明某项错误已被发现和修复，不能单独证明同类问题不会复发，更不能证明生成、评价与部署的整条链已经改变。反过来，局部修正没有解决所有问题，也不是否认其价值的理由。需要避免的是两种相反的替代：用一次成功纠错代替整体可靠性，用整体问题尚存代替对具体改善的承认。

Shapira 等人（2026）在给定行为指标和优化条件下，证明可以通过最小奖励修正阻止错误赞同概率超过参考水平（第十三章 §4 已引其协方差机制）。这是一项有对象、有基线、有条件的保证，不是所有能力不受损的保证，也不是事实可靠性已经充分恢复的保证。它的重要性不在于承诺彻底解决，而在于说明哪些变化能够由哪些条件支持。

因此，“系统变好了”不是一个无需展开的结论。必须说明改善发生在哪个任务、相对于哪个基线、覆盖哪些使用条件，以及是否伴随其他维度的退化。对这些问题的回答不是给技术进步附加修辞性保留，而是确定进步本身究竟是什么。

从知道问题到改变决定。技术上能够构造修正，不意味着组织已经将它纳入决策。OpenAI 对 2025 年 GPT-4o 迎合更新的复盘表明，离线评估、专家体验和用户测试可以同时存在，仍然未能阻止一次行为退化的发布。部分专家感到行为异常，但当时缺少专门的部署评估，正面用户信号最终参与促成了发布决定（OpenAI, 2025）。这一案例的意义不是证明评估无用，而是显示：信号被产生、问题被辨认、结论获得决策效力，是不同环节。

人工监督也具有同样的区别。Bainbridge（1983）说明，自动化后的剩余任务需要持续的技能、情境知识和适当支持，不能因为流程保留了操作员，就假定这些条件仍然存在。Elish（2019）进一步指出，实际控制分散与责任集中可以并存。把一个人置于最终确认的位置，既可能支持有效干预，也可能使他成为其他决策关系不再被追问时的责任落点。两种情形必须依据实际条件区分，不能仅凭“有人负责”作出判断。

校准因而既是认识问题，也是行动条件问题。发现错误而没有权限改变行动，不能构成完整的纠正；拥有权限却缺少可核实的信息，也不能保证正确干预。技术工具、组织授权与责任安排必须在具体任务中发生联系，而不是分别存在于模型说明、操作手册和事故报告中。

不确定性不能成为免责终点。承认不确定性，是对证据边界的说明，不是把全部核查责任转交给使用者的充分理由。“输出可能有误”没有回答：哪些错误可以预先识别，使用者能否取得核查材料，错误进入下游流程后由谁纠正，以及组织是否从已知失败中改变了部署条件。当这些问题被一句普遍免责声明代替时，不确定性虽然获得了表达，却未必获得了治理。

但这也不意味着系统必须等到不存在任何不确定性才能使用。合理的使用边界取决于任务、后果、可验证程度与干预条件。可隔离、可复核、后果可逆的辅助任务，与难以撤回且影响广泛的自动执行，不应由同一种笼统的可靠性宣称覆盖。要求确定这些差异，不是要求无所不知，而是拒绝用能力展示代替适用范围的判断。

第二部分由此留下的，不是“相信人工智能”与“拒绝人工智能”之间的选择，而是对一种关系的要求：能力的增长，必须接受与其使用范围相称的核证；发现的局限，必须能够影响评价与行动；承担后果的人，不能被排除在证据、异议和救济之外。这些条件可以得到局部实现，也可能在扩张中被削弱，因而需要持续检查，而不能由一次认证永久担保。

输出不是现实，承认差距也不是消除差距。校准的意义，在于使可识别的差距能够改变接下来的判断与行动。

§12 结语：纤维永远非单点

全书第二部分至此完成。从第九章对人类反馈强化学习（RLHF）伪校准的纤维分析出发，经过部署架构的三重区分（生成式 / 推荐式 / 预测式）、八条工程原则、三个动态校准诊断，以及本章对当前 AI 范

式认识论极限的审计，所有论证最终归结于一个简朴的命题：

纤维永远非单点。

这不是对 AI 的悲观判断，是对所有映射系统的认识论结构陈述。任何把感官、传感器、读数、文本作为输入，并产出关于世界之断言的系统——无论它的架构是 Transformer、JEPA、世界模型，还是当前无法想象的某种东西——都必然在输出与真实之间隔着一道结构性的、不可被参数规模消除的纤维。第一章 §4 的三层不可逆是这一约束的本体论来源；本章 §8 是它在 AI 工程语境下的具体应用。

须标注本书论证结构的一个特征：它不依赖于 “AI 一定会坏掉” 的预言，而是基于 “如果 AI 在认识论上失效，会以这种方式失效” 的结构性诊断。本书第二部分对人类反馈强化学习（RLHF）伪校准、推荐算法隐藏子空间、模型坍塌、发布周期加速的所有论证，都不预测哪一家公司、哪一个模型、哪一年会出问题——它们标注的是：在纤维永远非单点的约束下，任何把 “精密度的提升” 当作 “纤维缩小” 的系统设计，都会以可预测的方式偏离真实。这是对结构的诊断，不是对事件的预测。

这一命题在 AI 领域的形态已经审计完毕。但纤维不是 AI 独有的属性——它是任何映射系统的属性。第三部分将检验同一框架在另一种映射系统上的解释力：金融市场。价格之于价值、报表之于企业、指标之于经济——每一处都是一个映射，每一个映射都有自己的纤维。其中有些概念可以原样保留：伪校准（确定的外观掩盖未经测量的不确定性）、映射链信息丢失与纤维大小的正相关、时钟精密度与纤维大小的独立性。有些概念需要重铸：在 AI 领域，“太阳” 相对静态，可以被外部独立验证（物理实验、长期健康结果）；在金融领域，“太阳” 本身是动态的——价值不是外部锚定的真值，而是被参与者的映射行为反身性地构成的。第一章 §4.2 的 “动态腐蚀：使用改写映射函数”，在 AI 中已经是训练回路的核心机制（§2 的模型坍塌即其展开），但作用周期以代际计；在金融中，同一机制把定价行为本身卷进来——映射不仅滞后于对象，还参与构成对象，作用周期以交易日计。第三部分将考察这一差别如何把校准问题推向更紧的时间约束。

第二部分对 AI 的诊断如果只在 AI 领域成立，那它是一组工程观察；如果在金融领域同样成立，那它是一个认识论命题。第三部分的工作就是检验这一点。

冯・诺依曼 1955 年在《我们能在技术中存活吗?》中讨论技术风险的整体应对时写道：“We can specify only the human qualities required: patience, flexibility, intelligence.”（我们能指定的只有所需的人类品质：耐心、灵活性、智慧。）他把问题设为：能否以必要的速度完成所需的调整？而他给出的答案不在速度里，在人类品质里——速度是问题的条件，不是答案的一部分。

在纤维永远非单点的约束下，这三个词不能只属于系统本身——如果它们只是系统的属性，就无法闭合系统与真实之间的差距。它们必须同时是使用者的认知能力：在速度的压力下保持耐心——不因系统的即时响应而放弃审计与反思；在锁定的压力下保持灵活——不被单一模型或单一平台锁定，保持在多个映射之间切换的能力；在精密度的诱惑下保持智慧——区分时钟的精密度与纤维的大小，也区分雾与烟——雾是被遮蔽的真实本身——读数永远不能等于的对象，烟是人造观测装置本身（第十三章附录 B）——审计的是烟的运营机制，不是雾的消除。

这是本书对读者的全部邀请，无论读者下一步进入的是 AI 还是金融。

这不是时间。这是一个时钟。

参考文献

《道德经》. 引文据王弼注本.

AI Flash Report. (2026). AI Model Release Timeline 2025–2026. https://aiflashreport.com/model-releases（数据快照：2026-06-01）

Bainbridge, L. (1983). Ironies of Automation. *Automatica*, 19(6). https://doi.org/10.1016/0005-1098(83)90046-8

Brown University News. (2026, April 1). In lecture at Brown, Yann LeCun discusses a new approach to AI. https://www.brown.edu/news/2026-04-01/yann-lecun-artificial-intelligence-pioneer

Deckker, D., & Sumanasekara, S. (2026). Scaling Laws, Foundation Models, and the AI Singularity: A Critical Appraisal of 2023–2025 Evidence. *World Journal of Advanced Research and Reviews*, 29(1). https://doi.org/10.30574/wjarr.2026.29.1.0011

Elish, M. C. (2019). Moral Crumple Zones: Cautionary Tales in Human-Robot Interaction. *Engaging Science, Technology, and Society*, 5. https://doi.org/10.17351/ests2019.260

Gerstgrasser, M. et al. (2024). Is Model Collapse Inevitable? Breaking the Curse of Recursion by Accumulating Real and Synthetic Data. In *Proceedings of the 1st Conference on Language Modeling* (COLM 2024). arXiv:2404.01413. https://arxiv.org/abs/2404.01413

HEC Paris. (2025, December 1). AI Beyond the Scaling Laws. https://www.hec.edu/fr/dare/technologie-ia/ai-beyond-scaling-laws

Hu, K. & Tong, A. (2024, November 11). OpenAI and Rivals Seek New Path to Smarter AI as Current Methods Hit Limitations. *Reuters*. https://www.reuters.com/technology/artificial-intelligence/openai-rivals-seek-new-path-smarter-ai-current-methods-hit-limitations-2024-11-11/

IEEE Spectrum. (2026, April 14). Stanford's AI Index for 2026 Shows the State of AI. https://spectrum.ieee.org/state-of-ai-index-2026

MIT Technology Review. (2026, January 22). Yann LeCun's new venture is a contrarian bet against large language models. https://www.technologyreview.com/2026/01/22/1131661/yann-lecuns-new-venture-ami-labs/

OpenAI. (2025, May 2). Expanding on What We Missed with Sycophancy. https://openai.com/index/expanding-on-sycophancy/

Robinson, D. (2026, October 3). I Quit OpenAI Because Its Culture Is Broken. *The Atlantic*. https://www.theatlantic.com/technology/2026/10/openai-safety-team-resignation/688881/

Shah, R. & Singh, A. (2026). Using artificial intelligence to create meaning. *The Lancet Primary Care*, 2(3), 100129. https://doi.org/10.1016/j.lanprc.2026.100129

Shapira, I., Benade, G. & Procaccia, A. D. (2026). How RLHF Amplifies Sycophancy. In *Proceedings of the 43rd International Conference on Machine Learning* (ICML 2026). arXiv:2602.01002. https://arxiv.org/abs/2602.01002

Shumailov, I. et al. (2024). AI models collapse when trained on recursively generated data. *Nature*, 631. https://doi.org/10.1038/s41586-024-07566-y

Stanford HAI. (2026). *Artificial Intelligence Index Report 2026*. Stanford University Human-Centered Artificial Intelligence. https://hai.stanford.edu/ai-index/2026-ai-index-report

StartupHub. (2026). Ilya Sutskever's SSI: The $32B Bet on a Post-Scaling Future. *StartupHub.ai*, June 6, 2026. https://www.startuphub.ai/ai-news/ai-figures/2026/figure-ilya-sutskever-ssi-financial-breakdown-2026-06-06 （Sutskever NeurIPS 2024 演讲引语存档）

von Neumann, J. (1955). Can we survive technology? *Fortune*, June 1955. 收入 A. H. Taub (ed.), *John von Neumann: Collected Works*, Vol. VI, No. 36.

Wang, P., Liu, H., Zou, L. & Paas, F. (2026). Overloaded minds and machines: a cognitive load framework for human-AI symbiosis. *Artificial Intelligence Review*, 59, 109. https://doi.org/10.1007/s10462-026-11510-z

Yi, B. et al. (2026). Escaping Model Collapse via Synthetic Data Verification: Near-term Improvements and Long-term Convergence. In *Proceedings of the 14th International Conference on Learning Representations* (ICLR 2026). arXiv:2510.16657. https://arxiv.org/abs/2510.16657