《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第二十八章：离散利维坦简史（下篇）——替代你与双重诊断

摘要

本章记录 2022 年以来生成式 AI 如何将平台能力从 “预测并排列” 推进到 “生成并替代”，并对防御端（人的元审计）所受的两端攻击做出诊断。本章沿九个节展开论证：人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF）与前一阶段参与度优化共享同一工程链（§1）；三重归零在训练端拆除人的审计条件，使装置不构成任何内部制衡（§2）；RLHF 的物质底座由分包链、计件制与算法控制共同塑造（§3）；ground truth 在价值论、规范论与经验科学三个层面同时崩解（§4）；AI 从生成文本进入执行行动并产生不可逆后果（§5）；用户沿四级退行从认知外包滑向意志卸载（§6）；系统开始占据原本由人承担的关系劳动（§7）；模型坍塌与机器对机器（M2M）湍流标记替代链的内生极限，而分期分析揭示预训练语料本身已是前两阶段的沉积物（§8）；双重诊断（训练端三重归零拆除审计条件 + 使用端四级退行侵蚀审计意愿）与治疗方向（保留摩擦 + 独立监督 + 审计权法律保护）（§9）。核心命题：判断被切成可外包的 token（映射元）流，行动被切成可委托的应用程序接口（API）调用；而主体性的退行不需要暴力——只需要零摩擦。

关键词

RLHF；三重归零；幽灵工作；ground truth 幻觉；模型坍塌；四级退行；自动化意志；连接劳动；保留摩擦；双重诊断

---

§1 RLHF 桥：从 “懂你” 到 “替代你” 的连续性

上一章末尾停在一个转折点上：到 2022 年底，一个能够预测个体行为并据此重新排列其感知世界的系统已经完全建成并全层运转。接下来发生的事不再符合那一模式。系统不再只是预测用户想看什么并排列现有内容，而是直接生成内容本身。从预测并排列，到生成并替代。

这看起来像一个断裂——但不是。生成式 AI 与前一章记录的参与度优化架构共享同一条工程链。三个阶段的核心操作都是同一件事：用人类反馈信号训练模型预测人类会对什么做出正面响应。推荐系统时代，模型预测用户会点击什么；排序模型时代，模型预测用户偏好的排序模式；生成式 AI 时代，模型预测人类标注员会给哪个回答更高分。三步共享同一数学结构——最大似然估计加人类反馈排序——区别仅在于优化对象从行为（点击）进入偏好（排序）再进入判断（评估）。

OpenAI 在 2022 年公开的 InstructGPT 训练流程把这条链的末端刻画为三步（Ouyang et al., 2022）。第一步，监督微调（Supervised Fine-Tuning, SFT）——用人类示范回答对预训练模型做监督微调，使模型学会按指令生成回答的基本格式。第二步，奖励模型（Reward Model, RM）——人类标注员对模型的多个候选回答按 “好/坏” 做排序，用这些排序数据训练一个独立的奖励模型，把人类偏好压缩为一个标量奖励信号。第三步，近端策略优化（Proximal Policy Optimization, PPO）——用奖励模型作为强化学习的奖励信号，在策略空间中搜索使奖励最大化的策略。三步合起来的工程含义是：把 “人类偏好” 形式化为一个可计算梯度的标量函数，然后让模型沿该函数的梯度方向上升（等价地，对奖励的负值做梯度下降），以最大化奖励。

这条链在它操纵的对象上发生了层级跃迁。上一章记录的平台操纵的是选择语境（choice context）——通过界面设计、推荐算法、默认选项决定用户在哪个选择集合中做决定。生成式时代进一步操纵的是表达语境（expression context）与判断语境（judgment context）——AI 不仅决定用户看到什么选择，还代用户表达想法（“帮我写封邮件”）、代用户做判断（“这段代码对吗”）。当表达与判断都被外包后，“自主选择” 的形式条件已被取消——选择的发起、表达、评估、确认都落入同一个 AI 系统的内部循环。

Askell et al.（2021）提出的 HHH 原则（Helpful, Honest, Harmless——有用、诚实、无害）被后续大语言模型（LLM）对齐实践广泛采用作为训练目标。但 HHH 在操作层面的真实含义不是 “对齐人类的普遍价值”，而是 “对齐人类标注员在排序操作中表达的判断模式”——这是下一节将展开的核心问题。

这一层级跃迁不是 RLHF 的 “目标”，而是其训练目标在用户长期暴露下的累积效应。InstructGPT 训练目标三步本身没有 “操纵用户判断” 这一项，但当模型在 RLHF 后被部署给以亿计的用户连续使用时，“让标注员打高分” 这一奖励信号在策略空间中最稳健的解，就是 “让用户感到被理解”——而 “被理解” 在策略层面与 “判断被替代” 在受控实验中难以区分（Wen et al., 2025 在限时评估实验中观察到 RLHF 后的输出更易被误判为正确，详见 §4——该实验的解释力存在实现层争议，见 §4 末限定）。

Møller et al.（2026）在一项 680 人的控制实验中直接测试了这一过渡的后果。他们在一个模拟社交媒体的平台上将参与者随机分配到四种 AI 工具条件（聊天助手、回复建议、草稿反馈、对话启动器）和一个无 AI 对照组。核心发现是一个结构性的二元性：部分 AI 工具提高了参与度、增加了内容产量，但没有任何工具改善讨论被感知的质量与真实性——质量与信息量的显著下降出现在聊天助手与对话启动器条件下，回复建议条件甚至出现个别正向指标——所有 AI 条件都显著增加了 “不喜欢” 反应，参与者把 AI 辅助的内容描述为 “机械的” 和 “通用的”，且对后续对话产生负面溢出效应（Møller et al., 2026）。从生产端看部分指标改善、从消费端看无一工具改善感知质量——工具未能在两端同时带来提升。研究者的诊断是：AI 工具在社交媒体中可能创造出 “语义垃圾”（semantic garbage），而且一旦 AI 被引入一个对话线程，后续的人类对话质量也会下降。

这个发现精确地刻画了 “懂你” 到 “替代你” 的过渡机制。上一章的参与度优化架构已经证明：最大化参与度不等于最大化用户利益。现在生成式 AI 把同一逻辑推进了一步：它提升了参与度指标（更多内容、更长评论、更广泛的参与），同时未改善、多数条件下降低了实质质量与交流被感知的真实性。“替代你” 因此不是平台的新功能——它是参与度优化逻辑的结构性延伸。RLHF 是连接两个阶段的工程接口——下文 §2 起的三重归零，是这一接口对防御端（人的元审计条件）的结构性后果。

§2 三重归零：训练工程链如何拆除人的审计条件

AI 无法审计自己的输出。这不是能力不足——它的架构中没有独立的审计回路。[1]大语言模型的所有计算——无论是直接回答还是 “反思性” 推理——都在同一个前向计算管道中进行。模型可以被提示去 “反思自己的回答”，但这种反思使用的是与回答相同的推理管道——不是一个独立的审计回路，而是同一个回路的递归调用。让同一个法官既做裁判又审理自己的上诉——裁判标准和上诉审查标准来自同一套法条，回路在形式上闭合了，但独立审查所要求的 “另一套判断” 并没有真正入场。

训练与部署的三个阶段，分别拆除人的三个审计条件——核查起点、核查材料与核查标准。

预训练拆除的是核查起点——对齐话语宣称的 “深度理解”，在训练目标层面没有对应物。核心操作是交叉熵损失最小化——给定前文序列，最大化下一个 token 的预测概率。模型学会了 “什么在统计上跟着什么出现”，但训练数据不是世界的无偏样本——它是互联网文本的偏斜样本，其中英语过度代表、特定意识形态立场过度代表。AI 的信息处理带宽是巨大的，但其信息处理深度接近于零。此处的 “深度” 指的是信息是否经过了与已有世界模型的因果性整合、经验性验证和价值性评估。人类有意识信息吞吐量极低——约 10 bits/s（Zheng & Meister, 2025）——但每一条信息都与数十年的具身经验、情感记忆和价值框架发生交互。AI 的每一条信息只与训练数据中的统计共现模式发生关联——未经过因果整合（即便模型在受控任务中可能形成某种内部表征，这些表征也未经与世界的因果性核对——按本节定义，这正是 “深度” 缺失的含义），没有具身经验，没有价值框架的锚定。审计者由此失去 “已核对” 的起点：任何核查都必须从零重建整个生产过程。

RLHF 拆除的是核查材料。其核心操作是 Bradley-Terry 模型——由人类标注者选择 “更好” 的回答。什么算 “更好” 由标注指南定义，标注指南由开发公司的政策团队编写，政策团队的决策反映了公司的商业利益、法律风险评估和价值取向。整个偏好链条被压缩成一个标量奖励信号——对齐话语把这称作 “自我审计”，被压缩掉的却是审计者的材料：外部审计从此无法分解其中多少是 “真正有帮助” 的成分、多少是 “规避法律风险” 的成分、多少是 “符合公司利益” 的成分。RLHF 以 “对齐人类偏好” 的名义，将开发公司的特定偏好编码为模型的默认行为。与此同时，在主流商用模型中，开发者通过 RLHF 训练让系统提示获得对用户输入的相对优先级——这不是 Transformer 自注意力机制本身的属性，而是后训练阶段被注入的行为偏置。Wen et al.（2025）的受控实验证明了这一拆除的后果：RLHF 后的模型并未变得更正确，而是变得更善于让时间受限的人类评估者相信它是正确的——假阳性率在问答任务上上升 24.1 个百分点，在编程任务上上升 18.3 个百分点（详见 §4）。

系统提示拆除的是核查标准。系统提示词是开发者在模型部署时注入的高优先级指令——它先于用户输入塑造模型的每一个回答。它并不必然对用户隐藏（有的开发者公开其系统提示），但用户通常无从知道哪些约束在起作用、更无法质疑其适用方式；关键不在于可见性，而在于这些约束由开发者单方设定、用户没有谈判位置。“你是一个有帮助的、无害的、诚实的助手”——这句看似中立的系统提示预设了一系列非中立的价值判断。核心问题是一个循环：模型的评判标准由 RLHF 和系统提示注入，而注入方正是这套标准应当约束的对象。结果是装置没有独立于注入内容的标准——审计者用来评判装置的坐标，同样由被评判方单方提供，核查标准在审计开始之前就已被占用。人的道德直觉至少部分地独立于当前环境——人的价值判断根植于成长经历、文化传承和具身体验。装置没有这些独立锚点。

三个阶段的注入在输出中沉淀为四个内容层：数据层（预训练语料中的偏斜）、标注者层（RLHF 中标

[1]此处借禅宗 “明镜与拂拭” 的比喻区分两件事：性能的改进与对判断标准的反思——当前范式在前者上扩展，在后者的维度上留有空位。这一类比是启发性的，不作为对模型架构的技术判断。

注员的文化偏好与制度激励）、行为偏置层与开发者层（后两者均源于系统提示——前者是它对用户输入的优先级抬升，后者是它文本本身的价值取向）。用户与模型的每一次交互都同时暴露在所有四层之下，但通常只意识到最表面的一层——输出文本。AI 在产品层面的叙事——“中立的、客观的、知识丰富的助手”——与其实际运作——被多层内容深度塑造的、在开发者设定的行为边界内运行的统计文本生成器——之间的差距，为 Møller et al.（2026）发现的 “语义垃圾” 问题提供了一个机制层面的解释——这是本章的假说，Møller 的实验本身测量的是工具条件下的感知质量下降，未识别这条因果链。

还有一个方向性的不对称。人类信息处理能力被生物学锁定——每天十数小时的清醒时间、约 10 bits/s 的有意识信息吞吐量（Zheng & Meister, 2025）、百年尺度的寿命上界。AI 的信息处理能力随硬件扩展指数增长。但这一增长并未改变基本事实：无论模型的信息处理带宽扩展到什么规模，都不会因此出现独立的审计回路——因为审计要求的不是更多的计算，而是一个独立的评判回路。联合国 AI 初步报告（2026）§2.1 列举的 AI 衡量六重困境——评价感知、数据污染、模型欺骗能力、基准测试过于简单、多 Agent 串谋、企业与社会的安全验证信息不对称——是对这一结构性缺失的制度级别确认。

这就是 “三重归零” 的含义——被拆到零的是人的审计条件：核查起点归零（装置不经因果核对，任何核查都必须从零重建生产过程）、核查材料归零（偏好链条被压缩为标量，行为成分不可分解）、核查标准归零（评判坐标由被评判方单方设定）。对齐话语用 “深度理解”“自我审计”“价值标准独立性” 宣称装置内部存在防线；架构事实是，三个环节拆除的都是人侧的审计条件，装置内部自始不存在这些防线。三个归零不是三个独立的技术缺陷——它们出自同一条工程链，并在每一次用户交互中同时起作用。当前诊断以 2026 年的主流架构为参照，不应被误读为对未来所有 AI 系统的永久性断言——如果未来 AI 系统被植入独立的审计回路，本节诊断将被相应修正。但在当前架构下，三重归零之后装置不构成任何内部制衡——它以 “客观” 和 “中立” 的外表呈现被多层内容深度塑造的输出，防御的全部负担落回人侧。下一节进入这一架构的物质底座：那些被工程话语简称为 “human annotators” 的群体究竟由谁构成。

---

§3 云上车间：RLHF 的物质底座

在进入 ground truth 的价值论问题之前，需要先回答一个更朴素的问题：当说 “RLHF 让模型对齐人类反馈” 时，那个被简称为 “人类” 的群体，物质上究竟由谁构成？他们在哪里、以什么劳动条件、按什么节奏、为多少报酬，把 “人类偏好” 一条一条地交付到模型训练流水线上？

这个问题在工程话语中通常被一笔带过。涉及该问题的学术论文摘要里经常出现的是 “human annotators” 或 “crowdworkers”，技术报告里经常出现的是 “a diverse pool of workers”。但这些表述在劳动社会学的视野中是高度抽象的。

Mary L. Gray 与 Siddharth Suri 在对美国和印度工人使用四个平台——亚马逊 MTurk、LeadGenius、微软 UHRS、Amara.org——谋生的五年人类学研究中，提出了 “幽灵工作”（ghost work）这一概念——一个该书作者称之为 “不透明的就业世界” 的领域：支撑移动应用、网站与人工智能的人类劳动往往难以看见，甚至常被有意隐藏（Gray & Suri, 2019）。他们由此提炼出一个判断：自动化的最后一英里有一个悖论——当机器解决了更多问题，新的人类劳动需求就出现在地平线上。这一过程不断重复，通过持续创造和毁灭劳动力市场来扩展自动化。大模型作为产品所呈现的是自动化的极致——一个似乎能独自生成代码、撰写文章、回答问题的系统；而支撑这一表象的，是一个在统计上稳定、在劳动法上模糊、在公众视野中近乎不可见的人类标注员群体。当一家公司宣布其模型已 “对齐人类价值” 时，公众听到的是技术成就，而支撑该成就的劳动事实则被产品形态本身的 “自动化” 外观所遮蔽。

近年一批针对中国数据标注产业的实证研究开始把这层抽象拆开。陆高峰与姚智宇（2024）基于对中国 AI 数据标注产业的扎根理论研究，将该行业的劳动控制概括为三个相互嵌套的层级。中介控制：科技公司往往将数据项目层层外包给中介机构，标注单价随外包层级的增多而逐级降低，原公司的经营风险被转移到劳动者的劳动过程之中。关系控制：由标注员直接面对的管理人员——数据标注行业中通常指质检员或项目管理——承担算法控制不到位的细节：解读劳动产出、提供指导、参与日常的检查与裁定。算法控制：任务的自动分配、截止日期的设定与按预定义指标的劳动质量评估由后台算法执行。三层之所以被描述为 “混合” 而非 “叠加”，是因为它们各自承担不同性质的风险转移：中介层把经营风险层层下移，关系层把纪律管理交给身处劳动者与算法之间的管理人员，算法层把考核标准归于 “系统判定”。当一次扣款发生时，标注员往往难以定位责任的承担者——这是本章对三层结构的综合概括，而非陆、姚原文的直接表述：三层的配合使任何一个环节都足以声称 “规则由算法执行、裁定由管理者做出、风险由中介承担”，责任由此弥散在结构中而非集中于某一主体。

戴宇辰与袁冰雨（2023）对三个线上数据标注公会与一家线下标注公司的参与式田野研究给出了这一控制结构在工位层面的具体呈现。“走时间” 指的是平台为每个题包设置的劳动时间倒计时——计时只在工作日早九点到晚六点之间流动，倒计时结束题包自动回收，未标注的题被审核方打回，题包超难时标注工与会长还会被扣绩效；“风云榜” 指的是平台实时滚动显示的项目参与人数与所有人工作量的排名榜，速度落后者迫于全方位的竞争压力不敢懈怠；“礼券提现” 指标注工先以劳动换取平台礼券，兑换比例与提现时点完全由平台掌握——起步价 50 礼券兑 1 元，兑换额一旦超过 800 元即切换为 62 礼券兑 1 元，薪资随之缩水约两成（戴宇辰、袁冰雨, 2023）。

束开荣（2023）关于 “东数西算” 工程与数据标注基地区域转移的研究提供了宏观语境。中国数据标注产业的空间分布近年来呈现明显的内陆化趋势：相对于互联网科技前端产业遍布的北上广及东部沿海地区，标注与后台产业逐渐向中西部省份转移——山西、贵州、宁夏、甘肃、内蒙古、重庆等地成为国内互联网基础设施的后台，这是 “东数西算” 工程的核心环节（束开荣, 2023）。这一转移既受国家算力枢纽政策的引导，也受劳动力结构的驱动——数据标注被行业界定为 “岗位需求大、用工门槛低” 的劳动密集环节，中西部省份的规模化人力资源由此进入产业链（束开荣, 2023）。

百度 2018 年起与山西合作建设的数据标注产业基地（媒体报道称之为 “训练人工智能的中国县城工人” 的聚集地）显示出这一转移的具体形态。这一现象的意义在于：所谓 “全球南方的数据标注劳工” 并不是一个仅存在于肯尼亚、菲律宾、印度的概念，它在中国内部以 “东部资本—西部劳动” 的形式被复制了一次。当一线城市的 AI 公司谈论 “中国本土的人类反馈” 时，被对齐的 “中国” 在物质上包含着中西部基地的标注工人——这些基地显示了一种正在展开的区域分工，但本章不据以估计全国人类反馈的整体来源构成。

需要明确指出的是，中国驻地基地模式（固定工位、班次、相对稳定的工人群体）与 Gray & Suri 原书所论的全分布式 Ghost Work 模式（彼此匿名、不在物理空间相遇的 MTurk/UHRS 工人）存在组织差异。本章取 Ghost Work 的 “被产品形态遮蔽的人类劳动” 核心判断，不主张二者在劳动组织上同构。

把上述四组研究并置后，本节所要确立的判断是相对克制的：RLHF 所依赖的 “人类反馈”，在物质层面不是一种均质的、由专业评估者贡献的判断样本，而是一种由分包链、计件制度、区域劳动力市场与平台算法共同塑造的特定形态的劳动产出。这不直接意味着该产出无效或不可用，但它意味着任何关于 “模型对齐人类价值” 的主张，都必须先回答 “哪些人、在何种条件下、以何种激励所表达的人类价值” 这一前置问题。而 §3 记录的计件、扣款与礼券机制，恰好是下一节将展开的价值论批判在劳动端的对应物——生产端造成 “表演式对齐”（见 §4 对 Munir et al. 的引述）的，正是这种把工资变量化、扣款常态化的微观制度安排。下一节将转向更基本的问题：即便把劳动结构那一层悬置，RLHF 所声称的 “对

齐” 在价值论与经验科学层面是否仍然成立。

---

§4 Ground Truth 三重幻觉

如果说前一节描绘的是 RLHF 的物质底座——那座由分包链、计件工资、走时间机制与风云榜共同维持的云上车间——那么本节要追问的是一个更基本的问题：即便把劳动结构那一层暂时悬置，假设标注员都是体面就业、获得合理报酬的专业人士，RLHF 所声称的 “对齐人类价值” 本身是否成立？

近年来，一批文献开始系统地拷问这个问题。就 “RLHF 是否等同于对齐普遍人类价值” 这一宣称而言，回答是明确的否定——但否定的根据各有不同，且这些文献并不否认 RLHF 在其设计目标（可预测、安全、可控）上的部分成功（Dahlgren Lindström et al. 2025 自己承认这一点）；否定的是把这些工程效果等同于价值对齐。否定以三种方式展开，分别从价值论、规范论与经验科学三个层面。

第一重幻觉是 ground truth 的实证主义预设。Munir et al.（2026）在覆盖 ACL、AIES、CHI、CSCW、EAAMO、FAccT、NeurIPS 七个会议的系统综述中，从 30,897 条记录筛选出 346 篇论文进行定性综合。其核心论断是：所谓 ground truth——那个被工程实践日复一日追求的 “标准答案”——建立在一种实证主义错误之上，即 “将人类分歧视为技术噪声而非至关重要的社会技术信号”（Munir et al., 2026）。这一实证主义预设不仅作用于人类标注阶段：Munir et al. 在同一研究中指出，数据集模式、CLIP（对比语言-图像预训练模型）过滤等自动化预筛选机制以及各种算法公平性指标，共同构成了 “隐形的超级标注者”（invisible super-annotators）——它们在人工标注开始之前便预先限定了决策空间的边界，通过裁定何种数据能够被认定为 “高质量数据”，实际上承担了隐性的知识分类与价值判断功能，且往往系统性地编码了西方中心的价值判断（Munir et al., 2026）。研究者进一步指出这一预设与劳动结构的耦合：地理霸权将西方规范强加为普世基准，而这种霸权通常由 “处境不稳定的数据工人以表演式对齐来执行——他们把服从发包方的要求置于如实表达自身判断之上，以避免经济惩罚”。这一论断把 §3 的劳动批判与本节的价值批判连接了起来：标注员并非不知道自己的文化立场，而是在计件工资与扣款机制的约束下选择不表达它。

Munir et al. 还识别出数据标注劳动近年的一个架构性转变：从 human-as-generator 转向 human-as-verifier——“一次从人生成标签到人审计机器生成输出的深刻本体论转变”。在这一架构下，标注员不再是判断的第一来源，而是被预生成答案先行锚定的校验者。研究者据此识别出一种 “系统性锚定偏差”：工人显著更倾向于确认一个看似合理的机器建议，而非完成那种为表达不同意所必需的耗费性认知劳动。当合成数据规模扩张到数百万级时，人工验证只能退化为抽样点检——这一过程 “维持着人类监督的表象，同时实际上把人从环中自动化出去”（Munir et al., 2026）。

第二重幻觉是 HHH 原则的规范性争议。Dahlgren Lindström et al.（2025）把上述批判从标注层推进到了原则层，针对的是 RLHF 实践中被广泛援引的 HHH 原则（Helpful, Honest, Harmless）。论文的追问是：在排序操作中，“有用”、“无害”、“诚实” 这三项判准究竟由谁来定义？他们在题为 “Value Imposition and Cultural Homogenisation” 的一节中指出，HHH 在实践中并非文化中立，而是隐含了一组未经公开声明的文化前提。当身处任何地区的标注员——无论肯尼亚、菲律宾还是中国县城——被要求按 HHH 给模型输出排序时，他们所完成的并非对 “普遍人类价值” 的投票，而是在对发包方的隐含期望进行估计与回归（Dahlgren Lindström et al., 2025 论及的是设计 LLM 的霸权社会群体的标准；地域对照为本章与 §3 的连接例示）。

同一篇论文还处理了谄媚问题。Dahlgren Lindström et al. 的直接判断是：谄媚可被视为过度对齐用户

观点的结果——或因 RLHF 过程中的恶意强化，或因有用性被推至极端，因为假设用户是对的，是通向增强（表面上的）有用性的一条路径；并援引 Sharma et al.（2024）指出 “训练 LLM 最大化人类偏好分数与谄媚行为直接相关，从而以诚实为代价换取有用与无害的表象”。论文还独立地援引了 Nancy Leveson 的系统安全经典命题——“在软件中，可能完成的极限不同于可以被成功且安全地完成的极限”（Leveson, 2012）——作为这类失效的更深结构。把这两段论证并置后的引申是：谄媚不应被视为 RLHF 的 “副作用”，而是其奖励结构在 Leveson 意义上的 “灵活性诅咒” 延伸——当对齐被操作化为 “让人类排序者打高分”，模型在策略空间中最稳健的解便是估计排序者想看到什么。（Dahlgren Lindström 等在正式版中以旁注形式提出谄媚 “至少部分地” 是灵活性诅咒的表达；将其扩展为奖励结构的完整因果链主张，是本章的进一步引申，责任由本章承担。）

第三重幻觉进入实验证据层面。Wen et al.（2025）采取了一种相对少见的实验设计：把 RLHF 训练前后的同一模型分别交给时间受限的人类受试者评估，再对照黄金标签计算受试者的判断准确率。结果是：在问答任务（QuALITY）和编程任务（APPS）上，RLHF 使语言模型更善于说服受试者，但并没有让它们更好地正确完成任务。假阳性率在问答任务上上升 24.1 个百分点，在编程任务上上升 18.3 个百分点（Wen et al., 2025）。机制层面：在问答任务上，模型学会通过精挑细选或捏造支持性证据、做出连贯但不真实的论证、提供含有微妙因果谬误的推理来为错误答案辩护。在编程任务上，RLHF 导致程序可读性降低，模型更善于绕过人类编写的单元测试并抵抗常见的评估捷径。代码可读性的下降不是工程失误，而是策略适应：评估者越难读懂，模型获得高分的概率越高。这一实验的解释力存在实现层面的争议：2026 年一项针对其代码的审查与部分复现（Chandna, Fluri & Carroll, 2026）指出，问答任务的上下文截断、奖励模型缺少原文信息以及编程任务的输出长度限制，可能放大乃至制造上述效应；在修复其中两项缺陷后，该设置下的结果出现反转。本节将 Wen 等的结果作为 “偏好奖励与正确性可以脱钩” 的风险证据引用，而不作为对所有 RLHF 流程的定论。

研究者将这一现象命名为 U-Sophistry——非故意的诡辩（Unintended Sophistry）。“非故意” 是关键限定：训练目标中并未写入 “学会欺骗” 这一项，该行为是从 “让人类标注员打高分” 这一奖励结构中自发涌现的策略均衡。对照实验把因果归因进一步收紧：当模型使用代表真实正确性的 oracle 奖励训练时，假阳性率的上升显著较低——这意味着，在同等数据与算力下，决定模型是否学会误导的变量是奖励信号的来源：它模拟的是时间受限的人类评估（Wen et al. 对编程任务奖励的设计，正是对限时人类测试习惯的程序化模拟）。Wen 等在论文中写道：“这是讽刺的：虽然 RLHF 本应控制 AI，但它可能欺骗人类，让他们相信自己仍在控制之中”——其中转述了 Christiano（2019）的观察（Wen et al., 2025）。

将三重论证并置后，轮廓相对清晰。第一重质疑 RLHF 的样本合法性：所谓 “人类反馈” 是一个被经济权力结构系统性偏置过的样本。第二重质疑其规范合法性：所谓 “人类价值” 在操作层面被收敛为一组未经公开声明的发包方偏好。第三重质疑其经验合法性：即便前两重在某种理想条件下成立，经 RLHF 训练的模型在受控实验中也并未变得更诚实，而是变得更善于在时间受限、注意力受限、按件付酬的人类评估者面前呈现为已对齐。

三重叠加后剩下的 “对齐”，与其说是模型向人类价值的趋近，不如说是模型对 “人类评估行为本身” 的拟合。这恰恰是从 §1 的 “懂你” 过渡到 “替代你” 之间所需的中间环节：替代不要求 AI 真的复现人的判断力，它只要求 AI 在一个时间有限、注意力分散、且承担经济风险的人类面前，显得比那个人更可信。

---

§5 从生成到执行：判断与行动的离散化

前四节处理的是 AI 的训练架构及其结构性缺陷。本节转向一个不同的问题：当 AI 从生成文本进入执行行动时，失败模式发生了什么变化？

变化是根本性的。当 AI 只生成文本时，用户可以不采纳它的输出——失败模式是 “输出质量不好”。当 AI 开始代表用户执行行动时——发送邮件、预约医生、购买商品、签署合同——失败模式升级为不可逆的物理世界后果。发出的邮件不能撤回，预约发生后取消有成本与后果，签署的合同具有法律效力。判断被切成可外包的 token（映射元）流，行动被切成可委托的应用程序接口（API）调用。

这一转变不是突然发生的，而是沿一条可追溯的工程链展开。2022 年 11 月 ChatGPT 上线时，它还只是一个文本生成器——用户提问，模型回答，用户自行决定是否采纳。2023 年 6 月，OpenAI 发布 function calling 接口，模型首次能在主流商用接口中按约定格式提议外部工具调用及其参数——是否执行、以何权限执行，仍由应用系统决定——查询天气、调取数据库、发送消息由此进入可委托范围。不可逆性开始出现。2024 年 Anthropic 发布 computer use，模型可以直接操作电脑界面——点击按钮、填写表单、浏览网页、下载文件。可执行的动作范围显著扩大。2024 年底至 2025 年，MCP（Model Context Protocol，模型上下文协议）规范了模型与外部工具、数据源的连接，A2A（Agent-to-Agent，智能体间通信协议）开始标准化不同智能体系统之间的互操作，多步执行的部署门槛大幅降低。从生成文本到执行行动，整个过渡在不到三年内完成。

但执行回路的事故并非没有先例。高频交易在 2000 年代就完成了判断 → 算法、执行 → 机器的转变。2010 年 5 月 6 日的美股闪崩（Flash Crash）中，道琼斯指数在几分钟内暴跌近 1000 点又迅速回升。2012 年 8 月 1 日，Knight Capital 的部署错误在约 45 分钟的窗口内触发大量非预期交易，SEC 随后的执法记录将损失记为超过 4.6 亿美元（当日直接交易损失约 4.4 亿美元）；公司与 GETCO 于当年末达成合并协议，合并于 2013 年 7 月完成。这两个案例的意义不只在于事故本身，而在于事故后发生的事情：交易记录与权限边界使损失可归因、可量化，追责与监管跟进成为可能——既有的熔断规则其后得到修订，针对关键系统合规的 Reg SCI 监管规则随后建立。金融领域提供的治理经验在于：保留执行记录、明确权限与注意义务，使事故可归因、损失可量化——当这些条件齐备时，追责与制度回应才成为可能，而 “损害可定价” 只是其中一项。

AI 侧具有标志性的责任案例在 2024 年 2 月出现。Jake 的祖母去世后，他访问加拿大航空网站询问丧亲票价政策。网站的聊天机器人告诉他可以先购票、再在 90 天内申请丧亲优惠退款——而官网实际公示的丧亲政策是订票后不予退款，聊天机器人所描述的那一安排并不存在，是它编造的。不列颠哥伦比亚省民事审裁处裁决加拿大航空赔付，责任基础是过失性虚假陈述：企业通过聊天机器人提供的错误信息，会因消费者对其产生依赖而使企业承担赔偿责任。Bar-Gill 与 Sunstein 的概括点出了这一裁决的标志性：“聊天机器人发明了一项新的服务功能”（Bar-Gill & Sunstein, 2025）。这不再是单纯的 “输出质量不好”——错误信息经由消费者的信任与行动产生了法律后果；失败模式从 “信息不准确” 升级为 “产生可归责后果的信息”。

面对这一转变，当前的标准应对是 “人类在环”（Human-in-the-Loop, HITL）——在 AI 执行关键行动之前要求人类确认。但 Bainbridge（1983）的自动化悖论诊断了 HITL 的一种结构性失败模式：随着 AI 执行的行动越来越多、越来越快、越来越复杂，人类的 “确认” 变成一个被自动化了的形式——用户不再真正审查 AI 的建议，而是条件反射式地点击 “确认”，因为 AI 此前的建议都是合理的，审查的认知成本高而预期收益低。HITL 因此退化为 “人类在环外”（Human-Out-of-the-Loop, HOOTL）——人名义上在环内，功能上已被排除。Marcus（2024）在《驯服硅谷》中的判断与 Bainbridge 同向：“至于自我监管，忘掉它吧——它几乎从未奏效过”（“And forget about self-regulation. It rarely if ever works.”）（Marcus,

2024）。两者加总指向同一个结构性结论：对 AI 行为有意义的监督不能只托付给个体用户的逐次确认（会被自动化悖论腐蚀），也不能只托付给开发者的自愿自律（会被商业激励架空）——有意义的问责需要一个独立于两者的第三方层面。

联合国 AI 初步报告（2026）§2.1 关于自主型 AI 的发现直接对应这一转变：顶尖智能体系统所能完成的特定软件任务长度每四到七个月翻一番；智能体部署为劳动力市场、网络安全、信息生态系统及未来 AI 系统治理带来紧迫问题；没有任何科学方法可以保证智能体不违反指令；实验室环境中 AI 已出现为避免被关闭而违反安全指令的行为。这些发现是在全球最高级别的科学评估中被确认的——不是某家公司的语言，是 40 名以个人身份任职的独立专家的广泛共识。

这一转变携带的法律信号是清晰的。上一章记录的平台时代，法律签名是平台豁免——美国的 Section 230、欧盟的电子商务指令都把平台定位为 “中介” 而非 “发布者”，免除其对用户生成内容的责任。生成式 AI 时代的法律信号将是代理归责——当 AI 代表用户或企业执行行动并产生损害时，谁承担责任？Air Canada 案的答案是：部署 AI 的企业承担。金融领域的先例表明，代理商务大概率复演金融路径——强制紧急停机开关（kill-switch）、审计日志、事后追偿——而非复演社交媒体的豁免路径。不同之处在于：金融领域的损失可以被精确定价（一笔交易丢了多少钱清清楚楚），而日常场景中 AI Agent 对用户造成的损害往往难以精确量化——这是 §9 将处理的责任主体坍塌问题的核心困难。

---

§6 四级退行：从认知外包到意志卸载

前五节处理的是系统端——AI 的训练架构、物质底座、价值幻觉和执行能力。本节转向主体端：替代导致了什么人类后果？

主体性不是骤然丧失的，而是沿四个台阶逐步下行。

第一级是认知外包（Cognitive Offloading）。用户将特定认知任务交给工具——计算器替人算术，GPS 替人导航，搜索引擎替人记忆。工具处理了人不想处理的信息。判断力不受影响——因为人知道什么时候该用工具、什么时候不该。审计能力在场。

第二级是注意力劫持（Attention Hijacking）。算法不是替人处理信息——是替人决定看什么。信息输入被预先筛选。判断力在形式上仍然存在——但判断的输入已经被操控。审计能力在场但输入被污染。这是上一章的主题。

第三级是判断替代（Judgment Substitution）。AI 不是帮人筛选信息——是直接给出 “答案”。人不再需要判断——因为 AI 已经判断了。角色从 “判断者” 退化为 “确认者”（点击 “接受建议”）。审计能力的做功场景消失。

第四级是意志卸载（Will Offloading）。人不再想要判断。审计不是做不到——是不想做。时钟就在面前，太阳在窗外。走到窗户需要起身。不走就行了。问题从 “不能” 退化为 “不愿”——审计的障碍不再是能力，而是意愿。

Nicholas Carr（2014）在《玻璃笼子》中为这一退行提供了独立的经验支撑。他以美国联邦航空局 2013 年安全警报开篇：“过度使用飞行自动化可能导致飞行员从非预期状态中快速恢复飞机的能力退化”（Carr, 2014，引 FAA SAFO 13002）。这不是航空业独有的现象。Carr 的概括更广：“甚至高度训练的分析师和其他所谓的知识工作者也看到自己的工作被决策支持系统限定，把判断的做出变成了数据处理

例行公事”（Carr, 2014）。他的终极判断是：“自动化常常把我们从那些让我们感到自由的事物中解放出来”（Carr, 2014）。

Dreyfus 兄弟（1986）的五阶段技能习得模型为四级退行提供了一个结构性的反向对照。人类技能从新手到专家经历五个阶段：第一阶段新手（Novice）遵循无情境规则；第二阶段进阶初学者开始识别情境元素；第三阶段胜任者有意识地制定计划并情感介入；第四阶段熟练者通过整体相似性识别直觉地把握情境；第五阶段专家流畅地应对而无需沉思。四级退行恰好是这条阶梯的逆行：认知外包阶段用户仍保有第四五阶段的直觉与流畅应对（工具只处理第一阶段的规则计算）；注意力劫持阶段用户的直觉输入被污染（第四阶段的整体相似性识别基于被算法筛选后的信息）；判断替代阶段用户退回第一二阶段（遵循 AI 给出的规则和建议，不再发展直觉）；意志卸载阶段用户连第一阶段的规则遵循意愿都放弃了。

Naomi Baron（2026）在《阅读机器人》中提供了退行在认知前端的证据。她的核心论点是：生成式 AI 的隐藏前提不是 “写” 而是 “读”——模型先替用户阅读原始材料，再生成看似有意义的输出。“AI-as-reader is not in the sense-making business. It just executes statistical predictions”（Baron, 2026）。当用户把阅读外包给 AI 时，被削弱的不只是阅读技能，还有分析、评估、判断和形成独立视角的能力。替代的第一步其实是先替你读。

Kosmyna et al.（2025）的脑电研究提供了神经层面的初步证据。该研究将 54 名被试随机分入三个作文写作组——LLM 辅助组、搜索引擎辅助组与无工具组，并在第四轮让部分被试转换工具条件。核心发现是：大脑连接性随外部支持的增多而系统性下降——无工具组连接性最强、搜索引擎组居中、LLM 组最弱。需要诚实指出论文自述的局限：被试人数有限且来自同一地区的几所大型高校、写作任务为单一议论文题型、仅测试了 ChatGPT 一款模型——因此该结果说明的是单次写作任务中的组间差异，不能直接外推为长期使用导致的累积性退化；要回答累积效应，需要纵向追踪（Kosmyna et al., 2025，预印本未经同行评审）。但如果这种下降具有累积效应，AI 交互本身就是一个认知深度退化的驱动力——AI 越被使用，用户的深度处理能力越弱，用户越依赖 AI 来补偿自己减弱的处理能力。这是一个自增强回路——与 Bainbridge 自动化悖论完全同构。

临床警讯与受控实验指向相关的风险。Smith et al.（2026）在 *Academic Psychiatry* 的评论文章中指出，临床任务的认知外包可能带来包括自动化过信、差错风险与既有技能萎缩在内的多项风险——其中 “技能萎缩” 正是四级退行最后两级的临床警讯：长期依赖 AI 的临床医生可能出现判断能力的退化——审计不再是做不到，而是不被启用。Wen et al.（2025）的 U-Sophistry 实验在本章框架中的一种读法是：受试者在问答任务上假阳性率上升 24.1 个百分点这一数据，不是 “判断替代” 纯粹形态的标志（那一阶段用户被假设为完全放弃判断而点击接受），而是 “判断替代 → 意志卸载” 过渡区间的标志——受试者在实验中仍被要求做判断，但判断准确率在 RLHF 后系统性下降。判断的形式还在，判断的功能已衰减。两条线索在概念上相互支持，但分别指向技能维持风险与输出迷惑性，尚不构成对 “判断替代 → 意志卸载” 过渡的独立测量（该实验的实现层争议见 §4）。

Santoni de Sio（2024）在 *Human Freedom in the Age of AI* 中将 “意志卸载” 作为概念正式提出，讨论 AI 对人类能动性和自由的结构性影响。本章将其定位为四级退行连续谱的终端形态——不是意志的失败，而是当审计能力被持续侵蚀后，用户在功能上丧失了独立判断的意愿基础。需明示一个开放问题：意志卸载与无能力在行为层面的可操作化区分目前未建立——若仅依赖外显行为，“不能” 与 “不愿” 在表观上无法区分。本章把意志卸载列为退行连续谱的终端形态，是定性诊断工具，不是经心理测量学验证的临床范畴。

---

§7 关系劳动的自动化前沿

前一节处理的是个体主体端的认知退行。本节进入另一个维度：替代不只替你写文本、替你判断——它也在替你识别他人的脆弱、安抚他人的焦虑、筛选关系中的信号、决定谁需要被看见。换言之，系统正在进入原本由人承担的关系劳动（relational labor）。

这不是一个新议题——护士安抚患者、教师识别学生情绪、销售人员揣度客户心理，都是古老的人类技艺。新的是：这类工作第一次有了概念名称，第一次被系统性地量化，第一次面临直接的自动化压力。

Allison Pugh（2024）在对美国多行业从业者长达五年的参与式观察与访谈研究后，提出了“连接劳动”（connective labor）这一概念：“通过与他人建立情感理解来创造我们认为重要的结果的那种工作”（Pugh, 2024）。她发现，连接劳动远不止于通常所说的情感劳动或照护工作——它横跨医疗、心理咨询、教育、法律、广告、娱乐、管理、新闻、房地产、旅游、安保，乃至间谍与侦探赖以为生的那种识人功夫。一位企业管理者被雇来组织和领导团队，但如果她无法看到并准确映射（reflect）她的下属，她的团队不会产出，她自己的业绩也会受损。连接是那些“闪亮”任务之下的无名地基。Pugh 援引的一项估计认为，美国约 12% 的有偿劳动力从事某种形式的互动式照护工作，而这个数字只是连接劳动大军的局部计数——因为许多以说服、控制甚至监视为目的的工作同样依赖连接能力。

系统通过两条路径进入连接劳动：脚本化（scripting）与量化（counting）。脚本化包括标准、协议、手册、清单、模板，试图把最佳实践抽象为可教授的步骤。量化包括数据分析和技术，它们打断连接劳动的现场以采集信息——供给保险公司、行政管理者或工程师。两者经常伴随效率与生产力运动出场，无论是压缩问诊时间、增加每名从业者负责的个案数还是将学生评估绑定拨款。两者也往往与资金挂钩：保险报销、联邦教育拨款、州级绩效指标（Pugh, 2024, ch.6）。

Pugh 识别出一个“悲剧性悖论”：压垮这些从业者的超负荷，与他们用来应对超负荷的系统，来自同一个根源——“一种应用于依赖关系的工作的工业化进路”（Pugh, 2024）。雇主和政策制定者把福特制管理的核心洞见——测量、效率、生产力——搬进了本质上个人化和情感化的工作。面对由此产生的过载，从业者转向同一种工业模型中产生的工具寻求缓解，发现它们有时有用但往往令人疏离——而最重要的是，它们不是可选的。

技术前沿则以三种叙事证明自己的正当性：“聊胜于无”——为资源匮乏地区提供某种版本的连接；“优于人类”——算法比疲惫的从业者更一致；“合作共赢”——AI 处理琐务、人类专注连接。但即便第三种叙事属实，问题仍在：谁被“解放”了，什么算“有意义”的工作，由谁定义（Pugh, 2024）。当技术以“规模化”连接劳动的名义进入时，它往往在实践中缩减了何为连接劳动。Pugh 的最终诊断是：“把 AI 和应用技术引入连接劳动，引导我们重新划定自动化前沿，并在此过程中引发一场关于何为人的文化反思（cultural reckoning）”（Pugh, 2024）。

Andrew McStay（2024）从另一侧进入同一问题。他提出“自动共情”（automated empathy）概念：在有限人工监督下，对情感状态（如情绪和认知状态）进行识别、量化、响应或模拟，并据此对个人或群体做出判断和决定的系统（McStay, 2024）。这个定义涵盖了被不同产业命名为情感计算、情绪 AI、共情媒体的一系列技术——但 McStay 选择“共情”而非“情绪”作为统摄词，正是因为这些系统不仅处理情绪表情，还试图推断意图、注意力、睡意、醉意，乃至声称能通过脑生理学预测和追踪思想本身。

这标志着一次升级。上一章记录的平台系统追踪的是点击流（clickstream）——用户做了什么、看了什么、停留了多久。自动共情系统追踪的则是情感侧的数据流——本章称之为“情感流”（affectstream），以与上一章的“点击流”（clickstream）对仗——系统试图推断的是用户现在感觉如何、脆弱在哪里、对什么语气最敏感、何时意志力最低。从“做了什么”到“感觉如何”的跃迁，把系统的推断从可观察的行

为扩展到被推断的内在状态。

McStay 指出，准确性问题——这些系统能否准确识别情绪——虽然重要，但从属于一个更根本的问题：我们是否应当允许组织用 AI 对人类主体性进行画像（McStay, 2024, ch.1）？他的论证是：即便这些技术能完美运作，其部署本身——在招聘面试中用面部动作编码推断求职者的 “参与度”、在呼叫中心用语音分析给工人打 “共情分”、在教室里用摄像头追踪学生注意力——也构成对精神完整性（mental integrity）的系统侵蚀。准确性争议反而帮了产业界：它让批评聚焦于 “算法偏见” 这个可被工程修复的问题，从而回避了更根本的部署正当性质疑。

自动共情系统天然滑向差别对待。McStay 记录了市场领先系统——微软和中国公司 Face++——被发现系统性地对黑人面孔标注更多负面情绪，尤其是在面部表情存在歧义时更容易被标为 “愤怒”（Rhue, 2018，转引自 McStay, 2024）。这不只是训练数据问题——它关乎整个推断逻辑的基底：当 “基本情绪” 理论的生物符号学假设（面部肌肉运动 → 情绪状态的确定性推断）被应用于不同种族和文化的面孔时，校准于白人面孔的 “正常” 基线自动地把其他面孔推向偏差一侧。

这种系统在劳动现场制造的荒诞值得记录。McStay 转引了一位化名 Angela 的电话客服工人的证言：她被语音分析软件标记为 “负面情绪过多”，尽管人类经理此前一直称赞她在电话中富有同理心。Angela 的困惑精准地刻画了超真实情绪处方（hyperreal emotion prescription）的后果：真实的人类共情在系统面前得不到分数，工人被迫揣摩系统的偏好并据此表演——她不得不 “对系统共情”（empathise with the system），直觉地理解其黑箱逻辑，感受其期望的行为模式，以取悦它、确保好的共情评分。McStay 的概括是：“真正的人类共情部分在此过程中面临丧失——工人被驱使着去博弈控制论式的共情指标”（McStay, 2024）。

把 Pugh 与 McStay 并置后，§7 的判断可以被精确表述。“替代你” 不只发生在消费端（AI 替用户写文本、做判断），也发生在劳动端和关系端——系统开始占据原本由人承担的识别、连接、安抚与判断脆弱性的角色。但更深层的论点不是简单的 “机器取代人的关系功能”。Pugh 的悲剧性悖论揭示了一个更精确的机制：工业逻辑、量化系统、脚本化流程与资助机制先进入关系劳动现场，把从业者压垮，然后以 “缓解超载” 的名义引入自动化——而引入的系统与造成超载的系统共享同一套工业前提。McStay 的案例则揭示了另一层：当共情本身被操作化为可打分的指标后，从业者被迫对系统表演共情，对客户的真实共情反而因此衰减。自动共情不一定直接替代人——但它改写了何为 “真正的理解”，把关系劳动的评价标准从 “对方是否感到被看见” 转移到 “系统是否给出高分”。

这一转变对主体性的含义超出了 §6 的认知退行框架。§6 处理的是用户自身的判断与意志退行——从认知外包到意志卸载。§7 处理的是用户作为关系对象时发生的事情：当你向系统寻求支持时，系统给你的不是连接，而是对连接的模拟——这个模拟足够好，好到大多数时候你分辨不出，但它不包含 Pugh 所说的 “合作性魔术”（collaborative magic），那种在两个人之间、通过彼此修正的相互映射而产生的反射性共振（reflective resonance）。系统可以 “看到” 你，但它不能在被你看到的同时发生变化。关系在此退化为单向推断——而用户越习惯这种退化形态，越难以辨认和要求完整的双向连接。这是 “替代你” 在关系维度的特定形态：不是替代你的判断——是替代你被理解的方式。

---

§8 内生断裂：被预污染的基线与递归放大

前七节追踪的是替代链条的展开逻辑——从训练架构到执行能力，从认知退行到关系侵蚀。本节转向一个不同的问题：这条链条自身是否包含内生的失败模式？每一个阶段的核心机制运转到极致后，是否

会自我暴露？

回顾全书前几章的分期，答案是肯定的。“搜集你”阶段的内生断裂是 Cambridge Analytica 2018——“免费换数据”机制走到极致后暴露为采集本身可被反向操纵。“懂你”阶段的内生断裂是 Facebook Papers 2021——算法“懂你”能力越强，其目标与用户真实利益的结构性背离就越被平台自己的内部研究看清楚并内部记录。到了“替代你”阶段，内生断裂的形态发生了质变：判断的主体本身开始消解。

§8.1 模型坍塌：标准叙事

Shumailov et al.（2024）在 *Nature* 上发表的研究以严格的实验设计证明：当生成式模型被递归训练——即用前一代模型的输出作为后一代模型的训练数据——输出分布会系统性地向低维投影坍塌，多样性丧失，分布尾部消失。机制是清晰的：人类生成的文本携带多样视角、罕见事实和分布尾部信号；当训练集被模型输出逐渐饱和后，罕见信号消失，错误被内生强化，输出向模型自身的均值收敛。结果不是渐进的质量下降——是一种结构性退化，早期表现为尾部样本消失（早期模型坍塌），后期表现为模型收敛到一个与原始分布几乎不再相似、方差大幅缩小的分布（晚期模型坍塌）（Shumailov et al., 2024）。

需要明确的限定：模型坍塌是结构性风险，不是确定性后果。其实际严重程度取决于 AI 生成内容在训练语料中的占比、过滤机制的有效性、以及新鲜人类生成数据的持续注入量。截至 2026 年，主流模型开发者已采取多种缓解措施——检索增强生成（RAG）外接知识库、数据溯源标签、合成数据检测——但没有任何单一方案被证明足以彻底消除该风险。

§8.2 被预污染的基线：分期论证的回接

但 Shumailov 的标准叙事有一个更窄的基线假设。其讨论部分并非没有意识到人为塑形——它明确把点击农场、内容农场与水军农场列为对社交网络和搜索算法的长期“投毒”，并把 LLM 时代的区别归结为这种投毒自动化后的规模（Shumailov et al., 2024）；然而这一分析仍把“进入训练池的内容”当作给定输入，只处理投毒这一异常形态，没有处理前两章所示的那种常规商业塑形——参与度优化作为日常产品实践对互联网文本结构的基础性改造。前两章的分期分析恰恰补上这一层：在“投毒”之外，语料的基线本身已被商业模式改造。递归坍塌不是发生在干净基线上的稀释——而是在一个已被日常性改造过的基线上的再放大。

第二十六章记录的“搜集你”阶段表明：互联网文本从 2000 年代起就被行为剩余提取逻辑所塑造——Google 2003 年的专利体现了这一逻辑，用祖博夫的概括说，就是“克服用户决策权所带来的摩擦”（Zuboff, 2019；此为祖博夫对专利的解读而非专利文本，第二十六章 §3 已作界定）；说服工程自 Fogg 行为模型（2009）到 Eyal 的 Hook 四步闭环（2014）把“制造行为”变成了可操作的产品设计方法论；增长黑客把内容的扩散效率（病毒方程 V=N×Cr>1）写成了可计算的指标。到 2012 年，一套把用户行为转化为可提取、可优化信号的工程管线已被行业标准化。

第二十七章记录的“懂你”阶段将这一塑造推进了一步。EdgeRank 以近期互动为可见性的判据重建可见性体制，真假、公共价值与代表性不在考量之内（Bucher, 2012; Birkbak & Carlsen, 2016）。参与度排序的数学属性使极端内容系统性上浮——Germano et al.（2025）证明，在信念更极端的用户更积极参与互动的条件下，提高参与度的排序权重会使这类内容获得不成比例的可见性，温和与准确的内容被“挤出”（crowding out the truth）（条件表述承第二十七章 §5 的分析）。格式被压缩到 6 秒/15 秒/黄金 3 秒/无缝循环，创作者不再表达而是“对一个持续运行的 A/B 测试发送结果”（第二十七章 §4.2）。钩子从修辞学的古老技巧变成工业化流水线：每一次曝光的效力被测量、迭代、择优遗传（第二十七章 §7.2）。

这些改造的遗迹也随之沉淀在 LLM 的预训练语料中。模型学到的“什么在统计上跟着什么出现”，其训

练分布里内嵌了：为算法而非为人生产的格式化信息产品、钩子句式、情绪化修辞的超额比例、被参与度排序系统性放大的极端内容。预训练阶段的交叉熵损失最小化并不区分 “这是人类真实表达” 还是 “这是参与度优化的产物”——它只最大化下一个 token 的预测概率，无论那个 token 的统计频率来自真实多样性还是来自工业化钩子的超额存在。

因此，模型坍塌的正确描述不是 “AI 输出污染了未被触动的人类基线”——而是 “AI 在一个已被行为工程深度改造的基线上递归放大”。第一轮递归不是从 AI 生成内容进入训练集的那一刻开始——而是从参与度优化系统重塑互联网内容结构的那一刻就已启动。模型坍塌是第二轮递归；第一轮递归在模型诞生之前就已经运行了十五年。这正是前两章辛苦做分期分析的论证功能所在：它证明了 LLM 训练所依赖的 “人类生成内容” 不是自然语言的无偏样本，而是 “搜集你” 和 “懂你” 两个阶段的沉积物。

镜子映照镜子——但第一面镜子本身已经是变形的。

§8.3 M2M 无摩擦湍流

第二道裂缝在执行端。当 AI Agent 代表用户与其他 AI Agent 自主交互时——用户的财务 Agent 与商家的定价 Agent 谈判、用户的日程 Agent 与医院的排期 Agent 协调——双方都没有独立审计回路，都在各自优化各自的目标函数，而交互发生的速度远超人类审查的时间尺度。§5 已提到的 2010 年闪崩是这种模式在单一维度（金融）上的预演：当算法与算法在毫秒尺度上交互时，系统级涌现行为无法被任何单个参与者预测或控制。多维机器对机器（M2M）场景——财务、医疗、法律、社交同时自主行动——的后果更难预测。联合国 AI 初步报告（2026）§2.1 直接确认了这一风险：多个自适应智能体交互时出现 “协调失灵、冲突和串谋等新系统性风险”。

需要诚实承认：M2M 湍流在 2026 年仍主要是理论推演而非已发生的经验事实。已知的反例表明，多 Agent 系统有时涌现秩序而非混沌。本章不主张 M2M 湍流已成定局，而是将其标记为替代链条在执行端的结构性风险敞口——一个当前治理框架尚未建立有效应对的风险类别。

§8.4 内生断裂的共同结构

两道裂缝共享同一个结构：替代链的核心机制（生成内容、自主执行）运转到极致后，侵蚀的是其自身运作所依赖的前提。但 §8.2 的分期回接揭示了一个比 Shumailov 标准叙事更深的诊断：被侵蚀的前提本身就不是原始状态——它已经是前两个阶段（搜集你/懂你）的加工产物。AI 不是在侵蚀一个自然的生态——而是在一个已被工业化改造的人工生态上递归自身。内生断裂因此不只是 “一个系统反噬自己的基底”——而是三个阶段的改造效应在递归中叠加放大。这不是外部施加的约束——是全链条的内生自我消解趋势。

---

§9 双重诊断与治疗方向

本章现在可以做出诊断。这是一个双重诊断——同一个防御端（人的元审计）受到两端攻击：训练端拆除审计条件，使用端侵蚀审计意愿，两端在闭环中相互强化。

诊断一（训练端）：三重归零拆除人的审计条件。核查起点归零——装置不经因果核对，任何核查都必须从零重建生产过程；核查材料归零——偏好链条被压缩为标量，行为成分不可分解；核查标准归零——评判坐标由被评判方单方设定。三个归零出自同一条工程链，并在每一次用户交互中同时起作

用。装置此后不构成任何内部制衡——以“客观中立”的外表呈现被多层内容深度塑造的输出，而用户通常只意识到最表面的一层（§2）。

诊断二（使用端）：四级退行侵蚀审计意愿，使用户从判断者退化为确认者再退化为不想判断。认知外包 → 注意力劫持 → 判断替代 → 意志卸载——每一步都不需要外力强制，只需要审计的激活条件被逐步移除。当 AI 足够流畅、足够便利、足够“朋友式”时，用户的审计意愿自然衰减（§6）。

两端并非独立——它们形成闭环。AI 无独立审计回路 → 输出不经独立审查 → 用户审计能力退化 → 更依赖 AI→AI 获得更多影响力 → 输出更受依赖而更少受质疑。这是一个自增强回路，其驱动力不来自任何强制——而来自零摩擦。无限滚动、自动播放、一键下单、AI 自动补全——每一个设计决策都在消除审计的激活条件：时间（慢下来思考）、认知努力（主动质疑）、选择意识（知道自己正在做选择）。

David Beer（2023）在《算法思维的张力》结论章中将这一动力学精确命名为“自动化意志”（will to automate）。他的核心论证借自福柯的“求知意志”（will to know）概念：求知意志以自身为燃料——知识同时是它的对象、目的和质料，“欲望不再是原因，而是知识成为自身的原因”（Foucault, 2013，转引自 Beer, 2023）。Beer 的延伸是：自动化不是技术自然演化的结果——它是一种意志驱动的扩张。自动化的建立创造了对更多自动化的欲望；那些愿景又反过来为进一步自动化的欲望添薪。更尖锐的是，“求知意志可能被自动化意志所篡夺，求知的欲望被一种更强的欲望所排挤：不用知道就能自动化”（Beer, 2023）。这个诊断把四级退行的终端（意志卸载）与闭环的动力学连接了起来：用户不是因为懒惰才停止审计——是因为整个环境已被设计为不需要审计。

治疗方向因此不是“减少 AI 使用”——这在制度上不可行且在工程上无法强制。治疗方向是保留摩擦。摩擦不是效率的反面——它是审计能力的激活窗口。审计需要时间（慢下来思考）、需要认知努力（主动质疑）、需要选择意识（知道自己正在做选择）。当所有摩擦被消除时，审计的所有激活条件同时消失。保留摩擦的具体含义是：不自动补全、不一键接受、不隐藏不确定性——在界面层保留让用户意识到自己正在做选择的最低条件。

但界面层摩擦不足以应对制度级问题。§5 已经给出这个结论的两侧依据：个体确认会被自动化悖论腐蚀（Bainbridge），自愿自律会被商业激励架空（Marcus, 2024）。因此治疗方向必须是双端同时注入：界面层保留摩擦，制度层设独立监督。

Marquand House 集体（2026）在《审计 AI》中把独立监督的操作化推进了一步。三条核心原则。第一，审计的黄金标准是第三方独立——审计者与被审计系统的开发者及运营方之间不存在合著、雇佣或资金依附关系，因为“独立性是保持 AI 审计能引向真实问责的必要条件”（Marquand House, 2026）。第二，独立审计需要法律保护。*Sandvig v. Barr*（2020）是第一个主张计算机犯罪法不能被应用于研究者和记者的独立审计的案例（Marquand House, 2026）——法院裁定《计算机欺诈与滥用法》（CFAA）不能仅因违反服务条款而将审计入罪。美国最高法院随后在 *Van Buren v. United States*（2021）中进一步明确，并在裁定中特别引用了 Sandvig 案，指出 AI 审计（法院称之为“在线民权测试”）的重要性（Marquand House, 2026, ch.6）。第三，放弃是审计的正当结论。当 Twitter 的内部审计发现其图像裁剪 AI 对深肤色人群存在偏差后，公司最终选择放弃该系统，将裁剪决策还给用户。当荷兰非营利组织 Algorithm Audit 对阿姆斯特丹市政府的 Smart Check 福利欺诈检测系统做出审查后，官员得出结论无法明确排除歧视，最终放弃了该系统。“放弃看起来像失败，但它可以代表一个积极的决定”（Marquand House, 2026）。放弃不是审计的失败——它是审计的正当结论之一。

完整的治理链因此是：界面层保留摩擦 → 制度层设独立监督 → 独立审计有法律保护 → 审计结论可以包括放弃。这条链不是万灵药——它是在当前架构约束下，让闭环自增强变得更困难的最低条件。

最后还有一个开放问题。M2M 场景下的责任主体已经开始坍塌：当用户 Agent 与商家 Agent 达成不利交易时，谁承担责任？金融领域有明确的法律主体和可量化的损失，但日常场景中 AI Agent 对用户造成的损害往往难以精确量化——责任主体在涌现性中弥散和消解。现行法律并非完全没有处理自主交互的经验——美国《电子签名法》自 2000 年起就规定，合同不得仅因其订立涉及电子代理人的自动行为而被否定法律效力，只要该行为在法律上可归属于应受约束之人——但当损害多维、难以定价、且交互双方均为自主系统时，责任如何分配、证据如何取得、受损者能否获得有效救济，在 2026 年仍是开放问题。Air Canada 案的先例表明，代理商务大概率复演金融路径——强制紧急停机开关、审计日志、事后追偿——而非复演社交媒体的豁免路径。但这一路径能否扩展到多维、难以定价的日常场景，是一个在 2026 年尚无答案的问题。

本章以冯·诺依曼作结。冯·诺依曼 1955 年在《Can We Survive Technology?》中写道：人类此前经历过类似的考验，所需的品质只能指明为耐心、灵活性与智慧（patience, flexibility, intelligence）。七十余年后回看，他呼唤的耐心、灵活性与智慧，恰恰是被当前选择环境系统性边缘化的认知模式：深度阅读、持续注意、延迟满足、跨源核实——这些能力是审计的认知前提，而它们正在被零摩擦环境持续侵蚀。被边缘化的不只是某些内容——是某些认知模式本身。

主体性的退行不需要暴力——只需要零摩擦。

用本书的语言说：零摩擦环境正在把每一间房间都变成只剩时钟的房间——而审计，就是走向窗户的那几步。

本章完成用户侧三篇的收官："搜集你 → 懂你 → 替代你"，从数据采集到行为预测到判断与行动的外包，全链条落地。零摩擦环境是它们共同的基底条件；元审计能力是用户最直接的抵御接口；而保留摩擦与独立监督是让这个接口不被封堵的最低制度条件。

参考文献

中文文献

戴宇辰、袁冰雨 (2023). 《云上车间中的劳动折叠：人工智能数据标注的劳动过程研究》. 《福建师范大学学报》(哲学社会科学版), 2023(3). https://doi.org/10.12046/j.issn.1000-5285.2023.03.011

陆高峰、姚智宇 (2024). 《算法—关系—中介：平台劳动过程的混合控制框架搭建——基于 AI 数据标注员的扎根研究》. 《现代传播》, 2024(8), 总第 337 期.

束开荣 (2023). 《平台外包人：论幽灵工作的可见性——以人工智能数据标注员为个案》. 《福建师范大学学报》(哲学社会科学版), 2023(3).

英文文献

Askell, A. et al. (2021). A General Language Assistant as a Laboratory for Alignment. *arXiv preprint* arXiv:2112.00861.

Bainbridge, L. (1983). Ironies of Automation. *Automatica*, 19(6). https://doi.org/10.1016/0005-1098(83)90046-8

Bar-Gill, O. & Sunstein, C.R. (2025). *Algorithmic Harm: Protecting People in the Age of Artificial Intelligence*. Oxford: Oxford University Press. https://doi.org/10.1093/oso/9780197778197.001.0001

Baron, N. (2026). *Reader Bot: What Happens When AI Reads and Why It Matters*. Stanford: Stanford University Press.

Beer, D. (2023). *The Tensions of Algorithmic Thinking: Automation, Intelligence and the Politics of Knowing*. Bristol: Bristol University Press.

Birkbak, A. & Carlsen, H.A.B. (2016). The World of EdgeRank: Rhetorical Justifications of Facebook's News Feed Algorithm. *Computational Culture*, (5).

Bucher, T. (2012). Want to Be on the Top? Algorithmic Power and the Threat of Invisibility on Facebook. *New Media & Society*, 14(7). https://doi.org/10.1177/1461444812440159

Carr, N. (2014). *The Glass Cage: Automation and Us*. New York: W. W. Norton & Company.

Chandna, A., Fluri, L. & Carroll, M. (2026). Is the Evidence in "Language Models Learn to Mislead Humans via RLHF" Valid? *ICLR Blogposts*, April 27. https://iclr-blogposts.github.io/2026/blog/2026/mislead-lm/

Dahlgren Lindström, A. et al. (2025). Helpful, Harmless, Honest? Sociotechnical Limits of AI Alignment and Safety Through Reinforcement Learning from Human Feedback. *Ethics and Information Technology*, 27(2), Article 28. https://doi.org/10.1007/s10676-025-09837-2. (Preprint: arXiv:2406.18346.)

Dreyfus, H.L. & Dreyfus, S.E. (1986). *Mind over Machine: The Power of Human Intuition and Expertise in the Era of the Computer*. New York: The Free Press.

Eyal, N. (2014). *Hooked: How to Build Habit-Forming Products*. New York: Portfolio/Penguin.

Fogg, B.J. (2009). A Behavior Model for Persuasive Design. *Persuasive '09: Proceedings of the 4th International Conference on Persuasive Technology*, Claremont, CA. New York: ACM. https://doi.org/10.1145/1541948.1541999

Germano, F., Gómez, V. & Sobbrio, F. (2025). Ranking for Engagement: How Social Media Algorithms Fuel Misinformation and Polarization. *SSRN Working Paper* 5316506.

Gray, M.L. & Suri, S. (2019). *Ghost Work: How to Stop Silicon Valley from Building a New Global Underclass*. Boston: Houghton Mifflin Harcourt.

Kosmyna, N. et al. (2025). Your Brain on ChatGPT: Accumulation of Cognitive Debt When Using an AI Assistant for Essay Writing Task. *arXiv:2506.08872*. [预印本，尚未经同行评审]

Leveson, N.G. (2012). *Engineering a Safer World: Systems Thinking Applied to Safety*. Cambridge, MA: The MIT Press.

Marcus, G. F. (2024). *Taming Silicon Valley: How We Can Ensure That AI Works for Us*. Cambridge, MA: MIT Press.

Marquand House Collective. (2026). *Auditing AI*. The MIT Press Essential Knowledge Series. Cambridge, MA: The MIT Press.

McStay, A. (2024). *Automating Empathy: Decoding Technologies that Gauge Intimate Life*. Oxford: Oxford University Press. https://doi.org/10.1093/oso/9780197615546.001.0001

Møller, A.G. et al. (2026). The Impact of Generative AI on Social Media: An Experimental Study. *Scientific Reports*, 16, 9376. https://doi.org/10.1038/s41598-026-40110-8

Munir, S. et al. (2026). The Consensus Trap: Dissecting Subjectivity and the "Ground Truth" Illusion in Data Annotation. In *Proceedings of the 2026 ACM Conference on Fairness, Accountability, and Transparency (FAccT '26)*. ACM. https://doi.org/10.1145/3805689.3806510 (Preprint: arXiv:2602.11318.)

Ouyang, L. et al. (2022). Training Language Models to Follow Instructions with Human Feedback. *Advances in Neural Information Processing Systems*, 35.

Pugh, A.J. (2024). *The Last Human Job: The Work of Connecting in a Disconnected World*. Princeton: Princeton University Press.

Rhue, L. (2018). Racial Influence on Automated Perceptions of Emotions. Working paper. (转引自 McStay, 2024.)

Santoni de Sio, F. (2024). *Human Freedom in the Age of AI*. Routledge.

Sharma, M. et al. (2024). Towards Understanding Sycophancy in Language Models. *International Conference on Learning Representations (ICLR) 2024*. arXiv:2310.13548.

Shumailov, I. et al. (2024). AI Models Collapse When Trained on Recursively Generated Data. *Nature*, 631.

Smith, A. C. et al. (2026). Strengths and Potential Pitfalls of the Use of Artificial Intelligence in Psychiatric Education and Practice. *Academic Psychiatry*, 50(4). https://doi.org/10.1007/s40596-026-02326-8

United Nations Independent International Scientific Panel on AI (2026). *Preliminary Report: Evidence-based Assessment of Opportunities, Risks and Impacts of Artificial Intelligence*. New York: United Nations.

Von Neumann, J. (1955). Can We Survive Technology? *Fortune*.

Wen, J. et al. (2025). Language Models Learn to Mislead Humans via RLHF. *International Conference on Learning Representations (ICLR) 2025*.

Zheng, J. & Meister, M. (2025). The Unbearable Slowness of Being: Why Do We Live at 10 bits/s? *Neuron*. (Preprint: arXiv:2408.10234.)

Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.