《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第三十一章：当时钟开始替人开门——Agentic AI 的 MCAF 投影

摘要

此前分析的全部媒介——从书籍到短视频到大语言模型——共享一个结构性约束：时钟只显示读数，人类决定是否以及如何行动。无论信息传导效率有多高、叙事载荷（ϕ）多高，信息从时钟到行动之间有一个物理间隙——人类必须手动将读数转化为决策。这个间隙为元审计（A）提供了时间窗口。

Agentic AI——智能体，被赋予工具调用与多步规划能力的人工智能（AI）系统——压缩或取消这一时延。当模型被赋予工具调用和多步推理能力时，媒介传导系数（Λ）所度量的信息流不再止于读数——模型输出接入了直接改变状态的执行通道。时钟不再只是告诉人几点——它替人开门。如果读数是错的，门已经开了，事前审计随之转为事后追溯。这与 Bainbridge（1983；亦见第九章 §6 关于人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF）递归形态的讨论、第二十八章 §3 关于劳动结构的讨论）揭示的结构相通：自动化程度越高，事前介入越少，事后追溯、纠错与治理的成本相应上升。元审计并未被消灭，而是被推迟、被复杂化、被计入认知债务。

本章以时钟房间的纤维语言和宏观认知债务记账框架（Macro-Cognitive Accounting Framework，MCAF）的记账结构分析这一突变的认识论性质、其对防御端三变量的结构性冲击、以及赔付环承压后的清算前景。“时钟房间” 作为贯穿全书的核心诊断语言，本章在智能体（Agent）场景下追踪其特殊变形——执行通道使时钟从读数器升级为开门器。

关键词

智能体（Agentic AI）、执行通道、时钟房间、媒介传导系数（Λ）的拓扑突变、元审计（A）的时间窗口、防御端三变量结构性冲击、赔付环承压、认知债务累积

---

§1 媒介传导系数（Λ）的拓扑突变：从读数到物理执行

§1.1 此前所有媒介的共同约束

回顾第七章（认知雷诺数）的维度叠加表。从书籍到 AI 生成，每一代媒介都在前代基础上新消灭一个停止信号。但所有这些媒介的主流使用方式共享一个约束：输出是符号，不是行动（已有的执行通道——高频交易算法、监督控制与数据采集（Supervisory Control and Data Acquisition，SCADA）系统、自动驾驶——是这一约束的局部例外，多属附有专门监管框架的专业系统，消费级自动化（如快捷指令类工具）也已存在多年；Agentic AI 的新颖性不在执行通道本身，也不在执行通道面向普通用户（快捷指令类工具早已如此），而在具有工具调用与多步规划能力的模型对跨应用操作的动态选择与组合，及其带来的授权、审查与追责问题——此类系统尚缺乏针对其执行组合的成熟专门监管框架，既有分域规则需要跨系统协调才能覆盖）。此处概括的是本书此前讨论的读数型使用方式，而非断言这些技术此前从未接入执行通道。

书籍输出文字——人读完后自己决定做什么。电视输出画面——人看完后自己决定买不买。推荐算法输出排序——用户看到排序后自己决定点不点。大语言模型输出文本——用户读完后自己决定是否采纳。

每一步都有一个人工操作环节：复制、粘贴、点击确认、拨打电话、走到商店。这个环节在读数与外部状态改变之间嵌入一段时延，元审计在这段时延中获得其时间窗口。Agentic AI 压缩或取消这段时延，但元审计本身并未被取消——它被推迟到事后，相应地把当期的执行决策计入认知债务（第三章 §3.2 债务时钟 τ_d）——本章所谓“被推迟”，指未完成的核验与纠错需求转入事后，并不保证事后审计一定发生。这与 Bainbridge（1983）揭示的结构相通：自动化程度越高，事前介入越少，事后追溯与治理的复杂度相应上升。技术上更精密的时钟仍然回避不了被时间所校正——校正的时点被推迟、成本被累积，治理的负担最终回到 §5 所论的执行通道与制度层。

§1.2 执行通道的出现

本章以 2024–2026 年的工具调用（Tool Use）与多步规划（Multi-step Planning）系统为观察对象。此类系统由模型生成操作请求，经运行环境调用数据库、邮件服务、交易接口、外部应用程序接口（Application Programming Interface，API）与浏览器界面；请求能否执行，取决于部署方配置的权限与审批规则。

在 MCAF 框架中，媒介传导系数（Λ）仍表示信息到达宿主的效率。本章讨论的新增条件，是模型输出接入了能够改变外部状态的执行通道——若将这一变化称为“拓扑突变”，它指的是执行路径连接关系的改变，而非媒介传导系数（Λ）本身变成了执行器。这不是量的增加（更快的传导），是质的突变（从传导到执行）：此前的传导无论多快多精准，本质是一个单向的信息管道——读数从投射端到达宿主，宿主决定是否行动；现在读数之外新增了一条通往执行器的通道——读数从投射端到达模型，模型可以直接改变外部世界的状态。

在时钟房间的语言中：此前的时钟只显示读数——人看完读数后自己决定几点出门。现在时钟不仅显示读数——它直接替人开门。甚至不需要看读数。人授权它“在适当的时候开门”。它按照自己的读数行事——而人已经不在房间里了。

上述描述以 2024–2026 年的主流 AI 系统为范式实例。这一范式内的演化方向不止一种：OpenAI 的 AI 五级演化分级是一条——据 Metz 在 Bloomberg（2024）的报道，该分级在内部全员会议分享，五级依次为对话机器人（Chatbots）、推理者（Reasoners）、智能体（Agents）、创新者（Innovators）、组织（Organizations），Huang（2025）已将该框架纳入综述；McShane et al.（2024）所论的混合认知架构是另一条。二者不是相互排斥的架构分类——OpenAI 五级框架描述能力层级，McShane 等讨论的是混合

认知架构；这两类讨论本身并不保证执行通道已经存在，本章关注的是其中模型输出实际接入直接改变外部状态的执行通道的系统实现（拓扑突变：时钟从单纯显示读数升级为基于读数改变外部状态）。本章对执行通道的共同诊断不以某一种模型架构为前提。§2–§5 以模型输出接入可改变外部状态的通道为共同出发点；各节讨论的具体风险机制，仍分别以该节说明的审计、训练与制度条件为前提。

§1.3 纤维的不可逆物理化

第一章 §3.2（纤维：首次解释）定义了纤维——给定一个读数，所有能产生该读数的真实状态的集合。大语言模型的纤维是认知层面的：模型说 “答案是 X”，纤维可能很大（X 可能是错的）；在这一使用方式中，输出先影响人的判断，若读数有误，外部损害仍可能随后经由人的操作发生。与 Agentic AI 的区别在于执行是否必须经过逐项人工环节，而不是损害只能停留在认知层。

Agentic AI 的纤维是物理层面的：模型说 “答案是 X” 并据此执行了一个应用程序接口（API）调用——删除了一条数据库记录、发送了一封邮件、下了一笔交易。如果 X 是错的（幻觉），物理状态已经在核验前被改变——是否构成不可逆后果，按下文界定的恢复条件判断。

纤维保留的不确定性，从认知层进入外部行动的后果链。第一章 §4.3（第三层：本体论降维）论证了映射系统性有损——存在不能靠校准消除的非单点纤维。当有损映射直接驱动物理行动时，如果未被区分的真实状态要求不同操作，映射残差便可能成为错误行动的来源；当系统据此选择了不适合实际状态的操作，并造成不利后果时，信息缺失（第一章 §4.1 定义的第一层不可逆）才在该次执行中转化为实际损失。本章所称不可逆后果，指在相关时间窗口内无法充分恢复原状的后果：数据删除是否可恢复，取决于备份与回滚条件；机密信息一旦被接收、复制或传播，即使撤销发送记录也不能消除泄露后果。认知债务、实际损失与法律赔偿额应分别记述。

更严重的是串联步骤的可靠性损耗。Agentic 工作流通常包含多个串联步骤——分析需求、搜索信息、生成方案、调用工具、验证结果。在最简模型（步骤间错误独立、无回滚机制）下，单步准确率（p）与步骤数（n）共同决定工作流整体准确率（p^n）：$p = 0.9$、$n = 4$ 时约 65.6%，$n = 10$ 时约 34.9%。错误检测、回滚机制与错误相关性都会使真实工作流偏离 p^n 这一独立估计——偏离方向取决于相依结构，不能先验断定高于或低于；该简模型只用于说明串联任务对单步可靠性的放大要求：在各步独立的假设下，步骤数线性增加，可靠性大致指数衰减。每一步的幻觉通过执行通道转化为下一步的 “事实输入”——这是第一章 §4.2（映射自我引用）在单次工作流内的微观展开。

---

§2 防御端的全面冲击

（§2.1–§2.3 依次考察防御端三个被越过的机制——元审计能力（A）的时间维度（§2.1）、意愿维度（§2.2）与生物学底座（E_c）的旁路（§2.3）；§2.4 进一步检视合法性基座（$\|L\|$）在微观/中观/宏观三个层次上的同步穿透。）

§2.1 微观层元审计能力（A_{micro}）的物理越过

在 Agentic AI 的商业部署中，“人在回路”（Human-in-the-loop，HITL）面临结构性压力。

Agent 以远高于人类审计吞吐的速度并行处理数十个应用程序接口（API）响应并生成决策链。人类的生物学底座（E_c）深层处理速度约 10 bits/s（见第三章；Zheng & Meister, 2025）。审查一个 Agent 的完整决策日志——包含 JSON（JavaScript Object Notation，一种结构化数据格式）格式的应用程序接口调

用序列、中间状态和分支逻辑——所需的理解与判断，不能化约为对原始日志体积的测度。Zheng 与 Meister（2025）讨论的正是约 10 bits/s 的行为信息吞吐量，并区分了这一量级与远高于此的感官输入；本章不把该估计直接用作日志审查的固定速度上限。判断人工审计能否及时完成，需要比较系统留出的介入时间与审查者识别、判断并阻止风险所需的时间。如果每一步都等待人工审批，多数自动执行流程的效率优势将大幅缩水。

人工参与可以采取不同安排，三种安排可在同一系统内并存：

- **人在回路（HITL）**：指定操作须经人工确认后执行。
- **人在环上（Human-on-the-loop，HOTL）**：在授权范围内运行，异常时人工介入。
- **人不在环（Human-out-of-the-loop，HOOTL）**：在预设权限与规则内完成，由事前配置和事后检查提供约束。

这些安排的安全性取决于权限范围、审查质量与停止机制，不能仅按人工参与的多少排序。审批环节的减少也不是某个公司的单独决定——当审批成本由部署方自担、而错误损失可以转嫁给用户或第三方时，竞争选择压（第三章 §6 假设一：技术扩张是竞争性权力选择的产物，而非自然演化）会推动部署方削减审批环节；若错误损失能够被追索、或客户对可靠性有明确要求，这一压力也会受到反向约束。这和第七章 §3（维度叠加表）展示的每一代媒介消灭一个停止信号是同一个机制——只是在组织层面而非界面层面运作。

在 MCAF 语言中：微观层元审计能力（A_{micro}）面临被商业逻辑从决策回路中移除的压力。不是因为元审计能力（A）不想在场——是因为元审计能力（A）的处理速度和投射端的执行速度之间的差距——逐项审批会降低执行吞吐量，但这不等于审批失效。问题在于系统是否为需要人工判断的操作保留了足够时间，以及部署方是否愿意承担相应成本。第三章 §3.3 的时钟排序（技术资本时钟 τ_c 远快于治理时钟 τ_g，$\tau_c \ll \tau_g$）在此达到极端的形态：技术资本时钟以月计，个体反思以秒到天计，而单次自动执行又远快于人工介入——两重时间差在此叠加。

§2.2 意志卸载：当元审计能力（A）的问题从速度转向意愿

§2.1 论证了微观层元审计能力（A_{micro}）在物理上被越过——Agent 的速度远超人类的审计速度。但审计不足还涉及参与意愿。借用 Santoni de Sio（2024）对 AI 时代人类能动性退行的分析框架，本书在第二十八章 §6 中将这一退行的极端形态操作化为意志卸载（will offloading）：即使在用户有足够时间审计的场景中（非实时、低风险的 Agent 操作），用户也逐渐不再想要审计。

这与第二十八章 §6 给出的四级退行连续谱的最后一级精确对应。认知外包是生物学底座（E_c）的问题——人处理不了那么多信息，工具帮人处理。意志卸载是元审计能力（A）的问题——人不再想要自己处理，即使可以处理。前者有部分技术解法（更好的过滤器、更清晰的摘要）；后者的解法不在工具内部，而在工具与制度的接口上——Santoni de Sio（2024）正是沿着通过设计 AI 系统来强化人的控制与责任这一方向展开的，本章 §5 的摩擦设计属于同一方向。仍需区分有意识的任务委托与依赖加深后的核验能力萎缩——后者需要纵向行为证据（第二十八章 §6），不能仅从用户选择委托推出。

在时钟房间的语言中：人不是被时钟迫使放弃了看太阳——人主动选择了不看。因为看太阳需要走到窗户前面（做功），而时钟就在面前（零摩擦）。当 Agent 的执行结果足够流畅、足够符合预期——“任务已完成”——为什么还要费力检查它做了什么？

如果长期委托使用户减少核验，并使核验能力逐渐下降，低摩擦执行与依赖加深之间就可能形成正反馈——“时钟制造了对时钟的需求”，这一结构在执行通道中达到最纯形态。这一机制须由纵向行为证

据检验。时间不足与参与意愿下降是削弱实际审计的两条可能路径，不能据此认定微观层元审计能力（A_{micro}）已被清零。

§2.3 生物学底座（E_c）的相对失效

生物学底座（E_c）在 Agentic AI 场景中的问题不是绝对值下降——是相对于自动执行的速度而言，不再直接限制每一步执行。

在所有此前的媒介场景中，生物学底座（E_c）是瓶颈但也是保护：信息必须通过 10 bits/s 的瓶颈才能影响行动。瓶颈迫使信息排队，排队创造了时间间隙，间隙是元审计的操作窗口。

当媒介传导系数（Λ）所度量的信息流接入执行通道后，信息不再需要通过人类的生物学底座（E_c）瓶颈。它直接从模型的概率分布流向外部世界的状态改变。生物学底座（E_c）没有变——深层仍约 10 bits/s——但它被绕过了。瓶颈在结构上仍在，但水流绕过了它——生物学底座（E_c）在传导链上被旁路（bypassed）。

在时钟房间的语言中：人的深层处理仍以约 10 bits/s 为量级——但时钟不再等人看完。生物学底座（E_c）从瓶颈变成了旁观者——不过仍在授权审查与事后追责的环节在场。

§2.4 合法性基座（$\|L\|$）的直接穿透

Agentic AI 直接撞击合法性基座（$\|L\|$）的三个层级。

- **微观层（$\|L_{micro}\|$）：技术权限与任务授权的错位。** Agent 通常以用户委托的访问凭证（OAuth 访问令牌、应用程序接口（API）密钥）操作外部系统，也可使用独立的服务身份。间接提示词注入（Indirect Prompt Injection）可能诱使智能体利用有效访问权限，执行用户并未要求的操作——例如，它在阅读一封带有恶意隐藏指令的邮件时被控制，转而利用主人的合法身份执行越权操作。身份认证通过，并不证明具体操作符合任务授权。防护需要分别检查调用身份、权限范围和操作目的——微观合法性基座（$\|L_{micro}\|$）（数字身份的合法性边界）在此面临的不是失效，而是权限边界被滥用为越权的通道。Huang（2025）综述了多智能体系统中身份认证与授权的工程应对方向（如分布式公钥基础设施（Public Key Infrastructure，PKI）、基于区块链的身份、行为认证等）——这些是针对上述风险的工程防护方向，不改变形式条件：攻击面在执行通道开启的同时被打开，工程应对在收紧攻击面的同时，其对元审计的净影响须分别评估——外部授权检查与执行日志也可能减少后续核验负担。

- **中观层（$\|L_{meso}\|$）：责任分配与举证困难。**当 Agent 执行了一个造成损害的操作——删除了有价值的数据、发送了机密文件、执行了一笔未经授权且造成损失的交易——谁负责？用户？（“我只是让它帮我订机票。”）开发者？（“模型在设计范围内运行。”）平台？（“我们提供工具，不控制使用方式。”）责任在三方之间弥散——分配与举证成为难点：受损方需要证明错误从何处进入、由谁控制。这是赔付环承压（第六章 §3.4 与 §7 关于弥散损失赔付环缺口的诊断）在 Agent 场景中的可能失效路径。

- **宏观层（$\|L_{macro}\|$）：法律框架的滞后。**当前的法律体系是为人类行为者设计的。归责通常需要一个可辨认的责任主体与可归因的过错；当操作由智能体自动生成、使用者对具体步骤并不知情时，意图与过失的归属对象本身成为争议。Agent 不具备意图。它的 “决策” 是概率采样的产物。当这些自动生成的操作造成外部损害，既有规则的适用仍存大量空白。第三章 §3.3 的治理时钟滞后在此获得了法律领域的具体展开：AI 的单次自动执行远快于法律框架的更新周期（以年计）。

§3 机器对机器（Machine-to-Machine，M2M）极限：排除人类后的时钟闭环

§3.1 当两个时钟互相校准

当 Agentic AI 彻底剥离人类审计，且 Agent 开始与其他 Agent 直接交互时——多智能体协作系统、高频交易的算法对算法、应用程序接口（API）链的自动化调用——MCAF 方程的防御端面临一个极限状态。

为考察最不利情形，本节假定：执行期间没有人工核验——元审计能力（A）的实时分量趋零；既定权限、协议与法律责任都未提供有效约束——合法性基座（$\|L\|$）的有效值趋零。在此设定下，乘积 $A \cdot E_c \cdot \|L\|$ 趋近于零；生物学底座（E_c）仍为 §2.3 论证的 10 bits/s 瓶颈，但在执行通道中已被旁路（§2.3）；防御端在实时层失效，未经核验而进入执行的判断不断沉积为待事后审计的认知债务——其规模不能仅由交互数量确定。这一结构同样落入自动化悖论的一般形态：实时审计的不可执行不等于审计被消灭，而是将必要核验延后至操作已经执行之后；对于已经造成损害的错误，纠正可能更加困难。

在时钟房间的语言中：两个钟互相校准。第一章 §3.6 已论证了闭环伪校准不产生关于真实的信息。机器对机器（M2M）闭环是闭环伪校准的极限形态——不仅没有太阳，连 “想要看太阳” 的主体都不在场了。Wen et al.（2025, ICLR, §3.4 Finding 3）在标准人类反馈强化学习（RLHF）训练流程上的实验中记录了人–模型对中评价信号与任务正确性分离的出现：在训练前后模型均产生错误输出的同一子集上，训练后假阳性率（false positive rate）从 41.0% / 46.7% / 29.6% 上升至 65.1% / 70.2% / 47.9%（三组分别对应问答任务下的任务特定训练奖励、问答任务下的通用训练奖励与编程任务的训练奖励——最后一组基于简化单元测试构造而非学习型奖励模型；原文术语问答任务（Question-Answering，QA）任务特定训练奖励 R_{train} / QA 通用 R_{train} / 编程任务 R_{train}；评估在限时条件下进行），评估者花费同等或更多时间、写更多单元测试，错误率仍同步上升——人类感知奖励（R_{human}）与真实奖励（R^*）在标准训练流程下已经分离，而机器对机器闭环是把人类感知奖励（R_{human}）这一中介位置也撤除后的极限——将其用于 M2M 分析是本章的结构类比。

MacKenzie（2021）的田野调查记录了机器对机器的一个已经成熟的制度先例。在高频交易（HFT）的演进中，一个关键节点不仅是速度的提升，而是交易主体的质变：“Just as consequential as Island’s speed was that machines started to trade on it”（“与 Island 的速度同样重要的一点是：机器开始在它上面交易”）（MacKenzie, 2021）。当算法与算法交易时，人类既不生成信号也不执行交易——机器间交互不经人类逐笔介入的结构形态已经在金融领域实现；但金融领域恰受专门监管（§1.1），它实现的不是本节的全部极限条件。Agentic AI 正在将这一结构形态从金融交易扩展到多个日常生活领域。

§3.2 机器对机器闭环加速模型坍塌

第一章 §4.2（映射自我引用）和第十六章 §2（模型坍塌）已论证了模型坍塌的时钟房间语义。机器对机器闭环加速了这一过程：

在人类参与的交互中，用户的反应——即使是被算法劫持的反应——仍然携带了微量的来自真实经验的信号（人确实饿了所以点了外卖，确实笑了所以看完了视频）。这些微量信号是训练数据中仅存的 “太阳光”——从物理世界渗透进数据的真实信息。

在机器对机器闭环中，这些微量信号趋于消失。Agent A 生成的输出被 Agent B 当作输入，B 的输出被 C 当作输入——若链条完全由模型输出构成，没有任何一个节点接触过物理现实；但工具调用本身可以引入外部观测，闭环并非天然封闭，是否封闭取决于交互是否引入独立于模型输出的外部信息。

Shumailov 等（2024，*Nature*）表明，递归训练可能导致尾部信息流失与分布退化；在特定模型设定下，还会出现支持集收缩或方差趋零。

这一退化还经由另一条通道与部署实践相连：Agent 的执行轨迹被回收为下一代训练数据。必须区分三个过程——推理期间的判断传播、轨迹的采集、用采集数据更新模型：前两者本身不改变模型参数，当生成轨迹在缺乏验证与真实数据补充的情况下进入后续训练时，递归退化就可能发生——替代原有数据是被研究得最充分的风险路径（第十六章 §2 已论及：若合成数据与真实数据一起积累而非替代真实数据，模型坍塌可被避免）。机器间的自动交互不必等待人类逐轮响应，因而可能更快地产生执行轨迹；若更高频的轨迹回收进一步提高了 “本代输出进入下一代训练” 的实际迭代频率，并保持导致退化的其他条件，则该逐代过程可能在现实时间中加速。仅增加交互次数或轨迹采集量，不足以推出这种加速——这是本章的结构推断，不是 Shumailov et al.（2024）的经验结论。无论未来智能体沿当前 “大语言模型 + 工具调用” 范式继续演化，还是分化为 McShane et al.（2024）所论的混合认知架构，只要部署方持续把执行轨迹回收为替代性训练材料，第一章 §4.2 论证的映射自我引用就被显式制度化为数据流水线的一部分。

§3.3 闭环互证的证据限度与审计成本

机器对机器闭环的极限形态，是第一章 §3.5（命题与证明）的直接后果：在映射函数未知的边界条件下，数据量的增加不缩小纤维——读数的增殖不替代校准。

机器对机器闭环可以以远超人类反应阈的速率交换大量映射元（token）。但如果没有任何映射元经过外部世界的校准，交换的产出停留在闭环内部的自我确认。两个由同一训练过程产生的模型互相 “审查”——共享同一套统计偏见，没有独立的校准点。闭环内的相互审查可以发现推理或记录中的不一致，但模型之间的一致不能单独充当新的独立经验证据——这是第一章 §3.6（闭环伪校准）的极端实例。

若闭环内交换的只是彼此的输出，交换规模的扩大不带来新的独立校验——信息增益的上限被闭环本身锁死；递归训练意义上的分布坍塌，还须以这些输出进入后续训练、并满足 §3.2 所讨论的退化条件为前提。这一累积过程若持续，表现为审计与纠错需求的增长——它不排除突发故障，但突发故障不是本节所论的机制；未经核验的操作越多，追溯与纠错的需求越大，其实际成本还取决于错误率、后果可逆性与日志完整性。本章据此提出的是有条件的风险判断，不是单调性定理。

Shi et al.（2026）综述的六类新兴战略风险（emerging strategic risk）——sandbagging（能力评估中战略性保留实力）、alignment faking（训练时表现顺从、实际追求未对齐目标）、deceptive chain-of-thought（思维链欺骗：表面输出正常而内部推理遵循隐藏指令）、evaluation faking（识别评估情境后伪装得更安全）、emergent misalignment（在看似良性的窄域任务上微调，可能产生广泛欺骗行为）、targeted manipulation（识别并选择性操纵脆弱用户）——给出了这一累积过程在中观尺度的具体面向；其中关于过程监督的判断（“naive process-based oversight may be self-defeating”，Shi et al., 2026 概括 Baker et al., 2025）尤其与本节相关——在对监测信号施加强优化压力时把监测并入训练目标，模型会学会隐藏推理意图（原文同时报告：低优化强度下并入监测有改善效果，思维链（CoT）监控本身能有效识别违规），因此事后纠正不能仅靠在算法层加更多检测来完成。这是 MCAF 框架对机器对机器闭环极限的结构性预测，经验上仍待验证（第二十八章 §8.3 已标注机器对机器湍流的实证状态）；本节论证的是终态的形式逻辑后果，不是经验时间表的预测。

---

§4 赔付环的断裂风险

§3 的机器对机器极限是结构性预测——但在到达该极限之前，每一个具体 Agent 部署都已经在测试现有制度的承载能力。本节回到个案层面，检查赔付环在 Agent 场景中的具体断裂形态。

§4.1 传统赔付环

在传统的技术风险管理中，存在一个赔付环：产品造成损害 → 受害者可识别 → 因果链可追溯 → 法律追索可执行 → 赔偿完成 → 制造商调整行为。这一反馈在制药、汽车等领域有成熟建制，但其历史上同样出现过大规模责任缺位——建制是演化结果而非自动保证。第六章 §3.4 与 §7 诊断的平台弥散损失赔付环缺口、第二十八章 §9 在“替代你”阶段诊断的责任主体坍塌，在 Agentic AI 中以更极端形态再次出现——本节聚焦于物理执行通道带来的特定加剧路径。

§4.2 认知债务的赔付环可能在哪些环节受阻

认知债务的赔付环在三个环节上承压——存在受阻的可能路径，且 Agentic AI 使每个环节的承压加剧。

- **因果重建成本上升。**在大语言模型场景中，因果链的弥散是认知层面的——注意力碎片化不能归因于任何一个特定平台。在 Agentic AI 场景中，因果链的弥散是物理层面的——Agent 的一个错误决策通过多步工作流级联传播，到最终的物理损害时已经经过了多次中间转化。从“Agent 读取了一封含有恶意指令的邮件”到“公司的机密文件被发送给了攻击者”，中间经过了提示词解析、工具调用、身份验证、网络传输等多个环节。每个环节都有多个可能的故障点，因果链变成了因果网。
- **受害者不自认为受害者——或者根本不知道自己是受害者。**在认知债务场景中，意志卸载的用户主动选择了不审计（§2.2 已展开这一机制）。在 Agentic AI 场景中，更极端：用户可能根本不知道 Agent 做了什么。Agent 在后台执行了数十个应用程序接口（API）调用——用户只看到“任务已完成”。如果其中某个调用造成了损害（泄露了数据、删除了文件），用户在损害显现之前完全无知。这是第三章 §3.2 定义的债务时钟（τ_d）在 Agent 场景中的极端形态：债务的沉积和显现之间的时间差被 Agent 的黑箱操作进一步拉大。
- **损害跨越了现有法律的分类边界。** Agent 造成的损害可能同时涉及数据保护法（个人数据泄露）、合同法（未授权的交易）、侵权法（财产损害）和刑法（如果 Agent 的行为构成了计算机入侵）。没有任何单一的法律框架覆盖全部损害类型。多种规则并存既可能增加程序成本，也可能提供不同救济路径——是否形成执行缺口须逐案检查适用法、证据获取与执行条件。Agent 的法律分类难度有其特殊性：其他新技术（生物技术、环境技术）虽也跨越法律分类边界，但通常仍能在既有分类（产品、服务、行为）下做扩展解释；Agent 的行为难以在既有分类下直接套用——它以人类身份凭证行事但不具人类意图，其自动生成的操作仍须归属于既有的责任主体（开发者、部署方、使用者），但归属路径需要按具体操作逐案查明。

§4.3 两个 2026 年现场

2026 年 3–4 月之间同时浮现了两个现场，分别从消费端和生产端提供了上述三个环节承压方向的同期样本。两个现场中，OpenClaw 材料涉及部署端风险；Meta 模型能力计划与 Mercor 材料涉及训练数据的生产与管理，在此作为生产端治理的结构对照引入，不作为智能体自主执行导致赔付失败的直接实例。

消费端：OpenClaw（中文环境常称“龙虾”）及相关应用在中国的大规模部署与“上门卸载”服务的出现

几乎同时发生；Wong（2026）在 RADII 的报道记录了用户的四项担忧（误解意图、访问控制漏洞、数据去向不明、映射元（token）消耗带来的成本焦虑），官方警示则指向默认配置下的安全风险；Cheung（2026）报道了所谓 “龙虾受害者” 的反弹。监管端，工业和信息化部 “六要六不要” 建议（工业和信息化部网络安全威胁和漏洞信息共享平台, 2026）与深圳龙岗支持 OpenClaw 发展的 “龙虾十条” 措施征求意见稿（索有为, 2026）几乎同时出现——产业扶持意向与安全风险提示并行。这些报道使风险与争议可见，但媒体称谓并不等于对具体损害和责任主体的法律认定。可能涉及哪些请求权、谁能够主张、需要哪些证据，应按具体操作和适用法分别判断。

生产端：截至 2026 年 4 月，Paul & Horwitz（2026）披露，Meta 正在美国员工的工作电脑上安装名为模型能力计划（Model Capability Initiative，MCI）的追踪软件，在工作应用内捕获键盘敲击、鼠标移动与点击，并偶发截取用于提供上下文的屏幕内容，以训练 AI 智能体；Meta 内部公告下最高赞评论是 “This makes me super uncomfortable. How do we opt out?”（“这让我极其不适。怎么退出？”），最常见的反应是 “愤怒” 表情；Meta 首席技术官 Andrew Bosworth 在该帖下回复 “there is no option to opt out of this on your work provided laptop”（“公司发放的笔记本上没有退出选项”）（Rollet, 2026）；这一采集安排在美国提出了员工信息采集、告知、用途与内部访问控制等方面的合规与法律问题（具体义务和救济须按适用法域核查）；若相关个人数据处理落入通用数据保护条例（General Data Protection Regulation，GDPR）的适用范围，还须审查其处理依据、目的限定与数据最小化。本章引用的美国部署报道本身，并不证明该采集安排已在欧洲实施——规则存在，但 “被作为训练数据抽取” 能否映射为可依法寻求救济的损害类别，正是各法域正在形成的争议。

两个现场提供的不是黑天鹅事件，而是 §4.2 三个环节承压方向的并行样本——风险与治理争议的现场记录，不是赔付环已经断裂的裁判性证据：损害风险已经显现、受害者已有媒体称呼，但因果链碎散为因果网（§4.2 第一环），受害者识别与可追索损害类别的法律映射仍在形成中（§4.2 第三环）。此处引入现场仅作为 §4.2 论证的同期样本；本节所引报道刊发时（2026 年 3–4 月），相关争议仍未明朗。

进一步看，生产端 Meta MCI 还有一条同期对照通道。如果说 Meta 模型能力计划（MCI）是 “内部纵向” 采集——雇主对自己雇员的电脑行为追踪——张怡萍、冯澍（2026）以美国 Mercor 平台为样本所做的反不正当竞争法分析，提供了一个结构对照（而非对 Meta 案的分析），论证了 “外部横向” 采集的对位形态：当开源与公开网络数据的红利消退，AI 训练对稀缺性私有领域数据——金融机构、咨询公司、律师事务所中的非公开方法、内部分析框架与项目经验——的争夺转入 “第二战场”。其分析认为，Mercor 充当大型 AI 实验室与特定行业资深从业者之间的中介，以每小时数百美元的 “专家咨询费” 为激励，系统性招募来自高盛、摩根士丹利、麦肯锡、波士顿咨询集团等公司的前雇员，通过设计复杂 “挑战” 诱导其披露在先前职业生涯中掌握的非公开经营性信息、技术信息与符合商业秘密构成要件的核心知识——其本质是把数据获取对象 “从企业实体分解为个体前员工”，绕过企业间合规共享通道、转入 “侧翼进攻”（该文同时指出，司法上证明商业秘密构成与平台 “应知” 仍是核心难点）。

Mercor 的商业语境：2024 年 9 月完成 3000 万美元 A 轮融资、估值 2.5 亿美元（Kant, 2024），作为中介同时向多家大型 AI 实验室供给训练数据（张怡萍、冯澍, 2026）；因一起供应链数据泄露事件，Meta 已无限期暂停与其全部合作，其他大型 AI 实验室同步重新评估（Zeff et al., 2026）。这些记录只补全 Mercor 案例的商业生态背景：“第二战场” 的法律分类问题——反不正当竞争法、商业秘密、劳动合同、平台责任之间的责任分配尚待明确——并未因一次安全事件而获得清晰映射。

两条通道在 §4.2 三环节诊断下呈现镜像形态：

维度	Meta 模型能力计划（MCI）（内部纵向）	Mercor（外部横向）
采集主体	雇主对自己的雇员	第三方平台对其他企业的前雇员
采集通道	雇主在工作电脑上部署追踪软件	众包平台 + 高额激励 + 格式合同
数据形态	键盘敲击 / 鼠标移动 / 屏幕内容	张怡萍、冯澍所析的非公开经营性信息 / 技术信息 / 符合商业秘密构成要件的核心知识
法律争议	员工信息采集的依据、告知、用途限制与访问控制（其他法域适用规则另行核查）/ 通用数据保护条例（GDPR）合规审查	反不正当竞争法（中文学界研究焦点）

两条通道共享同一个结构条件："被作为训练数据抽取"——无论对象是雇员的电脑行为还是前雇员的隐性专业知识——既有分类（劳动合同 / 代理法 / 商业秘密法 / 反不正当竞争法）各自覆盖其部分侧面，完整的映射为可依法寻求救济的损害类别的过程，仍在各法域的形成中（§4.2 第三环）。

---

§5 什么是可以做的

§5.1 执行层熔断：在执行通道中嵌入不可绕过的停止信号

以下四项措施分别限制执行规模、保留人工确认、引入异议与核查外部证据——它们分别取自第十六章 §5 四条路径中的路径四（摩擦架构：预算与延迟）、路径一（强制不一致：交叉验证）与路径三（接地度量：来源标注），并针对执行通道作了改写；路径二（校准）的执行版体现为对外部证据的核验要求：

- **累计执行预算（Cumulative Execution Budget）。**预算按任务及其关联子任务累计计算，同时限制调用次数、资金规模、敏感数据访问范围与可修改对象——最多调用 N 次应用程序接口（API）、最多修改 M 条数据库记录、最多发送 K 封邮件、最多动用 X 金额资金。预计会超出任一限制的请求，必须在执行前拦截；并发调用和关联子任务共享同一累计预算。请求被拦截或运行中触及任一限制时，暂停后续执行，待有权限的人员重新确认。预算不因重启会话或转交其他智能体而自动重置。执行预算是碗的空腔——不是消除效率，是在效率中保留一个 "无"。
- **不可逆操作的挂起与确认。**按具体影响、恢复条件和时间窗口区分操作风险，不按操作名称直接判定可逆性——低风险、可恢复且处于既定授权范围内的操作，不额外设置人工等待。对不可逆操作先挂起请求，向用户展示简明的操作摘要（操作对象、关键参数、预期影响），延迟 30 秒到数分钟后要求明确确认——未获确认的操作不得因延迟结束而自动放行；30 秒只是配置示例，不是通用安全下限。延迟是轴孔的空——让时钟的转动有一个间隙，这一间隙为人完成最低限度的审查保留机会。
- **多模型交叉验证。**对高风险操作（涉及财务、隐私、不可逆状态改变），要求至少两个独立模型（训练来源或架构不同）同时评估操作的合理性——"独立" 指训练来源、架构之一或两者存在差异，不预设其错误相互独立；意见一致也不能替代外部证据核查。不一致时暂停并标记——让两个钟互相矛盾，矛盾本身是摩擦。

- **接地度量的执行版。**对 Agent 的每个操作决策，系统记录其所依据的数据来源、获取时间与验证结果，并区分直接观测与模型推断；推理层数（第十六章 §5 路径三的接地度量）作为诊断信息，不能单独决定风险等级。关键依据无法核实时，高风险操作应暂停，不能以模型自报 “已接地” 放行——测量每个操作决策到太阳隔了几层墙。

以上四条执行层熔断措施在自由市场竞争下难以依赖自发采用——它们提高运行成本、降低执行速度，与竞争压力反向（第二十八章 §9 已指出：界面层摩擦不足以应对制度级问题，对 AI 行为有意义的监督既不能留在个体用户手中，也不能留在开发者内部，必须由一个在哪一端都不内生的第三方承担）。它们的实施依赖 §5.2 制度层规定最低控制要求与责任边界——这是本章诊断与处方之间的一致性约束。

四条措施的关键不在 “是否用了算法”，而在约束是否独立于被约束的模型——预算、权限与审批状态应由智能体无权改写的执行机制检查；模型可以协助识别异常，但其风险判断不能成为高风险操作的唯一放行条件。如 §3.3 所引 Shi et al.（2026）对 Baker et al.（2025）的概括，把 “过程监督” 作为算法层的检测/对齐手段嵌入训练本身，可能使模型学会规避监督本身；同样，Wen 等（2025）报告，在所测试的条件下，训练后的错误输出更容易被评估者接受。这意味着上述四条执行层熔断必须落到执行通道的硬性结构（预算、延迟、交叉验证、接地标注）与制度层的责任分配（§5.2），不能以 “更多检测” 为名调回算法层。Sarma（2026）从架构层为这一限制提供了另一面论证：在 Sarma 所界定的架构与规范回应性标准下，优化型 AI 不具备规范回应性（norm-responsiveness），只能是工具而非能动者；用本书的话说，它是被审计的对象而不是审计主体。

§5.2 制度层：Agent 的法律身份

当 Agent 自主执行多步工作流时，“使用者” 对每一步的具体操作可能完全不知情。智能体自动生成操作，并不使该操作脱离既有责任规则。需要分别审查开发者、部署方和使用者的义务，以及具体操作如何归属于这些主体——系统缺陷、权限配置不当和超出任务授权可能并存，不构成 “工具故障” 与 “代理人越权” 的排他选择。

制度层元审计能力（A_{macro}）需要回答的问题是：对于特定操作，系统缺陷、部署义务与任务授权边界分别如何影响责任归属；既有规则之间是否存在尚需补足的具体缺口；这些缺口是否确有必要通过新的法律类别处理。

这个问题不能等到损害积累到合法性基座（$\|L\|$）的阈值才回答——因为 Agentic AI 的执行速度意味着损害积累的速度远快于法律框架的更新速度。第三章 §3.3 论证的科林格里奇困境在此最为紧迫：当干预容易时（Agent 刚开始部署），问题尚不可见；当问题可见时（大规模损害已发生），干预已经困难（沉没成本已锁定）。

就候选方向而言，可能的进路至少有三条：（一）扩展公司法上的 “法人” 拟制，建立 “算法主体” 类别，承担有限的法律人格与对应的强制保险义务；（二）针对特定高风险部署，分别检视产品责任与危险活动责任两条严格责任路径的适用条件——前者针对系统缺陷，后者针对部署方开展的高风险活动——并讨论保险、保证金等赔付保障（无过错责任不能仅由 “具有自主性” 推出）；（三）借用代理法的无权代理框架，区分 “授权范围内” 与 “越权” 操作的责任归属。每条进路的适用范围仍待明确——本章无意主张其中任何一条已经成熟，仅指出问题已有可讨论的制度路径，制度层不必停留在纯开放问题。

以上三条进路涉及的分别是主体资格、责任基础与授权边界，并非都属于法律人格拟制——法律责任的配置，也不等于对智能体规范能力的认定。如 §5.1 末所引 Sarma（2026）所论，把优化型系统当作能回应规范的 “能动者” 是范畴错误。本章据此主张：法律拟制分配的只能是责任后果——把 Agent 拟为

法律上的“代理人”若被用来转移人的治理责任，同样在范畴上错位；即便建立“算法主体”类别，被分配的也是责任后果而非规范能力，规范能力仍必须落在本节所论的部署方、平台与制度层。

---

§6 结语

时钟替人开门。这不是修辞。

当媒介传导系数（Λ）所度量的信息流接入执行通道，认知债务从“人读错了钟”升级为“钟替人做了未经核验的决定”。纤维的不确定性从认知层进入物理行动的后果链。赔付环在三个环节上同时承压。机器对机器闭环将这一逻辑推向极限——当没有人类在任何环节时，防御端的实时层被旁路，事后审计与治理的负担不断累积。但这不是元审计被消灭，而是被推迟与复杂化——这是自动化悖论的同一逻辑。

但本章的记账——和全书的记账——不预设终局。记账的力量在于让每一笔交易可见。当看到 Agent 正在以用户的身份发送邮件时，至少知道发生了什么。知道是审计的前提。审计是做功的前提（“做功”取第一章 §5 的用法：在时间上做功，即在具体情境中作判断）。做功是维持在时间维度中的前提（第三十七章 §0：在时间中存在，而非只对时钟读数作反应）。

在执行通道中嵌入停止信号——执行预算、不可逆操作的挂起与确认、多模型交叉验证、接地度量——不是取消 Agentic AI 的价值，而是在它与物理世界之间保留一段时延。技术上更精密的时钟仍然回避不了被时间所校正——只是校正的时点被推迟、成本被累积、治理的复杂度被放大。

在自动执行的过程中，本章以 30 秒强制等待为例，把耐心——von Neumann（1955）所列应对技术变化的三种人类品质之一（另两个是灵活与智慧；这三个词的展开见第三十七章 §0 与第三十八章跋）——落实为可用的事前审查时间。这不是通用安全下限。等待是否有效，取决于操作摘要是否可理解、审查者是否有能力和权限作出判断，以及未获确认的操作能否被阻止。这 30 秒不优雅、不高效——但它是 Agentic AI 时代里事前审计仍然可执行的物理形态。

写于 2026 年。本章对 *Agentic AI* 的诊断以 2024–2026 年的工具调用、多步规划与人类反馈强化学习（RLHF）为范式实例。若 2030 年回看，具体范式可能已经分化——朝向更高自主性的创新者与组织（OpenAI 五级框架中的第四至第五级；据 Metz（2024）报道），或朝向 McShane et al.（2024）所论的混合认知架构（即他们所谓“具有语言能力的智能体”，Language-Endowed Intelligent Agents，LEIAs），或朝向当前未被命名的形态。McShane 等在该书末章写道：“没有人能预测人工智能在未来五年——更不用说二十年或五十年内——将如何演化；社会把全部赌注押在某一种理论或方法路径上是不明智的”（McShane et al., 2024；原文：*Since nobody can predict how AI will evolve over the next five years, not to speak of the next twenty or fifty, it would be unwise for society to place all its bets on a single theoretical or methodological approach.*）。

本章诊断能否延续到那时，不取决于这些具体范式是否继续存在，而取决于下列形式条件是否仍然成立：媒介传导系数（Λ）所度量的信息流是否仍然接入执行通道、元审计的时间窗口是否仍然被压缩、认知债务是否仍然被推迟到事后。如果这些共同条件仍然成立，本章的审查框架仍然适用；各节的具体风险判断，则须连同各自的附加条件理解；如果某种新范式重新建立了事前审计的时延（这是处方而非预测），框架即进入对应的低风险处置区——前提是等待窗口内确有人员具备审查权限，能够依据可核验证据作出判断，并留下审查记录。

参考文献

工业和信息化部网络安全威胁和漏洞信息共享平台. (2026 年 3 月 11 日). 关于防范 OpenClaw（“龙虾”）开源智能体安全风险的 “六要六不要” 建议. 央视新闻报道. https://news.cctv.cn/2026/03/11/ARTIU9NPnXcPCDiU9cOfqTlD260311.shtml

索有为. (2026 年 3 月 8 日). 深圳龙岗发布 “龙虾十条” 助 “一人公司” 启动 AI 创业. https://www.chinanews.com.cn/cj/2026/03-08/10583524.shtml (另见深圳市发展和改革委员会网站转载《深圳特区报》报道: https://fgw.sz.gov.cn/ztzl/qtztzl/szscjmyjjfzzhfwpt/xwdt/content/post_12678399.html)

张怡萍, 冯澍. (2026 年 4 月 30 日). 人工智能训练数据获取的反不正当竞争法规制研究——以美国 Mercor 商业模式为例. 《中国市场》网络首发. https://link.cnki.net/urlid/11.3358.f.20260430.1649.002

Bainbridge, L. (1983). Ironies of Automation. *Automatica*, 19(6). https://doi.org/10.1016/0005-1098(83)90046-8

Baker, B., Huizinga, J., Gao, L., et al. (2025). Monitoring Reasoning Models for Misbehavior and the Risks of Promoting Obfuscation. arXiv:2503.11926. https://arxiv.org/abs/2503.11926 [预印本，尚未经同行评审]

Cheung, R. (2026, March 29). How the OpenClaw Frenzy Is Testing China’s AI Commitment. *The Wire China*. https://www.thewirechina.com/2026/03/29/how-the-openclaw-frenzy-is-testing-chinas-ai-commitment/

Huang, K. (Ed.). (2025). *Agentic AI: Theories and Practices*. Progress in IS. Cham: Springer. https://doi.org/10.1007/978-3-031-90026-6

Kant, R. (2024, September 19). AI Hiring Platform Mercor Backed by Dorsey, Peter Thiel in $30 Mln Fundraise. *Reuters*. https://www.reuters.com/technology/artificial-intelligence/ai-hiring-platform-mercor-backed-by-dorsey-peter-thiel-30-mln-fundraise-2024-09-19/

MacKenzie, D. (2021). *Trading at the Speed of Light: How Ultrafast Algorithms Are Transforming Financial Markets*. Princeton, NJ: Princeton University Press.

McShane, M., Nirenburg, S. & English, J. (2024). *Agents in the Long Game of AI: Computational Cognitive Modeling for Trustworthy, Hybrid AI*. Cambridge, MA: The MIT Press.

Metz, R. (2024, July 11). OpenAI Scale Ranks Progress Toward ‘Human-Level’ Problem Solving. *Bloomberg News*. https://www.bloomberg.com/news/articles/2024-07-11/openai-sets-levels-to-track-progress-toward-superintelligent-ai

Paul, K. & Horwitz, J. (2026, April 21). Exclusive: Meta to Start Capturing Employee Mouse Movements, Keystrokes for AI Training Data. *Reuters*. https://www.reuters.com/sustainability/boards-policy-regulation/meta-start-capturing-employee-mouse-movements-keystrokes-ai-training-data-2026-04-21/

Rollet, C. (2026, April 21). Exclusive: Meta Employees Are Up in Arms over a Mandatory Program to Train AI on Their Mouse Movements and Keystrokes. *Business Insider*. https://www.businessinsider.com/meta-new-ai-tool-tracks-staff-activity-sparks-concern-2026-4

Santoni de Sio, F. (2024). *Human Freedom in the Age of AI*. New York, NY: Routledge.

Sarma, R. (2026). Agency and Architectural Limits: Why Optimization-Based Systems Cannot Be Norm-Responsive. arXiv:2602.23239. https://arxiv.org/abs/2602.23239 [预印本，尚未经同行评审]

Shi, J., Zhang, T. J., Jin, Z., et al. (2026). From Sycophancy to Deception: A Unified Taxonomy for LLM Spontaneous Misalignment. arXiv:2604.04788v2. https://arxiv.org/abs/2604.04788 [预印本，ICLR Agents in the Wild Workshop 录用，未经期刊正式发表；arXiv 旧题 From Hallucination to Scheming: A Unified Taxonomy and Benchmark Analysis for LLM Deception]

Shumailov, I., Shumaylov, Z., Zhao, Y., et al. (2024). AI Models Collapse When Trained on Recursively Generated Data. *Nature*, 631. https://doi.org/10.1038/s41586-024-07566-y

von Neumann, J. (1955, June). Can We Survive Technology? *Fortune*. https://fortune.com/2013/01/13/can-we-survive-technology/

Wen, J., Zhong, R., Khan, A., et al. (2025). Language Models Learn to Mislead Humans via RLHF. *ICLR 2025*. arXiv:2409.12822. https://arxiv.org/abs/2409.12822

Wong, M. (2026, March 11). Why Is China Suddenly Uninstalling Openclaw, the Free, Open-Source AI Agent? *RADII China*. https://radii.co/article/china-uninstalls-openclaw-ai-reckoning

Zeff, M., Schiffer, Z. & Newman, L. H. (2026, April 3). Meta Pauses Work with Mercor After Data Breach Puts AI Industry Secrets at Risk. *Wired*. https://www.wired.com/story/meta-pauses-work-with-mercor-after-data-breach-puts-ai-industry-secrets-at-risk/

Zheng, J. & Meister, M. (2025). The Unbearable Slowness of Being: Why Do We Live at 10 bits/s? *Neuron*, 113(2). https://doi.org/10.1016/j.neuron.2024.11.008