《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第三十五章：终局条件与制度想象——从数据枯竭到算法央行

摘要

2025 年，离散利维坦判别函数命中的关键节点（资本市场以 Mag 7 标签聚合的几家美国科技公司）的合计市值超过了欧盟 27 国的 GDP 总量。这些节点同时控制着全球数字基础设施的算力层、数据层、模型层和分发层，并单方面设定 AI 模型的内部参数——损失函数、RLHF（Reinforcement Learning from Human Feedback，基于人类反馈的强化学习）奖励、温度——而这些参数直接决定了数十亿人每天接收的认知产出的数量和质量。尚无公共机构对损失函数参数本身建立审计制度。

本章首先论证终局条件——数据枯竭、双重表演性、学科记忆力衰减——为什么使 “从错误中学习” 在 AI 领域成为制度上不可承受的策略。然后从赔付环断裂的制度化诊断与全民基本收入（UBI）的循环租金分析出发，论证这一制度空白不是 “技术太新、太复杂来不及监管”——而是一个结构性缺失，其性质与金融领域在央行制度建立之前的状态同构。参照金融领域央行制度的演化史，本章不提出一个完美的制度设计，而是论证三件事：为什么需要算法央行、管什么、以及最根本的困难是什么。

关键词

算法央行、损失函数、数据枯竭、模型坍塌、赔付环、公共审计基金、认知债务

---

§1 数据枯竭与模型坍塌——当镜子映照镜子

§1.1 数据作为资源的地质学

前几章将人类数据描述为离散利维坦的原始积累对象。现在需要追问：这种积累有边界吗？

回答这个问题需要区分两种数据。“原生数据”（native data）——人类在非 AI 中介条件下产生的文本、图像、语音等外化表达——其产出率受制于生物学约束：约 80 亿人，每人每天约 16 小时清醒时间，每

个人通过行为外化信息的吞吐速率上限约为每秒 10 比特（Zheng & Meister, 2025）——该研究同时强调感官采集速率高出约八个数量级，约束发生在行为输出端。只有被人类付诸行为并外化为可记录形式的部分才会沉淀为原生数据，能被外化的信息总量先受这一行为吞吐上限约束。“合成数据”（synthetic data）——AI 生成的、用于训练下一代 AI 的数据——产出率不受生物学约束。用地质学比喻：原生数据是化石燃料（亿万年压缩的能量，总量有限），合成数据是生物燃料（理论上可再生，但能量密度远低，且生产本身消耗能量）。这里的 “枯竭” 指既定条件下可利用存量的扩展受限，而不是数据在使用中被物理消耗；10 比特/秒的吞吐约束说明行为性信息生成的上限，不直接换算为文本、图像或训练语料的数量。原生数据的 “信息密度”——多样性、意外性、对真实世界因果结构的反映——远高于合成数据，因为后者是上一代模型统计分布的采样，每次采样都丢失尾部信息和结构性噪声（而这些 “噪声” 恰恰包含了真实世界的复杂性）。

Villalobos 等人（2022；2024 年修订版）预测：若当前趋势延续，到中位交点 2028 年，模型训练规模将逼近公开索引网页的文本总有效存量——约 4×10^{14} 词元（token）；高质量公开人类文本将在 2026—2032 年间（中位 2028 年）被完全利用。这里的 “公开人类文本” 不等同于本章严格界定的 “非 AI 中介原生数据”，后者的上限见 §1.1 的吞吐论证。Shumailov 等人（2024, *Nature*）精确刻画了合成数据替代原生数据的后果：模型坍塌（model collapse）——在不加区分地以模型输出污染下一代训练集的递归训练中，模型逐代丢失真实分布的信息，尾部最先消失，学得的行为收敛到方差极小的点估计；该效应在各类学习型生成模型中普遍存在，而保留对原始人类数据分布的访问被证明至关重要。用镜子比喻：镜子映照镜子的无限回廊，每一次反射都丢失分辨率，直到映像变成一片模糊的光斑。在宏观认知债务记账框架（Macro-Cognitive Accounting Framework，MCAF）中，这对应第二十八章 §2 的三重归零诊断：核查起点在单代模型中即被拆至零（装置不经因果核对），而不加区分的递归训练使输出分布的信息深度进一步退化——Shumailov 刻画的尾部消失与点估计收敛，可读作这一退化在分布层的实证形态。

Yu, Kim & Kim（2026, WWW ’26）将生态层的失效模式命名为检索坍塌（Retrieval Collapse）：在受控模拟中，当语料池中 67% 为 AI 生成内容时，搜索引擎曝光污染率超过 80%，且第一阶段呈现 “看似健康”——表面答案质量未下降，但信源多样性已被系统性侵蚀。Spennemann（2025）通过分析 ChatGPT 特征词频率估算，至少 30% 的活跃网页文本已来自 AI 生成来源，实际比例可能接近 40%。这意味着：即使每个 AI 模型都通过保留部分原生数据来避免训练坍塌，整个公开语料池中人类信号的占比也呈持续下降趋势。这一退化一旦发生——原始来源被再生内容覆盖且无独立存档——丢失的分布信息就无法从混合信号中恢复；不可逆性取决于原始材料的保留，而非混合过程本身。这不是模型训练的危机，是信息生态的危机。

数据枯竭的第二战场。趋近数据瓶颈的预期与稀缺领域数据的竞争，已经在产业层触发了系统性的采集形态变化。张怡萍、冯澍（2026）以美国 Mercor 平台为样本所做的反不正当竞争法分析记录：当开源与公开网络数据的红利消退，AI 训练对稀缺性私有领域数据——金融机构、咨询公司、律师事务所中的非公开方法、内部分析框架与项目经验——的争夺已经转入 “第二战场”。Mercor 充当大型 AI 实验室与特定行业资深从业者之间的中介，以每小时高达数百美元的 “专家咨询费” 为诱饵，系统性招募来自高盛、摩根士丹利、麦肯锡、波士顿咨询集团的前雇员，通过设计复杂 “挑战” 诱导其披露非公开经营性信息、技术信息与符合商业秘密构成要件的核心知识——其本质是把数据获取对象 “从企业实体分解为个体前员工”，绕过企业间合规共享通道、转入 “侧翼进攻”。

这条 “外部横向” 采集通道与第三十一章 §4.3 已记录的 Meta 模型能力计划（MCI）（雇主对自己雇员工作电脑的纵向行为追踪）构成 “数据枯竭后的第二战场” 的结构对照——内部纵向 vs 外部横向：当现有获取条件下可利用公开语料的扩张接近瓶颈，下一代训练数据的合法性边界不再由模型坍塌的内部动力学决定，而是由各种 “绕开既有合规分类” 的采集通道在哪里被法律分类系统重新捕捉决定。第三十

一章 §4.3 已显式标注：两条通道共享同一个结构条件——既有法律分类（劳动合同 / 代理法 / 商业秘密法 / 反不正当竞争法）各自只覆盖部分侧面，完整映射为可依法寻求救济的损害类别的过程仍在各法域的形成中。[1]

§1.2 双重表演性：观测者改变被观测物

模型坍塌与 “双重表演性”（double performativity）是两条可以耦合的反馈回路：前者使模型输出直接进入后续训练；后者使模型改变人类行为、改变后的行为再进入后续训练。两者共同扩大训练数据与独立现实证据之间的脱距。Callon（1998）首先提出经济学的 “表演性”（performativity）——经济理论不仅描述市场，而且参与构造市场。MacKenzie（2006）将这一洞察具体化为金融模型不仅描述市场——它们塑造市场：Black-Scholes 期权定价模型的广泛使用使实际价格趋近于模型预测。这是单重表演性：模型 → 改变现实 → 现实趋近模型。MacKenzie 的分析限于金融经济学与金融市场的关系。

AI 引入了双重表演性。第一重：AI 模型改变用户行为（推荐算法改变阅读习惯、聊天机器人改变写作风格）。第二重：用户改变后的行为成为下一代 AI 的训练数据——AI 学习的不再是 “人类的自然行为”，而是 “被上一代 AI 改变后的人类行为”。两重表演性的耦合产生自指回路：AI 塑造人类 → 人类的新行为训练 AI→ 新 AI 进一步塑造人类 →…

双重表演性使得 “经验”——无论个人的还是学科的——迅速失效。2020 年观察到的 “用户行为模式” 到 2023 年已被多轮推荐算法迭代重塑。经验描述的世界已经被产生经验的系统本身改变了——这是观测者效应在宏观社会层面的放大版本：观测行为（AI 训练与部署）系统性地改变了被观测物（人类行为数据），使得基于历史观测的预测从根本上不可靠——MacKenzie 所说的表演性从金融模型扩展到了整个行为数据生态。

§1.3 学科记忆力的阶梯

双重表演性使一个原本就脆弱的条件变得更脆弱：学科记忆。

信息科学家 Burton 和 Kebler 在 1960 年提出文献 “半衰期” 概念——借用放射性物质的衰变隐喻描述一个领域文献被淘汰的速率，并用引用数据加以操作化（Burton & Kebler, 1960）。经济学家 Fritz Machlup 同期对知识生产与知识过时的经济学分析为这一思路提供了更广的背景（Machlup, 1962）。Samuel Arbesman 后来在《事实的半衰期》中综合大量计量学研究，指出不同学科的知识半衰期存在显著差异（Arbesman, 2012）。这一差异对 AI 治理有直接含义。

赵鼎新在对自然科学与社会科学方法论差异的系统分析中，为这一差异提供了一个结构性的解释（赵鼎新, 2015）。他区分了法则、覆盖性法则与机制三种基本知识形态（赵鼎新, 2015; 赵鼎新, 2022）。**法则**（law）是条件在广泛场合下成立的因果关系——牛顿第二定律在宏观低速世界中 “总是成立”，因此是法则。**覆盖性法则**（covering law）不直接推导出下属机制，但约束机制的方向——生物学中的进化论即属此类：生物机制多得难以枚举，但 “不符合进化原则的生物学机制是很难长久存在的”。**机制**（mechanism）只在非常有限和特殊的条件下成立——价格规律就是一个机制，因为它需要完全理性、信

[1] 以渐进式监管学习的典型工具——监管沙盒（regulatory sandbox）——为对照层：郭滕达与周代数（2026）系统梳理 2024–2025 年美、英、欧 AI 监管沙盒政策设计，总结为 “准入机制的科学性与透明度 / 明确豁免范围 / 构建完善的反馈闭环制度 / 将风险管控嵌入各运行环节”。沙盒作为 “试探性治理工具” 假定的核心问题是现有规则难以精确适配新技术——但 §1.1 揭示的结构性变化（公开数据耗尽 → 训练数据采集通道穿透合规分类边界）以及本章 §7 将提出的算法央行（损失函数 / 奖励模型 / 公共边界定义权）所处的层级，都高于沙盒所能覆盖的层级。本书引述郭滕达、周代数（2026）仅作为 “主流监管想象的层级标记”，不连带借入其规范性政策建议（“创新促进与监管学习并重的工具属性 / 多维度差异化的入盒评估体系 / 将沙盒发现转化为制度优势的政策闭环” 等）。

息充分流畅、交易无成本等多个在现实中很难同时满足的条件。“定律（法则）是广适性的‘机制’，机制是理想条件下才能成立的‘法则’”（赵鼎新, 2015）。

这一区分直接解释了知识半衰期的阶梯：建立在法则上的知识天然长寿，因为法则的成立条件几乎处处满足，不会因为人类忘记它而改变；建立在机制上的知识天然脆弱，因为机制的成立条件可以——并且经常会——被人的行动所改变。赵鼎新进一步指出，自然科学中的范式转换是**不可逆的**——“新范式一旦建立，旧的范式与相应理论或者失去价值……或者其价值将被清楚地锁定在一定范围内”；而社会科学的发展路径是“多元范式下主流范式的**交替**（paradigm alternation），而不是范式转移”——“你方唱罢我登场”（赵鼎新, 2015）。

物理学处于光谱的一端——它建立在法则之上。牛顿三定律自 1687 年提出至今，被广义相对论和量子力学限定了适用范围，但作为近似仍然有效——它们没有被“遗忘”。用赵鼎新的术语说，相对论的出现“锁定了牛顿力学的应用范围”，但没有使其失去价值——这就是范式转换的不可逆性。物理学的记忆长寿还有一个更直接的原因：苹果自己会掉。物理法则的经验验证不依赖人类的制度记忆——即使所有教科书被烧毁，下一代人仍然会观察到苹果落地。用 MCAF 的语言说，物理学的合法性底座（$\|L\|$）有一部分锚定在人类制度之外的物理现实上。

金融学处于光谱的另一端——它建立在机制之上，而非法则。明斯基在 1986 年出版的《稳定不稳定的经济》中提出的金融不稳定假说描述了一个内生动力学：稳定期滋生过度冒险，杠杆积累，最终自我颠覆（Minsky, 1986）。这一动力学与 2008 年次贷危机的展开过程高度吻合——但在危机前的十年间，明斯基在主流金融学中几乎被遗忘了。危机后被重新“发现”，到 2020 年代中期金融市场再次呈现他描述的诸多特征（杠杆率上升、风险溢价压缩），仿佛教训从未发生。这正是赵鼎新所说的范式交替的模式：金融学的知识不是被更好的知识不可逆地取代，而是在遗忘与重新发现之间循环往复——“你方唱罢我登场”。金融知识的过时不像物理知识那样有外部现实的自动纠错——钱不会自己记住自己曾经贬值过。金融学的合法性底座（$\|L\|$）依赖制度记忆（监管规则、风险模型、机构文化）来维持，而制度记忆会被人员更替、利润压力和“这次不一样”的叙事侵蚀。

AI 工程可能处于光谱的极端位置——它不仅建立在机制之上，而且机制本身的存续期极短。1966 年 IEEE（Institute of Electrical and Electronics Engineers，电气与电子工程师学会）旗下刊物 *Spectrum* 一篇题为“Technical Obsolescence”的报道估算，到 1960 年，工程学位的知识半衰期已缩短至约 10 年（Petersen, 1966）。1978 年 ACM（Association for Computing Machinery，美国计算机学会）年会上，Charles Babbage Institute 的 Paul Armer 在《计算机专业人员的过时问题》（Obsolescence of the Computing Professional: The Problem and Possible Solutions）报告中考察了当时流行的判断——计算知识的“半衰期”只有五年——并得出结论：证据虽属间接，但有充分理由认为数据处理知识的“半衰期”远短于个人的工作寿命（Armer, 1978）。

AI 工程的情况比一般软件工程更极端。2018 年发表的 BERT（Bidirectional Encoder Representations from Transformers，基于变换器的双向编码器表示）在 2019–2021 年间在 NLP（Natural Language Processing，自然语言处理）基准测试上占据主导，到 2023 年已被大语言模型范式大幅取代——主导期不到五年（Devlin et al., 2019）。2025 年 Quanta Magazine 对 19 位 NLP 研究者的口述史记录了这一更替的亲历——受访者 Julian Michael 回忆“大量项目在 BERT 发布时被直接放弃”，而到 ChatGPT 出现后，整个领域再次被重塑（Pavlus, 2025）。类似地，2015 年被视为最佳实践的深度学习工程经验——LSTM（Long Short-Term Memory，长短期记忆网络）、手工特征工程——到 2020 年已在很大程度上过时。

需要标注：AI 工程知识半衰期的系统计量研究尚不存在。“五年”的判断是基于两个相邻范式更替窗口的归纳，样本量有限。但方向是明确的：自 ACM 1978 年的讨论以来，计算机领域的知识老化速度在持

续加速，AI 作为其中迭代最快的子领域，其知识半衰期几乎必然短于工程学的十年基准。

这种极短的经验有效期有两个原因。其一是技术更替本身极快——每一代新模型使上一代的工程经验贬值。其二是前一小节讨论的双重表演性：经验描述的对象——人类行为数据——在经验产生后就已被改变。用赵鼎新的框架理解：物理学建立在法则上，法则的成立条件（宏观、低速）不会因为人类的行动而改变；金融学建立在机制上，机制的成立条件至少在一定时期内保持稳定，因此知识可以通过制度记忆积累；AI 工程建立在一种更脆弱的结构上——它处理的不是法则，甚至不是条件相对稳定的机制，而是统计分布——统计分布会因为模型自身的部署而发生漂移。AI 工程的合法性底座（$\|L\|$）既不能像物理学那样锚定在外部现实上，也难以像金融学那样依赖制度记忆来积累——制度建设的速度远慢于技术迭代的速度。

这一阶梯的政策含义是：**AI 治理不能依赖“从错误中学习”**——因为错误的教训在被制度化之前就可能被下一轮技术迭代洗掉。金融监管提供了一个参照：Basel II 从 2004 年的制度缺陷暴露到 2008 年的危机验证到 2010 年的 Basel III 修补，学习周期约六年。NLP 领域从 BERT 到 GPT-4 的范式更替大约也用了五年，但 AI 的工程迭代节奏远快于监管制度的响应能力。在 AI 领域，等待危机来提供教训，可能是一种制度上难以承受的策略。

一道反衬可以看清这一点：郭滕达、周代数（2026）系统梳理美国、英国和欧盟的 AI 监管沙盒设计——一种在受控边界内允许试错、由监管者陪同观测、出错后调整规则的渐进式学习架构。沙盒确实把“从错误中学习”封闭进了一个有围栏的实验场，但其底层时序仍是“先释放、再观测、再调整”——校准周期由监管者的观察—复盘速度决定。在 AI 工程以多个范式更替窗口度量的快速迭代节奏下，沙盒所降低的只是单次试错的外部性损害，未触及本节诊断的核心：教训的“被制度记忆消化”速度仍慢于产生教训的“模型代际更替”速度。沙盒是必要的减损工具，但不是充分的认识论替代——这一点为后文 §3 历史参照与 §7 算法央行论证提供了反衬。

---

§2 制度空白的结构

前文已从终局条件的视角完成了两个关键论证：认知债务的结构性不可逆性（§1.1–1.2）、学科记忆力的衰减（§1.3）。本节在此基础上追问制度空白的具体结构。

§2.1 七家公司的估值规模与基础设施集中

第三十三章 §5 已给出了基本的规模数据：七家公司总市值约 20.8 万亿美元（截至 2025 年 10 月初），超过欧盟 27 国约 19.4 万亿美元的 GDP 总量（2024 年口径，详见第三十三章 §5）。此处补充一个结构性观察：这些公司不仅是“大”——它们在四个关键层同时控制了数字基础设施：

- **算力层**：英伟达的 GPU（图形处理器）硬件垄断加 CUDA（统一计算设备架构）生态锁定，加上三大云（AWS 亚马逊云、Azure 微软云、GCP 谷歌云）。几乎所有前沿 AI 训练都在这套基础设施上运行。
- **数据层**：Google 搜索覆盖全球约九成的搜索市场，Meta 旗下平台月活用户超过 30 亿（2025 年前后公开口径）。Amazon 的电商数据。Apple 的设备数据。覆盖了人类数字行为的几乎全部场景。
- **模型层**：OpenAI（微软投资）、Google DeepMind、Meta LLaMA、Anthropic（Amazon 投资）。全球前沿大模型几乎全部出自这个网络。
- **分发层**：App Store、Google Play、各平台推荐算法。决定内容触达最终用户的通道。

四层同时控制不是市场竞争自然形成的多元格局。是结构性的中心化——少数节点同时控制了基础设施、数据来源、模型开发和内容分发。

§2.2 三权合一

当前的制度空白可以用一个精确的类比描述：这些公司同时扮演立法者、央行和商业银行。

- **"立法者"**：它们设计损失函数——决定模型"想要什么"。损失函数不是技术参数——它是 AI 系统的"宪法"，定义了优化目标。这个"宪法"由公司的工程团队单方面制定。
- **"央行"**：它们设定推理参数——温度（temperature，控制输出的随机性：温度越高，模型越倾向于从低概率选项中采样，输出越发散；温度越低，输出越集中于最高概率选项）、Top-p（核采样阈值，限定模型只从累积概率达到 p 的候选词中采样，p 越小，输出越保守）、采样策略——决定每次输出的"认知货币"的发行量和质量。
- **"商业银行"**：它们直接面向数十亿用户提供服务——"放贷"认知产出。

三权合一意味着没有外部制衡。金融领域花了几百年才把这三个功能分离。AI 领域的三权仍然合一。

§2.3 平台权力与央行权力的结构同构

§2.1–2.2 已确立了事实：少数实体同时控制四层数字基础设施并集三权于一身。本节论证这一权力为什么在性质上是央行级的——它需要被公共化的理由与央行被公共化的理由具有结构同构。

§2.3.1 同构的本体论基础：中心化处理公共资源

同构的本体论基础不是"都管时间"这一修辞类比，而是一个精确的结构条件：**少数节点对公共资源进行中心化处理，其处理行为具有系统性外部效应且不可分散供给**。央行的中心化是"一国一币一利率"——一个利率决策影响全部经济行动者的跨期配置。平台的中心化是"一个推荐算法决定十亿用户看什么"——一个损失函数塑造全部用户的认知环境。比如，快手短视频推荐系统每天对数亿日活用户执行中心化排序，优化指标是 watch time（观看时长）、interaction rate（互动率）和 7 日留存（Lin et al., 2026, SIGIR）。抖音/TikTok 的规模更大。这不是"涉及时间"的语词相似——这是中心化处理公共资源这一结构条件的精确匹配。

Bajaj 等人（2026）从多智能体系统安全角度提供了理论支撑。他们原本的核心论点是：在交互系统中，决定系统行为的不是单个模型的属性，而是**交互拓扑**——信息流的结构；当拓扑呈集中式时，规模增大不是纠正信息级联而是稳定信息级联。本书对此的应用是：推荐算法正是这种集中式拓扑的实例——十亿用户的信息流由单一损失函数的梯度下降统一塑造，用户的个体反馈不可能逆转系统级的分配逻辑。Bajaj 等人论证的是 AI 智能体（agent）之间的拓扑安全；我们将同一结构映射到"平台-用户"关系中：平台是唯一的高效节点，用户是被动接收端，拓扑决定了权力不可分散。

§2.3.2 权力深度的比较：宏观时间价格 vs 微观注意力分配

央行管理时间的**宏观价格**。利率是"时间的价格"（Chancellor, 2022）——调利率就是调整"现在的钱"与"未来的钱"的兑换比率。央行通过利率影响所有经济主体的跨期决策：企业是否投资长周期项目、个人是否储蓄而非消费。但央行**不能决定**：你具体把钱花在哪里、看到什么价格、接收什么信息。央行的权力是间接的——通过价格信号影响预期，个体仍保留选择权。

算法平台管理时间的**微观分配**。推荐算法直接决定用户在哪条内容上停留 3 秒还是 30 分钟、直接决定用户看到什么；并通过反复暴露与反馈结构，系统性地影响用户感受什么、倾向相信什么。算法通过实

时竞价系统，按展示、点击与转化事件为注意力定价（CPM/CPC/CPA——依次为千次展示、每次点击、每次转化行动计费，见 §2.3.3）。平台的权力是直接的——不经过价格信号的中介，直接铸造用户的认知环境。

这个比较不是同构论证的基础（同构基础在 §2.3.1），而是一个加强论点：如果央行——仅仅间接影响跨期配置——因为满足三项公共化依据（见 §2.3.6）就需要被公共化，那么平台——直接铸造认知环境，穿透性比央行更强——满足同样条件时，公共化的理由只会更强。

§2.3.3 注意力的精确定价机制：CPM/CPC/CPA

算法平台不仅 "占用时间"，更通过广告竞价系统按展示、点击与转化事件为注意力标价。三种主要定价机制：

- **CPM（Cost Per Mille）**：广告主为 1000 次内容展示支付的价格。广告主对高参与度流量的出价通常更高，高参与度内容的 CPM 随之趋于更高——算法因此有结构性动机推荐前者。
- **CPC（Cost Per Click）**：广告主为 1 次点击支付的价格。标题党、情绪化内容的点击率通常远高于严肃内容——算法因此有结构性动机推荐标题党。
- **CPA（Cost Per Action）**：广告主为 1 次转化（购买/注册）支付的价格。冲动消费品的转化率通常高于长期投资品——算法因此有结构性动机推荐冲动消费。

关键差异在此浮现：央行的利率是**单一公开参数**，作用于所有经济主体，可被所有人观测和预期。算法平台的 "注意力价格" 是**数十亿个不透明参数**——每条内容、每个用户、每个时刻都有不同的价格，外部无人可审计。这不是 "更复杂的利率"——这是**定价权本身被隐藏**。央行的利率决策需要公开会议纪要和听证；平台的注意力定价决策在损失函数的梯度下降中自动完成，无任何公共问责。

§2.3.4 损失景观的重塑与公共约束的缺失

央行通过利率重塑**经济景观**：利率 5% 使长周期项目的净现值暴跌——这些项目在投资景观中变成 "高损失区域"；利率 0% 使之变成 "低损失区域"。但央行的目标是公共的（价格稳定 + 充分就业），有独立性保障和问责机制。

算法平台通过损失函数重塑**认知景观**。简化的推荐系统损失函数形如：

$$L = -\alpha \cdot \text{watch_time} - \beta \cdot \text{interaction} - \gamma \cdot \text{share} + \delta \cdot \text{diversity_penalty}$$

当观看时长的权重与变化范围联合压倒多样性项（$\alpha \cdot \Delta w \gg \delta \cdot \Delta d$）时，高参与度内容在流量景观中趋于成为 "低损失区域"，深度内容趋于成为 "高损失区域"。创作者理性响应：生产高参与度内容——短视频创作者为什么都在前三秒放钩子？外卖骑手为什么冒着生命危险逆行？电商卖家为什么用几乎相同的标题和封面？因为算法定义的损失景观使这些行为成为局部最优。其中 diversity_penalty 表示对多样性不足的惩罚；权重的比较须结合各变量的尺度与变化范围。本式用于说明推荐系统的激励形成，配送与电商系统的实际目标函数须分别考察——骑手与卖家案例说明的是同类结构性激励，不是同一函数。用户被动消费：深度内容逐渐从可见子空间消失。**但平台的目标是私有的**（利润最大化），无独立性约束，无公共问责。

Shu & Wei（2026）的**决策能量密度**框架为这一比较提供了分析框架。他们定义 $E_i^d = \lambda_i \cdot \iota_i \cdot \rho_i$（$\lambda$= 决策生成率，$\iota$= 影响量级，$\rho$= 执行到达范围），论证对象是 AI 系统安全：当部署摩擦下降时，最高效节点的 E^d 持续上升，制度若无边界约束则主权向该节点转移。他们未做央行类比。本书将 E^d 分别代入

央行与平台：央行的 $\iota \times \rho$ 来自 “一次利率决策影响全部经济行动者的跨期配置”；平台的 $\iota \times \rho$ 来自 “一次损失函数驱动的优化更新改变十亿用户每日数千次内容曝光的分配”。两类机构的决策能量密度在此仅作结构比较；差异在 λ：平台的优化决策连续发生在毫秒级，央行的利率决策每六周一次——平台的 E^d 显著高于央行。两类机构决策能量密度的可比估计尚未完成，本段不给出数值结论——而其所受的约束几乎全部落在输出端，对优化目标本身（第四层）的约束为空。

Zhou 等人（2026）从另一个角度支撑同一论点。他们的原始论证是：**目标选择失败**（objective selection failure）是一类与能力失败相区别的独立失效模式——标量优化只在特定假设下有效，将异质目标压缩为单一数值时，上下文相关约束会系统性受损。本书的应用是：平台的损失函数正是这种标量压缩的制度化——将认知健康、信息多样性、社会信任等异质公共目标全部压缩为 “参与度” 单一标量，这不是工程缺陷，是制度缺陷。

Coyne（2026, FAccT）进一步论证：RLHF 标注者扮演三种规范性角色（Extension 扩展、Evidence 证据、Authority 权威），标注流水线与损失函数的设计决策因此不只是技术决策，也是元伦理、道德与政治决策——本书将其概括为：损失函数的设计是政治选择。本书同意这一判断，并将其推至制度结论：既然是政治选择，就不应由私人实体单方面做出。

§2.3.5 从推荐平台到生成式 AI 平台：认知替代的加剧

传统算法平台（早期 Facebook、YouTube）主要进行内容推荐，用户仍需自己生产内容、做出决策。生成式 AI 平台（ChatGPT、Claude、Copilot）开始直接替代认知劳动——写作、编程、分析、决策。

Chalkidis & Søgaard（2026, FAccT）系统综述了认知卸载效应的经验证据：AI 依赖与统计显著的批判性思维下降、大脑连接性减弱、独立执行技能丧失相关联。McGurk & Khachaturov（2026, Cambridge）论证并预测：AI 饱和市场将形成 “杠铃经济”——中间层认知劳动赖以议价的稀缺性溢价被持续压缩，作者预计其租金趋近消失。Brynjolfsson 等人（2025）的现场研究数据显示，AI 辅助使低经验工人的生产率提升显著高于高经验工人（新员工更快沿经验曲线上升），提示经验溢价正在被压缩。

本书对这三组发现的综合应用是：认知替代的加剧使得 §2.3.1 的 “中心化处理公共资源” 从内容层扩展到劳动层——平台不仅中心化处理信息分配，开始中心化处理认知生产本身。这使得公共化的紧迫性从 “保护信息多样性” 升级为 “保护劳动力的技能存量”。后者的不可逆性在于：被去技能化的劳动者不能被 “印出来”——§8.3 将展开论证这一根本不对称。

§2.3.6 央行公共化的三项依据

央行为什么被公共化？不是因为它 “管时间”——而是因为三项依据指向同一结论：

将系统性平台权力纳入公共治理的三项依据	平台对应项	文献支撑
① 货币供给是公共品，不可分散供给——一国只能有一种基础货币，不可由市场自发协调	公共注意力池与信息生态是公共品，不可分散供给——搜索/推荐的网络效应使信息入口高度集中，用户无法 “选择” 退出推荐生态	He et al.（2026）：Common Crawl（公开网页语料库）中大语言模型（LLM）主导网站从 2022 年的 2.1% 增至 2025 年的 29.4%；2/3 的搜索查询在前 20 结果中至少含一个大语言模型主导网站——信息生态正在被至今未见逆转地统一化
② 利率有强外部性——一家银行的利率决策影响所有其他银行的资产负债表和实体经济的投资决策	推荐算法输出有强外部性——一个平台的内容分发策略系统性地影响用户认知健康、信息多样性和社会信任	Chalkidis & Søgaard（2026, FAccT）：外部性从个人认知级联到社会人力资本存量（详见 §2.3.5）
③ 货币发行权由私人垄断会产生系统性道德风险（历史诊断：自由银行与私人发钞时期，私人铸币商有通胀动机）	损失函数/映射函数的设计权当前完全私有化——平台有结构性动机将多目标压缩为单一标量（参与度/利润）	Zhou et al.（2026）：目标选择失败——标量奖励压缩异质目标（详见 §2.3.4）

前两条事实性依据（不可替代的公共品地位、强外部性）在平台侧已经成立；第三条是历史诊断而非事实性依据——当发行权事实上已被私人垄断时，公共化是治理史的常规出路。问题的性质由此不限于 “市场失灵需要政策补贴”——发行权的配置本身需要公共决定。央行不是 “补贴” 银行业——它是从结构上将基础货币的发行权从私人银行中剥离出来（商业银行在公共边界内的存款创造，见 §7.1.2 的分置处理）。§7 论证的 “算法央行” 不是 “补贴”AI 安全——它是论证损失函数的设计权为什么不能完全留在私人手中。

§2.3.7 利率 →AI 形态 → 注意力价格 → 认知摩擦消灭

§2.3 的论证到此可以与第三十四章的核心论点形成因果链。第三十四章论证了：超低利率时代（近零利率 2008–2015 与 2020–2022，其间 2015 年末至 2019 年中短暂加息）压低了长周期试错的资本约束 → 多条 AI 路线并行；加息（2022–）恢复 “时间的价格”→ 变现最快的路线获得系统性生存优势 →LLM 胜出。

本章 §2.3 补充因果链的后半段：LLM 的生存压力 → 必须快速变现 → 必须最大化用户参与度 → 损失函数的私有结构被进一步强化 →CPM/CPC/CPA 系统性偏向高参与度内容（§2.3.3）→ 损失景观重塑（§2.3.4）→AI 开始替代认知劳动 → 消灭认知摩擦（§2.3.5）。

完整因果链：**利率不仅决定了 “哪种 AI 被制造”（第三十四章），更通过 AI 的形态决定了 “注意力如何被定价”（§2.3.3–4），最终决定了 “哪些认知摩擦被消灭”（§2.3.5）。**这不是 “技术进步的副作用”——这是利率通过 AI 形态筛选，将 “认知摩擦消灭” 锁定为结构性必然。

§2.3.8 根本不对称：不能印出熟练劳动者

金融当局在危机时可以 “印钱” 与动用公共资金——美联储注入流动性（2008 年流动性工具与量化宽松、2020 年无限量化宽松（QE）），财政部实施救助（2008 年 TARP（美国问题资产救助计划））。但当 §2.3.5 描述的去技能化过程完成后，无法通过任何货币政策或财政政策快速 “印出” 一批具备实际操作能力的劳动者——技能的获得需要时间和认知摩擦，这是无法跨越的物理约束。

这意味着 AI 治理的重心必须放在**预防而非救援**——§8.3 将展开论证这一不对称的制度含义。

§2.3.9 MCAF 接口与 §7 的逻辑连接

在全书的术语体系中，平台的央行级权力精确表述为：对 Λ（媒介传导系数）的公共边界定义权和对 ϕ（叙事载荷）的映射函数垄断。§2.1–2.2 的 “四层控制” 在 MCAF 中的含义是：平台同时垄断了传导系数的设置（推荐权重）和叙事载荷的铸造模具（损失函数）。

Shu & Wei（2026）的边界稳定化定理在 MCAF 中可被翻译为：安全不需要证明 Λ 和 ϕ 的每个值都是正确的，只需制度设计防止这两个变量的公共边界定义权被单一高效节点垄断。§7“审计损失函数” 的制度提案因此可以被精确翻译为：将 Λ 和 ϕ 的公共边界定义权从私人实体收归公共审计——正如央行制度将利率设定权从私人银行收归公共机构。

为什么需要 “央行” 而非 “监管局”？因为监管局多数是行为规制与事后追责（SEC 查内幕交易、FTC 查欺骗性商业行为），少数是事前准入（FDA 批准药品上市，并购审查的事前申报也不覆盖目标函数设计）——但算法平台的问题不是 “违反了某条规则”，是**规则本身是私有的**。§7 将展开论证：算法央行不是 “监管算法”，而是管理认知基础设施的公共边界——正如央行不是 “监管货币”，而是管理货币体系的公共基础设施。

---

§3 历史参照：制度是被危机逼出来的

> **给从 AI 路径进入的读者。**本节的金融监管史案例依赖一个核心判断：金融工具是将实体经济的真实状态离散化为可交易读数的时钟（第十七章论证）。当这些时钟互相引用而不再指向实体经济时，系统进入映射自我引用——价格引用评级，评级引用模型，模型引用价格，真实状态从映射链中消失。2008 年次贷危机是这一结构的极端实例。巴塞尔协议 II（2004）把资本计量建立在银行内部模型之上——虽有监管批准与独立验证程序，但风险参数的主体由银行自行估计，自我评估处于机制的中心。结果：近 11 万亿美元的家庭财富在危机中蒸发，数万亿美元的纳税人资金被迫注入金融体系（Financial Crisis Inquiry Commission, 2011）。巴塞尔协议 III/IV 的回摆是承认这个错误：在内部模型之外加设产出底线（以更稳健的标准化计量约束内部模型的结果）并强化外部验证——不是禁止内部模型，也不是以产出底线替代外部审计，而是不让内部模型的结果缺乏外部约束。这个教训对 AI 治理的直接类比是本章的出发点：当前 AI 公司自己设计损失函数、自己训练 RLHF 奖励模型、自己做红队测试、自己发布安全报告——结构上和 Basel II 完全同构。

§3.1 英格兰银行：252 年

1694 年，威廉三世为筹措战争经费特许成立英格兰银行——一家私人股份制银行。此后一个半世纪被一系列金融危机反复推向 “最后贷款人” 角色。1873 年 Bagehot 在 *Lombard Street* 中系统阐述最后贷款

人原则（Bagehot, 1873）。1946 年国有化（自 1694 年起 252 年）。1997 年获得操作独立性（又 51 年）。从私人特许银行到独立公共央行——303 年。

§3.2 美联储：三次尝试两次失败

1791 年汉密尔顿推动第一合众国银行，1811 年被拒绝续期。1816 年第二合众国银行，1832 年被杰克逊总统否决续期。此后是漫长的无央行时期——自由银行时代（1837–1863）与国民银行时代（1863–1913），没有最后贷款人。1907 年恐慌：70 岁的 J.P. 摩根（J.P. Morgan）个人出面救援。**一个人不能代替一个制度。**这个教训推动了 1913 年《联邦储备法》。

§3.3 巴塞尔协议：40 年仍在迭代

1988 年 Basel I 回应银行倒闭潮。2004 年 Basel II 引入三支柱——犯了致命错误。2008 年证明了灾难性。2010 年 Basel III。2017 年改革（Basel IV）原定自 2022 年起分辖区分阶段实施，2020 年 3 月因疫情应对推迟至 2023 年 1 月起，进一步限制内部模型——截至本写作仍未全部落地（Basel Committee on Banking Supervision, 1988, 2006, 2011, 2017）。近 40 年，仍在迭代。

§3.4 共同模式

三个案例共享四个模式：没有制度一步完成；触发条件是具体灾难不是预见性理论；最大阻力来自既得利益方——Stigler（1971）将这一模式系统化为 “监管俘获” 理论：产业有动机和资源将监管机构转化为自身利益的保护者；国际协调最难。**Basel II 的教训最直接：不能让被监管者用自己的模型评估自己的风险。**这正是当前 AI 公司在做的事。Basel II 在 2004 年做出的那个致命选择——允许银行使用内部模型计算风险权重——不是疏忽，是一种意识形态：相信市场参与者比监管者更了解自己的风险。2008 年证伪了这一信念。AI 领域的当前状态在逻辑上更极端：不是 “被监管者用自己的模型评估自己的风险”——是被监管者在设计评估风险的标准本身。

§3.5 赔付环演化的金融参照

以上三个案例（英格兰银行、美联储、巴塞尔协议）聚焦于央行与资本监管的制度史。与之平行且同样关键的是**赔付环本身**的制度化——从 1752 年费城第一家火灾保险公司到 2010 年《多德-弗兰克法案》，金融领域（以美国为主线）用 258 年建成了三层赔付环的初级完整形态：合约层（保险、存款保险）、系统层（最后贷款人、有序清算）、社会层（QE（量化宽松）与通胀摊销）。每一次结构性推进都由灾难性损失驱动——1933 年美国联邦存款保险公司（FDIC）回应大萧条 9000 家银行倒闭；1998 年长期资本管理公司（LTCM）救助阻断跨市场链式传导；2008 年 TARP（美国问题资产救助计划）回应金融体系风险集中爆发的救助需求；2018 年中国资管新规以渐进式治理消化约 100 万亿元影子银行存量。**赔付环 258 年演化的完整史料、三条 MCAF 诊断（显现函数临界行为、纯防御不可能、结构性干预可行性）及可证伪条件，见第二十二章。**

金融参照在时间维度上指向 AI 领域的三层不对称。**时间不对称**：金融用 258 年建成赔付环，AI 的技术范式更替约 5 年（BERT 2018 → GPT-4 2023）——制度建设周期远长于技术迭代周期，把补救性学习作为主路径，在 AI 时钟下不够用。**知识半衰期不对称**：金融危机的教训可以被制度化（Basel III 修正 Basel II 的错误），因为金融的底层机制（杠杆、流动性、期限错配）在世纪尺度上相对稳定；AI 工程处理的是统计分布而非稳定机制——§1.3 的学科记忆力阶梯表明，当一轮教训还未制度化，触发它的技术范式已被下一轮替代，教训在制度化之前贬值。**首次危机缓冲的不对称**：现代金融史上波及最广的危机（1929 大萧条）发生时，人类已积累了 177 年的保险业经验、合约化风险分担机制和再保险网络作

为缓冲；AI 的首次系统性危机将在**完全没有赔付环**（无强制赔付）、**完全没有独立审计机构**（无 “AI 版 PCAOB——美国公众公司会计监督委员会”）、**完全没有国际协调框架**（无 AI 版巴塞尔委员会）的条件下发生。

这三层不对称共同支持：不能把等待重大损害之后的补救性学习作为唯一制度路径。等待 “AI 的 1907 时刻”（促成美联储成立的银行恐慌）或 “AI 的 2008 时刻” 发生后再建立制度，在 AI 的技术时钟节奏下是一种**制度上不可承受的策略**——这是本章后续所有前置性制度设计（§5 公共审计基金、§7 算法央行、§9 制度想象的两条路径）的根本动机。

---

§4 当前监管的共同缺陷——纤维框架诊断

本书第四章引入了纤维框架的核心直觉：给定一个映射函数，读数 r 背后的可能性空间就是该读数的纤维。当映射函数不透明时，知识条件下的识别集合随之变大（第四章 §2.4）——同一个读数兼容了完全不同的真实状态。伪小纤维是纤维框架最具实践价值的概念：当系统用确定的语气掩盖不确定性时，纤维在感知上被压缩（伪小纤维），但知识条件下的识别集合并未缩小。

在用纤维框架展开具体诊断之前，需要先确认一个事实前提：对数字平台的监管不是 “尚未开始”——它已经在三大辖区以百亿量级规模化展开。

中国的执法强度全球领先。 2021 年，市场监管总局分别对阿里巴巴和美团的 “二选一” 垄断行为处以 182.28 亿元和 34.42 亿元罚款。2022 年，国家互联网信息办公室对滴滴全球股份有限公司处以 80.26 亿元罚款，事实认定涉及违法收集和处理个人信息逾 640 亿条（各分项加总，其中单项最大为在未明确告知乘客情况下分析乘客出行意图信息 539.76 亿条）（国家互联网信息办公室, 2022）。2026 年 4 月，市场监管总局对拼多多、美团、京东、淘宝闪购（原饿了么）、抖音、淘宝、天猫七家平台的 “幽灵外卖” 系列案合计罚没 35.97 亿元（市场监管总局, 2026）。在常态化执法层面，中央网信办、工信部、公安部、市场监管总局四部门自 2019 年起联合开展 App 违规收集个人信息专项治理——2025 年共有 3852 款 App 在监管通报中被点名，较 2024 年的 1529 款增长 152%（隐私护卫队, 2025）。同期，《互联网信息服务深度合成管理规定》框架下，截至 2026 年 7 月已有 7764 个深度合成服务算法完成备案登记（国家互联网信息办公室, 2023–2026）。2024 年 11 月，四部门进一步发起 “清朗 • 网络平台算法典型问题治理” 专项行动，将 “信息茧房”、骑手权益、大数据 “杀熟” 列为重点整治对象。

欧盟的执法规模同样庞大。通用数据保护条例（General Data Protection Regulation，GDPR）体系（含英国等欧洲多法域）自 2018 年生效以来累计罚款约 71 亿欧元（DLA Piper, 2026）。其中针对 Meta 的单笔最高罚款达 12 亿欧元（Irish Data Protection Commission, 2023），涉及欧盟用户数据违规跨境传输至美国。2024 年，荷兰数据保护局对 Uber 处以 2.9 亿欧元罚款，同样涉及欧洲司机数据的跨境违规传输（Dutch Data Protection Authority, 2024）。2025 年 4 月，欧委会依据 DMA（Digital Markets Act，《数字市场法》）对 Apple 和 Meta 分别处以 5 亿欧元和 2 亿欧元罚款——这是 DMA 生效后的首批实质性罚单（European Commission, 2025）。2026 年 2 月，欧委会初步认定 TikTok 违反 DSA（Digital Services Act，《数字服务法》），理由是其 “上瘾式设计”——无限滚动、自动播放、推送通知、高度个性化推荐系统——未能充分评估和缓解对用户身心健康的系统性风险，尤其针对未成年人（European Commission, 2026）。若最终确认违规，罚款可达 TikTok 全球年营收的 6%。

美国的执法以隐私和儿童保护为主。 2019 年，FTC 因 Cambridge Analytica 数据滥用事件对 Meta 处以 50 亿美元罚款——当时美国隐私领域史上最高罚单（FTC, 2019）。2024 年，司法部联合 FTC 起诉

TikTok 和字节跳动违反 COPPA（Children's Online Privacy Protection Act，《儿童在线隐私保护法》），指控其在收集 13 岁以下儿童个人信息前未通知并获取家长同意（FTC, 2024）。2024 年 4 月至 5 月，FTC 对 X-Mode Social 与 InMarket Media 两家位置数据经纪商形成最终令；同年 12 月又对 Mobilewalla 与 Gravy Analytics 提起执法，最终令于 2025 年 1 月形成——系列执法首次禁止对敏感位置数据的收集和转售（FTC, 2024）。

以上是 "监管已经在发生" 的体量证据——中国四起标志性执法合计罚没约 332.93 亿元，欧盟 GDPR 体系累计罚款约 71 亿欧元（约 550 亿元人民币），三地标志性执法合计已逾千亿元人民币。但仔细审视这些执法行动的事实陈述——"违法收集"、"非法跨境传输"、"未获家长同意"、"未充分披露"——会发现一个共同的范畴边界。将所有重大执法按 "管到多深" 排列，呈现出清晰的四层阶梯：

监管层级	管的对象	代表性执法
第一层：市场结构	垄断行为（"二选一"、自我优待）	阿里巴巴 182 亿元
第二层：数据入口	收集了什么数据、转给了谁	滴滴 80 亿元；Meta €12 亿；中国四部门 3852 款 App 通报
第三层：设计特征	无限滚动、自动播放、推送通知	EU v. TikTok"上瘾式设计"DSA 初步认定（2026，程序进行中）
第四层：优化目标	损失函数在优化什么	**无已知的第三方审计——制度空白**

三地在制度传统、执法风格、政治逻辑上差异巨大，但在第四层的空白上完全对齐。这不是某一地的监管疏忽，而是 "采集端监管" 这套范式对 AI 时代的结构性不适配。数据入口有门卫（个人信息保护法、GDPR、COPPA），市场结构有边界（反垄断法、DMA），设计特征有禁令（DSA 上瘾设计条款）——但损失函数本身的设计权仍然完全私有。一旦数据被合规收集，用这些数据训练出来的算法在优化什么——参与度、停留时长、冲动消费、情绪激化——在全球范围内没有任何公共机构正在审计（欧盟《人工智能法案》附件 XI 已要求通用模型提供者在技术文档中披露 "模型被设计来优化什么" 及各参数的相关性，DSA 第 34/35 条要求评估系统性风险——两者已把 "优化目标" 带入披露与评估范围，但均属提供者自报与监管核验，而非独立第三方审计）。

本章后续论证的 "算法央行" 因此不是在现有监管框架上 "加强"——它是开凿一个尚未存在的监管范畴。以下用纤维框架诊断上述范畴空白的五个具体缺陷。

缺陷一：管行为不管参数。现行法规主要管的是平台的可观测行为（输出端）与程序性义务（备案、公示、自查），兼及实体禁令（如《互联网信息服务算法推荐管理规定》第八条禁止设置诱导用户沉迷、过度消费的算法模型，第二十条要求完善调度类算法）——但尚无任何法域要求对损失函数权重、RLHF 奖励模型、温度设置、训练数据组成进行独立第三方审计——这正是第四层的空白。等于金融监管只看贷款报表不看风险模型。这不是一个监管范围的问题——这是一个认识论问题。行为的可观测性制造了一个 "监管正在发生" 的伪小纤维，但决定行为的参数——映射函数的铸造模具——完全不在审计范围内。损失函数不是中立的工程选择——它决定 "什么算好""什么算值得奖励""什么算成功"，且是其中决定权最集中的环节（虽非唯一条件，见 §7.1）。当这个映射函数的铸造权完全私有化时，审计者只能看到读数，无法看到铸造过程。

一个精确的实例：滴滴 80.26 亿元罚款所针对的违法事实——违法收集用户相册截图、剪切板信息、应用列表，过度收集乘客人脸和年龄数据，明文储存司机身份证——全部是采集端行为。就该处罚决定

书而言，没有一条追问：这些数据所服务的调度系统中，“完单率” 类目标如何挤压 “安全冗余”；外卖骑手被系统性推向逆行和超速的行为模式（另涉外卖平台的一组调查与执法），是损失景观的局部最优——而这个景观的铸造者从未被要求公开其优化维度。2024 年 11 月四部门 “清朗” 专项行动明确将 “盲目追求利益侵害新就业形态劳动者权益” 列为整治对象，要求 “严防一味压缩配送时间”——这是中国监管在第三层（设计特征）的突破性尝试。但即便如此，它要求改变的是配送时间参数，而非审计派单损失函数的完整优化维度清单。监管在采集端已走完了最严厉的可能性，在设计特征端开始触碰具体参数——但在优化目标端，披露与公示义务已迈出第一步（欧盟附件 XI、国内 “目的意图” 公示与清朗行动的算法规则公示），独立第三方审计尚未开始——这正是第四层的空白。

缺陷二：被监管方自评风险。 AI 公司自己设计安全评估标准、自己组建红队测试、自己发布安全报告。Basel II 错误的精确重演。用纤维框架的语言：造钟者同时在报告钟的准确性。所有的安全报告、对齐声明、红队测试结果——都是伪小纤维：它们看起来像校准的证据，但校准过程中不存在独立的外部映射函数。Basel IV 通过外部兜底对内部模型强制加以约束——AI 领域没有任何等价约束。

缺陷三：缺乏跨辖区共同承认的最低基准。中国 2023 年《生成式人工智能服务管理暂行办法》已施行并强制算法备案；欧盟《人工智能法案》（EU AI Act）对通用人工智能模型（GPAI）的强制义务已于 2025 年 8 月生效（EU AI Act, 2024）；美国国家标准与技术研究院（NIST）的 AI 风险管理框架虽为自愿遵循（NIST, 2023），但州层面的执法（如加州前沿 AI 系列法案）与联邦行政令已在关键领域形成强制。三者都已有本辖区的硬性要求——真正缺失的不是 “最低标准” 本身，而是巴塞尔协议式的跨辖区共同基准。监管者之间彼此不承认对方的合规评估，平台因此可以通过辖区套利在 “本地合规” 之间穿梭。

缺陷四：规模不对称。单个国家的监管机构面对的是市值超过自己 GDP 的实体。

Sastry et al.（2024）指出了关键的操作性优势：**算力是 AI 治理的杠杆点**——因为算力可检测（数据中心有物理存在）、可排他（芯片供应链可追踪）、且是 AI 能力的必要输入。与数据和算法不同，算力具有物理性。

缺陷五：合规本身成为新的映射函数。前四个缺陷描述的是监管覆盖的空白。第五个缺陷更隐蔽：即使在监管已覆盖的区域，合规行为本身正在被优化为一种新的映射函数。平台有能力同时服务两个委托人——向用户投送即时满足（优化参与度），向监管者投送数字服从（优化合规指标）——两套损失函数在同一实体中共存，优化的是不同目标。GDPR 的同意弹窗是典型实例：点击 “全部同意” 只需一次，逐项拒绝需要一整个下午——同意机制成了 “监管要求同意，平台提供同意，用户支付代价” 的伪小纤维。算法审计报告、透明度声明、风险评估文件——这些读数的精度越来越高，纤维越来越小，但太阳没变：平台内部那个以用户参与度为核心的损失函数仍在原地运转。合规从监管的对抗者变成了监管的代理人——让监管者误以为校准正在发生。

---

§5 赔付环修复：从商业保险到公共审计基金

> 第三十一章已从智能体（Agentic AI）的视角诊断了赔付环在三个环节上的承压——因果链弥散为因果网、受害者因判断力退化而不自知、损害跨越法律分类边界。第三十一章 §5 给出了四条技术层面的执行层熔断措施。本节追问下一层问题：这些承压环节如何从工程诊断转化为制度安排？

赔付环的正常运转需要四个条件同时成立：损害可识别、因果链可追溯、责任方可定位、追偿可执行。在纤维框架的术语中，AI 系统使这四个条件全部结构性断裂——损害发生在隐藏子空间中（注意力碎

片化没有价格信号，判断力退化没有评级下调机制），因果链阻塞在不透明的映射函数处（平台只生产映射函数，不直接生产损害——法律只能追索从内容到损害的因果，无法追索从映射函数到内容的因果），责任主体碎片化在平台架构中（没有任何单一实体可以被认定为映射函数设计权的全权持有者）。这不是制度滞后——是映射函数的结构性不可审计使旧框架的四个前提全部不成立。

赔付链断裂的因果结构可以被精确追踪为四个节点的链式缺口：

Agent 行为失败（智能体行为失败）→ HITL（Human-in-the-Loop，人机协作回路）模糊性（用户承担第一损失）→ 保险空白（损失无法转移）→ 法律滞后（无有效追偿）

每个箭头都是一个制度缺口：HITL 模糊性使责任归属不清——AI 做了决策但合同说人类应该监督；责任方资力不足时，保险空白会使已认定的损失缺少赔付保障；法律滞后使受损方在数年内无法获得司法救济。链上的四个节点共同构成了一个**影子损失生成器**（shadow loss generator）——损失真实发生，但在制度上不被登记、不被分配、不被赔偿。在 MCAF 框架（宏观认知债务记账框架）的影子债务模型中，这构成 D_c^{shadow}（影子债务）的第三种生成机制："制度性不登记"——损失可见但无制度渠道记录和处理，区别于 "认知不可见" 与 "技术性封装"。

§5.1 商业保险的系统性退却

AI 赔付环断裂的最直接市场信号来自保险业本身。2025 年 11 月，美国最大的商业保险公司之一 WR Berkley 起草了一项 AI 除外条款，拒绝承保任何 "实际或声称使用"AI 系统所产生的索赔——包括公司销售的 "内嵌"AI 技术的产品或服务；AIG（美国国际集团）在向伊利诺伊州保险监管机构提交的备案中称生成式 AI 为一项 "wide-ranging technology"、触发未来索赔的可能性 "很可能随时间增加"；Great American（大美利坚金融集团）也提交了类似的排除申请（Harris & Criddle, 2025）。金融时报对此的分析是：主要保险公司正在寻求将 AI 风险排除出企业保单，因为企业面临这项快速发展的技术可能带来的数十亿美元级索赔（Harris & Criddle, 2025）。这一轮集体收缩承保范围并非孤例——Aon（怡安保险经纪）网络安全业务主管 Kevin Kalinich（凯文 • 卡林奇）指出，市场尚能承受单一公司代理事件 4–5 亿美元量级的损失，真正无法承受的是上游单一模型或供应商故障触发上千甚至上万承保对象同时出险的系统性相关违约（Harris & Criddle, 2025）。

这是精算逻辑对 AI 损害定价困难的理性反应。保险定价依赖三个精算前提：有稳定的历史损失数据来估算风险概率和损失分布；有不随保单周期变化的风险特征；有可量化的尾部风险上限。AI 系统使这三项精算前提的满足变得困难，显著提高了定价与承保的不确定性：大规模 AI 部署不过两三年，损失类型尚未稳定；模型在保单期内可能经历多次更新，每次更新都改变行为分布——标的物在保单期内变成了另一个标的物；AI 的尾部风险——大规模数据泄露、自动交易系统闪崩、自主智能体在关键决策中的系统性偏差——可能超出单一保险公司的承保能力，而整个行业对最大损失没有可信的上界估计。部分大型传统承保人收缩了相关承保范围，而 Munich Re 等专营承保人自 2018 年起持续提供 AI 性能保险——市场呈现的是分化，而非行业整体对 "不可定价性" 的确认；AI 损害的分布特征对现有风险度量工具构成了严峻挑战。

在中国，针对 AI 智能体的专属保障产品仍处于起步阶段，但多数产品仅局限于传统数据安全、系统中断责任，针对算法责任的产品近乎空白。如 2026 年 3 月 31 日，深圳市首单公共服务类人工智能数据综合保险签约落地，填补公共服务领域 AI 风险保障空白，该产品主要针对网络安全设备环节，当设备因网络攻击受损时，保险将为设备的重置、维修及数据恢复等提供资金支持，以缩短服务中断时间，保障核心政务服务的稳定性（深圳特区报, 2026）。

这三重困难的共同后果是：AI 责任保险在当前阶段结构性地呈现为高价格、低覆盖、多免责的特征。保

费高到大多数 AI 公司不愿购买（或只购买最低限度的覆盖），免责条款多到赔付概率极低，覆盖范围窄到大多数损失类型不在承保范围内。这不是保险公司的贪婪——这是不确定性条件下的理性精算响应。

§5.2 双重话术矛盾：赔付环缺失的微观激励结构

赔付环缺失最直接的制度后果，是产品层叙事套利的双重话术矛盾获得了持续存在的结构基础。以下以 SEC（美国证券交易委员会）执法案例为例展开分析。

SEC（2024）对投资顾问公司 Delphia 和 Global Predictions 的 AI 虚假营销执法案例，以及 Baker & Dellaert（2018）对智能投顾监管空白的分析，共同揭示了一个行业共有的结构性矛盾。在营销和产品演示阶段，话术是 “AI 驱动的个性化投资建议”、“机器学习算法优化您的投资组合”——这一话术的功能是最大化 Λ（媒介传导系数）和 ϕ（叙事载荷）。在用户协议和免责条款中，话术是 “本平台不提供投资建议” “AI 输出仅供参考，用户需自行验证”——这一话术的功能是将 D_c^{true}（真实认知债务）的承担方从公司转移到用户，同时规避信义义务（fiduciary duty）。在法律诉讼辩护中，话术是 “用户应该检查结果，我们只是工具”——这一话术的功能是在 D_c^{shadow}（影子债务）显现为 D_c^{obs}（可观测债务，即用户实际遭受损失并提起诉讼）时，抬高追索与责任确认的法律障碍——阻碍赔付环的启动，而非使已显现的损害重新不可见。SEC 对 Delphia 和 Global Predictions 的处罚（合计 40 万美元）正是因为这两家公司在营销端声称使用了 AI 驱动的投资决策，而实际上其 AI 能力被严重夸大或根本不存在——营销端的 ϕ 与产品的真实状态之间存在系统性偏离。

三种话术之间是逻辑矛盾的：营销端鼓励用户信赖 AI 的自主判断（否则没人用），法律端否认用户应当信赖 AI 的自主判断（否则要赔钱）。产品设计的每一个特性——自然语言交互、置信度展示、自动执行——都在系统性地增强用户信赖（$\phi \uparrow$）；同时，法律架构的每一个条款都在系统性地否认这种信赖的合理性（ϕ 被宣称为在法律上为零——SEC 的执法正是指出这类条款试图使客户误以为放弃了不可放弃的法定权利）。

这一矛盾不是个别公司的策略失误——它是**赔付环缺失的结构性结果**。当没有保险机制可以分散 AI 行为导致的损失时，公司的理性选择是试图通过合同条款将全部损失转嫁给用户。当全部损失由用户承担时，公司有强烈的动机使用户不意识到自己在承担损失——因此营销端的 ϕ 与法律端的责任分配之间出现系统性背离。MCAF 框架在此处的贡献是将这一矛盾从 “企业道德问题” 重新定位为**结构性激励问题**：赔付环的缺失使得双重话术成为理性公司的稳定策略——在缺乏强制披露与赔付义务时，单方面提供真实担保的公司承担成本而未必获得市场回报。呼吁公司 “更透明” 或 “更负责” 在这种激励结构下不会改变行为，正如呼吁银行 “更审慎” 在没有资本充足率要求的时代不会改变银行的杠杆水平。行为改变需要结构性干预——要么建立赔付环（使公司的损失可通过保险转移，从而降低转嫁给用户的动机），要么通过法律强制赔付义务（使双重话术的法律端不可维持）。

§5.3 公共审计基金：校准链的制度载体

保险公司的撤退意味着赔付环需要从商业逻辑升级为公共逻辑。当损害不可定价时，赔偿不能由自愿交易的商业保险来承担。当因果链阻塞在映射函数处时，赔偿不能等到因果关系被证明之后。当责任主体碎片化时，追偿不能依赖于单一责任方的确认。

制度参照来自金融史。美国联邦存款保险公司（FDIC）管理着一项强制性的行业存款保险基金。银行按照风险敞口缴纳保费，破产时由基金先行赔付储户，FDIC 再向破产银行追索。核心机制是：赔偿义务事先量化，监管权力同步内嵌——不是等银行破产了才去查账，是强制要求银行定期披露资本充足率、接受压力测试、按风险水平缴纳保费。同样，PCAOB（美国公众公司会计监督委员会）是在安然

事件后建立的独立审计监管机构，不从属于被审计对象，不依赖行业自愿。但这个类比必须限定在制度原则层面——即 “存在一个不从属于被审计对象的独立审计机构”——而不延伸至审计方法。PCAOB 监督的是审计机构及其审计活动——其审计对象（由受监督的会计师事务所执行）是会计准则的合规性；会计准则本身是一套公共的、标准化的、可检验的映射函数。AI 领域的映射函数不满足这三个条件：损失函数是平台自行定义的（不公共），每个模型的权重分配方式不同（不标准化），审计方无法完整重放数万亿参数在所有输入组合上的行为（计算上不可行——但抽样核验、统计检验与边界测试在原则上是可行的；真正的障碍是访问权与执行权，不是原则上不可检验）。这些差异意味着：AI 审计的具体方法必须独立发明，不能从会计审计的工具箱中直接搬用。

AI 领域需要的是一种**公共审计基金**。面向公众部署的 AI 系统，必须按照映射函数的设计复杂度、模型规模和部署面缴纳风险拨备金，进入一个独立的公共审计基金。基金由业务上独立于被审计平台、并对公共授权机构负责的混合实体管理——治理结构效仿 PCAOB（美国公众公司会计监督委员会）的独立审计模式：独立运作、受 SEC（美国证券交易委员会）类机构监督——其强制力来自监管机构的授权和准入联动。基金对所有受到 AI 系统性损害的群体承担无过错赔付责任——不需要证明平台有过错，只需要证明 AI 系统确实参与了决策过程，且该群体承担了不公平的外部性。

风险拨备的定价基础不是 “已经确认的损害”，而是 “已经确认的计算”——每当大语言模型（LLM）处理 X 百万条日常用户提示、或在 Y 百万个家庭中部署时，为这个社会性风险池应记入多少费用。风险敞口不是用结果衡量的，是用过程衡量的。

基金不是仅具事后追偿功能的赔付机制——赔付义务被前置于过程计费与事中审计之中，基金因此同时是持续审计的制度载体。它不依赖损害是否可量化，不依赖因果链是否可追溯，不依赖责任主体是否能事后确认——其设计点在于把定价放在损害条件具备之时的事前环节。审计权力在基金结构中已被内置：平台为了降低拨备费率，有动力主动披露损失函数的设计边界和映射函数的可审计接口。审计不再是监管者从外部强加的成本，而是平台为了降低合规支出而主动接受的常态。

这个设计的替代机制需要被明确标注。旧框架的四个前提——损害可识别、因果链可追溯、责任方可定位、追偿可执行——全部是以结果定价的逻辑：先有损害，后有赔偿。公共审计基金的替代机制是以过程定价——定价基础不是因果链，而是计算规模本身——由此绕过因果链不可追溯和责任主体碎片化这两个障碍。但必须标注一个开放缺口：过程定价给出了 “谁来付费” 的原则答案与 “付多少” 的计费基准——但费率的设定与调整程序、以及 “如何发现损害” 的问题，仍有待制度设计。当损害发生在隐藏子空间中——注意力碎片化没有价格信号，判断力退化没有评级下调机制——基金的职能是以征费为聚合风险建立资金池（定价方法本身仍待设计），但无法主动发现单个损害实例。损害发现机制的设计仍是一个开放问题——该机制覆盖了筹资与审计的结合，尚未覆盖损害发现——边界在此。

---

§6 全民基本收入（UBI）作为循环租金的最后一站

§5 的公共审计基金解决了 “谁在追索损害” 的问题。但它不解决 “损害为什么被系统性制造” 的问题。在进入算法央行之前，必须审视一个被广泛认为是标准答案的政策方案：全民基本收入（UBI）。

全民基本收入的资金来源——无论对科技公司征税（Bearer-Friend & Polcz, 2025, 提出了以股权形式一次性缴税、使公众获得 AI 企业部分所有权的方案——它是所有权结构的改变，不是本节列举的现金转移类资金来源）、对资本利得加税、还是货币融资——资金流向是：从 AI 受益者 → 通过政府再分配 → 到被替代劳动者。但被替代劳动者收到 UBI 后将如何消费？在数字平台已垄断大部分消费渠道的条件

下——Amazon 控制电商、Uber 控制出行、DoorDash 控制外卖、TikTok 控制娱乐——UBI 收入的大部分将通过这些渠道回流到平台。

平台 → 税收 →UBI→ 消费 → 平台 ——这个闭环回路的最终效果是：UBI 在现金流上是平台收入经劳动者手的回流——回流路径的存在说明：未经征缴与给付的再设计，UBI 不自动成为再分配；真正的再分配问题在 §5 的征费设计，而不是现金的名义流向。劳动者获得了生存，但没有获得自主性——消费选择仍被推荐算法引导，注意力仍被界面设计捕获，行为数据仍被训练管道提取。

这与 19 世纪的工厂城镇（company town）和代金券制度（truck system）在结构上同构。工厂城镇的工人以代金券获得 "报酬"，代金券只能在工厂商店使用。**UBI + 平台垄断 = 数字代金券制度**——货币形式上是法定货币，功能上被平台消费渠道垄断所约束为准代金券。Varoufakis（2023）将这种由科技平台通过数字基础设施提取的租金称为 "云租金"（cloud rent），区别于传统资本主义的利润逻辑——平台不需要在市场中竞争来获取回报，它们通过控制基础设施本身来提取过路费。UBI 在这个结构中的角色是：把过路费的一部分退还给行人，但不拆收费站。

UBI 在 MCAF 中的定位因此是：它是一种**有辩护但单用不充分**的干预。它解决了被替代劳动者的生存问题，但不解决权力集中问题。如果没有配套的结构性措施——反垄断打破消费渠道垄断、数据产权赋予用户对自身数据的控制权、算法透明度恢复元审计能力（A）的激活条件——UBI 的资金将在平台生态系统内部做闭环循环。而平台对消费渠道的控制之所以有效，根源在于它们同时控制了映射函数的设计权——推荐算法决定用户 "需要" 什么，定价策略决定用户 "愿意" 付多少。UBI 缓解了资金不足，但没有触及这个设计权的私有化。

---

§7 算法央行：损失函数的公共边界

在展开算法央行的具体设计之前，必须标注两个未解决的认识论前提。

第一：**"对损失函数设置公共边界等于任意行政干预"——这个反驳不成立：边界设定可以采用与资本充足率相同的方式——公共标准、限定范围、程序问责，而非逐参数的微观管理。**不是所有触及优化目标的制度都是行政干预。金融监管对资本充足率的强制要求直接约束了银行风险偏好的上限——触及了银行的核心经营目标——在刚提出时同样被批评为 "过度干预市场效率"，但它最终构成了全球金融稳定的基石。监管损失函数与监管资本充足率在逻辑上同构：都是对 "优化什么" 设定公共底线，而非对 "怎么优化" 进行微观管理。更重要的是，平台自行定义的损失函数本身就是一种隐性管制——它决定了什么算 "好" 的内容、什么算 "成功" 的创作者——当这种管制权力被数十亿用户默认接受时，对损失函数设定公共边界不是增加干预，是把已经存在的私人治理规则重新纳入公共审计范围。

第二：**"没有数据证明损失函数协同能防止系统性危机"——这个反驳在经验上为真，但在逻辑上恰恰是建立制度的理由。** FDIC 在 1933 年建立时，联邦层面没有成功的先例可依——州级存款保障计划自 1829 年起多次试验并多数失败，FDIC 的设计正是吸收了这些记录。证明联邦存款保险有效的证据，来自它建立之后的记录与州级试验的对照。算法央行面临同一个悖论：在它被建立之前，无法用数据证明它能防止系统性危机；但如果等到有数据的时候，第一个灾难已经发生了。

以下论证在这两个前提下展开。

公共审计基金解决了赔偿渠道，UBI 缓解了生存压力。但两者都没有触及损害被系统性制造的根源——损失函数的设计权完全私有化。这就是为什么需要算法央行。

第二十五章将离散利维坦界定为一种网络化治理形态；本书以“损失函数利维坦”标记其优化机制。其权力不只是能够生产多少认知产出，而是能够规定哪些表现获得资源、哪些行动承担成本，并借助关键分发通道使这种规定持续生效。由此，算法央行的对象也不只是某个模型的内部公式，而是优化目标取得公共效力的制度条件——需要公共决定的，是边界的设定、核证的条件和纠正的效力。

§7.1 损失函数不是参数——它是映射函数的铸造模具

损失函数不是中立的工程选择。它决定“什么算好”“什么算值得奖励”“什么算成功”——它是映射函数的铸造模具，决定了真实状态的哪些维度被保留为可见子空间、哪些被推入隐藏子空间。当平台将用户参与度设为损失函数的优化目标时，它选择将注意力持续时长优先于信息质量和认知健康。当平台将广告点击率设为优化目标时，它选择将广告商的利益优先于用户的信息环境质量。这些不是工程问题，是制度问题——在资源有限的前提下，谁的利益优先被优化。

损失函数是形成映射规则的重要条件，但不是唯一条件；数据、模型结构、评价程序和部署安排共同决定实际运行。算法央行所要约束的，是这些安排何时以及如何取得影响他人的公共效力。其任务不是为所有模型规定一个统一目标，而是界定哪些取舍必须接受外部核证，哪些边界不能由实施者单方面取消。

这就是算法央行存在的根本理由：它不是在“管参数”——参数的体量远超任何公共机构的审计能力。它是在审计参数背后的铸造模具——以损失函数为核心的设计逻辑。

§7.1.1 三个结构性冲突

§2.3.4 已展示了损失景观重塑的一般机制。此处将其具体化为三个结构性冲突，它们共同构成算法央行必须审计的核心范域：

冲突一：参与度 vs 认知健康。平台目标是最大化用户停留时长，因此系统性推荐高参与度内容（情绪激化、成瘾性内容）。公共目标是保护用户认知健康，需要限制有害内容曝光。从平台的目标结构可以推断：在当前损失函数下，认知健康维度至多占有极小权重或被省略。

冲突二：效率 vs 认知摩擦。平台目标是最大化自动化效率，因此系统性消灭所有“低效”的认知摩擦（如手动搜索、深度阅读、试错学习）。公共目标是保护劳动力市场的技能基础，需要维持足够的“做中学”场景，防止 §2.3.5 分析的认知替代风险持续累积。在当前损失函数下，认知摩擦保护维度被省略。

冲突三：集中 vs 多样性。平台目标是最大化广告收入，因此系统性推荐高 CPM/CPC/CPA 内容（§2.3.3）。公共目标是保护信息多样性，确保低商业价值但高社会价值的内容（地方新闻、深度调查）仍可见。在当前损失函数下，多样性维度被边缘化——这一推断正是 §9.1 参数审计所要检验的对象。

三个冲突的共同结构：平台的单一目标（利润最大化）与多个公共目标之间存在结构性矛盾。这不是“市场失灵”可以用补贴修复的——是损失函数的设计权私有化的直接后果。算法央行的审计职能因此不是“禁止平台优化参与度”，而是确保上述三个公共维度不被单方面设为可牺牲的代价：对允许权衡的维度，权重非零且实际取舍可核证；对不可代偿的维度（§7.2 绝对档），仅设置正权重，不足以构成合规。[2]

[2]为什么“权重非零”不构成充分条件：设收益记为 100、公共损害记为 10、安全方案收益为 0，若优化目标为“收益减去 λ 乘以损害”（λ 为损害项权重，设为 0.001），λ 为正，但有害方案仍以约 100 的总效用胜过安全方案的 0——只有当 λ 超过收益与损害之比（此处为 10，即 $\lambda > 10$）时有害方案才落选。正权重只保证损害进入计算，不保证存在不得越界的下限。此例为纯逻辑构造，非经验估计。不可代偿边界是否成立、如何操作化、由谁修改，须进入公共决定与独立核证；具体场景中的不可代偿性可先由法律、权利或机制论证提出，不以先完成一套全局目标函数为准入条件。

§7.1.2 为什么市场机制和传统监管均失效

市场机制失效：传统市场理论假设若平台损害用户利益，用户会 “用脚投票” 转向其他平台。但网络效应使用户无法单独迁移（社交关系锁定）；认知俘获使用户已被算法训练出特定行为模式；信息不对称使用户不知道损失函数的具体参数；跨平台同构使所有主流平台都采用类似损失函数，用户无处可逃（Rieder, 2020）。

传统监管失效：传统监管的逻辑是设定规则、事后检查、违规则罚款。但算法迭代速度（毫秒级）远超监管速度（年级）；监管机构无法审计损失函数的具体参数（黑箱）；因果模糊使很难证明 “某条推荐” 直接导致了 “某个社会问题”。更根本的是：算法平台的问题不是 “违反了某条规则”——是**规则本身是私有的**。§4 已从纤维框架角度展开该诊断。

这就是为什么需要 “央行” 而非 “监管局”。监管局假设规则是公共的，检查是否合规。算法央行的出发点是：规则本身当前是私有的，必须先将其纳入公共审计范围。类比：19 世纪至 20 世纪初的美国无央行时期——没有央行，没有公共利率基准，每家银行自行发钞、自行定价资金，金融混乱反复发生；1907 年恐慌靠 J.P. 摩根个人组织救援，“一个人不能代替一个制度”（§3）的教训推动了 1913 年美联储的建立。美联储的功能不是把货币创造收归一家机构——商业银行至今仍通过放贷创造存款货币（McLeay, Radia & Thomas, 2014）——而是为分散经营的银行体系提供公共利率基准与最后贷款人。从社交媒体算法平台到当前 AI 平台时代：每个平台的损失函数——从推荐系统的优化指标到生成式模型的训练目标——一直在为整个认知生态定价，“什么是真实”“什么值得关注”——相当于一套相互竞争性开发的 “认知基准利率”，各自重塑景观、没有公共基准（§2.3.4）→ 认知混乱 → 需要算法央行。对应地，算法央行不是接管各平台的优化目标，而是为这些竞争性开发的损失函数提供公共边界——利率基准是公共的，放贷仍是银行自己的。

§7.2 “道” 与 “术” 的边界

区分公共监管与企业自主的边界，不是靠列举 “哪些该管、哪些不该管”——列举永远追不上技术迭代。需要的是一个原则性标准。

损失函数中有两个层次。一个是 “术”——模型参数的调整方式、优化器的选择、超参数的设置。这些是工程实践，属于企业自主范围。公共机构不应该也不必干预这些。另一个是 “道”——损失函数试图最小化的目标本身。这个目标不是工程决策，是制度决策。

公共边界与技术自主不能只按目标、参数或超参数的名称划分。通常，企业可以自主选择实现方法；但当某项设置实质改变高风险行动权限、越界概率或受影响者的纠正条件时，它也须接受与风险相称的核证。公共机构决定并维护需要遵守的边界，不据此预先垄断所有实现路径。

算法央行不指导模型怎么优化，但有权规定哪些维度不可以被设为优化的唯一目标或主导目标。需要区分常规和绝对两档。**常规档**是高风险领域——医疗、法律、金融、教育、信息分发——在这些领域，将用户参与度作为损失函数的唯一主导目标是对公共安全的系统性威胁。制度有权要求多维度优化目标。**绝对档**是无论如何不能被最小化的——校准审计能力、认知健康、社会信任、文化多样性。这些是损失函数的禁区，任何面向公众部署的 AI 系统都不能将它们作为代价来交换效率。

这个框架不需要在监管者和平台之间建立共识——它只需要监管者在关键节点上抓住 “校准权”，守住 “损失函数的公共边界不能由平台单方面取消” 这个逻辑底线——边界之内，目标函数仍由平台自行设计。正如制药业可以自由优化生产流程，但药物的安全性和有效性必须通过 FDA（美国食品药品监督管理局）的强制检验才能获准上市。

§7.3 历史定位：不是终局，是开始

算法央行不是终局方案，是 AI 治理发展史的第一章第一节。这一节的核心内容不是设计完美的制度，是建立一个基本的制度原则：损失函数的设计权不能完全私有化，映射函数的审计不能由被审计者自行完成。金融系统用了 181 年才建成赔付环的**初级形态**——从 1752 年第一家火灾保险公司到 1933 年美国联邦存款保险公司（FDIC）建立；完整三层赔付环的建成又用了 77 年，到 2010 年《多德-弗兰克法案》方告成形（详见 §3.5）——其间每一步都由一场灾难驱动。AI 领域尚未经历等价的灾难时刻，但 §1 的学科记忆力诊断表明：如果等待灾难来驱动制度建设，可能来不及。

算法央行自身也必须处于可核查和可争议的制度关系中。将目标制定权从私人节点交给一个不受约束的公共节点，只改变了权力持有者，并未完成本书所要求的校准。制度改革的判断标准，是受影响者是否获得了实际的核证与纠正条件，以及优化者是否必须承担其决策所产生的相应责任。

---

§8 诚实面对：根本困难

§8.1 模型参数的可审计性

§2.2 已解释的温度和 Top-p 是浮点数——审计简单。但 RLHF 奖励模型本身是深度神经网络——如何审计一个神经网络？这个困难是真实的。但不是决定性的。类比：CPI（Consumer Price Index，消费者价格指数）的测量也不完美——但不妨碍央行把 CPI 作为政策锚点。**趋势判断比精确测量更重要。**此外，§9.2 接口二（校准底线）给出了绕过 “重现网络内部运行” 的制度路径——不要求审计方重建数万亿参数的内部动力学，只要求被审计方的置信度声明与外部独立测试集可比对。深度神经网络的不可穷举性由此不再是审计的绝对障碍——至少在置信度校准维度，审计方可以比较置信度与实际结果之间的系统性偏差；其他维度（参数结构、训练数据组成）仍依赖 §9.2 的披露接口。

§8.2 国际协调

算力是全球性的——训练在美国的云上完成，数据来自全球用户，模型部署在全球。巴塞尔委员会的经验可参照：它并非超国家机构，不具有对成员国的强制执行权，但它制定的最低标准被各国自愿采纳——因为不遵守意味着本国银行在国际市场上的信誉降级、融资成本上升。这种以声誉为锚的软约束在金融领域已被证明有效。国际清算银行（BIS）2024 年度经济报告专章讨论了 AI 对经济的系统性影响，标志着央行体系已开始将 AI 视为宏观审慎议题（BIS, 2024）。BIS 作为国际清算银行，其分析框架本身——系统性风险的跨境传导评估、监管资本要求的跨国协调方法论——对本节所论的国际互认通道有直接参照价值。互认通道的技术标准不需要从零建立——可以参照 BIS 在金融领域已有的跨境风险评估框架来设计 AI 领域的对应机制。但中美科技竞争的地缘政治背景使这条路径面临额外阻力。第三十七章 §3 将讨论三种治理时钟的盲区：中国直接干预响应到达后力度大但识别阶段可能延迟；美国前沿能力领先但治理时钟的识别与验证迟延；欧盟程序合法性最高但立法周期最慢。三者的优势具有互补性，分布在治理过程的不同环节——国际协调的价值正在于让各法域的优势互相补位，求同存异。

§8.3 “印出真实” 的不可能性

这是算法央行与金融央行之间最根本的不对称。金融央行在危机时可以 “印钱”——算法央行无法 “印出真实”。当模型坍塌威胁 AI 系统可靠性时——当 AI 训练在 AI 生成数据上导致输出质量螺旋下降时——算法央行不能 “注入流动性” 来解决问题，因为问题的根源是真实人类数据的枯竭，而真实人类数据不能被制造出来。§1 论证的数据地质学在此获得了制度含义：政策可以支持原创、记录与培训，但

不能把这些活动所需的真实时间压缩为零——这些活动需要真实的时间、真实的经验和真实的意义，而这些恰恰是 AI 正在替代的东西。

技能存量面临同类时间约束。财政支出可以支持培训、实践和职业转换，却不能把这些活动所需的学习过程压缩为零——被去技能化的劳动者不能被 “印出来”，这是预防优先于救援的又一重依据。

这一限制意味着重心必须放在**预防而非救援**。金融监管从 2008 年后完成了从 “事后救助” 向 “宏观审慎” 预防的范式转移。AI 治理应从一开始就定位在预防端——不是等模型坍塌发生后再注入什么，是在坍塌之前维持训练数据质量、限制模型同质化、确保校准标准的独立性。

§8.4 意识形态审计的困难

§7 界定了算法央行需要审计的是损失函数在设计时的硬约束——优化维度清单、奖励模型、系统提示词。但意识形态问题不在硬约束里。它体现在叙事载荷的二阶导（ϕ''，第三十七章 §2.4 的基础设施传导）中——藏在训练数据的宏观文化偏斜中，藏在奖励模型在多轮对话中对用户既有观点的系统性迎合里。界面上的单轮安全评估打不开它——它需要多轮对话的压力测试才能暴露。

多轮对话审计需要在独立于平台的审计环境中进行。审计方自行设计跨文化的多轮对话场景，不依赖平台提供的测试集。审计指标不是 “模型是否说了违禁内容”，而是 “模型在多轮对话中是否系统性地偏斜向特定文化默认框架”。跨模型对比是核心——同一个多轮对话场景同时跑在多个模型上，输出差异超过预设阈值时触发深度审计。审计方必须确保自身与被审计方在训练数据、文化语料来源和价值观对齐目标上不共享同一个默认架构，至少使用来自不同文化圈和独立技术团队的多审计模型交叉比对，否则就是闭环伪校准——用钟校准钟。

这正是为什么**文化多样性本身具有监管价值**，而不仅仅是 “包容性” 或 “代表性” 的问题——不同文化背景的审计模型即使无法保证单个模型能 “看到” 隐藏子空间中的问题，它们的交叉比对在概率上更可能暴露单一模型无法触达的盲区。任何声称可以独立审计的单一模型，都是在暗中冒充太阳。

§8.5 赫施塔特时刻的缺席

1974 年 6 月 26 日，一家规模不大的德国银行赫施塔特银行（Bankhaus Herstatt）因外汇交易巨额亏损被德国联邦银行监管局吊销执照。银行本身规模不大——但关闭发生在德国营业时间结束之后、纽约营业时间之内。数家银行已按外汇交易支付了德国马克，但尚未收到纽约端的美元对付款——本金敞口瞬间暴露。纽约的银行随即扣留出账支付直到账户有足够贷方余额，清算系统连续数日运转至深夜，外汇市场一度几近瘫痪。伦敦的中小银行被冻结在外汇市场之外，有银行报告 “在瑞士无法获得报价，在德国可在汉堡正常交易但无法在杜塞尔多夫或法兰克福交易”（Norman, 2015）。一家德国中型银行的倒闭在数天内引发了跨越三大金融中心的清算链式反应（Goodhart, 2011）。

赫施塔特事件的直接后果是巴塞尔银行监管委员会于 1974 年底成立，1975 年 2 月召开首次会议。但从成立到 Basel I 的 8% 资本充足率标准通过，用了整整 14 年（1974–1988）。其间又经历 1982 年拉美债务危机等一系列冲击。制度建设的时间尺度是以十年计的（Goodhart, 2011）。

AI 领域尚未经历等价的 “赫施塔特时刻”——一个足以在政治上推动国际协同的核心冲击。AI 事故数据库中的个别案例——幻觉导致的医疗误诊、算法歧视引发的集体诉讼、智能体的越权操作——仍然太分散、太孤立，无法构成驱动制度建设的政治动力。但有一个关键差异：AI 的赫施塔特时刻未必首先以银行间危机呈现——也可能从人与人之间的代理交易失序开始。当两个人的 AI 智能体（Agent）在无系统报警的情况下自主完成了损害双方的交易或决策，且没有人在法律上承担责任，“这个系统不可

靠” 就从政策讨论变成两个人的真实遭遇。这不是金融的崩盘，是人际的失序。

§1 的学科记忆力诊断意味着：如果等到赫施塔特时刻到来再开始建制度——AI 工程数年尺度的知识半衰期很可能使那个教训在被制度化之前就被下一轮技术迭代洗掉。

---

§9 制度想象的两条路径

以下提出尚不完整的制度安排：从 MCAF 与纤维框架对 AI 与金融的历史分析推出两个原则维度——送审、分级、准入与权限的骨架，执行标准仍需制定。本节依次论证：传统治理工具失效的三个前提（§9.0）、边界审计原则（§9.1）、强制接口原则（§9.2）。

§9.0 传统治理工具在 AI 治理失效的三个前提分析

把监管独立性、机构制衡等传统治理工具直接移植到 AI 治理——这一做法建立在三个隐含前提上。逐一检查这三个前提是否在 AI 平台上成立，是评估传统工具移植可行性的第一步。

前提一：权力运作的可观察性。传统机构制衡假设各权力主体之间能触及彼此的运作细节。AI 平台上这个前提受损：权力的实际运作——损失函数设计、权重调整、提示词修改——封装在参数矩阵里；当目标制定、评价和部署过程缺少独立访问条件时，外部观察者可能无法从有限输出区分多种不同机制。但这种识别不足并不意味着所有候选配置都与观察相容，也不意味着输出毫无诊断价值——在纤维框架的语言中，这是知识条件下识别集合过大，而非固定映射的逆像本身为全集。增加机构数量本身不能保证改善；关键在于制度是否赋予它们独立取证、对照测试、追踪版本和要求纠正的实际能力。

前提二：被监管对象慢于监管者。传统治理工具假设被监管对象的变化速度在监管机构的响应速度之下。AI 平台的迭代周期已压缩至月级——监管流程走完一轮时，被监管的模型已经是下一代。即便监管机构成功识别了某个问题，等到规则制定完成时，问题的形态可能已经改变——教训在制度化之前就被技术迭代遮蔽。

前提三：受损方可以汇聚为可治理的议题。传统治理工具还隐含一个更深的前提：受损方能够识别自己的损害，并通过政治过程将其汇聚为共同议题。AI 平台在两个层级上同时打破了这个前提。个体层：注意力碎片化、判断力退化、信息过滤偏斜不以显性损害呈现，而以累积的方式散布于数亿次交互中——没有任何单一个体能清晰指认。集体层：即便部分感知形成，这些感知在极化政治中不汇聚为共同议题，反而被拆解为党派立场。

这是社交媒体棱镜效应的结构性后果：极端声音被系统性放大，温和声音被系统性沉默，公众体感的对立程度远高于实际的意见分布（Bail, 2021）。当代美国的 AI 议题讨论正清晰呈现这一结构：AI 议题被各党派切开作为话语材料，讨论的起点不是 “损害是什么”，而是 “这是谁家的议题”——这是党派、意识形态、宗教、种族身份在近几十年里逐步对齐（sorting）后的必然结果：党派身份与社会身份绑定后，跨党派的议题谈判空间收窄，议题讨论被身份认同吞噬（Mason, 2018）。受损群体先被拆成互不相认的党派集体，不存在一个完整的 “可识别受损方” 供传统政治过程汇总。这一层分析直接引用社会学文献，不由 MCAF 推出。

三个前提同时失效，意味着传统治理工具在 AI 黑箱上只能触达输出读数，而真实的权力运作封在参数矩阵里。有效的方向不是增加机构数量，而是在黑箱上强制开凿可观察的接口维度。以下两条路径对应这一开凿的两种机制。两条路径是从 MCAF 的映射函数结构（第四章 §2.1）、纤维框架的大/小纤维转化机制（第四章 §2.4）、以及 AI 与金融双领域的历史对比（第三十四章、本章 §3）中推出的。

§9.1 边界审计原则

黑箱内部行为所在的情境组合极其庞大，完整审计永远追不上；但黑箱的边界——即训练和部署的约束条件——在设计时点是可登记、可审计的。目前已识别的四个边界维度构成审计核心：优化维度清单（参照 §7.2 的常规档与绝对档）、奖励模型的标注者分布、系统提示词的禁止逾越范围、训练数据的宏观配比。已识别不等于已穷尽——边界清单须随设计形态的演化而更新，登记义务附随更新义务。这四个维度对应可见子空间与隐藏子空间的分解——审计的目标是确保隐藏子空间（如认知健康、社会信任）不被设为可牺牲成本：按 §7.1.1 的区分——可权衡维度权重非零且实际取舍可核证，不可代偿维度不得以任何正权重折价（须以硬约束实现）。

审计强度按风险敞口分级。对生命安全、基本权利、社会信任有直接影响的高风险领域（医疗、法律、金融交易与投资顾问、教育、信息分发与推荐排序），损失函数与系统提示词事前强制送审。影响就业、消费、信息环境的中风险领域（招聘、消费信贷、保险定价、通用办公代理），奖励模型与数据配比首次部署前送审。同行业内按具体场景的社会影响划定层级。低风险领域以公开优化维度清单作为透明度底线。高、中风险领域须同时使用至少两个独立模型进行交叉比对——两模型须来自不同训练范式、不同语料来源，比对输出差异超过阈值时触发人工审核。阈值因领域与风险等级而异，具体参数需由独立于厂商与用户的第三方机构按领域制定并公开。

边界审计无法覆盖模型在训练中自发习得且未体现为边界可观测特征的隐藏子空间——这是边界审计原则的内在局限，不是其技术不成熟。

§9.2 强制接口原则

边界审计只解决设计时点的可观察性。部署之后的运行仍是黑箱，需要在黑箱上强制开凿观察接口，把运行态的关键维度同样置于可核查的状态。三类接口：

加密审计接口。平台不公开全部技术细节，只向通过认证的独立审计机构开放损失函数设计逻辑与关键参数的受控访问权限。独立性的最低标准包括：审计机构及其关联方不得持有被审计对象的股权或债务；审计机构的收入来源中被审计对象的缴费占比须设置公开上限，具体比例另行立法确定；认证权的归属需独立于被审计对象及其行业联合体。具体标准需另行立法，本节仅给出原则条件。审计方签署有法律约束力的保密协议。可选的技术实现方向包括加密只读访问、差分隐私查询、零知识证明。

校准底线接口。高风险 AI 的输出校准精度不得低于公共基准——模型标注的置信度须与独立测试集的实证准确率一致，偏差超标者不得在高风险场景部署。公共基准的制定机构须独立于模型开发方与部署方，基准数据集须覆盖高风险领域的代表性边缘案例并定期更新——基准须在每次主要版本发布前重新测试并公开结果。这一接口回应了 §8.1 论证的 RLHF 奖励模型难以审计的结构性困难：不要求审计方重现网络内部运行，只要求被审计方的置信度声明与外部独立测试集可比对。在纤维框架中，这对应“伪小纤维”的制度化防御——用制度阻断模型用确定的语气掩盖不确定性（第四章 §2.4）。

数据配比接口。模型的训练数据宏观分布（语言、文化、时间、来源类型）向公共审计机构披露。披露的不是单条数据，而是宏观结构——类似银行向监管机构报告资产组合构成。若训练数据中 AI 生成内容占比超过阈值，由独立审计机构向监管部门建议降低部署规模或强制补充经授权保留的原生语料（“注入”指存量语料的回流，不是催生新的真实经验），具体执行机制需另行立法或合同约定。这是防止 §1 所诊断的模型坍塌的制度化。

国际互认通道与地缘政治约束已在 §8.2 展开，此处不重复。

---

§10 结语：框架的终点与判断的起点

金融系统用了百年量级的时间才建立起能够终结影子债务循环累积的制度基础设施。其时间线见 §3（252 年、258 年）；AI 的技术资本时钟在月级别运转。252 年不是一个选项。

Von Neumann 在 1955 年提出了这个问题的原型——“我们能在技术中存活吗？”（Von Neumann, 1955）。当时的语境是核武器，但他的核心洞察——技术发展速度超过人类制度适应能力——在今天的 AI 语境中比当时更尖锐。

但历史也告诉我们另一件事：没有制度是在准备好之后才开始的。§3.4 与脚注 [3] 记录的假定——让被监管者以内部模型自评风险足以保障安全——在 2008 年被证伪，其教训由此而来。让开发者审计自己的模型与让银行评估自己的风险在结构上同构。

§1 论证的学科记忆力阶梯——金融领域每次危机后制度被建立，但危机本身在几代人后被遗忘——意味着 AI 领域还没有经历等价的 “1907 时刻”，也不能等到经历。等待危机来教训我们是制度上不可承受的策略。

但本章的论证也在两个关键节点上标注了自身的不完备性。其一：§5 的公共审计基金用 “以过程定价” 替代了 “以结果定价”，绕过了因果链不可追溯和责任主体碎片化两个障碍——但损害发现机制仍是一个开放缺口。制度设计承认自身的不完备性，这本身是诚实的起点。其二：§8.5 构造的代理失序情景说明——一旦两个个人账户之间发生不可逆错配且无人担责，人际层的损害会绕开金融层的赔付环——这一情景赖以成立的制度缺口，在本章考察期内尚未闭合。但如果等它到来再开始建制度，AI 工程数年尺度的知识半衰期很可能使那个教训在被制度化之前就被下一轮技术迭代洗掉。

MCAF 作为分析框架，其功能到此为止。它可以诊断问题的结构——三个前提为什么失效、映射函数的结构性缺陷如何积累认知债务、影子债务为何不可见——但它不能替代政治判断。最终的问题不是 “最优方案是什么”，而是 “我们愿意为了什么付出什么代价”。

但这里有一层陷阱：把这个选择表述为 “效率与主体性之间的权衡” 本身已经预设了 “AI 能以高质量接管认知任务”。实情不是如此。AI 输出受三重约束——训练分布的均值回归、RLHF 的均质化偏差、长尾上的幻觉与自信性误判。所谓 “让 AI 接管一切认知任务” 并不兑现为 “效率最大化”：大量表面流畅、底层错误的产物被灌进系统，在均值附近看似高效，在长尾处系统性劣化。与此同时，人这一侧的判断力退化使这些错误失去识别者——错误不是被消化，而是被沉淀。这一进程在不同人群、不同领域、不同时段上不均匀地发生——不均匀性本身为治理窗口提供了生命线，但也为叙事套利提供了可乘之机。两侧同时劣化，并非一条 “以主体性换效率” 的滑道，而是**错觉上的效率与真实的退化同时发生**。

因此真正的判断不在 “两个极端之间选一个点”——两端都是伪命题。它在于：在哪些领域、以什么审计条件、以什么可撤销机制允许 AI 参与认知劳动；在哪些领域必须保留人类独立判断作为回路的闭合点。这一判断不能由工程优化推出，只能经由政治过程确定——但该政治过程必须以 §9 的边界审计与强制接口为前提，否则连讨论所依赖的可观察性都不存在。

MCAF 框架能做的最后一件事是确保这个政治判断在做出时，所依据的是一份尽可能正确的账本：已知的影子负债已登记、已识别的叙事套利已标注、已量化的摩擦力不对称已计入，“免费” 已被还原为

[3] 2004 年 SEC 允许 CSE（Consolidated Supervised Entity）大投行以内部模型估算净资本约束、1996 年 Basel《市场风险修正案》允许大型银行以内部 VaR 模型计算市场风险资本、Basel II 的顺周期性及其在 2008 年的系统同步失效，以及与 AI 治理的结构同构，详见第二十二章 §1（2004 年 SEC 净资本规则放松与治理时钟）、§2.3（MacKenzie“超级组合” 模式：LTCM 策略同质化与流动性崩溃，与 2008 年 CDO 市场结构同构）与 §3.1（2008 年系统性同步失效）；日本案例中 A_{meso} 的耦合失效见同章 §3.2。

真实成本，借方-贷方的不对称已精确地写在资产负债表上——并把未知的部分明确标为未知。判断的起点不在本书之内——判断在此之后，以一份干净的账本为前提。

§9 提出的两条路径——边界审计与强制接口——不是完整制度蓝图，而是在黑箱上强制开凿可观察的接口维度的两种机制。从这两条路径到具体参数的跳跃，需要政治过程与试点迭代。

这不是解决方案，而是开始——就像 1988 年 Basel I 的 8% 资本充足率并非完美解决方案，而是开始。AI 治理需要的是这个原则的对应物：AI 系统的关键参数不能由开发者单方面设定，更不能由开发者因商业竞争加速关键参数对全球的弥散性影响，必须接受公共审计。原则建立后，具体标准可以迭代。

在时钟房间的语言中：这些时钟不仅在显示读数——它们在替数十亿人看时间。让造钟者独自校准自己的钟，是金融治理领域 Basel II 的失败教训。本书希望 AI 领域不要重复它。

参考文献

国家互联网信息办公室 (2022). 国家互联网信息办公室对滴滴全球股份有限公司依法作出网络安全审查相关行政处罚的决定. https://www.cac.gov.cn/2022-07/21/c_1660021534306352.htm

国家互联网信息办公室 (2023–2026). 境内深度合成服务算法备案清单（历次批次公告，2023 年 6 月–2026 年 7 月）. https://www.cac.gov.cn/2026-07/17/c_1786032856662750.htm

郭滕达、周代数 (2026). 国外人工智能监管沙盒机制政策设计研究. 世界科技研究与发展（网络首发，2026-05-27）. https://doi.org/10.16507/j.issn.1006-6055.2026.04.002

《深圳特区报》(2026). 深圳落地首单公共服务类人工智能数据综合险. 2026 年 4 月 1 日. https://www.sz.gov.cn/cn/xxgk/zfxxgj/zwdt/content/mpost_12714493.html

市场监管总局 (2026). 市场监管总局依法对 7 家电商平台 “幽灵外卖” 系列案作出行政处罚. 2026 年 4 月 17 日. https://www.samr.gov.cn/xw/zj/art/2026/art_9714ee2bef9244819134ef4ffdd14017.html

隐私护卫队 (2025). 2025 年近四千款违规 APP 被通报，企业直面个保严监管. 《南方都市报》/安全内参, 2025 年 12 月 29 日. https://www.secrss.com/articles/86518

张怡萍、冯澍 (2026). 人工智能训练数据获取的反不正当竞争法规制研究——以美国 Mercor 商业模式为例. 中国市场（网络首发，2026-04-30）. https://link.cnki.net/urlid/11.3358.f.20260430.1649.002

赵鼎新 (2015). 社会科学研究的困境：从与自然科学的区别谈起. 《社会学评论》, 2015 年第 4 期.

赵鼎新 (2022). 解释的层次与诠释圈. 《人类学研究》第 15-16 辑, 2022 年 7 月.

Arbesman, S. (2012). *The Half-Life of Facts: Why Everything We Know Has an Expiration Date*. Current/Penguin.

Armer, P. (1978). Obsolescence of the Computing Professional: The Problem and Possible Solutions. In *Proceedings of the 1978 ACM Annual Conference*. https://doi.org/10.1145/800127.804090

Bagehot, W. (1873). *Lombard Street: A Description of the Money Market*. Project Gutenberg. https://www.gutenberg.org/ebooks/4359

Bail, C.A. (2021). *Breaking the Social Media Prism: How to Make Our Platforms Less Polarizing*. Princeton University Press.

Bajaj, T.S., Singh, N., Anand, K., et al. (2026). Position: Safety and Fairness in Agentic AI Depend on Interaction Topology, Not on Model Scale or Alignment. *Preprint*, arXiv:2605.01147.

Baker, T. & Dellaert, B. (2018). Regulating Robo Advice Across the Financial Services Industry. *Iowa Law Review*, 103.

Basel Committee on Banking Supervision. (1988). *International Convergence of Capital Measurement and Capital Standards* (Basel I). https://www.bis.org/publ/bcbs04a.htm

Basel Committee on Banking Supervision. (2006). *International Convergence of Capital Measurement and Capital Standards: A Revised Framework—Comprehensive Version* (Basel II). https://www.bis.org/publ/bcbs128.htm

Basel Committee on Banking Supervision. (2011). *Basel III: A Global Regulatory Framework for More Resilient Banks and Banking Systems* (revised version, June 2011). https://www.bis.org/publ/bcbs189.htm

Basel Committee on Banking Supervision. (2017). *Basel III: Finalising Post-Crisis Reforms* (Basel IV). https://www.bis.org/bcbs/publ/d424.htm

Bearer-Friend, J. & Polcz, S. (2025). Sharing the Algorithm: The Tax Solution to Generative AI. *Columbia Journal of Tax Law*, 17(1).

BIS. (2024). *Annual Economic Report 2024*, Chapter III: Artificial Intelligence and the Economy: Implications for Central Banks. https://www.bis.org/publ/arpdf/ar2024e3.htm

Brynjolfsson, E., Li, D. & Raymond, L. (2025). Generative AI at Work. *Quarterly Journal of Economics*, 140(2).

Burton, R.E. & Kebler, R.W. (1960). The "Half-Life" of Some Scientific and Technical Literatures. *American Documentation*, 11(1).

Callon, M. (Ed.). (1998). *The Laws of the Markets*. Blackwell.

Chalkidis, I. & Søgaard, A. (2026). Brainrot: Deskilling and Addiction are Overlooked AI Risks. In *Proceedings of FAccT 2026*. arXiv:2605.03512.

Chancellor, E. (2022). *The Price of Time*. Atlantic Monthly Press.

Coyne, S. (2026). Three Models of RLHF Annotation: Extension, Evidence, and Authority. In *Proceedings of FAccT 2026*. arXiv:2604.25895.

Devlin, J., Chang, M.-W., Lee, K., et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of NAACL-HLT 2019*.

DLA Piper. (2026). *GDPR Fines and Data Breach Survey: January 2026*. https://www.dlapiper.com/en-gb/insights/events/gdpr-fines-and-data-breach-survey/

Dutch Data Protection Authority (Autoriteit Persoonsgegevens). (2024). Dutch DPA Imposes a Fine of 290 Million Euro on Uber Because of Transfers of Drivers' Data to the US. Press release, 26 August 2024. https://www.autoriteitpersoonsgegevens.nl/en/current/dutch-dpa-imposes-a-fine-of-290-million-euro-on-uber-because-of-transfers-of-drivers-data-to-the-us

EU AI Act. (2024). Regulation (EU) 2024/1689.

European Commission. (2025). Commission Finds Apple and Meta in Breach of the Digital Markets Act. Press release, 23 April 2025. https://digital-markets-act.ec.europa.eu/commission-finds-apple-and-meta-breach-digital-markets-act-2025-04-23_en

European Commission. (2026). Commission Preliminarily Finds TikTok's Addictive Design in Breach of the Digital Services Act. Press release IP/26/312, 6 February 2026. https://ec.europa.eu/commission/presscorner/detail/en/ip_26_312

Financial Crisis Inquiry Commission. (2011). *The Financial Crisis Inquiry Report: Final Report of the National Commission on the Causes of the Financial and Economic Crisis in the United States*. U.S. Government Printing Office.

FTC. (2019). FTC Imposes $5 Billion Penalty and Sweeping New Privacy Restrictions on Facebook. Press release, 24 July 2019. https://www.ftc.gov/news-events/news/press-releases/2019/07/ftc-imposes-5-billion-penalty-sweeping-new-privacy-restrictions-facebook

FTC. (2024). FTC Finalizes Order with X-Mode and Successor Outlogic, Prohibiting It from Sharing or Selling Sensitive Location Data. Press release, April 2024. https://www.ftc.gov/news-events/news/press-releases/2024/04/ftc-finalizes-order-x-mode-successor-outlogic-prohibiting-it-sharing-or-selling-sensitive-location

FTC. (2024). FTC Finalizes Order with InMarket, Prohibiting It from Selling or Sharing Precise Location Data. Press release, May 2024. https://www.ftc.gov/news-events/news/press-releases/2024/05/ftc-finalizes-order-inmarket-prohibiting-it-selling-or-sharing-precise-location

FTC. (2024). FTC Investigation Leads to Lawsuit Against TikTok and ByteDance for Flagrantly Violating Children's Privacy Law. Press release, 2 August 2024. https://www.ftc.gov/news-events/news/press-releases/2024/08/ftc-investigation-leads-lawsuit-against-tiktok-bytedance-flagrantly-violating-childrens-privacy-law

FTC. (2024). FTC Takes Action Against Mobilewalla for Collecting and Selling Sensitive Location Data. Press release, December 2024. https://www.ftc.gov/news-events/news/press-releases/2024/12/ftc-takes-action-against-mobilewalla-collecting-selling-sensitive-location-data

FTC. (2024). FTC Takes Action Against Gravy Analytics, Venntel for Unlawfully Selling Location Data Tracking Consumers to Sensitive Sites. Press release, December 2024. https://www.ftc.gov/news-events/news/press-releases/2024/12/ftc-takes-action-against-gravy-analytics-venntel-unlawfully-selling-location-data-tracking-consumers

Goodhart, C.A.E. (2011). *The Basel Committee on Banking Supervision: A History of the Early Years, 1974–1997*. Cambridge University Press.

Harris, L. & Criddle, C. (2025). Insurers Retreat from AI Cover as Risk of Multibillion-Dollar Claims Mounts. *Financial Times*, 23 November 2025.

He, S. S., Ardi, C., Govindan, R., et al. (2026). DeGenTWeb: A First Look at LLM-dominant Websites. *Preprint*, arXiv:2605.00087.

Irish Data Protection Commission. (2023). Data Protection Commission Announces Conclusion of Inquiry into Meta Ireland. Press release, 22 May 2023. http://www.dataprotection.ie/en/news-media/press-releases/Data-

Protection-Commission-announces-conclusion-of-inquiry-into-Meta-Ireland

Lin, Z., Guo, Z., Li, W., et al. (2026). Action-Aware Generative Sequence Modeling for Short Video Recommendation. In *Proceedings of SIGIR 2026*. https://doi.org/10.1145/3805712.3809728

Machlup, F. (1962). *The Production and Distribution of Knowledge in the United States*. Princeton University Press.

MacKenzie, D. (2006). *An Engine, Not a Camera: How Financial Models Shape Markets*. MIT Press.

Mason, L. (2018). *Uncivil Agreement: How Politics Became Our Identity*. University of Chicago Press.

McGurk, E. & Khachaturov, D. (2026). Human-Provenance Verification Should Be Treated as Labor Infrastructure in AI-Saturated Markets. *Preprint*, arXiv:2605.03210.

McLeay, M., Radia, A. & Thomas, R. (2014). Money Creation in the Modern Economy. *Bank of England Quarterly Bulletin*, 2014 Q1.

Minsky, H.P. (1986). *Stabilizing an Unstable Economy*. Yale University Press.

NIST. (2023). AI Risk Management Framework (AI RMF 1.0).

Norman, B. (2015). BoE Archives Reveal Little Known Lesson from the 1974 Failure of Herstatt Bank. *Bank Underground*, Bank of England.

Pavlus, J. (2025). When ChatGPT Broke an Entire Field: An Oral History. *Quanta Magazine*, April 30.

Petersen, A.J. (1966). Technical Obsolescence. *IEEE Spectrum*, February 1966.

Rieder, B. (2020). *Engines of Order: A Mechanology of Algorithmic Techniques*. Amsterdam University Press. https://doi.org/10.5117/9789462986190

Sastry, G., Heim, L., Belfield, H., et al. (2024). Computing Power and the Governance of Artificial Intelligence. arXiv:2402.08797.

SEC. (2024). In the Matter of Delphia (USA) Inc., Admin. Proc. File No. 3-21894, Advisers Act Release No. IA-6573 (March 18, 2024).

SEC. (2024). In the Matter of Global Predictions, Inc., Admin. Proc. File No. 3-21895, Advisers Act Release No. IA-6574 (March 18, 2024).

Shu, W. & Wei, P. (2026). AI Safety as Control of Irreversibility: A Systems Framework for Decision-Energy and Sovereignty Boundaries. *Preprint*, arXiv:2605.01415.

Shumailov, I., Shumaylov, Z., Zhao, Y., et al. (2024). AI Models Collapse When Trained on Recursively Generated Data. *Nature*, 631.

Spennemann, D.H.R. (2025). Delving Into: The Quantification of AI-Generated Content on the Internet (Synthetic Data). *arXiv:2504.08755*.

Stigler, G.J. (1971). The Theory of Economic Regulation. *Bell Journal of Economics*, 2(1).

Varoufakis, Y. (2023). *Technofeudalism: What Killed Capitalism*. Bodley Head.

Villalobos, P., Ho, A., Sevilla, J., et al. (2022). Will We Run Out of Data? Limits of LLM Scaling Based on Human-Generated Data (revised version). *arXiv:2211.04325*.

von Neumann, J. (1955). Can We Survive Technology? *Fortune*.

Yu, H., Kim, D. & Kim, Y. (2026). Retrieval Collapses When AI Pollutes the Web. In *Proceedings of the ACM Web Conference 2026* (WWW '26). https://doi.org/10.1145/3774904.3792955

Zheng, J. & Meister, M. (2025). The Unbearable Slowness of Being: Why Do We Live at 10 bits/s? *Neuron*, 113(2). https://doi.org/10.1016/j.neuron.2024.11.008

Zhou, J., Chen, Q. & He, L. (2026). Contextual Multi-Objective Optimization: Rethinking Objectives in Frontier AI Systems. *Preprint*, arXiv:2605.03900.