《时钟的房间与宏观认知债务记账框架——AI、金融与算法平台的映射链分析》五卷书（含中文版与英文版）采用知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）授权。

许可摘要：https://creativecommons.org/licenses/by-nc-nd/4.0/deed.zh-hans 许可全文：https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.zh-hans

作者另行依据欧盟《数字单一市场版权指令》（Directive (EU) 2019/790）第 4 条第 3 款，明确保留为文本和数据挖掘目的复制、提取本书的权利，包括为人工智能或机器学习模型的训练、微调或评估而进行的文本和数据挖掘。本保留仅用于排除该指令第 4 条第 1 款规定的例外或限制，不影响该指令第 3 条或其他可适用的例外与限制，也不减少 CC 许可已经授予的权利。

超出 CC 许可范围且依法需要取得授权的使用，须事先通过 theclockroom@139.com 取得作者书面授权。

在许可范围内分享本书时，须适当署名、提供许可链接并标明是否作了修改，不得暗示作者为分享者或其使用背书；仅限非商业性使用；不得分享演绎作品。

除本许可明确授予的权利外，其余权利由作者保留。书中第三方材料（如有）依其原有权利声明或许可处理，不视为由本书作者另行授权。

内容免责声明

本书内容属于学术研究、思想实验，相关分析主要基于历史数据和公开文献。作者具有 12 年金融机构宏观策略研究经验，目前未持有证券投资咨询牌照。本书不构成投资建议、技术实施建议或政策建议，亦不构成对任何证券、金融产品或交易策略的推荐或要约。读者应独立判断，并自行承担其决策风险。历史表现不代表未来结果。

第三十七章：Agency Is All You Need——以元审计（致良知、再启蒙）保护人类主体性

摘要

2017 年，Vaswani 等人发表 “Attention Is All You Need”（Vaswani et al., 2017），Transformer（变换器）架构以注意力权重分配定义了当代人工智能（AI）的基础操作。这篇论文至今（2026 年 9 月 11 日）累积超过二十六万次引用。本章论证：不够。

三个概念需被严格区分。注意力（attention）是在给定读数中分配权重的时钟维度操作——Transformer（变换器）的核心机制；元审计（meta-audit）是检查读数与真实之关系的动作——追问 “这个钟可靠吗” 的能力，属人，可被工程化支持（第九章 §7 的四个工程方向激活的是用户的元审计）；主体性（agency）是人的存在方式，其存在模式是连续的、多通道的、关系性的时间维度。三者构成从时钟维度到时间维度的层次：注意力分配权重，元审计质疑权重分配的前提，主体性自发生成问题——所问不回溯到任何预设的问题或行动条件。

当前 AI 具有时钟维度的注意力、可被工程化以模仿人的元审计，但其运作仍然是离散的、有刻度的、仅处理读数的。

本章沿四条线索论证这一判断。其一（§1），映射函数垄断的历史回归——中世纪教会通过语言与神学垄断救赎读数（第一层信息缺失，可被路德式翻译打开），AI 黑箱通过数万亿维参数空间重建了同一垄断（第三层本体论降维，不能指望完整打开）；第九章 §7 的四个工程方向不是打开黑箱，而是让黑箱诚实标注不确定性。其二（§2），叙事载荷（ϕ）二阶导在黑箱内的文明偏斜——个体作为默认分析单元（个人主义作为默认框架）、西方中心主义作为默认校准基准，通过基础设施而非说服传导，绕过了文明内部通过分布式道德判断形成的制约。其三（§3），中美欧三种治理时钟的差异与共同限制——美国侧重投射端扩张，欧盟侧重程序框架，中国侧重针对性干预；这些取向的优势与盲区既有差异也有重叠，其组合效果取决于审查资源、实施能力与纠错程序，而全球治理主钟归属未定，本身构成映射自我引用。其四（§4），洪水神话的两种原型策略——方舟（离散化 + 系统重启，等待救赎）与治水（连续性

疏导 + 十三年持续做功，不预设救赎）。

最终判断（§5）：**文明为人类而存在，不是人类为文明服务。**元审计是主体性在当前技术条件下的最小可操作化——是让 AI 不消灭人类的主体性（Agency）。有关万万亿个时钟等同于时间的尝试，这是数学上的自我繁殖。

关键词

主体性（Agency）；元审计（Meta-Audit）；注意力机制；映射函数垄断；叙事载荷二阶导；三种治理时钟；诺亚方舟与大禹治水；时钟的房间；冯 • 诺依曼

---

§0 主体性与元审计的区分

在进入正文之前，需要精确区分两个贯穿全章的核心概念。这个区分不是术语偏好——它标注了两个不同的认识论层次。

注意力（attention）是在读数中分配权重的操作。Transformer（变换器）的自注意力机制精确地做这件事：给定一个词元（token）序列，计算每个词元与可访问位置之间的相关性权重，据此组合信息。这是时钟维度内的操作——在一组给定的时钟读数中，决定看哪个钟、各看多大权重、怎么组合多个钟的读数。操作的全部前提是：读数已经到达了。

元审计（meta-audit）是检查读数与真实之间关系的动作——不只是读钟，而是追问 “这个钟可靠吗”。元审计需要一个触发条件（一个读数到达了）和一套标准（合法性基座（$\|L\|$）提供的验证工具）。它是可操作化的——第九章 §7 的四个工程方向（集成不一致、共形预测集、证据溯源、认知摩擦设计；第十六章将其展开为强制不一致、校准、接地度量、摩擦架构四条路径，下文沿用简称）全部为元审计提供不同条件的工程支撑——模型分歧提供比较线索，校准方法约束不确定性表述，溯源信息支持依据核查，摩擦设计保留审查机会；它们是否实际支持了元审计，取决于这些信息是否可用、是否经过检验，以及审查结果能否改变后续行动。可以设计系统来支持元审计，可以衡量元审计是否发生。元审计是一个动作。下文区分元审计行为与元审计能力：前者是一次具体检查，后者是发起并完成这种检查的能力。能力需要持续维护，但不因此与主体性本身等同。

主体性（agency）则不是能力——是人的存在方式。第一章 §1.2 第四类问题（元信息问题）测量的正是它：新时钟被推进房间，没有人发问，没有给出行动条件，只发生了一个事件；把事件本身识别为需要解释的信号、由此自发生成问题——“为什么送新钟进来？它依据什么校准？”——是人在时间维度中的存在模式（第一章 §5.2：时间维度是连续的、多通道的、关系性的存在模式，时钟维度是离散的、有刻度的、仅处理读数的操作模式）。这一判据是对人认知处境的正面描述，不是机器测试：人自发问出的问题，不回溯到任何预设的问题或行动条件。

AI 的全部表现则发生在时钟维度内——操作模式中的处理，无论触发来自即时指令、预设规则还是随机数。把 “自主发问” 的表现读作主体性的迹象，是把操作当作存在——读数当作真实的又一次发生。Searle 的中文房间区分形式符号操作与理解，与此同向：句法的完备不构成语义。当前架构中，AI 的触发面（提示、系统流程、目标函数）是工程上给定的事实——主体性在 AI 的结构里不出现，在人的存在里现成。元审计因此是属人的：“元” 预设一个对判断负责的自我，审查者与被审查的判断同属这个自我——审查的对象可以是自己的判断，也可以是自己准备采信的外部读数；反身性在于：采信本身也

是一个判断，同样要被审查——致良知说的正是这个结构。AI 的自检是处理，不是元审计；它可以被工程化以模仿人的元审计，但那不是元审计的实例。

三者的层次关系：

概念	定义	第一章 §1.2 对应	时间性质	AI 是否具有
注意力	在给定读数中分配权重	第一、二类问题：读数内处理	时钟维度	有——Transformer（变换器）的核心
元审计	检查读数与真实的关系	第三类问题：行动判断	时钟-时间界面	无——可被工程化以模仿；元审计属人
主体性	人的存在方式：无人给定问题时，把事件本身识别为需要解释的信号	第四类问题：自发提问	时间维度	无——仍是离散的、有刻度的、仅处理读数的

注意力是人做的最基本的事——看。元审计是人做的更高阶的事——质疑所看到的。主体性表现为：即使没有明确要求，人也能决定是否关注、是否质疑。

MacKenzie（2009）转述卡隆的 agencement 概念提供了一个互补的视角——“For Callon, an actor is ‘made up of human bodies but also of prostheses, tools, equipment, technical devices, algorithms, etc.’—in other words is made up of an agencement”（“在 Callon 看来，行动者是‘由人体，同时也由义肢、工具、设备、技术装置、算法等组合而成的’——换句话说，行动者就是一个 agencement”）（MacKenzie, 2009）。Agencement 描述的是行动能力如何被拼装——人体加工具加算法加程序，组装成一个复合行动者。本章追问的是拼装之后的问题：在这个复合体中，审计维度是否被保留？如果 agencement 中的审计成分被压缩为零——工具替代了判断、算法替代了校准——主体性的行使就退化为对既定流程的执行：一个行动者在行动，但不知道自己在做什么、为什么做、做得对不对。从 agencement 到主体性的距离，就是从“被装配出来的行动能力”到“知道自己被装配成了什么的主体性”之间的距离。

冯 • 诺依曼 1955 年的三个词全在主体性这一层。Patience 不是一种审计行为——它是一种存在状态：在时间中存在而不被任何特定时钟驱动。耐心不是一次核验动作，而是持续判断所需的状态——在没有输入时仍然维持。Flexibility 不是在两种审计方法之间切换——它是在两种存在模式（时间维度和时钟维度）之间切换的能力。Intelligence 不是“审计某个钟的读数”——是“看到时钟结构本身”。三个词描述的都是主体性，不是审计。

本章的论证结构因此是：**需要的是主体性（agency）。但主体性不可直接工程化——不能给一个工程师说“请在 AI 中实现主体性”。元审计（meta-audit）是主体性在当前技术条件下的最小可操作切片。**第十六章 §5 的四条路径——强制不一致、校准、接地度量、摩擦架构——不是在 AI 中实现主体性，而是在 AI 的设计中为人类的主体性保留操作空间。不是让 AI 获得主体性——是让 AI 不消灭人类的主体性。

这个区分决定了全章的方向：不是“如何让 AI 更智能”——是“如何在 AI 越来越智能的世界中保护人类作为主体的存在条件”。主体性是所需要的。元审计是所能做的。前者是目的。后者是手段。

元审计在这个意义上是**再启蒙**——不是以钟校钟意义上的启蒙：那一种用新读数替换旧读数，把“光明”当作新叙事灌输，是遮蔽的延续。康德警告过：“新的偏见会和旧的偏见一样，役使不会思考的众

人”（Kant, 1784；本书译文）——康德指出的是政治革命并不自动改变思维方式；本书据此进一步强调：一种学说曾经打破旧有遮蔽，当它不再接受审查时，也可能成为新的遮蔽。王阳明的根据在于良知的本明：良知“灵昭不昧”（王阳明，《大学问》）——明是本有的；但常人之心“暂明暂灭”，蔽去复来，故功夫“只求日减，不求日增”（王阳明，《传习录》）。去蔽的功夫，王阳明称为**致良知**：在事上把蔽去掉，以复其本体之明（王阳明，《传习录》）——不是一次性赋明，是持续去蔽。元审计的全部路径都在这个“再”字上：不给人添加什么，只是把遮蔽物一次次移开。

§1 从赎罪券到黑箱：映射函数垄断的历史回归

§1.1 中世纪的时钟房间

中世纪天主教会构建了一个完整的时钟房间。

真实状态（T）是灵魂的状态——信众是否得救。映射函数（π）是教义解释权——从信众的行为到教会裁决读数（r）的映射规则；救赎状态（T）是否随之变化，正是该映射所宣称而非所验证的。读数（r）是教会的裁决——“有罪”或“被赦免”。

信众无法独立验证。不是因为太阳不存在——信众相信上帝存在。是因为通向太阳的窗户被制度性地垄断了。教会声称自己是唯一合法的中介——只有受过神学训练、经过教会授权的祭司才能解读经文、执行圣礼、传达神意。经文用拉丁文书写——普通信众不识拉丁文，无法自己阅读。教义由教会的神学体系论证——而神学体系的权威由教宗授权。这是第一章 §3.6 的闭环伪校准：用钟校准钟，用教义论证教义。

赎罪券在这个结构中的位置是精确的：**付钱改变读数（r）——是否改变真实状态（T），不由本节判定。**在本节的分析情形中，购买者的行为没有变；变的只是教会给出的那个读数：从“炼狱中的刑期”变为“刑期缩短”。这是纯粹的叙事载荷（ϕ）操作——纤维被人为地操纵了。教会卖的不是救赎——是救赎的读数。

须立即声明本章的边界：以上分析不涉及信仰本身的真伪——那超出了时钟房间框架的适用域。第一章 §3.4 的定义未限定 T 的类型（第九章 §3 已将其核心范围限定为可被独立校准的事态）。灵魂状态是否属于这个集合，是神学和哲学的问题，不是本章的问题。本章分析的是映射函数的制度性垄断结构——无论 T 是什么，垄断通向 T 的通道并将通道的使用权变现，这个操作的结构可以被时钟房间的语言精确描述。这个结构在不涉及信仰内容的情况下独立成立。

§1.2 古登堡的双重工具

15 世纪中叶，古登堡在欧洲发展了金属活字印刷体系。早期印刷品包括圣经和赎罪券。

同一技术同时服务于两个方向。教会用它放大叙事载荷（ϕ）——大规模印刷赎罪券，将此前手工抄写的、小规模流通的赎罪操作扩展为工业化生产。路德用它打开窗户——1522 年将新约翻译为德文并用印刷术大量复制，让更多普通人能够自己阅读经文，绕过祭司的映射函数（π）——德语译本扩大了普通读者接触经文的渠道，降低了对既有解释中介的依赖，但翻译本身仍包含解释选择。

这是第一章 §4.2 适应性偏移的历史原型。印刷术（解封存量（C）的一次大规模释放——将书写从手抄的稀缺品变为可批量生产的商品）被竞争中的双方各自使用：垄断方用它强化垄断，挑战方用它打破垄断。技术本身不决定方向。决定方向的是使用者和技术之间的权力关系。

路德的宗教改革在时钟房间的框架中是一次成功的第一章 §4.1 第一层解法：信息缺失被消除了。拉丁

文是语言障碍——翻译消除了障碍。复制稀缺是传播障碍——印刷术消除了障碍。普通信众获得了一条独立于教会的、与经文（他们心目中的太阳）的接触通道。文本获取与解释权的分配发生了变化——这里发生变化的是获取与解释权，而不是救赎状态获得了独立验证。

§1.3 AI 黑箱：第三层不可逆条件下的映射函数垄断

当代 AI 商业化重建了中世纪教会的映射函数垄断结构——但在一个更深的不可逆层级上。

结构同构的五个层面：

1. **映射函数的垄断。**教会垄断了教义解释权——只有祭司能解读经文。AI 公司垄断了前沿训练——只有拥有算力和数据的公司能训练前沿模型；部分商业模型还限制权重与训练信息的获取。第九章 §5 已论证：训练语料以英语为绝对主导（常用的网页爬取公共语料库 Common Crawl 约 44% 为英语，中文约 4.6%），且基于英语语料优化的分词器对其他语言存在系统性的效率歧视。生产读数的能力被集中在少数实体手中。

2. **不透明性的结构层级。**中世纪经文用拉丁文书写——语言障碍。模型参数存储在数万亿维的数值空间中——维度障碍。两者的不透明性来源不同，但效果一样：用户被结构性地排斥在映射函数之外。关键差异在于：拉丁文可以被翻译（路德做了），这是第一章 §4.1 第一层的问题——映射未知时读数不足以唯一确定真实，但建立一条独立于读数集合之外、与真实有因果接触的校准通道即可收窄（原则上可解）。参数空间不能被 “翻译” 成人类可读的形式——因为这是第一章 §4.3 第三层的问题——本体论降维：真实状态的维度高于读数的维度，被丢弃的维度不因事后审计而恢复。数万亿维的映射函数的无损压缩未被证明可能——判定其无损性所需的检查，其规模远超个体在可行时间内所能处理的范围——机构可以通过分工部分抵消，但不改变判定任务本身的规模（第四章命题三）。

3. **闭环自证。**教会的权威由教会自己的神学体系论证，神学体系的权威由教宗授权——第一章 §3.6 的闭环伪校准。AI 的可靠性由 AI 开发者设计的基准测试证明，基准测试的权威性由 AI 开发者的声誉背书——第一章 §4.2 的映射自我引用。

4. **质疑成本的系统性抬高。**质疑教义的人被绝罚。质疑 AI 的人被标记为 “不懂技术” 或 “阻碍进步”。机制不同（宗教惩罚 vs 社会排斥），功能一样：提高质疑的社会成本，降低质疑的发生率。这是第十七章 §6 论证的主钟通过改写 “什么算正确的经济制度” 侵蚀合法性基座——华盛顿共识把 “资本管制” 预装为 “落后”；本章把同一机制平行外推：硅谷共识把 “AI 怀疑论” 预装为 “反进步”。

5. **不可见的支付。**教会收什一税——收入的十分之一，可见且可审计。平台提供免费服务——以注意力和数据为代价，不可见且不可审计。什一税是叙事载荷（ϕ）的一阶导（可见的交易）。免费经济的成本是叙事载荷的二阶导——人不知道自己 “支付了” 多少注意力碎片化、多少判断力退化、多少隐私泄露。第九章 §5 论证的叙事载荷（ϕ）二阶导消灭审计对比条件的机制在此获得了历史纵深：人没有一个 “不使用免费服务” 的参照状态来对比——第八章 §4.2 已论证 AI 产品以 “免费” 形态呈现、以注意力、行为数据和认知习惯为对价——就像中世纪信众没有一个 “不通过教会接触上帝” 的参照状态来对比。

路德的策略为什么不能直接复制。路德的成功依赖于一个条件：拉丁文的不透明性是第一章 §4.1 第一层问题——翻译就解决了。打开黑箱，让每个人自己读经文。AI 的不透明性是第一章 §4.3 第三层的问题——被映射丢弃的维度不因事后审计而恢复，且按第四章命题三，判定一次压缩是否无损，须检查状态支持与映射是否保留了区分相关状态所需的信息。打开黑箱——即验证存在一条无损的翻译——不

是治理可以依赖的前提：不是因为公司不愿意，而是对数万亿参数的模型，判定无损性所需的检查，其信息规模远超任何已知方法在可行时间内所能完成的范围。治理不能建立在未经检验的无损假设上。

第十六章 §5 的四条路径因此是一种不同于路德的策略。路德说：打开黑箱，让每个人自己看。第九章 §7 说：不打开黑箱（第一章 §4.3 告诉我们：被丢弃的维度不因事后审计而恢复——治理不能以完整无损的打开为前提），而是让黑箱诚实地标注自己的不确定性。不是让人看见太阳——是让祭司在每句话后面加上 “我也不确定”——诚实标注不确定性是审计的必要条件，不是审计已经完成的证明。强制不一致让人看到多个钟的矛盾。校准让钟诚实地标注偏差范围。接地度量测量钟到太阳隔了几层墙。摩擦架构给人时间抬头看窗户。

这比打开黑箱更温和。但可能是第三层不可逆条件下最主要的方向。

---

§2 黑箱内的叙事载荷二阶导：语法而非观点

§2.1 叙事载荷（ϕ）的一阶导可见，二阶导不可见

第九章 §5 已论证：大语言模型的错误有两个层次。一阶导数是可见的——模型说 “拿破仑赢了滑铁卢”，事实错误，可检测可纠正。二阶导数是不可见的——模型的默认分析框架来自训练语料的统计分布，而训练语料以英语为绝对主导。

此处需要将二阶导的内容展开为具体的文明偏斜——不是 “英语占比高” 这个统计事实本身，而是这个统计事实在模型输出中沉淀为什么样的默认语法。

§2.2 个人主义作为默认语法

许烺光（Hsu, 1971/2002）从文化人类学诊断了西方社会在人际关系领域仍依赖一种将离散化的原子个体当作人的本体论默认。“Individual” 的拉丁语词源（*in-dividuus*）即 “不可再分的最小离散单元”。

当数万亿参数的模型在以这种本体论为默认的语料上训练时，个人主义不是作为 “一种观点” 被编码的——而是作为组织句子的方式被编码的。本节以 “语法” 比喻回答中默认采用的问题结构、分析单位与评价标准，不指语言学意义上的句法规则；“默认” 也不预先规定其技术来源——训练语料、后训练、系统提示和产品设计都可能参与形成这种倾向。在未被要求比较不同框架时，模型可能优先以个体属性、选择与责任组织回答——个体的权利、个体的选择、个体的责任、个体的体验。“关系” 在模型的输出中不是不存在——但它被处理为 “个体之间的连接”，不是许烺光论证的 “先于个体存在的、构成个体的场”。

用时钟房间的语言：模型的映射函数（π）在训练过程中内化了一种特定的投影方式——将人类经验的高维状态空间投影到以 “个体” 为基本单元的坐标系上。第一章 §4.3 的降维在这里不仅是量的丢失——是表示方式的选择。这里的关键不只是坐标系的选择，而是表示过程中保留或省略了哪些关系：如果回答只保留个体属性与选择，而不表示关系义务、共同历史和相互依赖，这些因素便难以进入后续判断。当这种表示进一步把关系处理为 “个体之间的连接” 时，它便丢弃了关系维度中不可还原为连接的部分——许烺光所论证的心理-社会稳态（PSH）第三层核心区的情感纽带。

这不是模型在 “表达” 个人主义立场——模型不知道自己在做什么。这是第一章 §4.2 的选择性适应（无意图的）在训练过程中的结果：英语语料中的某些主导叙述，为以个体为中心的分析提供了大量训练

材料——这一机制不以设计者有意推广个人主义为必要条件，产出这些文本的文明以个人主义为默认。模型在这些文本上训练，统计规律将默认内化为语法。

选择许烺光的框架来诊断这一偏斜，本身也是一种立场——它来自一个非西方人类学传统的视角，第五章已论证其经验基础。

§2.3 西方中心主义作为默认校准

更深一层。模型的映射函数不仅以个体为分析单元（个人主义作为默认框架），还以西方历史经验为默认的校准基准。

什么是“发展”？模型的默认回答会以工业化、城市化、国内生产总值（GDP）增长为衡量标准——这是西方从 18 世纪以来的特定历史路径。什么是“好的治理”？默认回答会以多党选举、独立司法、自由市场为标准——这是冷战后西方主流的自由主义制度处方。什么是“理性”？默认回答会以分析哲学、假设检验、可证伪性为标准——这是从笛卡尔到波普尔的特定认识论传统。

这些不是“错误”——它们是在特定文明经验中有效的框架。但当它们通过模型的全球部署成为所有文明的默认分析工具时，第九章 §5 论证的叙事载荷二阶导完成了覆盖：替代框架可能更难进入默认回答，需要使用者主动提出。替代框架面对的不是模型的反驳或排斥，而是默认设置的略过——它们的缺席不是反对的动作，而是“不主动给出就不出现”的默认机制本身。

赵鼎新（2019）的“多样性时间”概念在这里获得了技术放大。意识形态竞争因无明确输赢准则而多元、缓慢、无方向——这是第三章 §3.1 论证的治理时钟运行的社会学条件。但当一个技术基础设施将特定的意识形态框架硬编码为全球默认时，多样性时间被积累性发展时间短路了——不是通过说服（那需要多样性时间中的漫长竞争），而是通过基础设施的覆盖（那运行在积累性发展时间上，有方向、可累积、产生同构压力）。

§2.4 和中世纪教会的精确对应

中世纪教会的映射函数垄断植入了特定的世界观：原罪（人类默认状态是有罪的）、个体-神的二元关系（救赎是个体和超越者之间的事，不是社群内部的事）、线性末世论（历史从创世到末日是一条单向的线）。这些不止是教会在“宣传”的观点——它们是教会的整个运作框架的默认预设。一个生活在中世纪欧洲的人，即使从不进教堂，也在这套预设中生活——因为法律、节日、时间计量（基督纪年）、空间组织（教区）全部以这些预设为基础设施。

AI 商业化的映射函数垄断植入了另一套世界观：原子化的个体（人的默认存在方式是离散的独立单元）、个体-市场的二元关系（价值由个体在市场中的交换决定，不是由社群内部的关系决定）、线性进步论（历史从落后到先进是一条单向的线）。这些不必是 AI 公司宣传的——它们可以由训练语料的统计分布，连同后训练与产品设计，共同形成。一个使用 AI 辅助写作、搜索、决策的人，即使不认同这些预设，也在这套预设中操作——因为模型的输出以这些预设为语法。

两者的共同结构：**叙事载荷的二阶导通过基础设施而非说服来传导。**人不需要同意教会的教义就会被基督纪年框住。人不需要同意个人主义就会被模型的默认分析单元框住。基础设施不必逐次说服使用者，也能影响问题如何被提出、哪些选项首先出现，以及哪些依据更容易被调用——说服需要主体的注意力（人可以不听），基础设施不需要（人无法不使用日历）。

§2.5 跨文明的不对称脆弱性

赎罪券式的映射函数垄断，在其他文明中并不多见。许烺光论证的中国文明以心理-社会稳态（PSH）第三层（亲近的社会关系）为核心——道德判断分散在社会关系网络中，不集中在任何超越性权威手里。这种分布式结构能够限制单一中介集中控制道德判断，但不排除网络内部形成权威集中。

但 AI 商业化的全球部署绕过了这个制约机制。离散利维坦（按第二十五章 §1 判别函数命中的关键节点网络，下文同）不需要说服中国文明接受个人主义——它只需要成为中国用户获取信息的默认通道。当用户通过同一批以英语为主导的模型搜索、写作、分析时，模型的默认语法（以个体为分析单元的个人主义框架、西方中心的校准基准）不是作为 “外来观点” 到达的——是作为 “工具的默认设置” 到达的。人不会质疑计算器的默认设置。

这意味着：历史上通过文明内部的制度安排（分布式的道德判断、关系本位的社会结构）抵御映射函数垄断的机制，在全球化的技术基础设施面前可能失效。不是因为这些机制本身变弱了——是因为传导方式变了。中世纪的映射函数垄断通过制度通道传导（人必须去教堂），可以被制度通道抵御（中国文明没有教会）。AI 的映射函数垄断通过技术通道传导（人必须使用搜索引擎），技术通道的跨境性使单一文明内部的制度安排难以完全约束它。

---

§3 三种治理时钟：中美欧的结构性差异

第三十四章 §1 已沿筛选机制的轴线分类了塑造 AI 路线的四种力量（国家安全、学术派系、资本、替代场）；本节沿主体（国家/地区）的轴线观察这四种力量在当代的具体组合，两个分类是互补的。

> 本章的 τ_{cap}、τ_{gov}、τ_{debt} 分别为第三章 §3.2 定义的技术资本时钟（τ_c）、治理时钟（τ_g）、债务时钟（τ_d）在本章治理比较语境下的场景记号，三组符号一一对应，不构成新的时钟定义。

§3.1 AI 寡头的形成机制

在分析三种监管模式之前，先用唐世平（Tang, 2013）的社会演化框架理解被监管对象的形成。

AI 产业的寡头结构不是偶然的——它是竞争性权力选择（第三章 §6 假设一：技术扩张是竞争性权力选择的产物）在特定资源约束下的结构性产物。前沿模型的训练需要三种稀缺资源的同时集中：算力（解封存量（C）——全球 AI 算力约每 7 个月翻倍（You et al., 2026），但 AI 芯片的供应高度集中于少数设计商——由英伟达设计的芯片提供的算力占估计总量的 60% 以上）、数据（互联网文本语料——公开语料之外，高价值与专有数据的采集集中在少数平台）、人才（AI 研究者——能独立推动前沿模型进步的核心研究者处于千人量级）。三种资源的同时集中产生了极高的进入壁垒——唐世平意义上的 “人工变异” 受到资源约束的严格选择，只有少数实体能通过选择关卡。

结果是：第二十五章 §1 与第三十三章 §5 锚定的离散利维坦（按串联控制、替代成本不对称、跨主权可达、资本结构反身性四条判别条件界定的关键节点网络），其上市部分——七家领先的美国科技公司（英伟达、微软、苹果、Alphabet、亚马逊、Meta、特斯拉）——截至 2025 年 10 月 2 日收盘合计市值 20.8 万亿美元（Cingari, 2025）。这一集中不仅是市场失灵的表征，更是竞争过程在资源集中条件下的内生产物。此处 “跨主权可达” 内嵌于判别函数本身，而非事后描述——这一点对下文 §3.5 的论证具有结构性意义：单一主权管辖范围对节点网络难以独立完成审计或重定向，协作的必要性取决于具体控制点与替代路径。Hoffman（2015）的锦标赛模型在这里适用：竞争的不成比例收益（赢者通吃的市场结构）使得参与者的激进投入是理性的——即使投入的总量从社会角度看过大。

元审计在第三章的记账框架中承担防御端的偿付做功：认知债务——投射载荷超出防御容量时沉淀的序数残差的累积存量——其偿付是部分的（第三章 §4.1：第三层债务不可偿还），可操作的科目是元审计能力（A）与合法性基座（$\|L\|$），人的生物学底座（E_c）近似为常数。

§3.2 美国：投射端扩张优先

美国的 AI 治理模式推动投射端快速扩张，同时降低制度干预频率，使技术资本时钟（τ_{cap}）维持短周期，而治理响应相对滞后。

宏观认知债务记账框架（Macro-Cognitive Accounting Framework，MCAF）按照具体行动对六变量的作用方向判断端位，不把国家、企业或个体预先归入投射端或防御端（第三章 §2.8）。在美国的 AI 治理模式中，国家行动主要推动投射端扩张，而制度层元审计没有同步加强；联邦层面长期缺乏综合性 AI 立法（Chun et al., 2024）。监管哲学是 “创新优先，出了问题再说”——翻译成时钟房间：让造钟者不受干扰地造钟，等时钟碎了再讨论要不要监管。

这一模式中，前沿能力领先构成其绩效合法性（L_{perf}）的重要来源——全球前沿 AI 能力集中在美国公司。但制度层元审计的识别与验证没有同步加强，治理响应存在时滞，已经形成的问题未能及时得到制度处理。第十七章 §6 论证的主钟通过改写 “什么算正确的经济制度” 侵蚀合法性基座的机制在此处于最活跃的状态：“监管阻碍创新” 这个叙事已经从行业立场固化为政策默认。

§3.3 欧盟：程序合法性优先

欧盟的 AI 治理模式：最大化程序合法性（L_{proc}），通过立法框架预先界定可接受的行为边界。

2024 年 8 月生效的欧盟《人工智能法案》（EU AI Act）是全球第一部综合性 AI 法规（Chun et al., 2024）——基于风险分级的监管框架，禁止若干特定用途，包括符合其法定条件的社会评分，以及原则上禁止在公共可进入空间为执法目的使用实时远程生物识别系统（后者设严格限定的例外），对高风险应用要求合规评估。翻译成时钟房间：在钟被挂上墙之前，要求造钟者证明钟经过了校准。

这一模式中，明确规则、可预测程序与责任安排构成其程序合法性的重要来源。但它面临第三章 §3.4 论证的时钟赛跑问题：立法周期（治理时钟（τ_{gov}）——欧盟《人工智能法案》（EU AI Act）从提案到生效约三年）远慢于技术扩张周期（技术资本时钟（τ_{cap}）——所引研究记录的知名模型训练计算量约每 6 个月翻倍（Rahman & Owen, 2024））。法案通过时，它试图监管的技术形态可能已经被新一代替代。

更深的问题是第一章 §4.2 论证的动态腐蚀——监管框架一旦建立，被监管方立即开始围绕框架的边界进行适应性偏移（δ）。分类系统被博弈——什么算 “高风险” 的边界成为游说的焦点。合规变成了一种可购买的服务——不是真正降低了风险，而是产出了一套读数（合规报告）使其看起来降低了风险。第九章 §4 论证的伪校准在监管层面的重演。

§3.4 中国：制度层元审计能力（A_{macro}）的直接作用

中国的 AI 治理模式：制度层元审计能力（A_{macro}）直接作用于投射端变量。

与美国的 “创新优先” 和欧盟的 “框架优先” 不同，中国的监管倾向于直接修改投射端——针对特定行为发布禁令或要求，而非建立全面框架后等待合规。2022 年以来先后生效的算法推荐管理规定、深度合成管理规定与生成式 AI 管理暂行办法（Chun et al., 2024）——每一项都是针对投射端特定变量的直接干预。

这一模式已有现实中的对应实例：《汽车车门把手安全技术要求》（GB 48001-2026）已于 2026 年 1 月 28 日发布、定于 2027 年 1 月 1 日实施。截至 2026 年 9 月 11 日该标准尚未实施——本例用于分析设计约束的制度形式，不评价其实施效果。“三条红线” 直接约束高周转开发模式的融资。算法推荐管理规定直接约束平台的分发行为——这些行为影响 Λ 所代表的传导。这些干预不通过每个个体的生物学底座（E_c）——一纸禁令的信息量极小（数百字），但它对投射端的压缩效果可以是全局性的（第三章 §3.1 论证，制度层元审计能力（A_{macro}）的有效值可以远超个体上界）。

但这一模式有自己的盲区。直接干预的有效性取决于识别速度（治理时钟的识别子过程）。门把手案例：据车质网统计，其自 2021 年 10 月起累计评测的数百款车型中，隐藏式门把手占比超过 50%，2025 年测试车型中的比例达 73.3%（李丰, 2026）。这些数据说明该设计在其评测样本中已广泛采用，但没有给出占比首次过半或监管首次识别风险的日期——本例用于说明设计扩散与标准形成之间需要制度衔接，不作为治理时钟识别迟延的测量。第一章 §4.2 的两种适应性偏移——策略性博弈和选择性适应——在干预到达之前就在重塑投射端的形态。制度层元审计能力（A_{macro}）的有效值可以远超个体上界，但它的到达时间受治理时钟约束，它的行使范围受合法性基座的授权约束，它的回溯能力受解封存量（C）的沉没成本约束。

补注：中文学界相关研究的补充与对照。上述 §3.2–3.4 的三段诊断，可以与中文学界的一组研究相互补充。

针对 §3.2 的美国部分，刘爱彬、戚凯（2025）以安全化、自由化与工具化三重逻辑拆解特朗普 2.0 的人工智能政策：以精准制裁、投资审查与制度立法持续加固安全边界（安全化），以政府统筹、资本驱动与能源配套的协同部署加快技术迭代与产业规模化扩张（自由化），以 “胡萝卜加大棒” 的条件性交易策略重塑以美国利益为核心的人工智能生态体系（工具化）。这三重逻辑与 §3.2 诊断的 “创新优先，出了问题再说” 不重叠，但指向同一个后果：§3.2 从制度识别与干预的延迟入手，看的是国家为什么未能及时响应；刘爱彬、戚凯从政策工具入手，看的是国家一面加固安全边界、一面加速产业扩张。两者指认的是同一个后果的不同生成机制——制度层元审计的识别与验证不足使治理响应存在时滞，已经形成的问题因而未能及时得到制度处理。

针对 §3.3 的欧盟部分，王叶滔（2026）对欧盟《人工智能法案》（EU AI Act）生效后的美欧互动做了跨大西洋考察，记录了布鲁塞尔效应（Brussels Effect，指欧盟凭单一市场规模单边推行监管规则、使全球商业的诸多领域实现 “欧洲化” 的能力）在人工智能领域的失灵迹象：美国企业选择性地遵循欧盟监管要求，事实上的布鲁塞尔效应影响有限；美国奉行自愿性和非约束性的监管政策，与法案具有本质差异，法律上的布鲁塞尔效应亦未出现。原因之一是这一效应赖以形成的五个条件——市场规模、监管能力、严格监管偏好、监管目标非弹性、标准不可分割性——未能同时成立：欧盟市场吸引力受美国技术垄断力掣肘，内部严格监管意愿减弱、监管能力萎缩。这补充了程序合法性跨辖区传导的条件：程序合法性在本土辖区内可以实现，越出辖区则依赖市场规模、监管能力等条件的同时成立，而人工智能领域这些条件正在衰减——它不直接测量立法周期与技术周期的相对长度。

针对 §3.4 的中国部分，有两条补足。一是褚松燕、孙幼龄（2026）以制度语法工具梳理中国人工智能伦理治理政策，提出政策规制整体上呈现 “软硬兼治，以软为主” 的特点，并展现底线规制、高线规制和过程规制 “三线并行” 的伦理规制逻辑——这说明 §3.4 所述的制度层元审计能力（A_{macro}）直接作用于投射端变量并非唯一手段，而是在以伦理导向为底色的软性规制之上，选择性地叠加直接干预。二是苗勃然、问斌（2026）梳理了欧美治理规则分化背景下中国工业人工智能受 “双向挤压” 的传导后果——在市场准入、技术研发、产业合作与标准竞争等维度上，需要同时适配取向相反的两套合规要求。这补充了企业跨法域适配的成本与可能形成的锁定效应：跨境经营使同一家企业同时面对多个法域的要求，

一国制度约束的实际效果取决于适用规则、管辖连接点与执行条件——它不直接测量国内识别迟延。

本补注只取上述四篇研究的实证与梳理发现，不连带引入其规范性主张；它们分别补充了政策工具、规则域外传导与跨法域适配的分析，不能直接作为三种时钟速度的测量。

§3.5 三种时钟的差异与共同限制

三种模式不是 “哪个更好”——是三种不同的时钟校准策略，各有盲区。

维度	美国	欧盟	中国
核心策略	最大化投射端增速	建立程序框架	直接修改投射端
优势	前沿能力领先	程序合法性高	响应到达后力度大
盲区	治理时钟的识别与验证迟延	治理时钟追不上技术时钟	识别阶段的延迟
宏观认知债务记账框架（MCAF）对应	国家行动主要作用于投射端	程序合法性（L_{proc}）的集中体现	制度层元审计能力（A_{macro}）的直接行使
各自的失效机制	叙事载荷（ϕ）改写了合法性底座（$\|L\|$）	适应性偏移腐蚀框架	识别前的沉没成本

三种取向的优势与限制既有差异，也有重叠。在一个理想的世界中，三种策略的要素可以被整合——保持前沿能力（美国的优势）、建立可预测的规则体系（欧盟的优势）、保留直接干预的制度能力（中国的优势）——但组合是否改善治理，取决于审查资源、实施能力和纠错程序。

但第十七章 §6 已论证了一个更深的障碍：全球 AI 治理的主钟由谁设定？当美国公司控制了前沿模型的能力定义、欧盟试图通过立法建立替代标准、中国通过直接干预维护自主空间——三者之间的竞争不仅是政策竞争，是时钟之间的竞争。每一方都在试图让自己的时钟成为全球校准的基准。这个竞争本身就是第一章 §4.2 映射自我引用的国际版——各方标准同时受到经验事实、利益目标与相互竞争的影响：全球治理的困难不仅在于标准不同，还在于可共同核查的事实依据与存在争议的价值排序经常混在一起；标准竞争不能因此免除外部核查，也不能仅凭利益相关性就判定核查无效。

§3.6 监管的持续性：反熵增做功

第十七章 §7 论证了金融监管是持续做功——停止的那一刻系统沿熵增方向滑回脱锚状态。AI 监管面临同样的结构。

三种模式中，持续性最受考验的是美国——因为 “创新优先” 的叙事将监管本身标记为成本而非投资。每一次监管提案都面临 “阻碍创新” 的叙事压力——这是叙事载荷的二阶导在治理层面的运作。做功被系统性地抑制。

欧盟的框架模式在持续性上有制度保障——法案生效后具有法律约束力，具体义务的分阶段适用由相应条款规定。但第一章 §4.2 的动态腐蚀意味着框架的实际效力随时间递减——被监管方的适应性偏移持续改写框架的实际含义。

中国的直接干预模式需要持续的识别和响应——制度层元审计能力（A_{macro}）必须持续做功才能跟上投射端的变化。如果做功中断——监管注意力被其他优先事项分散——系统同样滑回脱锚状态。

三种模式的共同结论：**AI 治理不是一次性的政策选择——是必须持续做功才能维持的反熵增操作。**这和第三章 §3.1 论证的元审计（A）的发育-衰退不对称特征一致：停止做功，系统便滑回依赖时钟读数的盲目自动化状态——这里的 “反熵增” 指持续监测、执行和修订对抗制度安排失效的工作，这一判断依赖具体社会机制，不由热力学定律直接推出。

---

§4 诺亚方舟与大禹治水：两种原型策略

§4.1 洪水作为共同场景

在全球文明的洪水神话中，两种应对策略构成了最鲜明的对比。

洪水在时钟房间框架中的对应是：信息洪水——投射端的读数（r）以超过防御端处理能力的速率到达。第七章 §3.3 的三区间框架中，短视频以来的媒介环境——包括 AI 生成——已处于湍流区间（由行为、神经影像与临床三类证据的方向收敛支持；序数判断，非数值测量）。人被淹没了——不是被水，是被时钟。

两种神话提供了两种截然不同的结构性应对。

§4.2 方舟策略：离散化与系统重启

诺亚方舟的结构：洪水不可阻挡。旧世界将被毁灭。解法是建造一个新容器——方舟——将需要保存的要素（成对保存；创世记叙事内部对洁净动物另有七对的记载，本节取其成对保存的结构要点）离散化提取，装入容器，等待洪水退去后在新世界中重新开始。

翻译成时钟房间：旧的时钟系统已经不可修复（所有钟都坏了，闭环自引用，纤维膨胀到全集）。解法不是修复旧系统——是建造一个新系统。从旧系统中提取核心要素（离散化——选择并保存延续所需的要素），放入新的容器中（方舟），在洪水过后重新部署。

这个策略的深层逻辑是：**连续性不可保持。**旧世界和新世界之间有一个断裂——洪水。能做的是最小化断裂中的损失（带上最重要的东西），然后在断裂之后重新开始。这是一种离散化操作——将连续的生态系统离散化为可装入容器的单元。

§4.3 治水策略：疏导与连续性

大禹治水的结构：洪水不可阻挡。但大地不会被毁灭。解法不是建造容器逃离——是在现有地形中开凿渠道（疏导），让水流入大海。

翻译成时钟房间：时钟的读数确实在以超过处理能力的速率到达（洪水）。但房间不需要被抛弃——需要在房间中开凿通道（疏导），让读数流过而不造成淹没。不是建造一个新房间——是在旧房间里打开窗户、建造排水系统、让水（信息）有地方去。

大禹的 “导” 不是消灭洪水——是给洪水一个去处。翻译成第二章 §3.1 的语言：不是消灭投射端（那不可能也不必要——金融和技术有正当的功能），是维护防御端的 “无”——给信息流留出空间，让信息经过审计再通过，而不至于淹没审计者。

这个策略的深层逻辑是：**连续性可以而且必须保持。**旧世界和治水后的世界之间没有断裂——大禹花了十三年（《史记 • 夏本纪》载 “禹伤先人父鯀功之不成受诛，乃劳身焦思，居外十三年，过家门不敢入”；另《孟子 • 滕文公上》作 “禹八年于外，三过其门而不入”，本书从《史记》），在持续的洪水中持

续做功，逐步疏导，直到水归其位。这是一种连续操作——不是将系统离散化后重启，是在系统运行的同时修改它的结构。

§4.4 两种策略在时钟房间中的结构对比

维度	方舟策略	治水策略
对洪水的判断	不可共存，必须逃离	可以共存，需要疏导
核心操作	离散化提取 + 系统重启	连续性疏导 + 持续做功
和旧世界的关系	断裂——旧世界被毁灭	连续——在旧世界中改造
时间结构	两个纪元：洪水前 / 洪水后	一个连续过程：治水中
主体的角色	受命并执行给定方案（诺亚）	受命并在实施中持续调整（大禹）
与 “凿户牖” 的结构对应	建造新容器（方舟 = 新系统）	凿户牖（在现有墙上开窗）

最关键的差异在最后一行。方舟策略对应的是建造一个全新的系统——当旧时钟系统不可修复时，设计一个新的系统取代它。在 AI 治理中，这对应的是：如果当前的 AI 基础设施不可治理，就建造一个替代基础设施（如：主权 AI、完全开源的替代模型、脱钩的技术栈）。

治水策略对应的是第二章 §3.1 的 “凿户牖”——不是建造新房间，是在现有房间的墙上打洞。在 AI 治理中，这对应的是：不放弃当前的 AI 基础设施，而是在其上施加持续的治理做功——要求透明度（在墙上开窗）、维持认知摩擦（保护 “无”）、强制校准（让时钟诚实标注偏差）。

§4.5 两种策略的时间性质

方舟策略发生在时钟维度中——它是一个离散事件（建造、装载、漂浮、着陆）。洪水前的世界和洪水后的世界是两个不连续的状态。两个状态之间通过方舟（一个有限容量的容器）联系——容器的容量决定了有多少信息能从旧世界存活到新世界。这是一次降维（第一章 §4.3 第三层）——旧世界的全部复杂性被压缩为 “方舟里装了什么”。

治水策略发生在时间维度中——它是一个连续过程（十三年的持续疏导）。不存在 “治水前的世界” 和 “治水后的世界” 的断裂——大禹在洪水中做功，洪水在做功中被疏导，两者在时间中共存。两种策略都涉及选择、损失和结构变化——治水的代价是把取舍摊入十三年持续做功，而非一次性的容器压缩。

冯 • 诺依曼的三个词全在治水策略这边。Patience——十三年是 patience。Flexibility——在洪水的形态变化中持续调整疏导策略是 flexibility。Intelligence——判断哪里该挖、哪里该堵、什么时候水的流向会变是 intelligence。方舟策略以一次集中决策与装载为关键节点——尽管建造与维持本身也是持续劳动。治水策略需要十三年不间断的日常判断与调整——以冯 • 诺依曼所说的日常判断的明智运用的方式重新出现。

§4.6 个体与制度：相似结构，不同约束

这两种神话通常被解读为制度层面的隐喻——国家应该建方舟还是应该治水。但在宏观认知债务记账框架（MCAF）中，制度层和个体层的方程结构是相同的（第三章 §3.4）——区别只在分母中是否包含生物学底座（E_c）。

在个体层面，方舟策略是："当前的信息环境不可治理——我要建造自己的信息容器。" 卸载社交媒体、使用开源工具、构建个人的知识体系。这是一种离散化操作——从信息洪水中提取自认为重要的信息，装入自己的容器，和外部信息流断开。

在个体层面，治水策略是："我不退出信息环境——我在信息环境中维持做功。" 不是不看时钟——而是在需要判断时，用自己的判断校准时钟；不是不使用 AI——而是使用 AI 之后，保留用自己的判断复核的空间。

治水策略不要求人 "等待救赎"——不是有一个外部权威（上帝、国家、某个更好的 AI）会来拯救。是每个人自己每天用阳光校准自己的时钟。元审计能力不是被一次性授予的——它需要在实践中持续做功才能维持。停止做功的那一刻，人就被洪水淹没了——不是物理的淹没，是时钟不再指向太阳。保留元审计能力，不等于要求个体重新核查每条输出——审查应按风险、证据强弱和决定的可撤销性分配，由技术提供者、使用机构和个体分别承担相应工作。

---

§5 元审计 Is All You Need

§5.1 回应 2017 年

2017 年 6 月 12 日，Vaswani 等人将 "Attention Is All You Need" 的 arXiv 首版公开（NeurIPS 2017 会议正式出版在同年末）。至本章资料截点 2026 年 9 月 11 日，已过去九年多。这篇论文引入的 Transformer（变换器）架构使得 AI 的注意力机制能够在输入序列中精确分配权重——决定 "看哪里" 和 "各看多少权重"。技术上的突破是真实的——这个架构驱动了从 GPT 到 Claude 到 Gemini 的全部前沿模型。

但 "attention" 这个词在技术语境和人类语境中的含义完全不同。技术上的注意力是时钟维度的操作——在给定的读数集合中优化权重分配。人类的注意力是时间维度的资源——生物学底座（E_c）的有限信息吞吐量在真实世界中的分配。前者可以并行化、可以扩展、可以加速。后者约为 10 bits/s（该研究的核心启示不是数值本身，而是人类有意识注意力吞吐量的极小性——约八个数量级低于感官输入速率）、不可扩展、在文明史的时间尺度上恒定（Zheng & Meister, 2025）。

Transformer（变换器）的注意力解决了一个技术问题：如何在长序列中高效分配计算资源。它没有解决——也不可能解决——一个认知问题：模型的输出和真实之间的纤维有多大。第一章 §3 的命题不因注意力权重的精妙分配而失效。更精密的权重分配使时钟更精密——但第一章 §7 论证了更精密的时钟仍然不是时间。

§5.2 从注意力到主体性

本章 §5 的标题 "元审计 Is All You Need" 不是说注意力不重要——是说注意力不够。还需要元审计。

Transformer（变换器）极其擅长 attention。它在时钟维度内把权重分配做到了极致——按它学到的相关性组合所有读数。但它没有主体性——它可以被训练去检查输出、比较依据、生成关于前提可靠性的追问；这些处理仍由提示、系统流程等给定条件触发，发生在时钟维度内——是对人的元审计的模仿，不是元审计的实例（§0：元审计属人）。这里的区分是执行预设条件触发的检查与自主决定何时审查、审查什么、是否改变原有目标。

§5.3 文明为人类而存在

所有的讨论——三层不可逆（信息缺失、动态腐蚀、本体论降维，第一章 §4）、时钟与时间、赎罪券与黑箱、金融危机与城市替代、方舟与治水——汇聚到一个判断：

文明为人类而存在，不是人类为文明服务。

技术是文明的工具——从古登堡印刷术到 Transformer（变换器）架构。金融是文明的工具——从按揭贷款到担保债务凭证（CDO）。城市是文明的工具——从修道院钟楼到摩天大楼。工具的功能是服务于人类在时间维度中的存在——帮助人类更好地校准自己对真实的理解。

当工具反过来要求人类适应工具的节奏时——当印刷术要求人接受赎罪券的叙事、当金融化要求人按 90 天的时钟管理生活、当 AI 要求人接受模型输出为真——工具和人类的关系反转了。第十八章论证的四重相互关联的不对称问题就是这个反转的金融版。§1 论证的赎罪券到黑箱是这个反转的认知版。第三十三章论证的城市时钟被替代是这个反转的空间版。

元审计用于防止工具输出取代可检查的判断。不是摧毁工具——是让工具记得自己是工具。一个钟可以极其精密、极其有用、极其不可替代——但它必须知道自己不是时间。一个模型可以极其强大、极其有用、极其不可替代——但它的输出必须标注 “这是读数，不是真实”。

§5.4 不等待救赎

方舟策略的深层逻辑是把安全寄托于一次安排——接受指令、建造、维持，安排之后的维护仍需持续判断。

治水策略的深层逻辑是持续做功——受命给出的是任务，不是完成。洪水就在眼前。任务不会自己完成。开始挖。

在 AI 治理的语境中，等待救赎的形态有很多种。等待一个 “对齐了的”AI 来提供保护——等于等一个更好的时钟来替人看太阳。等待政府出台完美的监管框架——等于等别人开窗户。等待 AI 公司自律——等于等造钟的人告知钟是不是准的。

冯 • 诺依曼 1955 年的判断（von Neumann, 1955）拒绝了所有这些等待：试图 “为当前爆炸性进步寻找自动安全的通道，最终都将受挫”。唯一可能的安全机制依赖于日常判断的明智运用——一系列小的、正确的、基于全局关照的日常判定。全局关照不是修辞，而是判定得以正确的前提。他的原话：

> What safeguard remains? Apparently only day-to-day — or perhaps year-to-year — opportunistic measures, a long sequence of small, correct decisions. And this is not surprising. After all, the crisis is due to the rapidity of progress, to the probable further acceleration thereof, and to the reaching of certain critical relationships. Specifically, the effects that we are now beginning to produce are of the same order of magnitude as that of “the great globe itself.” Indeed, they affect the earth as an entity. Hence further acceleration can no longer be absorbed as in the past by an extension of the area of operations. Under present conditions it is unreasonable to expect a novel cure-all. For progress there is no cure. Any attempt to find automatically safe channels for the present explosive variety of progress must lead to frustration. The only safety possible is relative, and it lies in an intelligent exercise of day-to-day judgment. (von Neumann, 1955)
>
> 译文：还剩下什么保障？显然只有逐日——或许逐年——的因势制宜的措施，一长串小的、正确的决定。这并不奇怪。毕竟，危机源于进步的迅猛、其可能的进一步加速，以及若干关

> 系达到临界状态。具体而言，我们现在开始产生的影响，其规模已与“地球本身”处于同一数量级。事实上，它们影响着地球这个整体。因此，进一步的加速已无法再像过去那样通过扩大行动范围来吸收。在当前条件下，指望一种全新的万灵药是不合理的。对于进步没有治愈之法。任何为当前爆炸性进步寻找自动安全通道的尝试都必将受挫。唯一可能的安全是相对的，它在于日常判断的明智运用。

本书认为，正因为危机在全球尺度上展开，这种日常判定必须基于全局关照：只盯着一段读数，每一段都显得正确；把视野放大，才能看见各段读数之间共享的、从未被质疑的前提。这也是元审计不能停留在局部的原因：逐段校验都通过的读数，作为整体仍可能依赖未经检验的共同前提。

这些日常判定须由人来承担判断责任——机器可以执行部分检查，但不能以自动检查的存在，代替对判断责任和纠错机制的安排。元审计能力和主体性之行使的维持，不是一次性的——是持续的；不是被动的——是主动的；不是在时钟维度中——而是在时间维度中。

§5.5 最终判断

2017 年到 2026 年——Transformer（变换器）诞生九年。九年间，AI 从语言模型发展为多模态系统，从研究工具发展为全球基础设施，从几亿参数发展为数万亿参数。技术资本时钟（τ_{cap}）所标记的扩张压力在这九年间持续处于月级量级——所引研究分别记录了总算力（2022 年以来）、训练计算量与摊销训练成本的快速增长，它们的观察期与统计对象不同，共同提示技术资本扩张的压力，但不构成一个在 2017–2026 年始终不变的统一迭代周期：全球 AI 算力约每 7 个月翻倍（You et al., 2026），训练计算量约每 6 个月翻倍（Rahman & Owen, 2024），摊销训练成本约以每年 2.4 倍的速度增长（Cottier et al., 2024）。

九年间，治理时钟（τ_{gov}）也在走——欧盟《人工智能法案》（EU AI Act）通过了，中国出台了多项管理规定，美国也已形成风险管理框架并提出联邦立法方案——这些安排是否提供了充分的识别、验证与执行能力，仍需分别检验。但第三章 §3.3 的基本关系没有改变：技术资本周期（τ_{cap}）短于治理周期（τ_{gov}），债务显现周期（τ_{debt}）则高度不确定且通常更长。治理在追赶。追赶的速度在加快。但追赶不是追上。

九年间，叙事载荷（ϕ）的二阶导在无声地运转。模型的默认语法——以个体为分析单元的个人主义框架、西方中心的校准基准、线性进步的历史叙事——通过全球几十亿用户的日常交互，可能经由反复使用进入使用者的问题表述与判断习惯。所有时钟显示同一个时间。不是因为校准过了——是因为所有时钟出自同一条流水线。

“Attention Is All You Need”针对的是序列建模的架构选择——本章借用它的标题提出另一个问题：在时钟维度内，注意力权重的精妙分配确实能造出更精密的时钟；但更精密的时钟仍然不是时间。

但时钟不是时间。读数不是真实。纤维不会因为权重更精密而缩小为单点。还需要另一样东西——更强的模型不自动意味着人的主体性得到保留；审计步骤可以部分自动化，但人仍须保有提出异议、检查依据和修正判断的空间。需要一个人，在时间中存在，偶尔抬头，看看窗外的太阳，然后低下头，在他面前的时钟旁边写下一行小字：

这不是时间。这是一个时钟。

写下这行字，标明的是元审计的起点——Agency is all you need。

参考文献

褚松燕、孙幼龄. (2026). 中国人工智能伦理治理的政策规制：图景与逻辑. 中国行政管理, 2026(4). https://doi.org/10.19735/j.issn.1006-0863.2026.04.04

《传习录》. 引文据《王阳明全集》隆庆初刻本.

《大学问》. 引文据《王阳明全集》隆庆初刻本.

李丰. (2026). 创新遵循安全为先 全隐藏式车门把手终被禁. 车质网, 2026-02-13. https://www.12365auto.com/zlpl/20260213/563485.shtml

刘爱彬、戚凯. (2025). 安全化、自由化与工具化：特朗普 2.0 人工智能政策及其限度. 美国问题研究, 2025 年第二辑（总第四十一辑）. 上海: 上海人民出版社.

《孟子・滕文公上》. 引文据杨伯峻《孟子译注》, 北京: 中华书局, 2008.

苗勃然、问斌. (2026). 欧美人工智能治理规则分化背景下中国工业 AI 的挑战与应对. 中国科技产业, 2026(5). https://doi.org/10.16277/j.cnki.cn11-2502/n.2026.05.026

《史记・夏本纪》. 引文据张大可注译《史记全本注译》(全九册), 北京: 中国书店, 2025.

王叶湑. (2026). 布鲁塞尔效应的边界：欧盟人工智能监管影响力的跨大西洋考察. 德国研究, 41(2). https://german-studies-online.tongji.edu.cn/c3/0e/c32445a377614/page.htm

赵鼎新. (2019). 时间、时间性与智慧：历史社会学的真谛. 社会学评论, 7(1). http://src.ruc.edu.cn/CN/abstract/abstract222.shtml Chun, J., Schroeder de Witt, C., & Elkins, K. (2024). Comparative Global AI Regulation: Policy Perspectives from the EU, China, and the US. *arXiv:2410.21279*. [预印本，尚未经同行评审] Cingari, P. (2025). Magnificent Seven Surpass EU GDP: Is This a Tech Bubble Warning? *Euronews*, October 4. https://www.euronews.com/business/2025/10/04/magnificent-seven-surpass-eu-gdp-is-this-a-tech-bubble-warning Cottier, B., Rahman, R., Fattorini, L., et al. (2024). The Rising Costs of Training Frontier AI Models. *arXiv:2405.21015*. [预印本，尚未经同行评审] Hoffman, P. T. (2015). *Why Did Europe Conquer the World?* Princeton: Princeton University Press. Hsu, F. L. K. (1971/2002). Psychosocial Homeostasis and Jen: Conceptual Tools for Advancing Psychological Anthropology. *American Anthropologist*, 73(1).

Kant, I. (1784). Beantwortung der Frage: Was ist Aufklärung? *Berlinische Monatsschrift*, December 1784. 中文译文为本书译文，据 Fordham Internet Modern History Sourcebook 英译本. https://sourcebooks.fordham.edu/mod/kant-whatis.asp MacKenzie, D. (2009). *Material Markets: How Economic Agents are Constructed*. Oxford: Oxford University Press. Rahman, R. & Owen, D. (2024). The Training Compute of Notable AI Models Has Been Doubling Roughly Every Six Months. *Epoch AI*. https://epoch.ai/data-insights/compute-trend-post-2010

Searle, J. R. (1980). Minds, Brains, and Programs. *Behavioral and Brain Sciences*, 3(3). https://doi.org/10.1017/S0140525X00005756

Tang, S. (2013). *The Social Evolution of International Politics*. Oxford: Oxford University Press. Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. In *Proceedings of NeurIPS*. arXiv:1706.03762. von Neumann, J. (1955). Can We Survive Technology? *Fortune*, June 1955. Reprinted in *Collected Works*, vol. VI. Oxford: Pergamon Press, 1963. You, J., Somala, V., Edelman, Y., & Emberson, L. (2026). Global AI Computing Capacity Is Doubling Every 7 Months. *Epoch AI*. https://epoch.ai/data-insights/ai-chip-production.

Zheng, J. & Meister, M. (2025). The Unbearable Slowness of Being: Why Do We Live at 10 bits/s? *Neuron*, 113(2). https://doi.org/10.1016/j.neuron.2024.11.008